دانشکده مهندسی کامپیوتر
دانشگاه صنعتی شریف

آمار و احتمال مهندسی

جزوه کامل درس

بر اساس اسلایدهای جلسات سوم تا بیست‌ودوم

شامل توضیحات کامل همه مباحث،
همه مثال‌ها و پرسش‌های اسلایدها
به همراه حل کامل و تمرین‌های تکمیلی حل‌شده

مدرس: دکتر امیر نجفی

زمستان ۱۴۰۴ و بهار ۱۴۰۵

فهرست مطالب

پیش‌درآمد: مرور پیش‌نیازها (جلسات اول و دوم) ۱

نظریه مجموعه‌ها ۱

اصول شمارش ۲

فضای احتمال و اصول کولموگروف ۲

۳ نتایج اصول کولموگروف، آزمایش برنولی و استقلال آماری ۴

۱.۳ مرور مباحث جلسه قبل ۴

۲.۳ نتایج بدیهی قوانین کولموگروف ۴

۳.۳ اصل شمول و عدم شمول (Inclusion–Exclusion Principle) ۵

۴.۳ کران اجتماع (Union Bound) ۶

۵.۳ محاسبه احتمال وقایع پیچیده با استفاده از احتمال وقایع پایه ۷

۱.۵.۳ فضای نمونه متناهی و وقایع پایه ۷

۶.۳ یک مثال: آزمایش برنولی تکرارشونده (Repeated Bernoulli Trials) ۸

۱.۶.۳ پدیده تمرکز ۱۰

۷.۳ استقلال آماری (Statistical Independence) ۱۱

۱.۷.۳ استقلال و هندسه رویدادها ۱۲

۸.۳ چند مثال ۱۳

۱.۸.۳ ترکیب دو یا چند عامل تصادفی با Ω محدود ۱۳

۲.۸.۳ مسئله روز تولد (Birthday Party Problem) ۱۴

۳.۸.۳ مسئله Monty Hall ۱۵

۹.۳ تمرین‌های تکمیلی ۱۶

۴ احتمال شرطی، قانون زنجیره‌ای، احتمال کل و قانون بیز ۱۸

۱.۴ احتمال شرطی (Conditional Probability) ۱۸

۲.۴ قانون زنجیره‌ای (Chain Rule) ۲۰

۱.۲.۴ حالت دوتایی و سه‌تایی ۲۰

۲.۲.۴ حالت کلی و موارد کاربردی ۲۱

۳.۴ قانون احتمال کل (The Law of Total Probability) ۲۲

۴.۴ قانون بیز (Bayes' Rule) ۲۳

۱.۴.۴ دیدگاه بیزی ۲۴

۵.۴ استقلال شرطی (Conditional Independence) . . . ۲۵
۶.۴ تمرین‌های تکمیلی . . . ۲۶

۵ مثالی از استقلال شرطی و گراف‌های تصادفی ۲۷
۱.۵ مثال از استقلال شرطی (حل مسئله دو سکه) . . . ۲۷
۱.۱.۵ یک راه‌حل (اشتباه!) . . . ۲۸
۲.۱.۵ راه‌حل صحیح . . . ۲۸
۲.۵ یک مثال از گراف‌های تصادفی: تشکیل مثلث . . . ۲۹
۳.۵ گراف‌های Erdős–Rényi و مسئله تشکیل Clique . . . ۳۱
۱.۳.۵ کران بالا با کران اجتماع . . . ۳۱
۲.۳.۵ ساده‌سازی کران . . . ۳۱
۳.۳.۵ یک تخمین عددی ساده: شبکه‌های اجتماعی . . . ۳۲
۴.۵ تمرین‌های تکمیلی . . . ۳۳

۶ متغیر تصادفی و متغیرهای تصادفی گسسته معروف ۳۴
۱.۶ متغیر تصادفی (Random Variable) ــ مقدمه . . . ۳۴
۱.۱.۶ یک مثال: مدل‌سازی آب‌وهوا . . . ۳۴
۲.۱.۶ اندازه‌گیری در فضای نمونه . . . ۳۵
۳.۱.۶ متغیر تصادفی به مثابه یک «جعبه سیاه» . . . ۳۶
۲.۶ متغیرهای تصادفی گسسته (Discrete Random Variables) . . . ۳۶
۳.۶ متغیرهای تصادفی گسسته معروف . . . ۳۷
۱.۳.۶ توزیع برنولی (Bernoulli) . . . ۳۷
۲.۳.۶ توزیع دوجمله‌ای (Binomial Distribution) . . . ۳۷
۳.۳.۶ توزیع چندجمله‌ای (Multinomial Distribution) . . . ۳۸
۴.۳.۶ توزیع پواسون (Poisson Distribution) . . . ۳۹
۵.۳.۶ خواص توزیع پواسون: حد توزیع دوجمله‌ای . . . ۳۹
۶.۳.۶ توزیع هندسی (Geometric) ــ تکمیلی . . . ۴۱
۴.۶ تمرین‌های تکمیلی . . . ۴۱

۷ متغیرهای تصادفی پیوسته، CDF و PDF ۴۲
۱.۷ متغیرهای تصادفی پیوسته . . . ۴۲
۱.۱.۷ مشکل فضای ناشمارا . . . ۴۲
۲.۱.۷ مجموعه‌ها و میدان سیگمای بورل (Borel Sets and Borel σ-Field) . . . ۴۳
۳.۱.۷ کافی بودن احتمال بازه‌ها . . . ۴۴
۲.۷ تابع توزیع انباشته (Cumulative Distribution Function) . . . ۴۴
۳.۷ تابع چگالی احتمال (Probability Density Function) . . . ۴۵
۱.۳.۷ مفهوم . . . ۴۵
۲.۳.۷ خواص و مقایسه با سایر توابع . . . ۴۶
۳.۳.۷ مفهوم گرافیکی . . . ۴۷

۴.۷ متغیرهای تصادفی پیوسته معروف ۴۷
۱.۴.۷ توزیع یکنواخت (Uniform Distribution) ۴۷
۲.۴.۷ توزیع نمایی (Exponential Distribution) ۴۸
۳.۴.۷ توزیع گاوسی یا نرمال (Gaussian or Normal Distribution) ۴۹
۴.۴.۷ توزیع لاپلاس (Laplace Distribution) ۵۰
۵.۴.۷ توزیع بتا (Beta Distribution) ۵۰
۶.۴.۷ برخی توزیع‌های کمتر کاربردی... . . . . ۵۱
۵.۷ تمرین‌های تکمیلی ۵۱

۸ تساوی‌های آماری، استقلال متغیرهای تصادفی و متغیرهای مخلوط ۵۳
۱.۸ مفهوم almost sure در آمار و احتمال ۵۳
۲.۸ استقلال متغیرهای تصادفی ۵۴
۳.۸ متغیرهای تصادفی i.i.d. ۵۵
۴.۸ رفتار دُم توزیع‌های مختلف ۵۵
۱.۴.۸ نمونه اول ۵۶
۲.۴.۸ نمونه دوم ۵۶
۳.۴.۸ نمونه سوم ۵۶
۴.۴.۸ نمونه چهارم ۵۷
۵.۸ متغیرهای تصادفی مخلوط (گسسته و پیوسته) ۵۸
۱.۵.۸ تابع دلتای دیراک ۵۸
۲.۵.۸ حل مسئله دماسنج نامطمئن ۵۹
۳.۵.۸ تبدیل PMF به PDF ۵۹
۶.۸ تمرین‌های تکمیلی ۶۰

۹ توزیع‌های شرطی، مدل‌های مخلوط، میانگین و قانون اعداد بزرگ ۶۱
۱.۹ توزیع‌های شرطی (Conditional PMF/PDF/CDF) ۶۱
۲.۹ خاصیت بی‌حافظگی (memoryless property) ۶۲
۳.۹ مدل‌های آماری مخلوط (Statistical Mixture Models) ۶۳
۴.۹ توصیف یک متغیر تصادفی ۶۴
۱.۴.۹ آماره یا Statistic ۶۴
۵.۹ میانگین (Expected Value) ۶۴
۱.۵.۹ مفهوم ۶۴
۲.۵.۹ فرمول ریاضی ۶۵
۳.۵.۹ میانگین متغیرهای تصادفی گسسته معروف ۶۵
۴.۵.۹ میانگین متغیرهای تصادفی پیوسته معروف ۶۶
۶.۹ خواص میانگین ۶۷
۷.۹ مفهوم متغیرهای تصادفی i.i.d. و قانون اعداد بزرگ (Law of Large Numbers) ۶۸
۸.۹ توزیع‌های بدون میانگین ۶۹

۹.۹ یک مثال تمرینی: سکه تصادفی با احتمال نامعلوم . . . ۷۰
۱۰.۹ تمرین‌های تکمیلی . . . ۷۱

۱۰ عملگر میانگین‌گیری، واریانس، مُد و میانه ۷۳
۱.۱۰ میانگین‌گیری یا عملگر Expectation . . . ۷۳
۲.۱۰ واریانس و انحراف معیار . . . ۷۴
۱.۲.۱۰ خواص . . . ۷۴
۳.۱۰ واریانس توزیع‌های معروف . . . ۷۶
۱.۳.۱۰ توزیع‌های برنولی، دوجمله‌ای و پواسون . . . ۷۶
۲.۳.۱۰ توزیع‌های گاوسی، نمایی و یکنواخت . . . ۷۶
۴.۱۰ واریانس جمع متغیرهای تصادفی i.i.d. . . . ۷۸
۵.۱۰ مُد و میانه (Mode and Median) . . . ۷۸
۱.۵.۱۰ مُد (Mode) . . . ۷۸
۲.۵.۱۰ میانه (Median) . . . ۷۹
۶.۱۰ تمرین‌های تکمیلی . . . ۷۹

۱۱ گشتاورها، تابع مولد گشتاور، تابع مشخصه و توابع یک متغیر تصادفی ۸۱
۱.۱۱ گشتاورهای یک توزیع (Moments of a Distribution) . . . ۸۱
۱.۱.۱۱ خواص . . . ۸۱
۲.۱.۱۱ گشتاور دوم، واریانس و Kurtosis . . . ۸۲
۲.۱۱ تابع مولد گشتاور (MGF) . . . ۸۳
۱.۲.۱۱ خواص . . . ۸۳
۲.۲.۱۱ کاربرد اصلی: تولید گشتاورها . . . ۸۳
۳.۲.۱۱ خاصیت مهم: MGF جمع متغیرهای مستقل . . . ۸۴
۴.۲.۱۱ MGF توزیع‌های مشهور . . . ۸۵
۳.۱۱ تابع مشخصه (Characteristic Function) . . . ۸۵
۱.۳.۱۱ خواص و قضیه یکتایی . . . ۸۶
۲.۳.۱۱ توابع مشخصه توزیع‌های معروف . . . ۸۶
۴.۱۱ توابعی از یک متغیر تصادفی . . . ۸۷
۱.۴.۱۱ تعریف مسئله . . . ۸۷
۲.۴.۱۱ موارد ساده . . . ۸۷
۵.۱۱ تمرین‌های تکمیلی . . . ۸۸

۱۲ توابعی از یک متغیر تصادفی و تبدیل توزیع‌ها ۹۰
۱.۱۲ یادآوری: تعریف مسئله و موارد ساده . . . ۹۰
۲.۱۲ فرمول در حالت توابع g یک‌به‌یک . . . ۹۰
۳.۱۲ فرمول کلی . . . ۹۱
۴.۱۲ بررسی و شهود ریاضیاتی . . . ۹۱
۱.۴.۱۲ توجیه گرافیکی . . . ۹۱

۲.۴.۱۲ توجیه تحلیلی . . . ۹۲
۵.۱۲ مثال . . . ۹۲
۶.۱۲ تبدیل توزیع‌های مختلف به یکدیگر . . . ۹۳
۱.۶.۱۲ تبدیل توزیع‌ها به توزیع یکنواخت . . . ۹۳
۲.۶.۱۲ تبدیل توزیع یکنواخت به سایر توزیع‌ها . . . ۹۴
۷.۱۲ چگونگی تولید اعداد تصادفی . . . ۹۴
۸.۱۲ تمرین‌های تکمیلی . . . ۹۵

۱۳ توزیع مشترک دو یا چند متغیر تصادفی ۹۶
۱.۱۳ توزیع مشترک دو متغیر تصادفی (Joint Distributions) . . . ۹۶
۱.۱.۱۳ انگیزه . . . ۹۶
۲.۱.۱۳ تعریف ریاضی . . . ۹۷
۳.۱.۱۳ نحوه استفاده . . . ۹۷
۴.۱.۱۳ توزیع انباشته حاشیه‌ای (Marginal CDF) . . . ۹۸
۲.۱۳ تابع چگالی احتمال مشترک (Joint PDF) . . . ۹۹
۳.۱۳ خواص و حاشیه‌سازی (Marginalization) . . . ۹۹
۴.۱۳ توزیع مشترک چند متغیر تصادفی . . . ۱۰۱
۱.۴.۱۳ تعریف ریاضیاتی . . . ۱۰۱
۲.۴.۱۳ تابع چگالی احتمال مشترک: تعریف و حاشیه‌سازی . . . ۱۰۲
۵.۱۳ تمرین‌های تکمیلی . . . ۱۰۲

۱۴ چگالی شرطی، میانگین شرطی و متغیرهای مشترکاً گاوسی ۱۰۴
۱.۱۴ یادآوری: توزیع مشترک چند متغیر تصادفی . . . ۱۰۴
۲.۱۴ نکته جانبی: توابعی از متغیرهای مستقل . . . ۱۰۴
۳.۱۴ توابع چگالی احتمال شرطی و قانون بیز (Bayes' Rule) . . . ۱۰۵
۱.۳.۱۴ تابع چگالی احتمال شرطی . . . ۱۰۵
۲.۳.۱۴ قانون بیز و قانون زنجیره‌ای . . . ۱۰۵
۴.۱۴ میانگین‌گیری و میانگین‌های شرطی . . . ۱۰۶
۱.۴.۱۴ میانگین . . . ۱۰۶
۲.۴.۱۴ میانگین شرطی (Conditional Expectation) . . . ۱۰۶
۵.۱۴ متغیرهای تصادفی مشترکاً گاوسی . . . ۱۰۷
۱.۵.۱۴ تعریف . . . ۱۰۷
۲.۵.۱۴ خواص . . . ۱۰۸
۶.۱۴ تمرین‌های تکمیلی . . . ۱۱۰

۱۵ توزیع‌های مشترک تکین، گشتاورهای مشترک، کوواریانس و همبستگی ۱۱۱
۱.۱۵ ادامه بحث متغیرهای مشترکاً گاوسی . . . ۱۱۱
۱.۱.۱۵ حالت حدی $|r| = 1$ . . . ۱۱۱
۲.۱.۱۵ ترکیب‌های خطی . . . ۱۱۲

۲.۱۵ توزیع‌های مشترک ترکیبی (تکینگی‌های خطی و نقطه‌ای) . . . ۱۱۲
۱.۲.۱۵ توزیع‌های مشترک جرمی . . . ۱۱۲
۲.۲.۱۵ توزیع‌های مشترک خطی . . . ۱۱۳
۳.۲.۱۵ مرتبه تکینگی (Singularity Level) . . . ۱۱۳
۳.۱۵ گشتاورهای مشترک (Joint Moments) . . . ۱۱۴
۱.۳.۱۵ خواص و ویژگی‌ها . . . ۱۱۴
۴.۱۵ کوواریانس و همبستگی آماری . . . ۱۱۵
۵.۱۵ ویژگی‌های ضریب همبستگی . . . ۱۱۵
۱.۵.۱۵ ناهمبستگی و استقلال . . . ۱۱۶
۶.۱۵ تمرین‌های تکمیلی . . . ۱۱۷

۱۶ یک تابع از دو متغیر تصادفی: توزیع جمع و کانولوشن ۱۱۸
۱.۱۶ مرور: گشتاورهای مشترک، کوواریانس و همبستگی . . . ۱۱۸
۲.۱۶ مبحث جدید: یک تابع از دو متغیر تصادفی . . . ۱۱۸
۱.۲.۱۶ فرم کلی (تعریف مسئله) . . . ۱۱۸
۳.۱۶ حالت خاص: جمع $X+Y$ در حالت گسسته . . . ۱۱۹
۱.۳.۱۶ حالت مستقل: کانولوشن گسسته . . . ۱۱۹
۴.۱۶ حالت خاص: جمع $X+Y$ در حالت پیوسته . . . ۱۲۰
۱.۴.۱۶ مرور توزیع جمع $X+Y$ (اثبات از طریق CDF) . . . ۱۲۰
۵.۱۶ مثال‌ها . . . ۱۲۱
۶.۱۶ خواص: جمع $X+Y$ برای توزیع‌های گاوسی . . . ۱۲۲
۷.۱۶ تمرین‌های تکمیلی . . . ۱۲۳

۱۷ مثال‌های معروف از $g(X,Y)$، آماره‌های ترتیبی و قضیه حد مرکزی ۱۲۵
۱.۱۷ مثال‌های معروف از $g(X,Y)$ . . . ۱۲۵
۱.۱.۱۷ توزیع کای‌دو (Chi-Square $\chi^2(k)$) با k درجه آزادی . . . ۱۲۵
۲.۱.۱۷ توزیع رایلی و توزیع نسبت (اثبات در کتاب) . . . ۱۲۶
۲.۱۷ آماره‌های ترتیبی (min, max ...) . . . ۱۲۷
۱.۲.۱۷ تابع چگالی احتمال کمینه . . . ۱۲۸
۲.۲.۱۷ تابع چگالی احتمال بیشینه . . . ۱۲۸
۳.۲.۱۷ در خانه حل کنید . . . ۱۲۸
۳.۱۷ قضیه حد مرکزی (Central Limit Theorem) . . . ۱۲۹
۱.۳.۱۷ تعاریف . . . ۱۲۹
۲.۳.۱۷ مرور قانون اعداد بزرگ . . . ۱۳۰
۳.۳.۱۷ ویژگی‌های Z_n . . . ۱۳۰
۴.۳.۱۷ محاسبه توزیع حدی Z_n . . . ۱۳۰
۵.۳.۱۷ توزیع حدی Z_n در $n \to \infty$ . . . ۱۳۱
۶.۳.۱۷ چند مثال . . . ۱۳۱

۷.۳.۱۷ تفسیر همگرایی در قضیه حد مرکزی (CLT) . . . ۱۳۲
۴.۱۷ تمرین‌های تکمیلی . . . ۱۳۳

۱۸ نامساوی‌های احتمالاتی و مقدمه‌ای بر آمار ۱۳۴
۱.۱۸ نامساوی‌های احتمالاتی (Probabilistic Inequalities) . . . ۱۳۴
۱.۱.۱۸ نامساوی مارکوف (Markov's Inequality) . . . ۱۳۴
۲.۱.۱۸ نامساوی چبیشف (Chebyshev's Inequality) . . . ۱۳۵
۲.۱۸ آمار (Statistics) . . . ۱۳۶
۱.۲.۱۸ آمار در مقابل احتمال . . . ۱۳۶
۲.۲.۱۸ توزیع‌های آماری (Statistical) در مقابل تجربی (Empirical) . . . ۱۳۷
۳.۱۸ سرفصل‌های اصلی آمار . . . ۱۳۸
۱.۳.۱۸ تخمین (Estimation) . . . ۱۳۸
۲.۳.۱۸ آزمون فرض (Hypothesis Testing) . . . ۱۳۸
۳.۳.۱۸ پیش‌بینی (Prediction) . . . ۱۳۹
۴.۱۸ بهینگی (Optimality) . . . ۱۳۹
۵.۱۸ تمرین‌های تکمیلی . . . ۱۴۰

۱۹ آمار: مفاهیم تجربی، تخمین، آزمون فرض و پیش‌بینی (تعمیق) ۱۴۱
۱.۱۹ خلاصه: آمار در مقابل احتمال . . . ۱۴۱
۲.۱۹ مفاهیم تجربی و ویژگی‌های آن‌ها . . . ۱۴۲
۱.۲.۱۹ توزیع انباشته تجربی . . . ۱۴۲
۲.۲.۱۹ هیستوگرام: تقریب تجربی چگالی . . . ۱۴۲
۳.۲.۱۹ واریانس تجربی و ضریب $\frac{1}{n-1}$ . . . ۱۴۳
۳.۱۹ تخمین (Estimation) . . . ۱۴۳
۱.۳.۱۹ تخمین نقطه‌ای . . . ۱۴۳
۲.۳.۱۹ تخمین بازه‌ای . . . ۱۴۴
۳.۳.۱۹ تخمین بیزی . . . ۱۴۴
۴.۱۹ آزمون فرض (Hypothesis Testing) . . . ۱۴۵
۵.۱۹ پیش‌بینی (Prediction) . . . ۱۴۵
۶.۱۹ بهینگی: یادآوری . . . ۱۴۶
۷.۱۹ تمرین‌های تکمیلی . . . ۱۴۶

۲۰ تخمین میانگین مربع و مقدمه تخمین نقطه‌ای ۱۴۸
۱.۲۰ تخمین میانگین مربع (Mean Square Estimation) . . . ۱۴۸
۱.۱.۲۰ تخمین‌گر میانگین مربع . . . ۱۴۸
۲.۱.۲۰ تخمین غیرشرطی (Unconditional) . . . ۱۴۸
۳.۱.۲۰ تخمین‌گر MS خطی همگن . . . ۱۴۹
۴.۱.۲۰ تخمین‌گر MS خطی غیرهمگن . . . ۱۴۹
۵.۱.۲۰ تخمین‌گر MS غیرخطی . . . ۱۵۰

۶.۱.۲۰ توزیع‌های مشترکاً گاوسی ۱۵۱
۷.۱.۲۰ تخمین‌گر MS خطی غیرهمگن (چندمتغیره) ۱۵۲
۲.۲۰ تخمین نقطه‌ای (Point Estimation) ۱۵۳
۱.۲.۲۰ مفهوم ۱۵۳
۲.۲.۲۰ گرایش (Bias)، واریانس (Variance) و سازگاری (Consistency) ۱۵۳
۳.۲.۲۰ مصالحه میان گرایش و واریانس (Bias–Variance Tradeoff) ۱۵۴
۴.۲.۲۰ انواع تخمین‌گرهای نقطه‌ای ۱۵۵
۳.۲۰ تمرین‌های تکمیلی ۱۵۶

۲۱ تخمین‌گر بیشینه درست‌نمایی (MLE) ۱۵۷
۱.۲۱ مرور: تخمین نقطه‌ای و معیارهای کیفیت ۱۵۷
۲.۲۱ ایده درست‌نمایی ۱۵۸
۱.۲.۲۱ یک مثال شهودی ۱۵۸
۲.۲.۲۱ تابع درست‌نمایی ۱۵۹
۳.۲۱ تعریف تخمین‌گر بیشینه درست‌نمایی ۱۵۹
۱.۳.۲۱ حالت گسسته (بیشینه احتمال) ۱۵۹
۲.۳.۲۱ حالت پیوسته (بیشینه چگالی احتمال) ۱۶۰
۳.۳.۲۱ تابع Log-Likelihood (LL) ۱۶۰
۴.۲۱ خواص و ویژگی‌ها ۱۶۱
۵.۲۱ مثال‌ها: بهینه‌سازی با تابع هدف مشتق‌پذیر ۱۶۲
۱.۵.۲۱ میانگین توزیع گاوسی با واریانس معلوم ۱۶۲
۲.۵.۲۱ واریانس توزیع گاوسی با میانگین معلوم ۱۶۳
۶.۲۱ خاصیت ناوردایی MLE ۱۶۵
۷.۲۱ مثال‌های بیشتر از توزیع‌های مشهور ۱۶۵
۸.۲۱ تمرین‌های تکمیلی ۱۶۷

۲۲ بیشینه درست‌نمایی: مثال‌های پیشرفته ۱۷۰
۱.۲۲ بهینه‌سازی با تابع هدف غیرمشتق‌پذیر: حدود توزیع یکنواخت ۱۷۱
۱.۱.۲۲ خواص تخمین بیشینه درست‌نمایی در این مثال ۱۷۲
۲.۱.۲۲ تخمین‌گر بی‌گرایش و سازگار برای θ ۱۷۲
۲.۲۲ بهینه‌سازی بدون جواب تحلیلی: بازیابی رشته دودویی از کانال نویزی ۱۷۴
۳.۲۲ یک مثال ساده (گسسته): یافتن تعداد کارت‌های درون یک جعبه ۱۷۵
۴.۲۲ بهینه‌سازی دومتغیره با تابع هدف مشتق‌پذیر: گاوسی با میانگین و واریانس نامعلوم ۱۷۶
۱.۴.۲۲ خواص تخمین بیشینه درست‌نمایی در این مثال ۱۷۷
۲.۴.۲۲ تخمین بدون گرایش (Unbiased) برای σ^2 . . . . . ۱۷۸
۵.۲۲ تمرین‌های تکمیلی ۱۸۰

پیش‌درآمد: مرور پیش‌نیازها (جلسات اول و دوم)

نکته. این جزوه بر اساس اسلایدهای جلسه سوم به بعد نوشته شده است. از آنجا که در جلسات بعدی مدام به مفاهیم جلسات اول و دوم (نظریه مجموعه‌ها، اصول شمارش و تعریف فضای احتمال) ارجاع داده می‌شود، در این پیش‌درآمد خلاصه‌ای کامل و خودبسنده از این پیش‌نیازها آورده‌ایم تا جزوه به تنهایی قابل مطالعه باشد.

۱. نظریه مجموعه‌ها

مجموعه گردایه‌ای از اشیای متمایز است که به آن‌ها **عضو** می‌گوییم. اگر x عضو مجموعه A باشد می‌نویسیم $x \in A$ و در غیر این صورت $x \notin A$. مجموعه‌ای که هیچ عضوی ندارد را **مجموعه تهی** می‌نامیم و با $\varnothing$ نشان می‌دهیم. اگر هر عضو A عضو B نیز باشد، می‌گوییم A زیرمجموعه B است و می‌نویسیم $A \subseteq B$.

در احتمال، همیشه یک «مجموعه مرجع» یا **فضای نمونه** Ω داریم و همه مجموعه‌ها زیرمجموعه آن هستند. عملگرهای اصلی روی مجموعه‌ها عبارت‌اند از:

- **متمم:** $A^c = \{\omega \in \Omega : \ \omega \notin A\}$.
- **اجتماع:** $A \cup B = \{\omega : \ \omega \in A \text{ or } \omega \in B\}$ (رخ دادن «A یا B»).
- **اشتراک:** $A \cap B = \{\omega : \ \omega \in A \text{ and } \omega \in B\}$ (رخ دادن «A و B»). گاهی $A \cap B$ را به صورت AB یا A, B هم می‌نویسیم.
- **تفاضل:** $A \setminus B = A \cap B^c$ (رخ دادن A بدون B).
- **ضرب دکارتی:** $A \times B = \{(a,b) : \ a \in A,\ b \in B\}$؛ برای مثال فضای نمونه پرتاب دو تاس برابر است با $\{1,\dots,6\} \times \{1,\dots,6\}$.

دو مجموعه A و B را **ناسازگار** (disjoint) گوییم اگر $A \cap B = \varnothing$؛ یعنی هیچ‌گاه هم‌زمان رخ ندهند.

قضیه ۰-۱: قوانین دمورگان

برای هر خانواده از مجموعه‌ها $\{A_i\}$:

$$\Big(\bigcup_i A_i\Big)^c = \bigcap_i A_i^c, \qquad \Big(\bigcap_i A_i\Big)^c = \bigcup_i A_i^c.$$

اثبات. $\omega \in (\bigcup_i A_i)^c$ یعنی ω در هیچ‌یک از A_iها نیست؛ یعنی برای هر i داریم $\omega \in A_i^c$؛ یعنی $\omega \in \bigcap_i A_i^c$. رابطه دوم با اعمال رابطه اول روی A_i^cها و گرفتن متمم از دو طرف به دست می‌آید. □

۲. اصول شمارش

قضیه ۰-۲: اصل ضرب

اگر انجام یک کار شامل k مرحله باشد و مرحله iام به n_i طریق (مستقل از انتخاب‌های مراحل قبل) انجام شود، کل کار به $n_1 n_2 \cdots n_k$ طریق انجام می‌شود. معادلاً $|A_1 \times \cdots \times A_k| = |A_1| \cdots |A_k|$.

- **جایگشت:** تعداد ترتیب‌های n شیء متمایز برابر $n!$ است. تعداد ترتیب‌های kتایی از n شیء برابر $\frac{n!}{(n-k)!}$ است.
- **ترکیب:** تعداد زیرمجموعه‌های kعضوی یک مجموعه nعضوی برابر است با

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}.$$

- **قضیه دوجمله‌ای:** $(x+y)^n = \sum_{k=0}^{n} \binom{n}{k} x^k y^{n-k}$؛ به‌ویژه $\sum_{k=0}^{n} \binom{n}{k} = 2^n$ که همان تعداد کل زیرمجموعه‌های یک مجموعه nعضوی است.

قضیه ۰-۳: ستاره و میله (Stars and Bars)

تعداد جواب‌های معادله $x_1 + x_2 + \cdots + x_k = n$ در اعداد صحیح نامنفی برابر است با

$$\binom{n+k-1}{k-1}.$$

اثبات. هر جواب را می‌توان با یک رشته از n ستاره و $k-1$ میله نشان داد: تعداد ستاره‌های قبل از اولین میله برابر x_1، بین میله اول و دوم برابر x_2 و ... است. برای مثال با $k=3$ و $n=5$، رشته $\star\star|\star|\star\star$ نمایانگر جواب $(2,1,2)$ است. این تناظر یک‌به‌یک است، پس کافی است تعداد راه‌های انتخاب جای $k-1$ میله از میان $n+k-1$ جایگاه را بشماریم که برابر $\binom{n+k-1}{k-1}$ است. □

قضیه ۰-۴: اصل شمول و عدم شمول برای اندازه مجموعه‌ها

برای مجموعه‌های متناهی:

$$|A \cup B| = |A| + |B| - |A \cap B|,$$

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|.$$

۳. فضای احتمال و اصول کولموگروف

تعریف ۰-۵: فضای احتمال

یک **فضای احتمال** یک سه‌تایی مرتب $(\Omega, \mathcal{F}, \mathbb{P})$ است که در آن:

- Ω **فضای نمونه**، یعنی مجموعه همه نتایج ممکن یک آزمایش تصادفی است.

- $\mathcal{F}$ یک **میدان سیگما** (σ-field) روی Ω است؛ یعنی گردایه‌ای از زیرمجموعه‌های Ω (که به آن‌ها **رویداد** یا **پیشامد** می‌گوییم) با این ویژگی‌ها: (الف) $\Omega \in \mathcal{F}$؛ (ب) اگر $A \in \mathcal{F}$ آنگاه $A^c \in \mathcal{F}$؛ (ج) اگر $A_1, A_2, \ldots \in \mathcal{F}$ آنگاه $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.
- $\mathbb{P} : \mathcal{F} \to [0,1]$ یک **اندازه احتمال** است که در اصول کولموگروف صدق می‌کند.

تعریف ۰-۶: اصول کولموگروف

تابع $\mathbb{P}$ روی $\mathcal{F}$ یک اندازه احتمال است اگر:

۱. **نامنفی بودن:** برای هر $A \in \mathcal{F}$، $\mathbb{P}(A) \geq 0$.

۲. **نرمال بودن:** $\mathbb{P}(\Omega) = 1$.

۳. **جمع‌پذیری شمارا:** برای هر دنباله از رویدادهای دوبه‌دو ناسازگار $A_1, A_2, \ldots$:

$$\mathbb{P}\Big(\bigcup_{i=1}^{\infty} A_i\Big) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

به زبان ساده، اصول کولموگروف می‌گویند $\mathbb{P}$ یک «اندازه» (measure) روی Ω است ــ مانند طول، مساحت یا تعداد اعضا ــ با این قید اضافه که اندازه کل فضا برابر ۱ باشد.

نکته. تعبیر فرکانسی احتمال. اگر آزمایشی را N بار تکرار کنیم و رویداد A در N_A بار رخ دهد، فرکانس نسبی N_A/N برای Nهای بزرگ به $\mathbb{P}(A)$ نزدیک می‌شود. فرکانس نسبی به‌وضوح نامنفی است، برای Ω برابر ۱ است و برای دو رویداد ناسازگار داریم $N_{A\cup B} = N_A + N_B$؛ پس اصول کولموگروف دقیقاً همان ویژگی‌های شهودی فرکانس نسبی هستند.

نکته. وقتی Ω متناهی یا شماراست، معمولاً $\mathcal{F} = 2^{\Omega}$ (مجموعه همه زیرمجموعه‌های Ω) انتخاب می‌شود. اگر $|\Omega| = n$ آنگاه $|2^{\Omega}| = 2^n$.

جلسه ۳

نتایج اصول کولموگروف، آزمایش برنولی و استقلال آماری

۱.۳ مرور مباحث جلسه قبل

در جلسات گذشته با سه مفهوم پایه آشنا شدیم:

- **نظریه مجموعه‌ها:** مفهوم مجموعه، عضویت، ضرب دکارتی و عملگرهایی مانند متمم، اجتماع، اشتراک و تفاضل.
- **فضای احتمال:** یک سه‌تایی مرتب $(\Omega, \mathcal{F}, \mathbb{P})$ که در آن Ω فضای نمونه، $\mathcal{F}$ یک میدان سیگما (σ-field) روی Ω و بیانگر فضای رخدادها، و $\mathbb{P}$ یک اندازه احتمال از $\mathcal{F}$ به بازه $[0,1]$ است.
- **قوانین کولموگروف (Kolmogorov's Principles):** این قوانین به زبان ساده بیان می‌کنند که $\mathbb{P}$ یک اندازه (measure) روی Ω است، با این شرط که $\mathbb{P}(\Omega) = 1$.

۲.۳ نتایج بدیهی قوانین کولموگروف

تابع احتمال $\mathbb{P}$ صرفاً یک اندازه تعریف‌شده روی مجموعه Ω است، با این قید اضافی که $\mathbb{P}(\Omega)$ باید برابر ۱ شود. با استفاده از قضیه دمورگان و عملیات ساده روی مجموعه‌ها، می‌توان نتایج زیر را به دست آورد.

قضیه ۳-۱: احتمال متمم و تهی

برای هر $A \in \mathcal{F}$:

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \qquad \mathbb{P}(\varnothing) = 0.$$

اثبات. A و A^c ناسازگارند و $A \cup A^c = \Omega$. پس طبق اصل جمع‌پذیری و نرمال بودن: $1 = \mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c)$، که نتیجه می‌دهد $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$. با قرار دادن $A = \Omega$ و توجه به $\Omega^c = \varnothing$ داریم $\mathbb{P}(\varnothing) = 1 - 1 = 0$. □

قضیه ۳-۲: یکنوایی

اگر $A \subseteq B$ آنگاه $\mathbb{P}(A) \leq \mathbb{P}(B)$. به‌ویژه برای هر رویداد $0 \leq \mathbb{P}(A) \leq 1$.

اثبات. $B = A \cup (B \setminus A)$ و این دو مجموعه ناسازگارند. پس $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A)$ زیرا $\mathbb{P}(B \setminus A) \geq 0$. □

نکته. اصل اول کولموگروف، یعنی جمع‌پذیری احتمال تحت اجتماع شمارای مجموعه‌های ناسازگار، را پیش‌تر (جلسه قبل) به صورت شهودی و با تعریف «فرکانس نسبی رخدادها» برای احتمال نیز دیده بودیم.

۳.۳ اصل شمول و عدم شمول (Inclusion–Exclusion Principle)

در جلسه قبل این اصل را در مورد اندازه (کاردینالیته) مجموعه‌ها دیده بودیم. همین اصل در مورد احتمال (یا هر اندازه یا measure دیگری) نیز برقرار است.

قضیه ۳-۳: حالت دو و سه رویداد

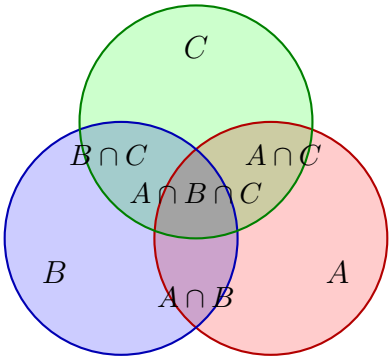
$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B),$$

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) + \mathbb{P}(A \cap B \cap C).$$

اثبات. $A \cup B$ را به سه قطعه ناسازگار $A \setminus B$، $A \cap B$ و $B \setminus A$ افراز می‌کنیم. چون $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ و $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

برای سه رویداد، رابطه دوتایی را برای $A \cup B$ و C به کار می‌بریم: $\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A \cup B) + \mathbb{P}(C) - \mathbb{P}\big((A \cap C) \cup (B \cap C)\big)$ و با بسط دوباره دو جمله اول و آخر (و توجه به $(A \cap C) \cap (B \cap C) = A \cap B \cap C$) رابطه به دست می‌آید. □



شکل ۱.۳: نمودار ون سه رویداد: در جمع $\mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$ نواحی دوتایی دو بار و ناحیه سه‌تایی سه بار شمرده می‌شوند؛ با کم کردن اشتراک‌های دوتایی، ناحیه سه‌تایی صفر بار شمرده می‌شود و باید دوباره اضافه شود.

قضیه ۳-۴: اصل شمول و عدم شمول ـ حالت کلی

برای هر n رویداد $E_1, \dots, E_n$:

$$\mathbb{P}\Big(\bigcup_{i=1}^{n} E_i\Big) = \sum_{i=1}^{n} \mathbb{P}(E_i) - \sum_{i<j} \mathbb{P}(E_i \cap E_j) + \sum_{i<j<k} \mathbb{P}(E_i \cap E_j \cap E_k)$$
$$- \cdots + (-1)^{\ell+1} \sum_{i_1<i_2<\cdots<i_\ell} \mathbb{P}\Big(\bigcap_{r=1}^{\ell} E_{i_r}\Big) + \cdots$$

که آخرین جمله آن $(-1)^{n+1}\mathbb{P}(E_1 \cap \cdots \cap E_n)$ است.

ایده اثبات. فرض کنید ω نقطه‌ای است که دقیقاً در $m \geq 1$ تا از E_iها قرار دارد. سهم این نقطه در جمع‌های طرف راست برابر است با $\binom{m}{1} - \binom{m}{2} + \binom{m}{3} - \cdots \pm \binom{m}{m} = 1 - (1-1)^m = 1$. پس هر نقطه از اجتماع دقیقاً یک بار شمرده می‌شود و نقاط بیرون از اجتماع اصلاً شمرده نمی‌شوند. □

۴.۳ کران اجتماع (Union Bound)

یک نامساوی بسیار کاربردی و نتیجه مستقیم اصل شمول و عدم شمول، کران اجتماع است که برای کران‌دار کردن احتمال اجتماع تعدادی واقعه به کار می‌رود.

قضیه ۳-۵: کران اجتماع یا نامساوی بول

برای هر دنباله از رویدادها (نه لزوماً ناسازگار):

$$\mathbb{P}\Big(\bigcup_{i=1}^{\infty} E_i\Big) \leq \sum_{i=1}^{\infty} \mathbb{P}(E_i).$$

اثبات. رویدادهای ناسازگار $F_1 = E_1$ و $F_i = E_i \setminus (E_1 \cup \cdots \cup E_{i-1})$ را تعریف می‌کنیم. اجتماع F_iها با اجتماع E_iها برابر است و $F_i \subseteq E_i$. پس طبق جمع‌پذیری و یکنوایی:

$$\mathbb{P}\Big(\bigcup_i E_i\Big) = \mathbb{P}\Big(\bigcup_i F_i\Big) = \sum_i \mathbb{P}(F_i) \leq \sum_i \mathbb{P}(E_i).$$

□

نکته. تساوی در کران اجتماع زمانی برقرار است که رویدادها (با احتمال یک) دوبه‌دو ناسازگار باشند. هرچه هم‌پوشانی رویدادها بیشتر باشد، این کران «شل‌تر» است.

مثال ۳-۶: پزشک یا پولدار

فرض کنید احتمال اینکه فردی در جامعه پزشک شود ۵٪، و احتمال اینکه شخصی پولدار شود ۱۵٪ باشد. در این صورت، احتمال اینکه شخصی یا پزشک شود، یا پولدار چقدر است؟

حل. رویداد پزشک شدن را D و پولدار شدن را R بنامید. از اصل شمول و عدم شمول $\mathbb{P}(D \cup R) = 0.05 + 0.15 - \mathbb{P}(D \cap R)$. چون $\mathbb{P}(D \cap R)$ را نمی‌دانیم، احتمال خواسته‌شده دقیقاً قابل محاسبه

نیست. **تنها جواب ممکن با داده‌های مسئله** از کران اجتماع به دست می‌آید:

$$\mathbb{P}(D \cup R) \le \mathbb{P}(D) + \mathbb{P}(R) = 0.20.$$

تساوی وقتی است که هیچ پزشکی پولدار نباشد ($\mathbb{P}(D \cap R) = 0$). در طرف دیگر، چون $R \subseteq D \cup R$، داریم $\mathbb{P}(D \cup R) \ge \max(0.05, 0.15) = 0.15$ (حالتی که همه پزشک‌ها پولدار باشند). پس در مجموع $0.15 \le \mathbb{P}(D \cup R) \le 0.20$. ■

۵.۳ محاسبه احتمال وقایع پیچیده با استفاده از احتمال وقایع پایه

۱.۵.۳ فضای نمونه متناهی و وقایع پایه

تعریف ۳-۷: وقایع پایه

به وقایعی مانند $\{\omega\}$ برای $\omega \in \Omega$ (مجموعه‌های تک‌عضوی)، «وقایع پایه» یا رویدادهای ساده اطلاق می‌گردد.

در صورتی که فضای Ω متناهی باشد، احتمال تمامی وقایعی که در $\mathcal{F} = 2^{\Omega}$ ظاهر می‌شوند را می‌توان با استفاده از اصل جمع‌پذیری احتمال تحت اجتماع به دست آورد. یعنی هر رویداد $E = \{\omega_1, \dots, \omega_n\}$ اجتماعی از وقایع پایه ناسازگار است و

$$\mathbb{P}\Big(E = \bigcup_{i=1}^{n} \{\omega_i\}\Big) = \sum_{i=1}^{n} \mathbb{P}\big(\{\omega_i\}\big).$$

لذا برای مشخص کردن کامل اندازه احتمال، صرفاً به مقادیر احتمال وقایع پایه نیازمندیم.

تعریف ۳-۸: تابع جرم احتمال (PMF)

به تابعی که احتمال وقایع پایه را به بازه $[0, 1]$ می‌نگارد، «تابع جرم احتمال» یا Probability Mass Function (PMF) می‌گوییم:

$$p : \Omega \to [0, 1], \qquad p(\omega) = \mathbb{P}(\{\omega\}).$$

برخلاف تابع احتمال $\mathbb{P}$ (تابع اندازه احتمال) که روی رویدادها تعریف می‌شود، برای p داریم:

$$\sum_{\omega \in \Omega} p(\omega) = 1.$$

نکته. کار کردن با p بسیار راحت‌تر از $\mathbb{P}$ است: دامنه p صرفاً $|\Omega|$ عضو دارد، در حالی که دامنه تابع اندازه احتمال $\mathbb{P}$ شامل $2^{|\Omega|}$ عضو است. برای مثال اگر $|\Omega| = 10$، کافی است ۱۰ عدد (در واقع ۹ عدد، چون مجموعشان باید ۱ شود) را بدانیم تا احتمال همه $2^{10} = 1024$ رویداد مشخص شود.

نکته. حالت هم‌احتمال. اگر همه نتایج هم‌احتمال باشند، $p(\omega) = 1/|\Omega|$ و برای هر رویداد $\mathbb{P}(E) = \frac{|E|}{|\Omega|}$. در این حالت محاسبه احتمال به یک مسئله **شمارشی** تبدیل می‌شود.

۶.۳ یک مثال: آزمایش برنولی تکرارشونده (Repeated Bernoulli Trials)

یک سکه متقارن یا fair را در نظر بگیرید که احتمال شیر (H) یا خط (T) آمدن آن برابر $\frac{1}{2}$ باشد. فرض کنید این سکه را n بار می‌اندازیم، به طوری که هر پرتاب «بی‌ربط» به نتیجه پرتاب‌های قبل و بعد از خود باشد. بعداً به این کار پرتاب‌های **مستقل** خواهیم گفت. به یک بار انجام کل این n پرتاب، یک **آزمون** یا experiment می‌گوییم.

واضح است که با هر بار انجام آزمون، یکی از 2^n نتیجه ممکن زیر احتمال وقوع دارند:

$$\begin{aligned} &1) \quad HHH\ldots HHH \\ &2) \quad HHH\ldots HHT \\ &3) \quad HHH\ldots HTH \\ &4) \quad HHH\ldots HTT \\ &\vdots \qquad\quad \vdots \\ &2^n) \quad TTT\ldots TTT \end{aligned}$$

پرسش: چرا تمامی این 2^n حالت هم‌احتمال هستند؟

پاسخ. هر دنباله مشخص، مثلاً $HTH\ldots$، یعنی نتیجه پرتاب اول یک مقدار مشخص، نتیجه پرتاب دوم یک مقدار مشخص و ... باشد. چون هر پرتاب جداگانه با احتمال $\frac{1}{2}$ هر یک از دو حالت را می‌دهد و پرتاب‌ها بر هم اثری ندارند (استقلال؛ بخش ۷.۳)، احتمال هر دنباله مشخص برابر $\frac{1}{2}\times\frac{1}{2}\times\cdots\times\frac{1}{2} = 2^{-n}$ است که به خود دنباله بستگی ندارد. به بیان دیگر، تقارن سکه باعث می‌شود جابه‌جا کردن H و T در هر جایگاه احتمال را تغییر ندهد؛ پس همه دنباله‌ها هم‌ارزند.

دقت کنید:

- هر یک از این 2^n حالت، یک عضو از **فضای نمونه** Ω هستند: $\Omega = \{H,T\}^n$ و $|\Omega| = 2^n$.
- فضای رخدادها یا $\mathcal{F}$ شامل 2^{2^n} عضو است، که شامل تمام زیرمجموعه‌های ممکن Ω (از جمله خود Ω و $\varnothing$) است.
- تابع جرم احتمال (PMF) در این مسئله به هر یک از این 2^n عضو Ω احتمال 2^{-n} را خواهد داد، تا جمع احتمالات ۱ شود.
- در نتیجه، محاسبه احتمال هر رخداد (هر عضو $\mathcal{F}$) در این مسئله، تبدیل به یک مسئله **شمارشی** (combinatorial) می‌شود.

مثال ۳-۹: احتمال دقیقاً k شیر

احتمال اینکه در یک آزمون، رشته‌ای ظاهر شود که دقیقاً شامل k عدد شیر باشد چقدر است؟ (برای $0 \le k \le n$)

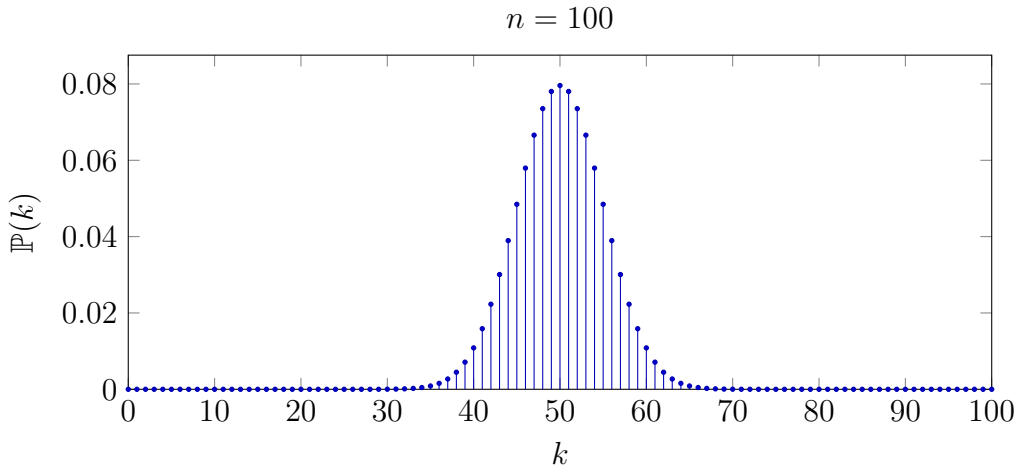
حل. طبق قوانین کولموگروف، تمام خروجی‌هایی که این اتفاق در آن‌ها رخ داده را باید در نظر بگیریم، و سپس چون این خروجی‌ها **اشتراکی ندارند** (وقایع پایه متمایز همیشه ناسازگارند)، احتمال هر یک را با هم جمع کنیم. تعداد رشته‌های به طول n با دقیقاً k شیر برابر تعداد راه‌های انتخاب k جایگاه از n جایگاه برای H است، یعنی $\binom{n}{k}$. هر کدام احتمال 2^{-n} دارند؛ پس:

$$\mathbb{P}(\text{having } k \text{ heads}) = \frac{1}{2^n}\binom{n}{k}.$$

■

دقت کنید که جمع این احتمالات برای همه مقادیر k برابر ۱ است (همان‌طور که باید باشد، چون رویدادهای $\{k=0\}, \dots, \{k=n\}$ یک افراز از Ω هستند). با استفاده از قضیه دوجمله‌ای:

$$\mathbb{P}(k=0) + \cdots + \mathbb{P}(k=n) = \sum_{k=0}^{n} \binom{n}{k} 2^{-n} = 2^{-n}(1+1)^n = 1.$$



شکل ۲.۳: احتمال مشاهده دقیقاً k شیر در $n = 100$ پرتاب سکه سالم. بیشینه در $k = 50$ و برابر حدود 0.0796 است.

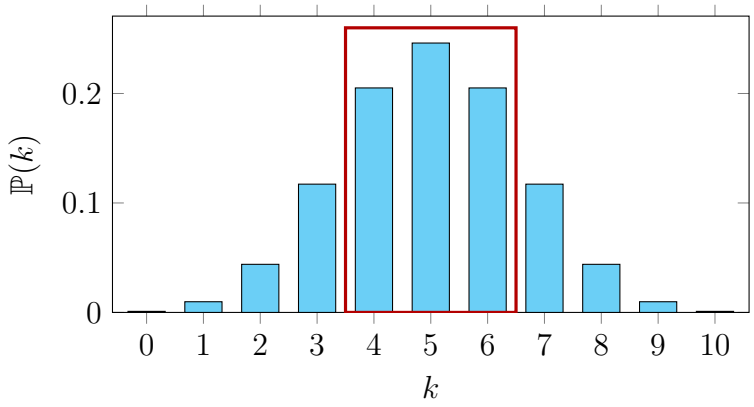
مثال ۳-۱۰: تعداد شیر بین ۴ و ۶

فرض کنید که $n = 10$ باشد. احتمال اینکه تعداد شیرهای ظاهر شده در یک آزمون، عددی بین ۴ تا ۶ باشد چقدر است؟

حل. با توجه به ناسازگاری سه رخداد $\{k=4\}$، $\{k=5\}$ و $\{k=6\}$ داریم:

$$\mathbb{P}(4 \le k \le 6) = \sum_{k=4}^{6} \binom{10}{k} 2^{-10} = \frac{210 + 252 + 210}{1024} = \frac{672}{1024} = 0.65625 \simeq 0.66.$$

■



شکل ۳.۳: توزیع تعداد شیرها برای $n = 10$. مستطیل قرمز رویداد $4 \le k \le 6$ را نشان می‌دهد.

مثال ۳-۱۱: دور شدن از میانگین

اگر $n = 100$ باشد، احتمال اینکه تعداد شیرهای ظاهرشده در یک آزمایش از ۴۰ کمتر ($k < 40$)، و یا از ۶۰ بیشتر ($k > 60$) باشند، چقدر است؟ با فرض $n = 1000$، سؤال بالا در مورد $k < 400$ و $k > 600$ چه تفاوتی می‌کند؟

حل. برای $n = 100$: دو رویداد $\{k < 40\}$ و $\{k > 60\}$ ناسازگارند؛ پس

$$\mathbb{P}(k < 40 \cup k > 60) = \sum_{k=0}^{39} \binom{100}{k} 2^{-100} + \sum_{k=61}^{100} \binom{100}{k} 2^{-100} = 1 - \sum_{k=40}^{60} \binom{100}{k} 2^{-100} \simeq 0.035.$$

برای $n = 1000$: به همین ترتیب

$$\mathbb{P}(k < 400 \ \cup \ k > 600) = 1 - \sum_{k=400}^{600} \binom{1000}{k} 2^{-1000} \simeq 2 \times 10^{-10}.$$

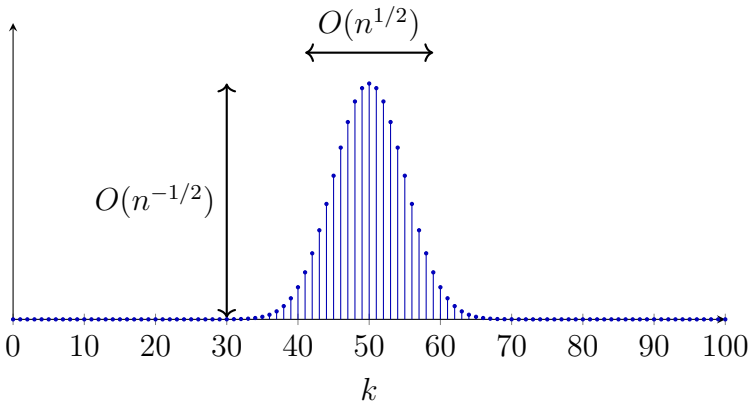
در هر دو حالت از ناحیه «۱۰٪ دورتر از نصف» صحبت می‌کنیم، اما با ده برابر شدن n احتمال آن از حدود ۵٫۳٪ به حدود دو ده‌میلیاردم کاهش یافته است! ■

۱.۶.۳ پدیده تمرکز

نتیجه مثال قبل یک پدیده مهم را نشان می‌دهد: با افزایش n، توزیع تعداد شیرها حول $n/2$ «متمرکز» می‌شود. در شکل ۲.۳ عرض ناحیه‌ای که تقریباً تمام جرم احتمال در آن قرار دارد از مرتبه $O(n^{1/2})$ است، در حالی که کل بازه ممکن طولی برابر n دارد؛ و ارتفاع قله از مرتبه $O(n^{-1/2})$ است. در واقع با استفاده از تقریب استرلینگ $m! \approx \sqrt{2\pi m}\,(m/e)^m$:

$$\mathbb{P}(k = n/2) = \binom{n}{n/2} 2^{-n} \approx \sqrt{\frac{2}{\pi n}},$$

که برای $n = 100$ مقدار 0.0798 را می‌دهد (مقدار دقیق 0.0796).



بنابراین **نسبت** شیرها k/n با افزایش n با احتمال بسیار زیاد به $\frac{1}{2}$ نزدیک می‌شود. این پدیده پیش‌درآمدی بر «قانون اعداد بزرگ» است که در جلسات آینده به‌طور دقیق خواهیم دید.

۷.۳ استقلال آماری (Statistical Independence)

تعریف ۳-۱۲: استقلال دو رویداد

با توجه به یک فضای نمونه مرکب، دو واقعه E_1 و E_2 را مستقل از یکدیگر می‌نامیم، اگر و تنها اگر

$$\mathbb{P}(E_1 \cap E_2) = \mathbb{P}(E_1) \times \mathbb{P}(E_2).$$

برای مثال:

- در صورت پرتاب یک تاس شش‌وجهی و مدل‌سازی تصادفی آن، دو رویداد **فرد** و یا **زوج** آمدن **نمی‌توانند** از یکدیگر مستقل باشند: $\mathbb{P}(\text{odd}\cap\text{even}) = \mathbb{P}(\varnothing) = 0$ در حالی که $\mathbb{P}(\text{even})\mathbb{P}(\text{odd}) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4} \neq 0$. شهوداً دانستن فرد بودن، کاملاً مشخص می‌کند که عدد زوج نیست.
- اما در صورت پرتاب دو تاس پشت سر هم، و با فرض مستقل بودن نتایج آنان، تمام رویدادهای مرتبط با پرتاب اول از تمامی رویدادهای متناظر با پرتاب دوم مستقل می‌شوند.

پرسش: وجود رابطه ضرب در احتمال وقایع مستقل، در ارتباط تنگاتنگ با اصل ضرب است. چرا؟

پاسخ. فرض کنید آزمایش مرکب از دو آزمایش با فضاهای نمونه متناهی Ω_1 و Ω_2 باشد و همه $|\Omega_1||\Omega_2|$ نتیجه در $\Omega = \Omega_1 \times \Omega_2$ هم‌احتمال باشند (مانند دو تاس). رویداد A فقط به آزمایش اول و B فقط به آزمایش دوم مربوط است؛ یعنی $A = A_1 \times \Omega_2$ و $B = \Omega_1 \times B_2$. آنگاه $A \cap B = A_1 \times B_2$ و طبق **اصل ضرب** $|A_1 \times B_2| = |A_1|\,|B_2|$. پس

$$\mathbb{P}(A \cap B) = \frac{|A_1||B_2|}{|\Omega_1||\Omega_2|} = \frac{|A_1|}{|\Omega_1|} \cdot \frac{|B_2|}{|\Omega_2|} = \mathbb{P}(A)\mathbb{P}(B).$$

یعنی قاعده ضرب احتمال‌ها، همان اصل ضرب شمارش است که بر حسب «کسرها» نوشته شده است: وقتی انتخاب در مرحله دوم به انتخاب مرحله اول بستگی ندارد، تعداد حالت‌ها و در نتیجه احتمال‌ها در هم ضرب می‌شوند.

مثال ۳-۱۳: حزب سیاسی و علاقه به پاستا

یک پژوهشگر در ایالات متحده قصد داشته بداند میزان دموکرات/جمهوری‌خواه بودن مردم جامعه، چقدر به علاقه آن‌ها به پاستا ارتباط دارد! با مطالعه روی یک جامعه آماری بزرگ (فرض کنید بی‌نهایت نفر) به احتمالات زیر رسیده است:

	جمهوری‌خواه	دموکرات
پاستا دوست ندارد	0.08	0.12
پاستا دوست دارد	0.32	0.48

آیا این دو ویژگی از یکدیگر مستقل هستند؟

حل. ابتدا احتمال‌های حاشیه‌ای را با جمع سطرها و ستون‌ها حساب می‌کنیم (قانون جمع‌پذیری؛ هر ستون، اجتماع دو خانه ناسازگار است):

$$\mathbb{P}(\text{Rep}) = 0.08 + 0.32 = 0.4, \quad \mathbb{P}(\text{Dem}) = 0.12 + 0.48 = 0.6,$$

$$\mathbb{P}(\text{Pasta}) = 0.32 + 0.48 = 0.8, \quad \mathbb{P}(\text{pasta No}) = 0.08 + 0.12 = 0.2.$$

حال هر خانه جدول را با حاصل‌ضرب احتمال‌های حاشیه‌ای مقایسه می‌کنیم:

$$0.4 \times 0.2 = 0.08, \quad 0.6 \times 0.2 = 0.12, \quad 0.4 \times 0.8 = 0.32, \quad 0.6 \times 0.8 = 0.48.$$

هر چهار خانه دقیقاً برابر حاصل‌ضرب حاشیه‌ها هستند؛ پس این دو ویژگی **مستقل**اند: دانستن حزب یک فرد هیچ اطلاعی درباره علاقه او به پاستا نمی‌دهد (در هر دو حزب ۸۰٪ پاستا دوست دارند). ■

نکته. در یک جدول 2×2، اگر یکی از خانه‌ها در شرط استقلال صدق کند، سه خانه دیگر خودبه‌خود صدق می‌کنند (به تمرین ۹.۳ نگاه کنید). در جدول‌های بزرگ‌تر باید همه خانه‌ها را بررسی کرد.

۱.۷.۳ استقلال و هندسه رویدادها

قضیه ۳-۱۴: چند ویژگی ساده

۱. اگر دو رویداد ناسازگار (disjoint) باشند، قطعاً مستقل نیستند؛ مگر اینکه یکی از آن‌ها (احتمال) تهی باشد.

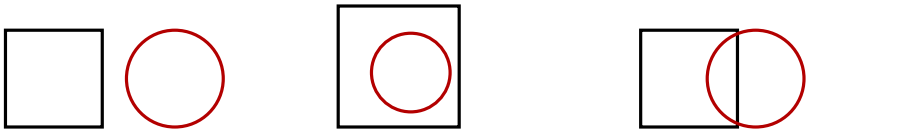
۲. اگر یک رویداد زیرمجموعه دیگری باشد، قطعاً مستقل نیستند؛ مگر اینکه یکی تهی یا خود Ω باشد (احتمال ۰ یا ۱ داشته باشد).

۳. هر رویدادی از $\varnothing$ و Ω مستقل است.

۴. دو رویدادی که قدری اشتراک و قدری عدم اشتراک دارند، می‌توانند مستقل باشند و می‌توانند

نباشند؛ باید رابطه را چک کرد.

اثبات. (۱) اگر $A\cap B=\varnothing$ آنگاه $\mathbb{P}(A\cap B)=0$؛ پس استقلال یعنی $\mathbb{P}(A)\mathbb{P}(B)=0$، یعنی یکی از دو احتمال صفر است. (۲) اگر $A\subseteq B$ آنگاه $A\cap B=A$؛ پس استقلال یعنی $\mathbb{P}(A)=\mathbb{P}(A)\mathbb{P}(B)$، یعنی $\mathbb{P}(A)=0$ یا $\mathbb{P}(B)=1$. (۳) $\mathbb{P}(A\cap\varnothing)=0=\mathbb{P}(A)\cdot 0$ و $\mathbb{P}(A\cap\Omega)=\mathbb{P}(A)=\mathbb{P}(A)\cdot 1$. (۴) با یک تاس سالم: اگر $A=\{1,2\}$ و $B=\{2,3,4\}$ آنگاه $\mathbb{P}(A\cap B)=\frac{1}{6}=\frac{1}{3}\cdot\frac{1}{2}$، پس مستقل‌اند. اما اگر $A=\{1,2\}$ و $B=\{2,3\}$ آنگاه $\mathbb{P}(A\cap B)=\frac{1}{6}\neq\frac{1}{3}\cdot\frac{1}{3}$، پس مستقل نیستند. □



شود چک باید جزئی: هم‌پوشانی وابسته زیرمجموعه: وابسته ناسازگار:

دقت کنید! «ناسازگار» و «مستقل» دو مفهوم کاملاً متفاوت‌اند و نباید آن‌ها را با هم اشتباه گرفت. ناسازگاری یک ویژگی **مجموعه‌ای** است (اشتراک تهی)، اما استقلال یک ویژگی **عددی** وابسته به اندازه احتمال است. در واقع دو رویداد ناسازگار با احتمال مثبت، به شدت وابسته‌اند: رخ دادن یکی، رخ ندادن دیگری را تضمین می‌کند.

تعریف ۳-۱۵: استقلال چند رویداد

رویدادهای $E_1,\dots,E_n$ را **(به طور متقابل) مستقل** گوییم اگر برای هر زیرمجموعه از اندیس‌ها $\{i_1<\cdots<i_\ell\}$ داشته باشیم

$$\mathbb{P}(E_{i_1}\cap\cdots\cap E_{i_\ell})=\mathbb{P}(E_{i_1})\cdots\mathbb{P}(E_{i_\ell}).$$

دقت کنید! استقلال دوبه‌دو، استقلال متقابل را نتیجه نمی‌دهد. مثال: دو سکه سالم را مستقل پرتاب کنید و قرار دهید A=«سکه اول شیر»، B=«سکه دوم شیر» و C=«دو سکه یکسان». هر سه احتمال $\frac{1}{2}$ دارند و هر دوتا از آن‌ها احتمال اشتراک $\frac{1}{4}$ دارند (پس دوبه‌دو مستقل‌اند)، اما $\mathbb{P}(A\cap B\cap C)=\mathbb{P}(HH)=\frac{1}{4}\neq\frac{1}{8}$.

۸.۳ چند مثال

۱.۸.۳ ترکیب دو یا چند عامل تصادفی با Ω محدود

مثال ۳-۱۶: مجموع سه تاس

یک تاس تصادفی و کاملاً متقارن را سه بار پشت سر هم می‌اندازیم. فرض کنید که پرتاب‌ها از یکدیگر مستقل هستند. احتمال اینکه جمع اعداد ظاهرشده برابر با ۸ شود چقدر است؟

حل. سه بار پرتاب یک تاس تصادفی:

$$\Omega=\{1,2,\dots,6\}^3=\{(1,1,1),\dots,(6,6,6)\},\qquad \mathcal{F}=2^\Omega,\qquad |\Omega|=216.$$

به واسطه تقارن تاس $P(1)=P(2)=\cdots=P(6)=\frac{1}{6}$ و به واسطه استقلال آماری پرتاب‌ها

$$P(i,j,k)=\frac{1}{6}\times\frac{1}{6}\times\frac{1}{6}=\frac{1}{216},\qquad \forall\, i,j,k\in\{1,\dots,6\}.$$

پس همه حالات هم‌احتمال هستند و با یک مسئله شمارش یا ترکیبیات روبه‌رو هستیم. اگر اعداد ظاهرشده برای سه تاس را به ترتیب با A، B و C نشان دهیم، به دنبال یافتن تعداد جواب‌های مسئله زیر هستیم:

$$A+B+C=8,\qquad A,B,C\in\{1,2,\dots,6\}.$$

چرا این مسئله با مسئله زیر معادل است؟

$$A'+B'+C'=5,\qquad A',B',C'\in\mathbb{Z}_{\geq 0}.$$

با تغییر متغیر $A'=A-1$، $B'=B-1$ و $C'=C-1$، شرط $A\geq 1$ به $A'\geq 0$ تبدیل می‌شود و مجموع به $8-3=5$ می‌رسد. این تغییر متغیر یک تناظر یک‌به‌یک بین جواب‌های دو مسئله است. اما شرط $A\leq 6$ (یعنی $A'\leq 5$) چه می‌شود؟ چون مجموع سه عدد نامنفی برابر ۵ است، هیچ‌کدام نمی‌تواند از ۵ بیشتر شود؛ پس قید بالایی خودبه‌خود برقرار است و می‌توان آن را کنار گذاشت.
جواب مسئله دوم را از جلسه اول (قضیه ستاره و میله) می‌دانیم: $\binom{5+3-1}{3-1}=\binom{7}{2}=21$. پس **جواب نهایی**:

$$P=\frac{1}{6^3}\binom{7}{2}=\frac{21}{216}\simeq 0.0972.$$

■

نکته. اگر مجموع مورد نظر مثلاً ۱۰ بود، تغییر متغیر به $A'+B'+C'=7$ می‌رسید و این بار ممکن بود یکی از متغیرها از ۵ بیشتر شود (مثل $A'=7$)؛ آنگاه باید حالت‌های نامعتبر را با اصل شمول و عدم شمول کم کنیم: $\binom{9}{2}-3\binom{3}{2}=36-9=27$، پس $\mathbb{P}(\text{sum}=10)=27/216=0.125$.

۲.۸.۳ مسئله روز تولد (Birthday Party Problem)

مثال ۳-۱۷: پارادوکس روز تولد

در یک جمع n نفره از افراد مستقل و تصادفی، احتمال اینکه هیچ دو نفری روز تولد یکسان نداشته باشند چقدر است؟ (فرض: سال ۳۶۵ روز دارد و روز تولد هر فرد با احتمال یکسان هر یک از این روزهاست.)

حل. افراد را به ترتیب در نظر می‌گیریم و رویداد E_i را «روز تولد نفر iام با هیچ‌یک از نفرات قبلی یکی نباشد» تعریف می‌کنیم.

- احتمال اینکه روز تولد نفر دوم با اولی یکی نباشد: $P(E_2)=1-\frac{1}{365}$.
- احتمال اینکه روز تولد نفر سوم با اولی و دومی یکی نباشد (به شرط اینکه آن دو متفاوت باشند): $P(E_3\,|\,E_2)=1-\frac{2}{365}$.

- ...
- احتمال اینکه روز تولد نفر nام با قبلی‌ها یکی نباشد: $P(E_n \mid E_{2:n-1}) = 1 - \frac{n-1}{365}$.

به دلیل استقلال، روز تولد یک نفر تأثیری در احتمالات روزهای تولد سایر افراد ندارد؛ نفر iام کافی است یکی از $365 - (i-1)$ روز «آزاد» را داشته باشد. لذا احتمال یکی نبودن هیچ روز تولدی (با قانون ضرب/زنجیره‌ای که در جلسه بعد دقیق می‌شود):

$$P(E_2 \cap E_3 \cap \cdots \cap E_n) = \prod_{i=1}^{n-1} \Big(1 - \frac{i}{365}\Big).$$

همین جواب را مستقیماً با شمارش نیز می‌توان دید: از 365^n حالت هم‌احتمال، تعداد حالت‌هایی که همه روزها متمایزند $365 \times 364 \times \cdots \times (365-n+1)$ است.
برای به دست آوردن یک تقریب ساده، از نامساوی $1 - x \le e^{-x}$ استفاده می‌کنیم:

$$\prod_{i=1}^{n-1} \Big(1 - \frac{i}{365}\Big) \le \prod_{i=1}^{n-1} e^{-\frac{i}{365}} = \exp\Big(-\frac{1}{365}\sum_{i=1}^{n-1} i\Big) = \exp\Big(-\frac{n(n-1)}{2\times 365}\Big).$$

■

جدول زیر مقدار دقیق احتمال وجود حداقل یک روز تولد مشترک را نشان می‌دهد:

n	10	20	23	30	40	50	57	70
$\mathbb{P}(\text{shared no})$	0.883	0.589	0.493	0.294	0.109	0.030	0.010	0.001
$\mathbb{P}(\text{shared})$	0.117	0.411	0.507	0.706	0.891	0.970	0.990	0.999

نکته. به همین دلیل به این مسئله «پارادوکس» می‌گویند: تنها با ۲۳ نفر، احتمال وجود دو نفر با روز تولد یکسان از ۵۰٪ بیشتر است و با ۵۷ نفر به ۹۹٪ می‌رسد. دلیل شهودی: تعداد **زوج‌های** افراد $\binom{n}{2}$ است که به صورت n^2 رشد می‌کند؛ برای $n = 23$ داریم ۲۵۳ زوج، و هر زوج با احتمال $1/365$ «برخورد» دارد. فرمول $\exp(-n(n-1)/730)$ نیز نشان می‌دهد احتمال وقتی n از مرتبه $\sqrt{365}$ است، به‌طور معناداری کاهش می‌یابد. این ایده در علوم کامپیوتر در تحلیل **برخورد توابع درهم‌ساز** (hash collision) و «حمله روز تولد» در رمزنگاری کاربرد دارد.

۳.۸.۳ مسئله Monty Hall

مثال ۳-۱۸: مسئله مونتی هال

فرض کنید که در یک مسابقه تلویزیونی شرکت کرده‌اید و جایزه‌ای پشت یکی از سه در زیر پنهان شده است. شما یک در را به صورت کاملاً تصادفی انتخاب می‌کنید... سپس، مجری برنامه (که می‌داند جایزه پشت کدام در است) یکی از دو در باقیمانده را که جایزه پشت آن نیست برای شما باز (پوچ) می‌کند و تنها یک در باقی خواهد ماند که شما انتخاب نکرده‌اید. **سؤال:** آیا انتخاب خود را تغییر می‌دهید؟

حل. بله؛ تغییر انتخاب احتمال برد را از $\frac{1}{3}$ به $\frac{2}{3}$ می‌رساند.

روش اول (استدلال مستقیم): احتمال اینکه انتخاب اولیه شما درست باشد $\frac{1}{3}$ است و کار مجری این

احتمال را تغییر نمی‌دهد؛ زیرا مجری **همیشه** می‌تواند یک در پوچ از میان دو در دیگر باز کند، پس باز کردن در توسط او اطلاعاتی درباره در شما نمی‌دهد. پس اگر روی انتخاب خود بمانید با احتمال $\frac{1}{3}$ برنده می‌شوید. اما اگر عوض کنید، دقیقاً زمانی برنده می‌شوید که انتخاب اولیه‌تان **اشتباه** بوده باشد (چون در آن صورت مجری مجبور است تنها در پوچ دیگر را باز کند و در باقیمانده حتماً جایزه دارد)، که احتمالش $\frac{2}{3}$ است.

روش دوم (شمارش حالات): فرض کنید شما در ۱ را انتخاب کرده‌اید. جایزه با احتمال برابر پشت یکی از سه در است:

محل جایزه	دری که مجری باز می‌کند	نتیجه ماندن	نتیجه تغییر
در ۱ (احتمال $\frac{1}{3}$)	۲ یا ۳	برد	باخت
در ۲ (احتمال $\frac{1}{3}$)	فقط ۳	باخت	برد
در ۳ (احتمال $\frac{1}{3}$)	فقط ۲	باخت	برد

پس $\mathbb{P}(\text{win} \mid \text{stay}) = \frac{1}{3}$ و $\mathbb{P}(\text{win} \mid \text{switch}) = \frac{2}{3}$. ■

دقت کنید! استدلال رایج اما غلط این است که «پس از باز شدن یک در، دو در باقی مانده و هر کدام احتمال $\frac{1}{2}$ دارند». این استدلال فرض می‌کند دو در باقیمانده متقارن‌اند، در حالی که نیستند: در شما **قبل** از اطلاعات مجری انتخاب شده، اما در باقیمانده توسط مجری (با دانستن محل جایزه) «پالایش» شده است. در جلسه بعد همین مسئله را با قانون بیز به‌طور دقیق حل می‌کنیم.

۹.۳ تمرین‌های تکمیلی

تمرین ۳-۱۹: کران پایین بونفرونی

نشان دهید برای هر دو رویداد $\mathbb{P}(A \cap B) \geq \mathbb{P}(A) + \mathbb{P}(B) - 1$. سپس اگر ۹۰٪ دانشجویان درس اول و ۸۰٪ درس دوم را پاس کرده باشند، کمترین درصد ممکن برای پاس کردن هر دو درس چقدر است؟

حل. از اصل شمول و عدم شمول $\mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cup B)$ و چون $\mathbb{P}(A \cup B) \leq 1$، حکم ثابت می‌شود. در مثال عددی: $\mathbb{P}(A \cap B) \geq 0.9 + 0.8 - 1 = 0.7$؛ یعنی دست‌کم ۷۰٪ هر دو درس را پاس کرده‌اند. این کران با حالتی که همه مردودها متفاوت باشند (۱۰٪ و ۲۰٪ بدون هم‌پوشانی) به دست می‌آید. (این نامساوی همان کران اجتماع است که روی متمم‌ها اعمال شده: $\mathbb{P}(A^c \cup B^c) \leq \mathbb{P}(A^c) + \mathbb{P}(B^c)$.) ■

تمرین ۳-۲۰

نشان دهید اگر A و B مستقل باشند، آنگاه A و B^c، و همچنین A^c و B^c نیز مستقل‌اند.

حل. $A = (A \cap B) \cup (A \cap B^c)$ و این دو ناسازگارند، پس $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A)(1 - \mathbb{P}(B)) = \mathbb{P}(A)\mathbb{P}(B^c)$. با اعمال دوباره همین نتیجه روی زوج مستقل (B^c, A) نتیجه می‌گیریم A^c و B^c نیز مستقل‌اند. ■

تمرین ۳-۲۱

سکه سالمی را ۶ بار پرتاب می‌کنیم. احتمال آمدن دست‌کم ۲ شیر چقدر است؟ احتمال اینکه تعداد شیرها زوج باشد چقدر است؟

حل. با متمم: $\mathbb{P}(k \geq 2) = 1 - \mathbb{P}(k = 0) - \mathbb{P}(k = 1) = 1 - \frac{1+6}{64} = \frac{57}{64} \approx 0.891$. برای زوج بودن: $\mathbb{P}(k \text{ even}) = \frac{\binom{6}{0}+\binom{6}{2}+\binom{6}{4}+\binom{6}{6}}{64} = \frac{1+15+15+1}{64} = \frac{1}{2}$. (در حالت کلی از $(1+1)^n + (1-1)^n = 2\sum_{k \text{ even}} \binom{n}{k}$ نتیجه می‌شود که برای هر $n \geq 1$ این احتمال $\frac{1}{2}$ است.) ■

تمرین ۳-۲۲: روز تولد شما

در یک جمع n نفره (به جز شما)، احتمال اینکه دست‌کم یک نفر روز تولدش با **شما** یکی باشد چقدر است؟ برای $n = 22$ مقدار آن را با مسئله روز تولد مقایسه کنید.

حل. روز تولد هر نفر مستقلاً با احتمال $\frac{364}{365}$ با شما متفاوت است؛ پس $\mathbb{P} = 1 - \left(\frac{364}{365}\right)^n$. برای $n = 22$ این مقدار حدود 0.059 است؛ در حالی که در جمع ۲۳ نفره احتمال وجود **یک جفت** با روز تولد یکسان حدود 0.507 است. تفاوت از آنجاست که در اینجا فقط n مقایسه (با شما) انجام می‌شود، اما در مسئله روز تولد $\binom{n+1}{2}$ مقایسه بین همه جفت‌ها. ■

تمرین ۳-۲۳

تاس سالمی را ۴ بار می‌اندازیم. احتمال اینکه دست‌کم یک بار ۶ بیاید را حساب کنید و نشان دهید کران اجتماع در اینجا چه عددی می‌دهد.

حل. با متمم و استقلال: $\mathbb{P}(\text{ one least at} 6) = 1 - (5/6)^4 = 1 - \frac{625}{1296} \approx 0.518$. کران اجتماع: $\mathbb{P}(\bigcup_{i=1}^{4} \{\text{ roll} i = 6\}) \leq 4 \times \frac{1}{6} \approx 0.667$. کران از مقدار واقعی بزرگ‌تر است، زیرا رویدادها ناسازگار نیستند (ممکن است چند بار ۶ بیاید). ■

جلسه ۴

احتمال شرطی، قانون زنجیره‌ای، احتمال کل و قانون بیز

۱.۴ احتمال شرطی (Conditional Probability)

در بسیاری موارد، **اطلاعاتی** در مورد یک واقعه تصادفی به دست ما می‌رسد. در این شرایط، به دنبال یافتن احتمال‌های به‌روزشده هستیم.

برای مثال، در پرتاب یک تاس ۶ وجهی متقارن، در صورتی که پیش‌تر بدانیم واقعه **آمدن یک عدد فرد**، یعنی $E_{\text{odd}} = \{1, 3, 5\}$، حتماً اتفاق افتاده است، آنگاه:

- احتمال رخ دادن عدد ۲ **صفر** خواهد شد (پیش از آن $\frac{1}{6}$ بود)؛
- احتمال واقعه رخ دادن عددی کوچک‌تر یا مساوی ۳ **بیشتر** خواهد شد: پیش از اطلاع برابر $\frac{3}{6} = \frac{1}{2}$ بود، اما پس از دانستن فرد بودن، از سه حالت ممکن $\{1, 3, 5\}$ دو حالت $\{1, 3\}$ مطلوب‌اند؛ پس احتمال به $\frac{2}{3}$ می‌رسد.

این در حالی است که این احتمالات پیش از رسیدن اطلاعات فوق، اعداد متفاوتی بودند.

تعریف ۴-۱: احتمال شرطی

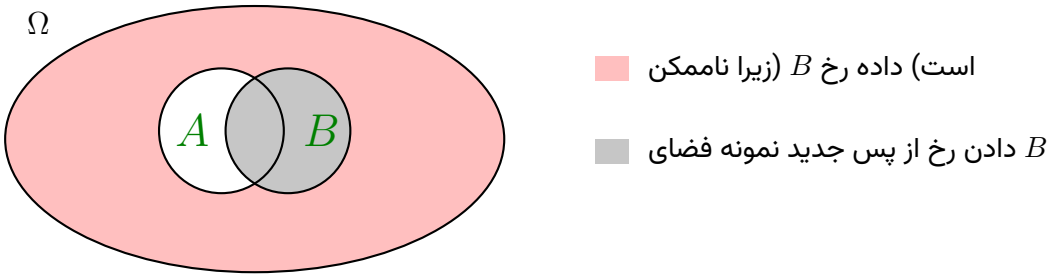
در آمار و احتمال، **احتمال شرطی** واقعه A به شرط B (خوانده می‌شود A given B یا A conditioned on B) را به صورت احتمال به‌روزشده رویداد A تعریف می‌کنیم، به شرطی که بدانیم رویداد B حتماً اتفاق افتاده است. برای $\mathbb{P}(B) > 0$ تعریف می‌کنیم:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

دلیل ظاهر شدن مخرج: پس از دانستن رخ دادن B، گویی فضای نمونه‌ها Ω کوچک‌تر شده است. تنها وقایعی که برابر یا زیرمجموعه B هستند باقی خواهند ماند. پس از A فقط قسمت $A \cap B$ هنوز ممکن است، و برای اینکه احتمال کل فضای جدید (یعنی B) برابر ۱ شود، همه احتمال‌ها را بر $\mathbb{P}(B)$ تقسیم می‌کنیم

(نرمال‌سازی). در مثال تاس:

$$\mathbb{P}(\leq 3 \,|\, \text{odd}) = \frac{\mathbb{P}(\{1,3\})}{\mathbb{P}(\{1,3,5\})} = \frac{2/6}{3/6} = \frac{2}{3}.$$



شکل ۱.۴: نمایش گرافیکی احتمال شرطی: بعد از رخداد B، فضای نمونه مؤثر (و به تبع آن، فضای وقایع مؤثر) کوچک‌تر خواهد شد.

نکته. دقت کنید که $\mathbb{P}(A \,|\, B)$ می‌تواند از $\mathbb{P}(A)$ **بزرگ‌تر**، **کوچک‌تر** یا **مساوی** باشد. این بستگی خواهد داشت که رویداد B، چه میزان اطلاعاتی در مورد رویداد A به دست می‌دهد. در مثال تاس: $\mathbb{P}(\leq 3 \,|\, \text{odd}) = \frac{2}{3} > \frac{1}{2}$ ولی $\mathbb{P}(2 \,|\, \text{odd}) = 0 < \frac{1}{6}$.

قضیه ۴-۲: احتمال شرطی و استقلال

اگر $\mathbb{P}(B) > 0$، آنگاه دو رویداد A و B مستقل‌اند اگر و تنها اگر $\mathbb{P}(A \,|\, B) = \mathbb{P}(A)$؛ زیرا در صورت استقلال

$$\mathbb{P}(A \,|\, B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A),$$

و برعکس، از $\mathbb{P}(A \,|\, B) = \mathbb{P}(A)$ با ضرب دو طرف در $\mathbb{P}(B)$ تعریف استقلال به دست می‌آید.

این تعبیر، استقلال را شهودی‌تر می‌کند: **دانستن رخ دادن B هیچ اطلاعی درباره A نمی‌دهد.**

نکته. به ازای B ثابت، تابع $A \mapsto \mathbb{P}(A \,|\, B)$ خودش یک اندازه احتمال (در اصول کولموگروف صادق) است: نامنفی است، $\mathbb{P}(\Omega \,|\, B) = \mathbb{P}(B)/\mathbb{P}(B) = 1$، و جمع‌پذیر است. پس همه قضایایی که برای احتمال ثابت کردیم (متمم، شمول و عدم شمول، کران اجتماع و ...) برای احتمال شرطی نیز برقرارند؛ مثلاً $\mathbb{P}(A^c \,|\, B) = 1 - \mathbb{P}(A \,|\, B)$.

مثال ۴-۳: تصادفات جاده‌ای و شرایط جوی

فرض کنید احتمالات زیر مربوط به واقعه تصادفات جاده‌ای در شرایط مختلف جوی باشند:

	صاف (clear)	مه‌آلود (mist)
تردد امن	0.73	0.17
تصادف (crash)	0.01	0.09

- سؤال ۱: احتمال تصادف چقدر است؟
- سؤال ۲: احتمال تصادف به شرط هوای مه‌آلود چقدر است؟

- سؤال ۳: آیا احتمال تصادف، از شرایط جوی جاده مستقل است؟

حل. سؤال ۱: رویداد تصادف اجتماع دو خانه ناسازگار سطر دوم است:

$$\mathbb{P}(\text{crash}) = 0.01 + 0.09 = 0.10.$$

سؤال ۲: ابتدا احتمال مه‌آلود بودن (جمع ستون مه‌آلود) و احتمال اشتراک را می‌یابیم:

$$\mathbb{P}(\text{crash} \cap \text{mist}) = 0.09, \qquad \mathbb{P}(\text{mist}) = 0.17 + 0.09 = 0.26,$$

$$\mathbb{P}(\text{crash} \mid \text{mist}) = \frac{0.09}{0.09 + 0.17} = \frac{0.09}{0.26} \approx 0.346.$$

سؤال ۳: $\mathbb{P}(\text{crash} \mid \text{mist}) \approx 0.346$ با $\mathbb{P}(\text{crash}) = 0.10$ **برابر نیستند.** پس واقعه تصادف مستقل از مه‌آلود بودن نیست. به‌علاوه در هوای صاف $\mathbb{P}(\text{crash} \mid \text{clear}) = \frac{0.01}{0.74} \approx 0.0135$؛ یعنی احتمال تصادف در هوای مه‌آلود حدود ۲۶ برابر هوای صاف است! ■

۲.۴ قانون زنجیره‌ای (Chain Rule)

۱.۲.۴ حالت دوتایی و سه‌تایی

با توجه به تعریف احتمال شرطی (و نوشتن $\mathbb{P}(A, B)$ به جای $\mathbb{P}(A \cap B)$) خواهیم داشت:

$$\boxed{\mathbb{P}(A, B) = \mathbb{P}(A \mid B)\, \mathbb{P}(B)}$$

در صورتی که سه واقعه A، B و C را مدنظر قرار داده باشیم، می‌توان رابطه بالا را به صورت تو در تو تکرار کرد. ابتدا (B, C) را یک رویداد در نظر می‌گیریم:

$$\mathbb{P}(A, B, C) = \mathbb{P}(A \mid B, C)\, \mathbb{P}(B, C),$$

و سپس رابطه دوتایی را برای $\mathbb{P}(B, C)$ به کار می‌بریم:

$$\boxed{\mathbb{P}(A, B, C) = \mathbb{P}(A \mid B, C)\, \mathbb{P}(B \mid C)\, \mathbb{P}(C)}$$

نکته. وقتی احتمالی را به بیش از یک رویداد مشروط می‌کنیم (مانند $\mathbb{P}(A \mid B, C)$)، منظور این است که فرض کنید **تمامی** آنان رخ داده باشند؛ یعنی $\mathbb{P}(A \mid B, C) = \mathbb{P}(A \mid B \cap C)$.

۲.۲.۴ حالت کلی و موارد کاربردی

قضیه ۴-۴: قانون زنجیره‌ای

در حالت کلی، برای احتمال رخ دادن توأمان تمامی رویدادهای $A_1, A_2, \ldots, A_n$ خواهیم داشت:

$$\mathbb{P}(A_1, A_2, \ldots, A_n) = \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}(A_i \mid A_{i-1}, \ldots, A_1).$$

اثبات. با استقرا روی n. برای $n = 2$ همان تعریف احتمال شرطی است. اگر برای $n-1$ برقرار باشد، با در نظر گرفتن $B = A_1 \cap \cdots \cap A_{n-1}$ داریم $\mathbb{P}(A_1, \ldots, A_n) = \mathbb{P}(A_n \mid B)\mathbb{P}(B)$ و با جایگذاری فرض استقرا برای $\mathbb{P}(B)$ حکم ثابت می‌شود. (معادلاً، در حاصل‌ضرب سمت راست، صورت هر کسر با مخرج کسر بعدی ساده می‌شود و فقط $\mathbb{P}(A_1 \cap \cdots \cap A_n)$ باقی می‌ماند.) □

در مواردی محاسبه احتمالات شرطی بسیار ساده است. مثلاً، یک مدل‌سازی آماری را از ابتدا بر حسب احتمال‌های شرطی بنا می‌کنیم (مانند مسئله روز تولد در جلسه قبل که در آن $\mathbb{P}(E_i \mid E_2, \ldots, E_{i-1}) = 1 - \frac{i-1}{365}$ به‌راحتی به دست می‌آمد).

نکته. نکته اضافی (خاصیت مارکوف): بسیاری از پدیده‌ها، خاصیت Markovian دارند. به عنوان مثال، رویداد A_i می‌تواند به شرط دانستن A_{i-1} از تمام رویدادهای $A_{i-2}, A_{i-3}, \ldots, A_1$ مستقل شود. در این صورت، محاسبه رابطه فوق بسیار ساده می‌شود:

$$\mathbb{P}(A_1, \ldots, A_n) = \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}(A_i \mid A_{i-1}).$$

برای مثال آب‌وهوای فردا را معمولاً تنها با دانستن آب‌وهوای امروز پیش‌بینی می‌کنیم.

مثال ۴-۵: بیرون کشیدن بدون جایگذاری

از یک دسته کارت ۵۲تایی، سه کارت بدون جایگذاری بیرون می‌کشیم. احتمال اینکه هر سه کارت آس باشند چقدر است؟

حل. A_i را رویداد «کارت iام آس است» بگیرید. با قانون زنجیره‌ای:

$$\mathbb{P}(A_1, A_2, A_3) = \mathbb{P}(A_1)\mathbb{P}(A_2 \mid A_1)\mathbb{P}(A_3 \mid A_1, A_2) = \frac{4}{52} \cdot \frac{3}{51} \cdot \frac{2}{50} = \frac{24}{132600} \approx 1.81 \times 10^{-4}.$$

هر احتمال شرطی به‌سادگی به دست می‌آید: پس از بیرون آمدن یک آس، ۳ آس در ۵۱ کارت باقی مانده است. (بررسی با شمارش: $\binom{4}{3}/\binom{52}{3} = 4/22100$، همان عدد.) ■

۳.۴ قانون احتمال کل (The Law of Total Probability)

تعریف ۴-۶: افراز

فرض کنید که $A_1, A_2, \ldots, A_n$ (که n می‌تواند ∞ هم باشد) رویدادهایی درون $\mathcal{F}$ باشند. آن‌ها را یک **افراز** (Partition) از Ω گوییم اگر

$$\bigcup_{i=1}^{n} A_i = \Omega, \qquad A_i \cap A_j = \varnothing \quad (\text{if} i \neq j).$$

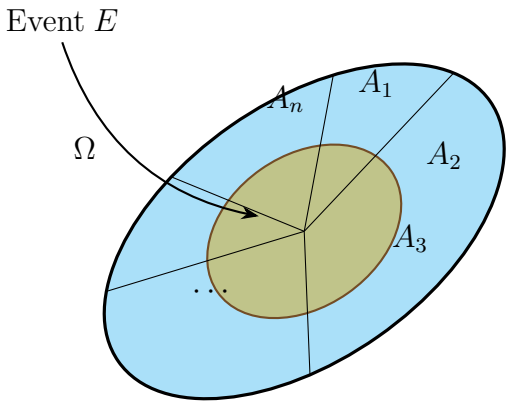
در این صورت، با هر بار انجام آزمایش یکی (و دقیقاً یکی) از $A_1, \ldots, A_n$ رخ خواهد داد. همچنین تمام $\mathbb{P}(A_i)$ها نیز تعریف شده هستند.

قضیه ۴-۷: قانون احتمال کل

اگر $A_1, \ldots, A_n$ یک افراز از Ω باشند، برای هر واقعه‌ای مانند E خواهیم داشت:

$$\mathbb{P}(E) = \sum_{i=1}^{n} \mathbb{P}(E \mid A_i)\, \mathbb{P}(A_i).$$

اثبات. رویدادهای $E \cap A_i$ ناسازگارند (چون A_iها ناسازگارند) و اجتماعشان $E \cap \Omega = E$ است. پس $\mathbb{P}(E) = \sum_i \mathbb{P}(E \cap A_i) = \sum_i \mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$. □



شکل ۲.۴: قانون احتمال کل: رویداد E (بیضی داخلی) توسط افراز $A_1, \ldots, A_n$ به قطعه‌هایی (slice) تقسیم می‌شود.

در واقع هر یک از $\mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$ها، طبق تعریف برابر با $\mathbb{P}(E, A_i)$ هستند، و برابر با جرم احتمال جمع‌شده در یکی از تکه‌ها (slice‌های) واقعه E می‌باشند.

نکته. قانون احتمال کل زمانی به درد می‌خورد که وقوع یک واقعه از طریق چندین **مکانیزم** وجود دارد، و احتمال وقوع به شرط هر یک از آنان را می‌دانیم. به این روش «شکستن به حالات» (conditioning) نیز می‌گویند.

مثال ۴-۸: کارخانه با سه خط تولید

یک کارخانه سه خط تولید دارد که به ترتیب ۵۰٪، ۳۰٪ و ۲۰٪ محصولات را تولید می‌کنند. درصد محصولات معیوب در این خطوط به ترتیب ۱٪، ۲٪ و ۵٪ است. احتمال اینکه یک محصول تصادفی معیوب باشد چقدر است؟

حل. خطوط تولید L_1, L_2, L_3 یک افراز هستند. با قانون احتمال کل:

$$\mathbb{P}(D) = 0.01 \times 0.5 + 0.02 \times 0.3 + 0.05 \times 0.2 = 0.005 + 0.006 + 0.010 = 0.021.$$

■

۴.۴ قانون بیز (Bayes' Rule)

قانون بیز، رابطه ساده ولی بسیار پرکاربردی است که کمک می‌کند تا ترتیب وقایع شرطی در احتمال را عوض کنیم. یعنی با داشتن $\mathbb{P}(A \mid B)$، و همین‌طور احتمال‌های حاشیه‌ای $\mathbb{P}(B)$ و $\mathbb{P}(A)$، بتوانیم $\mathbb{P}(B \mid A)$ را محاسبه کنیم.

قضیه ۴-۹: قانون بیز

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B)\,\mathbb{P}(B)}{\mathbb{P}(A)}.$$

اثبات. طبق قانون زنجیره‌ای، $\mathbb{P}(A \cap B)$ را به دو صورت می‌توان نوشت: $\mathbb{P}(B \mid A)\mathbb{P}(A) = \mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\mathbb{P}(B)$. با تقسیم بر $\mathbb{P}(A)$ حکم به دست می‌آید. □

یک شکل دیگر نگاه کردن به این رابطه، به صورت زیر است:

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \mid B)}{\mathbb{P}(A)}\,\mathbb{P}(B).$$

در رابطه بالا:

- به احتمال $\mathbb{P}(B)$ در اصطلاح **احتمال پیشین** (Prior Probability)، و
- به احتمال $\mathbb{P}(B \mid A)$ در اصطلاح **احتمال پسین** (Posterior Probability) می‌گوییم.

ضریب $\frac{\mathbb{P}(A \mid B)}{\mathbb{P}(A)}$ نشان می‌دهد مشاهده A باور ما به B را چند برابر می‌کند. به $\mathbb{P}(A \mid B)$ (به عنوان تابعی از B) «درست‌نمایی» (likelihood) می‌گویند.

قضیه ۴-۱۰: قانون بیز همراه با احتمال کل

اگر $B_1, \ldots, B_n$ یک افراز باشند، مخرج قانون بیز را می‌توان با قانون احتمال کل حساب کرد:

$$\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \mid B_j)\mathbb{P}(B_j)}{\sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)}.$$

۱.۴.۴ دیدگاه بیزی

دیدگاه Bayesian در آمار و احتمال بر این اصل مبتنی است که: برای مدل‌سازی تصادفی تأثیر دو رویداد تصادفی بر یکدیگر (مثلاً تأثیر فضای وقایع Ω_B بر Ω_A)، با فضای وقایع کلی $\Omega_A \times \Omega_B$، صرفاً لازم است تا موارد زیر را داشته باشیم (یا مدل‌سازی کنیم):

- احتمال در فضای وقایع منتسب به Ω_B (احتمال پیشین)؛
- احتمالات شرطی در فضای وقایع منتسب به Ω_A به شرط وقایع B (مدل مشاهده).

با این دو، طبق قانون زنجیره‌ای کل توزیع توأم مشخص می‌شود و با قانون بیز می‌توان «برعکس» فکر کرد: از مشاهده A درباره علت B استنتاج کرد. موارد کاربردی دیدگاه Bayesian بسیار زیاد هستند: Bayesian inference, Bayesian optimization, Bayesian network, Bayesian Hierarchy و ...

مثال ۴-۱۱: آزمایش پزشکی ــ یک مثال کلاسیک

بیماری خاصی در ۱٪ جامعه وجود دارد. یک آزمایش تشخیصی، فرد بیمار را با احتمال ۹۹٪ مثبت اعلام می‌کند (حساسیت) و فرد سالم را با احتمال ۹۵٪ منفی اعلام می‌کند. اگر جواب آزمایش یک فرد تصادفی مثبت باشد، احتمال اینکه واقعاً بیمار باشد چقدر است؟

حل. D را رویداد بیماری و $+$ را مثبت شدن آزمایش بگیرید. داریم $\mathbb{P}(D) = 0.01$، $\mathbb{P}(+ \mid D) = 0.99$ و $\mathbb{P}(+ \mid D^c) = 0.05$. با احتمال کل:

$$\mathbb{P}(+) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594.$$

با قانون بیز:

$$\mathbb{P}(D \mid +) = \frac{0.99 \times 0.01}{0.0594} \approx 0.167.$$

یعنی با وجود دقت ظاهراً بالای آزمایش، تنها حدود ۱۷٪ از افراد با جواب مثبت واقعاً بیمارند! علت، کوچک بودن احتمال پیشین (1%) است: تعداد افراد سالمی که به اشتباه مثبت می‌شوند (5% از 99%) از تعداد بیماران واقعی بیشتر است. ■

مثال ۴-۱۲: حل دقیق مسئله مونتی هال با قانون بیز

فرض کنید در ۱ را انتخاب کرده‌اید و مجری در ۳ را باز کرده است. احتمال اینکه جایزه پشت در ۲ باشد چقدر است؟ (فرض: اگر جایزه پشت در ۱ باشد، مجری با احتمال برابر یکی از درهای ۲ و ۳ را باز می‌کند.)

حل. C_i را رویداد «جایزه پشت در i» و O_3 را «مجری در ۳ را باز می‌کند» بگیرید. احتمال‌های پیشین $\mathbb{P}(C_i) = \frac{1}{3}$ هستند. درست‌نمایی‌ها:

$$\mathbb{P}(O_3 \mid C_1) = \tfrac{1}{2}, \qquad \mathbb{P}(O_3 \mid C_2) = 1, \qquad \mathbb{P}(O_3 \mid C_3) = 0.$$

با احتمال کل: $\mathbb{P}(O_3) = \frac{1}{3}(\frac{1}{2} + 1 + 0) = \frac{1}{2}$. با قانون بیز:

$$\mathbb{P}(C_2 \mid O_3) = \frac{1 \times \frac{1}{3}}{\frac{1}{2}} = \frac{2}{3}, \qquad \mathbb{P}(C_1 \mid O_3) = \frac{\frac{1}{2} \times \frac{1}{3}}{\frac{1}{2}} = \frac{1}{3}.$$

پس تغییر انتخاب احتمال برد را دو برابر می‌کند. ■

۵.۴ استقلال شرطی (Conditional Independence)

در موارد متعددی پیش می‌آید که دو رویداد A و B از یکدیگر مستقل نباشند:

$$\mathbb{P}(A, B) \neq \mathbb{P}(A)\mathbb{P}(B),$$

ولی در صورت دانستن رویداد سومی مانند C، به صورت شرطی از یکدیگر مستقل شوند.

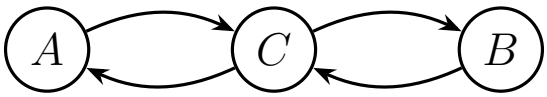
تعریف ۴-۱۳: استقلال شرطی

دو رویداد A و B را به شرط C مستقل گوییم (و می‌نویسیم $A \perp B \,|\, C$) اگر

$$\mathbb{P}(A, B \,|\, C) = \mathbb{P}(A \,|\, C)\, \mathbb{P}(B \,|\, C).$$

معادلاً (وقتی احتمال‌ها مثبت‌اند): $\mathbb{P}(A \,|\, B, C) = \mathbb{P}(A \,|\, C)$؛ یعنی وقتی C را می‌دانیم، دانستن B اطلاع بیشتری درباره A نمی‌دهد.

این اتفاق زمانی رخ می‌دهد که مسیر جریان اطلاعات (information flow) از سمت رویداد A به سمت B (و یا بالعکس)، به واسطه دادن/گرفتن اطلاعاتی در مورد رویداد C باشد:



اگر C معلوم باشد، این «کانال» مسدود می‌شود و A و B دیگر از طریق آن اطلاعاتی رد و بدل نمی‌کنند.

دقت کنید! استقلال و استقلال شرطی هیچ‌کدام دیگری را نتیجه نمی‌دهند. ممکن است $A \perp B$ ولی $A \not\perp B \,|\, C$ (مثلاً دو سکه مستقل و C=«دو سکه یکسان‌اند»؛ با دانستن C، نتیجه سکه اول، سکه دوم را کاملاً مشخص می‌کند). و ممکن است $A \not\perp B$ ولی $A \perp B \,|\, C$ (مثال بعد).

مثال ۴-۱۴: دو سکه نامتقارن ــ صورت مسئله

فرض کنید در جعبه‌ای دو سکه تصادفی و نامتقارن گذارده شده‌اند که احتمال شیر آمدن در آنان به ترتیب ۲۵٪ و ۸۰٪ است. بر این اساس، آزمون تصادفی زیر را انجام می‌دهیم:

۱. به صورت تصادفی و با احتمال‌های برابر، یکی از دو سکه را از جعبه انتخاب می‌کنیم.

۲. این سکه را ۵ بار به صورت مستقل پرتاب کرده و نتایج را در گزارش A ثبت می‌کنیم.

۳. سپس، سکه را ۵ بار دیگر (به صورت مستقل از یکدیگر و بند ۲) پرتاب کرده و نتایج را در گزارش B ثبت می‌کنیم.

سؤال: در صورت دانستن نتیجه گزارش A، پیش‌بینی شما در مورد گزارش B تغییر می‌کند یا خیر؟ چرا؟ فرض کنید که نتیجه گزارش A برابر با $HHTHT$ شود. آنگاه احتمال اینکه در گزارش B رشته $TTHTT$ را ببینیم چقدر است؟

پاسخ کامل این مثال را در ابتدای جلسه بعد خواهیم دید. پاسخ کیفی: **بله، تغییر می‌کند**؛ زیرا گزارش A اطلاعاتی درباره اینکه کدام سکه انتخاب شده است به ما می‌دهد (سه شیر از پنج پرتاب، احتمال سکه دوم

را بالا می‌برد) و این اطلاع، پیش‌بینی ما از B را تغییر می‌دهد. با این حال، **به شرط دانستن سکه**، A و B مستقل‌اند.

۶.۴ تمرین‌های تکمیلی

تمرین ۴-۱۵

دو تاس سالم پرتاب می‌کنیم. به شرط اینکه مجموع دو تاس ۸ باشد، احتمال اینکه دست‌کم یکی از تاس‌ها ۶ باشد چقدر است؟

حل. حالت‌های با مجموع ۸: $(2,6),(3,5),(4,4),(5,3),(6,2)$ ــ پنج حالت هم‌احتمال. از این‌ها دو حالت شامل ۶ هستند. پس $\mathbb{P}=\frac{2}{5}$. (در مقایسه، احتمال غیرشرطی وجود دست‌کم یک ۶ برابر $\frac{11}{36}\approx 0.31$ است.) ■

تمرین ۴-۱۶: دو فرزند

خانواده‌ای دو فرزند دارد (هر فرزند مستقلاً با احتمال $\frac{1}{2}$ پسر است). (الف) به شرط اینکه فرزند بزرگ‌تر پسر باشد، احتمال اینکه هر دو پسر باشند چقدر است؟ (ب) به شرط اینکه دست‌کم یکی پسر باشد چطور؟

حل. فضای نمونه $\{BB,\,BG,\,GB,\,GG\}$ هم‌احتمال است (حرف اول: فرزند بزرگ‌تر). (الف) شرط: $\{BB,BG\}$؛ پس $\mathbb{P}(BB\,|\,\cdot)=\frac{1}{2}$. (ب) شرط: $\{BB,BG,GB\}$؛ پس $\mathbb{P}(BB\,|\,\cdot)=\frac{1}{3}$. تفاوت دو جواب نشان می‌دهد که «چه اطلاعاتی» دقیقاً داده شده، اهمیت دارد. ■

تمرین ۴-۱۷: قانون بیز با سه خط تولید

در مثال کارخانه، اگر محصولی معیوب باشد، احتمال اینکه از خط سوم آمده باشد چقدر است؟

حل. با قانون بیز: $\mathbb{P}(L_3\,|\,D)=\frac{0.05\times 0.2}{0.021}=\frac{0.010}{0.021}\approx 0.476$. به طور مشابه $\mathbb{P}(L_1\,|\,D)=\frac{0.005}{0.021}\approx 0.238$ و $\mathbb{P}(L_2\,|\,D)=\frac{0.006}{0.021}\approx 0.286$ (جمع سه احتمال پسین برابر ۱ است). خط سوم با اینکه فقط ۲۰٪ تولید را دارد، تقریباً نیمی از محصولات معیوب را تولید می‌کند. ■

تمرین ۴-۱۸: آزمایش تکراری

در مثال آزمایش پزشکی، اگر فردی دو بار (به صورت مستقل به شرط وضعیت بیماری) آزمایش دهد و هر دو بار مثبت شود، احتمال بیماری او چقدر است؟

حل. می‌توان احتمال پسین مرحله اول (0.167) را به عنوان پیشین مرحله دوم به کار برد:

$$\mathbb{P}(D\,|\,++)=\frac{0.99\times 0.1667}{0.99\times 0.1667+0.05\times 0.8333}=\frac{0.165}{0.165+0.0417}\approx 0.798.$$

همین جواب مستقیماً نیز به دست می‌آید: $\frac{0.99^2\times 0.01}{0.99^2\times 0.01+0.05^2\times 0.99}\approx 0.798$. (این‌جا از استقلال شرطی دو آزمایش به شرط وضعیت بیماری استفاده کردیم.) ■

جلسه ۵

مثالی از استقلال شرطی و گراف‌های تصادفی

۱.۵ مثال از استقلال شرطی (حل مسئله دو سکه)

صورت مسئله را در جلسه قبل (مثال ۵.۴) دیدیم: دو سکه با احتمال شیر ۲۵٪ و ۸۰٪، یکی به تصادف انتخاب می‌شود، ۵ پرتاب در گزارش A و ۵ پرتاب بعدی در گزارش B ثبت می‌شود. اگر $A = HHTHT$ باشد، احتمال $B = TTHTT$ چقدر است؟

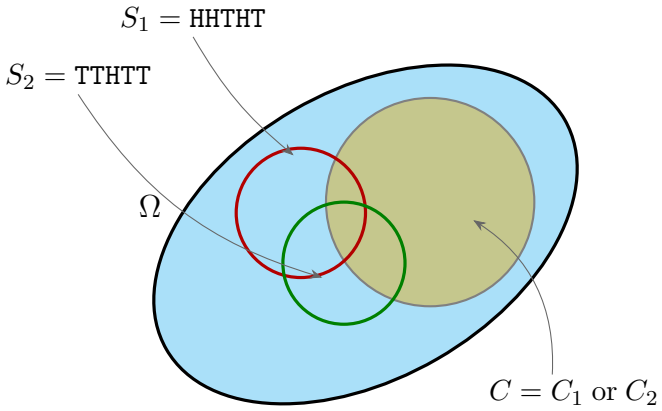
نمادگذاری (notation)

به رشته ۵تایی نخست S_1 و به رشته دوم S_2 می‌گوییم. سکه نخست را با C_1 (۲۵٪ احتمال شیر و ۷۵٪ احتمال خط) و دیگری (۸۰٪ احتمال شیر و ۲۰٪ احتمال خط) را با C_2 نشان می‌دهیم. رویداد سکه انتخابی را $C \in \{C_1, C_2\}$ می‌نامیم.

هدف: می‌خواهیم $\mathbb{P}(S_2 \mid S_1)$ را به ازای $S_1 = \texttt{HHTHT}$ و $S_2 = \texttt{TTHTT}$ بیابیم.

دقت کنید که S_1 و S_2 در حالت کلی مستقل نیستند. اما به شرط دانستن سکه انتخابی C، داریم

$$S_1 \perp S_2 \mid C.$$



۱.۱.۵ یک راه‌حل (اشتباه!)

به راه‌حل زیر دقت کنید:

$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &\overset{?}{=} \mathbb{P}(S_2 \mid S_1, C_1)\mathbb{P}(C_1) + \mathbb{P}(S_2 \mid S_1, C_2)\mathbb{P}(C_2) \\ &= \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_1)\mathbb{P}(C_1) + \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_2)\mathbb{P}(C_2) \\ &= (0.75)^4 \times (0.25)^1 \times \tfrac{1}{2} + (0.20)^4 \times (0.80)^1 \times \tfrac{1}{2} \approx 0.0402.\end{aligned}$$

در سطر دوم از استقلال شرطی استفاده شده است: به شرط دانستن C، دیگر اطلاع از S_1 بی‌اهمیت است. آیا به نظر شما درست است؟ این راه‌حل نشان می‌دهد که S_1 اصلاً مهم نیست! (عدد 0.0402 دقیقاً برابر احتمال غیرشرطی $\mathbb{P}(S_2)$ است.)

> **دقت کنید! این راه‌حل اشتباه است!** اشکال در سطر اول است: قانون احتمال کل به صورت $\sum_i \mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$ برای احتمال غیرشرطی $\mathbb{P}(E)$ است. وقتی خود احتمال مورد نظر شرطی است ($\mathbb{P}(\cdot \mid S_1)$)، وزن‌ها نیز باید شرطی باشند. به بیان دیگر، دانستن S_1 احتمال انتخاب هر سکه را تغییر می‌دهد و نمی‌توان از $\mathbb{P}(C_i) = \frac{1}{2}$ استفاده کرد.

۲.۱.۵ راه‌حل صحیح

دقت کنید که وقتی احتمالی را مشروط می‌کنیم، از آنجا به بعد **همه چیز** مشروط شده است. به عبارتی Ω مؤثر ما دیگر کوچک شده و باید همواره آن را رعایت کرد. (یادآوری: $\mathbb{P}(\cdot \mid S_1)$ خود یک اندازه احتمال است و قانون احتمال کل را باید برای همین اندازه نوشت.) لذا نحوه صحیح نوشتن **قانون احتمال کل** این‌گونه می‌شود:

$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &= \mathbb{P}(S_2 \mid S_1, C_1)\mathbb{P}(C_1 \mid S_1) + \mathbb{P}(S_2 \mid S_1, C_2)\mathbb{P}(C_2 \mid S_1) \\ &= \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_1)\,\mathbb{P}(C_1 \mid S_1 = \texttt{HHTHT}) \\ &\quad + \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_2)\,\mathbb{P}(C_2 \mid S_1 = \texttt{HHTHT}).\end{aligned}$$

در سطر دوم (به‌درستی) از استقلال شرطی $S_1 \perp S_2 \mid C$ استفاده کرده‌ایم. حال می‌ماند احتمال‌های شرطی $\mathbb{P}(C_1 \mid S_1)$ و $\mathbb{P}(C_2 \mid S_1)$ را حساب کنیم.

گام ۱ ــ درست‌نمایی‌ها: رشته HHTHT سه شیر و دو خط دارد و پرتاب‌ها به شرط سکه مستقل‌اند:

$$\mathbb{P}(S_1 = \texttt{HHTHT} \mid C_1) = (0.25)^3 \times (0.75)^2 \approx 0.00879,$$

$$\mathbb{P}(S_1 = \texttt{HHTHT} \mid C_2) = (0.80)^3 \times (0.20)^2 = 0.02048.$$

گام ۲ ــ قانون احتمال کل برای مخرج:

$$\mathbb{P}(S_1 = \texttt{HHTHT}) = (0.25)^3(0.75)^2 \times \tfrac{1}{2} + (0.80)^3(0.20)^2 \times \tfrac{1}{2} \approx 0.01463.$$

گام ۳ ــ قانون بیز:

$$\mathbb{P}(C \mid S_1) = \frac{\mathbb{P}(S_1 \mid C)\mathbb{P}(C)}{\mathbb{P}(S_1)} \implies \mathbb{P}(C_1 \mid S_1) \approx \frac{0.00439}{0.01463} \approx 0.300, \quad \mathbb{P}(C_2 \mid S_1) \approx 0.700.$$

یعنی دیدن سه شیر در پنج پرتاب، احتمال اینکه سکه دوم (که بیشتر شیر می‌آورد) انتخاب شده باشد را از ۵۰٪ به ۷۰٪ رسانده است.

گام ۴ ــ جواب نهایی: با ترکیب نتایج پیشین خواهیم داشت:

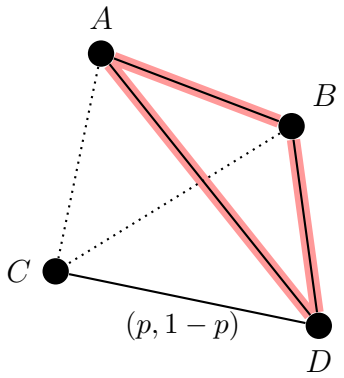
$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &= (0.75)^4 \times (0.25)^1 \times \left(\frac{(0.25)^3(0.75)^2 \cdot \frac{1}{2}}{(0.25)^3(0.75)^2 \cdot \frac{1}{2} + (0.80)^3(0.20)^2 \cdot \frac{1}{2}} \right) \\ &\quad + (0.20)^4 \times (0.80)^1 \times \left(\frac{(0.80)^3(0.20)^2 \cdot \frac{1}{2}}{(0.25)^3(0.75)^2 \cdot \frac{1}{2} + (0.80)^3(0.20)^2 \cdot \frac{1}{2}} \right) \\ &\approx 0.0791 \times 0.300 + 0.00128 \times 0.700 \approx 0.0246.\end{aligned}$$

نکته. مقایسه کنید: احتمال غیرشرطی $\mathbb{P}(S_2 = \texttt{TTHTT}) \approx 0.0402$ است، اما پس از دیدن $S_1 = \texttt{HHTHT}$ به حدود 0.0246 کاهش یافت. دلیلش این است که S_1 (با شیرهای زیاد) شواهدی به نفع سکه C_2 است و سکه C_2 به‌ندرت رشته پرخطی مثل TTHTT تولید می‌کند. پس S_1 و S_2 **مستقل نیستند**، هرچند به شرط C مستقل‌اند. اطلاعات از S_1 از طریق «کانال» C به S_2 جریان می‌یابد.

۲.۵ یک مثال از گراف‌های تصادفی: تشکیل مثلث

مثال ۵-۱: مسئله تشکیل مثلث در گراف تصادفی

یک گراف تصادفی با ۴ رأس (Node) به نام‌های A, B, C, D را در نظر بگیرید. هر یک از ۶ یال (Edge) بالقوه این گراف، **مستقل** از یکدیگر، می‌توانند با احتمال p وجود داشته باشند، و با احتمال $1-p$ ایجاد نشوند. در اینجا p عددی دلخواه بین ۰ و ۱ است. احتمال اینکه در این گراف، حداقل یک مثلث ایجاد شود چقدر است؟



حل

$$\mathbb{P}(\text{۱ least At}\Delta) = \mathbb{P}(ABC \cup ABD \cup ACD \cup BCD).$$

- کلاً $\binom{4}{3} = 4$ مثلث می‌توانند رخ دهند: ABC، ABD، ACD و BCD.

- احتمال تشکیل هر یک از آن‌ها (به خاطر استقلال سه یال آن) برابر با $p \times p \times p = p^3$ است. یعنی داریم

$$\mathbb{P}(ABC) = \mathbb{P}(ABD) = \mathbb{P}(ACD) = \mathbb{P}(BCD) = p^3.$$

پرسش: آیا می‌توان گفت $\mathbb{P}(\text{۱ least At}\Delta) = 4p^3$ ؟

پاسخ. **خیر، نمی‌توان گفت!** زیرا رخ دادن یک مثلث (مانند ABC) مانع رخ دادن یکی دیگر (مانند BCD) نمی‌شود. به عبارتی، این رخدادها ناسازگار (disjoint) نیستند. پس احتمال اجتماع آنان برابر با جمعشان نیست. (البته طبق کران اجتماع، $4p^3$ یک **کران بالا** است.)

پس باید از **اصل شمول و عدم شمول** استفاده کنیم:

۱. **اشتراک‌های دوتایی:** باید احتمالاتی مانند $\mathbb{P}(ABC \cap ABD)$ که دو بار شمرده شده‌اند کم شوند. تعداد این اشتراکات $\binom{4}{2} = 6$ است. از طرفی، هر دو مثلث متمایز در K_4 دقیقاً در یک یال مشترک‌اند (مثلاً ABC و ABD در یال AB)؛ پس هر اشتراک شامل رخ دادن دقیقاً ۵ یال مستقل است و احتمال هر یک برابر با p^5 است. تا بدین‌جا داریم: $4p^3 - 6p^5$.

۲. **اشتراک‌های سه‌تایی:** سپس باید اشتراک‌های ۳تایی که زیادی کم شده‌اند، دوباره اضافه شوند. تعداد این اشتراکات $\binom{4}{3} = 4$ است، و در صورت بروز هر یک، تمام ۶ یال گراف می‌بایست رخ داده باشند (مثلاً ABC، ABD و ACD با هم همه ۶ یال را می‌پوشانند). پس احتمال هر یک p^6 است.

۳. **اشتراک چهارتایی:** در نهایت، می‌بایست اشتراک ۴تایی (که یک حالت بیشتر ندارد) و دوباره مشتمل بر رخ دادن تمام یال‌های گراف است کم شود: $-p^6$.

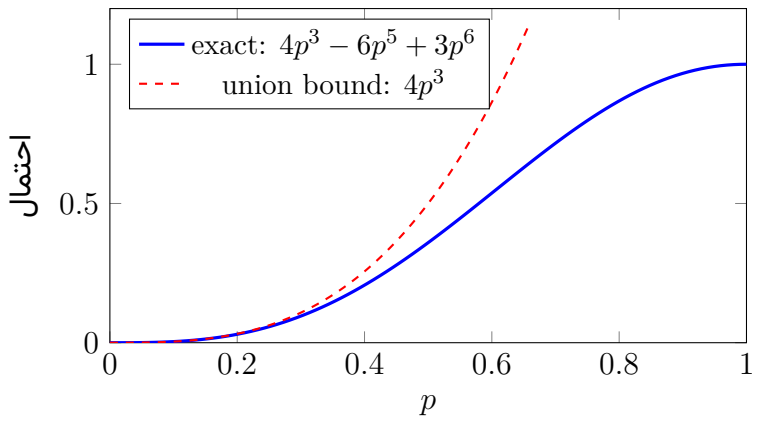
پس در نهایت خواهیم داشت:

$$4p^3 - 6p^5 + 4p^6 - p^6,$$

یعنی

$$\boxed{\mathbb{P}(\text{۱ least At}\Delta) = 4p^3 - 6p^5 + 3p^6}$$

نکته. **بررسی درستی:** به ازای $p = 1$ گراف کامل است و جواب باید ۱ باشد: $4 - 6 + 3 = 1$ ✓. به ازای pهای کوچک، جمله غالب $4p^3$ است؛ یعنی کران اجتماع در این حالت تقریب خوبی است (چون احتمال رخ دادن هم‌زمان دو مثلث، $O(p^5)$، بسیار کوچک‌تر است). این درستی را می‌توان با شمارش مستقیم همه $2^6 = 64$ حالت گراف نیز تأیید کرد.



۳.۵ گراف‌های Erdős–Rényi و مسئله تشکیل Clique

تعریف ۵-۲: گراف تصادفی Erdős–Rényi

یک گراف تصادفی با n رأس $V_1, \dots, V_n$ در نظر بگیرید. هر یک از $\frac{n(n-1)}{2}$ یال بالقوه، مستقل از یکدیگر، با احتمال ثابت p برقرار خواهند شد. به چنین گرافی، یک گراف تصادفی Erdős–Rényi اطلاق می‌گردد و آن را با $G(n,p)$ نشان می‌دهیم.

تعریف ۵-۳: r-clique

به یک زیرگراف کامل (شامل تمام یال‌های دوبه‌دو) به سایز r رأس (برای یک $2 \le r \le n$)، یک r-clique یا «خوشه rتایی» می‌گوییم. مثلث همان 3-clique است.

هدف: یافتن کرانی برای احتمال تشکیل حداقل یک r-clique در گراف، به ازای مقادیر ثابتی از n, p, r.

۱.۳.۵ کران بالا با کران اجتماع

- احتمال تشکیل هر r-clique مشخص (روی r رأس معین) برابر است با

$$\mathbb{P}(\text{ one} r\text{-clique}) = p^{\frac{r(r-1)}{2}},$$

زیرا هر r رأس، $\binom{r}{2} = \frac{r(r-1)}{2}$ یال دارند و همه باید (مستقلاً) برقرار باشند.

- از طرفی، می‌دانیم که تعداد $\binom{n}{r}$ کلیک (مکان بالقوه) از سایز r موجود هستند.
- طبق کران اجتماع (Union Bound)، می‌توان یک کران بالا برای احتمال تشکیل حداقل یک r-clique پیدا کرد:

$$\boxed{\mathbb{P}(\text{ one least At} r\text{-clique}) \le \binom{n}{r} p^{\frac{r(r-1)}{2}}}$$

نکته. محاسبه دقیق این احتمال با اصل شمول و عدم شمول (مانند حالت مثلث) بسیار پیچیده است، زیرا کلیک‌ها به شکل‌های مختلفی با هم هم‌پوشانی دارند. کران اجتماع با وجود سادگی، در بسیاری از کاربردها کافی است.

۲.۳.۵ ساده‌سازی کران

قضیه ۵-۴: کران ضریب دوجمله‌ای

برای $1 \le r \le n$: $\binom{n}{r} \le \left(\frac{ne}{r}\right)^r$.

اثبات. $\binom{n}{r} = \frac{n(n-1)\cdots(n-r+1)}{r!} \le \frac{n^r}{r!}$. از طرفی از بسط تیلور $e^r = \sum_{k\ge 0} \frac{r^k}{k!} \ge \frac{r^r}{r!}$، پس $r! \ge (r/e)^r$. با ترکیب این دو، $\binom{n}{r} \le n^r (e/r)^r$. □

برای ساده‌سازی بیشتر، با نوشتن $p = e^{-\log(1/p)}$ داریم:

$$\mathbb{P}(\text{clique}) \le \binom{n}{r} p^{\frac{r(r-1)}{2}} \le \left(\frac{ne}{r}\right)^r e^{-\frac{r(r-1)}{2}\log\left(\frac{1}{p}\right)} = \exp\left(r\left[\log\frac{ne}{r} - \frac{r-1}{2}\log\frac{1}{p}\right]\right).$$

با کمی عملیات جبری، می‌توان دید که در صورتی که داشته باشیم (فرمول ارائه‌شده در اسلاید)

$$r \ge \frac{2\log(ne)}{\log(1/p)} + \frac{3}{\log(ne)},$$

آنگاه احتمال تشکیل حداقل یک r-clique (در رژیم معمول n بزرگ) از مقدار 0.01 کمتر است. نکته اصلی این است که **بزرگ‌ترین کلیک یک گراف تصادفی، تنها از مرتبه $\frac{2\log n}{\log(1/p)}$ است.**

قضیه ۵-۵: یک شرط کافی دقیق

اگر $r \ge 4$ و $r \ge 1 + \frac{2\log(ne)}{\log(1/p)}$، آنگاه $\mathbb{P}(\text{ one least At} r\text{-clique}) \le r^{-r} \le \frac{1}{256} < 0.01$.

اثبات. از شرط دوم، $\log\frac{ne}{r} - \log(ne) = -\log r$؛ پس عبارت داخل کروشه حداکثر $\frac{r-1}{2}\log\frac{1}{p} \ge \log(ne)$ است و کران برابر $e^{-r\log r} = r^{-r}$ می‌شود. برای $r \ge 4$ داریم $r^{-r} \le 4^{-4} = \frac{1}{256}$. □

مثال ۵-۶: مثال عددی

برای $n = 1000$ و $p = \frac{1}{2}$، شرط بالا $r \ge 1 + \frac{2\log(1000e)}{\log 2} \approx 23.8$ می‌دهد. پس با احتمال بیش از ۹۹٪ هیچ کلیکی با ۲۴ رأس یا بیشتر در این گراف وجود ندارد؛ در حالی که گراف تقریباً $\frac{1}{2}\binom{1000}{2} \approx 250{,}000$ یال دارد! (محاسبه مستقیم کران $\binom{1000}{r}2^{-r(r-1)/2}$ نشان می‌دهد که حتی برای $r = 20$ این احتمال کمتر از 10^{-15} است.)

۳.۳.۵ یک تخمین عددی ساده: شبکه‌های اجتماعی

- در شبکه اجتماعی Facebook یا Instagram از قدر مرتبه $n = O(10^9)$ نفر عضو هستند.
- تعداد متوسط «دوست»های هر عضو، از قدر مرتبه $np \approx O(10^3)$ است. (در گراف Erdős–Rényi هر رأس به طور متوسط با $(n-1)p \approx np$ رأس دیگر همسایه است.) لذا داریم $p \approx O(10^{-6})$.
- با جایگذاری در رابطه قبلی، می‌توان دید که در این صورت احتمال تشکیل کلیک‌هایی با $r \ge O(1)$ بسیار پایین است. به‌طور دقیق‌تر: $\frac{2\log(ne)}{\log(1/p)} \approx \frac{2\times 21.7}{13.8} \approx 3.1$؛ پس طبق قضیه بالا احتمال وجود حتی یک کلیک ۵تایی کمتر از 5^{-5} است. در واقع کران اجتماع برای $r = 5$ مقدار $\binom{10^9}{5}10^{-60} \approx 8 \times 10^{-18}$ را می‌دهد!

پرسش: آیا این عدد برای شما معقول است؟ به نظر شما ایراد کار از کجاست؟

پاسخ. خیر، معقول نیست! در شبکه‌های اجتماعی واقعی، کلیک‌های بزرگ بسیار فراوان‌اند: اعضای یک خانواده، هم‌کلاسی‌ها، هم‌تیمی‌ها یا همکاران یک شرکت اغلب همگی با هم دوست‌اند و کلیک‌هایی با ده‌ها عضو می‌سازند.

ایراد در **مدل** است، نه در محاسبه. مدل Erdős–Rényi دو فرض غیرواقعی دارد:

۱. **استقلال یال‌ها:** در دنیای واقعی، اگر X با Y و Y با Z دوست باشد، احتمال دوستی X و Z بسیار بیشتر از حالت عادی است (پدیده «بستار سه‌گانه» یا triadic closure). یعنی رخداد یال‌ها به شدت **وابسته** است.

۲. **همگنی:** احتمال p برای همه جفت‌ها یکسان فرض شده، در حالی که افراد هم‌شهری، هم‌سن یا هم‌دانشگاهی با احتمال بسیار بیشتری دوست می‌شوند (ساختار اجتماعی یا community structure).

این مثال درس مهمی دارد: نتایج احتمالاتی فقط به اندازه فرض‌های مدل معتبرند. «فرض استقلال» یک فرض ساده‌کننده بسیار قوی است و باید با احتیاط به کار رود.

۴.۵ تمرین‌های تکمیلی

تمرین ۵-۷

در مسئله دو سکه، $\mathbb{P}(C_2 \mid S_1)$ را برای $S_1 = \text{HHHHH}$ حساب کنید. سپس احتمال اینکه پرتاب بعدی شیر باشد (به شرط S_1) را بیابید.

حل. درست‌نمایی‌ها: $\mathbb{P}(S_1 \mid C_1) = 0.25^5 \approx 0.000977$ و $\mathbb{P}(S_1 \mid C_2) = 0.8^5 \approx 0.32768$. با قانون بیز (پیشین‌های برابر):

$$\mathbb{P}(C_2 \mid S_1) = \frac{0.32768}{0.32768 + 0.000977} \approx 0.997.$$

با قانون احتمال کل شرطی و استقلال شرطی: $\mathbb{P}(H \mid S_1) = 0.25 \times 0.003 + 0.8 \times 0.997 \approx 0.798$. ■

تمرین ۵-۸

در گراف تصادفی با ۴ رأس، احتمال اینکه گراف **هیچ** مثلثی نداشته باشد را برای $p = \frac{1}{2}$ حساب کنید و با شمارش مستقیم تأیید کنید.

حل. از فرمول: $1 - (4p^3 - 6p^5 + 3p^6)$ و با $p = \frac{1}{2}$: $4/8 - 6/32 + 3/64 = \frac{32-12+3}{64} = \frac{23}{64}$؛ پس احتمال نبود مثلث $\frac{41}{64}$ است. شمارش مستقیم: با $p = \frac{1}{2}$ همه 64 گراف هم‌احتمال‌اند. گراف‌های دارای مثلث: با ۳ یال فقط ۴ گراف (خود مثلث‌ها)؛ با ۴ یال، هر مثلث به‌همراه یکی از ۳ یال دیگر: $4 \times 3 = 12$؛ با ۵ یال: هر ۶ گراف (حذف یک یال از K_4 فقط دو مثلث را خراب می‌کند)؛ با ۶ یال: ۱. جمع: $4 + 12 + 6 + 1 = 23$ ✓. ■

تمرین ۵-۹

در گراف $G(n,p)$، با استفاده از کران اجتماع نشان دهید احتمال وجود دست‌کم یک رأس **منزوی** (بدون هیچ یال) حداکثر $n(1-p)^{n-1}$ است. برای $n = 100$ و $p = 0.1$ این کران را حساب کنید.

حل. رأس i منزوی است اگر هیچ‌یک از $n-1$ یال آن برقرار نباشد؛ با استقلال احتمال آن $(1-p)^{n-1}$ است. با کران اجتماع روی n رأس: $\mathbb{P}(\exists \text{isolated}) \le n(1-p)^{n-1}$. برای $n = 100, p = 0.1$: $100 \times 0.9^{99} \approx 100 \times 2.95 \times 10^{-5} \approx 0.003$. ■

جلسه ۶

متغیر تصادفی و متغیرهای تصادفی گسسته معروف

۱.۶ متغیر تصادفی (Random Variable) ـ مقدمه

پیش‌تر دیدیم که مدل‌سازی تصادفی یک واقعه، معادل با تعریف یک فضای احتمال به صورت زیر است:

$$(\Omega,\ \mathcal{F},\ P).$$

بیایید هر سه جزء را یک بار دیگر، این بار با نگاه «مهندسی»، مرور کنیم:

- **فضای نمونه Ω:** مجموعه‌ای شامل تمامی **پیشامدهای** (outcome) ممکن است. هر عضو این فضا مشخص‌کننده یک وضعیت خاص از سیستم مدل‌سازی شده است:

$$\omega = \left(\omega^{(1)}, \omega^{(2)}, \dots\right) \in \Omega.$$

  این فضا می‌تواند ابعاد بسیار بالایی داشته باشد، که به معنی زیاد بودن پارامترهای آزاد در مدل‌سازی است. Ω حتی می‌تواند **فضایی بی‌نهایت‌بعدی** باشد.

- **فضای رویدادها $\mathcal{F}$:** مجموعه‌ای شامل تمام یا برخی زیرمجموعه‌های Ω است. وقوع هر پیشامد در Ω، می‌تواند باعث رخ دادن هیچ، یک یا تعدادی (گاهاً بی‌نهایت) رویداد شود. لازم است تا $\mathcal{F}$ یک σ-Field بر روی Ω باشد.

- **قانون یا اندازه احتمال P:** تابعی از فضای رویدادها به بازه بسته اعداد حقیقی بین صفر تا یک است، یعنی

$$P : \mathcal{F} \to [0, 1],$$

  و لازم است تا P قوانین کولموگروف (Kolmogorov) را رعایت کند.

۱.۱.۶ یک مثال: مدل‌سازی آب‌وهوا

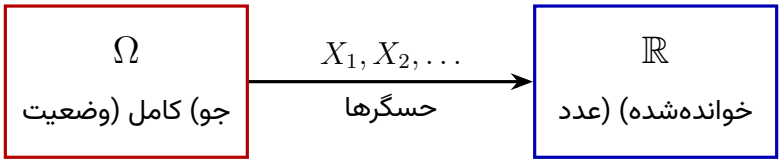
فرض کنید قصد داریم وضعیت آب‌وهوای یک ناحیه از کره زمین را به صورت تصادفی مدل‌سازی کنیم:

- فضای نمونه در این حالت، بسیار پیچیده خواهد بود. لازم است تا محل و تکانه تمامی ذرات و مولکول‌های معلق در هوا را به عنوان پارامتر آزاد (بخشی از ابعاد هر نمونه $\omega \in \Omega$) در نظر بگیریم...
- همچنین، تمامی پارامترهایی که می‌توانند مستقلاً و یا در کنار یکدیگر بر مفهومی که ما از آب‌وهوا در ذهن داریم تأثیرگذار باشند.
- رویدادهایی مانند «بارانی» (Rainy)، «آفتابی» (Sunny) و «طوفانی» (Windy) اعضای $\mathcal{F}$ هستند؛ هر کدام مجموعه بسیار بزرگی از وضعیت‌های میکروسکوپی ω است.

در عمل، **امکان سنجش فضای Ω اصلی وجود ندارد**. لذا، از اندازه‌گیری محدود و در دسترس استفاده خواهد شد:

- **دماسنج:** نگاشت فضای Ω به یک ناحیه از فضای $\mathbb{R}$ از طریق یک حسگر (sensor) دمایی.
- **رطوبت‌سنج:** اندازه‌گیری نادقیق تجمع مولکول‌های آب از طریق حسگر رطوبتی.
- و ...

هر یک از این حسگرها یک تابع $X_1, X_2, \dots$ از Ω به اعداد است.



۲.۱.۶ اندازه‌گیری در فضای نمونه

دستیابی به تمامی مقادیر لازم برای تشکیل فضای Ω و مشاهده یک پیشامد دلخواه $\omega \in \Omega$، بعضاً بسیار سخت و یا حتی غیرممکن است. لذا، به جای مشاهده (یا معادلاً اندازه‌گیری) خود ω، تابعی از آن را مانند $X(\omega)$ اندازه می‌گیریم.

تعریف ۶-۱: متغیر تصادفی

یک **متغیر تصادفی** تابعی از فضای نمونه به یک مجموعه عددی است:

$$X : \Omega \to R.$$

در اینجا، برد تابع X (یعنی R) یک **مجموعه عددی** دلخواه است. R می‌تواند مجموعه اعداد حقیقی $\mathbb{R}$، اعداد طبیعی $\mathbb{N}$ یا مجموعه محدود $\{0, 1\}$ باشد.

نکته. نام «متغیر تصادفی» کمی گمراه‌کننده است: X در واقع یک **تابع** (کاملاً معین) است و تصادف از انتخاب ω می‌آید. احتمال رویدادهایی مانند $\{X \leq 3\}$ به صورت $P(\{\omega \in \Omega : \ X(\omega) \leq 3\})$ تعریف می‌شود؛ یعنی هر سؤال درباره X در نهایت یک سؤال درباره یک رویداد در $\mathcal{F}$ است. (از نظر ریاضی لازم است این مجموعه‌ها عضو $\mathcal{F}$ باشند؛ به این شرط «اندازه‌پذیری» می‌گویند.)

مثال ۶-۲: تعداد شیرها در دو پرتاب

دو سکه سالم پرتاب می‌شوند: $\Omega = \{HH, HT, TH, TT\}$. متغیر تصادفی X = «تعداد شیرها» را تعریف کنید. آنگاه $X(HH) = 2$، $X(HT) = X(TH) = 1$ و $X(TT) = 0$. پس

$$P(X = 0) = \tfrac{1}{4}, \qquad P(X = 1) = P(\{HT, TH\}) = \tfrac{1}{2}, \qquad P(X = 2) = \tfrac{1}{4}.$$

این مثال نشان می‌دهد که X اطلاعات را «فشرده» می‌کند: دو پیشامد متفاوت HT و TH به یک مقدار نگاشته می‌شوند.

۳.۱.۶ متغیر تصادفی به مثابه یک «جعبه سیاه»

برای فهم بهتر، می‌توانید یک متغیر تصادفی مانند X را به مثابه یک **جعبه سیاه** در نظر بگیرید که نمی‌دانید در داخل آن چه خبر است...

- هر بار که دکمه روی جعبه سیاه را فشار می‌دهید، یک آزمایش تصادفی درون آن انجام می‌گیرد (یک مقدار $\omega \in \Omega$ به صورت تصادفی مقدار می‌گیرد)، و یک مقدار تصادفی به X می‌دهد.
- به این مقدار یک **نمونه** از X گفته می‌شود. در حالت کلی، هر بار که این کار را می‌کنید مقادیر مختلفی به دست خواهید آورد (مثلاً $1.2,\ 3.45,\ -2.1,\ 5,\ -0.4, \ldots$). در واقع X یک مقدار مشخص ندارد، و در هر آزمایش یک مقدار خاص خواهد گرفت.
- اما «**توزیع**» یا distribution مقادیر آن مشخص است: اگر تعداد زیادی نمونه بگیریم و هیستوگرام آن‌ها را رسم کنیم، شکل هیستوگرام به یک شکل ثابت (توزیع X) میل می‌کند.

۲.۶ متغیرهای تصادفی گسسته (Discrete Random Variables)

متغیرهای تصادفی می‌توانند پیوسته و یا گسسته باشند. **متغیرهای تصادفی گسسته** می‌توانند مقادیری از یک مجموعه محدود و یا حداکثر شمارا را داشته باشند.

تعریف ۶-۳: تابع جرم احتمال (PMF)

برای متغیر تصادفی گسسته X با مقادیر ممکن $x_1, x_2, \ldots$، تابع جرم احتمال عبارت است از

$$P_X(x) = P(X = x),$$

که در دو شرط صدق می‌کند: $P_X(x) \geq 0$ و $\sum_i P_X(x_i) = 1$.

در صورتی که یک متغیر تصادفی گسسته باشد، **به طور کامل توسط PMF تعیین خواهد شد**؛ زیرا برای هر مجموعه A داریم

$$P(X \in A) = \sum_{x \in A} P_X(x).$$

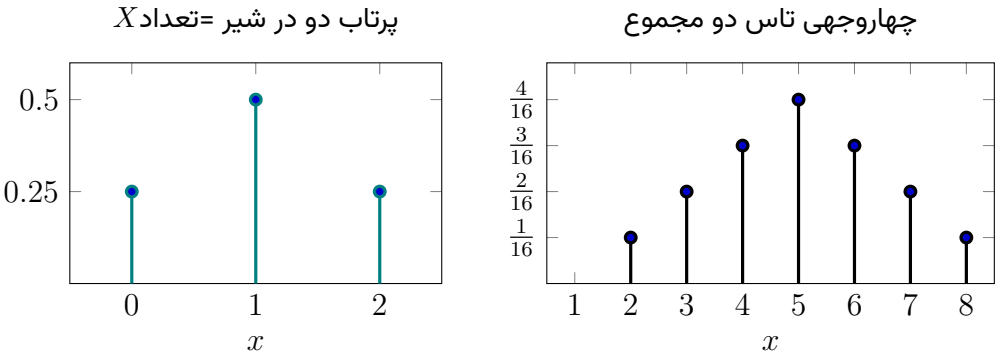
مثال ۶-۴: مجموع دو تاس چهاروجهی

دو تاس چهاروجهی سالم (با وجوه ۱ تا ۴) را پرتاب می‌کنیم و X را مجموع آن‌ها می‌گیریم. PMF آن را بیابید.

حل. ۱۶ حالت هم‌احتمال داریم. تعداد حالت‌هایی که مجموع برابر x می‌شود برای $x = 2, \dots, 8$ به ترتیب $1, 2, 3, 4, 3, 2, 1$ است (مثلاً برای $x = 5$: $(1,4), (2,3), (3,2), (4,1)$). پس:

x	2	3	4	5	6	7	8
$P_X(x)$	$\frac{1}{16}$	$\frac{2}{16}$	$\frac{3}{16}$	$\frac{4}{16}$	$\frac{3}{16}$	$\frac{2}{16}$	$\frac{1}{16}$

که جمع آن‌ها $\frac{16}{16} = 1$ است. ■



۳.۶ متغیرهای تصادفی گسسته معروف

۱.۳.۶ توزیع برنولی (Bernoulli)

ساده‌ترین متغیر تصادفی، نتیجه یک آزمون با دو خروجی «موفقیت» (۱) و «شکست» (۰) است. اگر احتمال موفقیت p باشد، $X \sim \text{Bernoulli}(p)$:

$$P_X(1) = p, \qquad P_X(0) = 1 - p.$$

۲.۳.۶ توزیع دوجمله‌ای (Binomial Distribution)

توزیع دوجمله‌ای مربوط به **تعداد موفقیت‌های** تکرار nباره (مستقل) یک آزمون برنولی است.

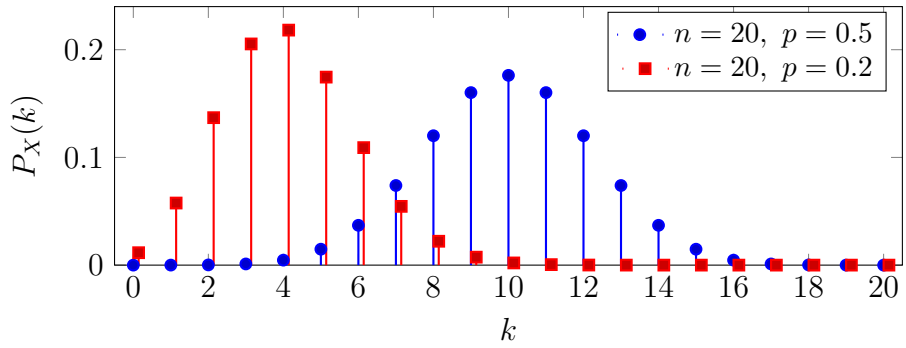
قضیه ۶-۵: PMF توزیع دوجمله‌ای

برای $X \sim \text{Binomial}(n, p)$ و $X = 0, 1, 2, \dots, n$:

$$\boxed{P_X(k) = \binom{n}{k} p^k (1-p)^{n-k}}$$

اثبات. هر رشته مشخص از n نتیجه که دقیقاً k موفقیت دارد، به دلیل استقلال احتمال $p^k(1-p)^{n-k}$ دارد (ضرب احتمال‌ها). تعداد چنین رشته‌هایی $\binom{n}{k}$ است (انتخاب جای موفقیت‌ها) و این رشته‌ها ناسازگارند؛ پس با جمع کردن، حکم به دست می‌آید. جمع کل احتمال‌ها طبق قضیه دوجمله‌ای $(p+(1-p))^n = 1$ است ــ و نام «دوجمله‌ای» از همین‌جاست. □

نکته. آزمایش سکه سالم در جلسه سوم حالت خاص $p = \frac{1}{2}$ است: $\binom{n}{k}2^{-n}$.



مثال ۶-۶: آزمون چندگزینه‌ای

یک آزمون ۱۰ سؤال چهارگزینه‌ای دارد و دانشجویی همه سؤال‌ها را تصادفی جواب می‌دهد. احتمال اینکه دقیقاً ۵ سؤال را درست جواب دهد، و احتمال اینکه دست‌کم ۶ سؤال را درست جواب دهد چقدر است؟

حل. تعداد پاسخ‌های درست $X \sim \text{Binomial}(10, \frac{1}{4})$ است. پس

$$P(X=5) = \binom{10}{5}\left(\frac{1}{4}\right)^5\left(\frac{3}{4}\right)^5 = 252 \times \frac{243}{4^{10}} \approx 0.0584,$$

$$P(X \geq 6) = \sum_{k=6}^{10}\binom{10}{k}\left(\frac{1}{4}\right)^k\left(\frac{3}{4}\right)^{10-k} \approx 0.0197.$$

یعنی شانس قبولی (با حد نصاب ۶) با حدس تصادفی کمتر از ۲٪ است. ■

۳.۳.۶ توزیع چندجمله‌ای (Multinomial Distribution)

توزیع چندجمله‌ای، تعمیم توزیع دوجمله‌ای برای تکرار nباره آزمون‌هایی است که **بیش از دو خروجی** ممکن داشته باشند. فرض کنید آزمونی با m خروجی ممکن، هر یک با احتمال‌های $p_1, p_2, \ldots, p_m$ (با جمع ۱)، را n بار به صورت مستقل انجام می‌دهیم. هدف، به دست آوردن احتمال وقوع k_i بار از پیشامد iام است $(n = k_1 + \cdots + k_m)$.

قضیه ۶-۷: PMF توزیع چندجمله‌ای

برای $(k_1, \ldots, k_m) \sim \text{Multinomial}(n, p_1, \ldots, p_m)$:

$$\boxed{P_X(k_1, \ldots, k_m) = \binom{n}{k_1, \ldots, k_m}\prod_{i=1}^{m} p_i^{k_i}}, \qquad \binom{n}{k_1, \ldots, k_m} = \frac{n!}{k_1!\,k_2!\cdots k_m!}.$$

اثبات. هر رشته مشخص با k_1 بار خروجی ۱، ... و k_m بار خروجی m احتمال $\prod p_i^{k_i}$ دارد. تعداد این رشته‌ها برابر تعداد جایگشت‌های n شیء است که k_1 تای آن‌ها یکسان (از نوع ۱)، k_2 تا یکسان و ... باشند؛ یعنی ضریب چندجمله‌ای $\frac{n!}{k_1!\cdots k_m!}$. (برای $m=2$ همان توزیع دوجمله‌ای به دست می‌آید.) □

مثال ۶-۸: تاس و توزیع چندجمله‌ای

(الف) تاس سالمی را ۶ بار می‌اندازیم. احتمال اینکه هر عدد دقیقاً یک بار ظاهر شود چقدر است؟ (ب) در یک انتخابات، ۵۰٪ به نامزد A، ۳۰٪ به B و ۲۰٪ به C رأی می‌دهند. اگر ۱۰ نفر را تصادفی انتخاب کنیم، احتمال اینکه ۵ نفر به A، ۳ نفر به B و ۲ نفر به C رأی داده باشند چقدر است؟

حل. (الف) $n=6$، $m=6$، همه $k_i=1$ و $p_i=\frac{1}{6}$: $\frac{6!}{1!\cdots 1!}\left(\frac{1}{6}\right)^6 = \frac{720}{46656} \approx 0.0154$.

(ب) $\frac{10!}{5!\,3!\,2!}(0.5)^5(0.3)^3(0.2)^2 = 2520 \times 0.03125 \times 0.027 \times 0.04 \approx 0.0851$. ■

۴.۳.۶ توزیع پواسون (Poisson Distribution)

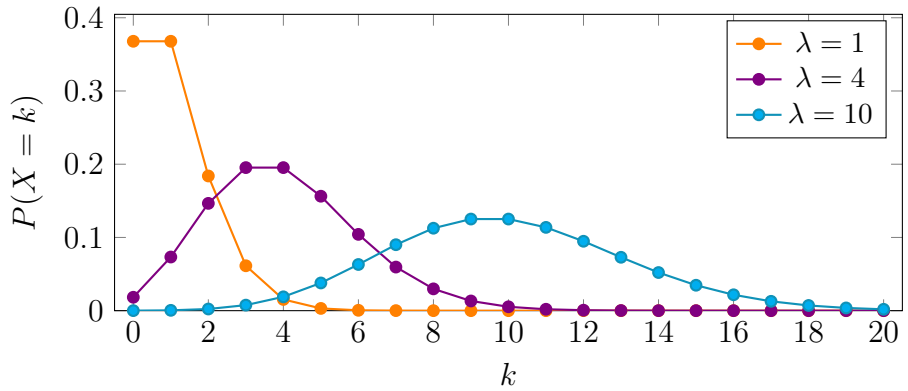
متغیر تصادفی پواسون کاربرد فراوانی در مدل‌سازی **تعداد پیشامدهای** یک ماهیت تصادفی بی‌حافظه در طول زمان دارد (مثلاً تعداد تماس‌های ورودی به یک مرکز تلفن در یک ساعت، تعداد بسته‌های رسیده به یک روتر در یک ثانیه، تعداد ذرات تابیده‌شده از یک ماده رادیواکتیو). این توزیع بر روی اعداد حسابی $k=0,1,2,\ldots$ تعریف شده و تنها دارای یک پارامتر آزاد $\lambda \in \mathbb{R}_{>0}$ (نرخ) است.

تعریف ۶-۹: توزیع پواسون

برای $X \sim \text{Pois}(\lambda)$:

$$P_X(k) = e^{-\lambda}\frac{\lambda^k}{k!}, \qquad k=0,1,\ldots$$

بررسی نرمال بودن: با بسط تیلور $e^{\lambda} = \sum_{k\geq 0}\frac{\lambda^k}{k!}$ داریم $\sum_k P_X(k) = e^{-\lambda}e^{\lambda} = 1$.



۵.۳.۶ خواص توزیع پواسون: حد توزیع دوجمله‌ای

توزیع پواسون نتیجه یکی از حالت‌های توزیع دوجمله‌ای (Binomial) است.

قضیه ۶-۱۰: تقریب پواسون

در توزیع دوجمله‌ای $\text{Binomial}(n,p)$، فرض کنید $n \to \infty$ و $p \to 0$ به طوری که حاصل‌ضرب آن‌ها عددی ثابت بماند، یعنی $np = \lambda$. آنگاه برای هر k ثابت ($k \ll n$):

$$\binom{n}{k} p^k (1-p)^{n-k} \longrightarrow \frac{\lambda^k}{k!} e^{-\lambda}.$$

اثبات.

$$\binom{n}{k} p^k (1-p)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!}\, p^k (1-p)^{n-k}.$$

سه عامل را جداگانه بررسی می‌کنیم:

- $\dfrac{n(n-1)\cdots(n-k+1)}{n^k} = 1 \cdot \left(1-\frac{1}{n}\right)\cdots\left(1-\frac{k-1}{n}\right) \to 1$؛ پس صورت تقریباً n^k است و $n^k p^k = (np)^k = \lambda^k$.
- $(1-p)^{-k} \to 1$ چون $p \to 0$ و k ثابت است؛ پس $(1-p)^{n-k} \simeq (1-p)^n$.
- $(1-p)^n = \left(1-\frac{\lambda}{n}\right)^n \to e^{-\lambda}$ (حد معروف).

پس

$$\simeq \frac{n^k p^k}{k!}(1-p)^n \simeq \frac{(np)^k}{k!} e^{-np},$$

که در حد، دقیقاً برابر با این مقدار خواهد شد. □

نکته. تعبیر: پواسون مدل «تعداد زیادی فرصت مستقل، هر یک با احتمال بسیار کم» است: مثلاً یک ساعت را به n بازه بسیار کوچک تقسیم کنید که در هر کدام با احتمال $p = \lambda/n$ یک تماس رخ می‌دهد. وقتی $n \to \infty$، تعداد تماس‌ها پواسون با میانگین λ می‌شود. به همین دلیل پواسون برای رخدادهای «نادر» و «بی‌حافظه» در زمان به کار می‌رود.

مثال ۶-۱۱: دقت تقریب پواسون

در یک خط تولید هر قطعه با احتمال 0.002 معیوب است. در یک محموله ۱۰۰۰تایی، احتمال اینکه دقیقاً ۳ قطعه معیوب باشد را به صورت دقیق و با تقریب پواسون حساب کنید.

حل. مقدار دقیق (دوجمله‌ای): $\binom{1000}{3}(0.002)^3(0.998)^{997} \approx 0.1806$. تقریب پواسون با $\lambda = np = 2$: $e^{-2}\frac{2^3}{3!} \approx 0.1804$. جدول زیر نشان می‌دهد تقریب برای همه kها بسیار دقیق است:

k	0	1	2	3	4	5
دوجمله‌ای	0.1351	0.2707	0.2709	0.1806	0.0902	0.0360
پواسون	0.1353	0.2707	0.2707	0.1804	0.0902	0.0361

■

۶.۳.۶ توزیع هندسی (Geometric) ــ تکمیلی

اگر آزمون‌های برنولی مستقل با احتمال موفقیت p را تا رسیدن به **اولین** موفقیت تکرار کنیم، تعداد آزمون‌ها X توزیع هندسی دارد:

$$P_X(k) = (1-p)^{k-1}p, \qquad k = 1, 2, \dots$$

زیرا باید $k-1$ شکست متوالی و سپس یک موفقیت رخ دهد. جمع احتمال‌ها یک سری هندسی است: $p\sum_{k\geq 1}(1-p)^{k-1} = p\cdot\frac{1}{p} = 1$. این توزیع همتای گسسته توزیع نمایی (جلسه بعد) و تنها توزیع گسسته **بی‌حافظه** است.

۴.۶ تمرین‌های تکمیلی

تمرین ۶-۱۲

ثابت c را چنان بیابید که $P_X(k) = c\,(1/3)^k$ برای $k = 0, 1, 2, \dots$ یک PMF باشد. سپس $P(X \geq 2)$ را حساب کنید.

حل. $\sum_{k\geq 0}(1/3)^k = \frac{1}{1-1/3} = \frac{3}{2}$؛ پس $c = \frac{2}{3}$. آنگاه $P(X \geq 2) = 1 - P(0) - P(1) = 1 - \frac{2}{3} - \frac{2}{9} = \frac{1}{9}$.
■

تمرین ۶-۱۳

به یک سرور به طور متوسط ۳ درخواست در دقیقه می‌رسد (مدل پواسون). احتمال اینکه در یک دقیقه مشخص هیچ درخواستی نرسد، و احتمال اینکه بیش از ۲ درخواست برسد چقدر است؟

حل. $X \sim \text{Pois}(3)$. $P(X = 0) = e^{-3} \approx 0.0498$. $P(X > 2) = 1 - e^{-3}\big(1 + 3 + \frac{9}{2}\big) = 1 - 8.5e^{-3} \approx 1 - 0.4232 = 0.5768$.
■

تمرین ۶-۱۴

یک بسته داده از طریق کانالی ارسال می‌شود که هر بیت را مستقلاً با احتمال 10^{-3} خراب می‌کند. بسته ۲۰۰۰ بیتی است و کد تصحیح خطا تا ۲ بیت خطا را تصحیح می‌کند. احتمال دریافت صحیح بسته را تقریب بزنید.

حل. تعداد بیت‌های خراب $X \sim \text{Binomial}(2000, 10^{-3}) \approx \text{Pois}(2)$. احتمال موفقیت: $P(X \leq 2) \approx e^{-2}(1 + 2 + 2) = 5e^{-2} \approx 0.677$.
■

تمرین ۶-۱۵

تاسی را آن‌قدر می‌اندازیم تا ۶ بیاید. احتمال اینکه بیش از ۱۰ پرتاب لازم باشد چقدر است؟

حل. تعداد پرتاب‌ها هندسی با $p = \frac{1}{6}$ است. «بیش از ۱۰ پرتاب لازم باشد» یعنی ۱۰ پرتاب اول همگی شکست باشند: $P(X > 10) = (5/6)^{10} \approx 0.1615$.
■

جلسه ۷

متغیرهای تصادفی پیوسته، CDF و PDF

۱.۷ متغیرهای تصادفی پیوسته (Continuous R.V.s)

پیش‌تر دیدیم که مدل‌سازی تصادفی یک واقعه، معادل با تعریف یک فضای احتمال به صورت $(\Omega, \mathcal{F}, P)$ است. این تعاریف، در مورد خود یک متغیر تصادفی نیز برقرار هستند: می‌توانیم به جای فضای پیچیده اولیه، مجموعه مقادیر خود متغیر تصادفی را به عنوان فضای نمونه در نظر بگیریم. برای مثال، در مورد یک متغیر تصادفی گسسته، Ω فضای شمارای مقادیری است که متغیر می‌تواند بگیرد:

- برای متغیر تصادفی برنولی داریم $\Omega = \{0, 1\}$،
- در مورد یک توزیع دوجمله‌ای داریم $\Omega = \{0, 1, \dots, n\}$،
- و برای متغیر تصادفی با توزیع پواسون خواهیم داشت $\Omega = \mathbb{N}_{\geq 0}$.

در تمام موارد بالا، برای فضای وقایع (یعنی $\mathcal{F}$)، قرار می‌دهیم $\mathcal{F} = 2^{\Omega}$.

۱.۱.۷ مشکل فضای ناشمارا

در مورد متغیرهای تصادفی پیوسته (Continuous R.V.s) معمولاً داریم $\Omega = \mathbb{R}$. در این حالات معمولاً (البته نه همیشه!) احتمال بروز تک‌مقدارها صفر هستند. برای مثال، اگر X یک متغیر تصادفی کاملاً پیوسته باشد، خواهیم داشت:

$$\mathbb{P}(X = 1.2) = \mathbb{P}(X = -\sqrt{2}) = \cdots = 0.$$

پرسش: اما احتمال بازه‌ها چطور؟ آیا می‌توان مطابق رابطه زیر نتیجه گرفت؟ چرا این رابطه اشتباه است؟

$$\mathbb{P}(X \in A) = \sum_{x \in A} \mathbb{P}(X = x), \qquad \forall A \in \mathcal{F}.$$

پاسخ. این رابطه اشتباه است زیرا اصل جمع‌پذیری کولموگروف فقط برای اجتماع‌های **شمارا** برقرار است، در حالی که یک بازه مانند $[0, 1]$ اجتماع **ناشمارایی** از نقاط است. اگر این رابطه درست بود، چون همه $\mathbb{P}(X = x) = 0$ هستند، نتیجه می‌گرفتیم $\mathbb{P}(X \in \mathbb{R}) = \sum_{x \in \mathbb{R}} 0 = 0$، که با $\mathbb{P}(\Omega) = 1$ در

تناقض است. پس احتمال یک بازه را نمی‌توان از احتمال نقاط آن به دست آورد؛ بلکه باید مستقیماً برای مجموعه‌ها (بازه‌ها) احتمال تعریف کنیم.

همان‌طور که ملاحظه کردید، در مورد متغیرهای تصادفی پیوسته می‌بایست به صورت مجزا برای زیرمجموعه‌های $\mathbb{R}$ احتمال تعریف کنیم (نمی‌توانیم مستقیماً از اصول کولموگروف استفاده کرده و احتمالشان را به صورت جمع احتمال اعضای آنان بنویسیم؛ به دلیل **ناشمارا** (uncountable) بودن).

اما این سؤال مطرح می‌شود که برای کدام زیرمجموعه‌های $\mathbb{R}$ می‌توانیم احتمال تعریف کنیم... بهتر است سراغ تمام زیرمجموعه‌های موجود در $2^{\mathbb{R}}$ نرویم! (برای مطالعه بیشتر به سراغ عواقب ناخواسته **اصل انتخاب** (Axiom of Choice) در مجموعه‌ها، و همچنین Banach–Tarski paradox بروید.)

نکته. چرا همه زیرمجموعه‌ها نه؟ با پذیرش اصل انتخاب می‌توان زیرمجموعه‌هایی «بسیار عجیب» از $\mathbb{R}$ ساخت (مانند مجموعه ویتالی) که به هیچ وجه نمی‌توان به آن‌ها «طول» یا «احتمال» سازگار با اصول کولموگروف نسبت داد. پارادوکس باناخ–تارسکی حتی نشان می‌دهد که یک کره را می‌توان به چند تکه (غیراندازه‌پذیر) تقسیم کرد و با جابه‌جایی و چرخش آن‌ها دو کره هم‌اندازه کره اول ساخت! پس باید خود را به زیرمجموعه‌های «خوش‌رفتار» محدود کنیم.

۲.۱.۷ مجموعه‌ها و میدان سیگمای بورل (Borel Sets and Borel σ-Field)

به جای تمامی زیرمجموعه‌های $\mathbb{R}$، فقط سراغ زیرمجموعه‌های معقول و زیبای آن می‌رویم! و صرفاً برای آنان احتمال تعریف می‌کنیم.

تعریف ۷-۱: مجموعه بورل

زیرمجموعه‌های معقول و زیبا (nice) روی $\mathbb{R}$ را به صورت زیر تعریف می‌کنیم:

$$\bigcup_{i=1}^{\infty} I_i \subseteq \mathbb{R}, \qquad \text{where} I_i \text{intervals are s},$$

که در اینجا، هر I_i یک بازه کاملاً دلخواه (مانند $(-\infty, 4.7]$، یا $(3, 4.2)$، یا $[1, 1]$، و غیره) روی $\mathbb{R}$ است. همچنین دنباله $\{I_1, I_2, \dots\}$ می‌تواند محدود، یا نامحدود (ولی شمارا) باشد. به هر زیرمجموعه‌ای از $\mathbb{R}$ که بتواند به شکل بالا (یا متمم آن، و به‌طور کلی با تکرار شمارای این اعمال) نوشته شود یک Borel set می‌گوییم.

قضیه ۷-۲

مجموعه تمام Borel setهای روی $\mathbb{R}$ تشکیل یک σ-Field می‌دهند. به آن **میدان سیگمای بورل** گفته و با $\mathcal{B}(\mathbb{R})$ نشان می‌دهیم. (به طور دقیق، $\mathcal{B}(\mathbb{R})$ کوچک‌ترین میدان سیگمایی است که شامل همه بازه‌هاست.)

تقریباً هر مجموعه‌ای که در عمل با آن سر و کار داریم بورل است: بازه‌ها، نقاط تکی، مجموعه‌های شمارا (مثل اعداد گویا)، اجتماع و اشتراک شمارای بازه‌ها و ...

در این صورت، می‌توانیم با خیال راحت فضای وقایع قابل اندازه‌گیری (یعنی $\mathcal{F}$) را به صورت یک Borel

σ-Field روی $\mathbb{R}$ در نظر بگیریم.

۳.۱.۷ کافی بودن احتمال بازه‌ها

در این صورت، برای تعریف احتمال برای تمامی اعضای $\mathcal{F}$ (یعنی یک واقعه یا Event)، کافی است احتمال را برای هر بازه (مثلاً $(a, b]$) به ازای تمامی مقادیر $a, b \in \mathbb{R}$ با شرط $b \geq a$ تعریف کرده باشیم. سپس با استفاده از قوانین کولموگروف احتمال تمامی وقایع به صورت خودکار تعریف می‌شود.

پرسش: چرا؟

پاسخ. هر مجموعه بورل از بازه‌ها با تعداد شمارایی عمل اجتماع، اشتراک و متمم ساخته می‌شود. اصول کولموگروف دقیقاً به ما می‌گویند احتمال تحت این اعمال چگونه رفتار می‌کند:

- احتمال اجتماع شمارای بازه‌های ناسازگار = جمع احتمال بازه‌ها (جمع‌پذیری شمارا)؛ هر اجتماع شمارا از بازه‌ها را هم می‌توان به اجتماع شمارای بازه‌های ناسازگار تبدیل کرد.
- احتمال متمم = یک منهای احتمال.
- احتمال یک نقطه هم از بازه‌ها به دست می‌آید: $\{a\} = \bigcap_n (a - \frac{1}{n}, a]$ و با پیوستگی احتمال $\mathbb{P}(X = a) = \lim_n \mathbb{P}(a - \frac{1}{n} < X \leq a)$.

بنابراین احتمال هر مجموعه بورل به‌طور یکتا از احتمال بازه‌ها تعیین می‌شود. (اثبات کامل این گزاره ــ «قضیه گسترش کاراتئودوری» ــ در درس نظریه اندازه دیده می‌شود.)

پس به یک تابع مانند $P(a, b)$ نیاز داریم که به ازای a, b ورودی احتمال بازه $(a, b]$ را بازگرداند. اما می‌توان به راحتی این تابع را به یک متغیر ورودی کاهش داد. **چگونه؟** چون $(-\infty, b] = (-\infty, a] \cup (a, b]$ و این دو ناسازگارند:

$$P\big((a, b]\big) = P\big((-\infty, b]\big) - P\big((-\infty, a]\big).$$

پس کافی است تابع یک‌متغیره $x \mapsto P((-\infty, x])$ را بدانیم. این همان تابع توزیع انباشته است.

۲.۷ تابع توزیع انباشته (Cumulative Distribution Function)

تعریف ۷-۳: تابع توزیع انباشته (CDF)

تابع توزیع انباشته (CDF) متغیر تصادفی X را به صورت زیر تعریف می‌کنیم:

$$F_X(x) = \mathbb{P}\{X \leq x\}.$$

لذا F_X یک تابع از اعداد (مثلاً اعداد حقیقی) به بازه بسته $[0, 1]$ است.

دقت کنید! اشتباه رایج: دقت کنید که در این رابطه، X بیان‌گر منتسب بودن F_X به یک متغیر تصادفی خاص است. ولی x یک عدد (مثلاً یک عدد حقیقی) و در اینجا صرفاً یک متغیر کمکی (در اصطلاح dummy variable) است. مثلاً $F_X(2) = \mathbb{P}(X \leq 2)$ و $F_Y(2) = \mathbb{P}(Y \leq 2)$ دو عدد متفاوت‌اند.

قضیه ۷-۴: ویژگی‌های CDF

برای هر متغیر تصادفی X:

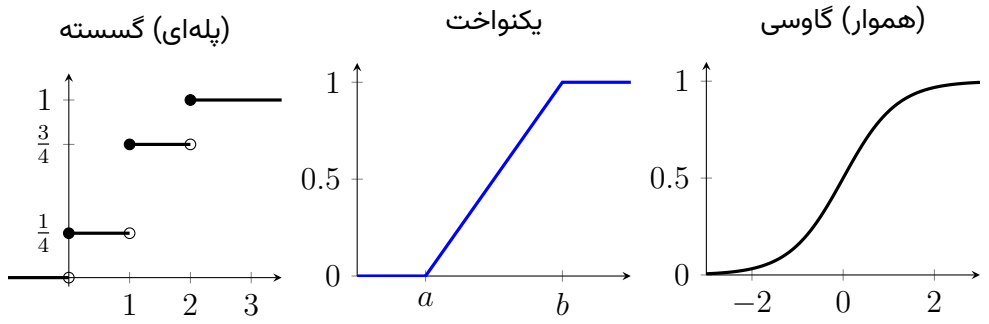
۱. تابع F_X **صعودی** (غیرنزولی) است، ولی لزوماً **اکیداً صعودی** نیست.

۲. مقادیر حدی: $F_X(+\infty) = \lim_{x\to+\infty} F_X(x) = 1.$ $\quad F_X(-\infty) = \lim_{x\to-\infty} F_X(x) = 0,$

۳. F_X از راست پیوسته است: $\lim_{h\to0^+} F_X(x+h) = F_X(x)$.

۴. $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$ و $\mathbb{P}(X = a) = F_X(a) - F_X(a^-)$ (اندازه پرش در نقطه a).

اثبات. (۱) اگر $x < y$ آنگاه $\{X \leq x\} \subseteq \{X \leq y\}$ و طبق یکنوایی احتمال، $F_X(x) \leq F_X(y)$. اما اکیداً صعودی نیست چون اگر X هیچ مقداری در بازه $(x, y]$ نگیرد، $\mathbb{P}(x < X \leq y) = 0$ و F_X روی این بازه ثابت می‌ماند (مانند نواحی افقی در CDF یک متغیر گسسته، یا بیرون بازه $[a, b]$ در توزیع یکنواخت). (۲) وقتی $x \to -\infty$، رویدادهای $\{X \leq x\}$ به $\varnothing$ و وقتی $x \to +\infty$ به Ω میل می‌کنند؛ با پیوستگی احتمال حدود ۰ و ۱ به دست می‌آیند. (۳) و (۴) نیز از پیوستگی احتمال و تعریف به دست می‌آیند. □



شکل ۱.۷: سه نمونه CDF: سمت راست مربوط به تعداد شیرها در دو پرتاب سکه (پرش‌هایی به اندازه $\frac{1}{4}, \frac{1}{2}, \frac{1}{4}$)، وسط توزیع یکنواخت روی $[a, b]$، و چپ یک CDF هموار.

نکته. CDF برای **همه** متغیرهای تصادفی (گسسته، پیوسته یا ترکیبی) تعریف می‌شود و توزیع را به‌طور کامل مشخص می‌کند. برای متغیر گسسته، CDF پله‌ای است و ارتفاع هر پله برابر PMF در آن نقطه است.

۳.۷ تابع چگالی احتمال (Probability Density Function)

۱.۳.۷ مفهوم

کار کردن با تابع توزیع انباشته (CDF) مقداری سخت است:

- شهود بالایی نسبت به آن نداریم.
- اطلاعات محلی (localized) مناسبی از نواحی مختلف فضا به دست نمی‌دهد (مقدار $F_X(x)$ همه جرم احتمال در سمت چپ x را با هم جمع می‌کند).

برای حل این مشکل، از تابع چگالی احتمال (PDF) استفاده خواهد شد:

تعریف ۷-۵: تابع چگالی احتمال

$$f_X(x) = \lim_{h\to 0^+} \frac{P\big(x < X \le x+h\big)}{h} = \frac{\mathrm{d}F_X(x)}{\mathrm{d}x}.$$

عبارت وسط **مفهوم چگالی دارد**: احتمال (جرم) واقع در یک بازه کوچک تقسیم بر طول آن بازه ــ دقیقاً مانند چگالی جرم در فیزیک (جرم بر واحد طول). به بیان دیگر، برای h کوچک:

$$P(x < X \le x+h) \approx f_X(x)\, h.$$

۲.۳.۷ خواص و مقایسه با سایر توابع

تابع چگالی احتمال (PDF):

- $f_X(x)$ همواره نامنفی است ($f_X \ge 0$)؛ زیرا مشتق یک تابع صعودی است.
- $f_X(x)$ **لزوماً بین ۰ و ۱ نیست.** حتی ممکن است گاهی بی‌نهایت شود (دقت کنید که f_X به خودی خود معنای احتمال ندارد). مثال: برای $X \sim \mathrm{Uniform}(0, 0.1)$ داریم $f_X = 10$ روی بازه.
- شرط بهنجارش (Normalization criteria):

$$\int_{-\infty}^{+\infty} f_X(x)\,\mathrm{d}x = F_X(+\infty) - F_X(-\infty) = 1.$$

مقایسه توابع CDF، PDF، PMF و اندازه احتمال P

- **اندازه احتمال** P (Probability Measure or Law): عضو سوم فضای احتمال $(\Omega, \mathcal{F}, P)$، که به هر رویداد در $\mathcal{F}$ عددی در بازه $[0,1]$ نسبت می‌دهد که می‌بایست قوانین کولموگروف را رعایت نماید.
- **تابع توزیع انباشته CDF:** در نقطه $x \in R$ به معنای $P(X \le x)$ خواهد بود. CDF معنای احتمال دارد و بین $[0,1]$ خواهد بود. همچنین تابعی صعودی است که در $-\infty$ برابر با صفر، و در $+\infty$ برابر با یک است.
- **تابع چگالی احتمال PDF:** مشتق تابع CDF، که همواره نامنفی و عددی در $\mathbb{R}_{\ge 0}$ خواهد بود. PDF مفهوم احتمال ندارد، و صرفاً انتگرال آن معنای احتمال می‌دهد:

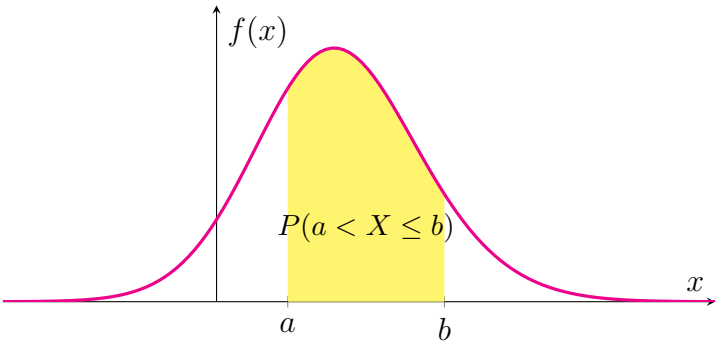
$$\boxed{P\big(a < X \le b\big) = \int_a^b f_X(x)\,\mathrm{d}x = F_X(b) - F_X(a)}$$

- **تابع جرم احتمال PMF:** زمانی که Ω مجموعه‌ای محدود (یا شمارا) باشد، برای $\Omega =$

$\{\omega_1, \ldots, \omega_N\}$ به صورت $p(\omega_i) = P(\{\omega_i\})$ تعریف می‌شود. لذا معنای احتمال دارد و همواره بین ۰ و ۱ است. همچنین، جمع PMF روی کل Ω برابر با ۱ می‌شود.

۳.۳.۷ مفهوم گرافیکی

احتمال اینکه X در بازه $(a, b]$ بیفتد، برابر **مساحت زیر منحنی** PDF بین a و b است:



نکته. برای متغیر پیوسته $P(X = a) = 0$، پس $P(a < X \leq b) = P(a \leq X \leq b) = P(a < X < b)$؛ یعنی باز یا بسته بودن انتهای بازه مهم نیست. این برای متغیرهای گسسته **درست نیست**.

۴.۷ متغیرهای تصادفی پیوسته معروف

۱.۴.۷ توزیع یکنواخت (Uniform Distribution)

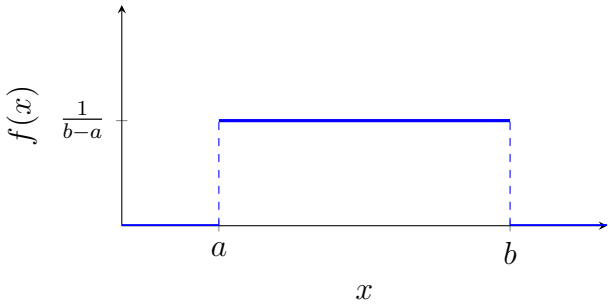
متغیر تصادفی یکنواخت، دارای بیشترین آنتروپی (تصادفی بودن) بین تمامی متغیرهای تصادفی با $\Omega = [a, b]$ است؛ یعنی وقتی فقط می‌دانیم مقدار در $[a, b]$ است و هیچ اطلاع دیگری نداریم، «بی‌طرفانه‌ترین» مدل است. این متغیر تصادفی دارای دو پارامتر آزاد a و b ($b > a$) است.

تعریف ۷-۶: توزیع یکنواخت

برای $X \sim \text{Uniform}(a, b)$:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{o.w.} \end{cases} \qquad F_X(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$$

احتمال هر زیربازه $[c, d] \subseteq [a, b]$ متناسب با طول آن است: $P(c \leq X \leq d) = \frac{d-c}{b-a}$.



۲.۴.۷ توزیع نمایی (Exponential Distribution)

توزیع نمایی (Exponential) دارای یک پارامتر آزاد به صورت $\lambda \in \mathbb{R}_{>0}$ است.

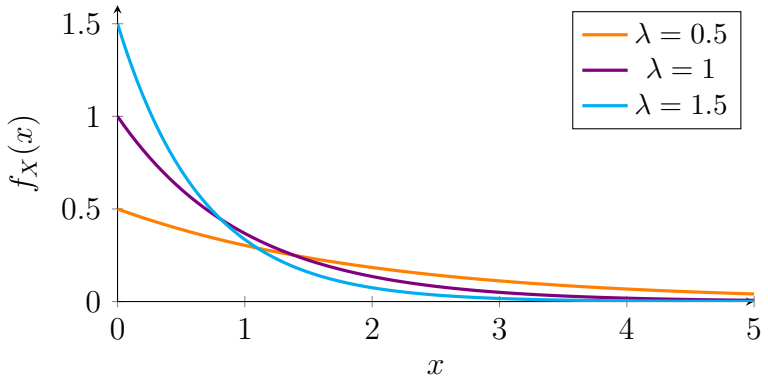
تعریف ۷-۷: توزیع نمایی

برای $X \sim \text{exponential}(\lambda)$:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases} \qquad F_X(x) = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

محاسبه CDF: برای $x \geq 0$، $F_X(x) = \int_0^x \lambda e^{-\lambda t}\,\mathrm{d}t = \big[-e^{-\lambda t}\big]_0^x = 1 - e^{-\lambda x}$.

این توزیع معمولاً برای مدل‌سازی **زمان وقوع** یک رخداد **بی‌حافظه** مورد استفاده قرار می‌گیرد (مثلاً زمان تا خرابی یک قطعه الکترونیکی، یا زمان بین دو تماس متوالی در فرایند پواسون).



قضیه ۷-۸: خاصیت بی‌حافظگی

اگر $X \sim \text{exponential}(\lambda)$، آنگاه برای هر $s, t \geq 0$:

$$P(X > s + t \,|\, X > s) = P(X > t).$$

اثبات. $P(X > x) = 1 - F_X(x) = e^{-\lambda x}$. پس

$$\begin{aligned} P(X > s + t \,|\, X > s) &= \frac{P(X > s + t,\ X > s)}{P(X > s)} = \frac{P(X > s + t)}{P(X > s)} \\ &= \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t). \end{aligned}$$

□

تعبیر: اگر یک لامپ با طول عمر نمایی تا لحظه s سالم مانده باشد، احتمال اینکه t واحد دیگر هم سالم بماند دقیقاً مثل یک لامپ نو است؛ لامپ «پیر نمی‌شود».

۳.۴.۷ توزیع گاوسی یا نرمال (Gaussian or Normal Distribution)

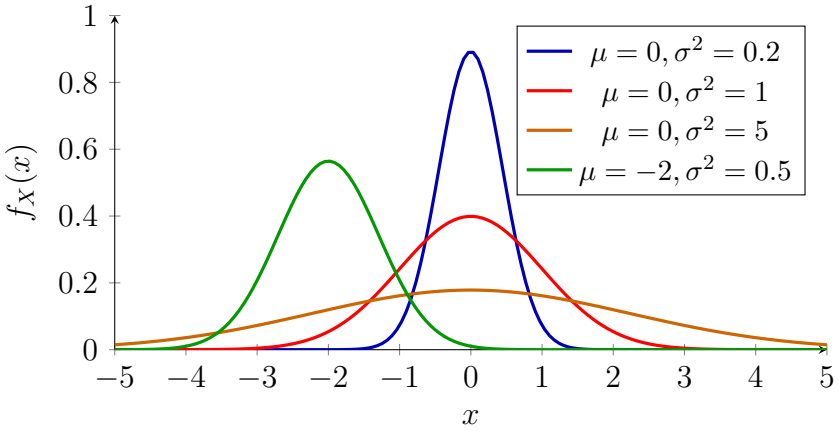
یکی از پرکاربردترین توزیع‌های آماری، توزیع احتمال گاوسی یا نرمال است. توزیع گاوسی $\mathcal{N}(\mu, \sigma^2)$ با دو پارامتر آزاد مشخص می‌شود:

- **میانگین** (mean) $\mu \in \mathbb{R}$، و **واریانس** (variance) $\sigma^2 \in \mathbb{R}_{\geq 0}$.
- به خود مقدار $\sigma \in \mathbb{R}_{\geq 0}$ **انحراف معیار** (standard deviation) اطلاق می‌گردد.

تعریف ۷-۹: توزیع گاوسی

برای $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$



خواص توزیع گاوسی

- حول میانگین μ متقارن است. همچنین، بیشینه چگالی احتمال نیز در همین نقطه رخ می‌دهد (مقدار آن $\frac{1}{\sqrt{2\pi}\sigma}$ است).
- دم توزیع (tail) خیلی سریع افت می‌کند (با سرعت e^{-x^2}).
- در طبیعت بسیار ظاهر می‌شود (**قضیه حد مرکزی**): مجموع تعداد زیادی اثر کوچک و مستقل، تقریباً گاوسی است.

تابع توزیع انباشته: انتگرال تابع گاوسی شکل بسته ندارد؛ لذا آن را بر حسب «تابع خطا» بیان می‌کنیم:

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2}\,\mathrm{d}t, \qquad F_X(x) = \frac{1}{2} + \frac{1}{2}\operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\,\sigma}\right).$$

استخراج. با تغییر متغیر $t := \frac{u-\mu}{\sqrt{2}\sigma}$ داریم $F_X(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(u-\mu)^2}{2\sigma^2}}\,\mathrm{d}u = \frac{1}{\sqrt{\pi}} \int_{-\infty}^{z} e^{-t^2}\,\mathrm{d}t$ با $z = \frac{x-\mu}{\sqrt{2}\sigma}$. چون $\int_{-\infty}^{0} e^{-t^2}\,\mathrm{d}t = \frac{\sqrt{\pi}}{2}$، داریم $F_X(x) = \frac{1}{2} + \frac{1}{\sqrt{\pi}} \int_{0}^{z} e^{-t^2}\,\mathrm{d}t = \frac{1}{2} + \frac{1}{2}\mathrm{erf}(z)$. □

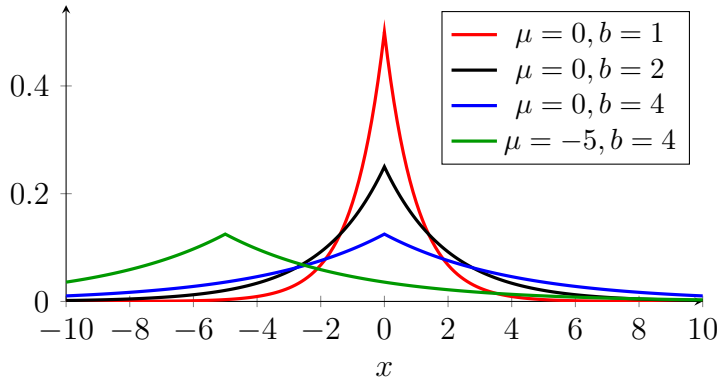
نکته. در آمار معمولاً از CDF گاوسی استاندارد $\Phi(z) = P(Z \le z)$ برای $Z \sim \mathcal{N}(0,1)$ استفاده می‌شود: $F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$. قاعده معروف «۶۸، ۹۵ و ۹۹٫۷ درصد»: $P(|X-\mu| \le \sigma) \approx 0.683$، $P(|X-\mu| \le 2\sigma) \approx 0.954$ و $P(|X-\mu| \le 3\sigma) \approx 0.997$.

۴.۴.۷ توزیع لاپلاس (Laplace Distribution)

توزیع لاپلاس (Laplace) دارای دو پارامتر آزاد به صورت $b \in \mathbb{R}_{>0}$ و میانگین $\mu \in \mathbb{R}$ است. برای $X \sim \mathrm{Laplace}(\mu, b)$:

$$f_X(x) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}.$$

این توزیع از دو توزیع نمایی پشت به پشت تشکیل شده و دم آن (به صورت $e^{-|x|}$) کندتر از گاوسی افت می‌کند؛ پس مقادیر دور از میانگین در آن محتمل‌ترند. (بررسی بهنجارش: $\int \frac{1}{2b} e^{-|x-\mu|/b}\,\mathrm{d}x = 2 \times \frac{1}{2}\int_0^\infty \frac{1}{b} e^{-u/b}\,\mathrm{d}u = 1$.)

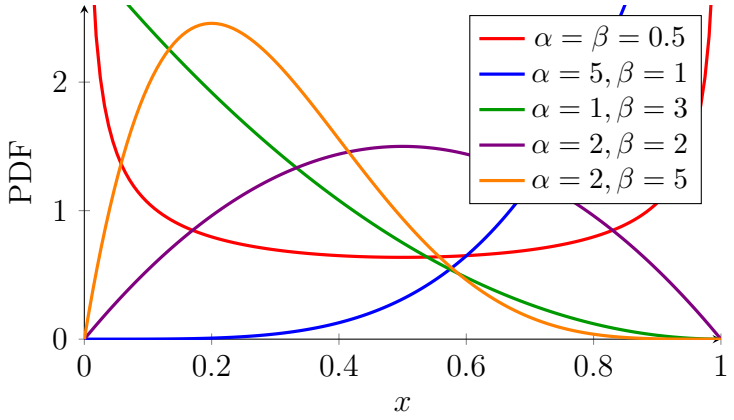


۵.۴.۷ توزیع بتا (Beta Distribution)

متغیر تصادفی بتا بین ۰ و ۱ تعریف شده و معمولاً برای مدل‌سازی احتمالاتی **خود احتمال وقوع یک پدیده** به کار می‌رود (مثلاً احتمال شیر آمدن یک سکه ناشناخته). این متغیر تصادفی دارای دو پارامتر آزاد $\alpha, \beta \in \mathbb{R}_{>0}$ است. به این پارامترها، پارامترهای شکلی (shape parameters) نیز اطلاق می‌گردد. برای $X \sim \mathrm{Beta}(\alpha, \beta)$ در بازه $[0,1]$ یا $(0,1)$ (بسته به پارامترها):

$$f_X(x) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1},$$

که در آن $\Gamma(z) = \int_0^\infty t^{z-1}e^{-t}\,\mathrm{d}t$ تابع گاما است (تعمیم فاکتوریل: $\Gamma(n) = (n-1)!$).



نکته. $\text{Beta}(1,1)$ همان $\text{Uniform}(0,1)$ است. منحنی $\alpha = \beta = 0.5$ مثالی از چگالی است که در دو انتها به بی‌نهایت می‌رود (هرچند مساحت زیر آن ۱ است).

۶.۴.۷ برخی توزیع‌های کمتر کاربردی...

توزیع	پارامترها	تکیه‌گاه	PDF
رایلی (Rayleigh)	$\sigma > 0$	$x \in [0, \infty)$	$\frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)}$
ارلانگ (Erlang)	$k \in \{1, 2, \ldots\},\ \lambda > 0$	$x \in [0, \infty)$	$\frac{\lambda^k x^{k-1} e^{-\lambda x}}{(k-1)!}$
لاگ‌نرمال (Log-normal)	$\mu \in \mathbb{R},\ \sigma > 0$	$x \in (0, \infty)$	$\frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right)$

- **رایلی:** (با CDF برابر $1 - e^{-x^2/(2\sigma^2)}$) اندازه یک بردار دوبعدی با مؤلفه‌های گاوسی مستقل (مثلاً دامنه سیگنال در کانال‌های بی‌سیم با محوشدگی).
- **ارلانگ:** زمان تا رخداد kام در یک فرایند پواسون؛ مجموع k متغیر نمایی مستقل. ($k = 1$ همان نمایی است.)
- **لاگ‌نرمال:** اگر $\ln X$ گاوسی باشد؛ برای کمیت‌هایی که حاصل‌ضرب عوامل تصادفی زیادند (مثل درآمد، اندازه فایل‌ها).

۵.۷ تمرین‌های تکمیلی

تمرین ۷-۱۰

فرض کنید $f_X(x) = cx^2$ برای $0 \le x \le 2$ و صفر در غیر این صورت. (الف) c را بیابید. (ب) $F_X(x)$ را بیابید. (ج) $P(1 < X \le 2)$ را حساب کنید.

حل. (الف) $\int_0^2 cx^2\,\mathrm{d}x = \frac{8c}{3} = 1 \Rightarrow c = \frac{3}{8}$. (ب) برای $0 \le x \le 2$: $F_X(x) = \int_0^x \frac{3}{8}t^2\,\mathrm{d}t = \frac{x^3}{8}$؛ برای $x < 0$ صفر و برای $x > 2$ یک. (ج) $F_X(2) - F_X(1) = 1 - \frac{1}{8} = \frac{7}{8}$. ■

تمرین ۷-۱۱

طول عمر یک هارد دیسک (بر حسب سال) نمایی با $\lambda = 0.2$ است. (الف) احتمال اینکه بیش از ۵ سال کار کند چقدر است؟ (ب) اگر دیسکی ۳ سال کار کرده باشد، احتمال اینکه دست‌کم ۵ سال دیگر کار کند چقدر است؟ (ج) میانه طول عمر (عدد m با $F(m) = \frac{1}{2}$) را بیابید.

حل. (الف) $P(X > 5) = e^{-0.2\times 5} = e^{-1} \approx 0.368$. (ب) با بی‌حافظگی: $P(X > 8 \,|\, X > 3) = P(X > 5) \approx 0.368$. (ج) $1 - e^{-0.2m} = \frac{1}{2} \Rightarrow m = \frac{\ln 2}{0.2} \approx 3.47$ سال. ■

تمرین ۷-۱۲

قد دانشجویان یک دانشگاه تقریباً $\mathcal{N}(170, 10^2)$ (سانتی‌متر) است. چند درصد دانشجویان بین ۱۶۰ و ۱۹۰ سانتی‌متر قد دارند؟ (از $\Phi(1) \approx 0.8413$ و $\Phi(2) \approx 0.9772$ استفاده کنید.)

حل. با استانداردسازی: $P(160 < X \le 190) = \Phi\big(\frac{190-170}{10}\big) - \Phi\big(\frac{160-170}{10}\big) = \Phi(2) - \Phi(-1) = \Phi(2) - (1 - \Phi(1)) \approx 0.9772 - 0.1587 = 0.8185$؛ یعنی حدود ۸۲٪. ■

تمرین ۷-۱۳

متغیر X با احتمال $\frac{1}{2}$ برابر صفر است و با احتمال $\frac{1}{2}$ از $\mathrm{Uniform}(0,1)$ پیروی می‌کند. CDF آن را رسم کنید. آیا X گسسته است یا پیوسته؟

حل. برای $x < 0$: $F = 0$. برای $0 \le x \le 1$: $F(x) = \frac{1}{2} + \frac{1}{2}x$. برای $x > 1$: $F = 1$. CDF در $x = 0$ پرشی به اندازه $\frac{1}{2}$ دارد و سپس به‌طور خطی تا ۱ بالا می‌رود. پس X نه کاملاً گسسته است و نه کاملاً پیوسته؛ یک متغیر **ترکیبی** (mixed) است. این مثال نشان می‌دهد چرا CDF کلی‌ترین ابزار توصیف توزیع است (این متغیر PDF معمولی ندارد). ■

جلسه ۸

تساوی‌های آماری، استقلال متغیرهای تصادفی و متغیرهای مخلوط

۱.۸ مفهوم almost sure در آمار و احتمال

- در مورد یک **متغیر یقینی** (Deterministic) مانند A، راحت می‌توانیم بگوییم $A = 2.7$.
- در مورد یک **متغیر تصادفی** (Random) مانند X، عبارت $X = 2.7$ معنی خیلی مشخصی می‌دهد: یعنی $\forall \omega \in \Omega$ خواهیم داشت $X(\omega) = 2.7$.

معمولاً مورد بالا را نمی‌توان به راحتی در مورد یک متغیر تصادفی فهمید، و سطح بالایی از دسترسی (به تک‌تک نقاط Ω) را می‌طلبد. در عوض، چیزی که معمولاً می‌توانیم بفهمیم این است که

$$\mathbb{P}\Big(\{\omega \in \Omega \mid X(\omega) = 2.7\}\Big) = 1,$$

یعنی متغیر تصادفی X **با احتمال ۱** مقدار 2.7 را به خود می‌گیرد.

تعریف ۸-۱: تساوی تقریباً حتمی

اگر $\mathbb{P}(X = c) = 1$ باشد می‌گوییم X almost surely equals to c یا

$$X \overset{\text{a.s.}}{=} c.$$

به طور کلی، یک گزاره درباره متغیرهای تصادفی «تقریباً حتماً» (a.s.) برقرار است اگر مجموعه ωهایی که در آن‌ها برقرار نیست، احتمال صفر داشته باشد. مثلاً $X \overset{\text{a.s.}}{=} Y$ یعنی $\mathbb{P}(X = Y) = 1$.

- این بدین معنی **نیست** که X **نمی‌تواند** مقداری غیر از 2.7 را به خود بگیرد. بلکه بدین معنی است که **احتمال آن صفر است**.
- یعنی در N آزمایش مستقل برای نمونه‌گیری از X، اگر $n(X \neq 2.7)$ را تعداد دفعاتی تعریف کنیم که X مقداری غیر از 2.7 گرفته، آنگاه خواهیم داشت:

$$\lim_{N \to \infty} \frac{n(X \neq 2.7)}{N} = 0.$$

- دقت کنید تساوی از حیث almost sure **ضعیف‌تر** از تساوی مطلق است: هر تساوی مطلق، تساوی a.s. هم هست، ولی عکس آن لزوماً درست نیست.

مثال ۸-۲: تفاوت تساوی مطلق و a.s.

فرض کنید $U \sim \text{Uniform}(0,1)$ و تعریف کنید $X = 0$ اگر U گویا باشد و $X = 1$ در غیر این صورت. آیا $X = 1$؟

حل. از نظر مطلق خیر: برای ωهایی که $U(\omega)$ گویاست، $X(\omega) = 0$. اما مجموعه اعداد گویای $[0,1]$ شماراست و احتمال هر نقطه برای متغیر پیوسته صفر است؛ پس طبق جمع‌پذیری شمارا $\mathbb{P}(U \in \mathbb{Q}) = \sum_q \mathbb{P}(U = q) = 0$. لذا $\mathbb{P}(X = 1) = 1$ و $X \overset{\text{a.s.}}{=} 1$. در عمل هرگز تفاوتی بین X و ثابت ۱ مشاهده نخواهیم کرد. ■

۲.۸ استقلال متغیرهای تصادفی

پیش‌تر **استقلال آماری** (Independence) میان دو رویداد $A, B \in \mathcal{F}$ را تعریف کرده بودیم: $\mathbb{P}(A,B) = \mathbb{P}(A)\mathbb{P}(B)$.

تعریف ۸-۳: استقلال دو متغیر تصادفی

دو متغیر تصادفی X, Y که روی یک فضای احتمال تعریف شده‌اند را مستقل گوییم، اگر به ازای تمام زیرمجموعه‌های «**خوبی**» (بورل) از اعداد حقیقی مانند $I_1, I_2 \subseteq \mathbb{R}$ داشته باشیم:

$$\forall I_1, I_2 \subseteq \mathbb{R}, \quad \begin{aligned} A &\triangleq \{\omega \,|\, X(\omega) \in I_1\} \\ B &\triangleq \{\omega \,|\, Y(\omega) \in I_2\} \end{aligned}, \quad \text{then} \quad A \perp B.$$

یعنی $\mathbb{P}(X \in I_1,\ Y \in I_2) = \mathbb{P}(X \in I_1)\mathbb{P}(Y \in I_2)$.

به عبارتی، هر رویدادی در ارتباط با فقط متغیر تصادفی X، از هر رویدادی که فقط مرتبط با متغیر تصادفی Y باشد، مستقل باشد.

نکته. در عمل کافی است این شرط را برای نیم‌خط‌ها چک کنیم: X و Y مستقل‌اند اگر و تنها اگر برای همه x, y: $\mathbb{P}(X \le x, Y \le y) = F_X(x)F_Y(y)$. برای متغیرهای گسسته معادل است با $\mathbb{P}(X = x, Y = y) = P_X(x)P_Y(y)$ و برای متغیرهای پیوسته (با چگالی توأم) معادل است با $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ (جلسات بعد).

۳.۸ متغیرهای تصادفی i.i.d.

تعریف ۸-۴: i.i.d.

متغیرهای تصادفی $X_1, X_2, \ldots, X_n$ را در نظر بگیرید. فرض کنید:

- تمامی این متغیرها از یکدیگر **مستقل** باشند؛ یعنی هیچ دو زیرمجموعه ناهم‌پوشان از این متغیرها، ارتباطی با دیگری نداشته باشد.
- توزیع تمام این متغیرها **یکسان** باشد؛ یعنی $X_1, X_2, \ldots, X_n \sim f_X(x)$.

در این صورت به این متغیرها independent and identically distributed یا به اختصار i.i.d. می‌گوییم.

مثال کلاسیک: نتایج n پرتاب مستقل یک تاس، یا n نمونه‌ای که از یک «جعبه سیاه» (جلسه ششم) گرفته می‌شود. فرض i.i.d. پایه بیشتر روش‌های آماری و یادگیری ماشین است (داده‌های آموزش معمولاً i.i.d. فرض می‌شوند).

دقت کنید! دقت کنید که دو متغیر تصادفی می‌توانند اصلاً مستقل نباشند (تقریباً هیچ دو متغیر تصادفی واقعی در جهان مستقل نیستند!). «هم‌توزیع بودن» و «مستقل بودن» دو مفهوم کاملاً جدا هستند:

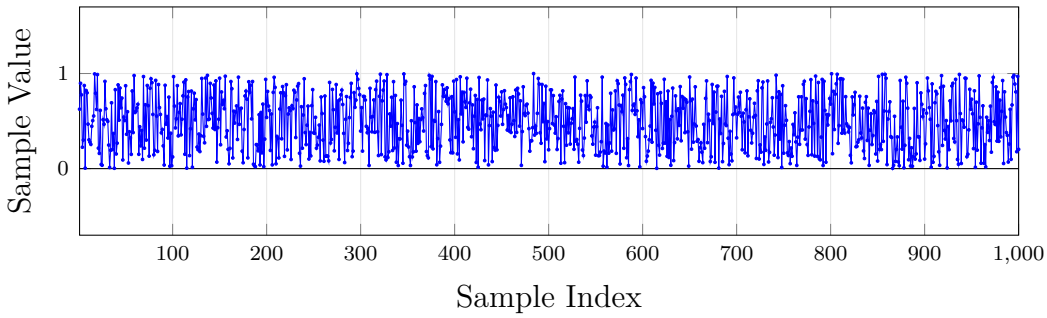
- مثلاً فرض کنید $X \sim \lambda e^{-\lambda x} u(x)$ توزیع نمایی داشته، و متغیر تصادفی $Y \sim \mathcal{N}(0,1)$ توزیع نرمال استاندارد داشته باشد. اما دانستن مقدار X، یا اطلاعاتی در مورد آن، باعث شود توزیع Y تغییر کند. این دو هم‌توزیع نیستند و مستقل هم نیستند.
- از سوی دیگر، این بار فرض کنید $X, Y \sim \mathcal{N}(0,1)$، یعنی **هم‌توزیع** باشند. با این اطلاعات در مورد ارتباط این دو با یکدیگر حرفی نمی‌توان زد. هم می‌توانیم داشته باشیم $X \perp Y$، و هم می‌توانیم داشته باشیم $X \overset{\text{a.s.}}{=} Y$ (یا حتی $Y = -X$ که آن هم $\mathcal{N}(0,1)$ است!).

۴.۸ رفتار دُم توزیع‌های مختلف

(Tail Behavior of Various Distributions)

در این بخش، برای هر توزیع یک نمونه ۱۰۰۰تایی i.i.d. تولید کرده‌ایم و مقادیر نمونه‌ها را بر حسب شماره نمونه رسم کرده‌ایم. سؤال این است: **با نگاه به نمونه‌ها، می‌توان حدس زد از کدام توزیع آمده‌اند؟** ویژگی مهمی که در این نمودارها دیده می‌شود، «**دُم**» (tail) توزیع است؛ یعنی اینکه احتمال مقادیر بسیار بزرگ با چه سرعتی کم می‌شود.

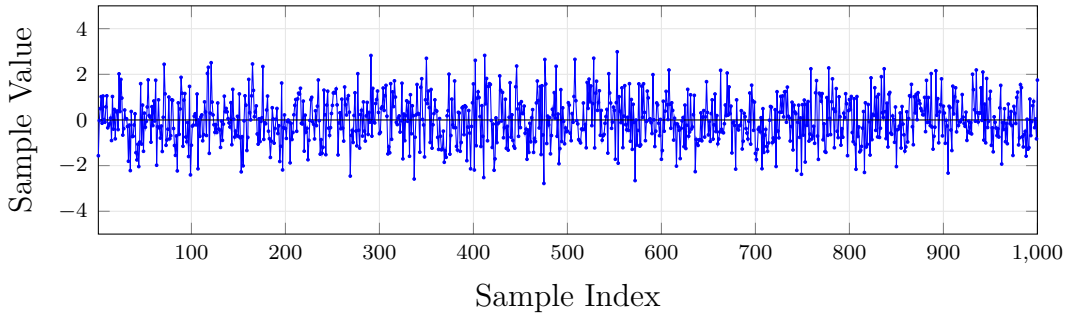
۱.۴.۸ نمونه اول



نمونه‌ها همگی بین ۰ و ۱ هستند و به طور یکنواخت پخش شده‌اند.

جواب: توزیع یکنواخت $X \sim \frac{\mathbf{1}(a \leq X \leq b)}{b-a}$، در اینجا $\text{Uniform}(0,1)$. دقت کنید تمام نمونه‌ها بین ۰ و ۱ هستند؛ این توزیع اصلاً دُم ندارد (تکیه‌گاه آن کران‌دار است).

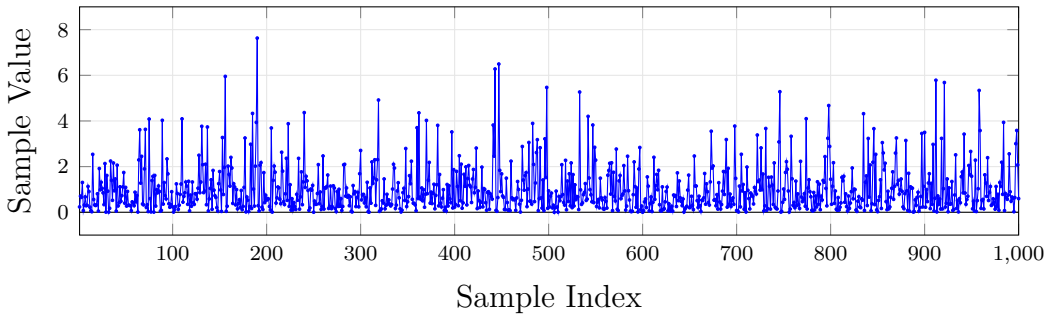
۲.۴.۸ نمونه دوم



نمونه‌ها حول صفر متمرکزند و هر از گاهی مقادیر بزرگ‌تر (تا حدود ± 3) دیده می‌شوند.

جواب: توزیع گاوسی $X \sim \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$، در اینجا $\mathcal{N}(0,1)$: هر از گاهی نمونه‌های بزرگ درست می‌شوند، ولی کماکان متمرکز هستند. طبق قاعده «۶۸، ۹۵ و ۷/۹۹ درصد»، تقریباً همه نمونه‌ها در بازه $[-3,3]$ می‌افتند؛ در ۱۰۰۰ نمونه انتظار داریم فقط حدود ۳ نمونه بیرون از این بازه باشند.

۳.۴.۸ نمونه سوم

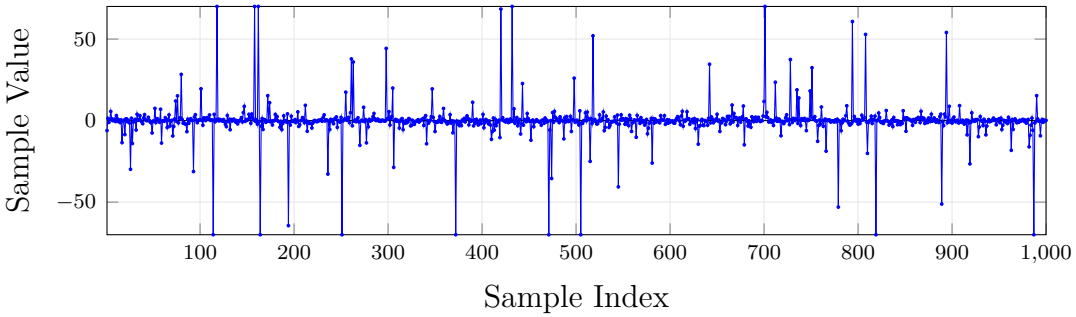


نمونه‌ها همگی نامنفی هستند و گاهی مقادیر بزرگ (تا حدود ۸) ظاهر می‌شوند.

جواب: توزیع نمایی $X \sim \lambda e^{-\lambda x} u(x)$، در اینجا $\text{Exp}(\lambda = 1)$. برخلاف توزیع گاوسی که چگالی دم آن $e^{-O(x^2)}$ است، دم نمایی از قدر مرتبه $e^{-O(x)}$ است و لذا spikeهای بزرگ بیشتر مشاهده می‌شوند. مثلاً

$\mathbb{P}(X > 5) = e^{-5} \approx 0.0067$ (حدود ۷ نمونه از ۱۰۰۰)، در حالی که برای گاوسی استاندارد $\mathbb{P}(Z > 5) \approx .3 \times 10^{-7}$

۴.۴.۸ نمونه چهارم



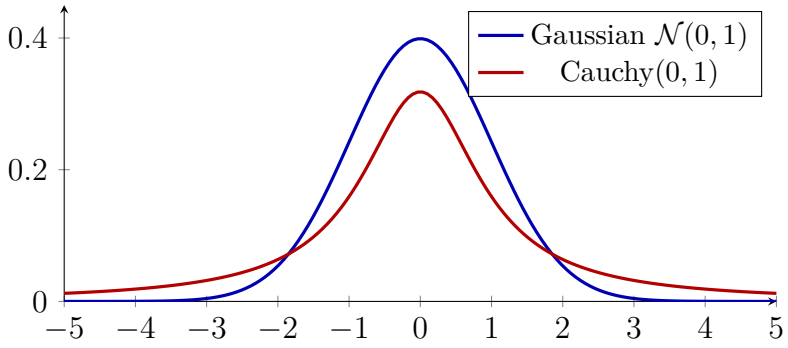
(مقادیر برای نمایش در بازه ± 70 بریده شده‌اند.) و اما مورد آخر... حدس شما چیست؟ چه چیزی در مورد این توزیع عجیب است؟

جواب: توزیع کوشی

$$X \sim \frac{1}{\pi(1+x^2)},$$

در اینجا $\mathrm{Cauchy}(0,1)$. چگالی دم این توزیع $O(1/x^2)$ است، و یکی از قوی‌دم‌ترین (heavy-tail) توزیع‌های دنیا محسوب می‌شود. لطفاً به Spikeهای آن دقت کنید! بیشتر نمونه‌ها نزدیک صفرند اما هر از گاهی مقادیری در حد ده‌ها یا صدها ظاهر می‌شوند.

نکته. چه چیزی عجیب است؟ برای کوشی، $\mathbb{P}(|X| > t) = 1 - \frac{2}{\pi}\arctan t \approx \frac{2}{\pi t}$؛ یعنی احتمال مقادیر بزرگ فقط به صورت $1/t$ کم می‌شود. مثلاً $\mathbb{P}(|X| > 60) \approx 0.0106$، پس در ۱۰۰۰ نمونه حدود ۱۰ نمونه بزرگ‌تر از ۶۰ (از نظر قدر مطلق) خواهیم داشت! نتیجه عجیب‌تر (که در جلسات بعد می‌بینیم): این توزیع **میانگین ندارد** ــ انتگرال $\int |x| \frac{1}{\pi(1+x^2)}\,\mathrm{d}x$ واگراست ــ و میانگین نمونه‌ای $\frac{1}{n}\sum X_i$ هیچ‌گاه همگرا نمی‌شود (در واقع خودش دوباره کوشی استاندارد است!).



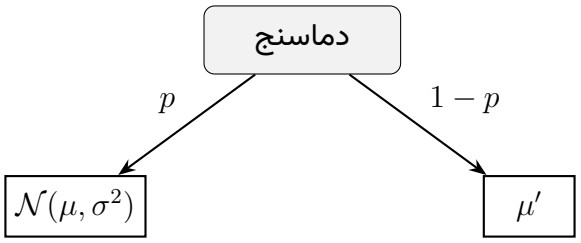
۵.۸ متغیرهای تصادفی مخلوط (گسسته و پیوسته)

مثال ۸-۵: دماسنج نامطمئن

فرض کنید قصد داریم تا دمای یک محیط را با یک دماسنج دیجیتال نامطمئن اندازه‌گیری کنیم:

- در هر بار اندازه‌گیری، دماسنج با احتمال موفقیت p کار کرده و خروجی آن به شکل یک توزیع گاوسی (با انحراف معیار σ) حول دمای واقعی (که با μ نشان داده می‌شود) ظاهر می‌گردد.
- اما دماسنج با احتمال $1-p$ کار نکرده و دمای پیش‌فرض «μ'» را نشان خواهد داد.

سؤال: در صورتی که عدد خروجی دماسنج را با متغیر تصادفی X نشان دهیم، توزیع آن را بیابید.



ابتدا CDF را با قانون احتمال کل می‌نویسیم (W = «دماسنج کار کند»):

$$F_X(x) = \mathbb{P}(X \le x \,|\, W)\mathbb{P}(W) + \mathbb{P}(X \le x \,|\, W^c)\mathbb{P}(W^c) = p\,\Phi\Big(\frac{x-\mu}{\sigma}\Big) + (1-p)\,\mathbf{1}(x \ge \mu').$$

این CDF در نقطه μ' یک **پرش** به اندازه $1-p$ دارد و در بقیه جاها هموار است. پس X نه گسسته است و نه پیوسته؛ یک متغیر **مخلوط** است. اما مشتق تابع پله در نقطه پرش چیست؟ برای پاسخ، به یک ابزار ریاضی نیاز داریم.

۱.۵.۸ تابع دلتای دیراک

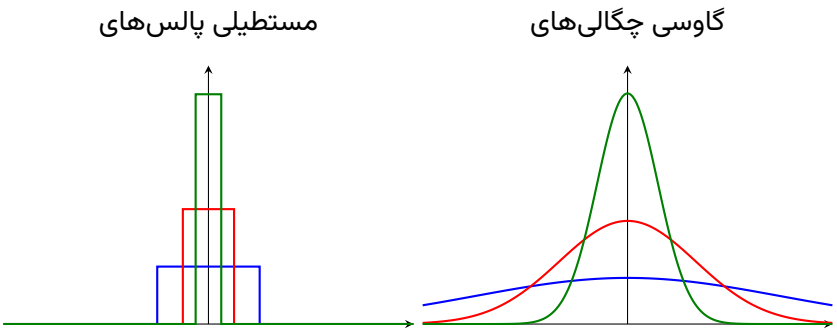
در ریاضیات کاربردی، موارد بسیاری وجود خواهند داشت که در آنان به دنبال **توابعی** می‌گردیم که تنها در **یک نقطه** غیر صفر شوند. در عین حال، نیاز داریم تا انتگرال تابع فوق در هر بازه‌ای که شامل نقطه مورد نظر است مقداری غیرصفر داشته باشد. به یکی از توابع معروفی که خواص فوق را دارد، **تابع دلتای دیراک** $\delta(x)$ اطلاق می‌گردد:

$$\delta(x) = \begin{cases} +\infty & x = 0 \\ 0 & x \neq 0 \end{cases}, \qquad \int_R \delta(x)\,\mathrm{d}x = \begin{cases} 1 & 0 \in R \\ 0 & 0 \notin R \end{cases}.$$

- در ریاضیات محض و شاخه آنالیز حقیقی، می‌توان نشان داد که موجودی مانند **دلتای دیراک** $\delta(x)$ نمی‌تواند یک تابع انتگرال‌پذیر (به معنای معمول) باشد: تابعی که جز در یک نقطه صفر است، انتگرال صفر دارد.
- در واقع، انتگرال مفاهیمی مانند دلتای دیراک به صورت اختصاصی و جداگانه تعریف می‌شوند (تعریف عام **جمع ریمان** یا Riemann Sum در مورد دلتای دیراک برقرار نیست). در ریاضیات دقیق، δ یک «تابع تعمیم‌یافته» یا distribution است.

چگونگی ساختن تابع دلتای دیراک: دلتا را می‌توان حد دنباله‌ای از توابع معمولی با مساحت ۱ در نظر گرفت که هر چه باریک‌تر و بلندتر می‌شوند:

- پالس مستطیلی به عرض ε و ارتفاع $\frac{1}{\varepsilon}$ حول صفر، وقتی $\varepsilon \to 0$؛
- چگالی گاوسی $\frac{1}{\sqrt{4\pi\alpha}} e^{-x^2/(4\alpha)}$ (یعنی $\mathcal{N}(0, 2\alpha)$)، وقتی $\alpha \to 0$.



قضیه ۸-۶: خاصیت غربالی

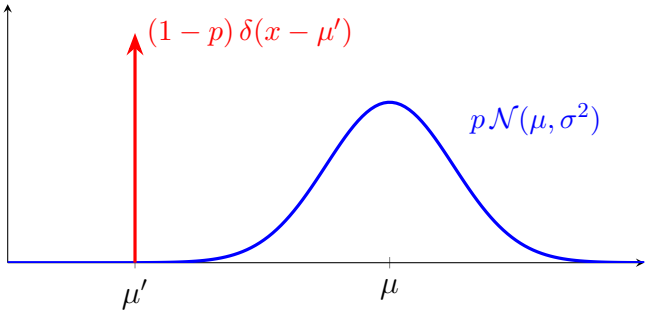
برای هر تابع پیوسته g: $\int_{-\infty}^{\infty} g(x)\,\delta(x-a)\,\mathrm{d}x = g(a)$. همچنین $\delta(x) = \frac{\mathrm{d}}{\mathrm{d}x}u(x)$ که u تابع پله واحد است (به این معنا که $\int_{-\infty}^{x} \delta(t)\,\mathrm{d}t = u(x)$).

۲.۵.۸ حل مسئله دماسنج نامطمئن

با مشتق‌گیری از CDF و استفاده از $\frac{\mathrm{d}}{\mathrm{d}x}\mathbf{1}(x \geq \mu') = \delta(x-\mu')$:

$$f_X(x) = \frac{p}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} + (1-p)\,\delta(x-\mu')$$

این PDF یک «زنگوله» با مساحت p به‌علاوه یک «ضربه» با وزن $1-p$ در نقطه μ' است؛ مساحت کل $p + (1-p) = 1$.



۳.۵.۸ تبدیل PMF به PDF

با دلتای دیراک، متغیرهای گسسته را هم می‌توان با PDF توصیف کرد. فرض کنید که متغیر تصادفی گسسته X دارای تابع جرم احتمال به شکل زیر است:

$$P(X = x_i) = p_i, \qquad \forall x_i \in \mathrm{Support}(X).$$

در این صورت، تابع چگالی احتمال (PDF) این متغیر تصادفی به شکل زیر خواهد بود:

$$f_X(x) = \sum_i p_i \, \delta(x - x_i).$$

بدین ترتیب یک چارچوب واحد برای همه متغیرها (گسسته، پیوسته و مخلوط) داریم: احتمال هر بازه برابر انتگرال PDF روی آن است، به شرطی که ضربه‌های داخل بازه را نیز در نظر بگیریم.

۶.۸ تمرین‌های تکمیلی

تمرین ۸-۷

در مسئله دماسنج نامطمئن با $\mu = 25$، $\sigma = 1$، $\mu' = 0$ و $p = 0.9$، احتمال اینکه دماسنج عددی بین ۲۴ و ۲۶ نشان دهد چقدر است؟ احتمال اینکه دقیقاً صفر نشان دهد چطور؟

حل. $P(24 \le X \le 26) = 0.9 \times P(|Z| \le 1) + 0.1 \times \mathbf{1}(0 \in [24,26]) \approx 0.9 \times 0.683 = 0.615$. و $P(X = 0) = 1 - p = 0.1$ (وزن ضربه در صفر؛ بخش گاوسی در یک نقطه احتمال صفر دارد). ■

تمرین ۸-۸

دو متغیر $X, Y \in \{0, 1\}$ با جدول توأم زیر داده شده‌اند: $P(0,0) = 0.3$، $P(0,1) = 0.2$، $P(1,0) = 0.3$، $P(1,1) = 0.2$. آیا X و Y مستقل‌اند؟ آیا هم‌توزیع‌اند؟

حل. حاشیه‌ها: $P_X(0) = 0.5$، $P_X(1) = 0.5$، $P_Y(0) = 0.6$، $P_Y(1) = 0.4$. حاصل‌ضرب‌ها: $0.5 \times 0.6 = 0.3$ و $0.5 \times 0.4 = 0.2$؛ همه خانه‌ها برابرند، پس **مستقل‌اند**. اما توزیع حاشیه‌ای‌شان متفاوت است، پس **هم‌توزیع نیستند** (و i.i.d. نیستند). ■

تمرین ۸-۹

PDF متغیر X = «تعداد شیرها در دو پرتاب سکه سالم» را با دلتای دیراک بنویسید و $\int_{0.5}^{3} f_X(x)\,\mathrm{d}x$ را حساب کنید.

حل. $f_X(x) = \tfrac{1}{4}\delta(x) + \tfrac{1}{2}\delta(x-1) + \tfrac{1}{4}\delta(x-2)$. بازه $[0.5, 3]$ شامل نقاط ۱ و ۲ است؛ پس انتگرال برابر $\tfrac{1}{2} + \tfrac{1}{4} = \tfrac{3}{4} = P(X \ge 1)$ است. ■

جلسه ۹

توزیع‌های شرطی، مدل‌های مخلوط، میانگین و قانون اعداد بزرگ

۱.۹ توزیع‌های شرطی (Conditional PMF/PDF/CDF)

همان‌طور که برای رویدادها احتمال شرطی تعریف کردیم، برای متغیرهای تصادفی نیز می‌توانیم توزیع شرطی تعریف کنیم. اگر B یک رویداد با $\mathbb{P}(B) > 0$ باشد:

$$F_X(x \mid B) = \mathbb{P}(X \le x \mid B) = \frac{\mathbb{P}(X \le x,\ B)}{\mathbb{P}(B)}, \qquad f_X(x \mid B) = \frac{\mathrm{d}}{\mathrm{d}x} F_X(x \mid B),$$

و برای متغیر گسسته $P_X(x \mid B) = \mathbb{P}(X = x \mid B)$. تابع $F_X(\cdot \mid B)$ خودش یک CDF معتبر است (صعودی، از ۰ تا ۱).

مثال ۹-۱: تابع توزیع انباشته شرطی

فرض کنید متغیر تصادفی X دارای تابع توزیع انباشته $F_X(x)$ باشد. تابع توزیع انباشته $F_X(x \mid X \le a)$ را بیابید.

حل. طبق تعریف:

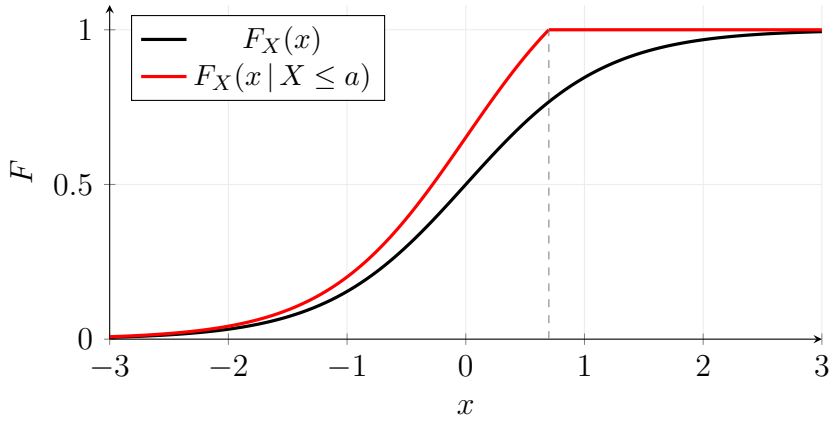
$$F_X(x \mid X \le a) = \frac{\mathbb{P}(X \le x,\ X \le a)}{\mathbb{P}(X \le a)}.$$

- اگر $x \le a$: رویداد $\{X \le x\}$ زیرمجموعه $\{X \le a\}$ است؛ پس اشتراک همان $\{X \le x\}$ است.
- اگر $x > a$: $\{X \le a\} \subseteq \{X \le x\}$ و اشتراک برابر $\{X \le a\}$ است.

بنابراین

$$\boxed{F_X(x \mid X \le a) = \begin{cases} \dfrac{F_X(x)}{F_X(a)} & x \le a \\[2mm] 1 & x > a \end{cases}}$$

با مشتق‌گیری، چگالی شرطی برابر $f_X(x \mid X \le a) = \frac{f_X(x)}{F_X(a)}$ برای $x \le a$ و صفر در غیر این صورت است: چگالی اصلی «بریده» (truncate) و سپس برای بهنجار شدن بر $F_X(a)$ تقسیم می‌شود. ■



(در شکل، X گاوسی استاندارد و $a = 0.7$ است.)

۲.۹ خاصیت بی‌حافظگی (memoryless property)

پیش‌تر بیان شد که توزیع نمایی $X \sim \lambda e^{-\lambda x} u(x)$ یک توزیع **بی‌حافظه** است. این توزیع معمولاً برای مدل‌سازی عمر وسایل الکترونیکی (یا برخی موارد مشابه!) به کار می‌رود.

تعریف ۹-۲: بی‌حافظگی

یک توزیع روی اعداد نامنفی را **بی‌حافظه** (memoryless) گوییم، اگر به ازای هر $a, \Delta \ge 0$ داشته باشیم:

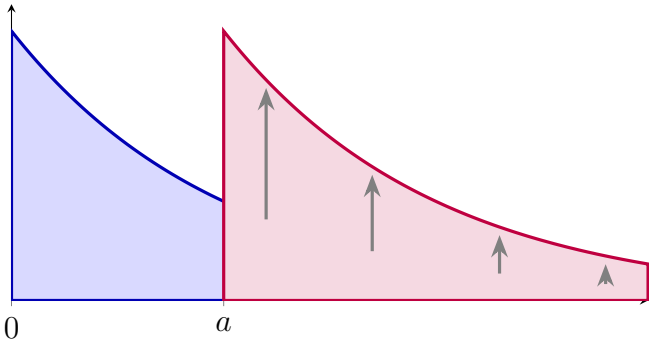
$$\mathbb{P}(X \ge a + \Delta \,|\, X \ge a) = \mathbb{P}(X \ge \Delta).$$

بی‌حافظه بودن توزیع نمایی به لحاظ ریاضیاتی به صورت زیر اثبات می‌شود (فرض کنید $X \sim \mathrm{Exp}(\lambda)$):

$$\begin{aligned}\mathbb{P}(X > a + \Delta \,|\, X > a) &= \frac{\mathbb{P}(X > a + \Delta)}{\mathbb{P}(X > a)} = \frac{1 - F(a + \Delta)}{1 - F(a)} \\ &= \frac{1 - \left(1 - e^{-\lambda(a+\Delta)}\right)}{1 - \left(1 - e^{-\lambda a}\right)} = \frac{e^{-\lambda(a+\Delta)}}{e^{-\lambda a}} = e^{-\lambda \Delta} = \mathbb{P}(X > \Delta).\end{aligned}$$

تعبیر هندسی: چگالی شرطی $f_X(x \mid X > a)$ از بریدن چگالی در $x = a$ و بزرگ‌نمایی (rescaling) بخش باقیمانده با ضریب $1/\mathbb{P}(X > a) = e^{\lambda a}$ به دست می‌آید. برای توزیع نمایی، نتیجه دقیقاً همان منحنی اولیه است که به اندازه a به راست منتقل شده است:

$$f_X(x \mid X > a) = \frac{\lambda e^{-\lambda x}}{e^{-\lambda a}} = \lambda e^{-\lambda(x-a)}, \qquad x > a.$$



نکته. می‌توان نشان داد توزیع نمایی **تنها** توزیع پیوسته بی‌حافظه است (و توزیع هندسی تنها توزیع گسسته بی‌حافظه روی اعداد طبیعی). دلیل: اگر $G(x) = \mathbb{P}(X > x)$ آنگاه بی‌حافظگی یعنی $G(a+\Delta) = G(a)G(\Delta)$، و تنها جواب‌های یکنوای این معادله تابعی به صورت $G(x) = e^{-\lambda x}$ هستند.

۳.۹ مدل‌های آماری مخلوط (Statistical Mixture Models)

یک خانواده از توزیع‌های آماری (مثلاً **خانواده توزیع‌های گاوسی**) را در نظر بگیرید:

- فرض کنید که برای مشخص کردن هر عضو از خانواده، مجموعه پارامترهای آزاد $\theta \in \Theta$ نیاز باشد.
- برای مثال، مشخص کردن هر عضو خانواده گاوسی به صورت یکتا از طریق مشخص کردن مقدار میانگین (μ) و واریانس (σ^2) آن امکان‌پذیر است. پس داریم:

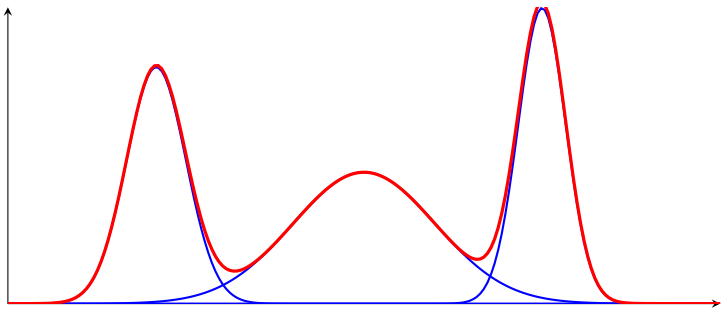
$$\theta = (\mu, \sigma), \qquad \Theta = \mathbb{R} \times \mathbb{R}_{\geq 0}.$$

در این صورت، تابع چگالی احتمال $f_X(x \mid \theta)$ نشان‌دهنده یک عضو از خانواده با پارامترهای θ است.

فرض کنید که متغیر تصادفی X، دارای توزیع احتمال متناظر با یکی از n عضو خانواده با پارامترهای $\theta_1, \theta_2, \ldots, \theta_n$ باشد. اما **این واقعیت که از کدامیک پیروی کند** خود یک متغیر تصادفی گسسته با احتمال‌های $p_1, p_2, \ldots, p_n$ را تشکیل دهد. در این صورت، با توجه به **قانون احتمال کل** داریم:

$$\boxed{f_X(x) = \sum_{i=1}^{n} p_i f_X(x \mid \theta_i)}$$

به چنین توزیع‌هایی اصطلاحاً توزیع‌های آماری مخلوط با n خوشه (یا mixture component) اطلاق می‌گردد. مثال معروف آن **مدل مخلوط گاوسی** (Gaussian Mixture Model — GMM) است که در یادگیری ماشین برای خوشه‌بندی داده‌ها کاربرد فراوان دارد. (مسئله دماسنج نامطمئن جلسه قبل نیز یک مدل مخلوط با دو مؤلفه بود.)



یک GMM با سه مؤلفه: منحنی قرمز = مجموع وزن‌دار سه منحنی آبی (وزن‌ها $0.3, 0.4, 0.3$).

نکته. نمونه‌برداری از مدل مخلوط: ابتدا با احتمال‌های $p_1, \ldots, p_n$ یکی از مؤلفه‌ها (مثلاً i) را انتخاب کنید، سپس یک نمونه از $f_X(\cdot \mid \theta_i)$ بگیرید. این دقیقاً همان «قانون احتمال کل» به زبان الگوریتم است.

۴.۹ توصیف یک متغیر تصادفی

فرض کنید که قصد دارید یک متغیر تصادفی را به صورت ناقص ولی به شکلی ساده توصیف کنید. مثلاً، کسی که اهل شهر شما نیست در مورد دمای هوا در محل زندگیتان از شما سؤالی می‌پرسد:

- دمای هوای شهر به شکل یک متغیر تصادفی مانند T مدل‌سازی شده که دارای فضای احتمال و تابع چگالی احتمال $f_T(T)$ است (برای مقادیر T بین صفر کلوین تا بی‌نهایت).
- ممکن است شما اطلاع دقیقی از تابع توزیع احتمال T داشته باشید. در این صورت تمام چیزی که در مورد دمای هوای شهر می‌توان داشت را دارید.

اما جواب آن شخص را چگونه می‌دهید؟ آیا کل تابع چگالی احتمال (شامل بی‌نهایت عدد) را به وی منتقل می‌کنید؟ آیا انتقال این حجم از اطلاعات در مقابل یک پرسش ساده، کاری منطقی به نظر می‌رسد؟ احتمالاً جواب می‌دهید: «معمولاً حدود ۲۵ درجه است، گاهی تا ۳۵ هم می‌رسد».

۱.۴.۹ آماره یا Statistic

- علم آمار و احتمال، در این مواقع ابزارهایی تحت عنوان «**آماره**» یا «**Statistic**» را در اختیار ما قرار می‌دهد.
- هر آماره، یک تک عدد و یا مجموعه‌ای نسبتاً کوچکی از اعداد است که اطلاعاتی کلی در مورد یک متغیر تصادفی در اختیار قرار می‌دهد.
- اطلاعات آماره در مورد یک متغیر تصادفی ناقص است، ولی در عوض انتقال و فهم آن بسیار سریع و راحت می‌نماید.

۵.۹ میانگین (Expected Value)

۱.۵.۹ مفهوم

- معروف‌ترین و پرکاربردترین آماره در تحلیل آماری و تصادفی وقایع، **میانگین** یا **Expected Value** یک متغیر تصادفی مانند X است.
- میانگین X را به صورت $\mathbb{E}(X)$ نشان می‌دهیم (به آن Expectation of X و یا Mean of X نیز اطلاق می‌گردد).
- میانگین یک متغیر تصادفی، **ماهیت تصادفی نداشته** و یک مقدار **یقینی** (deterministic) دارد.
- میانگین برای متغیرهای تصادفی مستقل از پیوسته یا گسسته بودن آنان تعریف می‌شود.
- امکان تعریف میانگین یا Expected Value برای برخی متغیرهای تصادفی وجود ندارد.

۲.۵.۹ فرمول ریاضی

تعریف ۹-۳: میانگین

میانگین یک متغیر تصادفی گسسته با تابع PMF برابر با $P(X = x)$ مطابق با زیر تعریف می‌شود:

$$\mathbb{E}(X) = \sum_{x_i \in \text{supp}(X)} x_i P(X = x_i).$$

میانگین یک متغیر تصادفی پیوسته (یا مخلوط) با تابع PDF برابر با $f_X(x)$ به صورت زیر تعریف می‌شود:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x)\,\mathrm{d}x.$$

(به شرطی که سری یا انتگرال به‌طور مطلق همگرا باشد، یعنی $\mathbb{E}|X| < \infty$.)

نکته. تعبیر فیزیکی: اگر PMF/PDF را توزیع جرم روی یک میله بدانیم، $\mathbb{E}(X)$ **مرکز جرم** (نقطه تعادل) آن است. **تعبیر آماری:** طبق قانون اعداد بزرگ (پایین‌تر)، میانگین تعداد زیادی نمونه مستقل از X به $\mathbb{E}(X)$ نزدیک می‌شود. همچنین برای هر تابع g داریم $\mathbb{E}[g(X)] = \sum g(x_i)P(X = x_i)$ یا $\int g(x)f_X(x)\,\mathrm{d}x$.

۳.۵.۹ میانگین متغیرهای تصادفی گسسته معروف

مثال ۹-۴: برنولی، تاس و دوجمله‌ای

برنولی با احتمال موفقیت p:

$$\mathbb{E}(X) = 1 \times p + 0 \times (1-p) = p.$$

تاس ۶وجهی متقارن:

$$\mathbb{E}(X) = \frac{1+2+\cdots+6}{6} = \frac{21}{6} = 3.5.$$

دوجمله‌ای $\text{Binomial}(n,p)$: با استفاده از اتحاد $k\binom{n}{k} = n\binom{n-1}{k-1}$:

$$\mathbb{E}(X) = \sum_{k=0}^{n} k\binom{n}{k}p^k(1-p)^{n-k} = np\sum_{k=1}^{n}\binom{n-1}{k-1}p^{k-1}(1-p)^{n-k} = np(p+1-p)^{n-1} = np.$$

(جمله $k=0$ صفر است؛ و مجموع باقیمانده با تغییر اندیس $j = k-1$ طبق قضیه دوجمله‌ای برابر ۱ است.) به‌طور شهودی: n آزمون، هر یک به طور متوسط p موفقیت.

مثال ۹-۵: هندسی و پواسون

هندسی: با قرارداد اسلاید، $P(X = k) = (1-p)p^{k-1}$ برای $k \geq 1$ (در اینجا p احتمال «ادامه دادن» یا

شکست در هر مرحله و $1-p$ احتمال توقف است). با مشتق‌گیری از سری هندسی $\sum_{k\ge 0} p^k = \frac{1}{1-p}$:

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} k(1-p)p^{k-1} = (1-p)\frac{\partial}{\partial p}\big(1+p+p^2+\cdots\big) = (1-p)\frac{1}{(1-p)^2} = \frac{1}{1-p}.$$

دقت کنید: در قرارداد جلسه ششم ($P_X(k)=(1-p)^{k-1}p$ با p = احتمال موفقیت) همین محاسبه نتیجه می‌دهد $\mathbb{E}(X)=\frac{1}{p}$؛ مثلاً به طور متوسط ۶ پرتاب لازم است تا اولین ۶ در تاس بیاید.

پواسون با پارامتر λ:

$$\mathbb{E}(X) = \sum_{k=0}^{\infty} k e^{-\lambda}\frac{\lambda^k}{k!} = \lambda e^{-\lambda}\frac{\partial}{\partial \lambda}\Big(\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}\Big) = \lambda e^{-\lambda}\frac{\partial}{\partial \lambda}\big(e^{\lambda}\big) = \lambda.$$

(از $k\lambda^k = \lambda\frac{\partial}{\partial\lambda}\lambda^k$ استفاده شد.) پس پارامتر λ همان «تعداد متوسط رخدادها» است ــ سازگار با $np=\lambda$ در تقریب پواسون.

۴.۵.۹ میانگین متغیرهای تصادفی پیوسته معروف

مثال ۹-۶: گاوسی و نمایی

گاوسی $\mathcal{N}(\mu,\sigma^2)$:

$$\mathbb{E}(X) = \frac{1}{\sqrt{2\pi}\sigma}\int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,\mathrm{d}x = \mu.$$

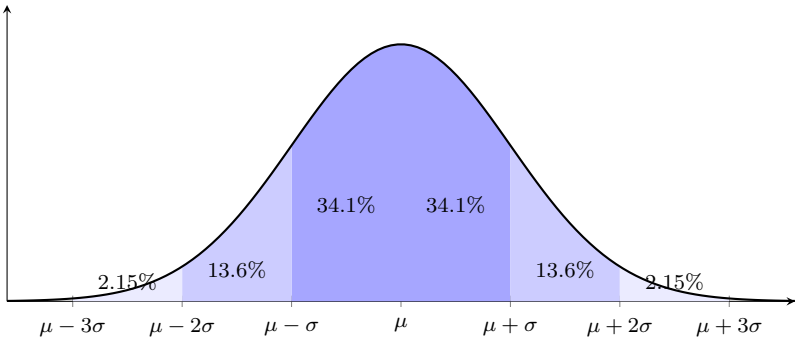
اثبات: با $x=\mu+t$ انتگرال برابر $\mu\int f + \frac{1}{\sqrt{2\pi}\sigma}\int t e^{-t^2/2\sigma^2}\,\mathrm{d}t = \mu\cdot 1 + 0$، زیرا انتگرال دوم از یک تابع فرد روی بازه متقارن است.

نمایی با پارامتر λ: با تغییر متغیر $u=\lambda x$ و انتگرال‌گیری جزءبه‌جزء ($\int_0^\infty ue^{-u}\,\mathrm{d}u = [-ue^{-u}]_0^\infty + \int_0^\infty e^{-u}\,\mathrm{d}u = 1$):

$$\mathbb{E}(X) = \lambda\int_0^\infty x e^{-\lambda x}\,\mathrm{d}x = \frac{1}{\lambda}\int_0^\infty u e^{-u}\,\mathrm{d}u = \frac{1}{\lambda}.$$

پس اگر نرخ خرابی یک قطعه $\lambda=0.2$ در سال باشد، عمر متوسط آن ۵ سال است.

نکته. تمرکز مقادیر حول میانگین در توزیع گاوسی: عمده احتمالات در بازه $\mu\pm 3\sigma$ تجمع پیدا کرده است: 34.1% بین μ و $\mu+\sigma$، 13.6% بین $\mu+\sigma$ و $\mu+2\sigma$، و 2.15% بین $\mu+2\sigma$ و $\mu+3\sigma$ (و به همین ترتیب در سمت چپ). در مجموع: 68.2% در $\mu\pm\sigma$، 95.4% در $\mu\pm 2\sigma$ و 99.7% در $\mu\pm 3\sigma$.



مثال ۹-۷: یکنواخت و بتا

یکنواخت در بازه $[a,b]$:

$$\mathbb{E}(X)=\frac{1}{b-a}\int_a^b x\,\mathrm{d}x=\frac{b^2-a^2}{2(b-a)}=\frac{a+b}{2}.$$

بتا با پارامترهای α,β: با استفاده از اتحاد تابع بتا $\int_0^1 x^{a-1}(1-x)^{b-1}\,\mathrm{d}x=\frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$ و $\Gamma(z+1)=z\Gamma(z)$:

$$\mathbb{E}(X)=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\int_0^1 x^{\alpha}(1-x)^{\beta-1}\,\mathrm{d}x=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\cdot\frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)}=\frac{\alpha}{\alpha+\beta}.$$

۶.۹ خواص میانگین

قضیه ۹-۸: برخی خواص میانگین ــ یک متغیر

فرض کنید X یک متغیر تصادفی گسسته، پیوسته و یا مخلوط باشد و $\mathbb{E}(X)$ وجود داشته باشد. آنگاه:

۱. در صورتی که تابع چگالی احتمال $f_X(x)$ حول نقطه‌ای متقارن باشد، مقدار میانگین نیز برابر با همان نقطه است (مثلاً در مورد متغیرهای تصادفی گاوسی و لاپلاس).

۲. لزومی ندارد که خود $\mathbb{E}(X)$ جزو $\mathrm{Support}(X)$ باشد (مثلاً میانگین تاس 3.5 است که هرگز ظاهر نمی‌شود).

۳. همواره داریم: $\min(X)\le\mathbb{E}(X)\le\max(X)$.

اثبات. (۱) اگر f_X حول c متقارن باشد، $Y=X-c$ چگالی زوج دارد و $\mathbb{E}(Y)=\int yf_Y(y)\,\mathrm{d}y=0$ (انتگرال تابع فرد)؛ پس $\mathbb{E}(X)=c$. (۳) اگر $m\le X\le M$، آنگاه $\mathbb{E}(X)=\int xf\le\int Mf=M$ و به طور مشابه $\ge m$. □

قضیه ۹-۹: خاصیت خطی Expectation

فرض کنید X,Y متغیرهای گسسته، پیوسته و یا مخلوط باشند و $\mathbb{E}(X)$ و $\mathbb{E}(Y)$ وجود داشته باشند. X و Y **لزوماً از یکدیگر مستقل نیستند**. آنگاه برای اعداد ثابت حقیقی a,b:

$$\mathbb{E}(aX+b)=a\mathbb{E}(X)+b.$$

به عبارت دیگر، در صورتی که g یک **تابع خطی** باشد، داریم $\mathbb{E}\big(g(X)\big) = g\big(\mathbb{E}(X)\big)$. همچنین همواره داریم:

$$\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y).$$

اثبات. برای حالت پیوسته: $\mathbb{E}(aX+b) = \int (ax+b) f_X(x)\,\mathrm{d}x = a\int x f_X + b\int f_X = a\mathbb{E}(X)+b$. برای جمع (حالت گسسته): $\mathbb{E}(X+Y) = \sum_{x,y}(x+y)P(x,y) = \sum_x x\sum_y P(x,y) + \sum_y y\sum_x P(x,y) = \sum_x xP_X(x) + \sum_y yP_Y(y)$. دقت کنید که در هیچ جای این اثبات از استقلال استفاده نشد. □

قضیه ۹-۱۰: نامساوی Jensen

اگر g تابعی **محدب** باشد (مثل x^2، e^x یا $|x|$)، آنگاه

$$\mathbb{E}\big(g(X)\big) \geq g\big(\mathbb{E}(X)\big).$$

(برای تابع مقعر جهت نامساوی برعکس است.)

ایده اثبات. تابع محدب بالای خط مماس خود در هر نقطه قرار دارد: با $\mu = \mathbb{E}(X)$، عددی c هست که برای همه x: $g(x) \geq g(\mu) + c(x-\mu)$. با میانگین‌گیری از دو طرف (و خاصیت خطی): $\mathbb{E}g(X) \geq g(\mu) + c(\mathbb{E}X - \mu) = g(\mu)$. □

دقت کنید! در حالت کلی $\mathbb{E}(g(X)) \neq g(\mathbb{E}(X))$. مثلاً برای تاس: $\mathbb{E}(X^2) = \frac{1+4+9+16+25+36}{6} = \frac{91}{6} \approx 15.17$ ولی $(\mathbb{E}X)^2 = 12.25$. طبق جنسن، اختلاف این دو همیشه نامنفی است (و در جلسه بعد نام «واریانس» می‌گیرد).

مثال ۹-۱۱: کاربرد خاصیت خطی ـ تطابق

n نفر کلاه‌های خود را در یک جعبه می‌اندازند و هر نفر یک کلاه به تصادف برمی‌دارد. میانگین تعداد افرادی که کلاه خودشان را برمی‌دارند چقدر است؟

حل. X_i را متغیر برنولی «نفر i کلاه خودش را برداشته» بگیرید؛ $\mathbb{E}(X_i) = \frac{1}{n}$. تعداد کل $X = \sum X_i$ است و با خاصیت خطی (با وجود اینکه X_iها مستقل نیستند!): $\mathbb{E}(X) = \sum_{i=1}^{n} \frac{1}{n} = 1$. جالب است که جواب به n بستگی ندارد. ■

۷.۹ مفهوم متغیرهای تصادفی i.i.d. و قانون اعداد بزرگ (Law of Large Numbers)

فرض کنید که $X_1, X_2, \ldots, X_n$ متغیرهای تصادفی i.i.d. از یک توزیع با میانگین μ باشند. متغیر تصادفی $\bar{X}_n$ را به صورت زیر تعریف می‌کنیم:

$$\bar{X}_n \triangleq \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

(دقت کنید که $\bar{X}_n$ خودش یک متغیر تصادفی است؛ طبق خاصیت خطی $\mathbb{E}(\bar{X}_n) = \mu$.) آنگاه قانون اعداد بزرگ به دو شکل زیر برقرار است:

قضیه ۹-۱۲: قانون اعداد بزرگ

شکل ضعیف: $\bar{X}_n \xrightarrow{P} \mu$ وقتی $n \to \infty$؛ یعنی برای هر عدد مثبت ε:

$$\lim_{n\to\infty} \Pr\left(|\bar{X}_n - \mu| > \varepsilon\right) = 0.$$

شکل قوی: $\bar{X}_n \xrightarrow{\text{a.s.}} \mu$ وقتی $n \to \infty$؛ یعنی

$$\Pr\left(\lim_{n\to\infty} \bar{X}_n = \mu\right) = 1.$$

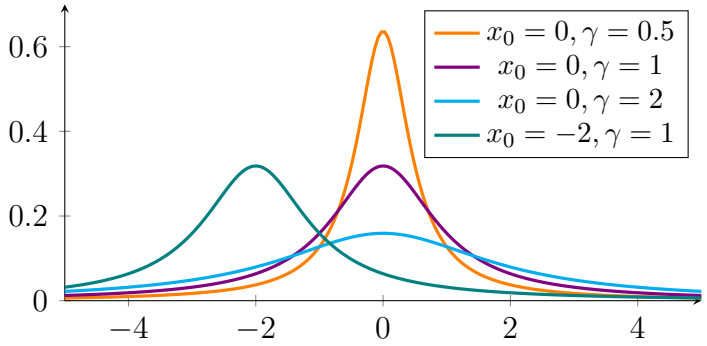
نکته. شکل ضعیف می‌گوید برای هر n بزرگ، احتمال اینکه میانگین نمونه‌ای از μ دور باشد کوچک است. شکل قوی بیشتر می‌گوید: تقریباً هر دنباله از نمونه‌ها (به جز مجموعه‌ای با احتمال صفر) در نهایت به μ همگرا می‌شود. شکل قوی، شکل ضعیف را نتیجه می‌دهد. این قانون توجیه ریاضی تعبیر فرکانسی احتمال است: اگر $X_i = \mathbf{1}(A$ در آزمایش $i)$ باشد، $\bar{X}_n$ همان فرکانس نسبی است و به $\mathbb{P}(A)$ میل می‌کند. (پدیده تمرکز در جلسه سوم نمونه‌ای از همین قانون بود.)

۸.۹ توزیع‌های بدون میانگین

تعریف ۹-۱۳: توزیع کوشی (Cauchy distribution)

توزیع کوشی با محلیت (location) x_0 و مقیاس $\gamma > 0$ را با چگالی احتمال زیر تعریف می‌کنیم:

$$f_X(x) = \frac{1}{\gamma\pi\left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]}.$$



می‌توانید به راحتی ببینید که یک متغیر تصادفی مانند X با توزیع کوشی میانگین ندارد. یعنی $\mathbb{E}(X)$ وجود نداشته و قابل تعریف نیست:

$$\int_{-\infty}^{\infty} |x| \frac{1}{\pi(1+x^2)}\,\mathrm{d}x = \frac{2}{\pi}\int_0^{\infty} \frac{x}{1+x^2}\,\mathrm{d}x = \frac{1}{\pi}\Big[\ln(1+x^2)\Big]_0^{\infty} = \infty.$$

(دقت کنید که با وجود تقارن چگالی حول صفر، نمی‌توان گفت میانگین صفر است؛ زیرا $\int_0^\infty$ و $\int_{-\infty}^0$ هر دو بی‌نهایت‌اند و $\infty - \infty$ تعریف نشده است. خاصیت تقارن فقط وقتی کار می‌کند که میانگین وجود داشته باشد.)

نکته. دقت کنید که این امر در تناقض با هیچ اصلی در آمار و احتمال نیست. تنها لازمه تعریف یک متغیر تصادفی، فضای احتمال $(\Omega, \mathcal{F}, P)$ است که با تعریف یک CDF خود به خود صورت می‌پذیرد. وجود داشتن میانگین شرط تعریف یک متغیر تصادفی نیست. همچنین قانون اعداد بزرگ برای کوشی برقرار نیست (فرض آن، یعنی وجود μ، برقرار نیست).

دلیل اصلی عدم وجود میانگین برای توزیع کوشی، دم (tail) خیلی قوی آن است:

توزیع	یکنواخت	گاوسی	نمایی	کوشی
رفتار دُم چگالی	$\propto 0$	$\propto e^{-x^2}$	$\propto e^{-x}$	$\propto x^{-2}$

برای وجود میانگین باید $xf(x)$ انتگرال‌پذیر باشد. با دم x^{-2}، $xf(x) \sim \frac{1}{x}$ که انتگرالش (لگاریتم) واگراست.

۹.۹ یک مثال تمرینی: سکه تصادفی با احتمال نامعلوم

مثال ۹-۱۴: استنتاج بیزی درباره احتمال شیر

فرض کنید یک سکه تصادفی با احتمال آمدن شیر p در دست داریم. در مورد p هیچ اطلاعی در دست نیست، و تمام اعداد حقیقی بازه $[0,1]$ برای آن شانس برابر دارند. این سکه را n بار به صورت تصادفی پرتاب می‌کنیم و مشاهده می‌شود که k بار شیر ظاهر شده است. در صورت دانسته بودن نتیجه این آزمایش، توزیع احتمال برای «احتمال شیر آمدن سکه p» چقدر است؟

حل. «هیچ اطلاعی نداریم» یعنی توزیع پیشین p یکنواخت است:

$$f_{\boldsymbol{p}}(p) = \begin{cases} 1 & 0 \le p \le 1 \\ 0 & \text{o.w.} \end{cases}$$

به شرط p، تعداد شیرها دوجمله‌ای است: $P(\text{test} \mid p) = \binom{n}{k} p^k (1-p)^{n-k}$. با قانون بیز (نسخه چگالی):

$$f_{\boldsymbol{p}}(p \mid \text{test}) = \frac{P(\text{test} \mid p) f_{\boldsymbol{p}}(p)}{P(\text{test})} = \frac{1}{P(\text{test})} \binom{n}{k} p^k (1-p)^{n-k}, \qquad 0 \le p \le 1.$$

مخرج با قانون احتمال کل (نسخه پیوسته) به دست می‌آید:

$$P(\text{test}) = \int_{\boldsymbol{p}} P(\text{test} \mid p) f_{\boldsymbol{p}}(p)\, \mathrm{d}p = \int_0^1 \binom{n}{k} q^k (1-q)^{n-k}\, \mathrm{d}q = \binom{n}{k} \frac{k!\,(n-k)!}{(n+1)!} = \frac{1}{n+1}.$$

(از اتحاد تابع بتا با $\Gamma(m+1) = m!$ استفاده شد. جالب است: پیش از آزمایش، همه مقادیر $k = 0, \dots, n$ هم‌احتمال‌اند!) پس

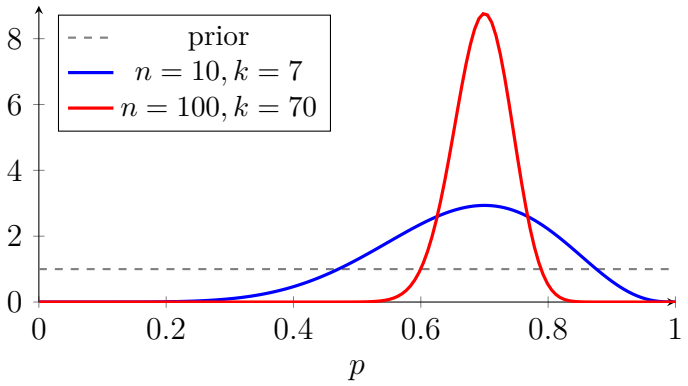
$$f_{\boldsymbol{p}}(p \mid \text{test}) = (n+1)\binom{n}{k} p^k (1-p)^{n-k} = \frac{\Gamma(n+2)}{\Gamma(k+1)\Gamma(n-k+1)} p^k (1-p)^{n-k},$$

که دقیقاً چگالی توزیع بتا است. **جواب نهایی:**

$$\boxed{\boldsymbol{p}\,|\,\text{test} \;\sim\; \text{Beta}(k+1\,,\; n-k+1)}$$

■

نکته. طبق فرمول میانگین بتا، $\mathbb{E}(\boldsymbol{p}\,|\,\text{test}) = \frac{k+1}{n+2}$ (معروف به «قاعده توالی لاپلاس»). مثلاً اگر در ۱۰ پرتاب ۷ شیر بیاید، تخمین ما $\frac{8}{12} \approx 0.67$ است (نه دقیقاً 0.7). با افزایش n، توزیع پسین حول $\frac{k}{n}$ باریک‌تر می‌شود. این مثال نشان می‌دهد چرا توزیع بتا برای مدل‌سازی «خود احتمال» مناسب است.



۱۰.۹ تمرین‌های تکمیلی

تمرین ۹-۱۵

X دارای چگالی $f(x) = 2x$ روی $[0,1]$ است. $\mathbb{E}(X)$ و $\mathbb{E}(X^2)$ را بیابید و نامساوی جنسن را برای $g(x) = x^2$ بررسی کنید.

حل. $\mathbb{E}(X) = \int_0^1 2x^2\,\mathrm{d}x = \frac{2}{3}$ و $\mathbb{E}(X^2) = \int_0^1 2x^3\,\mathrm{d}x = \frac{1}{2}$. داریم $\frac{1}{2} \geq \left(\frac{2}{3}\right)^2 = \frac{4}{9} \approx 0.444$ که با جنسن سازگار است. ■

تمرین ۹-۱۶

در یک بازی، تاسی پرتاب می‌کنید و اگر عدد k بیاید k^2 هزار تومان می‌برید. اگر هزینه ورود ۱۵ هزار تومان باشد، آیا بازی به نفع شماست؟

حل. سود متوسط $\mathbb{E}(X^2) - 15 = \frac{91}{6} - 15 = \frac{1}{6} \approx 0.17$ هزار تومان؛ پس بازی به‌طور متوسط اندکی به نفع بازیکن است. (دقت کنید $(\mathbb{E}X)^2 = 12.25 < 15$؛ استفاده نادرست از $g(\mathbb{E}X)$ نتیجه را برعکس می‌کرد.) ■

تمرین ۹-۱۷

یک کلکسیونر می‌خواهد همه N نوع کارت را جمع کند؛ هر بسته یک کارت تصادفی (یکنواخت) دارد. میانگین تعداد بسته‌های لازم را بیابید (مسئله جمع‌آوری کوپن).

حل. وقتی i نوع جمع شده است، هر بسته جدید با احتمال $\frac{N-i}{N}$ نوع تازه می‌دهد؛ پس تعداد بسته‌های لازم برای نوع بعدی هندسی با میانگین $\frac{N}{N-i}$ است. با خاصیت خطی: $\mathbb{E}(T)=\sum_{i=0}^{N-1}\frac{N}{N-i}=N\big(1+\frac{1}{2}+\cdots+\frac{1}{N}\big)\approx N\ln N$. برای $N=50$: حدود 225 بسته. ■

جلسه ۱۰

عملگر میانگین‌گیری، واریانس، مُد و میانه

۱.۱۰ میانگین‌گیری یا عملگر Expectation

فرض کنید که $X, Y, Z, \ldots$ متغیرهای تصادفی مستقل و یا وابسته باشند. در این صورت، به ازای یک تابع مشخص g، مقدار $g(X, Y, Z, \ldots)$ نیز بدل به یک متغیر تصادفی جدید خواهد شد.

تعریف ۱۰-۱: میانگین تابعی از چند متغیر

میانگین و یا Expectation تابع g در این شرایط را به صورت زیر تعریف می‌کنیم:

$$\mathbb{E}\{g(X, Y, Z, \ldots)\} = \sum_{x,y,z,\ldots} g(x, y, z, \ldots)\, \mathbb{P}(X = x,\ Y = y,\ Z = z, \ldots).$$

در صورت پیوسته بودن هر یک از متغیرهای تصادفی $X, Y, Z, \ldots$، به جای pmf می‌بایست از pdf کلی (توأم) استفاده نمود و جمع را با انتگرال جایگزین کرد:

$$\mathbb{E}\{g(X, Y, \ldots)\} = \int\int \cdots g(x, y, \ldots)\, f_{X,Y,\ldots}(x, y, \ldots)\, \mathrm{d}x\, \mathrm{d}y \cdots$$

- در صورتی که متغیرهای تصادفی **مستقل** باشند، تابع pmf کلی به صورت حاصل‌ضرب توابع pmf حاشیه‌ای در خواهد آمد: $\mathbb{P}(X = x, Y = y, \ldots) = \mathbb{P}(X = x)\mathbb{P}(Y = y) \cdots$.
- دقت کنید که با میانگین‌گیری یا عمل Expectation، به یک مقدار قطعی خواهیم رسید و تمام تصادفی بودن (Randomness) از بین می‌رود.

نکته. به این قاعده گاهی «قانون آماردان ناخودآگاه» (LOTUS) می‌گویند: برای محاسبه $\mathbb{E}[g(X)]$ لازم نیست ابتدا توزیع متغیر جدید $g(X)$ را پیدا کنیم؛ کافی است g را روی توزیع خود X میانگین بگیریم.

مثال ۱۰-۲: میانگین ضرب دو تاس

دو تاس سالم و مستقل پرتاب می‌شوند. $\mathbb{E}(XY)$ و $\mathbb{E}(\max(X, Y))$ را بیابید.

حل. با استقلال، $\mathbb{P}(X = x, Y = y) = \frac{1}{36}$:
$\mathbb{E}(XY) = \frac{1}{36}\sum_{x=1}^{6}\sum_{y=1}^{6} xy = \frac{1}{36}(21)(21) = \frac{441}{36} = 12.25 = \mathbb{E}(X)\mathbb{E}(Y)$.

برای ماکزیمم: $\mathbb{P}(\max \le m) = \frac{m^2}{36}$، پس $\mathbb{P}(\max = m) = \frac{m^2-(m-1)^2}{36} = \frac{2m-1}{36}$ و $\mathbb{E}(\max) = \frac{1}{36}\sum_{m=1}^{6} m(2m-1) = \frac{1+6+15+28+45+66}{36} = \frac{161}{36} \approx 4.47$.
■

۲.۱۰ واریانس و انحراف معیار (Variance & Std. Deviation)

یکی دیگر از آماره‌های پرکاربرد در آمار و احتمال **واریانس** یک متغیر تصادفی مانند X است که آن را با $\mathrm{Var}(X)$ نشان می‌دهیم.

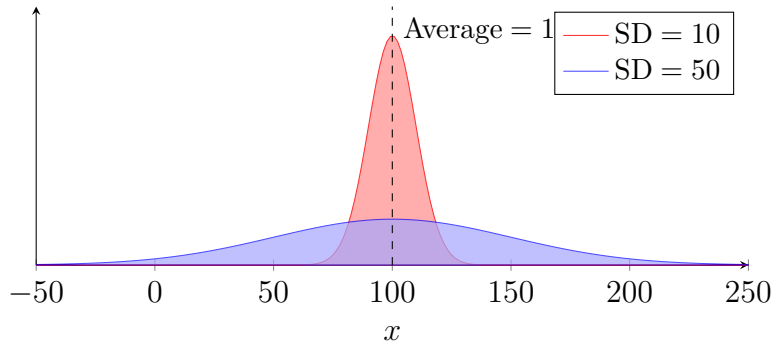
تعریف ۱۰-۳: واریانس و انحراف معیار

با $\mu = \mathbb{E}(X)$:

$$\mathrm{Var}(X) = \mathbb{E}\big((X-\mu)^2\big) = \int_{-\infty}^{\infty} (x-\mu)^2 f_X(x)\,\mathrm{d}x, \qquad \mathrm{Var}(X) = \sum_x (x-\mu)^2 P(X=x),$$

$$\sigma(X) = \sqrt{\mathrm{Var}(X)}.$$

واریانس، و یا جذر آن «انحراف معیار $\sigma(X)$» میزان **پراکندگی** یک متغیر تصادفی حول میانگین را نشان می‌دهند. دو توزیع می‌توانند میانگین یکسان (مثلاً ۱۰۰) ولی پراکندگی کاملاً متفاوت داشته باشند:



نکته. چرا مربع و نه قدر مطلق؟ $\mathbb{E}|X-\mu|$ (انحراف مطلق میانگین) هم معیار پراکندگی است، اما واریانس خواص جبری بسیار زیباتری دارد (مثلاً جمع‌پذیری برای متغیرهای مستقل، پایین‌تر). انحراف معیار هم‌واحد با X است (مثلاً سانتی‌متر)، اما واریانس واحد مربع دارد.

۱.۲.۱۰ خواص

قضیه ۱۰-۴: خواص واریانس

فرض کنید X یک متغیر تصادفی پیوسته، گسسته و یا مخلوط باشد و واریانس آن وجود داشته باشد. آنگاه:

۱. همواره داریم:

$$\mathrm{Var}(X) = \mathbb{E}\big((X-\mathbb{E}(X))^2\big) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \ge 0.$$

۲. در صورتی که a, b اعداد ثابت حقیقی باشند، داریم:

$$\operatorname{Var}(aX + b) = a^2 \operatorname{Var}(X).$$

۳. در صورتی که X, Y متغیرهای تصادفی مستقل باشند، داریم:

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y), \qquad \operatorname{Var}(X + Y) = \operatorname{Var}(X) + \operatorname{Var}(Y).$$

اثبات. (۱) با بسط مربع و خاصیت خطی میانگین (μ یک عدد ثابت است):

$$\mathbb{E}\big((X-\mu)^2\big) = \mathbb{E}(X^2 - 2\mu X + \mu^2) = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

نامنفی بودن از آنجاست که $(X-\mu)^2 \geq 0$ (یا از نامساوی جنسن).

(۲) $\mathbb{E}(aX+b) = a\mu+b$؛ پس $aX+b-\mathbb{E}(aX+b) = a(X-\mu)$ و $\operatorname{Var}(aX+b) = \mathbb{E}\big(a^2(X-\mu)^2\big) = a^2\operatorname{Var}(X)$. (افزودن ثابت b فقط توزیع را جابه‌جا می‌کند و پراکندگی را تغییر نمی‌دهد.)

(۳) **ضرب:** با استقلال، $\mathbb{P}\{X=x, Y=y\} = \mathbb{P}\{X=x\}\mathbb{P}\{Y=y\}$؛ پس

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y} xy\,\mathbb{P}\{X=x, Y=y\} = \sum_{x,y} xy\,\mathbb{P}\{X=x\}\mathbb{P}\{Y=y\} \\ &= \sum_{x} x\mathbb{P}\{X=x\} \sum_{y} y\mathbb{P}\{Y=y\} = \mathbb{E}(X)\mathbb{E}(Y).\end{aligned}$$

(در حالت پیوسته روابط مشابهی با انتگرال و $f_{X,Y} = f_X f_Y$ می‌توان نوشت.)

جمع: با $\mu_X = \mathbb{E}X$ و $\mu_Y = \mathbb{E}Y$:

$$\begin{aligned}\operatorname{Var}(X+Y) &= \mathbb{E}\big\{(X+Y-\mu_X-\mu_Y)^2\big\} \\ &= \mathbb{E}\big\{(X-\mu_X)^2 + (Y-\mu_Y)^2 + 2(X-\mu_X)(Y-\mu_Y)\big\} \\ &= \mathbb{E}\big\{(X-\mu_X)^2 + (Y-\mu_Y)^2\big\} = \operatorname{Var}(X) + \operatorname{Var}(Y).\end{aligned}$$

در سطر سوم از خاصیت خطی بودن عملگر Expectation و همچنین نتیجه بند پیشین استفاده شده است: $\mathbb{E}\{(X-\mu_X)(Y-\mu_Y)\} = \mathbb{E}(X-\mu_X)\,\mathbb{E}(Y-\mu_Y) = 0\times 0 = 0$ پس $X-\mu_X$ و $Y-\mu_Y$ مستقل‌اند.
□

دقت کنید! بدون استقلال، $\operatorname{Var}(X+Y) = \operatorname{Var}X + \operatorname{Var}Y$ لزوماً درست نیست. مثلاً اگر $Y = X$ آنگاه $\operatorname{Var}(2X) = 4\operatorname{Var}X \neq 2\operatorname{Var}X$؛ و اگر $Y = -X$ آنگاه $\operatorname{Var}(X+Y) = 0$. جمله اضافی $2\mathbb{E}\{(X-\mu_X)(Y-\mu_Y)\}$ همان «کوواریانس» است که در جلسات آینده مطالعه می‌کنیم. همچنین دقت کنید: $\operatorname{Var}(X-Y) = \operatorname{Var}X + \operatorname{Var}Y$ (نه تفاضل!)، زیرا $\operatorname{Var}(-Y) = (-1)^2\operatorname{Var}Y$.

۳.۱۰ واریانس توزیع‌های معروف

۱.۳.۱۰ توزیع‌های برنولی، دوجمله‌ای و پواسون

مثال ۱۰-۵: برنولی $X \sim \mathrm{Bern}(p)$

$$\mathrm{Var}(X) = p \times (1-p)^2 + (1-p) \times (0-p)^2 = p(1-p)\big[(1-p)+p\big] = p(1-p),$$
$$\sigma(X) = \sqrt{p(1-p)}.$$

(روش دیگر: $X^2 = X$ پس $\mathbb{E}X^2 = p$ و $\mathrm{Var}\, X = p - p^2$.) بیشینه واریانس در $p = \frac{1}{2}$ رخ می‌دهد: سکه سالم «غیرقابل‌پیش‌بینی‌ترین» است.

مثال ۱۰-۶: دوجمله‌ای $X \sim \mathrm{Binomial}(n, p)$

$$\mathrm{Var}(X) = \sum_{i=0}^{n} (i - np)^2 \binom{n}{i} p^i (1-p)^{n-i} = np(1-p).$$

حل. روش سریع: $X = \sum_{i=1}^{n} B_i$ که B_iها برنولی‌های مستقل‌اند. طبق خاصیت جمع واریانس برای متغیرهای مستقل: $\mathrm{Var}\, X = \sum \mathrm{Var}\, B_i = np(1-p)$.
روش مستقیم: با اتحاد $k(k-1)\binom{n}{k} = n(n-1)\binom{n-2}{k-2}$ داریم $\mathbb{E}[X(X-1)] = n(n-1)p^2$. پس $\mathbb{E}X^2 = n(n-1)p^2 + np$ و $\mathrm{Var}\, X = n(n-1)p^2 + np - n^2p^2 = np - np^2 = np(1-p)$. ■

مثال ۱۰-۷: پواسون $X \sim \mathrm{Poisson}(\lambda)$

$$\mathbb{E}(X) = \lambda, \qquad \mathrm{Var}(X) = \lambda.$$

حل. $\mathbb{E}[X(X-1)] = \sum_{k\geq 2} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda} \sum_{k\geq 2} \frac{\lambda^{k-2}}{(k-2)!} = \lambda^2$ پس $\mathbb{E}X^2 = \lambda^2 + \lambda$ و $\mathrm{Var}\, X = \lambda^2 + \lambda - \lambda^2 = \lambda$. (سازگار با حد دوجمله‌ای: $np(1-p) \to \lambda$ وقتی $p \to 0$.) ■

۲.۳.۱۰ توزیع‌های گاوسی، نمایی و یکنواخت

مثال ۱۰-۸: گاوسی $X \sim \mathcal{N}(\mu, \sigma^2)$

$\mathrm{Var}(X) = \sigma^2$.

حل. با $z = \frac{x-\mu}{\sigma}$: $\mathrm{Var}\, X = \sigma^2 \int z^2 \frac{e^{-z^2/2}}{\sqrt{2\pi}}\, \mathrm{d}z$. با انتگرال‌گیری جزءبه‌جزء ($u = z$، $\mathrm{d}v = ze^{-z^2/2}\,\mathrm{d}z$): $\int z^2 e^{-z^2/2}\,\mathrm{d}z = \big[-ze^{-z^2/2}\big]_{-\infty}^{\infty} + \int e^{-z^2/2}\,\mathrm{d}z = \sqrt{2\pi}$. پس $\mathrm{Var}\, X = \sigma^2$ ــ پارامتر σ^2 دقیقاً همان واریانس است. ■

مثال ۱۰-۹: نمایی $X \sim \text{Exponential}(\lambda)$

$$\text{Var}(X) = \lambda \int_0^\infty \left(x - \lambda^{-1}\right)^2 e^{-\lambda x}\,\mathrm{d}x = \lambda^{-2}.$$

حل. با $\int_0^\infty x^n e^{-\lambda x}\,\mathrm{d}x = \frac{n!}{\lambda^{n+1}}$: $\mathbb{E}X^2 = \lambda \cdot \frac{2}{\lambda^3} = \frac{2}{\lambda^2}$. پس $\text{Var}\, X = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$؛ یعنی $\sigma = \mathbb{E}X = \frac{1}{\lambda}$. ■

مثال ۱۰-۱۰: یکنواخت $X \sim \text{Uniform}(a, b)$

$$\text{Var}(X) = \frac{1}{12}(b-a)^2.$$

حل. $Y = X - \frac{a+b}{2}$ روی $[-\frac{L}{2}, \frac{L}{2}]$ یکنواخت است ($L = b - a$). پس $\text{Var}\, X = \mathbb{E}Y^2 = \frac{1}{L}\int_{-L/2}^{L/2} y^2\,\mathrm{d}y = \frac{1}{L}\cdot\frac{2}{3}\left(\frac{L}{2}\right)^3 = \frac{L^2}{12}$. ■

جدول خلاصه میانگین و واریانس توزیع‌های معروف

توزیع	$\mathbb{E}(X)$	$\text{Var}(X)$
برنولی $\text{Bern}(p)$	p	$p(1-p)$
دوجمله‌ای $\text{Bin}(n,p)$	np	$np(1-p)$
هندسی (احتمال موفقیت p)	$\frac{1}{p}$	$\frac{1-p}{p^2}$
پواسون $\text{Pois}(\lambda)$	λ	λ
یکنواخت $\mathcal{U}(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
نمایی $\text{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
گاوسی $\mathcal{N}(\mu,\sigma^2)$	μ	σ^2
لاپلاس (μ, b)	μ	$2b^2$
بتا (α,β)	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
کوشی	ندارد	ندارد

۴.۱۰ واریانس جمع متغیرهای تصادفی i.i.d.

فرض کنید که $X_1, X_2, \ldots, X_n$ متغیرهای تصادفی i.i.d. از یک توزیع با میانگین μ و واریانس σ^2 باشند. متغیر تصادفی $\bar{X}_n$ را به صورت زیر تعریف می‌کنیم:

$$\bar{X}_n \triangleq \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

در این صورت (با خاصیت جمع‌پذیری واریانس برای متغیرهای مستقل و $\operatorname{Var}(aX) = a^2 \operatorname{Var} X$) داریم:

$$\operatorname{Var}(\bar{X}_n) = \sum_{i=1}^{n} \operatorname{Var}\left(\frac{X_i}{n}\right) = \sum_{i=1}^{n} \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

با افزایش مجانبی n، واریانس متغیر تصادفی $\bar{X}_n$ به سمت صفر میل می‌کند. پس انحراف معیار میانگین نمونه‌ای $\frac{\sigma}{\sqrt{n}}$ است: برای نصف کردن خطا، باید چهار برابر نمونه جمع کنیم.

نکته. این نتیجه، شهود قانون اعداد بزرگ است: $\mathbb{E}\bar{X}_n = \mu$ و پراکندگی $\bar{X}_n$ حول μ به صفر میل می‌کند. در جلسه بعد با «نامساوی چبیشف» همین را به اثبات دقیق شکل ضعیف قانون اعداد بزرگ تبدیل می‌کنیم: $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \le \frac{\sigma^2}{n\varepsilon^2} \to 0$. این همچنین توضیح می‌دهد که چرا در جلسه سوم عرض توزیع تعداد شیرها $O(\sqrt{n})$ بود: $\sigma(\text{تعداد شیر}) = \sqrt{n/4}$.

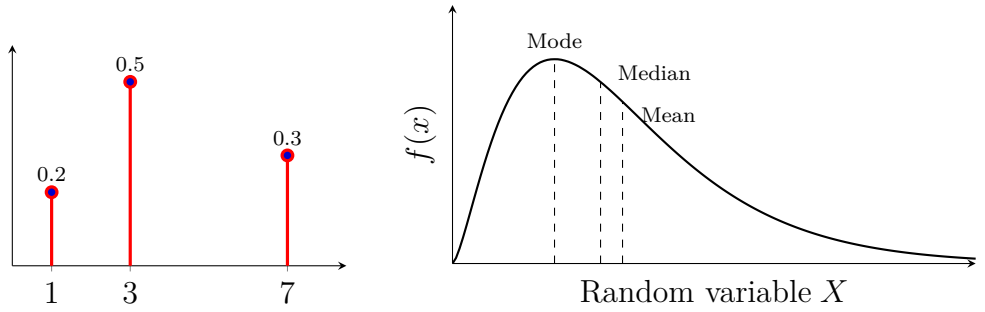
۵.۱۰ مُد و میانه (Mode and Median)

۱.۵.۱۰ مُد (Mode)

تعریف ۱۰-۱۱: مد

به محتمل‌ترین مقدار یک متغیر تصادفی، مُد (Mode) آن متغیر تصادفی اطلاق می‌گردد: برای متغیر گسسته، مقداری که PMF را بیشینه می‌کند؛ برای متغیر پیوسته، نقطه بیشینه PDF.

مثال: اگر $P(X=1) = 0.2$، $P(X=3) = 0.5$ و $P(X=7) = 0.3$ آنگاه مد برابر ۳ است (در حالی که میانگین $0.2 + 1.5 + 2.1 = 3.8$ است).



۲.۵.۱۰ میانه (Median)

تعریف ۱۰-۱۲: میانه

میانه به کوچک‌ترین مقداری اطلاق می‌گردد که یک متغیر تصادفی با احتمال $\frac{1}{2}$ کوچک‌تر یا مساوی آن است. به صورت معادل، به کوچک‌ترین مقداری اطلاق می‌گردد که تابع CDF در آن برابر یا بزرگ‌تر یا مساوی $\frac{1}{2}$ است:

$$m = \min\{x : \ F_X(x) \geq \tfrac{1}{2}\}.$$

برای متغیر پیوسته، میانه نقطه‌ای است که مساحت زیر PDF را به دو نیمه ۵۰٪ تقسیم می‌کند؛ در حالی که میانگین «نقطه تعادل» (مرکز جرم) است.

نکته. رابطه مد، میانه و میانگین: برای توزیع‌های متقارن تک‌قله (مانند گاوسی) هر سه برابرند. برای توزیع‌های چوله به راست (دم بلند در سمت راست، مانند نمایی یا توزیع درآمد) معمولاً میانگین $>$ میانه $>$ مد؛ زیرا مقادیر بزرگ دم، میانگین را به سمت خود می‌کشند. میانه نسبت به داده‌های پرت «مقاوم» (robust) است و حتی برای کوشی (که میانگین ندارد) وجود دارد و برابر x_0 است.

مثال ۱۰-۱۳: مد، میانه و میانگین توزیع نمایی

برای $X \sim \mathrm{Exp}(\lambda)$: مد $= 0$ (چگالی نزولی است)، میانه از $1 - e^{-\lambda m} = \frac{1}{2}$ برابر $m = \frac{\ln 2}{\lambda} \approx \frac{0.693}{\lambda}$ و میانگین $\frac{1}{\lambda}$. پس $0 < 0.693/\lambda < 1/\lambda$ ــ مطابق ترتیب توزیع‌های چوله به راست.

۶.۱۰ تمرین‌های تکمیلی

تمرین ۱۰-۱۴

واریانس عدد یک تاس سالم را حساب کنید. سپس واریانس مجموع اعداد ۱۰ تاس مستقل را بیابید.

حل. $\mathbb{E}X = 3.5$ و $\mathbb{E}X^2 = \frac{91}{6}$؛ پس $\operatorname{Var} X = \frac{91}{6} - \frac{49}{4} = \frac{182-147}{12} = \frac{35}{12} \approx 2.92$. برای مجموع ۱۰ تاس مستقل: $10 \times \frac{35}{12} = \frac{350}{12} \approx 29.17$ (انحراف معیار حدود 5.4 حول میانگین 35). ■

تمرین ۱۰-۱۵

اگر $\mathbb{E}X = 2$ و $\operatorname{Var} X = 3$ باشد، $\mathbb{E}[(2X-1)^2]$ و $\operatorname{Var}(5 - 3X)$ را بیابید.

حل. $\mathbb{E}X^2 = \operatorname{Var} X + (\mathbb{E}X)^2 = 7$. پس $\mathbb{E}[(2X-1)^2] = 4\mathbb{E}X^2 - 4\mathbb{E}X + 1 = 28 - 8 + 1 = 21$. $\operatorname{Var}(5 - 3X) = 9 \operatorname{Var} X = 27$. ■

تمرین ۱۰-۱۶

برای اندازه‌گیری یک کمیت، از دستگاهی با خطای تصادفی با انحراف معیار ۲ میلی‌متر استفاده می‌کنیم. چند اندازه‌گیری مستقل لازم است تا انحراف معیار میانگین اندازه‌گیری‌ها حداکثر 0.25 میلی‌متر شود؟

حل. $\sigma(\bar{X}_n) = \frac{2}{\sqrt{n}} \leq 0.25 \Rightarrow \sqrt{n} \geq 8 \Rightarrow n \geq 64$. ■

تمرین ۱۰-۱۷

میانه و مد توزیع $f(x) = 2x$ روی $[0, 1]$ را بیابید و با میانگین $(\frac{2}{3})$ مقایسه کنید.

حل. $F(x) = x^2$؛ میانه: $m^2 = \frac{1}{2} \Rightarrow m = \frac{1}{\sqrt{2}} \approx 0.707$. مد: $x = 1$ (چگالی صعودی است). ترتیب: مد $= 1 >$ میانه $= 0.707 >$ میانگین $= 0.667$ ــ این توزیع چوله به چپ است و ترتیب برعکس می‌شود. ■

جلسه ۱۱

گشتاورها، تابع مولد گشتاور، تابع مشخصه و توابع یک متغیر تصادفی

۱.۱۱ گشتاورهای یک توزیع (Moments of a Distribution)

تعریف ۱۱-۱: گشتاور (Moment)

برای $n \in \mathbb{W} = \{0, 1, 2, \dots\}$، گشتاورهای یک متغیر تصادفی مانند $X \sim f_X(x)$ به صورت زیر تعریف می‌شوند:

$$m_n \triangleq \mathbb{E}(X^n) = \int_{-\infty}^{\infty} x^n f_X(x)\,\mathrm{d}x.$$

گشتاورهای مرکزی (حول میانگین μ):

$$\mu_n \triangleq \mathbb{E}\big((X-\mu)^n\big).$$

همچنین گشتاورهای مطلق ($\mathbb{E}|X|^n$) و تعمیم‌یافته ($\mathbb{E}[(X-c)^n]$) حول نقطه دلخواه c، یا توان‌های غیرصحیح) نیز وجود دارند.

۱.۱.۱۱ خواص

- گشتاور صفرم همواره برابر با ۱، و گشتاور اول (در صورت وجود) برابر با **میانگین توزیع** هستند: $m_0 = \int f_X = 1$ و $m_1 = \mathbb{E}X = \mu$. همچنین $\mu_1 = 0$ و $\mu_2 = \mathrm{Var}(X)$.
- تمام و یا برخی از گشتاورها می‌توانند وجود نداشته باشند (توزیع کوشی)، گاهی اوقات نیز تمامی گشتاورها وجود دارند (گاوسی، نمایی و تمامی توزیع‌های finite-support).
- تحت شرایطی، کل توزیع f_X را می‌توان صرفاً با دانستن $m_0, m_1, m_2, \dots$ به صورت یکتا به دست آورد.
- همواره داریم:

$$m_{2n} \geq m_n^2.$$

اثبات نامساوی آخر. $\mathrm{Var}(X^n) = \mathbb{E}(X^{2n}) - \left(\mathbb{E}X^n\right)^2 \geq 0$. (یا از جنسن با تابع محدب $g(u) = u^2$ روی $U = X^n$.) □

نکته. اگر گشتاور مرتبه k وجود داشته باشد، همه گشتاورهای مرتبه کمتر نیز وجود دارند. برای توزیع‌های با تکیه‌گاه کران‌دار (مثلاً $|X| \leq M$) همه گشتاورها وجود دارند زیرا $|m_n| \leq M^n$. برای توزیع کوشی حتی m_1 وجود ندارد.

۲.۱.۱۱ گشتاور دوم، واریانس و Kurtosis

دقت کنید که برای یک متغیر تصادفی، سه مقدار زیر با یکدیگر فرق دارند:

- **گشتاور دوم:** $m_2 = \mathbb{E}(X^2)$؛
- **واریانس:** $\mathrm{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$؛
- **انحراف معیار:** $\sigma(X) = \sqrt{\mathrm{Var}(X)}$.

(این سه فقط وقتی $\mathbb{E}X = 0$ باشد به هم مربوط و $m_2 = \mathrm{Var}\, X$ می‌شود.)

تعریف ۱۱-۲: چولگی و کشیدگی

یکی از آماره‌های پرکاربرد در پردازش سیگنال (Signal Processing)، **Kurtosis** (کشیدگی) نام دارد:

$$\mathrm{Kurt}(X) = \frac{\mu_4}{\sigma^4}.$$

به طور مشابه، **چولگی** (Skewness) به صورت $\frac{\mu_3}{\sigma^3}$ تعریف می‌شود و میزان عدم تقارن توزیع را می‌سنجد.

از Kurtosis در Independent Component Analysis (ICA) و جداسازی کور منابع (Blind Source Separation) استفاده می‌گردد. برای توزیع گاوسی $\mathrm{Kurt} = 3$ است؛ توزیع‌های با دم سنگین‌تر (مثل لاپلاس با $\mathrm{Kurt} = 6$) کشیدگی بیشتر و توزیع‌های «پهن» (مثل یکنواخت با $\mathrm{Kurt} = 1.8$) کشیدگی کمتری دارند. ایده ICA: طبق قضیه حد مرکزی، مخلوط چند منبع مستقل «گاوسی‌تر» از تک‌تک منابع است؛ پس با بیشینه کردن فاصله Kurtosis از ۳ می‌توان منابع را از هم جدا کرد (مثلاً جدا کردن صدای چند گوینده که هم‌زمان ضبط شده‌اند).

مثال ۱۱-۳: گشتاورهای توزیع یکنواخت

گشتاورهای $X \sim \mathcal{U}(0,1)$ و Kurtosis آن را بیابید.

حل. $m_n = \int_0^1 x^n\,\mathrm{d}x = \frac{1}{n+1}$. پس $\mu = \frac{1}{2}$ و $\sigma^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$. گشتاور مرکزی چهارم: $\mu_4 = \int_{-1/2}^{1/2} y^4\,\mathrm{d}y = \frac{2}{5}\cdot\frac{1}{32} = \frac{1}{80}$. پس $\mathrm{Kurt} = \frac{1/80}{1/144} = \frac{144}{80} = 1.8$. ■

۲.۱۱ تابع مولد گشتاور (Moment Generating Function)

تعریف ۱۱-۴: تابع مولد گشتاور

تابع مولد گشتاور (MGF) برای متغیر تصادفی $X \sim f_X(x)$ و $t \in \mathbb{C}$ به صورت زیر تعریف می‌شود:

$$M_X(t) \triangleq \mathbb{E}\left[e^{tX}\right] = \int_{-\infty}^{\infty} e^{tx} f_X(x)\,\mathrm{d}x.$$

محدوده تعریف ورودی تابع MGF، تمامی مقادیری از $t \in \mathbb{C}$ است که مقدار میانگین فوق به ازای آن وجود داشته باشد.

۱.۲.۱۱ خواص

- تابع مولد گشتاور به ازای هر $t \in \mathbb{R}$ (صرفاً مقادیر حقیقی) همواره مقداری مثبت است (چون $e^{tX} > 0$).
- تابع MGF در اثر میانگین‌گیری بر روی یک ماهیت تصادفی (یعنی e^{tX}) به وجود آمده است. لذا MGF تصادفی نیست و تابعی یقینی به حساب می‌آید.
- تمام اطلاعات توزیع $f_X(x)$ در MGF آن وجود دارد. به عبارت دیگر، تابع MGF حاصل انتقال توزیع $f_X(x)$ به یک حوزه دیگر (مشابه حوزه لاپلاس) است. (در واقع $M_X(t)$ همان تبدیل لاپلاس دوطرفه f_X در $s = -t$ است.)
- می‌توان به راحتی دید که $M_X(0) = 1$. همچنین برای توزیع گاوسی، MGF به ازای تمامی صفحه اعداد مختلط وجود دارد.

۲.۲.۱۱ کاربرد اصلی: تولید گشتاورها

می‌توان به راحتی دید که خاصیت زیر برای مشتقات MGF وجود دارد (به دلیل خطی بودن عملگر مشتق، از انتگرال عبور خواهد کرد):

$$\frac{\partial^n}{\partial t^n} M_X(t) = \frac{\partial^n}{\partial t^n} \int_{-\infty}^{\infty} e^{tx} f_X(x)\,\mathrm{d}x = \int_{-\infty}^{\infty} x^n e^{tx} f_X(x)\,\mathrm{d}x.$$

در صورتی که مشتق nام تابع MGF را با $M_X^{(n)}(t)$ نشان دهیم، خواهیم داشت:

$$\boxed{M_X^{(n)}(0) = \int_{-\infty}^{\infty} x^n f_X(x)\,\mathrm{d}x = m_n}$$

یعنی مشتق nام در صفر، همان گشتاور مرتبه n برای متغیر تصادفی X است. معادلاً با بسط تیلور:

$$M_X(t) = \mathbb{E}\Big[\sum_{n\geq 0} \frac{t^n X^n}{n!}\Big] = \sum_{n\geq 0} \frac{m_n}{n!} t^n;$$

MGF همه گشتاورها را به صورت ضرایب سری تیلورش در خود «بسته‌بندی» کرده است ــ از این‌رو «مولد گشتاور» نام دارد.

مثال ۱۱-۵: MGF و گشتاورهای توزیع نمایی

حل. برای $t < \lambda$: $M_X(t) = \int_0^\infty e^{tx}\lambda e^{-\lambda x}\,\mathrm{d}x = \lambda\int_0^\infty e^{-(\lambda-t)x}\,\mathrm{d}x = \frac{\lambda}{\lambda-t}$ (برای $t \geq \lambda$ انتگرال واگراست). مشتقات: $M'(t) = \frac{\lambda}{(\lambda-t)^2}$ و $M''(t) = \frac{2\lambda}{(\lambda-t)^3}$؛ پس $m_1 = \frac{1}{\lambda}$ و $m_2 = \frac{2}{\lambda^2}$ و $\operatorname{Var} X = \frac{1}{\lambda^2}$ (مطابق جلسه قبل). در حالت کلی $M_X(t) = \frac{1}{1-t/\lambda} = \sum_n \frac{t^n}{\lambda^n}$، پس $m_n = \frac{n!}{\lambda^n}$. ■

مثال ۱۱-۶: MGF توزیع گاوسی

حل. ابتدا برای $Z \sim \mathcal{N}(0,1)$ با «تکمیل مربع»: $tz - \frac{z^2}{2} = -\frac{(z-t)^2}{2} + \frac{t^2}{2}$

$$M_Z(t) = \int \frac{1}{\sqrt{2\pi}} e^{tz - z^2/2}\,\mathrm{d}z = e^{t^2/2}\int \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2}\,\mathrm{d}z = e^{t^2/2}.$$

برای $X = \mu + \sigma Z$: $M_X(t) = \mathbb{E}e^{t\mu + t\sigma Z} = e^{t\mu}M_Z(\sigma t) = e^{t\mu + \sigma^2 t^2/2}$. ■

۳.۲.۱۱ خاصیت مهم: MGF جمع متغیرهای مستقل

قضیه ۱۱-۷

در صورتی که X, Y دو متغیر تصادفی مستقل با توابع مولد گشتاور $M_X(t), M_Y(t)$ باشند، برای متغیر تصادفی جدید $X+Y$ خواهیم داشت:

$$\begin{aligned} M_{X+Y}(t) &= \mathbb{E}\left[e^{t(X+Y)}\right] = \mathbb{E}\left[e^{tX+tY}\right] = \mathbb{E}\left[e^{tX}e^{tY}\right] \\ &= \mathbb{E}\left[e^{tX}\right]\mathbb{E}\left[e^{tY}\right] = M_X(t)\,M_Y(t). \end{aligned}$$

(در سطر دوم از استقلال e^{tX} و e^{tY} و قاعده $\mathbb{E}(UV) = \mathbb{E}U\,\mathbb{E}V$ استفاده شد.)

این خاصیت بسیار قدرتمند است: توزیع جمع متغیرهای مستقل (که مستقیماً با «کانولوشن» به دست می‌آید) در حوزه MGF به یک ضرب ساده تبدیل می‌شود ــ درست مثل تبدیل لاپلاس/فوریه در سیگنال‌ها و سیستم‌ها.

مثال ۱۱-۸: جمع پواسون‌های مستقل

اگر $X \sim \mathrm{Pois}(\lambda_1)$ و $Y \sim \mathrm{Pois}(\lambda_2)$ مستقل باشند، توزیع $X+Y$ چیست؟

حل. $M_X(t) = \sum_k e^{tk}e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}e^{\lambda e^t} = e^{\lambda(e^t-1)}$. پس $M_{X+Y}(t) = e^{\lambda_1(e^t-1)}e^{\lambda_2(e^t-1)} = e^{(\lambda_1+\lambda_2)(e^t-1)}$ که MGF توزیع $\mathrm{Pois}(\lambda_1+\lambda_2)$ است. طبق یکتایی (پایین‌تر)، $X+Y \sim \mathrm{Pois}(\lambda_1+\lambda_2)$.

مثلاً اگر به دو صف مستقل به ترتیب ۲ و ۳ مشتری در ساعت برسد، به مجموع آن‌ها پواسون با نرخ ۵ می‌رسد. به همین روش، جمع دو گاوسی مستقل نیز گاوسی است: $\mathrm{MGF} = e^{t\mu_1+\sigma_1^2t^2/2}e^{t\mu_2+\sigma_2^2t^2/2}$ $\mathcal{N}(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$. ■

۴.۲.۱۱ توزیع‌های مشهور MGF

توزیع	تابع مولد گشتاور $M_X(t)$
تباهیده (ثابت) δ_a	e^{ta}
برنولی $P(X=1)=p$	$1-p+pe^t$
دوجمله‌ای $B(n,p)$	$(1-p+pe^t)^n$
هندسی $(k\geq 0)$ $(1-p)^k p$	$\dfrac{p}{1-(1-p)e^t}, \quad t<-\ln(1-p)$
دوجمله‌ای منفی $\mathrm{NB}(r,p)$	$\left(\dfrac{p}{1-e^t+pe^t}\right)^r, \quad t<-\ln(1-p)$
پواسون $\mathrm{Pois}(\lambda)$	$e^{\lambda(e^t-1)}$
یکنواخت پیوسته $U(a,b)$	$\dfrac{e^{tb}-e^{ta}}{t(b-a)}$
یکنواخت گسسته $DU(a,b)$	$\dfrac{e^{at}-e^{(b+1)t}}{(b-a+1)(1-e^t)}$
لاپلاس $L(\mu,b)$	$\dfrac{e^{t\mu}}{1-b^2t^2}, \quad \lvert t\rvert<1/b$
نرمال $N(\mu,\sigma^2)$	$e^{t\mu+\sigma^2t^2/2}$
نمایی $\mathrm{Exp}(\lambda)$	$\dfrac{\lambda}{\lambda-t}, \quad t<\lambda$

نکته. دوجمله‌ای = جمع n برنولی مستقل، پس MGF آن توان nام MGF برنولی است. به همین ترتیب دوجمله‌ای منفی (تعداد شکست‌ها تا rامین موفقیت) جمع r هندسی مستقل است و MGF آن توان rام MGF هندسی است.

۳.۱۱ تابع مشخصه (Characteristic Function)

تعریف ۱۱-۹: تابع مشخصه

تابع مشخصه یا Characteristic Function برای $\omega \in \mathbb{R}$ به صورت زیر تعریف می‌شود:

$$\Phi(\omega) = M_X(j\omega) = \int_{-\infty}^{\infty} e^{j\omega x} f_X(x)\,\mathrm{d}x.$$

- همان‌گونه که مشخص است، این تابع به نوعی بیانگر **تبدیل فوریه** تابع چگالی احتمال متغیر تصادفی است (با علامت مثبت در نما).
- عمده خواص MGF، از جمله تولید گشتاور، برای Characteristic Function هم وجود دارد: $\Phi^{(n)}(0) = j^n m_n$ و برای متغیرهای مستقل $\Phi_{X+Y} = \Phi_X \Phi_Y$.

- مزیت بزرگ: چون $|e^{j\omega x}| = 1$، انتگرال همواره همگراست؛ پس تابع مشخصه **برای هر توزیعی** (حتی کوشی) وجود دارد، در حالی که MGF ممکن است وجود نداشته باشد.

۱.۳.۱۱ خواص و قضیه یکتایی

قضیه ۱۱-۱۰

۱. تابع مشخصه در $\omega = 0$ بیشترین مقدار قدرمطلق (Magnitude) را داراست:

$$|\Phi(\omega)| \le \Phi(0) = 1.$$

۲. **(یکتایی)** در صورتی که برای دو متغیر تصادفی X, Y داشته باشیم $\Phi_X(\omega) = \Phi_Y(\omega)$ (برای همه ω)، آنگاه دو متغیر تصادفی هم‌توزیع (identically distributed) هستند.

اثبات بند ۱. $|\Phi(\omega)| = \left|\int e^{j\omega x} f_X(x)\,\mathrm{d}x\right| \le \int |e^{j\omega x}| f_X(x)\,\mathrm{d}x = \int f_X(x)\,\mathrm{d}x = 1 = \Phi(0)$. □

(بند ۲ نتیجه وارون‌پذیری تبدیل فوریه است: $f_X(x) = \frac{1}{2\pi}\int \Phi(\omega) e^{-j\omega x}\,\mathrm{d}\omega$.)

۲.۳.۱۱ توابع مشخصه توزیع‌های معروف

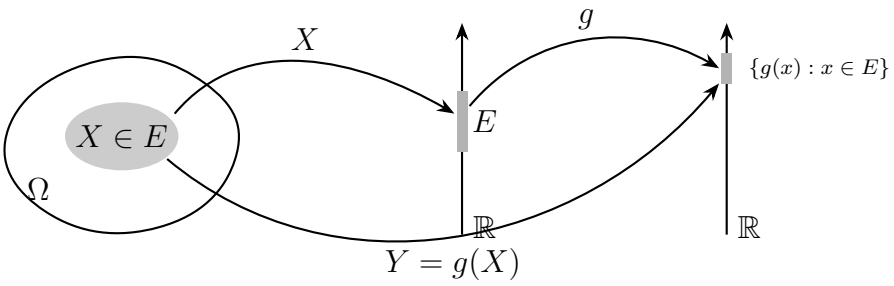
گاوسی $\mathcal{N}(\mu, \sigma^2)$	$\Phi_X(\omega) = e^{j\mu\omega - \sigma^2\omega^2/2}$
نمایی $\mathrm{Exponential}(\lambda)$	$\Phi_X(\omega) = \left(1 - \frac{j\omega}{\lambda}\right)^{-1}$
یکنواخت $\mathrm{Uniform}(a, b)$	$\Phi_X(\omega) = e^{j\omega\frac{a+b}{2}} \frac{\sin\left((b-a)\omega/2\right)}{(b-a)\omega/2}$
برنولی $\mathrm{Bern}(p)$	$\Phi_X(\omega) = pe^{j\omega} + (1-p)$
کوشی (x_0, γ)	$\Phi_X(\omega) = e^{jx_0\omega - \gamma\lvert\omega\rvert}$

نکته. (در اسلاید، فرمول یکنواخت بدون ضریب $\frac{1}{2}$ داخل سینوس آمده؛ شکل درست همان است که در جدول بالا نوشته‌ایم: $\int_a^b \frac{e^{j\omega x}}{b-a}\,\mathrm{d}x = \frac{e^{j\omega b} - e^{j\omega a}}{j\omega(b-a)} = e^{j\omega\frac{a+b}{2}} \frac{2\sin(\omega\frac{b-a}{2})}{\omega(b-a)}$.)
تابع مشخصه توزیع گاوسی، خود به شکل تابع چگالی احتمال یک توزیع گاوسی است ($e^{-\sigma^2\omega^2/2}$ یک «زنگوله» است) ــ همان خاصیت معروف «تبدیل فوریه گاوسی، گاوسی است». همچنین کوشی در نقطه $\omega = 0$ مشتق‌پذیر نیست (به دلیل $|\omega|$)، که با عدم وجود میانگین آن سازگار است.

۴.۱۱ توابعی از یک متغیر تصادفی

۱.۴.۱۱ تعریف مسئله

فرض کنید که متغیر تصادفی $X \sim f_X(x)$ و تابع دلخواه $g : \mathbb{R} \to \mathbb{R}$ داده شده باشند. متغیر تصادفی جدیدی به شکل $Y = g(X)$ را تشکیل می‌دهیم. هدف، به دست آوردن تابع چگالی احتمال $f_Y(y)$ بر حسب $f_X(x)$ و $g(\cdot)$ است.



روش کلی (از طریق CDF):

$$F_Y(y) = \mathbb{P}(g(X) \le y) = \mathbb{P}\big(X \in \{x :\ g(x) \le y\}\big) = \int_{\{x:\, g(x)\le y\}} f_X(x)\,\mathrm{d}x,$$

و سپس $f_Y = F_Y'$. این روش برای هر تابع g کار می‌کند.

۲.۴.۱۱ موارد ساده

شیفت. فرض کنید که متغیر تصادفی Y به صورت $Y = X + b$ تعریف شده باشد، که در اینجا b یک مقدار ثابت و یقینی است. در این صورت، هر مقدار تصادفی Y از طریق ابتدا نمونه‌گیری از X با استفاده از $f_X(x)$، و سپس شیفت دادن آن به اندازه مقدار ثابت و یقینی b حاصل می‌شود. پس می‌توان به راحتی استدلال کرد که:

$$\boxed{f_Y(y) = f_X(y-b)}$$

(از طریق CDF: $F_Y(y) = \mathbb{P}(X \le y-b) = F_X(y-b)$ و با مشتق‌گیری حکم به دست می‌آید.)

تبدیل خطی. حال فرض کنید که متغیر تصادفی Y به صورت $Y = aX + b$ تعریف شده باشد، که در اینجا $a \neq 0, b$ مقادیر ثابت و یقینی هستند. می‌توان نوشت (برای $a > 0$):

$$\begin{aligned} f_Y(y) &= \lim_{h\to 0} \frac{\mathbb{P}(y \le aX+b \le y+h)}{h} = \lim_{h\to 0} \frac{\mathbb{P}(y-b \le aX \le y+h-b)}{h} \\ &= \lim_{h\to 0} \frac{\mathbb{P}\big(\frac{y-b}{a} \le X \le \frac{y-b}{a} + \frac{h}{|a|}\big)}{h} = \frac{1}{|a|}\lim_{h\to 0} \frac{\mathbb{P}\big(\frac{y-b}{a} \le X \le \frac{y-b}{a} + \frac{h}{|a|}\big)}{h/|a|} \\ &= \frac{1}{|a|} f_X\Big(\frac{y-b}{a}\Big). \end{aligned}$$

(برای $a < 0$ جهت نامساوی‌ها برعکس می‌شود و همان نتیجه با $|a|$ به دست می‌آید.)

$$\boxed{f_Y(y) = \frac{1}{|a|} f_X\Big(\frac{y-b}{a}\Big)}$$

نکته. تعبیر: ضریب $\frac{1}{|a|}$ از آنجاست که تبدیل، بازه‌ها را $|a|$ برابر کش می‌دهد؛ برای حفظ مساحت (احتمال) کل، ارتفاع چگالی باید $|a|$ برابر کم شود. به عنوان نتیجه مهم: اگر $X \sim \mathcal{N}(\mu, \sigma^2)$ آنگاه $aX+b \sim \mathcal{N}(a\mu+b, a^2\sigma^2)$؛ به‌ویژه $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$ (استانداردسازی).

مثال ۱۱-۱۱: تبدیل خطی یکنواخت

اگر $X \sim \mathcal{U}(0,1)$ و $Y = 3 - 2X$، چگالی Y را بیابید.

حل. $a=-2$، $b=3$: برای $0 \le y \le 3$، یعنی $0 \le \frac{3-y}{2} \le 1$. پس $f_Y(y) = \frac{1}{2} f_X\!\left(\frac{y-3}{-2}\right) = \frac{1}{2}$ ■

$Y \sim \mathcal{U}(1,3)$.

مثال ۱۱-۱۲: یک تبدیل غیرخطی: $Y = X^2$

اگر $X \sim \mathcal{N}(0,1)$، چگالی $Y = X^2$ را بیابید.

حل. برای $y > 0$: $F_Y(y) = \mathbb{P}(-\sqrt{y} \le X \le \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$. با مشتق‌گیری (قاعده زنجیره‌ای):

$$f_Y(y) = \frac{1}{2\sqrt{y}}\big[f_X(\sqrt{y}) + f_X(-\sqrt{y})\big] = \frac{1}{\sqrt{2\pi y}} e^{-y/2}, \qquad y > 0.$$

این توزیع «کای‌دو با یک درجه آزادی» (χ^2_1) نام دارد. دقت کنید که چون $g(x) = x^2$ یک‌به‌یک نیست، دو شاخه $\pm\sqrt{y}$ هر دو سهم دارند. (این ایده در جلسه بعد به فرمول کلی تبدیل تعمیم داده می‌شود.) ■

۵.۱۱ تمرین‌های تکمیلی

تمرین ۱۱-۱۳

با استفاده از MGF، میانگین و واریانس توزیع دوجمله‌ای را به دست آورید.

حل. $M(t) = (1-p+pe^t)^n$. $M'(t) = npe^t(1-p+pe^t)^{n-1}$، پس $M'(0) = np$. $M''(t) = npe^t(\cdots)^{n-1} + n(n-1)p^2e^{2t}(\cdots)^{n-2}$، پس $M''(0) = np + n(n-1)p^2$. واریانس: $np + n(n-1)p^2 - n^2p^2 = np(1-p)$. ■

تمرین ۱۱-۱۴

اگر $M_X(t) = \frac{1}{4} + \frac{1}{2}e^t + \frac{1}{4}e^{2t}$، توزیع X را مشخص کنید.

حل. $M_X(t) = \sum_k P(X=k)e^{tk}$، پس با مقایسه ضرایب: $P(X=0) = \frac{1}{4}$، $P(X=1) = \frac{1}{2}$، $P(X=2) = \frac{1}{4}$ ــ یعنی $\mathrm{Bin}(2, \frac{1}{2})$ (تعداد شیر در دو پرتاب). در واقع $M_X(t) = \left(\frac{1}{2} + \frac{1}{2}e^t\right)^2$. ■

تمرین ۱۱-۱۵

اگر $X \sim \mathrm{Exp}(1)$، چگالی $Y = 2X + 1$ و $\mathbb{E}Y$ را بیابید.

حل. $f_Y(y) = \frac{1}{2}e^{-(y-1)/2}$ برای $y \geq 1$ (نمایی با نرخ $\frac{1}{2}$ که یک واحد شیفت خورده است). $\mathbb{E}Y = 2\mathbb{E}X + 1 = 3$.
■

تمرین ۱۱-۱۶

نشان دهید Kurtosis توزیع گاوسی برابر ۳ است.

حل. برای $Z \sim \mathcal{N}(0,1)$: $M_Z(t) = e^{t^2/2} = 1 + \frac{t^2}{2} + \frac{t^4}{8} + \cdots$. ضریب t^4 برابر $\frac{m_4}{4!}$ است، پس $m_4 = \frac{24}{8} = 3$. چون کشیدگی به تبدیل خطی حساس نیست (μ_4 و σ^4 هر دو در σ^4 ضرب می‌شوند)، برای هر گاوسی $\mathrm{Kurt} = 3$.
■

جلسه ۱۲

توابعی از یک متغیر تصادفی و تبدیل توزیع‌ها

۱.۱۲ یادآوری: تعریف مسئله و موارد ساده

فرض کنید که متغیر تصادفی $X \sim f_X(x)$ و تابع دلخواه $g : \mathbb{R} \to \mathbb{R}$ داده شده باشند. متغیر تصادفی جدیدی به شکل $Y = g(X)$ را تشکیل می‌دهیم. هدف، به دست آوردن تابع چگالی احتمال $f_Y(y)$ بر حسب $f_X(x)$ و $g(\cdot)$ است.

در جلسه قبل دو حالت ساده را دیدیم:

- **شیفت** $Y = X + b$: هر مقدار Y از نمونه‌گیری از X و سپس شیفت به اندازه b حاصل می‌شود؛ پس

$$f_Y(y) = f_X(y - b).$$

- **تبدیل خطی** $Y = aX + b$ با $a \neq 0$:

$$\begin{aligned} f_Y(y) &= \lim_{h \to 0} \frac{\mathbb{P}(y \leq aX + b \leq y + h)}{h} \\ &= \frac{1}{|a|} \lim_{h \to 0} \frac{\mathbb{P}\left(\frac{y-b}{a} \leq X \leq \frac{y-b}{a} + \frac{h}{|a|}\right)}{h/|a|} = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right). \end{aligned}$$

۲.۱۲ فرمول در حالت توابع g یک‌به‌یک

قضیه ۱۲-۱: تبدیل یک‌به‌یک

فرض کنید که g تابعی مشتق‌پذیر (با مشتق غیرصفر) و یک‌به‌یک باشد. در این صورت، فرض کنید به ازای مقدار معلوم y، مقدار یکتای x^* را به صورت زیر تعریف کنیم:

$$y = g(x^*) \qquad \text{or} \qquad x^* = g^{-1}(y).$$

مشابه با روش گام به گام پیشین می‌توان نشان داد که:

$$\boxed{f_Y(y) = \frac{1}{|g'(x^*)|} f_X(x^*)}$$

(برای $g(x) = ax + b$ داریم $g' = a$ و $x^* = \frac{y-b}{a}$، که همان فرمول تبدیل خطی است.)

۳.۱۲ فرمول کلی

قضیه ۱۲-۲: تبدیل کلی

فرض کنید که g تابعی مشتق‌پذیر باشد. همچنین $x_1, x_2, \dots$ را به صورت زیر تعریف می‌کنیم (همه ریشه‌های معادله $g(x) = y$):

$$y = g(x_1) = g(x_2) = \cdots \qquad \text{or} \qquad \{x_1, x_2, \dots\} = g^{-1}(y).$$

در این صورت، می‌توان رابطه کلی را به صورت زیر نوشت:

$$\boxed{f_Y(y) = \frac{1}{|g'(x_1)|} f_X(x_1) + \frac{1}{|g'(x_2)|} f_X(x_2) + \cdots}$$

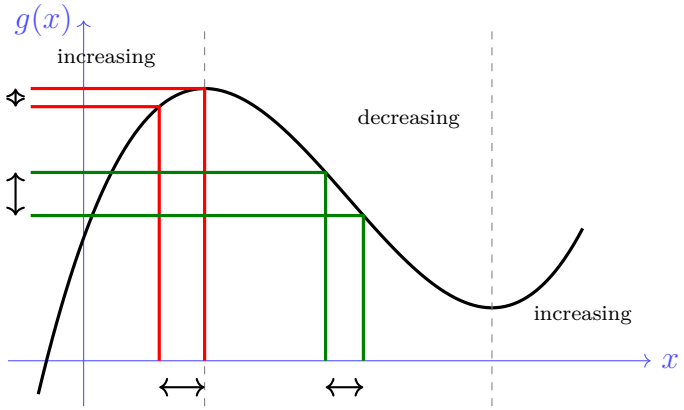
اگر معادله $g(x) = y$ هیچ ریشه‌ای نداشته باشد، $f_Y(y) = 0$.

در صورتی که تابع g در نقاطی مشتق‌پذیر نبود و یا مشتق آن صفر شد، معمولاً به صورت موردی باید تکلیف آن نقاط را مشخص نمود. (مثلاً اگر g روی یک بازه با احتمال مثبت ثابت باشد، Y در آن مقدار ثابت یک «ضربه» (دلتای دیراک) خواهد داشت.)

۴.۱۲ بررسی و شهود ریاضیاتی

۱.۴.۱۲ توجیه گرافیکی

دلیل ظاهر شدن مشتق در رابطه پیشین چیست؟ یک تابع غیریکنوا مانند شکل زیر را در نظر بگیرید که بخش‌هایی صعودی (increasing) و بخش‌هایی نزولی (decreasing) دارد.



- **نزدیک بیشینه (شیب کم):** یک بازه **بزرگ** از x به یک بازه **کوچک** از y نگاشته می‌شود (خطوط قرمز در شکل). کل احتمال یک بازه بزرگ در یک بازه کوچک فشرده می‌شود؛ پس چگالی Y آنجا **زیاد** است.

چون $|g'|$ کوچک است، $\frac{1}{|g'|}$ بزرگ است.

- **ناحیه پرشیب:** یک بازه **کوچک** از x به یک بازه **بزرگ‌تر** از y نگاشته می‌شود (خطوط سبز). احتمال کمی روی بازه بزرگی پخش می‌شود؛ پس چگالی Y **کم** است. چون $|g'|$ بزرگ است، $\frac{1}{|g'|}$ کوچک است.
- یک مقدار y (خط افقی) ممکن است منحنی را در چند نقطه قطع کند؛ احتمال همه این شاخه‌ها با هم جمع می‌شود ــ از این‌رو در فرمول کلی جمع ظاهر شده است.

به زبان دقیق: برای $\mathrm{d}y$ کوچک، $\mathbb{P}(y < Y \le y + \mathrm{d}y) = \sum_i \mathbb{P}(X \in$ حول $x_i) \approx$ بازه‌ای به طول $\frac{\mathrm{d}y}{|g'(x_i)|}$ $\sum_i f_X(x_i)\frac{\mathrm{d}y}{|g'(x_i)|}$.

۲.۴.۱۲ توجیه تحلیلی

(برای سادگی) فرض کنید که g تابعی اکیداً صعودی و لذا یک‌به‌یک باشد. در این صورت داریم:

$$F_Y(y) = \mathbb{P}\big(g(X) \le y\big) = \mathbb{P}\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big).$$

مطابق قبل تعریف می‌کنیم $x^* = g^{-1}(y)$. با قاعده زنجیره‌ای:

$$f_Y(y) = \frac{\partial}{\partial y} F_Y(y) = \frac{\partial g^{-1}(y)}{\partial y} \cdot \frac{\partial F_X\big(g^{-1}(y)\big)}{\partial g^{-1}(y)} = \frac{1}{g'(x^*)} f_X(x^*),$$

که در آن از مشتق تابع معکوس $\frac{\mathrm{d}g^{-1}(y)}{\mathrm{d}y} = \frac{1}{g'(x^*)}$ استفاده شد. به دلیل فرض اکیداً صعودی بودن تابع، $g' > 0$ و نیازی به قدرمطلق نیست.

اگر g اکیداً نزولی باشد، $F_Y(y) = \mathbb{P}(X \ge g^{-1}(y)) = 1 - F_X(g^{-1}(y))$ و مشتق آن $-\frac{f_X(x^*)}{g'(x^*)} = \frac{f_X(x^*)}{|g'(x^*)|}$ است (چون $g' < 0$). قدرمطلق هر دو حالت را یکجا پوشش می‌دهد. برای g غیریکنوا، دامنه را به بازه‌های یکنوا تقسیم کرده و سهم هر بازه را جمع می‌کنیم.

۵.۱۲ مثال

مثال ۱۲-۳: مربع یک متغیر یکنواخت

فرض کنید متغیر تصادفی X توزیعی یکنواخت بین -2 تا 2 دارد. متغیر تصادفی Y را به صورت $Y = X^2$ تعریف می‌کنیم.

۱. ساپورت Y شامل چه مقادیری است؟

۲. در کدام بخش‌های ساپورت، چگالی احتمال Y خیلی زیاد می‌شود؟ در کدام بخش‌ها کم است؟

۳. چگالی احتمال متغیر تصادفی Y، یعنی $f_Y(y)$ را به دست آورید.

حل. ۱. ساپورت: چون $X \in [-2, 2]$، داریم $Y = X^2 \in [0, 4]$.
۲. شهود: $g'(x) = 2x$ نزدیک $x = 0$ صفر است (شیب کم)؛ پس بازه‌ای از x حول صفر به بازه بسیار کوچکی از y نزدیک صفر فشرده می‌شود و چگالی Y نزدیک $y = 0$ **خیلی زیاد** (حتی بی‌نهایت) است.

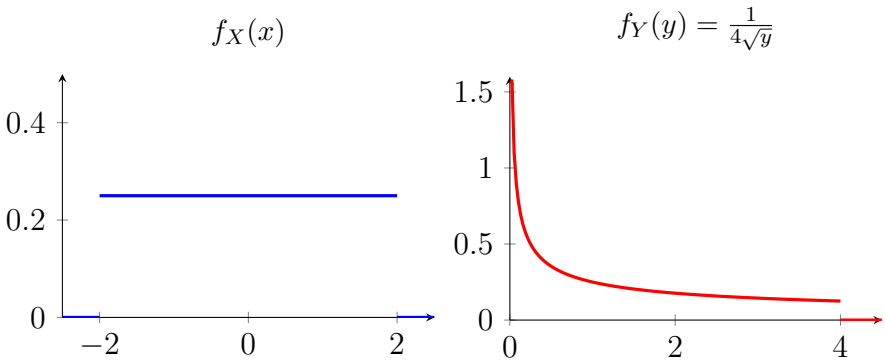
نزدیک $x = \pm 2$ شیب زیاد است ($|g'| = 4$)، پس چگالی Y نزدیک $y = 4$ **کم** است.

۳. محاسبه: $f_X(x) = \frac{1}{4}$ برای $-2 \le x \le 2$. برای $0 < y \le 4$، معادله $x^2 = y$ دو ریشه $x_{1,2} = \pm\sqrt{y}$ دارد و $|g'(x_{1,2})| = 2\sqrt{y}$. طبق فرمول کلی:

$$f_Y(y) = \frac{1}{2\sqrt{y}} \cdot \frac{1}{4} + \frac{1}{2\sqrt{y}} \cdot \frac{1}{4} = \frac{1}{4\sqrt{y}}, \qquad 0 < y \le 4,$$

و $f_Y(y) = 0$ در غیر این صورت.

بررسی: $\int_0^4 \frac{\mathrm{d}y}{4\sqrt{y}} = \frac{1}{4}\big[2\sqrt{y}\big]_0^4 = \frac{1}{4} \times 4 = 1$ ✓. همچنین $F_Y(y) = \mathbb{P}(|X| \le \sqrt{y}) = \frac{2\sqrt{y}}{4} = \frac{\sqrt{y}}{2}$ که مشتقش همان $\frac{1}{4\sqrt{y}}$ است. ■



نکته. دقت کنید که $f_Y(y) \to \infty$ وقتی $y \to 0^+$، ولی مساحت زیر آن متناهی (برابر ۱) است ــ نمونه دیگری از اینکه PDF می‌تواند از ۱ بزرگ‌تر شود.

۶.۱۲ تبدیل توزیع‌های مختلف به یکدیگر (Transforming Distributions)

۱.۶.۱۲ تبدیل توزیع‌ها به توزیع یکنواخت

قضیه ۱۲-۴: تبدیل انتگرال احتمال

برای متغیر تصادفی (پیوسته) X با توزیع انباشته دلخواه F_X، می‌توان مشاهده نمود که توزیع $Y = F_X(X)$ به صورت زیر محاسبه خواهد شد:

$$f_Y(y) = \frac{f_X\big(F_X^{-1}(y)\big)}{F_X'\big(F_X^{-1}(y)\big)} = \mathbf{1}(0 \le y \le 1).$$

لذا Y یک توزیع یکنواخت بین صفر و یک خواهد داشت.

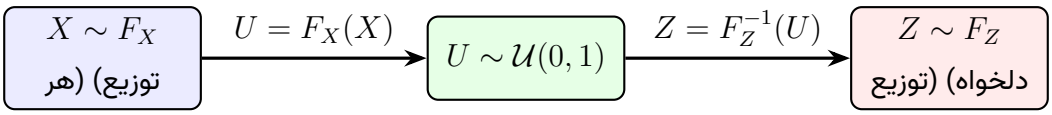
اثبات. $g = F_X$ اکیداً صعودی است (روی تکیه‌گاه) و $g' = F_X' = f_X$. با فرمول تبدیل یک‌به‌یک و $x^* = F_X^{-1}(y)$: $f_Y(y) = \frac{f_X(x^*)}{f_X(x^*)} = 1$ برای $y \in [0,1]$ (برد F_X). روش دوم با CDF: $\mathbb{P}(Y \le y) = \mathbb{P}(F_X(X) \le y) = \mathbb{P}(X \le F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y$. □

۲.۶.۱۲ تبدیل توزیع یکنواخت به سایر توزیع‌ها

قضیه ۱۲-۵: روش تبدیل معکوس

فرض کنید که f_Z, F_Z به ترتیب توابع چگالی و توزیع انباشته یک متغیر تصادفی فرضی مانند Z باشند (دقت کنید که f_Z و F_Z توابعی معلوم و غیرتصادفی هستند). برای متغیر تصادفی Y با توزیع یکنواخت $\mathcal{U}(0,1)$، می‌توان مشاهده نمود که توزیع متغیر تصادفی $F_Z^{-1}(Y)$ با متغیر تصادفی فرضی Z یکسان خواهد بود.

اثبات. $\mathbb{P}\big(F_Z^{-1}(Y) \le z\big) = \mathbb{P}\big(Y \le F_Z(z)\big) = F_Z(z)$، زیرا برای Y یکنواخت $\mathbb{P}(Y \le u) = u$. پس CDF متغیر $F_Z^{-1}(Y)$ دقیقاً F_Z است. □



یعنی توزیع یکنواخت مانند یک «زبان مشترک» است: با ترکیب دو مرحله، هر توزیع پیوسته را می‌توان به هر توزیع دیگری تبدیل کرد: $Z = F_Z^{-1}(F_X(X))$.

۷.۱۲ چگونگی تولید اعداد تصادفی

کامپیوترها معمولاً تنها یک مولد **شبه‌تصادفی** از اعداد یکنواخت در $[0,1)$ دارند (مثلاً بر پایه «مولد هم‌نهشتی خطی» $s_{k+1} = (a\,s_k + c) \bmod m$ و $u_k = s_k/m$، یا الگوریتم‌های پیشرفته‌تری مانند Mersenne Twister). سؤال: چگونه از این اعداد یکنواخت، نمونه‌هایی از توزیع‌های دیگر (نمایی، گاوسی، ...) تولید کنیم؟ پاسخ همان روش تبدیل معکوس است:

الگوریتم نمونه‌برداری با تبدیل معکوس (Inverse Transform Sampling)

۱. یک عدد u از $\mathcal{U}(0,1)$ تولید کنید.

۲. $z = F_Z^{-1}(u)$ را خروجی دهید.

مثال ۱۲-۶: تولید نمونه نمایی

برای $Z \sim \mathrm{Exp}(\lambda)$ داریم $F_Z(z) = 1 - e^{-\lambda z}$. با حل $u = 1 - e^{-\lambda z}$:

$$z = F_Z^{-1}(u) = -\frac{1}{\lambda}\ln(1-u).$$

چون $1-U$ نیز یکنواخت است، می‌توان از $z = -\frac{1}{\lambda}\ln u$ هم استفاده کرد. مثلاً با $\lambda = 2$ و $u = 0.3$: $z = -\frac{1}{2}\ln 0.7 \approx 0.178$.

مثال ۱۲-۷: تولید نمونه گسسته

برای متغیر گسسته (مثلاً تاس)، تبدیل معکوس یعنی: $[0,1)$ را به بازه‌هایی با طول $p_1, p_2, \dots$ تقسیم کنید و اگر u در بازه iام افتاد، مقدار x_i را برگردانید. برای تاس سالم: $x = \lfloor 6u \rfloor + 1$.

نکته. برای گاوسی، F^{-1} شکل بسته ندارد؛ در عمل از روش‌های دیگری مانند **تبدیل باکس–مولر** استفاده می‌شود: اگر U_1, U_2 یکنواخت و مستقل باشند، $Z = \sqrt{-2\ln U_1}\cos(2\pi U_2)$ گاوسی استاندارد است (این نتیجه از تبدیل دو متغیره به دست می‌آید که در جلسات بعد می‌بینیم).

۸.۱۲ تمرین‌های تکمیلی

تمرین ۱۲-۸

اگر $X \sim \mathcal{U}(0,1)$، چگالی $Y = -\ln X$ را بیابید.

حل. $g(x) = -\ln x$ روی $(0,1)$ اکیداً نزولی است و برد آن $(0,\infty)$. $x^* = e^{-y}$ و $|g'(x^*)| = \frac{1}{x^*} = e^{y}$. پس $f_Y(y) = \frac{1}{e^y}\cdot 1 = e^{-y}$ برای $y > 0$؛ یعنی $Y \sim \mathrm{Exp}(1)$ (همان نتیجه روش تبدیل معکوس). ■

تمرین ۱۲-۹

اگر $X \sim \mathcal{N}(0,1)$، چگالی $Y = e^X$ را بیابید (توزیع لاگ‌نرمال).

حل. $x^* = \ln y$ و $g'(x^*) = e^{x^*} = y$. پس برای $y > 0$: $f_Y(y) = \frac{1}{y}\cdot\frac{1}{\sqrt{2\pi}}e^{-(\ln y)^2/2}$ ــ همان لاگ‌نرمال جلسه هفتم با $\mu = 0, \sigma = 1$. ■

تمرین ۱۲-۱۰

اگر $X \sim \mathcal{U}(0,\pi)$، چگالی $Y = \sin X$ را بیابید.

حل. برد: $Y \in [0,1]$. برای $0 < y < 1$ دو ریشه دارد: $x_1 = \arcsin y$ و $x_2 = \pi - \arcsin y$؛ در هر دو $|g'| = |\cos x| = \sqrt{1-y^2}$. پس $f_Y(y) = 2\cdot\frac{1}{\pi}\cdot\frac{1}{\sqrt{1-y^2}} = \frac{2}{\pi\sqrt{1-y^2}}$، $0 < y < 1$. (بررسی: $\int_0^1 \frac{2}{\pi\sqrt{1-y^2}}\,dy = \frac{2}{\pi}\cdot\frac{\pi}{2} = 1$.) ■

تمرین ۱۲-۱۱

یک الگوریتم برای تولید نمونه از توزیعی با چگالی $f(z) = 2z$ روی $[0,1]$ بنویسید.

حل. $F(z) = z^2$، پس $F^{-1}(u) = \sqrt{u}$. الگوریتم: $u \sim \mathcal{U}(0,1)$ تولید کن و $z = \sqrt{u}$ را برگردان. (معادلاً $\max(U_1, U_2)$ برای دو یکنواخت مستقل نیز همین توزیع را دارد، چون $\mathbb{P}(\max \le z) = z^2$.) ■

جلسه ۱۳

توزیع مشترک دو یا چند متغیر تصادفی

۱.۱۳ توزیع مشترک دو متغیر تصادفی (Joint Distributions)

۱.۱.۱۳ انگیزه

دو متغیر تصادفی X و Y با توزیع‌های انباشته F_X و F_Y را در نظر بگیرید:

$$F_X(x) = \mathbb{P}(X \leq x), \qquad F_Y(y) = \mathbb{P}(Y \leq y).$$

در صورتی که در مورد استقلال این دو متغیر تصادفی هیچ فرضی نکنیم، در مورد احتمال وقایعی مانند زیر چه حرفی می‌توان زد؟

$$\mathbb{P}(0 \leq X \leq 2\ ,\ Y > 3)$$

- **در صورت برقرار استقلال آماری میان** X, Y، می‌توان احتمال کل را به صورت ضرب احتمال وقایع نوشت: $\mathbb{P}(0 \leq X \leq 2)\mathbb{P}(Y > 3) = \big(F_X(2) - F_X(0^-)\big)\big(1 - F_Y(3)\big)$.
- **در صورت نبود هیچ فرضی در مورد استقلال دو متغیر تصادفی**، به اطلاعاتی فراتر از توزیع جداگانه آنان نیاز خواهیم داشت. توزیع‌های حاشیه‌ای (جداگانه) فقط رفتار هر متغیر را به تنهایی توصیف می‌کنند و درباره «رابطه» آن‌ها چیزی نمی‌گویند.

مثال ۱۳-۱: حاشیه‌های یکسان، توزیع مشترک متفاوت

فرض کنید X و Y هر دو برنولی با $p = \frac{1}{2}$ باشند. سه سناریو را در نظر بگیرید: (الف) مستقل؛ (ب) $Y = X$؛ (ج) $Y = 1 - X$. در هر سه حالت توزیع‌های حاشیه‌ای یکسان‌اند، اما $\mathbb{P}(X = 1, Y = 1)$ به ترتیب برابر $\frac{1}{4}$، $\frac{1}{2}$ و 0 است. پس دانستن F_X و F_Y برای محاسبه احتمال‌های توأم کافی نیست.

۲.۱.۱۳ تعریف ریاضی

تعریف ۱۳-۲: تابع توزیع انباشته مشترک

برای دو متغیر تصادفی X و Y، تابع $F_{X,Y} : \mathbb{R}^2 \to [0,1]$ را مطابق تعریف زیر تابع توزیع انباشته مشترک (Joint Cumulative Distribution Function) X, Y می‌نامیم:

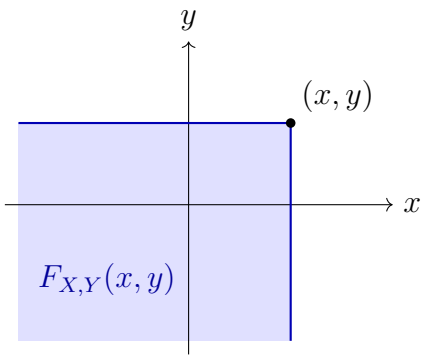
$$F_{X,Y}(x,y) = \mathbb{P}\big(X \leq x \ , \ Y \leq y\big).$$

مشابه با قبل، داریم:

- تابع CDF مشترک در کران‌های منفی برابر با صفر، و در کران مثبت به سمت ۱ میل می‌کند:

$$F_{X,Y}(-\infty, y) = 0 \quad , \quad F_{X,Y}(x, -\infty) = 0 \quad , \quad F_{X,Y}(\infty, \infty) = 1.$$

- تابع CDF مشترک، بر حسب هر دو ورودی x, y به صورت جداگانه صعودی است.



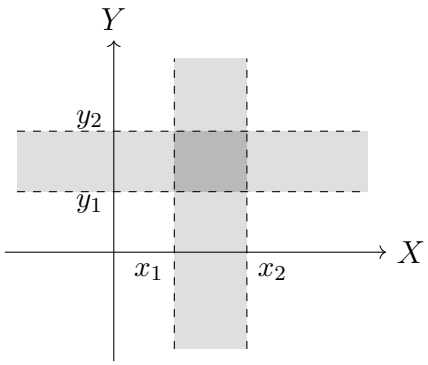
CDF مشترک در نقطه (x,y) برابر جرم احتمال کل ربع صفحه «جنوب‌غربی» این نقطه است.

۳.۱.۱۳ نحوه استفاده

از طریق توزیع انباشته مشترک، می‌توان احتمال هر واقعه‌ای در رابطه با دو متغیر تصادفی را محاسبه نمود. برای مثال (**با استفاده از اصل شمول و عدم شمول!**):

$$\mathbb{P}\big(X > x \ , \ Y > y\big) = 1 - F_{XY}(\infty, y) - F_{XY}(x, \infty) + F_{XY}(x, y).$$

اثبات. متمم رویداد $\{X > x, Y > y\}$ برابر $\{X \leq x\} \cup \{Y \leq y\}$ است. طبق اصل شمول و عدم شمول: $\mathbb{P}(\{X \leq x\} \cup \{Y \leq y\}) = F_{XY}(x, \infty) + F_{XY}(\infty, y) - F_{XY}(x, y)$. با کم کردن از ۱ حکم ثابت می‌شود. □



پرسش: $\mathbb{P}(x_1 \le X \le x_2 \ , \ y_1 \le Y \le y_2) = ?$ و $\mathbb{P}(x_1 \le X \le x_2 \text{ or } y_1 \le Y \le y_2) = ?$

پاسخ. (برای سادگی فرض کنید متغیرها پیوسته‌اند تا مرزها اهمیتی نداشته باشند.)

مستطیل (and): احتمال مستطیل (ناحیه تیره در شکل) با شمول و عدم شمول روی چهار ربع صفحه «جنوب‌غربی» به دست می‌آید:

$$\mathbb{P}(x_1 \le X \le x_2,\ y_1 \le Y \le y_2) = F_{XY}(x_2, y_2) - F_{XY}(x_1, y_2) - F_{XY}(x_2, y_1) + F_{XY}(x_1, y_1)$$

(ربع (x_2, y_2) را برمی‌داریم، ربع‌های سمت چپ مستطیل و زیر مستطیل را کم می‌کنیم، و چون ربع (x_1, y_1) دو بار کم شده، یک بار اضافه می‌کنیم.)

صلیب (or): اجتماع نوار عمودی و نوار افقی (کل ناحیه سایه‌دار):

$$\mathbb{P}(x_1 \le X \le x_2 \text{ or } y_1 \le Y \le y_2) = \big[F_X(x_2) - F_X(x_1)\big] + \big[F_Y(y_2) - F_Y(y_1)\big] - \mathbb{P}(x_1 \le X \le x_2,\ y_1 \le Y \le y_2),$$

که در آن $F_X(x) = F_{XY}(x, \infty)$ و $F_Y(y) = F_{XY}(\infty, y)$ و جمله آخر همان احتمال مستطیل بالاست.

۴.۱.۱۳ توزیع انباشته حاشیه‌ای (Marginal CDF)

پیش‌تر بحث کردیم که **اطلاعات مشترک** دو متغیر تصادفی در **توزیع انباشته جداگانه آنان** موجود نیست، و برای دانستن آن نیاز به داشتن تابعی بسیار بزرگ‌تر و غنی‌تر داریم. اما برعکس گزاره فوق صادق است. یعنی، تابع توزیع انباشته جداگانه هر یک از متغیرهای تصادفی از روی توزیع انباشته مشترک قابل حصول است:

$$F_X(x) = F_{XY}(x, \infty) \quad , \quad F_Y(y) = F_{XY}(\infty, y)$$

(زیرا $\{Y \le \infty\}$ همیشه رخ می‌دهد.)

قضیه ۱۳-۳: استقلال بر حسب CDF

دو متغیر تصادفی از یکدیگر مستقل‌اند اگر و تنها اگر رابطه زیر به ازای تمامی x, yها برقرار باشد:

$$F_{XY}(x, y) = F_X(x) \times F_Y(y).$$

۲.۱۳ تابع چگالی احتمال مشترک (Joint PDF)

تعریف ۱۳-۴: چگالی مشترک

مطابق پیشین، تابع چگالی احتمال مشترک برای دو متغیر تصادفی X, Y را به صورت زیر تعریف می‌کنیم:

$$f_{XY}(x,y) = \frac{\partial^2}{\partial x\,\partial y} F_{XY}(x,y).$$

مفهوم چگالی در حین مشتق‌گیری ظاهر می‌شود:

$$f_{XY}(x,y) = \lim_{h,t\to 0} \frac{\mathbb{P}\big(x \le X \le x+h\ ,\ y \le Y \le y+t\big)}{h\cdot t},$$

یعنی احتمال یک مستطیل کوچک تقسیم بر **مساحت** آن (جرم بر واحد سطح). (این از فرمول مستطیل بالا و تعریف مشتق دوم مخلوط به دست می‌آید.)

به عبارت صریح‌تر، احتمال واقعه عام $(X,Y) \in S \subseteq \mathbb{R}^2$ به صورت زیر محاسبه می‌شود:

$$\mathbb{P}(S) = \iint_{(x,y)\in S} f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y,$$

یعنی **حجم** زیر سطح f_{XY} روی ناحیه S.

۳.۱۳ خواص و حاشیه‌سازی (Marginalization)

- می‌توان دید که **تابع چگالی احتمال مشترک** نامنفی بوده و انتگرال آن بر روی تمامی صفحه $\mathbb{R}^2$ برابر با ۱ است.
- تابع چگالی احتمال حاشیه‌ای برای هر یک از متغیرهای تصادفی به صورت زیر به دست می‌آید:

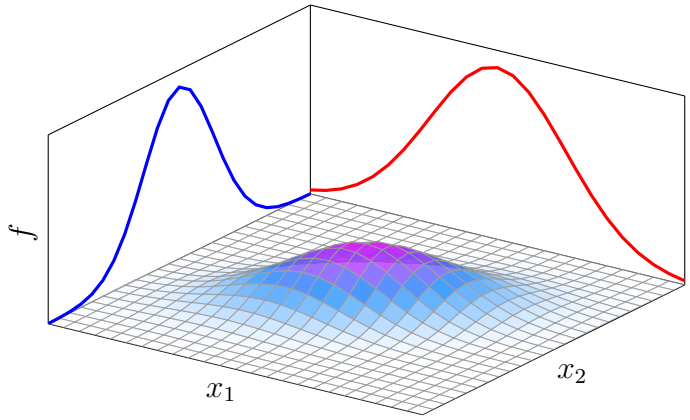
$$\boxed{f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x,y)\,\mathrm{d}y \quad , \quad f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x,y)\,\mathrm{d}x}$$

(این همان قانون احتمال کل در حالت پیوسته است: روی همه مقادیر ممکن متغیر دیگر «جمع» می‌زنیم.)

- دو متغیر تصادفی X, Y مستقل‌اند، اگر و تنها اگر داشته باشیم:

$$f_{XY}(x,y) = f_X(x) f_Y(y).$$

نکته. تصویر هندسی: چگالی مشترک یک «تپه» روی صفحه (x_1,x_2) با حجم کل ۱ است. چگالی حاشیه‌ای f_{X_1} «سایه» یا تصویر این تپه روی محور x_1 است (انتگرال در امتداد x_2)؛ مساحت زیر هر حاشیه ۱ است. اگر تپه را با صفحه $x_2 = b$ برش دهیم، شکل برش (پس از بهنجارسازی) چگالی شرطی $f_{X_1|X_2}(x_1 \mid b)$ است (جلسه بعد). در حالت داده‌ها، ابری از نقاط (x_1,x_2) داریم و هیستوگرام هر مؤلفه به‌تنهایی، حاشیه‌ها را تقریب می‌زند.



یک چگالی مشترک دو متغیره (سطح) و حاشیه‌های آن (منحنی‌های قرمز و آبی روی دیواره‌ها، به صورت نمادین)

مثال ۱۳-۵: چگالی مشترک روی مربع واحد

فرض کنید $f_{XY}(x,y) = x+y$ برای $0 \le x,y \le 1$ و صفر در غیر این صورت. (الف) نشان دهید این یک چگالی معتبر است. (ب) چگالی‌های حاشیه‌ای را بیابید. (ج) آیا X و Y مستقل‌اند؟ (د) $\mathbb{P}(X+Y \le 1)$ را حساب کنید.

حل. (الف) نامنفی است و $\int_0^1\int_0^1 (x+y)\,dx\,dy = \frac{1}{2}+\frac{1}{2} = 1$.

(ب) $f_X(x) = \int_0^1 (x+y)\,dy = x+\frac{1}{2}$ برای $0 \le x \le 1$؛ به طور متقارن $f_Y(y) = y+\frac{1}{2}$.

(ج) $f_X(x)f_Y(y) = (x+\frac{1}{2})(y+\frac{1}{2}) = xy + \frac{x+y}{2} + \frac{1}{4} \neq x+y$ (مثلاً در $(0,0)$: $\frac{1}{4} \neq 0$). پس مستقل نیستند.

(د) ناحیه مثلث $\{x,y \ge 0,\ x+y \le 1\}$ است:

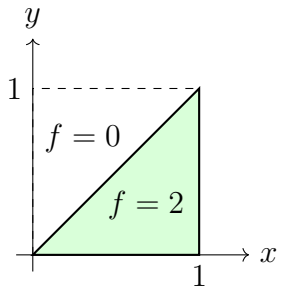
$$\int_0^1 \int_0^{1-x} (x+y)\,dy\,dx = \int_0^1 \left[x(1-x) + \frac{(1-x)^2}{2}\right] dx = \int_0^1 \frac{1-x^2}{2}\,dx = \frac{1}{2}\left(1-\frac{1}{3}\right) = \frac{1}{3}.$$

■

مثال ۱۳-۶: چگالی یکنواخت روی مثلث

(X,Y) به‌طور یکنواخت روی مثلث $0 \le y \le x \le 1$ توزیع شده است. چگالی مشترک و حاشیه‌ها را بیابید.

حل. مساحت مثلث $\frac{1}{2}$ است؛ پس $f_{XY} = 2$ روی مثلث. حاشیه‌ها: $f_X(x) = \int_0^x 2\,dy = 2x$ $(0 \le x \le 1)$ و $f_Y(y) = \int_y^1 2\,dx = 2(1-y)$ $(0 \le y \le 1)$. مستقل نیستند: حاصل‌ضرب $4x(1-y)$ روی کل مربع مثبت است، اما چگالی مشترک در ناحیه $y > x$ صفر است. **قاعده سرانگشتی:** اگر تکیه‌گاه چگالی مشترک «مستطیلی» (ضرب دکارتی) نباشد، متغیرها حتماً وابسته‌اند. ■



مثال ۱۳-۷: دو نمایی مستقل

X, Y مستقل و هر دو $\mathrm{Exp}(1)$ هستند. $\mathbb{P}(X < Y)$ و $\mathbb{P}(X + Y \le 1)$ را حساب کنید.

حل. $f_{XY}(x, y) = e^{-x}e^{-y}$ برای $x, y \ge 0$.

$$\mathbb{P}(X < Y) = \int_0^\infty \int_x^\infty e^{-x}e^{-y}\,\mathrm{d}y\,\mathrm{d}x = \int_0^\infty e^{-2x}\,\mathrm{d}x = \frac{1}{2}$$

(که از تقارن نیز واضح است).

$$\begin{aligned}\mathbb{P}(X + Y \le 1) &= \int_0^1 \int_0^{1-x} e^{-x-y}\,\mathrm{d}y\,\mathrm{d}x = \int_0^1 e^{-x}\left(1 - e^{-(1-x)}\right)\mathrm{d}x \\ &= (1 - e^{-1}) - e^{-1} = 1 - \frac{2}{e} \approx 0.264.\end{aligned}$$

■

۴.۱۳ توزیع مشترک چند متغیر تصادفی

۱.۴.۱۳ تعریف ریاضیاتی

تعریف ۱۳-۸

متغیرهای تصادفی $X_1, X_2, \ldots, X_n$ دارای تابع توزیع انباشته مشترک به صورت زیر خواهند بود:

$$F_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = \mathbb{P}\big(X_1 \le x_1, \ldots, X_n \le x_n\big).$$

متغیرهای تصادفی فوق را (به طور متقابل) مستقل می‌نامیم، اگر و تنها اگر:

$$F_{X_1,\ldots,X_n}(x_1, \ldots, x_n) = \prod_{i=1}^{n} F_{X_i}(x_i).$$

نکته. در اسلاید از عبارت «دو به دو مستقل» استفاده شده است؛ اما دقت کنید که شرط ضربی بالا برای **همه** n متغیر با هم، در واقع **استقلال متقابل** را تعریف می‌کند که از استقلال دوبه‌دو قوی‌تر است (مثال جلسه سوم را به یاد آورید). با قرار دادن $x_j = \infty$ برای برخی اندیس‌ها، از این شرط استقلال هر زیرمجموعه (از جمله هر دو تا) نتیجه می‌شود.

۲.۴.۱۳ تابع چگالی احتمال مشترک: تعریف و حاشیه‌سازی

برای متغیرهای تصادفی $X_1, X_2, \dots, X_n$ تابع چگالی احتمال مشترک به صورت زیر تعریف می‌شود:

$$f_{X_1,\dots,X_n}(x_1,\dots,x_n) = \frac{\partial^n}{\partial x_1 \cdots \partial x_n} F_{X_1,\dots,X_n}(x_1,\dots,x_n).$$

برای متغیرهای تصادفی منتخب $X_{\eta_1},\dots,X_{\eta_m} \subset \{X_1,\dots,X_n\}$ داریم:

$$f_{X_{\eta_1},\dots,X_{\eta_m}} = \int_{\mathbb{R}} \cdots \int_{\mathbb{R}} f_{X_1,\dots,X_n}(x_1,\dots,x_n) \prod_{i \notin \{\eta_1,\dots,\eta_m\}} \mathrm{d}x_i,$$

یعنی بر روی تمامی اندیس‌هایی که در بین $\eta_1,\dots,\eta_m$ نیستند باید انتگرال گرفت.

مثال ۱۳-۹: حاشیه‌سازی سه متغیره

$f(x,y,z) = 6$ روی ناحیه $0 \le x \le y \le z \le 1$ (و صفر در جای دیگر). چگالی حاشیه‌ای (X,Z) و چگالی Z را بیابید.

حل. حجم ناحیه $\frac{1}{6}$ است (یکی از $3!$ ترتیب ممکن)، پس چگالی ثابت ۶ درست است. $f_{XZ}(x,z) = \int_x^z 6\,\mathrm{d}y = 6(z-x)$ برای $0 \le x \le z \le 1$. $f_Z(z) = \int_0^z 6(z-x)\,\mathrm{d}x = 3z^2$ برای $0 \le z \le 1$. (بررسی: $\int_0^1 3z^2 = 1$.) جالب است که این همان توزیع ماکزیمم سه یکنواخت مستقل است ــ و در واقع (X,Y,Z) در اینجا همان «آماره‌های مرتب» سه یکنواخت مستقل است. ■

۵.۱۳ تمرین‌های تکمیلی

تمرین ۱۳-۱۰

$F_{XY}(x,y) = (1-e^{-x})(1-e^{-2y})$ برای $x,y \ge 0$. آیا X,Y مستقل‌اند؟ و $\mathbb{P}(X>1,Y>1)$ و f_{XY} را بیابید.

حل. CDF به صورت حاصل‌ضرب $F_X(x)F_Y(y)$ با $F_X = 1-e^{-x}$ و $F_Y = 1-e^{-2y}$ است؛ پس مستقل‌اند ($X \sim \mathrm{Exp}(1)$ و $Y \sim \mathrm{Exp}(2)$). $f_{XY} = \frac{\partial^2 F}{\partial x \partial y} = e^{-x}\cdot 2e^{-2y}$. $\mathbb{P}(X>1,Y>1) = 1 - F(\infty,1) - F(1,\infty) + F(1,1) = e^{-1}e^{-2} = e^{-3} \approx 0.0498$. ■

تمرین ۱۳-۱۱

نقطه‌ای به‌طور یکنواخت درون دایره واحد انتخاب می‌شود. چگالی حاشیه‌ای مختص X را بیابید. آیا X و Y مستقل‌اند؟

حل. $f_{XY} = \frac{1}{\pi}$ داخل دایره. $f_X(x) = \int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi}\,\mathrm{d}y = \frac{2}{\pi}\sqrt{1-x^2}$ برای $|x| \le 1$ (نیم‌دایره). مستقل نیستند: تکیه‌گاه مستطیلی نیست؛ مثلاً $f_{XY}(0.9,0.9) = 0$ ولی $f_X(0.9)f_Y(0.9) > 0$. ■

تمرین ۱۳-۱۲

برای متغیرهای گسسته، PMF مشترک $P(x,y) = c(x+y)$ با $x, y \in \{1,2\}$ است. c، حاشیه‌ها و $\mathbb{P}(X=Y)$ را بیابید.

حل. $\sum = c(2+3+3+4) = 12c = 1 \Rightarrow c = \frac{1}{12}$. $P_X(1) = \frac{2+3}{12} = \frac{5}{12}$ و $P_X(2) = \frac{7}{12}$ (برای Y نیز همین). $\mathbb{P}(X=Y) = \frac{2+4}{12} = \frac{1}{2}$. مستقل نیستند: $P(1,1) = \frac{2}{12} \neq \frac{25}{144}$. ■

جلسه ۱۴

چگالی شرطی، میانگین شرطی و متغیرهای مشترکاً گاوسی

۱.۱۴ یادآوری: توزیع مشترک چند متغیر تصادفی

متغیرهای تصادفی $X_1, \dots, X_n$ دارای تابع توزیع انباشته مشترک $F_{X_1,\dots,X_n}(x_1,\dots,x_n) = \mathbb{P}(X_1 \le x_1, \dots, X_n \le x_n)$ هستند و مستقل نامیده می‌شوند اگر و تنها اگر $F_{X_1,\dots,X_n} = \prod_i F_{X_i}(x_i)$. تابع چگالی مشترک $f_{X_1,\dots,X_n} = \frac{\partial^n}{\partial x_1 \cdots \partial x_n} F_{X_1,\dots,X_n}$ است و برای به دست آوردن چگالی هر زیرمجموعه از متغیرها، بر روی تمامی اندیس‌هایی که در آن زیرمجموعه نیستند انتگرال می‌گیریم (حاشیه‌سازی).

۲.۱۴ نکته جانبی: توابعی از متغیرهای مستقل

قضیه ۱۴-۱

به ازای هر دو تابعی مانند g, h، و در صورتی که متغیرهای تصادفی X, Y **مستقل** باشند، متغیرهای تصادفی $h(X)$ و $g(Y)$ هم **مستقل**اند.

اثبات. برای مجموعه‌های دلخواه A, B:

$$\mathbb{P}\big(h(X) \in A,\ g(Y) \in B\big) = \mathbb{P}\big(X \in h^{-1}(A),\ Y \in g^{-1}(B)\big) = \mathbb{P}\big(X \in h^{-1}(A)\big)\mathbb{P}\big(Y \in g^{-1}(B)\big),$$

که برابر $\mathbb{P}(h(X) \in A)\mathbb{P}(g(Y) \in B)$ است. (در اینجا $h^{-1}(A) = \{x : h(x) \in A\}$ پیش‌نگاره است و از تعریف استقلال X, Y برای مجموعه‌های پیش‌نگاره استفاده کردیم.) □

مثال: اگر X, Y مستقل باشند، X^2 و e^Y نیز مستقل‌اند. (ما از این نتیجه در جلسه دهم استفاده کردیم: $X - \mu_X$ و $Y - \mu_Y$ مستقل‌اند.)

۳.۱۴ توابع چگالی احتمال شرطی و قانون بیز (Bayes' Rule)

۱.۳.۱۴ تابع چگالی احتمال شرطی

تعریف ۱۴-۲: چگالی و توزیع شرطی

مشابه با حالت گسسته، توابع توزیع انباشته و چگالی احتمال شرطی برای دو متغیر تصادفی X, Y را به صورت زیر تعریف می‌کنیم:

$$F_{X|Y}(x \,|\, y) = \mathbb{P}(X \le x \,|\, Y = y), \qquad f_{X|Y}(x \,|\, y) = \frac{f_{XY}(x,y)}{f_Y(y)} \quad (f_Y(y) > 0).$$

دقت کنید که همواره داریم:

$$f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x,y)\,\mathrm{d}x.$$

نکته. برای متغیر پیوسته $\mathbb{P}(Y = y) = 0$؛ پس تعریف احتمال شرطی جلسه چهارم مستقیماً قابل استفاده نیست. تعریف بالا در واقع حد $\mathbb{P}(X \le x \,|\, y \le Y \le y + \varepsilon)$ وقتی $\varepsilon \to 0$ است. **تعبیر هندسی:** $f_{X|Y}(\cdot \,|\, y)$ برشی از سطح f_{XY} در امتداد خط $Y = y$ است که برای بهنجار شدن (مساحت ۱) بر مساحت آن برش، یعنی $f_Y(y)$، تقسیم شده است. به ازای هر y ثابت، $f_{X|Y}(\cdot \,|\, y)$ یک چگالی معتبر بر حسب x است.

۲.۳.۱۴ قانون بیز و قانون زنجیره‌ای

قضیه ۱۴-۳: قانون بیز برای چگالی‌ها

قانون بیز (Bayes' rule) نیز مشابه با قبل برقرار خواهد بود:

$$f_{X|Y}(x \,|\, y) = \frac{f_{Y|X}(y \,|\, x)\, f_X(x)}{f_Y(y)}, \qquad f_Y(y) = \int f_{Y|X}(y \,|\, x) f_X(x)\,\mathrm{d}x.$$

قضیه ۱۴-۴: قانون زنجیره‌ای

دقت کنید که همواره داریم:

$$f_{X_1,\dots,X_n}(x_1,\dots,x_n) = f_{X_1}(x_1) \cdot f_{X_2|X_1}(x_2 \,|\, x_1) \cdot f_{X_3|X_2,X_1}(x_3 \,|\, x_2, x_1) \cdots$$

(اثبات هر دو، مانند حالت رویدادها، مستقیماً از تعریف چگالی شرطی به دست می‌آید.) مثال سکه با احتمال نامعلوم در جلسه نهم، دقیقاً کاربرد قانون بیز در حالت مخلوط (پیوسته–گسسته) بود.

مثال ۱۴-۵: چگالی شرطی روی مثلث

در مثال جلسه قبل، (X, Y) یکنواخت روی مثلث $0 \le y \le x \le 1$ بود ($f_{XY} = 2$، $f_X(x) = 2x$، $f_Y(y) = 2(1-y)$). $f_{Y|X}(y \,|\, x)$ و $f_{X|Y}(x \,|\, y)$ را بیابید.

حل.

$$f_{Y|X}(y\,|\,x)=\frac{2}{2x}=\frac{1}{x},\quad 0\le y\le x;\qquad f_{X|Y}(x\,|\,y)=\frac{2}{2(1-y)}=\frac{1}{1-y},\quad y\le x\le 1.$$

یعنی به شرط $X=x$، Y یکنواخت روی $[0,x]$ است و به شرط $Y=y$، X یکنواخت روی $[y,1]$ است. (برش یک چگالی ثابت، یکنواخت است.) ■

۴.۱۴ میانگین‌گیری و میانگین‌های شرطی

۱.۴.۱۴ میانگین

میانگین هر یک از متغیرهای تصادفی X,Y مشابه با قبل محاسبه می‌شود:

$$\mathbb{E}(X)=\int_{\mathbb{R}} x f_X(x)\,\mathrm{d}x=\iint_{\mathbb{R}^2} x f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

همچنین میانگین، کماکان خاصیت خطی خود را حفظ خواهد کرد:

$$\mathbb{E}(X+Y)=\iint_{\mathbb{R}^2}(x+y)f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y=\mathbb{E}(X)+\mathbb{E}(Y).$$

(با شکستن انتگرال به دو قسمت و حاشیه‌سازی در هر قسمت.)

۲.۴.۱۴ میانگین شرطی (Conditional Expectation)

تعریف ۱۴-۶: میانگین شرطی

میانگین شرطی متغیر تصادفی X به شرط Y به صورت زیر تعریف می‌شود:

$$\mathbb{E}(X\,|\,Y)=\int_{\mathbb{R}} x f_{X|Y}(x\,|\,Y)\,\mathrm{d}x.$$

- مقدار میانگین $\mathbb{E}(X)$ یک عدد ثابت و یقینی، اما $\mathbb{E}(X\,|\,Y)$ در حالت کلی یک **متغیر تصادفی** است (چون همه چیز کماکان به Y بستگی دارد). دقیق‌تر: ابتدا برای هر عدد y تابع $\psi(y)=\mathbb{E}(X\,|\,Y=y)$ را حساب می‌کنیم؛ سپس $\mathbb{E}(X\,|\,Y)=\psi(Y)$ تابعی از متغیر تصادفی Y است.

قضیه ۱۴-۷: قانون میانگین کل (Law of Total Expectation)

$$\boxed{\mathbb{E}\big(\mathbb{E}(X\,|\,Y)\big)=\mathbb{E}(X)}$$

اثبات.

$$\mathbb{E}\big(\mathbb{E}(X\,|\,Y)\big)=\int\Big(\int x f_{X|Y}(x\,|\,y)\,\mathrm{d}x\Big)f_Y(y)\,\mathrm{d}y=\iint x f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y=\mathbb{E}(X).$$

(از $f_{X|Y}(x\,|\,y)f_Y(y) = f_{XY}(x,y)$ استفاده شد.) □

این رابطه نسخه «میانگینی» قانون احتمال کل است: برای محاسبه میانگین، ابتدا به ازای هر حالت ممکن Y میانگین را حساب کنید، سپس روی حالت‌ها وزن‌دار میانگین بگیرید. در حالت گسسته: $\mathbb{E}X = \sum_y \mathbb{E}(X\,|\,Y=y)\mathbb{P}(Y=y)$.

مثال ۱۴-۸: تعداد کل مشتری‌ها ــ جمع تصادفی

تعداد مشتریانی که در یک روز وارد فروشگاه می‌شوند $N \sim \text{Pois}(50)$ است و هر مشتری مستقلاً به طور متوسط ۲۰ هزار تومان خرید می‌کند. میانگین فروش روزانه چقدر است؟

حل. فروش کل $S = \sum_{i=1}^{N} X_i$ است. به شرط $N=n$، $\mathbb{E}(S\,|\,N=n) = 20n$؛ پس $\mathbb{E}(S\,|\,N) = 20N$ و $\mathbb{E}(S) = \mathbb{E}(\mathbb{E}(S\,|\,N)) = 20\mathbb{E}(N) = 1000$ هزار تومان. (توجه: N خودش تصادفی است و نمی‌توان مستقیماً از خاصیت خطی با تعداد ثابت جمله استفاده کرد.) ■

مثال ۱۴-۹: چوب شکسته

چوبی به طول ۱ را در نقطه تصادفی یکنواخت U می‌شکنیم و تکه چپ (به طول U) را دوباره در نقطه‌ای یکنواخت می‌شکنیم. میانگین طول تکه چپِ نهایی چقدر است؟

حل. اگر X طول نهایی باشد، به شرط $U=u$، $X \sim \mathcal{U}(0,u)$ و $\mathbb{E}(X\,|\,U) = \frac{U}{2}$. پس $\mathbb{E}X = \mathbb{E}\left(\frac{U}{2}\right) = \frac{1}{4}$. ■

۵.۱۴ متغیرهای تصادفی مشترکاً گاوسی (Jointly Gaussian R.V.s)

۱.۵.۱۴ تعریف

دو متغیر تصادفی گاوسی $X \sim \mathcal{N}(\mu, \sigma^2)$ و $Y \sim \mathcal{N}(\mu', \sigma'^2)$ را در نظر بگیرید. می‌دانیم که توزیع مشترک این دو متغیر تصادفی می‌تواند بسیاری توابع مختلف باشد... (مثلاً اگر مستقل باشند، $f_X f_Y$؛ اگر $Y = X$ باشند، تمام جرم روی یک خط است؛ و حالت‌های عجیب‌تر دیگر.)

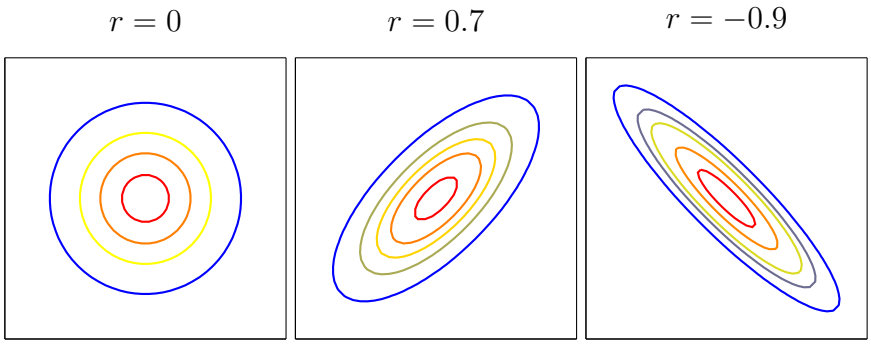
تعریف ۱۴-۱۰: توزیع مشترکاً بهنجار

می‌گوییم دو متغیر تصادفی فوق مشترکاً گاوسی با ضریب همبستگی (Correlation Coefficient) r (به شرط $|r| < 1$) هستند، اگر:

$$f_{X,Y}(x,y) = A\exp\left[\frac{-1}{2(1-r^2)}\left(\frac{(x-\mu)^2}{\sigma^2} + \frac{(y-\mu')^2}{\sigma'^2} - 2r\frac{(x-\mu)(y-\mu')}{\sigma\sigma'}\right)\right].$$

برای شرط بهنجارش باید داشته باشیم:

$$A = \frac{1}{2\pi\sigma\sigma'\sqrt{1-r^2}}.$$



منحنی‌های تراز چگالی مشترکاً گاوسی (با $\mu = \mu' = 0$ و $\sigma = \sigma' = 1$): بیضی‌هایی که با افزایش $|r|$ کشیده‌تر می‌شوند؛ $r > 0$ یعنی گرایش به هم‌جهتی و $r < 0$ یعنی خلاف‌جهتی.

نکته. بررسی ثابت بهنجارش: با استانداردسازی $u = \frac{x-\mu}{\sigma}$ و $v = \frac{y-\mu'}{\sigma'}$ ($\mathrm{d}x\,\mathrm{d}y = \sigma\sigma'\,\mathrm{d}u\,\mathrm{d}v$) و تکمیل مربع $u^2 - 2ruv + v^2 = (u - rv)^2 + (1 - r^2)v^2$:

$$\iint e^{-\frac{(u-rv)^2+(1-r^2)v^2}{2(1-r^2)}}\,\mathrm{d}u\,\mathrm{d}v = \int e^{-v^2/2}\Big(\int e^{-\frac{(u-rv)^2}{2(1-r^2)}}\,\mathrm{d}u\Big)\,\mathrm{d}v = \sqrt{2\pi}\cdot\sqrt{2\pi(1-r^2)}.$$

پس انتگرال کل $\sigma\sigma' \cdot 2\pi\sqrt{1-r^2}$ است و A باید عکس آن باشد. ✓

۲.۵.۱۴ خواص

متغیرهای تصادفی X, Y در صورتی که مشترکاً نرمال باشند، ویژگی‌های بسیار زیادی خواهند داشت:

قضیه ۱۴-۱۱: خواص توزیع مشترکاً گاوسی

۱. توزیع‌های حاشیه‌ای f_X و f_Y هر کدام گاوسی با میانگین‌ها و واریانس‌های به ترتیب (μ, σ^2) و (μ', σ'^2) خواهند بود.

۲. در صورتی که $r = 0$ باشد، متغیرهای تصادفی X, Y از یکدیگر **مستقل** خواهند بود.

۳. توزیع شرطی $f_{X|Y}(x \mid y)$ نیز گاوسی است:

$$\boxed{X \mid Y = y \;\sim\; \mathcal{N}\Big(\mu + \frac{\sigma}{\sigma'}r(y-\mu'),\; (1-r^2)\sigma^2\Big)}$$

۴. به ازای هر مقدار $a, b \in \mathbb{R}$، توزیع $aX + bY$ همواره گاوسی است.

۵. به ازای $a, b, c, d \in \mathbb{R}$، دو متغیر $aX + bY$ و $cX + dY$ مشترکاً گاوسی هستند.

اثبات. با نمادگذاری استاندارد u, v بالا و تکمیل مربع:

$$f_{XY}(x,y) = \underbrace{\frac{1}{\sqrt{2\pi}\sigma'}e^{-v^2/2}}_{f_Y(y)} \cdot \underbrace{\frac{1}{\sqrt{2\pi(1-r^2)}\,\sigma}\exp\Big(-\frac{(u-rv)^2}{2(1-r^2)}\Big)}_{f_{X|Y}(x\,|\,y)}.$$

(۱) با انتگرال‌گیری روی x، عامل دوم (که یک چگالی گاوسی بر حسب x است) انتگرال ۱ دارد و f_Y باقی می‌ماند که $\mathcal{N}(\mu', \sigma'^2)$ است. به‌طور متقارن f_X نیز گاوسی است. (۳) عامل دوم، بر حسب x، گاوسی است با u-مرکز

rv؛ یعنی $\frac{x-\mu}{\sigma}$ حول $r\frac{y-\mu'}{\sigma'}$ با واریانس $1-r^2$ پخش شده است. با برگرداندن به x: میانگین $\mu+\frac{\sigma}{\sigma'}r(y-\mu')$ و واریانس $(1-r^2)\sigma^2$. (۲) با $r=0$، چگالی شرطی همان $\mathcal{N}(\mu,\sigma^2)=f_X$ می‌شود؛ پس $f_{XY}=f_Xf_Y$. (۴) و (۵) را با ابزار تبدیل دو متغیره یا تابع مشخصه (جلسات بعد) می‌توان ثابت کرد. □

نکته. (در اسلاید واریانس شرطی به صورت $(1-r^2)\sigma$ نوشته شده که با نماد $\mathcal{N}(\mu,\sigma)$ اسلاید ــ یعنی پارامتر دوم به عنوان «پراکندگی» ــ آمده است؛ در قالب استاندارد (واریانس, میانگین)$\mathcal{N}$ مقدار درست $(1-r^2)\sigma^2$ است.)
تعبیر: میانگین شرطی $\mathbb{E}(X\,|\,Y=y)$ یک تابع **خطی** از y است (خط رگرسیون)؛ و دانستن Y واریانس X را با ضریب $(1-r^2)$ کاهش می‌دهد ــ هرچه $|r|$ بزرگ‌تر، Y اطلاعات بیشتری درباره X دارد. در حالت $|r|\to 1$، X تقریباً تابع خطی قطعی از Y می‌شود.

دقت کنید! بند (۲) ویژگی خاص توزیع **مشترکاً** گاوسی است: در حالت کلی، $r=0$ (ناهمبستگی) استقلال را نتیجه نمی‌دهد. همچنین «هر دو حاشیه گاوسی باشند» برای مشترکاً گاوسی بودن کافی نیست. مثال: $X\sim\mathcal{N}(0,1)$ و $Y=SX$ که $S=\pm1$ با احتمال برابر و مستقل از X است. Y نیز $\mathcal{N}(0,1)$ است، اما $X+Y$ با احتمال $\frac{1}{2}$ دقیقاً صفر است ــ پس $X+Y$ گاوسی نیست و (X,Y) مشترکاً گاوسی نیستند.

پرسش: میانگین و واریانس $aX+bY$ چقدر است؟

پاسخ. طبق خاصیت خطی، $\mathbb{E}(aX+bY)=a\mu+b\mu'$. برای واریانس:

$$\operatorname{Var}(aX+bY)=a^2\operatorname{Var}X+b^2\operatorname{Var}Y+2ab\,\mathbb{E}\big[(X-\mu)(Y-\mu')\big].$$

برای توزیع مشترکاً گاوسی، با قانون میانگین کل و میانگین شرطی بالا:

$$\mathbb{E}[(X-\mu)(Y-\mu')]=\mathbb{E}\Big[(Y-\mu')\,\mathbb{E}(X-\mu\,|\,Y)\Big]=\mathbb{E}\Big[(Y-\mu')\frac{\sigma}{\sigma'}r(Y-\mu')\Big]=r\sigma\sigma'.$$

پس

$$\boxed{aX+bY\sim\mathcal{N}\big(a\mu+b\mu',\ a^2\sigma^2+b^2\sigma'^2+2abr\sigma\sigma'\big)}$$

(جمله $r\sigma\sigma'$ همان «کوواریانس» است که در جلسه بعد تعریف می‌شود؛ از این‌رو r را ضریب همبستگی می‌نامند.) برای $r=0$ به نتیجه آشنای جمع واریانس‌ها برای متغیرهای مستقل می‌رسیم.

مثال ۱۴-۱۲: قد پدر و پسر

قد پدر X و قد پسر Y (سانتی‌متر) مشترکاً گاوسی‌اند با $\mu=\mu'=175$، $\sigma=\sigma'=7$ و $r=0.5$. اگر قد پدری ۱۸۹ باشد، توزیع قد پسرش چیست؟ احتمال اینکه پسر بلندتر از ۱۸۹ باشد چقدر است؟
حل. با فرمول شرطی (جای X,Y عوض شده): $Y\,|\,X=189\sim\mathcal{N}\big(175+0.5\times(189-175),\ (1-0.25)\times49\big)=\mathcal{N}(182,\ 36.75)$. یعنی انحراف معیار حدود 6.06. $\mathbb{P}(Y>189\,|\,X=189)=1-\Phi\big(\frac{189-182}{6.06}\big)=1-\Phi(1.155)\approx0.124$. پسر **«بازگشت به میانگین»** (regression to the mean): یک پدر بسیار بلند، به طور متوسط بلند است اما نه به اندازه پدر ــ همین پدیده بود که واژه «رگرسیون» را به وجود آورد (گالتون). ■

۶.۱۴ تمرین‌های تکمیلی

تمرین ۱۴-۱۳

$f_{XY}(x,y) = e^{-y}$ برای $0 < x < y$. (الف) f_X و f_Y را بیابید. (ب) $f_{X|Y}(x\,|\,y)$ و $\mathbb{E}(X\,|\,Y)$ را بیابید. (ج) با قانون میانگین کل، $\mathbb{E}X$ را حساب کنید.

حل. (الف) $f_X(x) = \int_x^\infty e^{-y}\,\mathrm{d}y = e^{-x}$ $(x > 0)$، یعنی $X \sim \mathrm{Exp}(1)$. $f_Y(y) = \int_0^y e^{-y}\,\mathrm{d}x = ye^{-y}$ $(y > 0)$ ــ ارلانگ با $k = 2$. (ب) یکنواخت روی $(0,y)$: پس $f_{X|Y}(x\,|\,y) = \frac{e^{-y}}{ye^{-y}} = \frac{1}{y}$ برای $0 < x < y$. $\mathbb{E}(X\,|\,Y) = \frac{Y}{2}$. (ج) $\mathbb{E}X = \mathbb{E}\frac{Y}{2} = \frac{1}{2}\int_0^\infty y^2 e^{-y}\,\mathrm{d}y = \frac{1}{2}\cdot 2 = 1$، که با $X \sim \mathrm{Exp}(1)$ سازگار است. ■

تمرین ۱۴-۱۴

X, Y مشترکاً گاوسی با $\mu = \mu' = 0$، $\sigma = 1$، $\sigma' = 2$ و $r = -0.5$. توزیع $Z = 2X + Y$ و $\mathbb{P}(Z > 2)$ را بیابید.

حل. $\mathbb{E}Z = 0$. $\mathrm{Var}\,Z = 4\cdot 1 + 1\cdot 4 + 2\cdot 2\cdot 1\cdot(-0.5)\cdot 1\cdot 2 = 4 + 4 - 4 = 4$. پس $Z \sim \mathcal{N}(0,4)$ و $\mathbb{P}(Z > 2) = 1 - \Phi(1) \approx 0.159$. ■

تمرین ۱۴-۱۵

یک سکه با احتمال شیر $P \sim \mathcal{U}(0,1)$ داریم (مانند جلسه نهم). احتمال اینکه پرتاب اول شیر بیاید، و احتمال اینکه دو پرتاب اول هر دو شیر بیایند، چقدر است؟ آیا دو پرتاب مستقل‌اند؟

حل. $\mathbb{P}(H_1) = \mathbb{E}\big(\mathbb{P}(H_1\,|\,P)\big) = \mathbb{E}P = \frac{1}{2}$. $\mathbb{P}(H_1H_2) = \mathbb{E}(P^2) = \frac{1}{3}$. چون $\frac{1}{3} \neq \frac{1}{4}$، دو پرتاب مستقل نیستند (هرچند به شرط P مستقل‌اند) ــ همان پدیده استقلال شرطی جلسه پنجم. $\mathbb{P}(H_2\,|\,H_1) = \frac{1/3}{1/2} = \frac{2}{3}$. ■

جلسه ۱۵

توزیع‌های مشترک تکین، گشتاورهای مشترک، کوواریانس و همبستگی

۱.۱۵ ادامه بحث متغیرهای مشترکاً گاوسی

در جلسه قبل دیدیم که دو متغیر $X \sim \mathcal{N}(\mu, \sigma^2)$ و $Y \sim \mathcal{N}(\mu', \sigma'^2)$ را مشترکاً گاوسی با ضریب همبستگی r می‌نامیم اگر

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma\sigma'\sqrt{1-r^2}} \exp\left[\frac{-1}{2(1-r^2)}\left(\frac{(x-\mu)^2}{\sigma^2} + \frac{(y-\mu')^2}{\sigma'^2} - 2r\frac{(x-\mu)(y-\mu')}{\sigma\sigma'}\right)\right],$$

و دیدیم که حاشیه‌ها گاوسی‌اند، $r=0$ استقلال را نتیجه می‌دهد، و توزیع شرطی نیز گاوسی است (اثبات در خانه ــ که در جلسه قبل با تکمیل مربع انجام دادیم):

$$X \,|\, Y = y \;\sim\; \mathcal{N}\Big(\mu + \frac{\sigma}{\sigma'} r(y-\mu'),\; (1-r^2)\sigma^2\Big).$$

۱.۱.۱۵ حالت حدی $|r| = 1$

در صورتی که ضریب همبستگی خاصیت $|r|=1$ را دارا باشد، واریانس شرطی $(1-r^2)\sigma^2$ صفر می‌شود؛ یعنی در صورت دانستن یکی از متغیرهای تصادفی X, Y، مقدار دیگری به صورت **یقینی** مشخص خواهد شد:

$$\boxed{X = \mu \pm \frac{\sigma}{\sigma'}(y-\mu')}$$

(علامت $+$ برای $r=1$ و علامت $-$ برای $r=-1$.) در صورتی که X, Y هم‌توزیع می‌بودند (یعنی میانگین و واریانس یکسان می‌داشتند)، ضریب همبستگی ۱ به معنی $X = Y$ می‌شد.

> **نکته.** در این حالت فرمول چگالی مشترک (که $\sqrt{1-r^2}$ در مخرج دارد) معنا ندارد: کل جرم احتمال روی یک خط در صفحه متمرکز است و چگالی دوبعدی معمولی وجود ندارد. برای توصیف چنین توزیع‌هایی به ابزار بخش بعد ــ «توزیع‌های تکین» ــ نیاز داریم.

۲.۱.۱۵ ترکیب‌های خطی

متغیرهای تصادفی X, Y در صورتی که مشترکاً نرمال باشند:

- به ازای هر مقدار $a, b \in \mathbb{R}$، توزیع $aX + bY$ همواره گاوسی است با میانگین $a\mu + b\mu'$ و واریانس $a^2\sigma^2 + b^2\sigma'^2 + 2ab r\sigma\sigma'$ (پاسخ پرسش جلسه قبل؛ پایین‌تر با مفهوم کوواریانس دوباره به آن می‌رسیم).
- به ازای $a, b, c, d \in \mathbb{R}$، دو متغیر $aX + bY$ و $cX + dY$ مشترکاً گاوسی هستند.

۲.۱۵ توزیع‌های مشترک ترکیبی (تکینگی‌های خطی و نقطه‌ای)

۱.۲.۱۵ توزیع‌های مشترک جرمی

فرض کنید که متغیرهای تصادفی X, Y هر دو ماهیت گسسته داشته باشند و $\mathrm{supp}(X) = \{x_1, x_2, \ldots\}$ و $\mathrm{supp}(Y) = \{y_1, y_2, \ldots\}$. در این صورت، خواهیم داشت:

$$\boxed{f_{XY}(x,y) = \sum_{x_i, y_j} \mathbb{P}(X = x_i, Y = y_j)\, \delta(x - x_i,\ y - y_j)}$$

در اینجا $\delta(x, y)$ نشانگر **تابع دلتای دیراک دومتغیره** است. تابع $\delta(x, y)$ فقط در نقطه $(0, 0)$ غیرصفر بوده و داریم:

$$\iint_{S \subseteq \mathbb{R}^2} \delta(x, y)\, \mathrm{d}x\, \mathrm{d}y = \mathbf{1}_{(0,0) \in S}.$$

(می‌توان نوشت $\delta(x, y) = \delta(x)\delta(y)$.)

توزیع حاشیه‌ای

دقت کنید که داریم:

$$\int_{-\infty}^{+\infty} \delta(x, y)\, \mathrm{d}y = \delta(x).$$

در نتیجه توزیع‌های حاشیه‌ای به صورت زیر درخواهند آمد:

$$\begin{aligned} f_X(x) &= \int_{\mathbb{R}} f_{XY}(x, y)\, \mathrm{d}y = \sum_{x_i, y_j} \mathbb{P}(X = x_i, Y = y_j) \int_{\mathbb{R}} \delta(x - x_i, y - y_j)\, \mathrm{d}y \\ &= \sum_{x_i} \mathbb{P}(X = x_i)\, \delta(x - x_i), \end{aligned}$$

که در آخرین تساوی، جملات با x_i یکسان را با هم جمع کرده‌ایم ($\sum_j \mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)$). این همان PDF متغیر گسسته X است که در جلسه هشتم دیدیم.

۲.۲.۱۵ توزیع‌های مشترک خطی

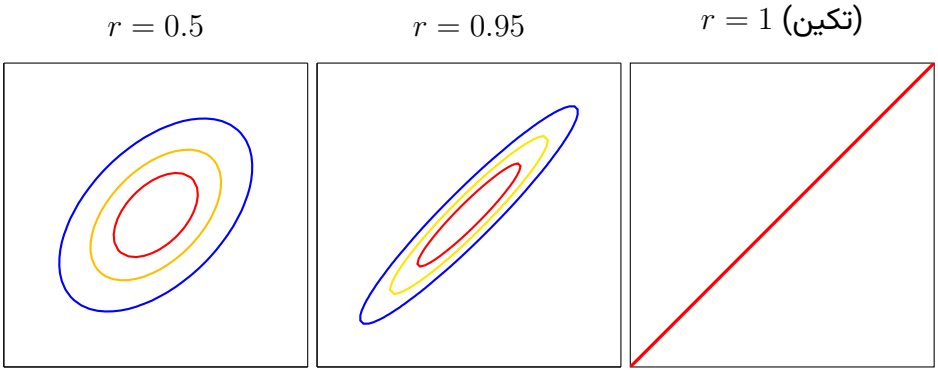
تعریف ۱۵-۱: توزیع مشترک خطی

فرض کنید که متغیر تصادفی X دارای توزیعی دلخواه با چگالی احتمال $f_X(x)$ و متغیر تصادفی Y با اعمال یک تابع یقینی مانند g بر X حاصل شود؛ یعنی داشته باشیم $Y = g(X)$. در این صورت، تابع توزیع مشترک X, Y به صورت زیر در خواهد آمد:

$$\boxed{f_{XY}(x,y) = f_X(x)\,\delta\big(y - g(x)\big)}$$

توجیه. با قانون زنجیره‌ای $f_{XY}(x,y) = f_X(x) f_{Y|X}(y\,|\,x)$. به شرط $X = x$، متغیر Y به‌طور قطعی برابر $g(x)$ است؛ پس توزیع شرطی آن یک ضربه در $g(x)$ است: $f_{Y|X}(y\,|\,x) = \delta(y - g(x))$. □

تصویر شهودی: یک چگالی مشترک معمولی (مثلاً گاوسی دو متغیره با $|r|$ نزدیک ۱) را در نظر بگیرید. وقتی $|r| \to 1$، عرض توزیع (در جهت عمود بر خم) به سمت صفر میل کرده و توزیع حول خم $y = g(x)$ **تکین** خواهد شد: یک «دیوار» بی‌نهایت نازک و بی‌نهایت بلند روی خم، با حجم کل ۱.



۳.۲.۱۵ مرتبه تکینگی (Singularity Level)

- در مورد توزیع‌های مشترک **خطی**، و بر خلاف توزیع‌های مشترک جرمی، تکینگی تابع pdf تنها **یک مرتبه** (یعنی از مرتبه $\delta(\cdot)$) است:
$$f_{XY}(x,y) = f_X(x)\,\delta\big(y - g(x)\big).$$
جرم روی یک **خم** (یک‌بعدی) پخش شده است.
- یادآوری: تکینگی تابع چگالی احتمال (pdf) در مورد توزیع‌های **جرمی** از **مرتبه ۲**، یعنی $\delta^2(\cdot)$ است:
$$f_{XY}(x,y) = \sum_{x_i,y_j} \mathbb{P}(X = x_i, Y = y_j)\,\delta(x - x_i)\,\delta(y - y_j).$$
جرم در **نقاط** (صفربعدی) متمرکز است.

مثال ۱۵-۲: استفاده از چگالی تکین

$X \sim \mathcal{U}(0,1)$ و $Y = X^2$. با استفاده از چگالی مشترک تکین، $\mathbb{E}(XY)$ و f_Y را بیابید.

حل. $f_{XY}(x,y) = \mathbf{1}_{[0,1]}(x)\,\delta(y-x^2)$. پس

$$\mathbb{E}(XY) = \iint xy\,\delta(y-x^2)\mathbf{1}_{[0,1]}(x)\,\mathrm{d}y\,\mathrm{d}x = \int_0^1 x\cdot x^2\,\mathrm{d}x = \frac{1}{4}$$

(خاصیت غربالی دلتا، y را با x^2 جایگزین می‌کند). برای حاشیه Y: $f_Y(y) = \int_0^1 \delta(y-x^2)\,\mathrm{d}x$. با تغییر متغیر $u = x^2$ ($\mathrm{d}x = \frac{\mathrm{d}u}{2\sqrt{u}}$): $f_Y(y) = \frac{1}{2\sqrt{y}}$ برای $0 < y < 1$ ــ همان نتیجه فرمول تبدیل جلسه دوازدهم. ■

۳.۱۵ گشتاورهای مشترک (Joint Moments)

تعریف ۱۵-۳: گشتاور مشترک

فرض کنید متغیرهای تصادفی X, Y دارای چگالی احتمال مشترک f_{XY} باشند. در این صورت، گشتاور مرتبه (m,n) از توزیع مشترک f_{XY} را به صورت زیر تعریف می‌کنیم:

$$m_{m,n} = \mathbb{E}\big(X^m Y^n\big) = \iint x^m y^n f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

۱.۳.۱۵ خواص و ویژگی‌ها

ویژگی‌های ذکر شده در قبل، کماکان به صورت تعمیم‌یافته برقرار هستند:

$$m_{1,0} = \mu_X\ , \quad m_{0,1} = \mu_Y, \qquad m_{2,0} - m_{1,0}^2 = \sigma_X^2\ , \quad m_{0,2} - m_{0,1}^2 = \sigma_Y^2.$$

- **خاصیت خطی Expectation:** $\mathbb{E}(aX+bY+c) = a\mathbb{E}(X) + b\mathbb{E}(Y) + c$.
- **اتحادهای ساده:**

$$\mathbb{E}\big((X-\mu_X)(Y-\mu_Y)\big) = m_{1,1} - m_{0,1}m_{1,0} = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

اثبات اتحاد آخر. با بسط ضرب و خاصیت خطی: $\mathbb{E}(XY - \mu_Y X - \mu_X Y + \mu_X\mu_Y) = \mathbb{E}(XY) - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y = \mathbb{E}(XY) - \mu_X\mu_Y$. □

۴.۱۵ کوواریانس و همبستگی آماری

تعریف ۱۵-۴: کوواریانس

به آماره زیر در اصطلاح **کوواریانس** (Covariance) دو متغیر تصادفی X, Y اطلاق می‌گردد:

$$\mathrm{Cov}(X,Y) = C_{X,Y} \triangleq \mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big] = \mathbb{E}(XY) - \mu_X\mu_Y.$$

کوواریانس، **میزان تغییرات خطی هم‌زمان** دو متغیر را اندازه‌گیری می‌کند: اگر وقتی X از میانگینش بزرگ‌تر است، Y نیز معمولاً از میانگینش بزرگ‌تر باشد، حاصل‌ضرب $(X-\mu_X)(Y-\mu_Y)$ اغلب مثبت و کوواریانس مثبت است؛ و برعکس.

تعریف ۱۵-۵: ضریب همبستگی

به منظور بهنجارسازی و داشتن دید بهتری از رفتار مشابه بین دو متغیر تصادفی، **ضریب همبستگی** (Correlation Coefficient) را به صورت زیر تعریف می‌کنیم:

$$\mathrm{corr}(X,Y) = \rho_{X,Y} \triangleq \frac{\mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big]}{\sigma_X\sigma_Y} = \frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}.$$

به این رابطه، **ضریب همبستگی پیرسون** (Pearson Correlation Coefficient) یا Correlation هم اطلاق می‌گردد.

نکته. کوواریانس به واحد اندازه‌گیری بستگی دارد (اگر قد را به جای متر با سانتی‌متر بسنجیم، کوواریانس ۱۰۰ برابر می‌شود)، اما ضریب همبستگی بی‌بُعد است و تحت تبدیل‌های خطی $aX+b$ (با $a>0$) تغییر نمی‌کند. خواص مفید کوواریانس: $\mathrm{Cov}(X,X) = \mathrm{Var}\,X$، $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$، $\mathrm{Cov}(aX+b,Y) = a\,\mathrm{Cov}(X,Y)$ و $\mathrm{Cov}(X+Z,Y) = \mathrm{Cov}(X,Y) + \mathrm{Cov}(Z,Y)$ (دوخطی بودن).

۵.۱۵ ویژگی‌های ضریب همبستگی

قضیه ۱۵-۶: کران ضریب همبستگی

ضریب همبستگی ρ_{XY} میان هر دو متغیر تصادفی دلخواه، همواره عددی در بازه $[-1,1]$ خواهد بود؛ یعنی $|\rho_{X,Y}| \le 1$.

اثبات. اثبات بنا بر نامساوی Cauchy–Schwarz است: برای هر دو متغیر U, V، $\big(\mathbb{E}(UV)\big)^2 \le \mathbb{E}(U^2)\mathbb{E}(V^2)$. (اثبات کوشی–شوارتز: برای هر t حقیقی، $0 \le \mathbb{E}\big((U-tV)^2\big) = \mathbb{E}U^2 - 2t\mathbb{E}(UV) + t^2\mathbb{E}V^2$؛ یک چندجمله‌ای درجه دوم نامنفی بر حسب t باید مُمَیِّز نامثبت داشته باشد: $4(\mathbb{E}UV)^2 - 4\mathbb{E}U^2\mathbb{E}V^2 \le 0$.) با قرار دادن $U = X-\mu_X$ و $V = Y-\mu_Y$: $\mathrm{Cov}(X,Y)^2 \le \sigma_X^2\sigma_Y^2$، یعنی $|\rho_{XY}| \le 1$. □

قضیه ۱۵-۷: همبستگی کامل

در صورتی که ضریب همبستگی میان دو متغیر برابر با 1 یا -1 شود (fully-correlated و یا anti-correlated)، بدین معنی است که یکی از دو متغیر به صورت **ترکیب خطی** دیگری نوشته می‌شود (با احتمال ۱): $Y = aX + b$ که $a > 0$ برای $\rho = 1$ و $a < 0$ برای $\rho = -1$.

اثبات. تساوی در کوشی–شوارتز یعنی مبین صفر است، پس t_0ای وجود دارد که $\mathbb{E}\big((U - t_0V)^2\big) = 0$؛ یعنی $U = t_0V$ تقریباً حتماً، که همان رابطه خطی بین $X - \mu_X$ و $Y - \mu_Y$ است. □

قضیه ۱۵-۸: واریانس جمع و تفریق

اتحاد زیر در مورد واریانس **جمع** و **تفریق** دو متغیر تصادفی همواره برقرار است:

$$\sigma^2_{X+Y} = \sigma^2_X + \sigma^2_Y + 2\rho_{XY}\sigma_X\sigma_Y, \qquad \sigma^2_{X-Y} = \sigma^2_X + \sigma^2_Y - 2\rho_{XY}\sigma_X\sigma_Y.$$

اثبات. $\mathrm{Var}(X \pm Y) = \mathbb{E}\big[\big((X - \mu_X) \pm (Y - \mu_Y)\big)^2\big] = \sigma^2_X + \sigma^2_Y \pm 2\,\mathrm{Cov}(X, Y)$ و $\mathrm{Cov}(X, Y) = \rho_{XY}\sigma_X\sigma_Y$. □

نکته

در صورتی که X, Y متغیرهای تصادفی مشترکاً گاوسی با میانگین و واریانس دلخواه، و ضریب همبستگی r باشند، همواره داریم $\rho_{XY} = r$. (این را در پاسخ پرسش جلسه قبل نشان دادیم: $\mathrm{Cov}(X, Y) = r\sigma\sigma'$.)

۱.۵.۱۵ ناهمبستگی و استقلال

تعریف ۱۵-۹

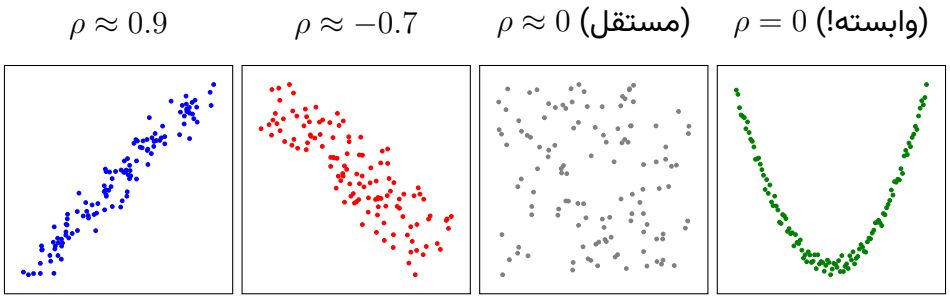
در صورتی که برای دو متغیر تصادفی X, Y داشته باشیم $\rho_{XY} = 0$، این دو متغیر را **ناهمبسته** (Uncorrelated) می‌نامیم.

- در صورتی که دو متغیر تصادفی **مستقل** باشند، **ناهمبسته** نیز خواهند بود (زیرا $\mathbb{E}(XY) = \mathbb{E}X\mathbb{E}Y$).
- اما در صورتی که دو متغیر تصادفی **ناهمبسته** باشند، لزوماً **مستقل** نیستند. استقلال آماری شرط بسیار قوی‌تری نسبت به ناهمبسته بودن است.

مثال ۱۵-۱۰: ناهمبسته اما وابسته

$X \sim \mathcal{U}(-1, 1)$ و $Y = X^2$. نشان دهید X, Y ناهمبسته‌اند ولی مستقل نیستند.

حل. $\mathbb{E}X = 0$ و $\mathbb{E}(XY) = \mathbb{E}(X^3) = \int_{-1}^{1} \frac{x^3}{2}\,\mathrm{d}x = 0$ (تابع فرد). پس $\mathrm{Cov}(X, Y) = 0 - 0 \cdot \mathbb{E}Y = 0$ و ناهمبسته‌اند. اما Y به‌طور کامل توسط X تعیین می‌شود! مثلاً $\mathbb{P}(Y > \frac{1}{4} \,|\, |X| > \frac{1}{2}) = 1 \neq \mathbb{P}(Y > \frac{1}{4}) = \frac{1}{2}$. **درس:** همبستگی فقط وابستگی **خطی** را می‌سنجد؛ در اینجا رابطه کاملاً غیرخطی (سهمی) است و همبستگی آن را «نمی‌بیند». ■



نکته. تنها در حالت **مشترکاً گاوسی** است که ناهمبستگی و استقلال معادل‌اند (جلسه قبل، خاصیت ۲).

۶.۱۵ تمرین‌های تکمیلی

تمرین ۱۵-۱۱

در مثال جلسه سیزدهم با $f_{XY} = x + y$ روی مربع واحد، $\mathrm{Cov}(X,Y)$ و ρ_{XY} را حساب کنید.

حل. $\mathbb{E}X = \int_0^1 x(x+\frac{1}{2})\,\mathrm{d}x = \frac{1}{3}+\frac{1}{4} = \frac{7}{12}$ (و $\mathbb{E}Y$ نیز همین). $\mathbb{E}X^2 = \int_0^1 x^2(x+\frac{1}{2})\,\mathrm{d}x = \frac{1}{4}+\frac{1}{6} = \frac{5}{12}$؛ $\mathbb{E}(XY) = \int_0^1\int_0^1 xy(x+y)\,\mathrm{d}x\,\mathrm{d}y = \frac{1}{6}+\frac{1}{6} = \frac{1}{3}$. $\sigma_X^2 = \frac{5}{12} - \frac{49}{144} = \frac{11}{144}$ پس $\mathrm{Cov} = \frac{1}{3} - \frac{49}{144} = -\frac{1}{144}$ و $\rho = \frac{-1/144}{11/144} = -\frac{1}{11} \approx -0.09$ ــ همبستگی منفی ضعیف. ■

تمرین ۱۵-۱۲

X, Y با $\mathrm{Var}\,X = 4$، $\mathrm{Var}\,Y = 9$ و $\rho_{XY} = 0.5$ داده شده‌اند. $\mathrm{Var}(2X - Y)$ را بیابید.

حل. $\mathrm{Cov}(X,Y) = 0.5 \cdot 2 \cdot 3 = 3$. $\mathrm{Var}(2X - Y) = 4 \cdot 4 + 9 - 2 \cdot 2 \cdot 3 = 16 + 9 - 12 = 13$. ■

تمرین ۱۵-۱۳

یک تاس سالم دو بار پرتاب می‌شود. S مجموع و D تفاضل دو عدد است. نشان دهید S و D ناهمبسته‌اند. آیا مستقل‌اند؟

حل. $\mathrm{Cov}(X_1 + X_2, X_1 - X_2) = \mathrm{Var}\,X_1 - \mathrm{Var}\,X_2 + \mathrm{Cov}(X_2,X_1) - \mathrm{Cov}(X_1,X_2) = 0$. پس ناهمبسته‌اند. اما مستقل نیستند: اگر $S = 2$ باشد حتماً $D = 0$ است، در حالی که $\mathbb{P}(D=0) = \frac{1}{6}$. ■

تمرین ۱۵-۱۴

نشان دهید برای هر متغیرهای $X_1, \dots, X_n$: $\mathrm{Var}\left(\sum_i X_i\right) = \sum_i \mathrm{Var}\,X_i + 2\sum_{i<j}\mathrm{Cov}(X_i,X_j)$.

حل. $\mathrm{Var}(\sum X_i) = \mathrm{Cov}(\sum_i X_i, \sum_j X_j) = \sum_{i,j}\mathrm{Cov}(X_i,X_j)$ (دوخطی بودن). جملات $i = j$ واریانس‌ها هستند و هر جفت $i \neq j$ دو بار ظاهر می‌شود. برای متغیرهای دوبه‌دو ناهمبسته (نه لزوماً مستقل!) این رابطه به $\sum \mathrm{Var}\,X_i$ کاهش می‌یابد. ■

جلسه ۱۶

یک تابع از دو متغیر تصادفی: توزیع جمع و کانولوشن

۱.۱۶ مرور: گشتاورهای مشترک، کوواریانس و همبستگی

در جلسه قبل تعاریف زیر را دیدیم (که در این جلسه نیز به آن‌ها نیاز داریم):

- گشتاور مشترک مرتبه (m,n): $m_{m,n}=\mathbb{E}(X^mY^n)$؛ با $m_{1,0}=\mu_X$، $m_{0,1}=\mu_Y$، $m_{2,0}-m_{1,0}^2=\sigma_X^2$ و $m_{0,2}-m_{0,1}^2=\sigma_Y^2$.
- کوواریانس: $\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]=m_{1,1}-m_{1,0}m_{0,1}=\mathbb{E}(XY)-\mu_X\mu_Y$؛ میزان تغییرات **خطی** هم‌زمان دو متغیر.
- ضریب همبستگی (پیرسون): $\rho_{X,Y}=\frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}$ با $|\rho_{XY}|\le 1$ (کوشی–شوارتز)، و $|\rho|=1$ اگر و تنها اگر رابطه خطی کامل.
- $\sigma^2_{X\pm Y}=\sigma_X^2+\sigma_Y^2\pm 2\rho_{XY}\sigma_X\sigma_Y$؛ برای متغیرهای مشترکاً گاوسی $\rho_{XY}=r$.
- مستقل $\Rightarrow$ ناهمبسته؛ اما ناهمبسته $\not\Rightarrow$ مستقل (استقلال شرط بسیار قوی‌تری است).

۲.۱۶ مبحث جدید: یک تابع از دو متغیر تصادفی

۱.۲.۱۶ فرم کلی (تعریف مسئله)

فرض کنید متغیرهای تصادفی X,Y با توزیع مشترک $f_{XY}(x,y)$ در اختیار ما هستند. متغیر تصادفی جدید $Z=g(X,Y)$ را با استفاده از تابع یقینی $g:\mathbb{R}^2\to\mathbb{R}$ تشکیل می‌دهیم. توزیع Z چگونه به دست خواهد آمد؟

روش کلی: مانند حالت یک متغیره، از CDF شروع می‌کنیم:

$$F_Z(z)=\mathbb{P}\big(g(X,Y)\le z\big)=\iint_{D_z} f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y,\qquad D_z=\{(x,y):\ g(x,y)\le z\},$$

و سپس $f_Z = F'_Z$. یعنی باید ناحیه D_z در صفحه را مشخص کرده و حجم زیر چگالی مشترک روی آن را حساب کنیم.

۳.۱۶ حالت خاص: جمع $X+Y$ در حالت گسسته

فرض کنید که دو متغیر تصادفی X, Y ماهیت گسسته داشته باشند؛ یعنی داریم $X, Y \in \mathbb{Z}$. تابع جرم احتمال مشترک این دو را به شکل $\mathbb{P}(X = x, Y = y)$ در نظر بگیرید. همچنین، تعریف می‌کنیم $Z = g(X,Y) = X + Y$. لذا، به راحتی می‌توان دید که:

$$\boxed{\mathbb{P}(Z = z) = \mathbb{P}(X + Y = z) = \sum_{t=-\infty}^{+\infty} \mathbb{P}(X = t,\ Y = z - t)}$$

(رویداد $\{X + Y = z\}$ اجتماع ناسازگار رویدادهای $\{X = t, Y = z - t\}$ روی همه t هاست.)

۱.۳.۱۶ حالت مستقل: کانولوشن گسسته

در مسئله پیشین، همچنین فرض کنید که متغیرهای تصادفی X, Y از یکدیگر **مستقل** هستند. برای سادگی در نمادگذاری، توابع $\mathbb{P}_X(\cdot), \mathbb{P}_Y(\cdot)$ را به صورت زیر تعریف می‌کنیم:

$$\mathbb{P}_X(x) \triangleq \mathbb{P}(X = x), \qquad \mathbb{P}_Y(y) \triangleq \mathbb{P}(Y = y).$$

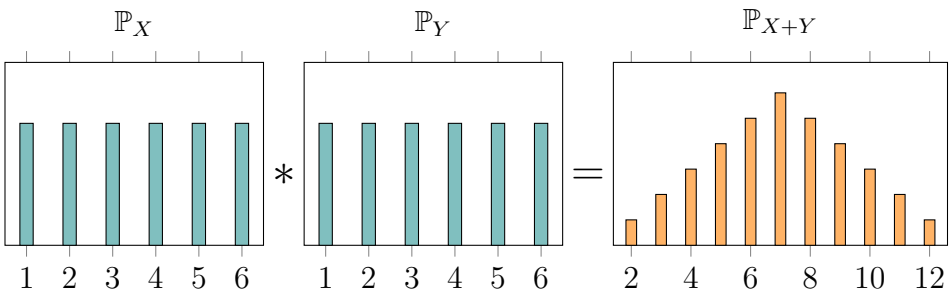
در این حالت، توزیع جمع X, Y برابر با **کانولوشن** (Convolution) توزیع آنان در یکدیگر خواهد شد:

$$\boxed{\mathbb{P}(Z = z) = \sum_{t=-\infty}^{+\infty} \mathbb{P}_X(t)\, \mathbb{P}_Y(z - t) = \big(\mathbb{P}_X * \mathbb{P}_Y\big)(z)}$$

مثال ۱۶-۱: مجموع دو تاس

PMF مجموع دو تاس سالم و مستقل را با کانولوشن به دست آورید.

حل. $\mathbb{P}_X(t) = \mathbb{P}_Y(t) = \frac{1}{6}$ برای $t = 1, \dots, 6$. برای $z \in \{2, \dots, 12\}$: $\mathbb{P}(Z = z) = \sum_t \mathbb{P}_X(t)\mathbb{P}_Y(z-t) = \frac{1}{36}\#\{t : 1 \le t \le 6,\ 1 \le z - t \le 6\} = \frac{6 - |z-7|}{36}$. مثلاً $\mathbb{P}(Z = 7) = \frac{6}{36}$ و $\mathbb{P}(Z = 2) = \frac{1}{36}$. کانولوشن دو تابع «مستطیلی» یک تابع «مثلثی» می‌دهد. ■



مثال ۱۶-۲: جمع دوجمله‌ای‌ها

اگر $X \sim \mathrm{Bin}(m,p)$ و $Y \sim \mathrm{Bin}(n,p)$ مستقل باشند، $X+Y$ چه توزیعی دارد؟

حل. با کانولوشن و اتحاد واندرموند $\sum_t \binom{m}{t}\binom{n}{z-t} = \binom{m+n}{z}$:

$$\mathbb{P}(X+Y=z) = \sum_t \binom{m}{t}p^t(1-p)^{m-t}\binom{n}{z-t}p^{z-t}(1-p)^{n-z+t} = \binom{m+n}{z}p^z(1-p)^{m+n-z}.$$

پس $X+Y \sim \mathrm{Bin}(m+n,p)$ ــ که شهوداً هم واضح است: $m+n$ آزمون برنولی مستقل. ■

۴.۱۶ حالت خاص: جمع $X+Y$ در حالت پیوسته

حال فرض کنید، متغیرهای تصادفی X,Y پیوسته باشند و با چگالی احتمال مشترک $f_{XY}(x,y)$ مدل‌سازی شوند. کماکان با فرض $Z = g(X,Y) = X+Y$، خواهیم داشت:

$$\boxed{f_Z(z) = \int_{\mathbb{R}} f_{XY}(u,\ z-u)\,\mathrm{d}u}$$

و در صورتی که دو متغیر تصادفی X,Y **مستقل** باشند، می‌توان دید که:

$$\boxed{f_Z(z) = \int_{\mathbb{R}} f_X(u)f_Y(z-u)\,\mathrm{d}u = \big(f_X * f_Y\big)(z)}$$

۱.۴.۱۶ مرور توزیع جمع $X+Y$ (اثبات از طریق CDF)

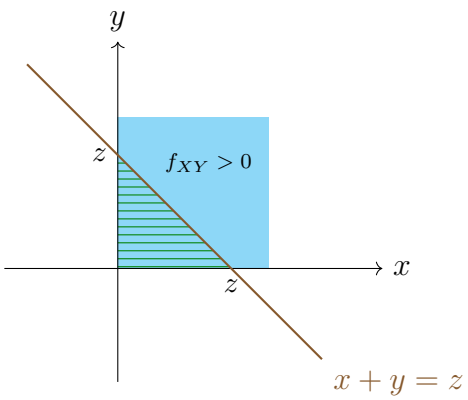
توزیع انباشته $F_{X+Y}(z)$ نیز به صورت زیر درخواهد آمد (حجم زیر چگالی مشترک روی نیم‌صفحه $x+y \le z$):

$$F_{X+Y}(z) = \int_{-\infty}^{+\infty}\int_{-\infty}^{z-x} f_{XY}(x,y)\,\mathrm{d}y\,\mathrm{d}x.$$

با مشتق‌گیری نسبت به z (قاعده لایبنیتس: مشتق انتگرال درونی نسبت به حد بالای آن برابر مقدار انتگرالده در آن حد است):

$$f_{X+Y}(z) = \int_{-\infty}^{+\infty} f_{XY}(x,z-x)\,\mathrm{d}x,$$

که همان رابطه بالاست.



CDF جمع در نقطه z: حجم زیر چگالی مشترک در ناحیه پایین خط $x+y=z$ (در اینجا، برای دو متغیر روی مربع واحد، ناحیه هاشورخورده).

همچنین، در صورتی که متغیرهای تصادفی $X_1, X_2, \dots$ به صورت (متقابل) مستقل از یکدیگر باشند، خواهیم داشت:

$$f_{X_1+X_2+\cdots}(z) = \big(f_{X_1} * f_{X_2} * \cdots\big)(z).$$

نکته. ارتباط با MGF: در جلسه یازدهم دیدیم که برای متغیرهای مستقل $M_{X+Y} = M_X M_Y$. این همان «قضیه کانولوشن» است: کانولوشن در حوزه چگالی معادل ضرب در حوزه تبدیل (لاپلاس/فوریه) است. در عمل، محاسبه MGF و ضرب آن‌ها اغلب بسیار ساده‌تر از محاسبه مستقیم انتگرال کانولوشن است.

۵.۱۶ مثال‌ها

مثال ۱۶-۳: جمع دو یکنواخت مستقل

فرض کنید که دو متغیر تصادفی X, Y مستقل از یکدیگر بوده و هر یک توزیع یکنواخت در بازه $[0,1]$ داشته باشند. توزیع $X+Y$ را بیابید.

حل.

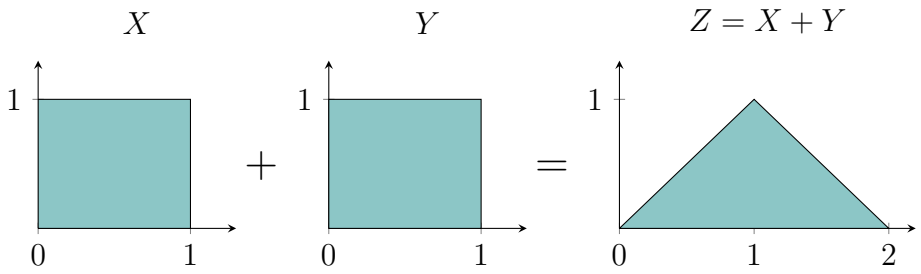
$$f_Z(z) = \int_{\mathbb{R}} f_X(u) f_Y(z-u)\,\mathrm{d}u = \int_0^1 \mathbf{1}_{0\le z-u\le 1}\,\mathrm{d}u.$$

انتگرالده برابر ۱ است وقتی $u \in [0,1]$ و $u \in [z-1, z]$؛ یعنی روی اشتراک $[\max(0, z-1),\ \min(1,z)]$. طول این بازه:

- برای $0 \le z \le 1$: $[0,z]$، طول z؛
- برای $1 \le z \le 2$: $[z-1,1]$، طول $2-z$.

$$f_Z(z) = \begin{cases} z & 0 \le z \le 1 \\ 2-z & 1 \le z \le 2 \\ 0 & \text{o.w.} \end{cases}$$

یعنی جمع دو یکنواخت مستقل، توزیع **مثلثی** دارد. ■



مثال ۱۶-۴: جمع متغیرهای وابسته

در سؤال قبل، فرض کنید که دو متغیر تصادفی X, Y وابسته بوده و داشته باشیم $Y = 2X$. حال، دوباره توزیع $X + Y$ را بیابید.

حل.

$$Z = X + Y = 3X \;\Rightarrow\; f_Z(z) = \frac{1}{3}\mathbf{1}_{0\le z\le 3} = \text{Uniform}(0, 3).$$

(از فرمول تبدیل خطی جلسه یازدهم: $f_Z(z) = \frac{1}{3} f_X(\frac{z}{3})$.) دقت کنید که اینجا حاشیه Y یکنواخت روی $[0, 2]$ است و **نمی‌توان** از کانولوشن حاشیه‌ها استفاده کرد؛ زیرا فرمول کانولوشن فقط برای متغیرهای مستقل درست است. (با فرمول کلی $f_{XY} = f_X(x)\delta(y - 2x)$ و چگالی تکین $\int f_{XY}(u, z - u)\,\mathrm{d}u$ نیز همین جواب به دست می‌آید.) ■

مثال ۱۶-۵: جمع دو نمایی مستقل

$X, Y \sim \text{Exp}(\lambda)$ مستقل. توزیع $Z = X + Y$ را بیابید.

حل. برای $z \ge 0$:

$$f_Z(z) = \int_0^z \lambda e^{-\lambda u}\lambda e^{-\lambda(z-u)}\,\mathrm{d}u = \lambda^2 e^{-\lambda z}\int_0^z \mathrm{d}u = \lambda^2 z e^{-\lambda z},$$

که توزیع **ارلانگ** با $k = 2$ است (جلسه هفتم). به همین ترتیب جمع k نمایی مستقل، ارلانگ مرتبه k است: زمان تا kامین رخداد در فرایند پواسون. ■

۶.۱۶ خواص: جمع $X + Y$ برای توزیع‌های گاوسی

دو متغیر گاوسی X, Y را با توزیع‌های حاشیه‌ای $\mathcal{N}(\mu, \sigma^2)$ و $\mathcal{N}(\mu', \sigma'^2)$ در نظر بگیرید. کماکان تعریف می‌کنیم $Z = X + Y$.

قضیه ۱۶-۶: جمع گاوسی‌های مستقل

فرض کنید که دو متغیر تصادفی **مستقل** هستند. در این صورت می‌توان دید:

$$f_Z = \mathcal{N}(\mu, \sigma^2) * \mathcal{N}(\mu', \sigma'^2) = \mathcal{N}(\mu + \mu',\ \sigma^2 + \sigma'^2).$$

اثبات. با MGF: $M_Z(t) = e^{t\mu+\sigma^2 t^2/2}\, e^{t\mu'+\sigma'^2 t^2/2} = e^{t(\mu+\mu')+(\sigma^2+\sigma'^2)t^2/2}$ که MGF گاوسی با پارامترهای ادعا شده است؛ طبق یکتایی، حکم ثابت می‌شود. (اثبات مستقیم با انتگرال کانولوشن و تکمیل مربع نیز ممکن است.) □

نکته. توابع چگالی احتمال گاوسی، تحت عمل convolution کماکان فرم گاوسی پیدا می‌کنند (خانواده گاوسی «بسته» به کانولوشن است). اسلاید این را این‌گونه بیان می‌کند که «توزیع گاوسی تنها توزیع با این خاصیت است»؛ به بیان دقیق‌تر: در میان توزیع‌های با **واریانس متناهی**، گاوسی تنها خانواده‌ای است که جمع متغیرهای مستقل آن هم‌خانواده می‌ماند (و طبق قضیه کرامر، اگر جمع دو متغیر مستقل گاوسی باشد، هر کدام گاوسی‌اند).

توزیع‌هایی مانند کوشی (با واریانس نامتناهی) نیز تحت کانولوشن بسته‌اند و به آن‌ها «توزیع‌های پایدار» می‌گویند. این خاصیت ریشه نقش ویژه گاوسی در قضیه حد مرکزی است.

حال فرض کنید که دو متغیر تصادفی **مشترکاً گاوسی** باشند (با ضریب همبستگی r). در این صورت، توزیع Z کماکان یک گاوسی با میانگین $\mu+\mu'$ خواهد شد.

پرسش: واریانس را در این حالت (مشترکاً گاوسی) در خانه به دست آورید.

پاسخ. طبق اتحاد واریانس جمع (جلسه پانزدهم) و $\rho_{XY}=r$:

$$\operatorname{Var}(Z)=\sigma^2+\sigma'^2+2r\sigma\sigma' \quad\Longrightarrow\quad Z\sim\mathcal{N}\big(\mu+\mu',\ \sigma^2+\sigma'^2+2r\sigma\sigma'\big).$$

برای $r=0$ به حالت مستقل می‌رسیم. حالت‌های حدی: $r=1$ و $\sigma=\sigma'$ ($Y=X$ پس از مرکزیت): واریانس $4\sigma^2=\operatorname{Var}(2X)$ ✓؛ $r=-1$ و $\sigma=\sigma'$: واریانس صفر، یعنی Z ثابت است ✓.

۷.۱۶ تمرین‌های تکمیلی

تمرین ۱۶-۷

X,Y مستقل و هر دو یکنواخت روی $[0,1]$ هستند. توزیع $W=X-Y$ را بیابید.

حل. $-Y$ یکنواخت روی $[-1,0]$ است و مستقل از X. با کانولوشن (یا با شیفت جواب مثال قبل به اندازه ۱): $f_W(w)=1-|w|$ برای $|w|\le 1$ ــ مثلثی متقارن حول صفر. ■

تمرین ۱۶-۸

$X\sim\text{Pois}(2)$ و $Y\sim\text{Pois}(3)$ مستقل‌اند. $\mathbb{P}(X+Y=4)$ و $\mathbb{P}(X=1\,|\,X+Y=4)$ را بیابید.

حل. $X+Y\sim\text{Pois}(5)$، پس $\mathbb{P}(X+Y=4)=e^{-5}\frac{5^4}{24}\approx 0.1755$. در واقع به شرط $X+Y=n$، $X\sim\text{Bin}(n,\frac{2}{5})$ و $\mathbb{P}(X=1\,|\,X+Y=4)=\frac{\mathbb{P}(X=1)\mathbb{P}(Y=3)}{\mathbb{P}(X+Y=4)}=\frac{2e^{-2}\cdot\frac{27}{6}e^{-3}}{\frac{625}{24}e^{-5}}=\frac{9\times 24}{625}=0.3456$. ✓ $\binom{4}{1}(0.4)(0.6)^3=0.3456$ ■

تمرین ۱۶-۹

X و Y مستقل و $\text{Exp}(1)$ هستند. توزیع $Z=\max(X,Y)$ و $W=\min(X,Y)$ را بیابید.

حل. $F_Z(z)=\mathbb{P}(X\le z,Y\le z)=(1-e^{-z})^2$ و $f_Z(z)=2e^{-z}(1-e^{-z})$ برای $z\ge 0$. $\mathbb{P}(W>w)=\mathbb{P}(X>w)\mathbb{P}(Y>w)=e^{-2w}$؛ پس $W\sim\text{Exp}(2)$ (کمینه نمایی‌های مستقل، نمایی با نرخ مجموع است). ■

تمرین ۱۶-۱۰

X,Y مستقل و $\mathcal{N}(0,1)$ هستند. $\mathbb{P}(X+Y>2)$ و $\mathbb{P}(X>Y+1)$ را بیابید.

حل. $X+Y \sim \mathcal{N}(0,2)$: $\mathbb{P}(X+Y>2) = 1-\Phi(\frac{2}{\sqrt{2}}) = 1-\Phi(1.414) \approx 0.0786$. $X-Y \sim \mathcal{N}(0,2)$: $\mathbb{P}(X-Y>1) = 1-\Phi(0.707) \approx 0.240$. ■

جلسه ۱۷

مثال‌های معروف از $g(X,Y)$، آماره‌های ترتیبی و قضیه حد مرکزی

۱.۱۷ مثال‌های معروف از $g(X,Y)$

۱.۱.۱۷ توزیع کای‌دو (Chi-Square) $\chi^2(k)$ با k درجه آزادی

تعریف ۱۷-۱: توزیع کای‌دو

فرض کنید $X_1, X_2, \ldots, X_k$ متغیرهای تصادفی گاوسی **مستقل** و **استاندارد** (دارای میانگین صفر و واریانس ۱) باشند. در این صورت متغیر تصادفی

$$Z = \sum_{i=1}^{k} X_i^2$$

را دارای توزیع $\chi^2(k)$ می‌نامیم.

کاربرد: مجموع مربعات خطاهای مستقل گاوسی (مثلاً توان نویز در k نمونه، یا آماره‌های آزمون فرض در آمار).

مثال ۱۷-۲: چگالی $\chi^2(2)$

سؤال: تابع چگالی احتمال $\chi^2(2)$ را بیابید.

حل. ابتدا تابع توزیع انباشته را به دست می‌آوریم. با $Z = X^2+Y^2$ و $f_{XY} = \frac{1}{2\pi}e^{-(x^2+y^2)/2}$ (استقلال)، ناحیه $\{Z \le z\}$ یک دایره به شعاع $\sqrt{z}$ است:

$$F_Z(z) = \iint_{x^2+y^2\le z} \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}\,\mathrm{d}x\,\mathrm{d}y = \frac{1}{2\pi}\int_0^{2\pi}\int_0^{\sqrt{z}} e^{-r^2/2}\, r\,\mathrm{d}r\,\mathrm{d}\theta.$$

همان‌طور که مشاهده شد، با تغییر مختصات از **دکارتی** به **قطبی** ($x = r\cos\theta$، $y = r\sin\theta$، $\mathrm{d}x\,\mathrm{d}y = r\,\mathrm{d}r\,\mathrm{d}\theta$)، فرم دلخواه پیش‌تر اشاره شده برای توزیع انباشته حاصل می‌شود. با مشتق‌گیری نسبت به z

از $F_Z(z)$ (قاعده لایبنیتس روی حد بالای $\sqrt{z}$)، چگالی احتمال $\chi^2(2)$ به دست خواهد آمد:

$$f_Z(z)=\frac{1}{2\pi}\int_0^{2\pi}\frac{\partial\sqrt{z}}{\partial z}\,e^{-(\sqrt{z})^2/2}\sqrt{z}\,\mathrm{d}\theta=\frac{1}{2\pi}\cdot 2\pi\cdot\frac{1}{2\sqrt{z}}e^{-z/2}\sqrt{z}=\frac{e^{-z/2}}{2}u(z).$$

(مستقیم‌تر: $F_Z(z)=\int_0^{\sqrt{z}}e^{-r^2/2}r\,\mathrm{d}r=1-e^{-z/2}$.) ■

نکته. در حالت خاص $k=2$، توزیع $\chi^2(k)$ برابر با یک توزیع **نمایی** (با پارامتر $\lambda=\frac{1}{2}$) خواهد شد.

پرسش: سعی کنید ضابطه $\chi^2(k)$ را برای $k>2$ در خانه به دست آورید.

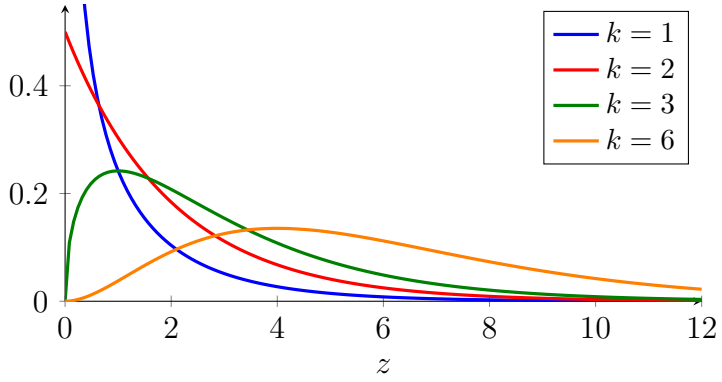
پاسخ. **روش MGF:** برای $X\sim\mathcal{N}(0,1)$:

$$M_{X^2}(t)=\mathbb{E}e^{tX^2}=\int\frac{1}{\sqrt{2\pi}}e^{-\frac{(1-2t)x^2}{2}}\,\mathrm{d}x=(1-2t)^{-1/2},\qquad t<\tfrac{1}{2}.$$

با استقلال، $M_Z(t)=(1-2t)^{-k/2}$. از طرفی چگالی $g(z)=\frac{z^{a-1}e^{-z/2}}{2^a\Gamma(a)}$ (توزیع گاما با شکل a و مقیاس ۲) دارای MGF برابر $(1-2t)^{-a}$ است (با تغییر متغیر $w=(1-2t)z/2$ و تعریف تابع گاما). پس با $a=k/2$ و یکتایی:

$$\boxed{f_{\chi^2(k)}(z)=\frac{1}{2^{k/2}\Gamma(k/2)}\,z^{\frac{k}{2}-1}e^{-z/2}\,u(z)}$$

بررسی: $k=2$: $\frac{1}{2\Gamma(1)}e^{-z/2}=\frac{1}{2}e^{-z/2}$ ✓. $k=1$: $\frac{1}{\sqrt{2}\Gamma(1/2)}z^{-1/2}e^{-z/2}=\frac{1}{\sqrt{2\pi z}}e^{-z/2}$ که با نتیجه جلسه یازدهم برای X^2 مطابقت دارد ✓. همچنین $\mathbb{E}Z=k$ و $\operatorname{Var}Z=2k$.



۲.۱.۱۷ توزیع رایلی و توزیع نسبت (اثبات در کتاب)

قضیه ۱۷-۳: رایلی

فرض کنید که متغیرهای تصادفی X,Y گاوسی $\mathcal{N}(0,\sigma^2)$ و مستقل باشند. تعریف می‌کنیم $Z=$

$\sqrt{X^2+Y^2}$. آنگاه Z توزیع رایلی (Rayleigh) دارد:

$$f_Z(z) = \frac{z}{\sigma^2} e^{-z^2/(2\sigma^2)} u(z).$$

اثبات. مانند مثال $\chi^2(2)$ با مختصات قطبی: $F_Z(z) = \mathbb{P}(X^2+Y^2 \le z^2) = \frac{1}{2\pi\sigma^2}\int_0^{2\pi}\int_0^{z} e^{-r^2/2\sigma^2} r \,\mathrm{d}r\,\mathrm{d}\theta = 1 - e^{-z^2/2\sigma^2}$ برای $z \ge 0$. با مشتق‌گیری حکم ثابت می‌شود. (معادلاً $Z^2/\sigma^2 \sim \chi^2(2)$.) □

کاربرد: دامنه (پوش) سیگنال در کانال‌های بی‌سیم با محوشدگی، که مؤلفه‌های هم‌فاز و متعامد آن گاوسی مستقل‌اند.

قضیه ۱۷-۴: نسبت دو گاوسی کوشی

فرض کنید که متغیرهای تصادفی X, Y مشترکاً گاوسی با میانگین‌های صفر، واریانس‌های σ_1^2 و σ_2^2، و ضریب همبستگی r باشند. تعریف می‌کنیم $Z = X/Y$. آنگاه Z توزیع کوشی (Cauchy) حول مقدار $\frac{r\sigma_1}{\sigma_2}$ دارد:

$$f_Z(z) = \frac{\gamma/\pi}{(z-x_0)^2+\gamma^2}, \qquad x_0 = \frac{r\sigma_1}{\sigma_2}, \quad \gamma = \frac{\sigma_1}{\sigma_2}\sqrt{1-r^2}.$$

طرح اثبات. برای نسبت، $F_Z(z) = \mathbb{P}(X \le zY,\ Y>0) + \mathbb{P}(X \ge zY,\ Y<0)$ و با مشتق‌گیری به فرمول کلی زیر می‌رسیم:

$$f_Z(z) = \int_{-\infty}^{\infty} |y|\, f_{XY}(zy,\ y)\,\mathrm{d}y.$$

با جایگذاری چگالی مشترکاً گاوسی، انتگرالده به شکل $|y|e^{-Ay^2}$ با $A = \frac{1}{2(1-r^2)}\left(\frac{z^2}{\sigma_1^2} - \frac{2rz}{\sigma_1\sigma_2} + \frac{1}{\sigma_2^2}\right)$ است و $\int |y|e^{-Ay^2}\,\mathrm{d}y = \frac{1}{A}$. پس $f_Z(z) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \cdot \frac{1}{A}$ و با ساده‌سازی (تکمیل مربع در مخرج) به فرم کوشی بالا می‌رسیم. در حالت خاص $r=0$ و $\sigma_1=\sigma_2$: نسبت دو گاوسی استاندارد مستقل، کوشی استاندارد است. □

۲.۱۷ آماره‌های ترتیبی (... min, max)

متغیرهای تصادفی $X_1, X_2, \ldots, X_n$ را به صورت i.i.d. با توزیع انباشته F_X و تابع چگالی احتمال f_X در نظر بگیرید. متغیرهای تصادفی جدید L, U را تعریف می‌کنیم:

$$L = \min(X_1, X_2, \ldots, X_n), \qquad U = \max(X_1, X_2, \ldots, X_n).$$

توابع چگالی احتمال f_U و f_L چگونه به دست خواهند آمد؟

۱.۲.۱۷ تابع چگالی احتمال کمینه

در مورد توزیع L مطابق با زیر عمل خواهیم کرد: فرض کنید $h \to 0^+$. در این صورت داریم (با نماد $X_{-i} > \ell$ یعنی «همه X_jها به جز X_i از ℓ بزرگ‌ترند»):

$$f_L(\ell)\,h = \mathbb{P}(\ell \le L \le \ell + h) = \mathbb{P}\Big(\bigcup_{i=1}^{n} \big[\ell \le X_i \le \ell + h\ ,\ X_{-i} > \ell\big]\Big)$$
$$= n\,\mathbb{P}\big(\ell \le X_1 \le \ell + h\ ,\ X_{-1} > \ell\big).$$

(رخدادهای اجتماع، تا مرتبه $o(h)$، ناسازگارند ــ احتمال اینکه دو متغیر هم‌زمان در بازه‌ای به طول h بیفتند از مرتبه h^2 است ــ و به دلیل تقارن i.i.d. همه احتمال برابر دارند.) با توجه به تعریف توابع توزیع انباشته و چگالی احتمال (یعنی F_X و f_X) و استقلال، می‌توان نوشت:

$$\boxed{f_L(\ell) = n\,f_X(\ell)\big(1 - F_X(\ell)\big)^{n-1}}$$

۲.۲.۱۷ تابع چگالی احتمال بیشینه

مشابه با قبل:

$$f_U(u)\,h = \mathbb{P}(u \le U \le u + h) = \mathbb{P}\Big(\bigcup_{i=1}^{n} \big[u \le X_i \le u + h\ ,\ X_{-i} \le u\big]\Big)$$
$$= n\,\mathbb{P}\big(u \le X_1 \le u + h\ ,\ X_{-1} \le u\big),$$

$$\boxed{f_U(u) = n\,f_X(u)\,F_X^{n-1}(u)}$$

نکته. روش جایگزین (با CDF): $U \le u$ اگر و تنها اگر **همه** $X_i \le u$؛ پس $F_U(u) = F_X(u)^n$. و $L > \ell$ اگر و تنها اگر همه $X_i > \ell$؛ پس $F_L(\ell) = 1 - (1 - F_X(\ell))^n$. مشتق‌گیری همان فرمول‌های بالا را می‌دهد.

مثال ۱۷-۵: بزرگ‌ترین و کوچک‌ترین از n یکنواخت

برای $X_i \sim \mathcal{U}(0,1)$:i.i.d. $f_U(u) = nu^{n-1}$ و $f_L(\ell) = n(1-\ell)^{n-1}$ روی $[0,1]$. پس $\mathbb{E}U = \frac{n}{n+1}$ و $\mathbb{E}L = \frac{1}{n+1}$: n نقطه تصادفی، بازه $[0,1]$ را به طور متوسط به $n+1$ قطعه مساوی تقسیم می‌کنند.

۳.۲.۱۷ در خانه حل کنید

پرسش: اگر $X_1, \dots, X_n$ مستقل باشند اما هم‌توزیع نباشند (فرض i.i.d. برقرار نباشد)، روابط f_U و f_L چه تغییری می‌کنند؟

پاسخ. با همان استدلال CDF و استقلال:

$$F_U(u) = \prod_{i=1}^{n} F_i(u), \qquad f_U(u) = \sum_{i=1}^{n} f_i(u) \prod_{j \ne i} F_j(u),$$

$$F_L(\ell) = 1 - \prod_{i=1}^{n} \big(1 - F_i(\ell)\big), \qquad f_L(\ell) = \sum_{i=1}^{n} f_i(\ell) \prod_{j \neq i} \big(1 - F_j(\ell)\big).$$

(ضریب n به جمع روی i تبدیل می‌شود، زیرا دیگر همه جملات برابر نیستند.) مثال: کمینه نمایی‌های مستقل با نرخ‌های λ_i، نمایی با نرخ $\sum \lambda_i$ است.

پرسش: اگر متغیرها نه مستقل و نه هم‌توزیع باشند (حالت کلی) چطور؟

پاسخ. باید از توزیع مشترک استفاده کرد:

$$F_U(u) = \mathbb{P}(X_1 \le u, \dots, X_n \le u) = F_{X_1,\dots,X_n}(u, u, \dots, u),$$

$$F_L(\ell) = 1 - \mathbb{P}(X_1 > \ell, \dots, X_n > \ell),$$

که احتمال دوم با شمول و عدم شمول بر حسب CDF مشترک قابل بیان است (مانند $\mathbb{P}(X > x, Y > y)$ در جلسه سیزدهم). چگالی‌ها با مشتق‌گیری به دست می‌آیند.

پرسش: اگر به جای کمینه یا بیشینه، به دنبال سایر آماره‌های ترتیبی باشیم چطور؟ مثلاً توزیع دومین مقدار بزرگ؟ یا توزیع یکی‌مانده‌به‌کوچک‌ترین؟

پاسخ. اگر $X_{(k)}$ را kامین کوچک‌ترین مقدار (در حالت i.i.d.) بگیریم، برای اینکه $X_{(k)} \in [x, x+h]$ باشد باید: یکی از متغیرها در $[x, x+h]$، دقیقاً $k-1$ تا کمتر از x و $n-k$ تا بیشتر از x باشند. تعداد راه‌های تخصیص (توزیع چندجمله‌ای!) برابر $\frac{n!}{(k-1)!\,1!\,(n-k)!}$ است:

$$\boxed{f_{X_{(k)}}(x) = \frac{n!}{(k-1)!\,(n-k)!}\, F_X(x)^{k-1} \big(1 - F_X(x)\big)^{n-k} f_X(x)}$$

$k = 1$ کمینه و $k = n$ بیشینه را می‌دهد. «دومین مقدار بزرگ» یعنی $k = n-1$: $f(x) = n(n-1)F^{n-2}(1-F)f$. «یکی‌مانده‌به‌کوچک‌ترین» یعنی $k = 2$: $f(x) = n(n-1)F(1-F)^{n-2}f$.
برای یکنواخت، $X_{(k)} \sim \mathrm{Beta}(k, n-k+1)$ با میانگین $\frac{k}{n+1}$.

۳.۱۷ قضیه حد مرکزی (Central Limit Theorem)

۱.۳.۱۷ تعاریف

در تمامی این بخش، فرض کنید که دنباله متناهی متغیرهای تصادفی $X_1, X_2, \dots, X_n$ به صورت i.i.d. توزیع شده و دارای تابع چگالی احتمال $f_X(\cdot)$ هستند. فرض کنید میانگین و واریانس این توزیع وجود داشته و به ترتیب برابر با μ و σ^2 باشند. متغیرهای تصادفی جدید $\bar{X}_n$ و Z_n را مطابق با زیر تعریف می‌کنیم:

$$\bar{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}, \qquad Z_n = \frac{\sum_i (X_i - \mu)}{\sqrt{n}} = \sum_{i=1}^{n} \frac{X_i - \mu}{\sqrt{n}}.$$

هدف، بررسی توزیع‌های حدی این دو متغیر در حالت $n \to \infty$ است.

۲.۳.۱۷ مرور قانون اعداد بزرگ

در مورد متغیر تصادفی $\bar{X}_n$ (میانگین نمونه‌ای یا sample mean) پیش‌تر مفصلاً بحث شد:

- این متغیر تصادفی دارای میانگین μ است.
- همچنین، به دلیل فرض i.i.d. واریانس آن از طریق رابطه زیر محاسبه می‌شود:

$$\mathrm{Var}(\bar{X}_n) = \sum_i \mathrm{Var}\left(\frac{X_i}{n}\right) = \sum_i \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

- لذا واریانس در حد $n \to \infty$ برابر صفر شده، و متغیر تصادفی $\bar{X}_n$ در حد به مقدار یقینی μ میل می‌کند.

۳.۳.۱۷ ویژگی‌های Z_n

در مورد متغیر تصادفی Z_n (که انحراف $\bar{X}_n$ از μ را با ضریب $\sqrt{n}$ «بزرگ‌نمایی» می‌کند: $Z_n = \sqrt{n}(\bar{X}_n - \mu)$):

- این متغیر تصادفی دارای میانگین 0 است:

$$\mathbb{E}(Z_n) = \sum_i \left(\frac{\mathbb{E}X_i - \mu}{n^{1/2}}\right) = 0.$$

- به دلیل فرض i.i.d.، واریانس Z_n برابر با σ^2 خواهد بود:

$$\mathrm{Var}(Z_n) = \sum_i \mathrm{Var}\left(\frac{X_i - \mu}{n^{1/2}}\right) = \sum_i \frac{\sigma^2}{n} = \sigma^2.$$

پس میانگین و واریانس Z_n با n تغییر نمی‌کنند. **اما توزیع Z_n با افزایش n به چه توزیعی میل خواهد کرد؟**

۴.۳.۱۷ محاسبه توزیع حدی Z_n

فرض کنید داشته باشیم $X \sim f_X(x)$. متغیر تصادفی $X_c \triangleq X - \mu$ را به صورت نسخه مرکزی (یا zero-centered) از X تعریف می‌کنیم. همچنین، فرض کنید که تابع MGF متناظر با X_c، $M_{X_c}(t)$ باشد. می‌توان به راحتی دید که:

$$M_{(X_c n^{-1/2})}(t) = \mathbb{E}\left[e^{tX_c/\sqrt{n}}\right] = M_{X_c}\left(\frac{t}{\sqrt{n}}\right).$$

به دلیل فرض i.i.d.، و با توجه به خاصیت مطرح شده برای تابع MGF جمع (جلسه یازدهم)، می‌توان نوشت:

$$\boxed{M_{Z_n}(t) = \prod_{i=1}^{n} M_{X_c}\left(n^{-1/2}t\right) = M_{X_c}^n\left(n^{-1/2}t\right)}$$

همچنین، حقایق زیر را در مورد تابع $M(\cdot)$ می‌دانیم:

$$M_{X_c}(0) = 1, \qquad M'_{X_c}(0) = \mathbb{E}[X_c] = 0, \qquad M''_{X_c}(0) = \mathbb{E}[X_c^2] = \sigma^2.$$

در نتیجه (با فرض همگرایی سری تیلور)، می‌توان دید برای $|t| \ll 1$ داریم:

$$M_{X_c}(t) = M_{X_c}(0) + M'_{X_c}(0)t + \tfrac{1}{2}M''_{X_c}(0)t^2 + O(t^3) = 1 + \tfrac{1}{2}\sigma^2 t^2 + O(t^3).$$

برای $M_{Z_n}(t)$ خواهیم داشت (با قرار دادن $t/\sqrt{n}$ به جای t؛ برای t ثابت و n بزرگ، $t/\sqrt{n}$ کوچک است):

$$M_{Z_n}(t) = M^n_{X_c}\big(n^{-1/2}t\big) = \Big(1 + \frac{\sigma^2 t^2}{2n} + O\big(n^{-3/2}\big)\Big)^n,$$

و در حالت حدی، با استفاده از حد معروف $\lim_{n\to\infty}(1+\frac{a}{n}+o(\frac{1}{n}))^n = e^a$، می‌توان نوشت:

$$\boxed{\lim_{n\to\infty} M_{Z_n}(t) = \lim_{n\to\infty}\Big(1 + \frac{\sigma^2 t^2}{2n} + O\big(n^{-3/2}\big)\Big)^n = \exp\Big(\frac{1}{2}\sigma^2 t^2\Big)}$$

۵.۳.۱۷ توزیع حدی Z_n در $n \to \infty$

در نهایت، رابطه حدی زیر حاصل شد:

$$\lim_{n\to\infty} M_{Z_n}(t) = e^{\frac{\sigma^2 t^2}{2}},$$

که بیانگر تابع مولد گشتاور (و به طور معادل، تابع مشخصه) یک توزیع گاوسی با میانگین صفر و واریانس σ^2 است. به عبارت دیگر، متغیر تصادفی $\lim_{n\to\infty} Z_n$ رفتار یک **متغیر تصادفی گاوسی** با توزیع $\mathcal{N}(0,\sigma^2)$ را دارد.

قضیه ۱۷-۶: قضیه حد مرکزی

اگر $X_1, X_2, \ldots$ i.i.d. با میانگین μ و واریانس متناهی σ^2 باشند، آنگاه برای هر z:

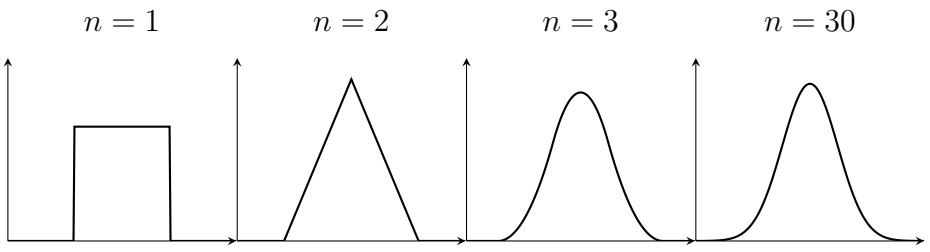
$$\lim_{n\to\infty} \mathbb{P}\Big(\frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}} \le z\Big) = \Phi(z).$$

نکته. شگفتی قضیه: توزیع اولیه X_i هر چه باشد (یکنواخت، نمایی، برنولی، ...)، مجموع تعداد زیادی از آن‌ها تقریباً گاوسی است. این توضیح می‌دهد که چرا توزیع گاوسی این‌قدر در طبیعت ظاهر می‌شود: بسیاری از کمیت‌ها (خطای اندازه‌گیری، نویز حرارتی، قد انسان) حاصل جمع تعداد زیادی اثر کوچک و تقریباً مستقل‌اند.
کاربرد عملی: $\sum_{i=1}^n X_i \approx \mathcal{N}(n\mu, n\sigma^2)$ و $\bar{X}_n \approx \mathcal{N}(\mu, \frac{\sigma^2}{n})$ برای n بزرگ.

۶.۳.۱۷ چند مثال

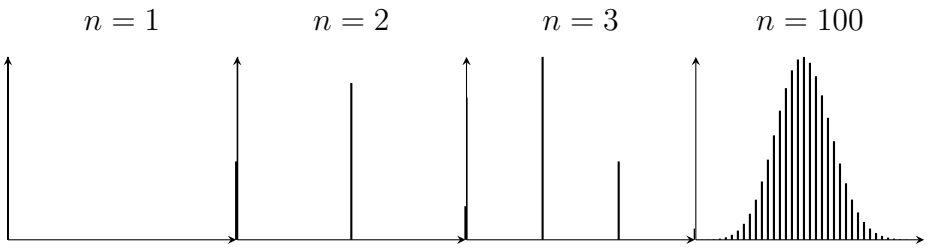
شکل‌های زیر توزیع Z_n را برای $n = 1, 2, 3$ و n بزرگ نشان می‌دهند:

توزیع پایه یکنواخت:



(برای $n=2$ مثلثی (جلسه قبل)، برای $n=3$ از سه قطعه سهمی تشکیل شده و هم‌اکنون بسیار شبیه گاوسی است.)

توزیع پایه برنولی (با $p=0.3$):



توزیع پایه گاوسی: ؟

پرسش: اگر توزیع پایه خودش گاوسی باشد، توزیع Z_n چیست؟

پاسخ. طبق جلسه قبل، جمع گاوسی‌های مستقل، دقیقاً گاوسی است: $\sum(X_i-\mu)\sim\mathcal{N}(0,n\sigma^2)$ و $Z_n\sim\mathcal{N}(0,\sigma^2)$ **برای هر** n ــ نه فقط در حد. توزیع گاوسی «نقطه ثابت» قضیه حد مرکزی است.

۷.۳.۱۷ تفسیر همگرایی در قضیه حد مرکزی (CLT)

با توجه به مثال‌هایی که در بالا دیده شد:

- در صورتی که تابع توزیع پایه، برای مثال، **یکنواخت** انتخاب شود، تابع چگالی احتمال (PDF) Z_n به صورت نقطه به نقطه به $\mathcal{N}(0,\sigma^2)$ همگرا خواهد شد.
- اما در صورتی که تابع توزیع پایه، برای مثال، **برنولی** انتخاب شود، چگالی احتمال Z_n همواره به صورت یک رشته ضربه (دلتای دیراک) باقی خواهد ماند و در عمل به هیچ تابعی همگرا نمی‌شود.

لذا همگرایی Z_n به یک متغیر تصادفی گاوسی مانند $Z^*\sim\mathcal{N}(0,\sigma^2)$ از حیث تابع چگالی احتمال نیست.

پرسش: وقتی می‌گوییم متغیر تصادفی Z_n به متغیر تصادفی Z^* همگرا خواهد شد، منظور از همگرایی چیست؟

پاسخ. منظور همگرایی **تابع اندازه احتمال** (Probability Measure) P یا معادلاً **تابع توزیع انباشته** $F_X(\cdot)$ میان دو متغیر است:

$$\lim_{n\to\infty} F_{Z_n}(z)=F_{Z^*}(z) \quad \text{برای هر} z.$$

به این نوع همگرایی، **همگرایی در توزیع** (convergence in distribution) می‌گویند و با $Z_n\xrightarrow{d}Z^*$ نشان می‌دهند. در مثال برنولی، CDF پله‌ای Z_n پله‌هایی با ارتفاع $O(1/\sqrt{n})$ و فاصله $O(1/\sqrt{n})$ دارد و به CDF هموار $\Phi(z/\sigma)$ نزدیک می‌شود، هرچند PMF/PDF آن هرگز به یک چگالی هموار تبدیل نمی‌شود. (به همین دلیل در عمل برای تقریب دوجمله‌ای با نرمال، از «تصحیح پیوستگی» استفاده می‌کنیم.)

۴.۱۷ تمرین‌های تکمیلی

تمرین ۱۷-۷

یک تاس سالم ۱۰۰ بار پرتاب می‌شود. با قضیه حد مرکزی، احتمال اینکه مجموع اعداد بین ۳۳۰ و ۳۷۰ باشد را تقریب بزنید.

حل. $\mu = 3.5$، $\sigma^2 = \frac{35}{12}$. مجموع $S \approx \mathcal{N}(350,\ 100 \times \frac{35}{12}) = \mathcal{N}(350, 291.7)$، $\sigma_S \approx 17.08$. $\mathbb{P}(330 \le S \le 370) \approx \Phi(\frac{20}{17.08}) - \Phi(-\frac{20}{17.08}) = 2\Phi(1.171) - 1 \approx 0.758$. ■

تمرین ۱۷-۸

یک سکه سالم ۴۰۰ بار پرتاب می‌شود. احتمال اینکه تعداد شیرها بیشتر از ۲۲۰ باشد را با CLT (با تصحیح پیوستگی) تقریب بزنید.

حل. $S \sim \mathrm{Bin}(400, \frac{1}{2})$، $\mathbb{E}S = 200$، $\sigma_S = \sqrt{100} = 10$. با تصحیح پیوستگی: $\mathbb{P}(S > 220) = \mathbb{P}(S \ge 221) \approx 1 - \Phi\big(\frac{220.5-200}{10}\big) = 1 - \Phi(2.05) \approx 0.020$. ■

تمرین ۱۷-۹

$X_1, \dots, X_5$ i.i.d. و $\mathrm{Exp}(1)$ هستند. احتمال اینکه بزرگ‌ترین آن‌ها کمتر از ۲ باشد، و توزیع کوچک‌ترین آن‌ها را بیابید.

حل. $\mathbb{P}(U < 2) = (1 - e^{-2})^5 \approx (0.8647)^5 \approx 0.483$. $f_L(\ell) = 5e^{-\ell}(e^{-\ell})^4 = 5e^{-5\ell}$؛ یعنی $L \sim \mathrm{Exp}(5)$ و $\mathbb{E}L = 0.2$. ■

تمرین ۱۷-۱۰

یک سرور ۴۸ درخواست مستقل را پردازش می‌کند که زمان هر کدام میانگین ۲ و انحراف معیار ۱ ثانیه دارد. احتمال اینکه کل زمان پردازش بیشتر از ۱۰۵ ثانیه باشد چقدر است؟

حل. $T \approx \mathcal{N}(96, 48)$، $\sigma_T \approx 6.93$. $\mathbb{P}(T > 105) \approx 1 - \Phi(\frac{9}{6.93}) = 1 - \Phi(1.30) \approx 0.097$. ■

جلسه ۱۸

نامساوی‌های احتمالاتی و مقدمه‌ای بر آمار

۱.۱۸ نامساوی‌های احتمالاتی (Probabilistic Inequalities)

در بسیاری از مسائل، توزیع دقیق یک متغیر تصادفی را نمی‌دانیم، اما برخی آماره‌های آن (مثل میانگین یا واریانس) را می‌دانیم. نامساوی‌های احتمالاتی به ما امکان می‌دهند تنها با همین اطلاعات ناقص، **کران**هایی برای احتمال رخدادهای «دور از انتظار» به دست آوریم.

۱.۱.۱۸ نامساوی مارکوف (Markov's Inequality)

قضیه ۱۸-۱: نامساوی مارکوف

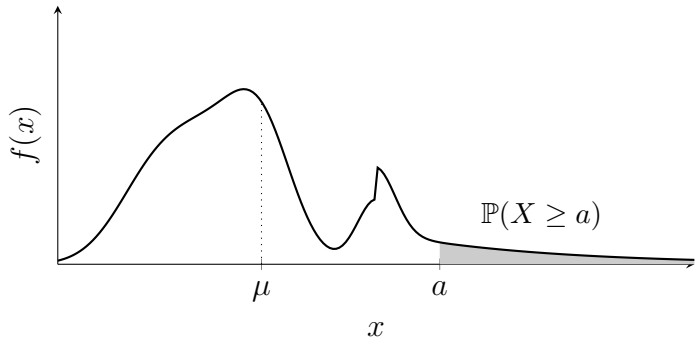
فرض کنید X یک متغیر تصادفی **نامنفی** باشد. در این صورت، برای هر $a > 0$ همواره داریم:

$$\boxed{\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}}$$

اثبات. چون $X \geq 0$:

$$\mathbb{E}(X) = \int_0^\infty x f_X(x)\,\mathrm{d}x \;\geq\; \int_a^\infty x f_X(x)\,\mathrm{d}x \;\geq\; \int_a^\infty a f_X(x)\,\mathrm{d}x = a\,\mathbb{P}(X \geq a).$$

(در نامساوی اول بخش $[0, a)$ را که نامنفی است دور ریختیم و در دومی از $x \geq a$ استفاده کردیم.) معادلاً به زبان متغیر نشانگر: $a\,\mathbf{1}(X \geq a) \leq X$ برای هر نمونه؛ با میانگین‌گیری $a\mathbb{P}(X \geq a) \leq \mathbb{E}X$. □



نکته. تعبیر: اگر میانگین درآمد یک جامعه ۱۰ میلیون باشد، حداکثر $\frac{1}{5}$ مردم می‌توانند درآمد ۵۰ میلیون یا بیشتر داشته باشند؛ وگرنه میانگین از ۱۰ بیشتر می‌شد. مارکوف به هیچ اطلاعی جز نامنفی بودن و میانگین نیاز ندارد، و به همین دلیل معمولاً کران «شُلی» است. برای $a \leq \mathbb{E}X$ کران بی‌اثر است (از ۱ بزرگ‌تر یا مساوی).

۲.۱.۱۸ نامساوی چبیشف (Chebyshev's Inequality)

قضیه ۱۸-۲: نامساوی چبیشف

فرض کنید متغیر تصادفی X دارای توزیعی با میانگین μ و واریانس σ^2 باشد. در این صورت، برای هر عدد حقیقی مثبت $k > 0$ داریم:

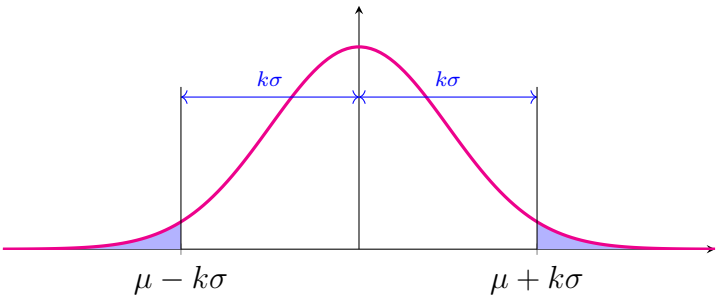
$$\boxed{\mathbb{P}\big(|X-\mu| \geq k\sigma\big) \leq \frac{1}{k^2}}$$

(معادلاً برای هر $\varepsilon > 0$: $\mathbb{P}(|X-\mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$.)

اثبات. متغیر نامنفی $Y = (X-\mu)^2$ را در نظر بگیرید که $\mathbb{E}Y = \sigma^2$. با نامساوی مارکوف روی Y با $a = k^2\sigma^2$:

$$\mathbb{P}(|X-\mu| \geq k\sigma) = \mathbb{P}\big((X-\mu)^2 \geq k^2\sigma^2\big) \leq \frac{\sigma^2}{k^2\sigma^2} = \frac{1}{k^2}.$$

□



احتمال دو دُم (ناحیه آبی) برای **هر** توزیعی حداکثر $1/k^2$ است.

مثال ۱۸-۳: مقایسه چبیشف با گاوسی

برای $k = 2$ و $k = 3$ کران چبیشف را با مقدار دقیق برای توزیع گاوسی مقایسه کنید.

حل.

k	کران چبیشف $1/k^2$	مقدار دقیق برای گاوسی
1	1	0.317
2	0.25	0.0455
3	0.111	0.0027

کران چبیشف بسیار محافظه‌کارانه است، اما برای **همه** توزیع‌ها با واریانس متناهی معتبر است. در

واقع این کران قابل بهبود نیست: توزیعی وجود دارد که آن را به تساوی می‌رساند ($X = \pm k\sigma$ هر کدام با احتمال $\frac{1}{2k^2}$ و $X = 0$ در بقیه موارد). ■

قضیه ۱۸-۴: اثبات قانون ضعیف اعداد بزرگ

اگر $X_1, X_2, \dots$ i.i.d. با میانگین μ و واریانس $\sigma^2 < \infty$ باشند، آنگاه برای هر $\varepsilon > 0$:

$$\mathbb{P}\big(|\bar{X}_n - \mu| \geq \varepsilon\big) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n\to\infty} 0.$$

اثبات. $\mathbb{E}\bar{X}_n = \mu$ و $\operatorname{Var}\bar{X}_n = \frac{\sigma^2}{n}$ (جلسه دهم). نامساوی چبیشف را روی $\bar{X}_n$ اعمال کنید. □

مثال ۱۸-۵: تعداد نمونه لازم

برای تخمین احتمال p یک رخداد با فرکانس نسبی در n آزمایش مستقل، چند آزمایش لازم است تا با احتمال دست‌کم ۹۵٪ خطا از 0.05 کمتر باشد؟

حل. $\bar{X}_n$ میانگین n برنولی با واریانس $\frac{p(1-p)}{n} \leq \frac{1}{4n}$ است. با چبیشف: $\mathbb{P}(|\bar{X}_n - p| \geq 0.05) \leq \frac{1}{4n(0.05)^2} = \frac{100}{n} \leq 0.05 \Rightarrow n \geq 2000$. (با تقریب CLT حدود $n \approx 385$ کافی است: $1.96\cdot\frac{0.5}{\sqrt{n}} \leq 0.05$؛ چبیشف به دلیل کلی بودن، کران محافظه‌کارانه‌تری می‌دهد.) ■

۲.۱۸ آمار (Statistics)

۱.۲.۱۸ آمار در مقابل احتمال

- **احتمال:** یک علم مجرد (abstract) است که ابتدا تعدادی اصول موضوعه تعریف کرده و سپس بر پایه آنان اقدام به تعاریف جانبی و اثبات احکام می‌نماید.
  - **اصول موضوعه:** فضای احتمال $(\Omega, \mathcal{F}, P)$ و اصول کولموگروف؛
  - **تعاریف جانبی:** احتمال شرطی، استقلال، متغیر تصادفی و ...؛
  - **احکام:** قانون بیز، قانون زنجیره‌ای، قضیه حد مرکزی، قانون اعداد بزرگ و ...
- **آمار:** به کاربرد احتمال در حل مسائل دنیای واقع اطلاق می‌گردد، در شرایطی که اصول موضوعه فوق وجود خارجی نداشته و ناچار به «استدلال‌های استقرایی بر پایه مشاهدات» هستیم.
- آمار در حالت کلی (به استثنای موارد خاص) علم کار کردن با مشاهدات و داده‌های واقعی است.

نکته. به بیان ساده: در **احتمال** مدل را می‌دانیم و درباره داده‌ها سؤال می‌کنیم (اگر سکه سالم باشد، احتمال ۷ شیر در ۱۰ پرتاب چقدر است؟). در **آمار** داده‌ها را داریم و درباره مدل سؤال می‌کنیم (۷ شیر در ۱۰ پرتاب دیده‌ایم؛ آیا سکه سالم است؟ احتمال شیر آن چقدر است؟). استدلال احتمالاتی «قیاسی» (از کل به جزء) و استدلال آماری «استقرایی» (از جزء به کل) است.

۲.۲.۱۸ توزیع‌های آماری (Statistical) در مقابل تجربی (Empirical)

- مفاهیم (توزیع، میانگین و ...) **آماری** به مقادیر، توابع و یا سایر مفاهیم یقینی اطلاق می‌گردد که یک موجود تصادفی را توصیف می‌کنند. برای مثال متغیر تصادفی X، دارای توزیع آماری $f_X(x)$ و میانگین آماری $\mathbb{E}(X)$ است که خود یقینی (deterministic) هستند.
- مفاهیم **تجربی** به تقریب مابه‌ازای آماری خود از روی تعدادی مشاهدات اطلاق می‌گردند (مفاهیم تجربی بر خلاف مابه‌ازاهای آماری **ماهیت تصادفی** دارند).
  - فرض کنید $X_1, X_2, \dots, X_n$ نمونه‌های مستقل گرفته شده از متغیر تصادفی X باشند.
  - توزیع انباشته تجربی $\hat{F}_X(x)$ و میانگین تجربی $\bar{X}_n$ به صورت زیر تعریف می‌شوند:

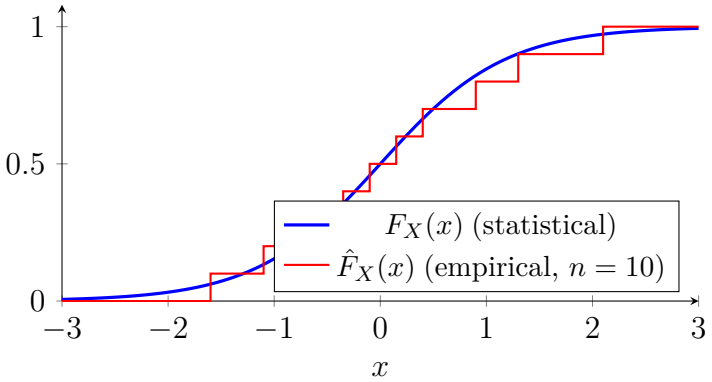
$$\hat{F}_X(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}(X_i \le x), \qquad \bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

  - مفاهیم تجربی فوق، خود متغیر تصادفی هستند (**چرا؟**). طبق قانون اعداد بزرگ، به ازای مقادیر بزرگ از n، مفاهیم تجربی (تحت شرایطی) به مابه‌ازاهای آماری خود میل می‌کنند.

پرسش: چرا مفاهیم تجربی، خود متغیر تصادفی هستند؟

پاسخ. زیرا توابعی از نمونه‌های تصادفی $X_1, \dots, X_n$ هستند. اگر آزمایش نمونه‌گیری را تکرار کنیم، نمونه‌های دیگری به دست می‌آید و در نتیجه $\bar{X}_n$ و $\hat{F}_X$ مقادیر دیگری خواهند داشت. در مقابل، $\mathbb{E}X$ و F_X اعدادی ثابت‌اند که به نمونه‌ها بستگی ندارند.

همگرایی: برای هر x ثابت، $\mathbf{1}(X_i \le x)$ متغیرهای برنولی i.i.d. با میانگین $F_X(x)$ هستند؛ پس $\hat{F}_X(x)$ میانگین نمونه‌ای آن‌هاست و طبق قانون اعداد بزرگ به $F_X(x)$ میل می‌کند (با $\mathbb{E}\hat{F}_X(x) = F_X(x)$ و $\operatorname{Var} \hat{F}_X(x) = \frac{F_X(x)(1-F_X(x))}{n}$). (قضیه گلیوِنکو–کانتلی حتی همگرایی یکنواخت روی همه x را تضمین می‌کند.)



۳.۱۸ سرفصل‌های اصلی آمار

۱.۳.۱۸ تخمین (Estimation)

متغیر تصادفی $X \sim f_X(x;\theta)$ را فرض نمایید، که در اینجا θ بیانگر یک یا چند پارامتر مربوط به توزیع باشند که نامعلوم هستند. فرض کنید که n نمونه مستقل از X به صورت $(X_1, X_2, \dots, X_n)$ در دسترس باشند.

- **تخمین نقطه‌ای (Point Estimation):** به دست آوردن تخمینی بهینه از پارامتر θ به صورت $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. (مثال: $\hat{\mu} = \bar{X}_n$ برای میانگین.)
- **تخمین بازه‌ای (Interval Estimation):** فرض کنید θ یک‌بعدی باشد. هدف به دست آوردن بازه‌ای مانند (θ_l, θ_u) است به طوری که $\mathbb{P}(\theta_l < \theta < \theta_u) \geq 1 - \delta$. (به این بازه «بازه اطمینان» با سطح $1-\delta$ می‌گویند؛ دقت کنید که θ_l, θ_u توابعی از نمونه‌ها و در نتیجه تصادفی‌اند.)
- **تخمین Bayesian:** فرض کنید $\theta \sim f_\Theta(\cdot)$ یک متغیر تصادفی باشد. هدف به دست آوردن آماره‌های مرتبط با θ بعد از مشاهده نمونه‌هاست (یعنی توزیع پسین $f_{\Theta|X}$ با قانون بیز، مانند مثال سکه با احتمال نامعلوم در جلسه نهم).

نکته. مبحث تخمین بسیار گسترده بوده و اشکال غیرآماری نیز دارد. برای مثال، یکی از شکل‌های تخمین، تقریب مقدار یک متغیر تصادفی با استفاده از متغیرهای تصادفی وابسته به آن است (مثلاً تخمین X از روی مشاهده Y). در اینجا، بر خلاف سناریوی شرح داده شده، توزیع مشترک تمام متغیرهای تصادفی دانسته فرض می‌شود. **تخمین میانگین مربع** (Mean Square Estimation) از این جمله است و جلوتر مطرح خواهد گشت.

مثال ۱۸-۶: تخمین بازه‌ای با CLT

از یک جامعه، ۱۰۰ نمونه گرفته‌ایم و میانگین نمونه‌ای $\bar{X} = 50$ به دست آمده است. اگر بدانیم $\sigma = 10$، یک بازه اطمینان ۹۵٪ برای μ بیابید.

حل. طبق CLT، $\bar{X} \approx \mathcal{N}(\mu, \frac{\sigma^2}{n}) = \mathcal{N}(\mu, 1)$. پس $\mathbb{P}(|\bar{X} - \mu| \leq 1.96) \approx 0.95$، که معادل است با $\mathbb{P}(\bar{X} - 1.96 \leq \mu \leq \bar{X} + 1.96) \approx 0.95$. بازه: $[48.04,\ 51.96]$. ■

۲.۳.۱۸ آزمون فرض (Hypothesis Testing)

متغیر تصادفی $X \sim f_X(x;\theta)$ با بردار پارامترهای نامعلوم θ را در نظر بگیرید. فرض کنید که n نمونه مستقل از X به صورت $(X_1, \dots, X_n)$ در دسترس باشند.

- هدف پاسخ دادن به سؤالی در مورد پارامتر(های) θ است. برای مثال: آیا $\theta = \theta_0$ یا خیر؟
- آزمون فرض کاربرد فراوانی در مطالعات آماری پزشکی و جامعه‌شناسی دارد (مثلاً: آیا یک داروی جدید اثری دارد یا تفاوت مشاهده‌شده تصادفی است؟).

مثال ۱۸-۷: آیا سکه سالم است؟

سکه‌ای را ۱۰۰ بار پرتاب کرده‌ایم و ۶۵ شیر آمده است. آیا می‌توان گفت سکه سالم است؟

حل. فرض صفر H_0: $p = \frac{1}{2}$. تحت H_0، تعداد شیرها $S \sim \text{Bin}(100, \frac{1}{2}) \approx \mathcal{N}(50, 25)$. احتمال

مشاهده نتیجه‌ای حداقل به این اندازه دور از ۵۰: $\mathbb{P}(|S-50| \geq 15) \approx 2(1-\Phi(\frac{14.5}{5})) = 2(1-\Phi(2.9)) \approx 0.004$. این احتمال (که «مقدار p» یا p-value نام دارد) بسیار کوچک است؛ پس شواهد قوی علیه سالم بودن سکه داریم و H_0 را رد می‌کنیم. (مقایسه کنید با مثال جلسه سوم: انحراف ۱۰٪ از میانگین برای $n=100$ حدود ۵٫۳٪ احتمال داشت.) ■

۳.۳.۱۸ پیش‌بینی (Prediction)

فرض کنید مدل تولید نمونه‌های تصادفی (منظور همان توزیع $f_X(x)$ است) معلوم است. در این صورت، هدف پیش‌بینی مقادیر تجربه مشاهدات آینده است:

- برای مثال، اگر اقدام به گرفتن n نمونه به صورت i.i.d. از $f_X(x)$ نماییم، توزیع میانگین تجربی $\bar{X}_n$ چه چیزی خواهد بود؟ (پاسخ تقریبی: $\mathcal{N}(\mu, \sigma^2/n)$ طبق CLT.)
- یا، در صورتی که احتمال موفقیت یک آزمایش مانند A معلوم باشد، احتمال اینکه در n بار انجام این آزمایش در آینده، تعداد آزمون‌های موفق چه توزیعی دارد؟ (پاسخ: $\text{Bin}(n, \mathbb{P}(A))$.)

۴.۱۸ بهینگی (Optimality)

- در بحث تخمین، بارها عبارت بهترین تخمین‌گر (یا Optimal Estimator) شنیده خواهد شد. اما مقصود از **بهترین** چیست؟
- **بسیار مهم:** تعریفی جهان‌شمول و یکتا برای بهترین وجود ندارد.
- صفت بهترین، همواره با توجه به یک حیث (یا sense) تعریف می‌شود. به عبارت صریح‌تر، یک معیار کمّی خطا/خوبی مانند $\ell(\theta, \hat{\theta})$ را فرض نموده و سپس ادعا می‌کنیم تخمین‌گر $\hat{\theta}$ آن را کمینه/بیشینه می‌نماید.

مثال ۱۸-۸: بهترین تخمین ثابت با معیارهای مختلف

فرض کنید باید مقدار یک متغیر تصادفی X را (بدون هیچ مشاهده‌ای) با یک عدد ثابت c «پیش‌بینی» کنیم. بهترین c چیست؟

حل.

- با معیار **خطای مربعی** $\ell = \mathbb{E}[(X-c)^2]$: $\mathbb{E}[(X-c)^2] = \text{Var}\, X + (\mathbb{E}X - c)^2$ که در $c = \mathbb{E}X$ کمینه است. پس بهترین c **میانگین** است.
- با معیار **خطای مطلق** $\ell = \mathbb{E}|X-c|$: مشتق نسبت به c برابر $\mathbb{P}(X<c) - \mathbb{P}(X>c)$ است که در **میانه** صفر می‌شود. پس بهترین c میانه است.
- با معیار **احتمال خطای صفر–یک** (برای متغیر گسسته) $\ell = \mathbb{P}(X \neq c)$: بهترین c **مُد** است.

این مثال به‌روشنی نشان می‌دهد که «بهترین» بدون مشخص کردن معیار معنا ندارد؛ و سه آماره جلسه دهم (میانگین، میانه، مد) هر کدام تحت یک معیار بهینه‌اند. ■

۵.۱۸ تمرین‌های تکمیلی

تمرین ۱۸-۹

تعداد درخواست‌های روزانه یک سایت به طور متوسط ۱۰۰۰ است. (الف) با مارکوف، کرانی برای احتمال بیش از ۲۰۰۰ درخواست بیابید. (ب) اگر انحراف معیار ۱۰۰ باشد، با چبیشف کران بهتری بیابید.

حل. (الف) $\mathbb{P}(X \geq 2000) \leq \frac{1000}{2000} = 0.5$. (ب) $\mathbb{P}(X \geq 2000) \leq \mathbb{P}(|X - 1000| \geq 1000) \leq \frac{100^2}{1000^2} = 0.01$. دانستن واریانس، کران را ۵۰ برابر بهتر کرد. ■

تمرین ۱۸-۱۰

نشان دهید برای هر متغیر تصادفی با میانگین μ و واریانس σ^2، دست‌کم ۷۵٪ احتمال در بازه $[\mu - 2\sigma, \mu + 2\sigma]$ قرار دارد.

حل. با چبیشف و $k = 2$: $\mathbb{P}(|X - \mu| < 2\sigma) \geq 1 - \frac{1}{4} = 0.75$. ■

تمرین ۱۸-۱۱

با استفاده از نامساوی مارکوف روی e^{tX}، نشان دهید برای هر $t > 0$: $\mathbb{P}(X \geq a) \leq e^{-ta} M_X(t)$ (کران چرنوف). سپس برای $X \sim \mathcal{N}(0,1)$ بهترین کران را بیابید.

حل. چون e^{tX} نامنفی و $x \mapsto e^{tx}$ صعودی است: $\mathbb{P}(X \geq a) = \mathbb{P}(e^{tX} \geq e^{ta}) \leq \frac{\mathbb{E}e^{tX}}{e^{ta}}$. برای گاوسی استاندارد: $e^{-ta + t^2/2}$ که در $t = a$ کمینه می‌شود: $\mathbb{P}(X \geq a) \leq e^{-a^2/2}$. این کران نمایی (برخلاف چبیشف که $\frac{1}{a^2}$ است) رفتار واقعی دم گاوسی را به خوبی نشان می‌دهد. ■

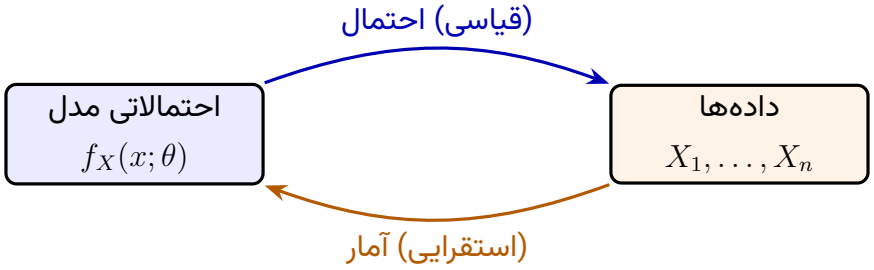
جلسه ۱۹

آمار: مفاهیم تجربی، تخمین، آزمون فرض و پیش‌بینی (تعمیق)

نکته. اسلایدهای جلسه نوزدهم همان مباحث بخش «آمار» جلسه هجدهم (آمار در مقابل احتمال، توزیع آماری در مقابل تجربی، سرفصل‌های اصلی آمار و بهینگی) را مرور و تکمیل می‌کنند. برای پرهیز از تکرار، در این فصل خلاصه‌ای از آن مطالب آورده و سپس هر سرفصل را با جزئیات بیشتر، مثال‌های حل‌شده و ابزارهای لازم برای جلسات بعد (تخمین نقطه‌ای و تخمین میانگین مربع) گسترش می‌دهیم.

۱.۱۹ خلاصه: آمار در مقابل احتمال

- **احتمال** علمی مجرد است: با اصول موضوعه (فضای احتمال $(\Omega, \mathcal{F}, P)$ و اصول کولموگروف) شروع می‌کند، تعاریف جانبی (احتمال شرطی، استقلال، متغیر تصادفی، ...) می‌سازد و احکامی (قانون بیز، قانون زنجیره‌ای، قضیه حد مرکزی، قانون اعداد بزرگ، ...) را اثبات می‌کند.
- **آمار** کاربرد احتمال در دنیای واقع است، جایی که مدل دقیق را نداریم و ناچار به «استدلال‌های استقرایی بر پایه مشاهدات» هستیم. آمار در حالت کلی علم کار کردن با داده‌های واقعی است.



۲.۱۹ مفاهیم تجربی و ویژگی‌های آن‌ها

۱.۲.۱۹ توزیع انباشته تجربی

اگر $X_1, \dots, X_n$ نمونه‌های i.i.d. از X با CDF آماری F_X باشند، توزیع انباشته تجربی و میانگین تجربی عبارت‌اند از:

$$\hat{F}_X(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}(X_i \le x), \qquad \bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

$\hat{F}_X$ یک تابع پله‌ای است که در هر نمونه X_i به اندازه $\frac{1}{n}$ بالا می‌رود؛ یعنی توزیعی است که به هر نمونه مشاهده‌شده جرم احتمال $\frac{1}{n}$ می‌دهد. پس $\bar{X}_n$ دقیقاً میانگین همین توزیع تجربی است.

قضیه ۱۹-۱: ویژگی‌های CDF تجربی

برای هر x ثابت، $n\hat{F}_X(x) \sim \mathrm{Bin}\big(n, F_X(x)\big)$. در نتیجه:

$$\mathbb{E}\big[\hat{F}_X(x)\big] = F_X(x), \qquad \mathrm{Var}\left[\hat{F}_X(x)\right] = \frac{F_X(x)\big(1-F_X(x)\big)}{n} \xrightarrow{n\to\infty} 0.$$

اثبات. $Y_i = \mathbf{1}(X_i \le x)$ متغیرهای برنولی i.i.d. با احتمال موفقیت $\mathbb{P}(X_i \le x) = F_X(x)$ هستند. $n\hat{F}_X(x) = \sum Y_i$ جمع n برنولی مستقل، یعنی دوجمله‌ای است. میانگین و واریانس از جدول جلسه دهم به دست می‌آیند. □

نکته. این قضیه پاسخ پرسش «**چرا** مفاهیم تجربی متغیر تصادفی‌اند؟» را دقیق‌تر می‌کند: $\hat{F}_X(x)$ برای هر x یک متغیر تصادفی (دوجمله‌ای تقسیم بر n) است. «به طور متوسط درست» است (میانگینش برابر مقدار آماری است) و پراکندگی‌اش با $\frac{1}{\sqrt{n}}$ کم می‌شود. بیشترین پراکندگی در میانه توزیع ($F_X(x) = \frac{1}{2}$) رخ می‌دهد.

۲.۲.۱۹ هیستوگرام: تقریب تجربی چگالی

برای تقریب PDF، محور را به بازه‌های $[a_k, a_k + h)$ تقسیم و کسر نمونه‌های هر بازه را بر h تقسیم می‌کنیم:

$$\hat{f}_X(x) = \frac{1}{nh}\#\{i : \ X_i \in [a_k, a_k + h)\}, \qquad x \in [a_k, a_k + h).$$

طبق قانون اعداد بزرگ، وقتی $n \to \infty$ این مقدار به $\frac{1}{h}\mathbb{P}(X \in [a_k, a_k + h))$ میل می‌کند که برای h کوچک تقریباً $f_X(x)$ است (تعریف چگالی در جلسه هفتم). دوباره یک «مصالحه» داریم: h کوچک دقت مکانی بیشتر ولی نوسان تصادفی بیشتر (نمونه‌های کمتر در هر بازه) می‌دهد.

۳.۲.۱۹ واریانس تجربی و ضریب $\frac{1}{n-1}$

قضیه ۱۹-۲: واریانس نمونه‌ای

برای نمونه‌های i.i.d. با واریانس σ^2:

$$S_n^2 \triangleq \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X}_n)^2 \;\Rightarrow\; \mathbb{E}\big[S_n^2\big]=\sigma^2. \qquad \text{پس} \qquad \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X}_n)^2\Big]=\frac{n-1}{n}\sigma^2,$$

اثبات. با اتحاد $\sum(X_i-\bar{X})^2=\sum(X_i-\mu)^2-n(\bar{X}-\mu)^2$ (بسط دهید و از $\sum(X_i-\mu)=n(\bar{X}-\mu)$ استفاده کنید):

$$\mathbb{E}\sum(X_i-\bar{X})^2=n\sigma^2-n\,\mathrm{Var}(\bar{X})=n\sigma^2-n\cdot\frac{\sigma^2}{n}=(n-1)\sigma^2.$$

□

شهود: انحراف‌ها از $\bar{X}_n$ (که خودش از روی همین داده‌ها و «نزدیک به آن‌ها» انتخاب شده) به طور سیستماتیک کوچک‌تر از انحراف‌ها از μ واقعی‌اند؛ تقسیم بر $n-1$ این کم‌برآوردی را جبران می‌کند. (به $n-1$ «درجات آزادی» می‌گویند: یک درجه آزادی صرف تخمین میانگین شده است.) این مفهوم در جلسه بعد با نام «گرایش» (Bias) دقیق می‌شود.

۳.۱۹ تخمین (Estimation)

متغیر تصادفی $X \sim f_X(x;\theta)$ با پارامتر(های) نامعلوم θ و نمونه‌های مستقل $X_1,\dots,X_n$ را در نظر بگیرید.

۱.۳.۱۹ تخمین نقطه‌ای

هدف: تابعی $\hat{\theta}=\hat{\theta}(X_1,\dots,X_n)$ که «به‌خوبی» θ را تقریب بزند. مثال‌ها:

مدل	پارامتر	تخمین‌گر طبیعی
$\mathrm{Bern}(p)$	p	$\hat{p}=\bar{X}_n$ (فرکانس نسبی)
$\mathcal{N}(\mu,\sigma^2)$	$\mu,\ \sigma^2$	$\hat{\mu}=\bar{X}_n,\quad \hat{\sigma}^2=S_n^2$
$\mathrm{Exp}(\lambda)$	λ	$\hat{\lambda}=1/\bar{X}_n$ (چون $\mathbb{E}X=1/\lambda$)
$\mathcal{U}(0,\theta)$	θ	$\hat{\theta}=\max_i X_i$ یا $\hat{\theta}=2\bar{X}_n$
$\mathrm{Pois}(\lambda)$	λ	$\hat{\lambda}=\bar{X}_n$

دقت کنید که برای یک پارامتر می‌توان چند تخمین‌گر متفاوت ساخت (مثل $\mathcal{U}(0,\theta)$)؛ اینکه کدام «بهتر» است، به معیار بهینگی بستگی دارد (بخش آخر و جلسه بعد).

۲.۳.۱۹ تخمین بازه‌ای

هدف: بازه تصادفی (θ_l, θ_u) با $\mathbb{P}(\theta_l < \theta < \theta_u) \geq 1-\delta$.

قضیه ۱۹-۳: بازه اطمینان برای میانگین

اگر $X_i \sim \mathcal{N}(\mu, \sigma^2)$ با σ معلوم باشند (یا به طور تقریبی، طبق CLT، برای n بزرگ و هر توزیعی):

$$\mathbb{P}\Big(\bar{X}_n - z_{\delta/2}\frac{\sigma}{\sqrt{n}} < \mu < \bar{X}_n + z_{\delta/2}\frac{\sigma}{\sqrt{n}}\Big) = 1-\delta,$$

که در آن $z_{\delta/2}$ عددی است که $\mathbb{P}(Z > z_{\delta/2}) = \frac{\delta}{2}$ (مثلاً $z_{0.025} = 1.96$ برای ۹۵٪ و $z_{0.005} = 2.576$ برای ۹۹٪).

اثبات. $Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$. پس $\mathbb{P}(|Z| < z_{\delta/2}) = 1-\delta$ و با جابه‌جا کردن نامساوی برای μ حکم به دست می‌آید. □

دقت کنید! تعبیر درست بازه اطمینان: μ عددی ثابت (غیرتصادفی) است و این **بازه** است که تصادفی است. «بازه ۹۵٪» یعنی اگر آزمایش نمونه‌گیری را بارها تکرار کنیم، حدود ۹۵٪ بازه‌های ساخته‌شده μ را دربر می‌گیرند؛ نه اینکه «μ با احتمال ۹۵٪ در این بازه مشخص است».

مثال ۱۹-۴: نظرسنجی

در یک نظرسنجی از ۱۶۰۰ نفر، ۸۸۰ نفر موافق بودند. بازه اطمینان ۹۵٪ برای نسبت موافقان در جامعه را بیابید.

حل. $\hat{p} = \frac{880}{1600} = 0.55$. انحراف معیار $\hat{p}$ برابر $\sqrt{p(1-p)/n} \approx \sqrt{0.55\times 0.45/1600} \approx 0.0124$. بازه: $0.55 \pm 1.96 \times 0.0124 = 0.55 \pm 0.024$، یعنی $[0.526,\ 0.574]$. («حاشیه خطای» نظرسنجی حدود 2.4% است.) ■

۳.۳.۱۹ تخمین بیزی

در دیدگاه بیزی، θ خودش متغیر تصادفی با توزیع پیشین f_Θ است و پس از مشاهده داده‌ها توزیع پسین را حساب می‌کنیم:

$$f_{\Theta|X_{1:n}}(\theta \mid x_{1:n}) = \frac{f_\Theta(\theta)\prod_i f_X(x_i;\theta)}{\int f_\Theta(t)\prod_i f_X(x_i;t)\,dt}.$$

از روی پسین می‌توان تخمین نقطه‌ای (میانگین پسین، مُد پسین یا میانه پسین) و «بازه باورپذیری» ساخت.

مثال ۱۹-۵: پسین بتا و میانگین پسین

برای سکه‌ای با احتمال شیر نامعلوم و پیشین یکنواخت، پس از k شیر در n پرتاب، پسین $\mathrm{Beta}(k+1, n-k+1)$ است (جلسه نهم). میانگین پسین $\frac{k+1}{n+2}$ و مُد پسین $\frac{k}{n}$ است. برای $n=3, k=3$: تخمین فرکانسی $\hat{p}=1$ (یعنی «سکه هرگز خط نمی‌آورد»!)، اما میانگین پسین $0.8 = \frac{4}{5}$ که معقول‌تر است. پیشین مانند «نمونه‌های مجازی» عمل می‌کند و تخمین را در داده‌های کم پایدار می‌سازد.

۴.۱۹ آزمون فرض (Hypothesis Testing)

تعریف ۱۹-۶: اجزای آزمون فرض

- **فرض صفر** H_0 (مثلاً $\theta = \theta_0$) و **فرض مقابل** H_1 (مثلاً $\theta \neq \theta_0$).
- یک **آماره آزمون** $T(X_1, \dots, X_n)$ و یک **ناحیه رد** R: اگر $T \in R$، H_0 را رد می‌کنیم.
- **خطای نوع اول:** رد H_0 در حالی که درست است؛ احتمال آن **سطح معناداری** α نام دارد.
- **خطای نوع دوم:** نپذیرفتن H_1 در حالی که درست است؛ احتمال آن β و $1-\beta$ «توان آزمون» است.

	H_0 درست است	H_1 درست است
H_0 را رد نمی‌کنیم	تصمیم درست $(1-\alpha)$	خطای نوع دوم (β)
H_0 را رد می‌کنیم	خطای نوع اول (α)	تصمیم درست $(1-\beta)$

نکته. این همان ساختار مثال «آزمایش پزشکی» جلسه چهارم است: مثبت کاذب (خطای نوع اول) و منفی کاذب (خطای نوع دوم). کاهش هم‌زمان هر دو خطا با n ثابت ممکن نیست؛ با تنگ کردن ناحیه رد، α کم و β زیاد می‌شود. تنها راه کاهش هر دو، افزایش تعداد نمونه است.

مثال ۱۹-۷: آزمون میانگین

یک کارخانه ادعا می‌کند وزن متوسط بسته‌هایش $\mu_0 = 500$ گرم با انحراف معیار ۱۰ گرم است. ۲۵ بسته تصادفی وزن متوسط ۴۹۵ گرم دارند. در سطح $\alpha = 0.05$ آیا ادعا رد می‌شود؟

حل. تحت H_0: $Z = \frac{\bar{X}-500}{10/\sqrt{25}} = \frac{-5}{2} = -2.5$. ناحیه رد (دوطرفه) $|Z| > 1.96$ است. چون $|-2.5| > 1.96$، H_0 رد می‌شود. مقدار p: $\mathbb{P}(|Z| \geq 2.5) = 2(1-\Phi(2.5)) \approx 0.012 < 0.05$. ■

۵.۱۹ پیش‌بینی (Prediction)

در پیش‌بینی، مدل f_X معلوم است و درباره داده‌های آینده سؤال می‌کنیم. دو مثال اسلاید را حل می‌کنیم:

مثال ۱۹-۸: پیش‌بینی میانگین تجربی

اگر n نمونه i.i.d. از f_X بگیریم، $\bar{X}_n$ چه توزیعی دارد؟

حل. در حالت کلی $\mathbb{E}\bar{X}_n = \mu$ و $\operatorname{Var}\bar{X}_n = \frac{\sigma^2}{n}$؛ برای n بزرگ طبق CLT: $\bar{X}_n \approx \mathcal{N}(\mu, \frac{\sigma^2}{n})$. اگر f_X گاوسی باشد این رابطه دقیق است؛ اگر f_X نمایی با نرخ λ باشد، $n\bar{X}_n$ دقیقاً ارلانگ مرتبه n است (جلسه شانزدهم). ■

مثال ۱۹-۹: پیش‌بینی تعداد موفقیت‌ها

اگر احتمال موفقیت یک آزمایش A برابر p باشد، تعداد موفقیت‌ها در n تکرار مستقل آینده چه توزیعی دارد؟ برای $p=0.9$ و $n=20$، احتمال اینکه دست‌کم ۱۸ آزمایش موفق باشند چقدر است؟

حل. $N \sim \mathrm{Bin}(n,p)$. $\mathbb{P}(N \ge 18) = \sum_{k=18}^{20} \binom{20}{k} 0.9^k 0.1^{20-k} = 0.2852 + 0.2702 + 0.1216 \approx 0.677$. ■

۶.۱۹ بهینگی: یادآوری

«بهترین» تخمین‌گر بدون مشخص کردن یک معیار $\ell(\theta, \hat\theta)$ معنا ندارد. سه معیار رایج:

معیار	فرمول	بهترین ثابت c برای تقریب X
خطای مربعی	$\mathbb{E}(X-c)^2$	میانگین $\mathbb{E}X$
خطای مطلق	$\mathbb{E}\lvert X-c\rvert$	میانه
خطای صفر–یک	$\mathbb{P}(X \neq c)$	مُد

معیار خطای مربعی (MSE) به دلیل سادگی جبری و ارتباط مستقیم با واریانس، پرکاربردترین است و موضوع اصلی جلسه بعد خواهد بود.

۷.۱۹ تمرین‌های تکمیلی

تمرین ۱۹-۱۰

داده‌های $\{2.1,\ 3.4,\ 1.7,\ 2.9,\ 3.9\}$ از توزیعی نامعلوم به دست آمده‌اند. $\bar X$، S^2 و $\hat F_X(3)$ را حساب کنید.

حل. $\bar X = \frac{14}{5} = 2.8$. انحراف‌ها: $-0.7, 0.6, -1.1, 0.1, 1.1$؛ مجموع مربعات $= 0.49 + 0.36 + 1.21 + 0.01 + 1.21 = 3.28$. $S^2 = \frac{3.28}{4} = 0.82$. $\hat F_X(3) = \frac{3}{5} = 0.6$ (سه نمونه ≤ 3). ■

تمرین ۱۹-۱۱

برای $\mathcal{U}(0,\theta)$، میانگین تخمین‌گرهای $\hat\theta_1 = 2\bar X_n$ و $\hat\theta_2 = \max_i X_i$ را بیابید. کدام «به طور متوسط» درست است؟

حل. $\mathbb{E}\hat\theta_1 = 2 \cdot \frac{\theta}{2} = \theta$. برای بیشینه، طبق جلسه هفدهم با مقیاس θ: $\mathbb{E}\max = \frac{n}{n+1}\theta$. پس $\hat\theta_1$ به طور متوسط درست است ولی $\hat\theta_2$ همیشه کمی کمتر از θ تخمین می‌زند (که البته با ضریب $\frac{n+1}{n}$ قابل اصلاح است). مقایسه کامل این دو با معیار MSE در جلسه بعد آمده است. ■

تمرین ۱۹-۱۲

چند نفر باید در یک نظرسنجی شرکت کنند تا حاشیه خطای ۹۵٪ حداکثر ۲٪ باشد (بدترین حالت $p = 0.5$)؟

حل. $1.96\sqrt{\frac{0.25}{n}} \leq 0.02 \Rightarrow \sqrt{n} \geq \frac{1.96 \times 0.5}{0.02} = 49 \Rightarrow n \geq 2401$. ■

جلسه ۲۰

تخمین میانگین مربع و مقدمه تخمین نقطه‌ای

۱.۲۰ تخمین میانگین مربع (Mean Square Estimation)

۱.۱.۲۰ تخمین‌گر میانگین مربع

- در این نوع از تخمین‌گرها، بر خلاف سناریوهای آماری مطرح شده در جلسات قبل، تعدادی نمونه از متغیر(های) تصادفی موجود نبوده و به جای آن **خود توزیع مشترک** را در اختیار داریم.
- **حالت ساده:** هدف، یافتن یک تابع بهینه برای تخمین زدن مقدار متغیر تصادفی Y به فرض دانستن مقدار متغیر تصادفی X است، به شرط آنکه توزیع مشترک $f_{XY}(x,y)$ در دسترس باشد.
- **حالت پیچیده:** هدف می‌تواند تخمین بهینه چند متغیر تصادفی از روی چند متغیر تصادفی دیگر باشد.
- این شکل از تخمین (تحت شرایطی) در مبحث **پیش‌بینی** نیز کاربرد فراوان دارد (مثلاً پیش‌بینی قیمت فردا از روی قیمت امروز، یا تخمین سیگنال ارسالی از روی سیگنال نویزی دریافتی).

معیار بهینگی در همه این بخش‌ها **خطای میانگین مربعات** (Mean Squared Error, MSE) است.

۲.۱.۲۰ تخمین غیرشرطی (Unconditional)

پرسش: متغیر تصادفی X با چگالی معلوم $f_X(x)$ را در نظر بگیرید. می‌خواهیم آن را با مقدار ثابت c تخمین بزنیم؛ c را چنان بیابید که $\mathrm{MSE} = \mathbb{E}[(X-c)^2]$ کمینه شود.

پاسخ. عبارت

$$\mathbb{E}\big[(X-c)^2\big] = \int_{\mathbb{R}} (x-c)^2 f_X(x)\,\mathrm{d}x$$

به صورت تابعی از مقدار نامعلوم c قابل نوشتن است. از طرفی واضح است که در حدود $c \to \pm\infty$ مقدار خطای میانگین مربع به سمت بی‌نهایت میل می‌کند. در نتیجه، تابع فوق به ازای مقداری از c کمینه است. این مقدار را با استفاده از مشتق‌گیری پیدا می‌کنیم:

$$\frac{\partial}{\partial c}\mathbb{E}\big[(X-c)^2\big] = \mathbb{E}\big[2(c-X)\big] = 0 \;\Rightarrow\; \boxed{c = \mathbb{E}(X)}$$

کمینه خطا برابر $\mathbb{E}[(X-\mathbb{E}X)^2]=\mathrm{Var}(X)$ است. (معادلاً: $\mathbb{E}(X-c)^2=\mathrm{Var}\,X+(\mathbb{E}X-c)^2$.)

۳.۱.۲۰ تخمین‌گر MS خطی همگن

پرسش: متغیرهای X,Y با چگالی مشترک معلوم f_{XY} را در نظر بگیرید. می‌خواهیم Y را به شکل $\hat{Y}=aX$ از روی X تخمین بزنیم. ضریب a را چنان بیابید که $\mathbb{E}[(Y-aX)^2]$ کمینه شود.

پاسخ. مشابه با قبل عمل می‌کنیم:

$$\mathbb{E}\big[(Y-aX)^2\big]=\iint_{\mathbb{R}^2}(y-ax)^2 f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

بعد از مشتق‌گیری خواهیم داشت:

$$\frac{\partial}{\partial a}\mathbb{E}\big[(Y-aX)^2\big]=\mathbb{E}\big[2X(aX-Y)\big]=0\ \Rightarrow\ \boxed{a=\frac{\mathbb{E}(XY)}{\mathbb{E}(X^2)}=\frac{m_{1,1}}{m_{2,0}}}$$

۴.۱.۲۰ تخمین‌گر MS خطی غیرهمگن

پرسش: این بار Y را به شکل $\hat{Y}=aX+b$ تخمین می‌زنیم. ضرایب a,b را چنان بیابید که $\mathbb{E}[(Y-aX-b)^2]$ کمینه شود.

پاسخ. مشابه با قبل عمل می‌کنیم، اما این بار دو مجهول داریم:

$$\mathbb{E}\big[(Y-aX-b)^2\big]=\iint_{\mathbb{R}^2}(y-ax-b)^2 f_{XY}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

بعد از مشتق‌گیری خواهیم داشت:

$$\frac{\partial}{\partial a}\mathbb{E}\big[(Y-aX-b)^2\big]=\mathbb{E}\big[2X(aX+b-Y)\big]=0\ \Rightarrow\ a\mathbb{E}(X^2)+b\mathbb{E}(X)=\mathbb{E}(XY),$$

$$\frac{\partial}{\partial b}\mathbb{E}\big[(Y-aX-b)^2\big]=\mathbb{E}\big[2(aX+b-Y)\big]=0\ \Rightarrow\ b=\mathbb{E}(Y)-a\mathbb{E}(X).$$

با جایگذاری b در معادله اول: $a\big(\mathbb{E}X^2-(\mathbb{E}X)^2\big)=\mathbb{E}(XY)-\mathbb{E}X\mathbb{E}Y$؛ پس

$$\boxed{a=\frac{\mathbb{E}(XY)-\mathbb{E}(X)\mathbb{E}(Y)}{\mathbb{E}(X^2)-\mathbb{E}^2(X)}=\frac{\sigma_{XY}}{\sigma_X^2}\quad,\quad b=\mu_Y-\frac{\sigma_{XY}}{\sigma_X^2}\mu_X}$$

که در آن $\sigma_{XY}=\mathrm{Cov}(X,Y)$.

قضیه ۲۰-۱: خطای تخمین‌گر خطی بهینه

با $\hat{Y} = \mu_Y + \frac{\sigma_{XY}}{\sigma_X^2}(X - \mu_X)$:

$$\mathrm{MSE}_{\min} = \mathbb{E}\big[(Y - \hat{Y})^2\big] = \sigma_Y^2(1 - \rho_{XY}^2),$$

و خطای تخمین $e = Y - \hat{Y}$ با X ناهمبسته است: $\mathbb{E}[eX] = 0$ و $\mathbb{E}[e] = 0$ **(اصل تعامد)**.

اثبات. $Y - \hat{Y} = (Y - \mu_Y) - a(X - \mu_X)$ با $a = \sigma_{XY}/\sigma_X^2$. پس $\mathbb{E}(Y - \hat{Y})^2 = \sigma_Y^2 - 2a\sigma_{XY} + a^2\sigma_X^2 = \sigma_Y^2 - \frac{\sigma_{XY}^2}{\sigma_X^2} = \sigma_Y^2\big(1 - \frac{\sigma_{XY}^2}{\sigma_X^2\sigma_Y^2}\big) = \sigma_Y^2(1 - \rho^2)$. اصل تعامد همان دو معادله مشتق برابر صفر است. □

نکته. این نتیجه تعبیر عملیاتی زیبایی به ضریب همبستگی می‌دهد: ρ^2 کسری از واریانس Y است که به کمک یک تابع خطی از X «توضیح داده می‌شود». اگر $\rho = 0$ آنگاه $a = 0$ و بهترین تخمین خطی همان ثابت μ_Y است (X هیچ کمکی نمی‌کند). اگر $|\rho| = 1$ خطا صفر است. **تعبیر هندسی:** اگر متغیرهای تصادفی با میانگین صفر را بردار و $\mathbb{E}[UV]$ را ضرب داخلی بگیریم، $\hat{Y}$ تصویر عمود Y روی فضای تولیدشده توسط $\{1, X\}$ است و خطا بر این فضا عمود است.

۵.۱.۲۰ تخمین‌گر MS غیرخطی

پرسش: این بار Y را به شکل کلی $\hat{Y} = \phi(X)$ از روی X تخمین می‌زنیم که تابع دلخواه $\phi(\cdot)$ مجهول است. ϕ را چنان بیابید که $\mathbb{E}[(Y - \phi(X))^2]$ کمینه شود.

پاسخ. این مورد کمی پیچیده‌تر است:

$$\mathbb{E}\big[(Y - \phi(X))^2\big] = \iint_{\mathbb{R}^2} \big(y - \phi(x)\big)^2 f_{XY}(x, y)\,\mathrm{d}x\,\mathrm{d}y.$$

از قانون میانگین کل (جلسه چهاردهم) استفاده می‌کنیم:

$$\mathbb{E}\big[(Y-\phi(X))^2\big] = \mathbb{E}\Big\{\mathbb{E}\big[(Y-\phi(X))^2 \,\big|\, X\big]\Big\} = \int \underbrace{\Big(\int \big(y - \phi(x)\big)^2 f_{Y|X}(y \,|\, x)\,\mathrm{d}y\Big)}_{\text{برای هر } x \text{ جداگانه}} f_X(x)\,\mathrm{d}x.$$

میانگین داخلی همواره مقداری نامنفی دارد، و برای هر x ثابت، $\phi(x)$ صرفاً یک عدد ثابت است. از بخش «تخمین غیرشرطی» می‌دانیم که کمینه $\mathbb{E}[(Y - c)^2 \,|\, X = x]$ در $c = \mathbb{E}(Y \,|\, X = x)$ اتفاق می‌افتد. چون می‌توان برای هر x جداگانه بهترین عدد را انتخاب کرد، کل انتگرال کمینه می‌شود. لذا داریم:

$$\boxed{\phi(X) = \mathbb{E}(Y \,|\, X)}$$

نکته مهم

همواره داریم (روابط زیر از چپ به راست خوانده شوند):

$$\underbrace{\min_{\phi} \mathbb{E}\big[(Y-\phi(X))^2\big]}_{\text{غیرخطی}} \le \underbrace{\min_{a,b} \mathbb{E}\big[(Y-aX-b)^2\big]}_{\text{خطی غیرهمگن}} \le \underbrace{\min_{a} \mathbb{E}\big[(Y-aX)^2\big]}_{\text{خطی همگن}}$$

و همچنین خطای خطی غیرهمگن از خطای بهترین ثابت (σ_Y^2) بیشتر نیست. به بیان دیگر: **خطای MS غیرخطی، کمتر یا مساوی خطای MS خطی است.**

پرسش: چرا؟

پاسخ. زیرا هر تخمین‌گر خطی همگن (aX) حالت خاصی از خطی غیرهمگن ($aX+b$ با $b=0$) است، و هر تخمین‌گر خطی، حالت خاصی از تابع کلی $\phi(X)$ است. کمینه گرفتن روی یک مجموعه بزرگ‌تر از توابع، هرگز جواب بدتری نمی‌دهد. به همین ترتیب تخمین ثابت $c=\mu_Y$ (با خطای σ_Y^2) حالت خاص $a=0$ است.

مثال ۲۰-۲: وقتی تخمین‌گر خطی کاملاً شکست می‌خورد

$X \sim \mathcal{U}(-1,1)$ و $Y=X^2$. بهترین تخمین‌گرهای خطی و غیرخطی Y از روی X را بیابید.

حل. از جلسه پانزدهم، $\mathrm{Cov}(X,Y)=0$؛ پس $a=0$ و $b=\mu_Y=\mathbb{E}X^2=\frac{1}{3}$. تخمین‌گر خطی: $\hat{Y}=\frac{1}{3}$ با خطای $\mathrm{Var}(Y)=\mathbb{E}X^4-\frac{1}{9}=\frac{1}{5}-\frac{1}{9}=\frac{4}{45}$. تخمین‌گر غیرخطی: $\mathbb{E}(Y\mid X)=X^2$ که خطای آن **صفر** است! همبستگی صفر به معنای بی‌اطلاعی نیست؛ فقط یعنی رابطه خطی وجود ندارد. ■

مثال ۲۰-۳: یک مثال عددی

برای چگالی $f_{XY}=x+y$ روی مربع واحد (جلسه سیزدهم)، تخمین‌گرهای MS را بیابید.

حل. از جلسه پانزدهم: $\mu_X=\mu_Y=\frac{7}{12}$، $\sigma_X^2=\sigma_Y^2=\frac{11}{144}$، $\sigma_{XY}=-\frac{1}{144}$.

- **ثابت:** $\hat{Y}=\frac{7}{12}$، خطا ≈ 0.07639 $\frac{11}{144}$.
- **خطی غیرهمگن:** $a=\frac{-1/144}{11/144}=-\frac{1}{11}$ و $b=\frac{7}{12}+\frac{1}{11}\cdot\frac{7}{12}=\frac{7}{11}$؛ پس $\hat{Y}=\frac{7-X}{11}$، خطا $\frac{11}{144}(1-\frac{1}{121})\approx 0.07576$.
- **غیرخطی:** $\mathbb{E}(Y\mid X=x)=\frac{\int_0^1 y(x+y)\,dy}{x+\frac{1}{2}}=\frac{x/2+1/3}{x+1/2}$، خطا (محاسبه عددی) ≈ 0.07570.

ترتیب خطاها مطابق نکته بالاست. در این مثال وابستگی ضعیف است و بهبودها کوچک‌اند. ■

۶.۱.۲۰ توزیع‌های مشترکاً گاوسی

فرض کنید که متغیرهای تصادفی X,Y مشترکاً گاوسی با میانگین‌های μ_X,μ_Y، واریانس‌های σ_X^2,σ_Y^2 و ضریب همبستگی r باشند ($\sigma_{XY}=r\sigma_X\sigma_Y$).

- **تخمین‌گر MS خطی غیرهمگن:**

$$\hat{Y} = \frac{r\sigma_X\sigma_Y}{\sigma_X^2}x + \mu_Y - \frac{r\sigma_X\sigma_Y}{\sigma_X^2}\mu_X = \frac{r\sigma_Y}{\sigma_X}(x-\mu_X) + \mu_Y.$$

- **تخمین‌گر MS غیرخطی:** از جلسه چهاردهم (توزیع شرطی گاوسی):

$$\hat{Y} = \mathbb{E}(Y \mid X) = \frac{r\sigma_Y}{\sigma_X}(x-\mu_X) + \mu_Y.$$

توزیع‌های مشترکاً گاوسی از جمله توزیع‌هایی هستند که تخمین‌گرهای خطی غیرهمگن و غیرخطی از حیث خطای MS برابرند (تخمین‌گرها یکی هستند). این یکی از دلایل محبوبیت بسیار زیاد مدل‌های گاوسی و فیلترهای خطی (مانند فیلتر وینر و فیلتر کالمن) در مهندسی است.

۷.۱.۲۰ تخمین‌گر MS خطی غیرهمگن (چندمتغیره)

پرسش: متغیرهای تصادفی $X_1, \dots, X_n, Y$ با چگالی مشترک معلوم را در نظر بگیرید. می‌خواهیم Y را به شکل $\hat{Y} = a_1X_1 + \cdots + a_nX_n + b$ تخمین بزنیم به طوری که $\mathbb{E}[(Y - a_1X_1 - \cdots - a_nX_n - b)^2]$ کمینه شود. ضرایب را بیابید.

پاسخ. مشابه با حالت دو متغیره، با مشتق‌گیری نسبت به هر a_i و b، یک دستگاه معادلات $(n+1)$تایی تشکیل می‌دهیم:

$$\sum_{j=1}^{n} a_j\mathbb{E}(X_iX_j) = \mathbb{E}(X_iY) - b\mathbb{E}(X_i), \qquad i = 1, 2, \dots, n,$$

$$b = \mathbb{E}(Y) - \sum_{i=1}^{n} a_i\mathbb{E}(X_i).$$

می‌توان به راحتی دید که دستگاه معادلات بالا خطی بوده و جواب آن از طریق محاسبه یک ماتریس معکوس به دست خواهد آمد. با جایگذاری b در معادلات اول (و نماد برداری $\underline{X} = (X_1, \dots, X_n)^T$):

$$\sum_j a_j \operatorname{Cov}(X_i, X_j) = \operatorname{Cov}(X_i, Y) \quad \Longleftrightarrow \quad \Sigma\,\underline{a} = \mathbb{E}\big[(\underline{X} - \mathbb{E}\underline{X})(Y - \mathbb{E}Y)\big],$$

$$\boxed{\underline{a} = \Sigma^{-1}\mathbb{E}\big[(\underline{X} - \mathbb{E}\underline{X})(Y - \mathbb{E}Y)\big] \quad , \quad b = \mathbb{E}(Y) - \mathbb{E}(\underline{X})^T\Sigma^{-1}\big(\mathbb{E}(\underline{X}Y) - \mathbb{E}\underline{X}\,\mathbb{E}Y\big)}$$

که در اینجا Σ ماتریس کوواریانس میان Xها است: $\Sigma_{ij} = \operatorname{Cov}(X_i, X_j)$. (برای $n = 1$ دقیقاً به $a = \sigma_{XY}/\sigma_X^2$ می‌رسیم.)

نکته. این همان «رگرسیون خطی» در یادگیری ماشین است: وقتی به جای توزیع، نمونه داریم، امیدهای ریاضی را با میانگین‌های تجربی جایگزین می‌کنیم و به روش «کمترین مربعات» ($\hat{\underline{a}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$) می‌رسیم.

۲.۲۰ تخمین نقطه‌ای (Point Estimation)

۱.۲.۲۰ مفهوم

- تخمین نقطه‌ای، به تخمین پارامتر (یا پارامترهای) یک توزیع آماری از روی مشاهدات به دست آمده از آن اطلاق می‌گردد.
- به طور دقیق‌تر، فرض کنید متغیر تصادفی $X \sim f_X(x;\theta)$ از توزیعی با پارامتر(های) نامعلوم θ حاصل شده باشد. فرض کنید $X_1, X_2, \dots, X_n$ تعدادی نمونه مشاهده شده (یا realized) از X باشند. نمونه‌ها می‌توانند i.i.d. یا غیر i.i.d. باشند.
- هدف یافتن تابعی مانند $\hat{\theta}$ است که مشاهدات را به عضوی از فضای پارامترهای Θ نگاشت دهد.
- عبارت «تخمین نقطه‌ای» از آن جهت استفاده می‌شود که به دنبال یافتن نقطه‌ای در فضای پارامترها هستیم (در مقابل تخمین بازه‌ای).

دقت کنید! دقت کنید که تخمین‌گر $\hat{\theta}(X_{1:n})$ خود یک **متغیر تصادفی** بوده و دارای یک توزیع آماری است. (θ یک عدد ثابت ولی نامعلوم است؛ $\hat{\theta}$ تابعی از نمونه‌های تصادفی است.)

۲.۲.۲۰ گرایش (Bias)، واریانس (Variance) و سازگاری (Consistency)

فرض کنید که توزیع $X \sim f_X(x;\theta)$ توسط فضای پارامتر(های) Θ پارامتریزه شده باشد. پارامتر(های) $\theta \in \Theta$ توزیع برای ما نامعلوم است. همچنین فرض کنید نمونه‌های $X_1, \dots, X_n$ i.i.d. گرفته شده از این توزیع باشند. تخمین‌گر $\hat{\theta} = \hat{\theta}(X_{1:n})$ را در نظر بگیرید:

تعریف ۲۰-۴: گرایش، واریانس و سازگاری

- **گرایش (Bias):** $\mathrm{Bias}(\hat{\theta}, \theta) = \mathbb{E}_{X_{1:n}|\theta}\{\theta - \hat{\theta}(X_{1:n})\}$.
- **واریانس (Variance):** $\mathrm{Var}(\hat{\theta}, \theta) = \mathbb{E}_{X_{1:n}|\theta}\{(\hat{\theta} - \mathbb{E}\hat{\theta})^2\}$.
- تخمین‌گر $\hat{\theta}$ را **سازگار** (Consistent) می‌نامیم اگر $\lim_{n\to\infty} \hat{\theta}(X_{1:n}) = \theta$ (در احتمال، یعنی برای هر $\varepsilon > 0$: $\mathbb{P}(|\hat{\theta} - \theta| > \varepsilon) \to 0$).

تخمین‌گری با گرایش صفر را **بی‌گرایش** (Unbiased) می‌نامیم.

(در بسیاری از کتاب‌ها گرایش با علامت مخالف، $\mathbb{E}\hat{\theta} - \theta$، تعریف می‌شود؛ برای MSE که با توان دوم گرایش کار می‌کند، علامت اهمیتی ندارد.)

نکته. دقت کنید که سه ویژگی زیر ارتباط مستقیمی با یکدیگر ندارند:

- برای مثال، کاهش Bias یک تخمین‌گر، لزوماً باعث کاهش واریانس آن نخواهد شد.
- یا بی‌گرایش (Unbiased) بودن یک تخمین‌گر، به معنای سازگار بودن آن نیست (و بالعکس).

مثال ۲۰-۵: بی‌گرایش اما ناسازگار، و برعکس

نمونه‌های i.i.d. از $\mathcal{N}(\mu, \sigma^2)$ داریم.

۱. $\hat{\mu}_1 = X_1$ (فقط اولین نمونه): $\mathbb{E}\hat{\mu}_1 = \mu$ پس بی‌گرایش است، اما واریانسش σ^2 با n کم نمی‌شود؛ پس **ناسازگار** است.

۲. $\hat{\mu}_2 = \bar{X}_n + \frac{1}{n}$: گرایش $-\frac{1}{n} \neq 0$ (گرایش‌دار)، اما چون $\bar{X}_n \to \mu$ و $\frac{1}{n} \to 0$، **سازگار** است.

۳. $\hat{\mu}_3 = \bar{X}_n$: هم بی‌گرایش و هم سازگار.

نکته. شرط کافی برای سازگاری: اگر گرایش و واریانس هر دو با $n \to \infty$ به صفر میل کنند، تخمین‌گر سازگار است. (اثبات: طبق مارکوف روی $(\hat{\theta} - \theta)^2$: $\mathbb{P}(|\hat{\theta} - \theta| > \varepsilon) \leq \frac{\text{MSE}}{\varepsilon^2} = \frac{\text{Bias}^2 + \text{Var}}{\varepsilon^2} \to 0$.)

۳.۲.۲۰ مصالحه میان گرایش و واریانس (Bias–Variance Tradeoff)

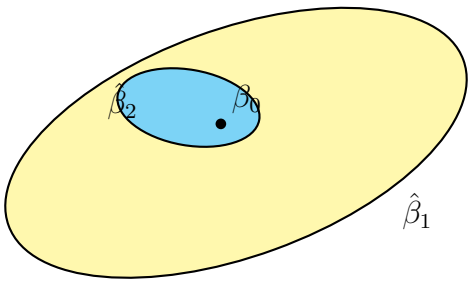
یک معیار معقول خطا برای یک تخمین‌گر، خطای میانگین مربعات آن است:

$$\text{MSE}(\hat{\theta}) = \mathbb{E}\big[(\hat{\theta} - \theta)^2\big].$$

قضیه ۲۰-۶: تجزیه گرایش–واریانس

$$\text{MSE}(\hat{\theta}) = \big(\mathbb{E}[\hat{\theta}] - \theta\big)^2 + \mathbb{E}\big[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2\big] = \big(\text{Bias}(\hat{\theta}, \theta)\big)^2 + \text{Var}(\hat{\theta}).$$

اثبات. $\hat{\theta} - \theta = (\hat{\theta} - \mathbb{E}\hat{\theta}) + (\mathbb{E}\hat{\theta} - \theta)$. با مربع کردن و میانگین گرفتن، جمله ضرب متقابل $2(\mathbb{E}\hat{\theta} - \theta)\mathbb{E}[\hat{\theta} - \mathbb{E}\hat{\theta}] = 0$ است. □



β_0 مقدار واقعی است. $\hat{\beta}_1$ بی‌گرایش است (ناحیه زرد حول β_0 متمرکز است) ولی واریانس زیادی دارد؛ $\hat{\beta}_2$ کمی گرایش دارد ولی واریانسش بسیار کمتر است و در مجموع MSE کمتری دارد.

همان‌گونه که مشاهده می‌شود، گاهی بهتر است برای پایین آوردن Variance، مقداری Bias را تحمل کرد.

مثال ۲۰-۷: تخمین واریانس: گرایش در برابر واریانس

برای نمونه‌های i.i.d. گاوسی، تخمین‌گرهای $\hat{\sigma}^2_c = c\sum_{i=1}^{n}(X_i - \bar{X})^2$ را در نظر بگیرید. کدام c کمترین MSE را می‌دهد؟

حل. برای گاوسی می‌توان نشان داد $\frac{1}{\sigma^2}\sum(X_i - \bar{X})^2 \sim \chi^2(n-1)$ با میانگین $n-1$ و واریانس

$2(n-1)$. پس با $W=\sum(X_i-\bar{X})^2$: $\mathbb{E}[cW]=c(n-1)\sigma^2$ و $\mathrm{Var}(cW)=2c^2(n-1)\sigma^4$، و

$$\mathrm{MSE}(c)=\sigma^4\big[(c(n-1)-1)^2+2c^2(n-1)\big].$$

با مشتق‌گیری: $c^*=\frac{1}{n+1}$. مقایسه:

c	گرایش	MSE/σ^4	برای $n=10$
$\frac{1}{n-1}$ (بی‌گرایش)	0	$\frac{2}{n-1}$	0.222
$\frac{1}{n}$	$\frac{\sigma^2}{n}$	$\frac{2n-1}{n^2}$	0.190
$\frac{1}{n+1}$	$\frac{2\sigma^2}{n+1}$	$\frac{2}{n+1}$	0.182

تخمین‌گر بی‌گرایش بیشترین MSE را دارد! با پذیرش کمی گرایش، واریانس به اندازه‌ای کم می‌شود که خطای کل کمتر شود. ■

مثال ۲۰-۸: تخمین پارامتر یکنواخت

برای $\mathcal{U}(0,\theta)$ سه تخمین‌گر $\hat{\theta}_1=2\bar{X}_n$، $\hat{\theta}_2=\max_i X_i$ و $\hat{\theta}_3=\frac{n+1}{n}\max_i X_i$ را از نظر MSE مقایسه کنید.

حل.

- $\hat{\theta}_1$: بی‌گرایش، $\mathrm{Var}=4\cdot\frac{\theta^2}{12n}=\frac{\theta^2}{3n}$؛ $\mathrm{MSE}=\frac{\theta^2}{3n}$.
- $\hat{\theta}_2$: با $f_U(u)=\frac{nu^{n-1}}{\theta^n}$: $\mathbb{E}U=\frac{n\theta}{n+1}$ و $\mathbb{E}U^2=\frac{n\theta^2}{n+2}$؛ پس $\mathrm{Var}\,U=\frac{n\theta^2}{(n+1)^2(n+2)}$ و $\mathrm{Bias}=\frac{\theta}{n+1}$. $\mathrm{MSE}=\frac{2\theta^2}{(n+1)(n+2)}$.
- $\hat{\theta}_3$: بی‌گرایش، $\mathrm{MSE}=\mathrm{Var}=\frac{(n+1)^2}{n^2}\cdot\frac{n\theta^2}{(n+1)^2(n+2)}=\frac{\theta^2}{n(n+2)}$.

برای $n=10$: $0.0333\theta^2$، $0.0152\theta^2$ و $0.0083\theta^2$. تخمین‌گرهای مبتنی بر بیشینه، خطایی از مرتبه $\frac{1}{n^2}$ دارند (در مقابل $\frac{1}{n}$ برای میانگین) ــ تفاوتی بسیار چشمگیر برای n بزرگ. ■

۴.۲.۲۰ انواع تخمین‌گرهای نقطه‌ای

- تخمین‌گر بی‌گرایش (unbiased) و دارای کمینه واریانس:
  (Minimum-Variance Unbiased Estimator — MVUE)
- تخمین‌گر کمینه میانگین مربعات خطا:
  (Minimum Mean Square Estimator — MMSE)
- تخمین‌گر بیشینه درست‌نمایی:
  (Maximum Likelihood Estimator — MLE)
- تخمین‌گر مبتنی بر گشتاور:

(Method of Moments Estimator — MoME)

- و بسیاری دیگر...

(دو مورد آخر در جلسات بعد به تفصیل بررسی می‌شوند.)

۳.۲۰ تمرین‌های تکمیلی

تمرین ۲۰-۹

X و N مستقل‌اند، $X \sim \mathcal{N}(0,4)$ (سیگنال) و $N \sim \mathcal{N}(0,1)$ (نویز). مشاهده $Y = X + N$ است. بهترین تخمین MS برای X از روی Y و خطای آن را بیابید.

حل. X, Y مشترکاً گاوسی‌اند (ترکیب خطی گاوسی‌های مستقل). $\operatorname{Cov}(X,Y) = \operatorname{Var} X = 4$، $\operatorname{Var} Y = 5$. پس $\hat{X} = \mathbb{E}(X \mid Y) = \frac{4}{5}Y$ (تخمین خطی و غیرخطی یکی است). خطا: $\sigma_X^2(1-\rho^2) = 4\big(1 - \frac{16}{4\cdot 5}\big) = \frac{4}{5} = 0.8$ (در مقایسه با خطای 1 اگر از خود Y استفاده می‌کردیم، و 4 اگر Y را نادیده می‌گرفتیم). ■

تمرین ۲۰-۱۰

نشان دهید $\mathbb{E}\big[\operatorname{Var}(Y \mid X)\big] + \operatorname{Var}\big(\mathbb{E}(Y \mid X)\big) = \operatorname{Var}(Y)$ (قانون واریانس کل) و تعبیر آن را در قالب تخمین MS بیان کنید.

حل. $\operatorname{Var} Y = \mathbb{E}Y^2 - (\mathbb{E}Y)^2 = \mathbb{E}[\mathbb{E}(Y^2 \mid X)] - (\mathbb{E}[\mathbb{E}(Y \mid X)])^2 = \mathbb{E}[\operatorname{Var}(Y \mid X) + \mathbb{E}(Y \mid X)^2] - (\mathbb{E}[\mathbb{E}(Y \mid X)])^2 = \mathbb{E}[\operatorname{Var}(Y \mid X)] + \operatorname{Var}(\mathbb{E}(Y \mid X))$. **تعبیر:** جمله اول خطای تخمین‌گر غیرخطی بهینه $\mathbb{E}[(Y - \mathbb{E}(Y \mid X))^2]$ است؛ جمله دوم واریانس «توضیح‌داده‌شده» توسط X. واریانس کل = خطای باقی‌مانده + بخش قابل پیش‌بینی. ■

تمرین ۲۰-۱۱

برای $\operatorname{Pois}(\lambda)$، تخمین‌گر $\hat{\lambda} = \bar{X}_n$ را از نظر گرایش، واریانس، MSE و سازگاری بررسی کنید.

حل. $\mathbb{E}\hat{\lambda} = \lambda$ (بی‌گرایش). $\operatorname{Var}\hat{\lambda} = \frac{\lambda}{n}$. $\mathrm{MSE} = \frac{\lambda}{n} \to 0$؛ پس سازگار است. ■

جلسه ۲۱

تخمین‌گر بیشینه درست‌نمایی (MLE)

در جلسه قبل مفهوم تخمین نقطه‌ای و معیارهای کیفیت یک تخمین‌گر (گرایش، واریانس، سازگاری و MSE) را دیدیم و با انواع تخمین‌گرها آشنا شدیم. در این جلسه، پس از یک مرور کوتاه، به مهم‌ترین و پرکاربردترین روش ساختن تخمین‌گر می‌پردازیم: **تخمین‌گر بیشینه درست‌نمایی** (Maximum Likelihood Estimator).

۱.۲۱ مرور: تخمین نقطه‌ای و معیارهای کیفیت

مرور جلسه قبل

- متغیر تصادفی $X \sim f_X(x;\theta)$ از توزیعی با پارامتر(های) نامعلوم $\theta \in \Theta$ حاصل شده و نمونه‌های $X_1, \dots, X_n$ (معمولاً i.i.d.) از آن در دست است. هر تابع $\hat{\theta} = \hat{\theta}(X_{1:n})$ از نمونه‌ها که مقداری در Θ بدهد یک **تخمین‌گر نقطه‌ای** است؛ $\hat{\theta}$ خود یک **متغیر تصادفی** است.
- **گرایش:** $\text{Bias}(\hat{\theta}, \theta) = \mathbb{E}_{X_{1:n}|\theta}\{\theta - \hat{\theta}(X_{1:n})\}$؛ تخمین‌گر با گرایش صفر را **بی‌گرایش** (Unbiased) می‌نامیم.
- **واریانس:** $\text{Var}(\hat{\theta}) = \mathbb{E}\{(\hat{\theta} - \mathbb{E}\hat{\theta})^2\}$.
- **سازگاری:** $\hat{\theta}$ سازگار است اگر $\lim_{n\to\infty} \hat{\theta}(X_{1:n}) = \theta$ (در اسلایدها این حد به صورت تقریباً حتمی (a.s.) نوشته شده است؛ تعریف رایج‌تر، همگرایی در احتمال است. در مثال‌های این درس هر دو برقرارند).
- این سه ویژگی ارتباط مستقیمی با یکدیگر ندارند: بی‌گرایش بودن، سازگاری را تضمین نمی‌کند و بالعکس؛ کاهش گرایش هم لزوماً واریانس را کم نمی‌کند.
- **مصالحه گرایش–واریانس:** $\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Bias}^2 + \text{Var}$. گاهی برای کاهش واریانس، تحمل مقداری گرایش به صرفه است.
- **انواع تخمین‌گرها:** MVUE، MMSE، MLE، MoME و...

مثال ۲۱-۱: سه ویژگی مستقل از هم

برای نمونه‌های i.i.d. از توزیعی با میانگین μ و واریانس σ^2، چهار ترکیب ممکن را نشان دهید.

حل.

تخمین‌گر	بی‌گرایش؟	سازگار؟
$\bar{X}_n = \frac{1}{n}\sum_i X_i$	بله	بله (قانون اعداد بزرگ)
X_1	بله ($\mathbb{E}X_1 = \mu$)	خیر (توزیعش با n تغییر نمی‌کند)
$\bar{X}_n + \frac{1}{n}$	خیر (گرایش $-\frac{1}{n}$)	بله
$X_1 + 1$	خیر	خیر

■

۲.۲۱ ایده درست‌نمایی

۱.۲.۲۱ یک مثال شهودی

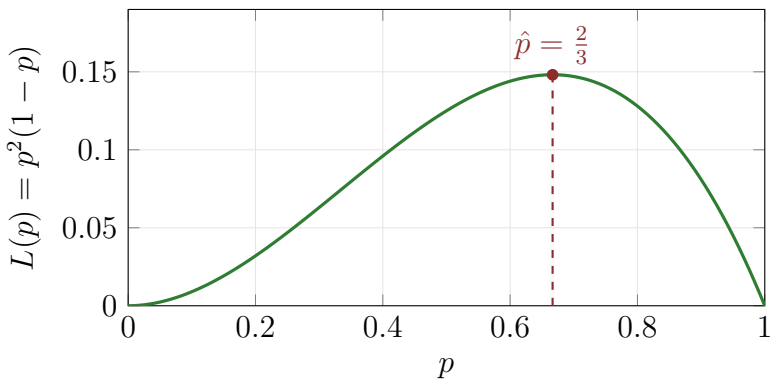
سکه‌ای با احتمال شیر نامعلوم p را سه بار پرتاب کرده‌ایم و نتیجه «شیر، شیر، خط» شده است. کدام مقدار p «باورپذیرتر» است؟ احتمال مشاهده همین داده‌ها به ازای هر p برابر است با

$$L(p) = \mathbb{P}(\text{H,H,T}; p) = p \cdot p \cdot (1-p) = p^2(1-p).$$

اگر $p = 0.1$ باشد این احتمال 0.009 است، اگر $p = 0.5$ باشد 0.125، و اگر $p = 0.9$ باشد 0.081. طبیعی است مقداری از p را برگزینیم که **داده‌های مشاهده‌شده را محتمل‌ترین** کند:

$$\frac{\mathrm{d}}{\mathrm{d}p}\left(p^2 - p^3\right) = 2p - 3p^2 = 0 \;\Rightarrow\; \hat{p} = \frac{2}{3}, \qquad L\left(\frac{2}{3}\right) = \frac{4}{27} \approx 0.148.$$

این همان نسبت شیرها در داده‌هاست! این ایده ساده، اساس تخمین‌گر بیشینه درست‌نمایی است.



تابع درست‌نمایی برای مشاهده «شیر، شیر، خط»؛ بیشینه در $\hat{p} = 2/3$ رخ می‌دهد.

۲.۲.۲۱ تابع درست‌نمایی

تعریف ۲۱-۲: تابع درست‌نمایی

فرض کنید نمونه‌های $X_1, \dots, X_n$ i.i.d. از توزیع $f_X(x;\theta)$ (یا $P_X(x;\theta)$ در حالت گسسته) مشاهده شده باشند. تابع

$$L(\theta; X_{1:n}) \triangleq \prod_{i=1}^{n} f_X(X_i;\theta) \qquad \left(\text{گسسته: } \prod_{i=1}^{n} P_X(X_i;\theta)\right)$$

که در آن داده‌ها **ثابت** و θ **متغیر** در نظر گرفته می‌شود، **تابع درست‌نمایی** (Likelihood Function) نامیده می‌شود.

دقت کنید! درست‌نمایی، یک «چگالی احتمال برای θ» **نیست**: θ در این چارچوب کمیتی **غیرتصادفی** (اما نامعلوم) است و انتگرال L روی θ لزوماً یک نمی‌شود (مثلاً در مثال سکه $\int_0^1 p^2(1-p)\,\mathrm{d}p = \frac{1}{12}$). عبارت $f_X(x;\theta)$ به عنوان تابعی از x چگالی است؛ همان عبارت به عنوان تابعی از θ (با x ثابت)، درست‌نمایی است.

۳.۲۱ تعریف تخمین‌گر بیشینه درست‌نمایی

۱.۳.۲۱ حالت گسسته (بیشینه احتمال)

- فرض کنید متغیر تصادفی گسسته X دارای تابع جرم احتمال (PMF) پارامتریزه‌شده $P_X(x;\theta)$ باشد که عدد (یا بردار) $\theta \in \Theta$ بیانگر پارامتر(های) توزیع است. همچنین فرض کنید نمونه‌های $X_1, X_2, \dots, X_n$ به صورت i.i.d. از توزیع به دست آمده باشند.
- در اینجا، پارامتر(های) θ خود ماهیتی **غیرتصادفی** دارند، اما برای ما **دانسته شده نیستند**.
- تخمین‌گر بیشینه درست‌نمایی (MLE) به صورت حل مسئله بهینه‌سازی زیر تعریف می‌گردد:

تعریف ۲۱-۳: MLE – حالت گسسته

$$\hat{\theta}_{\mathrm{ML}} = \hat{\theta}_{\mathrm{ML}}(X_1, X_2, \dots, X_n) = \arg\max_{\theta\in\Theta} \prod_{i=1}^{n} P_X(X_i;\theta)$$

در حالت گسسته، $\prod_i P_X(X_i;\theta) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n;\theta)$ دقیقاً **احتمال مشاهده همین داده‌ها** است (به دلیل استقلال). پس MLE مقداری از پارامتر است که احتمال رخ دادن داده‌های مشاهده‌شده را بیشینه می‌کند.

۲.۳.۲۱ حالت پیوسته (بیشینه چگالی احتمال)

- فرض کنید متغیر تصادفی پیوسته X دارای تابع چگالی احتمال (PDF) پارامتریزه‌شده $f_X(x;\theta)$ باشد که $\theta \in \Theta$ بیانگر پارامتر(های) توزیع است و نمونه‌های $X_1, \dots, X_n$ به صورت i.i.d. از توزیع به دست آمده باشند.
- مشابه قبل، θ غیرتصادفی ولی نامعلوم است. تخمین‌گر بیشینه درست‌نمایی به صورت زیر تعریف می‌گردد:

تعریف ۲۱-۴: MLE – حالت پیوسته

$$\hat{\theta}_{\text{ML}} = \hat{\theta}_{\text{ML}}(X_1, X_2, \dots, X_n) = \arg\max_{\theta\in\Theta} \prod_{i=1}^{n} f_X(X_i;\theta)$$

نکته. چرا در حالت پیوسته چگالی را بیشینه می‌کنیم؟ احتمال مشاهده دقیقاً یک نقطه صفر است، اما احتمال افتادن هر نمونه در همسایگی کوچکی به طول Δ حول مقدار مشاهده‌شده تقریباً $f_X(x_i;\theta)\Delta$ است. پس

$$\mathbb{P}\big(X_i \in [x_i, x_i+\Delta],\ i=1..n;\theta\big) \approx \Delta^n \prod_{i=1}^{n} f_X(x_i;\theta),$$

و چون Δ^n به θ بستگی ندارد، بیشینه کردن این احتمال با بیشینه کردن حاصل‌ضرب چگالی‌ها معادل است.

۳.۳.۲۱ تابع Log-Likelihood (LL)

معادلاً، می‌توان به جای بیشینه‌سازی تابع درست‌نمایی، لگاریتم آن را بیشینه نمود. به لگاریتم تابع درست‌نمایی، LL یا Log-Likelihood اطلاق می‌گردد:

تعریف ۲۱-۵: تابع لگاریتم درست‌نمایی

$$LL(\theta; X_{1:n}) = \sum_{i=1}^{n} LL(\theta; X_i) \triangleq \sum_{i=1}^{n} \log f_X(X_i;\theta)$$

$$\Rightarrow \qquad \hat{\theta}_{\text{ML}} = \arg\max_{\theta\in\Theta}\ LL(\theta; X_{1:n}).$$

تنها تفاوت در این است که در تابع LL به جای ضرب، **جمع** ظاهر می‌شود. دلایل استفاده از LL:

۱. **هم‌ارزی:** $\log$ تابعی اکیداً صعودی است؛ پس نقطه بیشینه L و $\log L$ یکسان است (مقدار بیشینه متفاوت است، اما محل آن نه).

۲. **سادگی مشتق‌گیری:** مشتق یک جمع، جمع مشتق‌هاست؛ در حالی که مشتق حاصل‌ضرب n جمله بسیار پیچیده است. همچنین برای خانواده‌های نمایی (گاوسی، نمایی، پواسون، ...) لگاریتم، تابع نمایی را حذف می‌کند.

۳. **پایداری عددی:** حاصل‌ضرب n عدد کوچک (مثلاً $n = 1000$ چگالی از مرتبه 0.1) برابر 10^{-1000} است که در کامپیوتر به صفر گرد می‌شود؛ اما جمع لگاریتم‌ها (≈ -2303) مشکلی ندارد.

دستورالعمل کلی محاسبه MLE (حالت مشتق‌پذیر)

۱. تابع درست‌نمایی $L(\theta) = \prod_i f_X(X_i;\theta)$ را بنویسید.

۲. لگاریتم بگیرید: $LL(\theta) = \sum_i \log f_X(X_i;\theta)$ و جملات مستقل از θ را در یک ثابت جمع کنید.

۳. معادله **نقطه بحرانی** (معادله امتیاز، score equation) را حل کنید: $\frac{\partial}{\partial\theta}LL(\theta) = 0$.

۴. بررسی کنید که جواب واقعاً **بیشینه** است (مثلاً $\frac{\partial^2}{\partial\theta^2}LL < 0$، یا رفتار LL در مرزهای Θ) و در فضای پارامتر Θ قرار دارد.

اگر LL مشتق‌پذیر نباشد (مثلاً وقتی تکیه‌گاه توزیع به θ وابسته است)، باید مستقیماً شکل تابع را بررسی کرد (جلسه بعد).

۴.۲۱ خواص و ویژگی‌ها

- تخمین‌گر بیشینه درست‌نمایی از حیث **بیشینه‌سازی احتمال مشاهده دادگان**، **بهینه** (optimal) است (این تعریف آن است!).
- تخمین‌گر MLE (تحت شرایط نظم معمول) **سازگار** است؛ یعنی با افزایش $n \to \infty$، تخمین‌گر به مقدار واقعی θ میل خواهد کرد.
- اما لزوماً **بی‌گرایش** (unbiased) نبوده و لزوماً **کمینه خطا (واریانس)** را دارا نیست.
- همان‌گونه که مشاهده شد، MLE از حل یک **مسئله بهینه‌سازی** حاصل خواهد شد. این دسته مسائل:
  - خیلی اوقات حل تحلیلی دارند، ولی خیلی اوقات هم به صورت تحلیلی حل نمی‌شوند (و باید از روش‌های عددی مانند گرادیان کاهشی یا نیوتن استفاده کرد).
  - حصول به حل عددی ممکن است در زمان بسیار طولانی نسبت به تعداد دادگان n (یا ابعاد مسئله) اتفاق بیافتد (NP-hardness)؛ نمونه‌ای از این وضعیت را در جلسه بعد (رمزگشایی کانال نویزی) خواهیم دید.

نکته. درباره «همواره سازگار». سازگاری MLE یک قضیه است که تحت **شرایط نظم** (regularity conditions) برقرار است: مثلاً تعداد پارامترها ثابت بماند و با n رشد نکند، مدل **شناسه‌پذیر** باشد (مقادیر متفاوت θ توزیع‌های متفاوت بدهند) و درست‌نمایی به اندازه کافی هموار باشد. مثال نقض مشهور (مسئله نیمن–اسکات): اگر n جفت نمونه $(X_{i1}, X_{i2}) \sim \mathcal{N}(\mu_i, \sigma^2)$ با میانگین‌های **متفاوت** μ_i داشته باشیم، تعداد پارامترها همراه با n رشد می‌کند و MLE واریانس به $\sigma^2/2$ (و نه σ^2) همگرا می‌شود. در تمام مثال‌های این درس، شرایط نظم برقرار است.

۵.۲۱ مثال‌ها: بهینه‌سازی با تابع هدف مشتق‌پذیر

۱.۵.۲۱ میانگین توزیع گاوسی با واریانس معلوم

مثال ۲۱-۶: میانگین گاوسی با واریانس معلوم

فرض کنید متغیر تصادفی $X \sim \mathcal{N}(\mu, \sigma^2)$ دارای میانگین نامعلوم μ و واریانس دانسته‌شده σ^2 است. در صورتی که نمونه‌های $X_1, X_2, \dots, X_n$ به صورت i.i.d. از این توزیع گرفته شده باشند، تخمین‌گر MLE برای μ، یعنی $\hat{\mu} = \hat{\mu}(X_{1:n})$ را به دست آورید.

حل. پارامتر نامعلوم را $\theta = \mu$ می‌نامیم. چگالی:

$$f_X(x;\theta) = \frac{1}{\sqrt{2\pi}\sigma}\, e^{-\frac{(x-\theta)^2}{2\sigma^2}}.$$

تابع درست‌نمایی:

$$\prod_{i=1}^{n} f_X(X_i;\theta) = \Big(\frac{1}{\sqrt{2\pi}\sigma}\Big)^n \exp\Big[-\sum_{i=1}^{n}\frac{(X_i-\theta)^2}{2\sigma^2}\Big].$$

ضریب $(\sqrt{2\pi}\sigma)^{-n}$ به θ بستگی ندارد و e^{-u} نزولی است؛ پس بیشینه کردن درست‌نمایی معادل کمینه کردن نما است:

$$\arg\max_{\theta} \prod_{i=1}^{n} f_X(X_i;\theta) = \arg\min_{\theta\in\mathbb{R}} \sum_{i=1}^{n}\frac{(X_i-\theta)^2}{2\sigma^2}.$$

(یعنی برای داده گاوسی، MLE میانگین همان **کمترین مربعات** است.) با مشتق‌گیری:

$$\frac{\partial}{\partial\theta}\sum_{i=1}^{n}\frac{(X_i-\theta)^2}{2\sigma^2} = \sum_{i=1}^{n}\frac{\theta - X_i}{\sigma^2} = \frac{n\theta - \sum_i X_i}{\sigma^2} = 0 \quad\Rightarrow\quad \boxed{\hat{\theta}_{\mathrm{ML}} = \frac{1}{n}\sum_{i=1}^{n} X_i = \bar{X}_n}$$

مشتق دوم تابع هدف $\frac{n}{\sigma^2} > 0$ است؛ پس این نقطه کمینه یکتای تابع هدف (و بیشینه یکتای درست‌نمایی) است. MLE میانگین، **میانگین نمونه‌ای** است. ■

خواص این تخمین‌گر

۱. **بی‌گرایش (Unbiased) است:**

$$\mathbb{E}\big(\hat{\theta}_{\mathrm{ML}}(X_1,\dots,X_n)\big) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}(X_i) = \frac{1}{n}\cdot n\mu = \mu.$$

۲. **سازگار (Consistent) نیز هست:** طبق قانون (قوی) اعداد بزرگ،

$$\lim_{n\to\infty}\hat{\theta}_{\mathrm{ML}}(X_{1:n}) = \lim_{n\to\infty}\frac{1}{n}\sum_{i} X_i = \mu \qquad \text{(a.s.)}$$

۳. **واریانس:** به دلیل استقلال نمونه‌ها،

$$\mathrm{Var}\left(\hat{\theta}_{\mathrm{ML}}\right) = \sum_{i=1}^{n} \mathrm{Var}\left(\frac{X_i}{n}\right) = \sum_{i=1}^{n} \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

در واقع $\hat{\theta}_{\mathrm{ML}} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ (جمع گاوسی‌های مستقل، گاوسی است).

۴. می‌توان نشان داد که این تخمین‌گر **کمترین واریانس** را در میان تمامی تخمین‌گرهای **بی‌گرایش** دارد (نکته زیر).

نکته. دقیق‌تر کردن ادعای «کمترین واریانس». ادعا باید به تخمین‌گرهای **بی‌گرایش** محدود شود؛ وگرنه تخمین‌گر ثابت $\hat{\theta} \equiv 0$ واریانس صفر دارد (هرچند گرایشش می‌تواند بسیار بزرگ باشد). ابزار اثبات، **نامساوی کرامر–رائو** است: برای هر تخمین‌گر بی‌گرایش $\hat{\theta}$ از نمونه‌های i.i.d. (تحت شرایط نظم)،

$$\mathrm{Var}(\hat{\theta}) \;\geq\; \frac{1}{n\,I(\theta)}, \qquad I(\theta) = \mathbb{E}\Big[\Big(\frac{\partial}{\partial\theta}\log f_X(X;\theta)\Big)^2\Big] = -\mathbb{E}\Big[\frac{\partial^2}{\partial\theta^2}\log f_X(X;\theta)\Big],$$

که $I(\theta)$ **اطلاعات فیشر** (Fisher Information) یک نمونه است. برای میانگین گاوسی: $\frac{\partial}{\partial\mu}\log f = \frac{x-\mu}{\sigma^2}$ و $I(\mu) = \frac{\mathbb{E}(X-\mu)^2}{\sigma^4} = \frac{1}{\sigma^2}$؛ پس کران برابر $\frac{\sigma^2}{n}$ است که دقیقاً واریانس $\bar{X}_n$ است. بنابراین $\bar{X}_n$ یک MVUE است. به علاوه، تحت شرایط نظم، MLE **به طور مجانبی** گاوسی با واریانس $\frac{1}{nI(\theta)}$ است: $\sqrt{n}(\hat{\theta}_{\mathrm{ML}}-\theta) \to \mathcal{N}\left(0, \frac{1}{I(\theta)}\right)$؛ یعنی برای n بزرگ، MLE تقریباً بهترین کار ممکن را انجام می‌دهد.

مثال ۲۱-۷: یک محاسبه عددی

شش اندازه‌گیری مستقل از یک کمیت فیزیکی با نویز گاوسی با انحراف معیار معلوم $\sigma = 0.6$ به صورت زیر است: $4.4,\ 5.6,\ 4.9,\ 3.8,\ 5.1,\ 4.2$. MLE مقدار واقعی μ و انحراف معیار این تخمین را بیابید.

حل. $\hat{\mu}_{\mathrm{ML}} = \bar{X} = \frac{28}{6} \approx 4.667$. انحراف معیار تخمین‌گر: $\sqrt{\mathrm{Var}\,\hat{\mu}} = \frac{\sigma}{\sqrt{n}} = \frac{0.6}{\sqrt{6}} \approx 0.245$. (برای دو برابر کردن دقت، یعنی نصف کردن این عدد، باید تعداد نمونه‌ها را **چهار برابر** کرد.) ■

۲.۵.۲۱ واریانس توزیع گاوسی با میانگین معلوم

مثال ۲۱-۸: واریانس گاوسی با میانگین معلوم

فرض کنید متغیر تصادفی $X \sim \mathcal{N}(\mu, \sigma^2)$ دارای میانگین معلوم μ و واریانس نامعلوم σ^2 است. در صورتی که نمونه‌های $X_1, \ldots, X_n$ به صورت i.i.d. از این توزیع گرفته شده باشند، تخمین‌گر MLE برای σ^2، یعنی $\hat{\sigma}^2 = \hat{\sigma}^2(X_{1:n})$ را به دست آورید.

حل. مطابق اسلایدها، پارامتر را **انحراف معیار** $\theta = \sigma > 0$ می‌گیریم:

$$f_X(x;\theta) = \frac{1}{\sqrt{2\pi}\theta}\, e^{-\frac{(x-\mu)^2}{2\theta^2}} \;\Rightarrow\; \prod_{i=1}^{n} f_X(X_i;\theta) = \Big(\frac{1}{\sqrt{2\pi}\theta}\Big)^n \exp\Big[-\sum_{i=1}^{n}\frac{(X_i-\mu)^2}{2\theta^2}\Big].$$

با لگاریتم گرفتن:

$$LL(\theta; X_{1:n}) = -n\log\theta - \sum_{i=1}^{n}\frac{(X_i-\mu)^2}{2\theta^2} + \underbrace{\Big(-\tfrac{n}{2}\log 2\pi\Big)}_{\text{const}}.$$

با مشتق‌گیری نسبت به θ:

$$\frac{\partial}{\partial\theta}LL(\theta;X_{1:n}) = -\frac{n}{\theta} + \sum_{i=1}^{n}\frac{(X_i-\mu)^2}{\theta^3} = 0 \quad \Rightarrow \quad \boxed{\hat{\theta}_{\mathrm{ML}} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2}}$$

بررسی بیشینه بودن: با نماد $W = \frac{1}{n}\sum_i(X_i-\mu)^2$ داریم $\frac{\partial LL}{\partial\theta} = \frac{n}{\theta^3}(W-\theta^2)$ که برای $\theta < \sqrt{W}$ مثبت و برای $\theta > \sqrt{W}$ منفی است؛ پس LL ابتدا صعودی و سپس نزولی است و $\theta = \sqrt{W}$ بیشینه سراسری است. (همچنین $LL \to -\infty$ وقتی $\theta \to 0^+$ یا $\theta \to \infty$.)
پس MLE انحراف معیار $\sqrt{W}$ است و، طبق خاصیت ناوردایی (پایین‌تر)، MLE واریانس

$$\hat{\sigma}^2_{\mathrm{ML}} = \hat{\theta}^2_{\mathrm{ML}} = \frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2.$$

راه دوم: اگر مستقیماً $v = \sigma^2$ را پارامتر بگیریم، $LL = -\frac{n}{2}\log v - \frac{nW}{2v} + c$ و $\frac{\partial LL}{\partial v} = -\frac{n}{2v} + \frac{nW}{2v^2} = 0 \Rightarrow \hat{v} = W$؛ همان جواب. ■

خواص این تخمین‌گر

- مشابه قبل، تخمین‌گر **واریانس** بدون گرایش است: چون $\mathbb{E}(X_i-\mu)^2 = \sigma^2$،
$$\mathbb{E}\big(\hat{\theta}^2_{\mathrm{ML}}\big) = \mathbb{E}\Big(\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2\Big) = \frac{1}{n}\cdot n\sigma^2 = \sigma^2.$$
- طبق قانون اعداد بزرگ (اعمال‌شده به متغیرهای $Y_i = (X_i-\mu)^2$ i.i.d. با میانگین σ^2)، و مشابه قبل، خاصیت سازگاری (Consistency) نیز برقرار است: $\hat{\theta}^2_{\mathrm{ML}} \to \sigma^2$ (a.s.).
- **واریانس:** $\frac{(X_i-\mu)^2}{\sigma^2} \sim \chi^2(1)$ با واریانس 2؛ پس $\mathrm{Var}(\hat{\theta}^2_{\mathrm{ML}}) = \frac{1}{n^2}\cdot n\cdot 2\sigma^4 = \frac{2\sigma^4}{n}$.
- کماکان می‌توان نشان داد که در میان تمامی تخمین‌گرهای **بی‌گرایش** σ^2، کمترین واریانس را داراست: اطلاعات فیشر برای $v = \sigma^2$ برابر $I(v) = \frac{1}{2v^2}$ است و کران کرامر–رائو $\frac{2\sigma^4}{n}$ دقیقاً برابر واریانس بالاست.

پرسش: آیا تخمین‌گر بیشینه درست‌نمایی برای انحراف معیار هم بدون گرایش (Unbiased) است؟ سازگار چطور؟

پاسخ. ۱) بی‌گرایش نیست. با نماد $W = \frac{1}{n}\sum_i(X_i-\mu)^2$ داریم $\hat{\theta}_{\mathrm{ML}} = \sqrt{W}$ و $\mathbb{E}W = \sigma^2$. تابع $\sqrt{\cdot}$ **اکیداً مقعر** است؛ پس طبق **نامساوی ینسن**:

$$\mathbb{E}\big[\hat{\theta}_{\mathrm{ML}}\big] = \mathbb{E}\big[\sqrt{W}\big] \;<\; \sqrt{\mathbb{E}W} = \sqrt{\sigma^2} = \sigma,$$

که نامساوی اکید است چون W ثابت نیست. راه ساده‌تر بدون ینسن:

$$0 < \mathrm{Var}\left(\sqrt{W}\right) = \mathbb{E}W - \left(\mathbb{E}\sqrt{W}\right)^2 = \sigma^2 - \left(\mathbb{E}\hat{\theta}_{\mathrm{ML}}\right)^2 \;\Rightarrow\; \mathbb{E}\hat{\theta}_{\mathrm{ML}} < \sigma.$$

یعنی MLE انحراف معیار به طور متوسط مقدار واقعی را **کمتر** تخمین می‌زند. در حالی که $\hat{\theta}^2_{\mathrm{ML}}$ برای σ^2 بی‌گرایش است، جذر آن برای σ بی‌گرایش نیست: **بی‌گرایشی تحت تبدیل‌های غیرخطی حفظ نمی‌شود.**

محاسبه دقیق: چون $\frac{nW}{\sigma^2} \sim \chi^2(n)$ و برای $Q \sim \chi^2(n)$ داریم $\mathbb{E}\sqrt{Q} = \sqrt{2}\,\frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})}$:

$$\mathbb{E}\hat{\theta}_{\mathrm{ML}} = c_n \sigma, \qquad c_n = \sqrt{\frac{2}{n}}\,\frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \approx 1 - \frac{1}{4n}.$$

n	1	2	3	5	10	30	100
c_n	0.798	0.886	0.921	0.952	0.975	0.992	0.998

گرایش برابر $\sigma(1-c_n) \approx \frac{\sigma}{4n}$ است که با $n \to \infty$ صفر می‌شود (**بی‌گرایش مجانبی**). تخمین‌گر $\hat{\theta}_{\mathrm{ML}}/c_n$ بی‌گرایش است، اما دیگر MLE نیست.

۲) سازگار است. طبق قانون اعداد بزرگ $W \to \sigma^2$ (a.s.). چون تابع $g(w) = \sqrt{w}$ **پیوسته** است، $\hat{\theta}_{\mathrm{ML}} = g(W) \to g(\sigma^2) = \sigma$ (a.s.). (اصل کلی: تابع پیوسته‌ای از یک تخمین‌گر سازگار، تخمین‌گری سازگار برای همان تابع از پارامتر است؛ قضیه نگاشت پیوسته.)

۶.۲۱ خاصیت ناوردایی MLE

قضیه ۲۱-۹: ناوردایی (Invariance)

اگر $\hat{\theta}_{\mathrm{ML}}$ تخمین‌گر بیشینه درست‌نمایی θ باشد و g یک تابع یک‌به‌یک باشد، آنگاه تخمین‌گر بیشینه درست‌نمایی $\eta = g(\theta)$ برابر است با

$$\hat{\eta}_{\mathrm{ML}} = g\big(\hat{\theta}_{\mathrm{ML}}\big).$$

اثبات. با پارامتر جدید η، درست‌نمایی برابر $\tilde{L}(\eta) = L(g^{-1}(\eta))$ است. وقتی η تمام مقادیر $g(\Theta)$ را می‌پیماید، $\theta = g^{-1}(\eta)$ تمام Θ را می‌پیماید؛ پس بیشینه $\tilde{L}$ در نقطه‌ای رخ می‌دهد که $g^{-1}(\eta) = \hat{\theta}_{\mathrm{ML}}$، یعنی $\hat{\eta} = g(\hat{\theta}_{\mathrm{ML}})$. (برای g غیر یک‌به‌یک نیز با تعریف «درست‌نمایی القایی» $\tilde{L}(\eta) = \sup_{\theta: g(\theta)=\eta} L(\theta)$ همین نتیجه برقرار است.) □

به همین دلیل در مثال قبل، پارامتر کردن با σ یا σ^2 تفاوتی نداشت. دقت کنید: MLE تحت تبدیل ناورداست، اما **بی‌گرایشی** چنین نیست (پرسش بالا).

۷.۲۱ مثال‌های بیشتر از توزیع‌های مشهور

مثال ۲۱-۱۰: برنولی: تخمین احتمال موفقیت

$X_1, \dots, X_n \sim \mathrm{Bernoulli}(p)$ به صورت i.i.d. و $K = \sum_i X_i$ تعداد موفقیت‌هاست. MLE پارامتر p را بیابید و خواص آن را بررسی کنید.

حل. $P_X(x;p) = p^x(1-p)^{1-x}$ برای $x \in \{0,1\}$. پس

$$L(p) = \prod_{i=1}^{n} p^{X_i}(1-p)^{1-X_i} = p^K(1-p)^{n-K}, \qquad LL(p) = K\log p + (n-K)\log(1-p).$$

اگر $0 < K < n$:

$$\frac{\mathrm{d}LL}{\mathrm{d}p} = \frac{K}{p} - \frac{n-K}{1-p} = 0 \;\Rightarrow\; K(1-p) = (n-K)p \;\Rightarrow\; \boxed{\hat{p}_{\mathrm{ML}} = \frac{K}{n} = \bar{X}_n}$$

و $\frac{\mathrm{d}^2LL}{\mathrm{d}p^2} = -\frac{K}{p^2} - \frac{n-K}{(1-p)^2} < 0$ نزولی است و بیشینه در مرز $\hat{p} = 0$ رخ می‌دهد (بیشینه). اگر $K = 0$ باشد، $L(p) = (1-p)^n$ (اینجا مشتق صفر نمی‌شود!)؛ به طور مشابه $K = n \Rightarrow \hat{p} = 1$. پس در همه حالات $\hat{p}_{\mathrm{ML}} = K/n$.

خواص: $\mathbb{E}\hat{p} = p$ (بی‌گرایش)، $\operatorname{Var}\hat{p} = \frac{p(1-p)}{n} \to 0$ (پس سازگار). مثال سکه ابتدای جلسه حالت خاص $n = 3, K = 2$ است. ■

مثال ۲۱-۱۱: پواسون

$X_1, \ldots, X_n \sim \mathrm{Pois}(\lambda)$ i.i.d. به صورت MLE پارامتر λ را بیابید.

حل.

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{X_i}}{X_i!} \;\Rightarrow\; LL(\lambda) = -n\lambda + \Big(\sum_i X_i\Big)\log\lambda - \sum_i \log(X_i!).$$

$$\frac{\mathrm{d}LL}{\mathrm{d}\lambda} = -n + \frac{\sum_i X_i}{\lambda} = 0 \;\Rightarrow\; \boxed{\hat{\lambda}_{\mathrm{ML}} = \bar{X}_n}, \qquad \frac{\mathrm{d}^2LL}{\mathrm{d}\lambda^2} = -\frac{\sum_i X_i}{\lambda^2} < 0.$$

(اگر همه $X_i = 0$ باشند، $L = e^{-n\lambda}$ نزولی است و $\hat{\lambda} = 0 = \bar{X}_n$.) این تخمین‌گر بی‌گرایش با واریانس $\frac{\lambda}{n}$ و سازگار است (تمرین جلسه قبل). ■

مثال ۲۱-۱۲: نمایی: یک MLE گرایش‌دار

$X_1, \ldots, X_n \sim \mathrm{Exp}(\lambda)$ با چگالی $f(x;\lambda) = \lambda e^{-\lambda x}$ برای $x \geq 0$. MLE پارامتر λ را بیابید، گرایش آن را محاسبه کرده و یک تخمین‌گر بی‌گرایش بسازید.

حل.

$$L(\lambda) = \lambda^n e^{-\lambda\sum_i X_i}, \qquad LL(\lambda) = n\log\lambda - \lambda\sum_i X_i,$$

$$\frac{\mathrm{d}LL}{\mathrm{d}\lambda} = \frac{n}{\lambda} - \sum_i X_i = 0 \;\Rightarrow\; \boxed{\hat{\lambda}_{\mathrm{ML}} = \frac{n}{\sum_i X_i} = \frac{1}{\bar{X}_n}}, \qquad \frac{\mathrm{d}^2LL}{\mathrm{d}\lambda^2} = -\frac{n}{\lambda^2} < 0.$$

گرایش: $S = \sum_i X_i \sim \mathrm{Erlang}(n,\lambda)$ با چگالی $f_S(s) = \frac{\lambda^n s^{n-1}e^{-\lambda s}}{(n-1)!}$. برای $n \geq 2$:

$$\mathbb{E}\Big[\frac{1}{S}\Big] = \int_0^\infty \frac{1}{s}\cdot\frac{\lambda^n s^{n-1}e^{-\lambda s}}{(n-1)!}\,\mathrm{d}s = \frac{\lambda}{n-1}\underbrace{\int_0^\infty \frac{\lambda^{n-1}s^{n-2}e^{-\lambda s}}{(n-2)!}\,\mathrm{d}s}_{=1\ (\text{چگالی } \mathrm{Erlang}(n-1,\lambda))} = \frac{\lambda}{n-1}.$$

پس $\mathbb{E}\hat\lambda_{\text{ML}} = \frac{n\lambda}{n-1} > \lambda$: MLE **گرایش‌دار** است (به سمت بالا)، هرچند گرایش با $n \to \infty$ صفر می‌شود. این هم از ینسن قابل پیش‌بینی بود: $1/x$ محدب است، پس $\mathbb{E}[1/\bar X] > 1/\mathbb{E}\bar X = \lambda$.
تخمین‌گر بی‌گرایش: $\tilde\lambda = \frac{n-1}{n}\hat\lambda_{\text{ML}} = \frac{n-1}{\sum_i X_i}$.
سازگاری: $\bar X_n \to \frac{1}{\lambda}$ (a.s.) و $x \mapsto 1/x$ در $\frac{1}{\lambda} > 0$ پیوسته است؛ پس $\hat\lambda_{\text{ML}} \to \lambda$.
عددی: برای داده‌های $1.2,\ 0.4,\ 2.5,\ 0.9,\ 1.5$ (زمان‌های بین ورود مشتریان، به دقیقه): $\sum X_i = 6.5$، $\hat\lambda_{\text{ML}} = \frac{5}{6.5} \approx 0.769$ و $\tilde\lambda = \frac{4}{6.5} \approx 0.615$ مشتری در دقیقه. ■

جمع‌بندی MLE توزیع‌های مشهور (یک پارامتر نامعلوم)

توزیع	پارامتر	$\hat\theta_{\text{ML}}$	بی‌گرایش؟
$\text{Bernoulli}(p)$	p	$\bar X_n$	بله
$\text{Pois}(\lambda)$	λ	$\bar X_n$	بله
$\mathcal{N}(\mu, \sigma^2)$، σ معلوم	μ	$\bar X_n$	بله
$\mathcal{N}(\mu, \sigma^2)$، μ معلوم	σ^2	$\frac{1}{n}\sum(X_i-\mu)^2$	بله
$\mathcal{N}(\mu, \sigma^2)$، μ معلوم	σ	$\sqrt{\frac{1}{n}\sum(X_i-\mu)^2}$	خیر
$\text{Exp}(\lambda)$	λ	$1/\bar X_n$	خیر

همه موارد بالا سازگارند.

۸.۲۱ تمرین‌های تکمیلی

تمرین ۲۱-۱۳

نمونه‌های $X_1, \dots, X_n$ i.i.d. از توزیع هندسی $P(X = x) = (1-p)^{x-1}p$، $x = 1, 2, \dots$ هستند. MLE پارامتر p را بیابید.

حل. $L(p) = p^n(1-p)^{\sum_i X_i - n}$ و $LL = n\log p + \big(\sum_i X_i - n\big)\log(1-p)$.

$$\frac{\mathrm{d}LL}{\mathrm{d}p} = \frac{n}{p} - \frac{\sum_i X_i - n}{1-p} = 0 \;\Rightarrow\; n(1-p) = p\Big(\sum_i X_i - n\Big) \;\Rightarrow\; \hat p_{\text{ML}} = \frac{n}{\sum_i X_i} = \frac{1}{\bar X_n}.$$

شهود: میانگین توزیع هندسی $\frac{1}{p}$ است و MLE معکوس میانگین نمونه‌ای است. (اگر همه $X_i = 1$ باشند، $\hat p = 1$ که با بیشینه در مرز سازگار است.) ■

تمرین ۲۱-۱۴

نمونه‌های i.i.d. از توزیع رایلی با چگالی $f(x;\sigma^2)=\frac{x}{\sigma^2}e^{-x^2/(2\sigma^2)}$، $x\ge 0$ داریم. MLE پارامتر $s=\sigma^2$ را بیابید و نشان دهید بی‌گرایش است.

حل. $LL(s)=\sum_i \log X_i - n\log s - \frac{1}{2s}\sum_i X_i^2$. پس

$$\frac{\mathrm{d}LL}{\mathrm{d}s}=-\frac{n}{s}+\frac{1}{2s^2}\sum_i X_i^2=0 \;\Rightarrow\; \hat{s}_{\mathrm{ML}}=\frac{1}{2n}\sum_{i=1}^{n}X_i^2.$$

برای رایلی $\mathbb{E}X^2=2\sigma^2$ (چون $X^2\sim\mathrm{Exp}$ با میانگین $2\sigma^2$)؛ پس $\mathbb{E}\hat{s}_{\mathrm{ML}}=\frac{1}{2n}\cdot n\cdot 2\sigma^2=\sigma^2$: بی‌گرایش است. ■

تمرین ۲۱-۱۵

برای نمونه‌های نمایی، MLE احتمال $q=\mathbb{P}(X>t)$ (مثلاً احتمال اینکه قطعه‌ای بیش از t ساعت کار کند) را بیابید. برای داده‌های مثال نمایی بالا و $t=2$ مقدار آن را حساب کنید.

حل. $q=e^{-\lambda t}$ تابع یک‌به‌یکی از λ است. طبق ناوردایی: $\hat{q}_{\mathrm{ML}}=e^{-\hat{\lambda}_{\mathrm{ML}}t}=e^{-t/\bar{X}_n}$. با $\bar{X}=1.3$ و $t=2$: $\hat{q}=e^{-2/1.3}\approx e^{-1.538}\approx 0.215$. ■

تمرین ۲۱-۱۶

یک پزشک $n=50$ بیمار را آزمایش کرده و $K=12$ مورد مثبت مشاهده کرده است. با فرض برنولی بودن نتایج، (الف) MLE احتمال ابتلا را بیابید؛ (ب) MLE نسبت شانس $\eta=\frac{p}{1-p}$ را بیابید؛ (ج) انحراف معیار تقریبی تخمین p را حساب کنید.

حل. (الف) $\hat{p}=\frac{12}{50}=0.24$. (ب) $g(p)=\frac{p}{1-p}$ روی $(0,1)$ یک‌به‌یک است؛ پس $\hat{\eta}=\frac{0.24}{0.76}\approx 0.316$. (ج) $\sqrt{\mathrm{Var}\,\hat{p}}=\sqrt{\frac{p(1-p)}{n}}$ که با جایگذاری $\hat{p}$: $\sqrt{\frac{0.24\times 0.76}{50}}\approx 0.060$. ■

تمرین ۲۱-۱۷

نشان دهید برای هر نمونه i.i.d. از توزیعی با میانگین μ و واریانس متناهی، $\mathbb{E}[(\bar{X}_n-\mu)^2]=\frac{\sigma^2}{n}$ و نتیجه بگیرید که اگر بخواهیم انحراف معیار تخمین μ در مثال عددی گاوسی بالا ($\sigma=0.6$) حداکثر 0.1 باشد، حداقل چند نمونه لازم است.

حل. $\mathbb{E}[(\bar{X}_n-\mu)^2]=\mathrm{Var}(\bar{X}_n)=\frac{1}{n^2}\sum_i \mathrm{Var}\,X_i=\frac{\sigma^2}{n}$ (استقلال). شرط $\frac{0.6}{\sqrt{n}}\le 0.1$ معادل $\sqrt{n}\ge 6$، یعنی $n\ge 36$ نمونه. ■

تمرین ۲۱-۱۸

فرض کنید $X_1,\dots,X_n$ i.i.d. با چگالی $f(x;\theta)=\theta x^{\theta-1}$ برای $0<x<1$ و $\theta>0$ باشند. MLE پارامتر θ را بیابید.

حل. $LL(\theta) = n\log\theta + (\theta-1)\sum_i \log X_i$. مشتق: $\frac{n}{\theta} + \sum_i \log X_i = 0$؛ پس

$$\hat{\theta}_{\mathrm{ML}} = -\frac{n}{\sum_{i=1}^{n} \log X_i}.$$

چون $0 < X_i < 1$، $\log X_i < 0$ و تخمین مثبت است. مشتق دوم $-\frac{n}{\theta^2} < 0$؛ پس بیشینه است. (توجه: $-\log X_i \sim \mathrm{Exp}(\theta)$، پس این مسئله در واقع همان مثال نمایی است و $\hat{\theta}_{\mathrm{ML}}$ نیز به همان دلیل گرایش‌دار است.) ■

جلسه ۲۲

بیشینه درست‌نمایی: مثال‌های پیشرفته

اسلایدهای این جلسه ابتدا تعریف تخمین‌گر بیشینه درست‌نمایی (حالت گسسته و پیوسته)، تابع Log-Likelihood، خواص کلی MLE و دو مثال گاوسی (میانگین با واریانس معلوم و واریانس با میانگین معلوم) را مرور می‌کنند؛ این مطالب به طور کامل در جلسه ۲۱ آمده است. در این فصل، پس از یک خلاصه کوتاه، به مثال‌های جدید می‌پردازیم: تابع هدف **مشتق‌ناپذیر**، بهینه‌سازی **بدون جواب تحلیلی**، یک مثال **گسسته** ساده، و بهینه‌سازی **دومتغیره**.

خلاصه جلسه قبل

- پارامتر θ غیرتصادفی ولی نامعلوم است و نمونه‌های $X_1, \dots, X_n$ به صورت i.i.d. از $f_X(x;\theta)$ (یا $P_X(x;\theta)$) گرفته شده‌اند.
- تعریف MLE و تابع لگاریتم درست‌نمایی:

$$\hat{\theta}_{\mathrm{ML}} = \arg\max_{\theta} \prod_{i=1}^{n} f_X(X_i;\theta) = \arg\max_{\theta} \; LL(\theta; X_{1:n}),$$

$$LL(\theta; X_{1:n}) = \sum_{i=1}^{n} \log f_X(X_i;\theta).$$

- MLE از حیث بیشینه کردن احتمال مشاهده داده‌ها بهینه است، (تحت شرایط نظم) **سازگار** است، اما لزوماً **بی‌گرایش** نیست و لزوماً کمینه واریانس را ندارد.
- گاوسی با σ^2 معلوم: $\hat{\mu}_{\mathrm{ML}} = \bar{X}_n$ (بی‌گرایش، سازگار، $\mathrm{Var} = \sigma^2/n$). گاوسی با μ معلوم: $\hat{\sigma}^2_{\mathrm{ML}} = \frac{1}{n}\sum_i (X_i - \mu)^2$ (بی‌گرایش، سازگار)؛ اما $\hat{\sigma}_{\mathrm{ML}} = \sqrt{\hat{\sigma}^2_{\mathrm{ML}}}$ برای σ گرایش‌دار (ولی سازگار) است.
- **ناوردایی:** $\widehat{g(\theta)}_{\mathrm{ML}} = g(\hat{\theta}_{\mathrm{ML}})$.

۱.۲۲ بهینه‌سازی با تابع هدف غیرمشتق‌پذیر: حدود توزیع یکنواخت

مثال ۲۲-۱: حد بالای توزیع یکنواخت

فرض کنید متغیر تصادفی X دارای توزیعی یکنواخت در بازه $[0, \theta]$ است که در اینجا θ (با $\theta > 0$) مقداری نامعلوم است. در صورتی که نمونه‌های $X_1, X_2, \ldots, X_n$ به صورت i.i.d. از این توزیع تولید شده باشند، تخمین‌گر بیشینه درست‌نمایی برای θ را بیابید.

حل. چگالی را با تابع نشانگر می‌نویسیم:

$$f_X(x;\theta) = \frac{1}{\theta}\,\mathbf{1}_{0\le x\le\theta}.$$

حاصل‌ضرب چگالی‌ها:

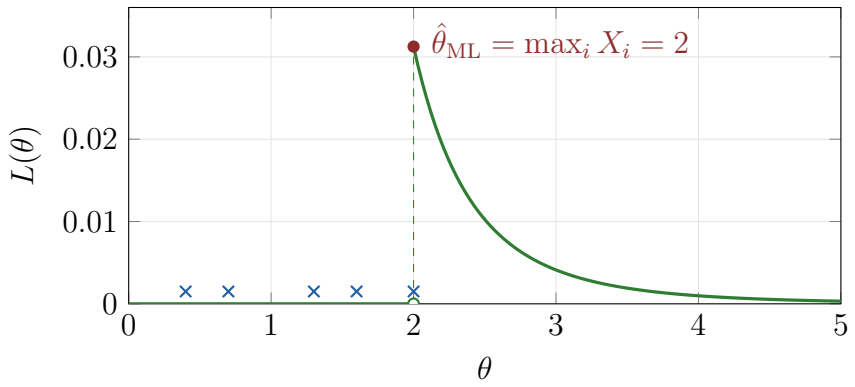
$$\prod_{i=1}^{n} f_X(X_i;\theta) = \frac{1}{\theta^n}\prod_{i=1}^{n}\mathbf{1}_{0\le X_i\le\theta} = \frac{1}{\theta^n}\,\mathbf{1}_{0\le X_1,\ldots,X_n\le\theta} = \frac{1}{\theta^n}\,\mathbf{1}_{\theta\ge\max_i X_i}.$$

(حاصل‌ضرب نشانگرها فقط وقتی 1 است که **همه** شرط‌ها برقرار باشند، و $X_i \ge 0$ همواره برقرار است؛ پس تنها شرط مؤثر $\theta \ge X_i$ برای همه i، یعنی $\theta \ge \max_i X_i$ است.)

چرا مشتق کار نمی‌کند؟ مشتق θ^{-n} برابر $-n\theta^{-n-1}$ است که هرگز صفر نمی‌شود! درست‌نمایی در $\theta = \max_i X_i$ یک **ناپیوستگی** (پرش) دارد: برای $\theta < \max_i X_i$ صفر است (مشاهده بزرگ‌ترین نمونه غیرممکن می‌شود) و برای $\theta \ge \max_i X_i$ برابر θ^{-n} و **اکیداً نزولی** است. پس بیشینه در کوچک‌ترین مقدار مجاز رخ می‌دهد:

$$\Rightarrow\ \hat\theta_{\mathrm{ML}} = \min\ \theta \quad \text{subject to} \quad \theta \ge X_1, \ldots, X_n \qquad \Rightarrow \qquad \boxed{\hat\theta_{\mathrm{ML}} = \max\left(X_1, \ldots, X_n\right)}$$

■



تابع درست‌نمایی $\mathcal{U}(0,\theta)$ برای $n = 5$ مشاهده (علامت‌های $\times$): $0.4, 0.7, 1.3, 1.6, 2.0$. برای $\theta < 2$ درست‌نمایی صفر است و پس از آن به صورت θ^{-5} نزول می‌کند؛ بیشینه روی لبه ناپیوستگی قرار دارد.

۱.۱.۲۲ خواص تخمین بیشینه درست‌نمایی در این مثال

- واضح است که تخمین‌گر MLE در این حالت **بدون گرایش نیست**. چرا که با احتمال یک

$$\max_i(X_i) < \theta \quad \Rightarrow \quad \mathbb{E}\big(\hat{\theta}_{\mathrm{ML}} = \max(X_{1:n})\big) < \theta.$$

یعنی تخمین‌گر همواره از مقدار واقعی کوچک‌تر است، پس میانگینش هم کوچک‌تر است (گرایش به سمت پایین).

- می‌توان دید که تخمین‌گر MLE در این مثال نیز (مانند همیشه) **سازگار** است. برای $0 < \varepsilon < \theta$:

$$\mathbb{P}\big(|\max X_{1:n} - \theta| > \varepsilon\big) = \mathbb{P}\big(\max X_{1:n} < \theta - \varepsilon\big) = \prod_{i=1}^{n} \mathbb{P}(X_i < \theta - \varepsilon) = \Big(1 - \frac{\varepsilon}{\theta}\Big)^n$$

(تساوی اول چون $\max \le \theta$ همواره برقرار است، و تساوی دوم به دلیل استقلال: بیشینه کمتر از یک مقدار است اگر و تنها اگر همه نمونه‌ها کمتر از آن باشند.) چون $0 < 1 - \frac{\varepsilon}{\theta} < 1$:

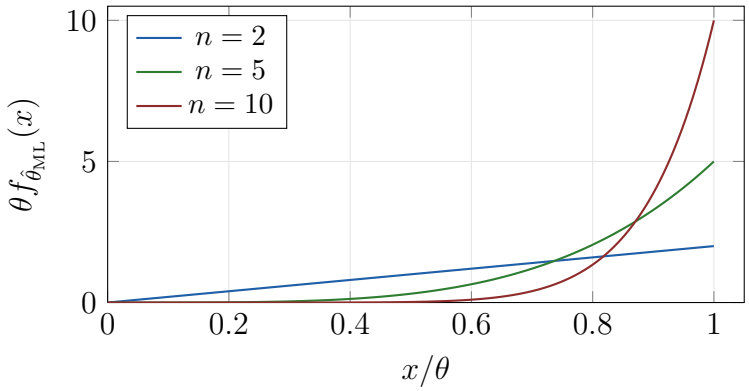
$$\Rightarrow \quad \lim_{n\to\infty} \mathbb{P}\big(|\hat{\theta}_{\mathrm{ML}} - \theta| > \varepsilon\big) = 0, \qquad \forall \varepsilon > 0$$

(برای $\varepsilon \ge \theta$ احتمال از ابتدا صفر است).

نکته. عبارت $\lim_{n\to\infty} \mathbb{P}(|\hat{\theta}_{\mathrm{ML}} - \theta| > \varepsilon) = 0$ برای هر $\varepsilon > 0$، به معنی **یک شکل از همگرایی**

$$\lim_{n\to\infty} \hat{\theta}_{\mathrm{ML}}(X_{1:n}) = \theta$$

است که **همگرایی در احتمال** (convergence in probability) نام دارد: احتمال اینکه تخمین‌گر بیش از هر مقدار ثابت ε از θ فاصله داشته باشد، به صفر میل می‌کند. در این مثال حتی همگرایی **تقریباً حتمی** نیز برقرار است: دنباله $\max(X_1, \dots, X_n)$ برحسب n **صعودی** و از بالا به θ محدود است، پس حتماً به حدی مانند $M \le \theta$ همگراست؛ و چون $\mathbb{P}(M < \theta - \varepsilon) \le (1 - \frac{\varepsilon}{\theta})^n \to 0$ برای هر n، داریم $M = \theta$ با احتمال یک.



چگالی $\hat{\theta}_{\mathrm{ML}} = \max_i X_i$ (یعنی nx^{n-1}/θ^n) برای چند مقدار n: با افزایش n جرم احتمال در نزدیکی θ (از سمت چپ) متمرکز می‌شود ــ هم گرایش و هم واریانس به صفر میل می‌کنند.

۲.۱.۲۲ تخمین‌گر بی‌گرایش و سازگار برای θ

- فرض کنید بخواهیم مشکل گرایش‌دار (Biased) بودن تخمین‌گر MLE در این مثال (تخمین حد بالای یک توزیع یکنواخت) را حل کنیم.

- ابتدا مقدار میانگین $\hat{\theta}_{\mathrm{ML}} = \max(X_1, \dots, X_n)$ را محاسبه می‌کنیم. از بحث آماره‌های ترتیبی (جلسه ۱۷) می‌دانیم که اگر $X_1, \dots, X_n \sim f_X(x)$ متغیرهای تصادفی i.i.d. باشند، آنگاه

$$\max_i(X_i) \sim n f_X(x) F_X^{n-1}(x)$$

(چون $F_{\max}(x) = \mathbb{P}(\text{همه} \le x) = F_X^n(x)$ و با مشتق‌گیری). که در حالت $X \sim \mathrm{Unif}(0, \theta)$ با $F_X(x) = x/\theta$ خواهیم داشت:

$$\max_i(X_i) \sim \frac{n x^{n-1}}{\theta^n} \mathbf{1}_{0 \le x \le \theta}.$$

- مقدار $\mathbb{E}\hat{\theta}_{\mathrm{ML}}$ مطابق زیر محاسبه خواهد شد:

$$\mathbb{E}\hat{\theta}_{\mathrm{ML}} = \int_0^\theta x \cdot \frac{n x^{n-1}}{\theta^n} \, \mathrm{d}x = \int_0^\theta \frac{n x^n}{\theta^n} \, \mathrm{d}x = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \Big(\frac{n}{n+1}\Big)\theta.$$

گرایش (با تعریف درس) برابر $\theta - \mathbb{E}\hat{\theta}_{\mathrm{ML}} = \frac{\theta}{n+1}$ است.

- همان‌گونه که پیش‌تر نیز می‌دانستیم، $\hat{\theta}_{\mathrm{ML}}$ یک تخمین‌گر Biased است. اما در صورتی که تخمین‌گر جدیدی به صورت

$$\hat{\theta}_* \triangleq \frac{n+1}{n} \hat{\theta}_{\mathrm{ML}}$$

تعریف کنیم، آنگاه:

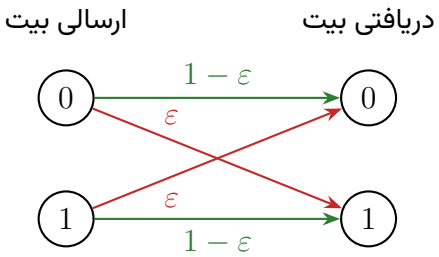
  - $\hat{\theta}_*$ یک تخمین‌گر Unbiased برای θ است: $\mathbb{E}\hat{\theta}_* = \frac{n+1}{n} \cdot \frac{n}{n+1}\theta = \theta$.
  - $\hat{\theta}_*$ سازگار نیز هست: $\frac{n+1}{n} \to 1$ و $\hat{\theta}_{\mathrm{ML}} \to \theta$، پس حاصل‌ضرب به θ میل می‌کند.
  - اما $\hat{\theta}_*$ دیگر از منظر بیشینه درست‌نمایی **بهینه نیست:** چون $\hat{\theta}_* > \hat{\theta}_{\mathrm{ML}}$ و $L(\theta) = \theta^{-n}$ در این ناحیه اکیداً نزولی است، $L(\hat{\theta}_*) < L(\hat{\theta}_{\mathrm{ML}})$.

نکته. مقایسه MSE. در جلسه ۲۰ دیدیم: $\mathrm{MSE}(\hat{\theta}_{\mathrm{ML}}) = \frac{2\theta^2}{(n+1)(n+2)}$ و $\mathrm{MSE}(\hat{\theta}_*) = \frac{\theta^2}{n(n+2)}$. برای $n \ge 2$ داریم $\frac{1}{n} < \frac{2}{n+1}$، پس در این مثال تخمین‌گر بی‌گرایش، MSE کمتری هم دارد (برای $n = 1$ برابرند). همچنین خطا از مرتبه $\frac{1}{n^2}$ است و نه $\frac{1}{n}$: در این مسئله تکیه‌گاه توزیع به θ وابسته است، شرایط نظم برقرار نیست و MLE (به جای رفتار گاوسی مجانبی با نرخ $\frac{1}{\sqrt{n}}$) با نرخ سریع‌تر $\frac{1}{n}$ همگرا می‌شود؛ در واقع $\frac{n(\theta - \hat{\theta}_{\mathrm{ML}})}{\theta}$ به توزیع $\mathrm{Exp}(1)$ همگراست، چون $\mathbb{P}\big(n(\theta - \hat{\theta}_{\mathrm{ML}}) > t\theta\big) = (1 - \frac{t}{n})^n \to e^{-t}$.

۲.۲۲ بهینه‌سازی بدون جواب تحلیلی: بازیابی رشته دودویی از کانال نویزی

مثال ۲۲-۲: بازیابی یک رشته دودویی ارسالی در گیرنده یک کانال نویزی

فرض کنید یک رشته دودویی kتایی (یعنی عضو $\{0,1\}^k$) توسط یک فرستنده روی یک کانال نویزی برای گیرنده فرستاده می‌شود. هر بیت ارسالی، مستقل از سایرین با احتمال دانسته‌شده ε عوض شده و با احتمال $1-\varepsilon$ تغییر نمی‌کند. به منظور کاهش احتمال خطا، رشته قبل از ارسال کدگذاری شده است. لذا می‌دانیم تعداد بیت‌های ۱ در این رشته حتماً عددی **زوج** است. در صورت مشاهده یک نمونه نویزی‌شده از این رشته در گیرنده، تخمین بیشینه درست‌نمایی از رشته اصلی را به دست آورید.



کانال دودویی متقارن (Binary Symmetric Channel, BSC) با احتمال خطای ε.

حل. مدل‌سازی. در اینجا «پارامتر» نامعلوم، خود رشته ارسالی $x=(x_1,\dots,x_k)$ است که مقداری **گسسته** در مجموعه

$$\mathcal{C}=\Big\{x\in\{0,1\}^k:\ \sum_{j=1}^{k}x_j \text{ زوج}\Big\},\qquad |\mathcal{C}|=2^{k-1}$$

دارد (فضای پارامتر $\Theta=\mathcal{C}$). مشاهده، رشته دریافتی $y\in\{0,1\}^k$ است. با تعریف **فاصله همینگ** $d(x,y)=$ تعداد مکان‌هایی که x و y با هم تفاوت دارند، و به دلیل مستقل بودن خطای بیت‌ها:

$$\mathbb{P}(y;x)=\prod_{j=1}^{k}\mathbb{P}(y_j;x_j)=\varepsilon^{d(x,y)}(1-\varepsilon)^{k-d(x,y)}=(1-\varepsilon)^k\Big(\frac{\varepsilon}{1-\varepsilon}\Big)^{d(x,y)}.$$

پس

$$\hat{x}_{\mathrm{ML}}=\arg\max_{x\in\mathcal{C}}\ (1-\varepsilon)^k\Big(\frac{\varepsilon}{1-\varepsilon}\Big)^{d(x,y)}.$$

اینجا هیچ مشتقی در کار نیست: یک مسئله بهینه‌سازی **ترکیبیاتی** روی 2^{k-1} گزینه است. رفتار جواب به ε بستگی دارد:

حالت ۱: $\varepsilon<\frac{1}{2}$ **(حالت معمول).** آنگاه $\frac{\varepsilon}{1-\varepsilon}<1$ و درست‌نمایی با افزایش d کاهش می‌یابد؛ پس

$$\hat{x}_{\mathrm{ML}}=\arg\min_{x\in\mathcal{C}}\ d(x,y)\qquad \text{(رمزگشایی کمینه فاصله)}.$$

- اگر تعداد یک‌های y **زوج** باشد، $y\in\mathcal{C}$ و با $d=0$: $\hat{x}_{\mathrm{ML}}=y$ (یکتا).

- اگر تعداد یک‌های y **فرد** باشد، $y \notin \mathcal{C}$ و کمترین فاصله ممکن 1 است: **هر** رشته‌ای که از تغییر **یک** بیت دلخواه y به دست آید، زوجیت را درست می‌کند. پس k جواب هم‌ارز وجود دارد و MLE **یکتا نیست!** این کد می‌تواند وجود خطا را **آشکار** کند ولی نمی‌تواند آن را **تصحیح** کند.

حالت ۲: $\varepsilon > \frac{1}{2}$. آنگاه $\frac{\varepsilon}{1-\varepsilon} > 1$ و باید فاصله را **بیشینه** کرد: اگر متمم $\bar{y}$ (همه بیت‌ها معکوس) در $\mathcal{C}$ باشد (یعنی $k - w(y)$ زوج باشد، که $w(y)$ تعداد یک‌های y است) آنگاه $\hat{x} = \bar{y}$ با $d = k$؛ وگرنه هر رشته با فاصله $k-1$ (متمم y با یک بیت برگشته). معادلاً: ابتدا همه بیت‌های y را معکوس کرده و سپس قاعده حالت ۱ را با $1-\varepsilon$ به کار ببرید.

حالت ۳: $\varepsilon = \frac{1}{2}$. درست‌نمایی برای همه x برابر 2^{-k} است؛ همه 2^{k-1} رشته مجاز، MLE هستند. مشاهده هیچ اطلاعاتی درباره ورودی ندارد (کانال کاملاً تصادفی است).

مثال عددی. $k = 4$، $\varepsilon = 0.1$ و $y = 1011$ (سه یک، فرد). هشت رشته مجاز و فاصله‌شان از y:

x	0000	0011	0101	0110	1001	1010	1100	1111
$d(x,y)$	3	1	3	3	1	1	3	1

چهار رشته 0011، 1001، 1010 و 1111 با درست‌نمایی $\varepsilon(1-\varepsilon)^3 = 0.0729$ همگی MLE هستند؛ چهار رشته دیگر درست‌نمایی $\varepsilon^3(1-\varepsilon) = 0.0009$ دارند. (اگر همه رشته‌های مجاز از پیش هم‌احتمال باشند، احتمال درست بودن هر یک از چهار گزینه اول با قاعده بیز $\frac{0.0729}{4(0.0729)+4(0.0009)} \approx 0.247$ است.)

چرا «بدون جواب تحلیلی»؟ برای این کد ساده (توازن زوج) جواب را با استدلال یافتیم؛ اما در حالت کلی، کدهای خطی با ماتریس توازن H استفاده می‌شوند ($\mathcal{C} = \{x : Hx = 0\}$ در حساب پیمانه ۲) و MLE یعنی یافتن نزدیک‌ترین کلمه کد به y (معادلاً کم‌وزن‌ترین الگوی خطای e با $He = Hy$). هیچ فرمول بسته‌ای برای آن وجود ندارد؛ جست‌وجوی کامل به $|\mathcal{C}|$ مقایسه نیاز دارد که به صورت **نمایی** با طول پیام رشد می‌کند، و ثابت شده است که این مسئله در حالت کلی **NP-سخت** است (برلکمپ، مک‌الیس و ون تیلبورگ، ۱۹۷۸). این همان نکته اسلاید خواص است: حل عددی MLE ممکن است بسیار زمان‌بر باشد. (به همین دلیل در عمل از کدهایی با ساختار خاص، مانند کدهای کانولوشنی با الگوریتم ویتربی، استفاده می‌شود که رمزگشایی ML برایشان کارآمد است.) ■

۳.۲۲ یک مثال ساده (گسسته): یافتن تعداد کارت‌های درون یک جعبه

مثال ۲۲-۳: تعداد کارت‌ها

فرض کنید n کارت شامل اعداد به ترتیب 1 تا n را درون یک جعبه انداخته و سپس یکی را به صورت تصادفی انتخاب می‌کنیم. روی کارت عدد X نمایش داده شده است.

- در صورتی که مقدار n را ندانیم و بخواهیم آن را بر اساس X تخمین بزنیم، تخمین‌گر بیشینه درست‌نمایی را برای آن بیابید.
- آیا این تخمین‌گر بی‌گرایش $(\mathrm{unbiased})$ است؟ تخمین‌گر بدون گرایش برای n برحسب X چه خواهد بود؟

حل. تابع درست‌نمایی (likelihood) مطابق زیر قابل نوشتن است ($n \in \{1,2,3,\dots\}$ پارامتر و X ثابت):

$$\mathbb{P}(X;n) = \frac{1}{n}\,\mathbf{1}_{X\le n}.$$

برای $n < X$ مقدار صفر است (کارتی با عدد X در جعبه نیست) و برای $n \ge X$ برابر $\frac{1}{n}$ است که با n کاهش می‌یابد. پس کوچک‌ترین n مجاز را انتخاب می‌کنیم. لذا، می‌توان به راحتی دید که داریم:

$$\boxed{\hat{n}_{\mathrm{ML}} = X}$$

(این همتای گسسته مثال توزیع یکنواخت پیوسته است: بیشینه درست‌نمایی روی لبه تکیه‌گاه.)
اما این تخمین‌گر Unbiased نیست، چرا که داریم

$$\mathbb{E}X = \frac{1}{n}(1+2+\cdots+n) = \frac{1}{n}\cdot\frac{n(n+1)}{2} = \frac{n+1}{2} \neq n \qquad (n \ge 2).$$

گرایش $n - \frac{n+1}{2} = \frac{n-1}{2}$ است (و بر خلاف مثال‌های قبل، به صفر میل نمی‌کند؛ چون همیشه فقط یک کارت داریم و «$n \to \infty$ نمونه» معنا ندارد).
تخمین‌گر بی‌گرایش: از $\mathbb{E}X = \frac{n+1}{2}$ داریم $n = 2\mathbb{E}X - 1 = \mathbb{E}(2X-1)$. پس می‌توان تحقیق نمود که تخمین‌گر

$$\boxed{\hat{n}_* = 2X - 1}$$

یک تخمین‌گر **بدون گرایش** برای n است: $\mathbb{E}\hat{n}_* = 2\cdot\frac{n+1}{2} - 1 = n$. اما دیگر از حیث بیشینه درست‌نمایی **بهینه** نیست (برای $X \ge 2$ داریم $2X-1 > X$ و $\frac{1}{2X-1} < \frac{1}{X}$).
مقایسه MSE (فراتر از اسلاید). با $\operatorname{Var} X = \frac{n^2-1}{12}$ (یکنواخت گسسته):

$$\mathrm{MSE}(\hat{n}_*) = \operatorname{Var}(2X-1) = \frac{n^2-1}{3},$$
$$\mathrm{MSE}(\hat{n}_{\mathrm{ML}}) = \operatorname{Var} X + \left(\frac{n-1}{2}\right)^2 = \frac{(n-1)(2n-1)}{6}.$$

چون $(n-1)(2n-1) \le 2(n-1)(n+1)$، تخمین‌گر ML (با وجود گرایش) MSE کمتری دارد! مثلاً برای $n = 10$: 28.5 در برابر 33. باز هم مصالحه گرایش–واریانس. ■

۴.۲۲ بهینه‌سازی دومتغیره با تابع هدف مشتق‌پذیر: گاوسی با میانگین و واریانس نامعلوم

مثال ۲۲-۴: تخمین همزمان میانگین و واریانس توزیع گاوسی

فرض کنید متغیر تصادفی $X \sim \mathcal{N}(\mu, \sigma^2)$ به ترتیب دارای میانگین و واریانس نامعلوم μ و σ^2 باشد. در صورتی که نمونه‌های $X_1, \dots, X_n$ به صورت i.i.d. از این توزیع گرفته شده باشند، تخمین‌گر MLE برای زوج مرتب $\theta = (\mu, \sigma^2)$ را به دست آورید.

حل.

$$f_X(x;\theta)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}} \;\Rightarrow\; \prod_{i=1}^{n} f_X(X_i;\theta)=\Big(\frac{1}{\sqrt{2\pi}\sigma}\Big)^n \exp\Big[-\sum_{i=1}^{n}\frac{(X_i-\mu)^2}{2\sigma^2}\Big]$$

$$\Rightarrow\; LL(\theta;X_{1:n})=-n\log\sigma-\sum_{i=1}^{n}\frac{(X_i-\mu)^2}{2\sigma^2}+\text{const.}$$

اکنون LL تابعی از **دو** متغیر است و در نقطه بیشینه باید **گرادیان** صفر شود؛ یعنی هر دو مشتق جزئی:

$$\frac{\partial}{\partial\mu}LL(\theta;X_{1:n})=\sum_{i=1}^{n}\frac{X_i-\mu}{\sigma^2}=0 \quad\Rightarrow\quad \boxed{\hat{\mu}_{\text{ML}}=\bar{X}_n=\frac{1}{n}\sum_{i=1}^{n}X_i}$$

$$\frac{\partial}{\partial\sigma}LL(\theta;X_{1:n})=-\frac{n}{\sigma}+\sum_{i=1}^{n}\frac{(X_i-\mu)^2}{\sigma^3}=0 \quad\Rightarrow\quad \boxed{\hat{\sigma}^2_{\text{ML}}=\frac{1}{n}\sum_{i=1}^{n}\big(X_i-\bar{X}_n\big)^2}$$

(در معادله دوم μ را با جواب معادله اول، $\bar{X}_n$، جایگزین کرده‌ایم. در اسلاید، در مشتق نسبت به μ یک ضریب 2 اضافه نوشته شده است؛ چون عبارت برابر صفر قرار می‌گیرد، در جواب اثری ندارد.)
بیشینه سراسری بودن. برای هر σ ثابت، LL برحسب μ فقط از طریق $-\sum(X_i-\mu)^2$ وابسته است که در $\mu=\bar{X}_n$ بیشینه می‌شود ــ **مستقل از** σ. پس می‌توان ابتدا $\mu=\bar{X}_n$ گذاشت و سپس تابع یک‌متغیره $-n\log\sigma-\frac{\sum(X_i-\bar{X})^2}{2\sigma^2}$ را برحسب σ بیشینه کرد؛ این دقیقاً مثال جلسه قبل (با μ معلوم) است و بیشینه یکتایش در جواب بالاست. (بررسی با ماتریس هسین: در نقطه جواب $\frac{\partial^2 LL}{\partial\mu^2}=-\frac{n}{\hat{\sigma}^2}$، $\frac{\partial^2 LL}{\partial\sigma^2}=-\frac{2n}{\hat{\sigma}^2}$ و مشتق مختلط صفر است؛ ماتریس معین منفی است.) ■

۱.۴.۲۲ خواص تخمین بیشینه درست‌نمایی در این مثال

- واضح است که تخمین‌گر MLE برای میانگین μ در اینجا **بدون گرایش** است (چون مشابه با حالتی است که واریانس σ^2 معلوم بود).
- اما، در مورد $\hat{\sigma}^2_{\text{ML}}$ چه چیزی می‌توان گفت؟

$$\mathbb{E}\hat{\sigma}^2_{\text{ML}}=\frac{1}{n}\sum_{i=1}^{n}\mathbb{E}\Big(\big(X_i-\bar{X}_n\big)^2\Big),$$

$$\mathbb{E}\Big(\big(X_i-\bar{X}_n\big)^2\Big)=\mathbb{E}\big[X_i^2+\bar{X}_n^2-2X_i\bar{X}_n\big]=\mathbb{E}\big[X_i^2\big]+\mathbb{E}\big[\bar{X}_n^2\big]-2\mathbb{E}\big[X_i\bar{X}_n\big].$$

با توجه به اینکه $\mathbb{E}[X_i^2]=\mu^2+\sigma^2$ و $\mathbb{E}[X_iX_j]=\mu^2$ برای $i\neq j$ (استقلال):

$$\mathbb{E}\big[X_i^2\big]=\mu^2+\sigma^2,$$

$$\mathbb{E}\big[\bar{X}_n^2\big]=\frac{1}{n^2}\sum_{i,j=1}^{n}\mathbb{E}\big[X_iX_j\big]=\frac{1}{n^2}\big[n(\mu^2+\sigma^2)+n(n-1)\mu^2\big]=\mu^2+\frac{\sigma^2}{n},$$

$$\mathbb{E}\big[X_i\bar{X}_n\big]=\frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\big[X_iX_j\big]=\frac{1}{n}\big[(\mu^2+\sigma^2)+(n-1)\mu^2\big]=\mu^2+\frac{\sigma^2}{n}.$$

پس $\mathbb{E}\big((X_i-\bar{X}_n)^2\big)=\mu^2+\sigma^2+\mu^2+\frac{\sigma^2}{n}-2\mu^2-\frac{2\sigma^2}{n}=\frac{n-1}{n}\sigma^2$ و

$$\Rightarrow \quad \boxed{\mathbb{E}\hat{\sigma}^2_{\mathrm{ML}}=\Big(\frac{n-1}{n}\Big)\sigma^2}$$

یعنی $\hat{\sigma}^2_{\mathrm{ML}}$ **گرایش‌دار** است و واریانس را به طور متوسط **کمتر** برآورد می‌کند (هرچند گرایش $\frac{\sigma^2}{n}$ با $n\to\infty$ صفر می‌شود و تخمین‌گر سازگار است).

نکته. شهود و اثبات دوم. چون $\bar{X}_n$ مقدار c ای است که $\sum_i(X_i-c)^2$ را **کمینه** می‌کند، همواره $\sum_i(X_i-\bar{X}_n)^2\le\sum_i(X_i-\mu)^2$: داده‌ها به میانگین نمونه‌ای خودشان نزدیک‌ترند تا به میانگین واقعی. دقیق‌تر، با نوشتن $X_i-\mu=(X_i-\bar{X}_n)+(\bar{X}_n-\mu)$:

$$\sum_{i=1}^{n}(X_i-\mu)^2=\sum_{i=1}^{n}(X_i-\bar{X}_n)^2+n(\bar{X}_n-\mu)^2$$

(جمله ضرب متقابل صفر است چون $\sum_i(X_i-\bar{X}_n)=0$). با امید گرفتن: $n\sigma^2=\mathbb{E}\sum_i(X_i-\bar{X}_n)^2+n\cdot\frac{\sigma^2}{n}$، پس $\mathbb{E}\sum_i(X_i-\bar{X}_n)^2=(n-1)\sigma^2$. اصطلاحاً با تخمین μ از روی همان داده‌ها، یک «درجه آزادی» از دست می‌رود.

۲.۴.۲۲ تخمین بدون گرایش (Unbiased) برای σ^2

- در یک توزیع گاوسی، در صورتی که مقدار واقعی میانگین را ندانیم و بخواهیم از تخمین‌گر بیشینه درست‌نمایی برای تخمین واریانس استفاده کنیم، ناچار هستیم تا میانگین را با تخمین میانگین نمونه‌ای (Sample Mean) جایگزین کنیم.
- در این حالت، تخمین‌گر واریانس نمونه‌ای (Sample Variance) دارای گرایش (Biased) خواهد شد.
- یک تخمین‌گر بدون بایاس برای واریانس نمونه‌ای به شکل زیر است:

$$\boxed{\hat{\sigma}^2_{UB}=\frac{1}{n-1}\sum_{i=1}^{n}\big(X_i-\bar{X}_n\big)^2=\frac{n}{n-1}\,\hat{\sigma}^2_{\mathrm{ML}}} \qquad \Rightarrow \qquad \mathbb{E}\hat{\sigma}^2_{UB}=\frac{n}{n-1}\cdot\frac{n-1}{n}\sigma^2=\sigma^2.$$

(این همان S^2 جلسات ۱۸ و ۱۹ است.)

- اما این تخمین‌گر از حیث بیشینه درست‌نمایی **بهینه نیست** (بیشینه درست‌نمایی فقط در $\hat{\sigma}^2_{\mathrm{ML}}$ رخ می‌دهد).

نکته. کدام بهتر است؟ از نظر MSE، طبق جدول جلسه ۲۰: $\mathrm{MSE}(\hat{\sigma}^2_{UB})=\frac{2\sigma^4}{n-1}$ و $\mathrm{MSE}(\hat{\sigma}^2_{\mathrm{ML}})=\frac{(2n-1)\sigma^4}{n^2}$ که دومی همواره کوچک‌تر است (و کوچک‌ترین MSE در این خانواده با ضریب $\frac{1}{n+1}$ به دست می‌آید). بنابراین «بی‌گرایش» و «بهینه از نظر خطا» دو معیار متفاوت‌اند. در عمل S^2 به دلیل بی‌گرایش بودن و نقش آن در آزمون‌ها و بازه‌های اطمینان (توزیع t) رایج‌تر است؛ برای n بزرگ تفاوت ناچیز است.

مثال ۲۲-۵: یک محاسبه عددی

برای داده‌های $4.2,\ 5.1,\ 3.8,\ 4.9,\ 5.6,\ 4.4$ (این بار بدون دانستن σ)، MLE زوج (μ, σ^2) و تخمین بی‌گرایش واریانس را بیابید.

حل. $\hat{\mu}_{\text{ML}} = \bar{X} = \frac{28}{6} \approx 4.667$. انحراف‌ها از میانگین و مجموع مربعات آن‌ها:

$$X_i - \bar{X}: \quad -0.467,\ 0.433,\ -0.867,\ 0.233,\ 0.933,\ -0.267$$

$$\Rightarrow \quad \sum_i (X_i - \bar{X})^2 \approx 2.153.$$

پس

$$\hat{\sigma}^2_{\text{ML}} = \frac{2.153}{6} \approx 0.359, \qquad \hat{\sigma}^2_{UB} = \frac{2.153}{5} \approx 0.431, \qquad \hat{\sigma}_{\text{ML}} = \sqrt{0.359} \approx 0.599.$$

(طبق ناوردایی، $\hat{\sigma}_{\text{ML}} = \sqrt{\hat{\sigma}^2_{\text{ML}}}$ است.) ■

جمع‌بندی: انواع مسائل بهینه‌سازی در MLE

نوع مسئله	مثال	روش حل
مشتق‌پذیر، یک پارامتر	گاوسی، برنولی، پواسون، نمایی	حل $\frac{\mathrm{d}}{\mathrm{d}\theta} LL = 0$ و بررسی بیشینه
مشتق‌پذیر، چند پارامتر	گاوسی با (μ, σ^2) نامعلوم	صفر کردن گرادیان (همه مشتقات جزئی)
مشتق‌ناپذیر (تکیه‌گاه وابسته به θ)	$\mathcal{U}(0, \theta)$، کارت‌ها	بررسی مستقیم شکل $L(\theta)$؛ جواب روی لبه
گسسته/ترکیبیاتی	کانال نویزی	جست‌وجو در فضای گسسته؛ ممکن است NP-سخت باشد

در اغلب این مثال‌ها MLE سازگار است ولی ممکن است گرایش داشته باشد؛ اصلاح گرایش (مانند $\max$، $\frac{n+1}{n}$ و $2X - 1$، $\frac{1}{n-1}$) تخمین‌گر بی‌گرایش می‌دهد که دیگر MLE نیست و لزوماً MSE کمتری هم ندارد.

۵.۲۲ تمرین‌های تکمیلی

تمرین ۲۲-۶: کد تکرار

برای ارسال یک بیت $b \in \{0,1\}$ روی کانال دودویی متقارن با $\varepsilon < \frac{1}{2}$، آن را سه بار تکرار می‌کنیم (000 یا 111). (الف) MLE بیت ارسالی را برحسب رشته دریافتی بیابید. (ب) احتمال خطای این تخمین را حساب کنید و برای $\varepsilon = 0.1$ با ارسال بدون کد مقایسه کنید.

حل. (الف) $\mathcal{C} = \{000, 111\}$ و طبق حالت ۱ مثال کانال نویزی، کلمه کد نزدیک‌تر به y انتخاب می‌شود: اگر حداقل دو بیت y برابر ۱ باشد، $\hat{b} = 1$ وگرنه $\hat{b} = 0$ (**رأی اکثریت**). اینجا MLE همواره یکتاست چون فاصله‌ها d و $3 - d$ هرگز برابر نیستند. (ب) خطا وقتی رخ می‌دهد که حداقل دو بیت از سه بیت عوض شوند:

$$P_e = \binom{3}{2}\varepsilon^2(1-\varepsilon) + \varepsilon^3 = 3(0.01)(0.9) + 0.001 = 0.028,$$

در مقایسه با 0.1 بدون کد (به قیمت سه برابر شدن طول ارسال). ■

تمرین ۲۲-۷: مسئله تانک آلمانی

تانک‌های دشمن با شماره‌های سریال $1, 2, \dots, N$ شماره‌گذاری شده‌اند (N نامعلوم). شماره k تانک (بدون جایگذاری و به تصادف) مشاهده شده و بزرگ‌ترین آن‌ها M است. (الف) MLE مقدار N را بیابید. (ب) نشان دهید $\mathbb{E}M = \frac{k(N+1)}{k+1}$ و یک تخمین‌گر بی‌گرایش بسازید. (ج) برای مشاهدات $19, 40, 42, 60$ هر دو تخمین را حساب کنید.

حل. (الف) هر زیرمجموعه kتایی هم‌احتمال است: احتمال مشاهده این مجموعه خاص $1/\binom{N}{k}$ برای $N \geq M$ و صفر برای $N < M$ است. چون $\binom{N}{k}$ با N صعودی است، درست‌نمایی نزولی است و $\hat{N}_{\mathrm{ML}} = M$ (تعمیم مثال کارت‌ها با $k = 1$).

(ب) $\mathbb{P}(M = m) = \binom{m-1}{k-1}/\binom{N}{k}$ (یک تانک شماره m دارد و $k-1$ تای دیگر از $m-1$ شماره کوچک‌تر). با اتحاد $m\binom{m-1}{k-1} = k\binom{m}{k}$ و اتحاد چوب هاکی $\sum_{m=k}^{N}\binom{m}{k} = \binom{N+1}{k+1}$:

$$\mathbb{E}M = \frac{k}{\binom{N}{k}}\sum_{m=k}^{N}\binom{m}{k} = \frac{k\binom{N+1}{k+1}}{\binom{N}{k}} = \frac{k(N+1)}{k+1}.$$

پس $\hat{N}_* = \frac{k+1}{k}M - 1 = M + \frac{M}{k} - 1$ بی‌گرایش است (برای $k = 1$ همان $2X - 1$).

(ج) $k = 4$، $M = 60$: $\hat{N}_{\mathrm{ML}} = 60$ و $\hat{N}_* = 60 \cdot \frac{5}{4} - 1 = 74$. ■

تمرین ۲۲-۸

نمونه‌های i.i.d. از $\mathcal{U}(-\theta, \theta)$ داریم. MLE پارامتر θ را بیابید.

حل. $L(\theta) = (2\theta)^{-n}\mathbf{1}_{\theta \geq |X_i|\ \forall i} = (2\theta)^{-n}\mathbf{1}_{\theta \geq \max_i |X_i|}$. نزولی روی ناحیه مجاز؛ پس $\hat{\theta}_{\mathrm{ML}} = \max_i |X_i|$. ■

تمرین ۲۲-۹: نمایی انتقال‌یافته

نمونه‌های i.i.d. با چگالی $f(x;\theta) = e^{-(x-\theta)}$ برای $x \geq \theta$ داریم. MLE پارامتر θ را بیابید، گرایش آن را حساب کرده و آن را اصلاح کنید.

حل. $L(\theta) = e^{-\sum_i (X_i-\theta)}\mathbf{1}_{\theta \leq \min_i X_i} = e^{-\sum_i X_i} e^{n\theta}\mathbf{1}_{\theta \leq \min_i X_i}$ که روی ناحیه مجاز **صعودی** است؛ پس بزرگ‌ترین مقدار مجاز: $\hat{\theta}_{\mathrm{ML}} = \min_i X_i$. **گرایش:** $\mathbb{P}(\min_i X_i - \theta > t) = \prod_i \mathbb{P}(X_i - \theta > t) = e^{-nt}$؛ پس $\min_i X_i - \theta \sim \mathrm{Exp}(n)$ و $\mathbb{E}\hat{\theta}_{\mathrm{ML}} = \theta + \frac{1}{n}$. تخمین‌گر بی‌گرایش: $\min_i X_i - \frac{1}{n}$. (هر دو سازگارند.) ■

تمرین ۲۲-۱۰: MLE یکتا نیست

نمونه‌های i.i.d. از $\mathcal{U}(\theta, \theta+1)$ داریم. نشان دهید MLE یکتا نیست.

حل. $L(\theta) = \prod_i \mathbf{1}_{\theta \leq X_i \leq \theta+1} = \mathbf{1}_{\max_i X_i - 1 \leq \theta \leq \min_i X_i}$. درست‌نمایی روی کل بازه $[\max_i X_i - 1,\ \min_i X_i]$ (که ناتهی است چون $\max - \min \leq 1$) برابر 1 و بیرون آن صفر است. پس **هر** نقطه این بازه یک MLE است؛ مثلاً نقطه وسط $\frac{\min_i X_i + \max_i X_i - 1}{2}$ انتخابی متقارن و معقول است. ■

تمرین ۲۲-۱۱

نمونه‌های i.i.d. از $\mathcal{U}(a,b)$ با هر دو پارامتر نامعلوم داریم. MLE زوج (a,b) را بیابید.

حل. $L(a,b) = (b-a)^{-n}\mathbf{1}_{a \leq \min_i X_i}\mathbf{1}_{b \geq \max_i X_i}$. برای بیشینه کردن، $b-a$ باید تا حد امکان کوچک باشد، یعنی a تا حد امکان بزرگ و b تا حد امکان کوچک: $\hat{a}_{\mathrm{ML}} = \min_i X_i$ و $\hat{b}_{\mathrm{ML}} = \max_i X_i$. ■

تمرین ۲۲-۱۲: توزیع لاپلاس و میانه

نمونه‌های i.i.d. با چگالی $f(x;\theta) = \frac{1}{2}e^{-|x-\theta|}$ داریم. نشان دهید MLE پارامتر θ **میانه نمونه‌ای** است و آن را برای داده‌های $2, 7, 3, 10, 4$ حساب کنید.

حل. $LL(\theta) = -n\log 2 - \sum_i |X_i - \theta|$؛ پس باید $g(\theta) = \sum_i |X_i - \theta|$ را کمینه کرد (تابعی مشتق‌ناپذیر در نقاط X_i). در هر نقطه غیر از داده‌ها:

$$g'(\theta) = \#\{i : X_i < \theta\} - \#\{i : X_i > \theta\}.$$

تا وقتی تعداد نمونه‌های سمت چپ کمتر از راست است g نزولی، و پس از آن صعودی است؛ پس کمینه در **میانه** رخ می‌دهد (برای n فرد یکتا؛ برای n زوج هر نقطه بین دو داده وسطی). داده‌های مرتب: $2, 3, 4, 7, 10$؛ پس $\hat{\theta}_{\mathrm{ML}} = 4$ (در حالی که میانگین 5.2 است و تحت تأثیر داده پرت 10 قرار گرفته است؛ میانه نسبت به داده‌های پرت **مقاوم** است). ■

تمرین ۲۲-۱۳

نشان دهید برای نمونه‌های گاوسی با μ, σ^2 نامعلوم، $\hat{\sigma}^2_{\mathrm{ML}}$ سازگار است.

حل. با اتحاد بالا: $\hat{\sigma}^2_{\mathrm{ML}} = \frac{1}{n}\sum_i (X_i - \mu)^2 - (\bar{X}_n - \mu)^2$. طبق قانون اعداد بزرگ جمله اول به σ^2 و $\bar{X}_n \to \mu$؛ پس جمله دوم به صفر میل می‌کند و $\hat{\sigma}^2_{\mathrm{ML}} \to \sigma^2$. (روش دیگر: گرایش $\frac{\sigma^2}{n}$ و واریانس $\frac{2(n-1)\sigma^4}{n^2}$ هر دو به صفر میل می‌کنند.) ■