دانشکده مهندسی کامپیوتر
دانشگاه صنعتی شریف

آمار و احتمال مهندسی

جزوه کامل درس

بر اساس اسلایدهای جلسات سوم تا بیست‌ودوم

شامل توضیحات کامل همه مباحث،
همه مثال‌ها و پرسش‌های اسلایدها
به همراه حل کامل و تمرین‌های تکمیلی حل‌شده

مدرس: دکتر امیر نجفی

زمستان ۱۴۰۴ و بهار ۱۴۰۵

فهرست مطالب

پیش‌درآمد: مرور پیش‌نیازها (جلسات اول و دوم) ۱

نظریه مجموعه‌ها ۱

اصول شمارش ۲

فضای احتمال و اصول کولموگروف ۲

۳ نتایج اصول کولموگروف، آزمایش برنولی و استقلال آماری ۴

۱.۳ مرور مباحث جلسه قبل ۴

۲.۳ نتایج بدیهی قوانین کولموگروف ۴

۳.۳ اصل شمول و عدم شمول (Inclusion–Exclusion Principle) ۵

۴.۳ کران اجتماع (Union Bound) ۶

۵.۳ محاسبه احتمال وقایع پیچیده با استفاده از احتمال وقایع پایه ۷

۱.۵.۳ فضای نمونه متناهی و وقایع پایه ۷

۶.۳ یک مثال: آزمایش برنولی تکرارشونده (Repeated Bernoulli Trials) ۸

۱.۶.۳ پدیده تمرکز ۱۰

۷.۳ استقلال آماری (Statistical Independence) ۱۱

۱.۷.۳ استقلال و هندسه رویدادها ۱۲

۸.۳ چند مثال ۱۳

۱.۸.۳ ترکیب دو یا چند عامل تصادفی با Ω محدود ۱۳

۲.۸.۳ مسئله روز تولد (Birthday Party Problem) ۱۴

۳.۸.۳ مسئله Monty Hall ۱۵

۹.۳ تمرین‌های تکمیلی ۱۶

۴ احتمال شرطی، قانون زنجیره‌ای، احتمال کل و قانون بیز ۱۸

۱.۴ احتمال شرطی (Conditional Probability) ۱۸

۲.۴ قانون زنجیره‌ای (Chain Rule) ۲۰

۱.۲.۴ حالت دوتایی و سه‌تایی ۲۰

۲.۲.۴ حالت کلی و موارد کاربردی ۲۱

۳.۴ قانون احتمال کل (The Law of Total Probability) ۲۲

۴.۴ قانون بیز (Bayes' Rule) ۲۳

۱.۴.۴ دیدگاه بیزی ۲۴

۵.۴ استقلال شرطی (Conditional Independence) . . . ۲۵
۶.۴ تمرین‌های تکمیلی . . . ۲۶

۵ مثالی از استقلال شرطی و گراف‌های تصادفی ۲۷
۱.۵ مثال از استقلال شرطی (حل مسئله دو سکه) . . . ۲۷
۱.۱.۵ یک راه‌حل (اشتباه!) . . . ۲۸
۲.۱.۵ راه‌حل صحیح . . . ۲۸
۲.۵ یک مثال از گراف‌های تصادفی: تشکیل مثلث . . . ۲۹
۳.۵ گراف‌های Erdős–Rényi و مسئله تشکیل Clique . . . ۳۱
۱.۳.۵ کران بالا با کران اجتماع . . . ۳۱
۲.۳.۵ ساده‌سازی کران . . . ۳۱
۳.۳.۵ یک تخمین عددی ساده: شبکه‌های اجتماعی . . . ۳۲
۴.۵ تمرین‌های تکمیلی . . . ۳۳

۶ متغیر تصادفی و متغیرهای تصادفی گسسته معروف ۳۴
۱.۶ متغیر تصادفی (Random Variable) ـ مقدمه . . . ۳۴
۱.۱.۶ یک مثال: مدل‌سازی آب‌وهوا . . . ۳۴
۲.۱.۶ اندازه‌گیری در فضای نمونه . . . ۳۵
۳.۱.۶ متغیر تصادفی به مثابه یک «جعبه سیاه» . . . ۳۶
۲.۶ متغیرهای تصادفی گسسته (Discrete Random Variables) . . . ۳۶
۳.۶ متغیرهای تصادفی گسسته معروف . . . ۳۷
۱.۳.۶ توزیع برنولی (Bernoulli) . . . ۳۷
۲.۳.۶ توزیع دوجمله‌ای (Binomial Distribution) . . . ۳۷
۳.۳.۶ توزیع چندجمله‌ای (Multinomial Distribution) . . . ۳۸
۴.۳.۶ توزیع پواسون (Poisson Distribution) . . . ۳۹
۵.۳.۶ خواص توزیع پواسون: حد توزیع دوجمله‌ای . . . ۳۹
۶.۳.۶ توزیع هندسی (Geometric) ـ تکمیلی . . . ۴۱
۴.۶ تمرین‌های تکمیلی . . . ۴۱

۷ متغیرهای تصادفی پیوسته، CDF و PDF ۴۲
۱.۷ متغیرهای تصادفی پیوسته . . . ۴۲
۱.۱.۷ مشکل فضای ناشمارا . . . ۴۲
۲.۱.۷ مجموعه‌ها و میدان سیگمای بورل (Borel Sets and Borel σ-Field) . . . ۴۳
۳.۱.۷ کافی بودن احتمال بازه‌ها . . . ۴۴
۲.۷ تابع توزیع انباشته (Cumulative Distribution Function) . . . ۴۴
۳.۷ تابع چگالی احتمال (Probability Density Function) . . . ۴۵
۱.۳.۷ مفهوم . . . ۴۵
۲.۳.۷ خواص و مقایسه با سایر توابع . . . ۴۶
۳.۳.۷ مفهوم گرافیکی . . . ۴۷

۴.۷ متغیرهای تصادفی پیوسته معروف ۴۷
۱.۴.۷ توزیع یکنواخت (Uniform Distribution) ۴۷
۲.۴.۷ توزیع نمایی (Exponential Distribution) ۴۸
۳.۴.۷ توزیع گاوسی یا نرمال (Gaussian or Normal Distribution) ۴۹
۴.۴.۷ توزیع لاپلاس (Laplace Distribution) ۵۰
۵.۴.۷ توزیع بتا (Beta Distribution) ۵۰
۶.۴.۷ برخی توزیع‌های کمتر کاربردی... . . . . ۵۱
۵.۷ تمرین‌های تکمیلی ۵۱

۸ تساوی‌های آماری، استقلال متغیرهای تصادفی و متغیرهای مخلوط ۵۳
۱.۸ مفهوم almost sure در آمار و احتمال ۵۳
۲.۸ استقلال متغیرهای تصادفی ۵۴
۳.۸ متغیرهای تصادفی i.i.d. ۵۵
۴.۸ رفتار دُم توزیع‌های مختلف ۵۵
۱.۴.۸ نمونه اول ۵۶
۲.۴.۸ نمونه دوم ۵۶
۳.۴.۸ نمونه سوم ۵۶
۴.۴.۸ نمونه چهارم ۵۷
۵.۸ متغیرهای تصادفی مخلوط (گسسته و پیوسته) ۵۸
۱.۵.۸ تابع دلتای دیراک ۵۸
۲.۵.۸ حل مسئله دماسنج نامطمئن ۵۹
۳.۵.۸ تبدیل PMF به PDF ۵۹
۶.۸ تمرین‌های تکمیلی ۶۰

۹ توزیع‌های شرطی، مدل‌های مخلوط، میانگین و قانون اعداد بزرگ ۶۱
۱.۹ توزیع‌های شرطی (Conditional PMF/PDF/CDF) ۶۱
۲.۹ خاصیت بی‌حافظگی (memoryless property) ۶۲
۳.۹ مدل‌های آماری مخلوط (Statistical Mixture Models) ۶۳
۴.۹ توصیف یک متغیر تصادفی ۶۴
۱.۴.۹ آماره یا Statistic ۶۴
۵.۹ میانگین (Expected Value) ۶۴
۱.۵.۹ مفهوم ۶۴
۲.۵.۹ فرمول ریاضی ۶۵
۳.۵.۹ میانگین متغیرهای تصادفی گسسته معروف ۶۵
۴.۵.۹ میانگین متغیرهای تصادفی پیوسته معروف ۶۶
۶.۹ خواص میانگین ۶۷
۷.۹ مفهوم متغیرهای تصادفی i.i.d. و قانون اعداد بزرگ (Law of Large Numbers) ۶۸
۸.۹ توزیع‌های بدون میانگین ۶۹

۹.۹ یک مثال تمرینی: سکه تصادفی با احتمال نامعلوم . . . ۷۰
۱۰.۹ تمرین‌های تکمیلی . . . ۷۱

۱۰ عملگر میانگین‌گیری، واریانس، مُد و میانه ۷۳
۱.۱۰ میانگین‌گیری یا عملگر Expectation . . . ۷۳
۲.۱۰ واریانس و انحراف معیار . . . ۷۴
۱.۲.۱۰ خواص . . . ۷۴
۳.۱۰ واریانس توزیع‌های معروف . . . ۷۶
۱.۳.۱۰ توزیع‌های برنولی، دوجمله‌ای و پواسون . . . ۷۶
۲.۳.۱۰ توزیع‌های گاوسی، نمایی و یکنواخت . . . ۷۶
۴.۱۰ واریانس جمع متغیرهای تصادفی i.i.d. . . . ۷۸
۵.۱۰ مُد و میانه (Mode and Median) . . . ۷۸
۱.۵.۱۰ مُد (Mode) . . . ۷۸
۲.۵.۱۰ میانه (Median) . . . ۷۹
۶.۱۰ تمرین‌های تکمیلی . . . ۷۹

۱۱ گشتاورها، تابع مولد گشتاور، تابع مشخصه و توابع یک متغیر تصادفی ۸۱
۱.۱۱ گشتاورهای یک توزیع (Moments of a Distribution) . . . ۸۱
۱.۱.۱۱ خواص . . . ۸۱
۲.۱.۱۱ گشتاور دوم، واریانس و Kurtosis . . . ۸۲
۲.۱۱ تابع مولد گشتاور (MGF) . . . ۸۳
۱.۲.۱۱ خواص . . . ۸۳
۲.۲.۱۱ کاربرد اصلی: تولید گشتاورها . . . ۸۳
۳.۲.۱۱ خاصیت مهم: MGF جمع متغیرهای مستقل . . . ۸۴
۴.۲.۱۱ MGF توزیع‌های مشهور . . . ۸۵
۳.۱۱ تابع مشخصه (Characteristic Function) . . . ۸۵
۱.۳.۱۱ خواص و قضیه یکتایی . . . ۸۶
۲.۳.۱۱ توابع مشخصه توزیع‌های معروف . . . ۸۶
۴.۱۱ توابعی از یک متغیر تصادفی . . . ۸۷
۱.۴.۱۱ تعریف مسئله . . . ۸۷
۲.۴.۱۱ موارد ساده . . . ۸۷
۵.۱۱ تمرین‌های تکمیلی . . . ۸۸

۱۲ توابعی از یک متغیر تصادفی و تبدیل توزیع‌ها ۹۰
۱.۱۲ یادآوری: تعریف مسئله و موارد ساده . . . ۹۰
۲.۱۲ فرمول در حالت توابع g یک‌به‌یک . . . ۹۰
۳.۱۲ فرمول کلی . . . ۹۱
۴.۱۲ بررسی و شهود ریاضیاتی . . . ۹۱
۱.۴.۱۲ توجیه گرافیکی . . . ۹۱

۲.۴.۱۲ توجیه تحلیلی ۹۲
۵.۱۲ مثال ۹۲
۶.۱۲ تبدیل توزیع‌های مختلف به یکدیگر (Transforming Distribution) ۹۳
۱.۶.۱۲ تبدیل توزیع‌ها به توزیع یکنواخت ۹۳
۲.۶.۱۲ تبدیل توزیع یکنواخت به سایر توزیع‌ها ۹۴
۷.۱۲ چگونگی تولید اعداد تصادفی ۹۴
۸.۱۲ تمرین‌های تکمیلی ۹۵

پیش‌درآمد: مرور پیش‌نیازها (جلسات اول و دوم)

نکته. این جزوه بر اساس اسلایدهای جلسه سوم به بعد نوشته شده است. از آنجا که در جلسات بعدی مدام به مفاهیم جلسات اول و دوم (نظریه مجموعه‌ها، اصول شمارش و تعریف فضای احتمال) ارجاع داده می‌شود، در این پیش‌درآمد خلاصه‌ای کامل و خودبسنده از این پیش‌نیازها آورده‌ایم تا جزوه به تنهایی قابل مطالعه باشد.

۱. نظریه مجموعه‌ها

مجموعه گردایه‌ای از اشیای متمایز است که به آن‌ها **عضو** می‌گوییم. اگر x عضو مجموعه A باشد می‌نویسیم $x \in A$ و در غیر این صورت $x \notin A$. مجموعه‌ای که هیچ عضوی ندارد را **مجموعه تهی** می‌نامیم و با $\varnothing$ نشان می‌دهیم. اگر هر عضو A عضو B نیز باشد، می‌گوییم A زیرمجموعه B است و می‌نویسیم $A \subseteq B$.

در احتمال، همیشه یک «مجموعه مرجع» یا **فضای نمونه** Ω داریم و همه مجموعه‌ها زیرمجموعه آن هستند. عملگرهای اصلی روی مجموعه‌ها عبارت‌اند از:

- **متمم:** $A^c = \{\omega \in \Omega : \ \omega \notin A\}$.
- **اجتماع:** $A \cup B = \{\omega : \ \omega \in A \text{ or } \omega \in B\}$ (رخ دادن «A یا B»).
- **اشتراک:** $A \cap B = \{\omega : \ \omega \in A \text{ and } \omega \in B\}$ (رخ دادن «A و B»). گاهی $A \cap B$ را به صورت AB یا A, B هم می‌نویسیم.
- **تفاضل:** $A \setminus B = A \cap B^c$ (رخ دادن A بدون B).
- **ضرب دکارتی:** $A \times B = \{(a,b) : \ a \in A,\ b \in B\}$؛ برای مثال فضای نمونه پرتاب دو تاس برابر است با $\{1,\dots,6\} \times \{1,\dots,6\}$.

دو مجموعه A و B را **ناسازگار** (disjoint) گوییم اگر $A \cap B = \varnothing$؛ یعنی هیچ‌گاه هم‌زمان رخ ندهند.

قضیه ۰-۱: قوانین دمورگان

برای هر خانواده از مجموعه‌ها $\{A_i\}$:

$$\Big(\bigcup_i A_i\Big)^c = \bigcap_i A_i^c, \qquad \Big(\bigcap_i A_i\Big)^c = \bigcup_i A_i^c.$$

اثبات. $\omega \in (\bigcup_i A_i)^c$ یعنی ω در هیچ‌یک از A_iها نیست؛ یعنی برای هر i داریم $\omega \in A_i^c$؛ یعنی $\omega \in \bigcap_i A_i^c$. رابطه دوم با اعمال رابطه اول روی A_i^cها و گرفتن متمم از دو طرف به دست می‌آید. □

۲. اصول شمارش

قضیه ۰-۲: اصل ضرب

اگر انجام یک کار شامل k مرحله باشد و مرحله iام به n_i طریق (مستقل از انتخاب‌های مراحل قبل) انجام شود، کل کار به $n_1 n_2 \cdots n_k$ طریق انجام می‌شود. معادلاً $|A_1 \times \cdots \times A_k| = |A_1| \cdots |A_k|$.

- **جایگشت:** تعداد ترتیب‌های n شیء متمایز برابر $n!$ است. تعداد ترتیب‌های kتایی از n شیء برابر $\frac{n!}{(n-k)!}$ است.
- **ترکیب:** تعداد زیرمجموعه‌های kعضوی یک مجموعه nعضوی برابر است با

$$\binom{n}{k} = \frac{n!}{k!\,(n-k)!}.$$

- **قضیه دوجمله‌ای:** $(x+y)^n = \sum_{k=0}^{n} \binom{n}{k} x^k y^{n-k}$؛ به‌ویژه $\sum_{k=0}^{n} \binom{n}{k} = 2^n$ که همان تعداد کل زیرمجموعه‌های یک مجموعه nعضوی است.

قضیه ۰-۳: ستاره و میله (Stars and Bars)

تعداد جواب‌های معادله $x_1 + x_2 + \cdots + x_k = n$ در اعداد صحیح نامنفی برابر است با

$$\binom{n+k-1}{k-1}.$$

اثبات. هر جواب را می‌توان با یک رشته از n ستاره و $k-1$ میله نشان داد: تعداد ستاره‌های قبل از اولین میله برابر x_1، بین میله اول و دوم برابر x_2 و ... است. برای مثال با $k=3$ و $n=5$، رشته $\star\star|\star|\star\star$ نمایانگر جواب $(2,1,2)$ است. این تناظر یک‌به‌یک است، پس کافی است تعداد راه‌های انتخاب جای $k-1$ میله از میان $n+k-1$ جایگاه را بشماریم که برابر $\binom{n+k-1}{k-1}$ است. □

قضیه ۰-۴: اصل شمول و عدم شمول برای اندازه مجموعه‌ها

برای مجموعه‌های متناهی:

$$|A \cup B| = |A| + |B| - |A \cap B|,$$

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|.$$

۳. فضای احتمال و اصول کولموگروف

تعریف ۰-۵: فضای احتمال

یک **فضای احتمال** یک سه‌تایی مرتب $(\Omega, \mathcal{F}, \mathbb{P})$ است که در آن:

- Ω **فضای نمونه**، یعنی مجموعه همه نتایج ممکن یک آزمایش تصادفی است.

- $\mathcal{F}$ یک **میدان سیگما** (σ-field) روی Ω است؛ یعنی گردایه‌ای از زیرمجموعه‌های Ω (که به آن‌ها **رویداد** یا **پیشامد** می‌گوییم) با این ویژگی‌ها: (الف) $\Omega \in \mathcal{F}$؛ (ب) اگر $A \in \mathcal{F}$ آنگاه $A^c \in \mathcal{F}$؛ (ج) اگر $A_1, A_2, \ldots \in \mathcal{F}$ آنگاه $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.
- $\mathbb{P} : \mathcal{F} \to [0,1]$ یک **اندازه احتمال** است که در اصول کولموگروف صدق می‌کند.

تعریف ۰-۶: اصول کولموگروف

تابع $\mathbb{P}$ روی $\mathcal{F}$ یک اندازه احتمال است اگر:

۱. **نامنفی بودن:** برای هر $A \in \mathcal{F}$، $\mathbb{P}(A) \geq 0$.

۲. **نرمال بودن:** $\mathbb{P}(\Omega) = 1$.

۳. **جمع‌پذیری شمارا:** برای هر دنباله از رویدادهای دوبه‌دو ناسازگار $A_1, A_2, \ldots$:

$$\mathbb{P}\Big(\bigcup_{i=1}^{\infty} A_i\Big) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

به زبان ساده، اصول کولموگروف می‌گویند $\mathbb{P}$ یک «اندازه» (measure) روی Ω است ــ مانند طول، مساحت یا تعداد اعضا ــ با این قید اضافه که اندازه کل فضا برابر ۱ باشد.

نکته. تعبیر فرکانسی احتمال. اگر آزمایشی را N بار تکرار کنیم و رویداد A در N_A بار رخ دهد، فرکانس نسبی N_A/N برای Nهای بزرگ به $\mathbb{P}(A)$ نزدیک می‌شود. فرکانس نسبی به‌وضوح نامنفی است، برای Ω برابر ۱ است و برای دو رویداد ناسازگار داریم $N_{A\cup B} = N_A + N_B$؛ پس اصول کولموگروف دقیقاً همان ویژگی‌های شهودی فرکانس نسبی هستند.

نکته. وقتی Ω متناهی یا شماراست، معمولاً $\mathcal{F} = 2^{\Omega}$ (مجموعه همه زیرمجموعه‌های Ω) انتخاب می‌شود. اگر $|\Omega| = n$ آنگاه $|2^{\Omega}| = 2^n$.

جلسه ۳

نتایج اصول کولموگروف، آزمایش برنولی و استقلال آماری

۱.۳ مرور مباحث جلسه قبل

در جلسات گذشته با سه مفهوم پایه آشنا شدیم:

- **نظریه مجموعه‌ها:** مفهوم مجموعه، عضویت، ضرب دکارتی و عملگرهایی مانند متمم، اجتماع، اشتراک و تفاضل.
- **فضای احتمال:** یک سه‌تایی مرتب $(\Omega, \mathcal{F}, \mathbb{P})$ که در آن Ω فضای نمونه، $\mathcal{F}$ یک میدان سیگما (σ-field) روی Ω و بیانگر فضای رخدادها، و $\mathbb{P}$ یک اندازه احتمال از $\mathcal{F}$ به بازه $[0,1]$ است.
- **قوانین کولموگروف (Kolmogorov's Principles):** این قوانین به زبان ساده بیان می‌کنند که $\mathbb{P}$ یک اندازه (measure) روی Ω است، با این شرط که $\mathbb{P}(\Omega) = 1$.

۲.۳ نتایج بدیهی قوانین کولموگروف

تابع احتمال $\mathbb{P}$ صرفاً یک اندازه تعریف‌شده روی مجموعه Ω است، با این قید اضافی که $\mathbb{P}(\Omega)$ باید برابر ۱ شود. با استفاده از قضیه دمورگان و عملیات ساده روی مجموعه‌ها، می‌توان نتایج زیر را به دست آورد.

قضیه ۳-۱: احتمال متمم و تهی

برای هر $A \in \mathcal{F}$:

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A), \qquad \mathbb{P}(\varnothing) = 0.$$

اثبات. A و A^c ناسازگارند و $A \cup A^c = \Omega$. پس طبق اصل جمع‌پذیری و نرمال بودن: $1 = \mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c)$، که نتیجه می‌دهد $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$. با قرار دادن $A = \Omega$ و توجه به $\Omega^c = \varnothing$ داریم $\mathbb{P}(\varnothing) = 1 - 1 = 0$. □

قضیه ۳-۲: یکنوایی

اگر $A \subseteq B$ آنگاه $\mathbb{P}(A) \leq \mathbb{P}(B)$. به‌ویژه برای هر رویداد $0 \leq \mathbb{P}(A) \leq 1$.

اثبات. $B = A \cup (B \setminus A)$ و این دو مجموعه ناسازگارند. پس $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A)$ زیرا $\mathbb{P}(B \setminus A) \geq 0$. □

نکته. اصل اول کولموگروف، یعنی جمع‌پذیری احتمال تحت اجتماع شمارای مجموعه‌های ناسازگار، را پیش‌تر (جلسه قبل) به صورت شهودی و با تعریف «فرکانس نسبی رخدادها» برای احتمال نیز دیده بودیم.

۳.۳ اصل شمول و عدم شمول (Inclusion–Exclusion Principle)

در جلسه قبل این اصل را در مورد اندازه (کاردینالیته) مجموعه‌ها دیده بودیم. همین اصل در مورد احتمال (یا هر اندازه یا measure دیگری) نیز برقرار است.

قضیه ۳-۳: حالت دو و سه رویداد

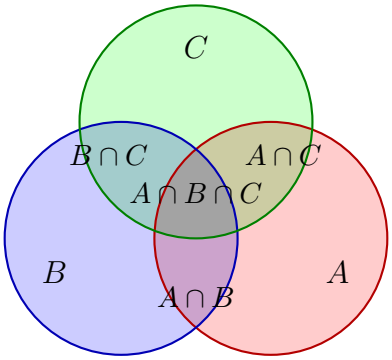
$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B),$$

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) + \mathbb{P}(A \cap B \cap C).$$

اثبات. $A \cup B$ را به سه قطعه ناسازگار $A \setminus B$، $A \cap B$ و $B \setminus A$ افراز می‌کنیم. چون $\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B)$ و $\mathbb{P}(B) = \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B)$:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

برای سه رویداد، رابطه دوتایی را برای $A \cup B$ و C به کار می‌بریم: $\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A \cup B) + \mathbb{P}(C) - \mathbb{P}\big((A \cap C) \cup (B \cap C)\big)$ و با بسط دوباره دو جمله اول و آخر (و توجه به $(A \cap C) \cap (B \cap C) = A \cap B \cap C$) رابطه به دست می‌آید. □



شکل ۱.۳: نمودار ون سه رویداد: در جمع $\mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$ نواحی دوتایی دو بار و ناحیه سه‌تایی سه بار شمرده می‌شوند؛ با کم کردن اشتراک‌های دوتایی، ناحیه سه‌تایی صفر بار شمرده می‌شود و باید دوباره اضافه شود.

قضیه ۳-۴: اصل شمول و عدم شمول ـ حالت کلی

برای هر n رویداد $E_1, \dots, E_n$:

$$\mathbb{P}\Big(\bigcup_{i=1}^{n} E_i\Big) = \sum_{i=1}^{n} \mathbb{P}(E_i) - \sum_{i<j} \mathbb{P}(E_i \cap E_j) + \sum_{i<j<k} \mathbb{P}(E_i \cap E_j \cap E_k)$$
$$- \cdots + (-1)^{\ell+1} \sum_{i_1<i_2<\cdots<i_\ell} \mathbb{P}\Big(\bigcap_{r=1}^{\ell} E_{i_r}\Big) + \cdots$$

که آخرین جمله آن $(-1)^{n+1}\mathbb{P}(E_1 \cap \cdots \cap E_n)$ است.

ایده اثبات. فرض کنید ω نقطه‌ای است که دقیقاً در $m \geq 1$ تا از E_iها قرار دارد. سهم این نقطه در جمع‌های طرف راست برابر است با $\binom{m}{1} - \binom{m}{2} + \binom{m}{3} - \cdots \pm \binom{m}{m} = 1 - (1-1)^m = 1$. پس هر نقطه از اجتماع دقیقاً یک بار شمرده می‌شود و نقاط بیرون از اجتماع اصلاً شمرده نمی‌شوند. □

۴.۳ کران اجتماع (Union Bound)

یک نامساوی بسیار کاربردی و نتیجه مستقیم اصل شمول و عدم شمول، کران اجتماع است که برای کران‌دار کردن احتمال اجتماع تعدادی واقعه به کار می‌رود.

قضیه ۳-۵: کران اجتماع یا نامساوی بول

برای هر دنباله از رویدادها (نه لزوماً ناسازگار):

$$\mathbb{P}\Big(\bigcup_{i=1}^{\infty} E_i\Big) \leq \sum_{i=1}^{\infty} \mathbb{P}(E_i).$$

اثبات. رویدادهای ناسازگار $F_1 = E_1$ و $F_i = E_i \setminus (E_1 \cup \cdots \cup E_{i-1})$ را تعریف می‌کنیم. اجتماع F_iها با اجتماع E_iها برابر است و $F_i \subseteq E_i$. پس طبق جمع‌پذیری و یکنوایی:

$$\mathbb{P}\Big(\bigcup_i E_i\Big) = \mathbb{P}\Big(\bigcup_i F_i\Big) = \sum_i \mathbb{P}(F_i) \leq \sum_i \mathbb{P}(E_i).$$

□

نکته. تساوی در کران اجتماع زمانی برقرار است که رویدادها (با احتمال یک) دوبه‌دو ناسازگار باشند. هرچه هم‌پوشانی رویدادها بیشتر باشد، این کران «شل‌تر» است.

مثال ۳-۶: پزشک یا پولدار

فرض کنید احتمال اینکه فردی در جامعه پزشک شود ۵٪، و احتمال اینکه شخصی پولدار شود ۱۵٪ باشد. در این صورت، احتمال اینکه شخصی یا پزشک شود، یا پولدار چقدر است؟

حل. رویداد پزشک شدن را D و پولدار شدن را R بنامید. از اصل شمول و عدم شمول $\mathbb{P}(D \cup R) = 0.05 + 0.15 - \mathbb{P}(D \cap R)$. چون $\mathbb{P}(D \cap R)$ را نمی‌دانیم، احتمال خواسته‌شده دقیقاً قابل محاسبه

نیست. **تنها جواب ممکن با داده‌های مسئله** از کران اجتماع به دست می‌آید:

$$\mathbb{P}(D \cup R) \le \mathbb{P}(D) + \mathbb{P}(R) = 0.20.$$

تساوی وقتی است که هیچ پزشکی پولدار نباشد ($\mathbb{P}(D \cap R) = 0$). در طرف دیگر، چون $R \subseteq D \cup R$، داریم $\mathbb{P}(D \cup R) \ge \max(0.05, 0.15) = 0.15$ (حالتی که همه پزشک‌ها پولدار باشند). پس در مجموع $0.15 \le \mathbb{P}(D \cup R) \le 0.20$. ■

۵.۳ محاسبه احتمال وقایع پیچیده با استفاده از احتمال وقایع پایه

۱.۵.۳ فضای نمونه متناهی و وقایع پایه

تعریف ۳-۷: وقایع پایه

به وقایعی مانند $\{\omega\}$ برای $\omega \in \Omega$ (مجموعه‌های تک‌عضوی)، «وقایع پایه» یا رویدادهای ساده اطلاق می‌گردد.

در صورتی که فضای Ω متناهی باشد، احتمال تمامی وقایعی که در $\mathcal{F} = 2^{\Omega}$ ظاهر می‌شوند را می‌توان با استفاده از اصل جمع‌پذیری احتمال تحت اجتماع به دست آورد. یعنی هر رویداد $E = \{\omega_1, \dots, \omega_n\}$ اجتماعی از وقایع پایه ناسازگار است و

$$\mathbb{P}\Big(E = \bigcup_{i=1}^{n} \{\omega_i\}\Big) = \sum_{i=1}^{n} \mathbb{P}\big(\{\omega_i\}\big).$$

لذا برای مشخص کردن کامل اندازه احتمال، صرفاً به مقادیر احتمال وقایع پایه نیازمندیم.

تعریف ۳-۸: تابع جرم احتمال (PMF)

به تابعی که احتمال وقایع پایه را به بازه $[0, 1]$ می‌نگارد، «تابع جرم احتمال» یا Probability Mass Function (PMF) می‌گوییم:

$$p : \Omega \to [0, 1], \qquad p(\omega) = \mathbb{P}(\{\omega\}).$$

برخلاف تابع احتمال $\mathbb{P}$ (تابع اندازه احتمال) که روی رویدادها تعریف می‌شود، برای p داریم:

$$\sum_{\omega \in \Omega} p(\omega) = 1.$$

نکته. کار کردن با p بسیار راحت‌تر از $\mathbb{P}$ است: دامنه p صرفاً $|\Omega|$ عضو دارد، در حالی که دامنه تابع اندازه احتمال $\mathbb{P}$ شامل $2^{|\Omega|}$ عضو است. برای مثال اگر $|\Omega| = 10$، کافی است ۱۰ عدد (در واقع ۹ عدد، چون مجموعشان باید ۱ شود) را بدانیم تا احتمال همه $2^{10} = 1024$ رویداد مشخص شود.

نکته. حالت هم‌احتمال. اگر همه نتایج هم‌احتمال باشند، $p(\omega) = 1/|\Omega|$ و برای هر رویداد $\mathbb{P}(E) = \frac{|E|}{|\Omega|}$. در این حالت محاسبه احتمال به یک مسئله **شمارشی** تبدیل می‌شود.

۶.۳ یک مثال: آزمایش برنولی تکرارشونده (Repeated Bernoulli Trials)

یک سکه متقارن یا fair را در نظر بگیرید که احتمال شیر (H) یا خط (T) آمدن آن برابر $\frac{1}{2}$ باشد. فرض کنید این سکه را n بار می‌اندازیم، به طوری که هر پرتاب «بی‌ربط» به نتیجه پرتاب‌های قبل و بعد از خود باشد. بعداً به این کار پرتاب‌های **مستقل** خواهیم گفت. به یک بار انجام کل این n پرتاب، یک **آزمون** یا experiment می‌گوییم.

واضح است که با هر بار انجام آزمون، یکی از 2^n نتیجه ممکن زیر احتمال وقوع دارند:

$$\begin{aligned} &1) \quad HHH\ldots HHH \\ &2) \quad HHH\ldots HHT \\ &3) \quad HHH\ldots HTH \\ &4) \quad HHH\ldots HTT \\ &\vdots \qquad\quad \vdots \\ &2^n) \quad TTT\ldots TTT \end{aligned}$$

پرسش: چرا تمامی این 2^n حالت هم‌احتمال هستند؟

پاسخ. هر دنباله مشخص، مثلاً $HTH\ldots$، یعنی نتیجه پرتاب اول یک مقدار مشخص، نتیجه پرتاب دوم یک مقدار مشخص و ... باشد. چون هر پرتاب جداگانه با احتمال $\frac{1}{2}$ هر یک از دو حالت را می‌دهد و پرتاب‌ها بر هم اثری ندارند (استقلال؛ بخش ۷.۳)، احتمال هر دنباله مشخص برابر $\frac{1}{2}\times\frac{1}{2}\times\cdots\times\frac{1}{2} = 2^{-n}$ است که به خود دنباله بستگی ندارد. به بیان دیگر، تقارن سکه باعث می‌شود جابه‌جا کردن H و T در هر جایگاه احتمال را تغییر ندهد؛ پس همه دنباله‌ها هم‌ارزند.

دقت کنید:

- هر یک از این 2^n حالت، یک عضو از **فضای نمونه** Ω هستند: $\Omega = \{H,T\}^n$ و $|\Omega| = 2^n$.
- فضای رخدادها یا $\mathcal{F}$ شامل 2^{2^n} عضو است، که شامل تمام زیرمجموعه‌های ممکن Ω (از جمله خود Ω و $\varnothing$) است.
- تابع جرم احتمال (PMF) در این مسئله به هر یک از این 2^n عضو Ω احتمال 2^{-n} را خواهد داد، تا جمع احتمالات ۱ شود.
- در نتیجه، محاسبه احتمال هر رخداد (هر عضو $\mathcal{F}$) در این مسئله، تبدیل به یک مسئله **شمارشی** (combinatorial) می‌شود.

مثال ۳-۹: احتمال دقیقاً k شیر

احتمال اینکه در یک آزمون، رشته‌ای ظاهر شود که دقیقاً شامل k عدد شیر باشد چقدر است؟ (برای $0 \le k \le n$)

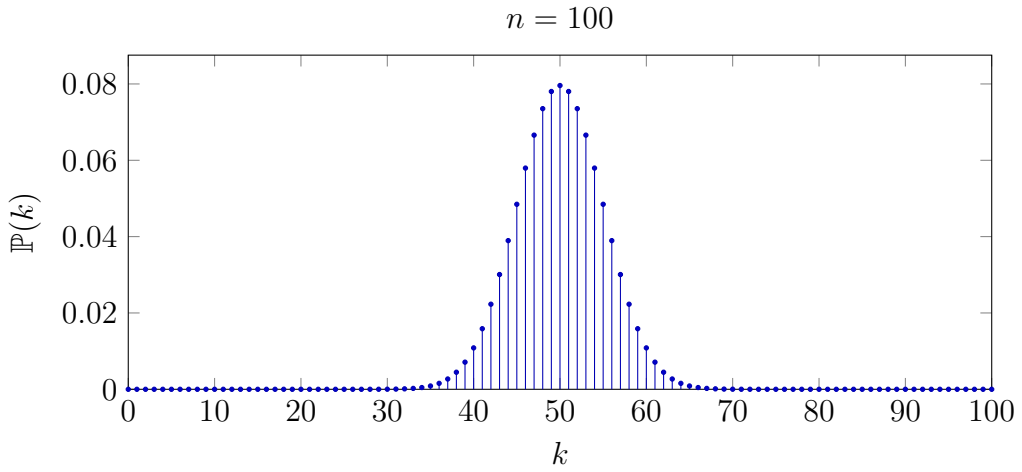
حل. طبق قوانین کولموگروف، تمام خروجی‌هایی که این اتفاق در آن‌ها رخ داده را باید در نظر بگیریم، و سپس چون این خروجی‌ها **اشتراکی ندارند** (وقایع پایه متمایز همیشه ناسازگارند)، احتمال هر یک را با هم جمع کنیم. تعداد رشته‌های به طول n با دقیقاً k شیر برابر تعداد راه‌های انتخاب k جایگاه از n جایگاه برای H است، یعنی $\binom{n}{k}$. هر کدام احتمال 2^{-n} دارند؛ پس:

$$\mathbb{P}(\text{having } k \text{ heads}) = \frac{1}{2^n}\binom{n}{k}.$$

■

دقت کنید که جمع این احتمالات برای همه مقادیر k برابر ۱ است (همان‌طور که باید باشد، چون رویدادهای $\{k=0\}, \dots, \{k=n\}$ یک افراز از Ω هستند). با استفاده از قضیه دوجمله‌ای:

$$\mathbb{P}(k=0) + \cdots + \mathbb{P}(k=n) = \sum_{k=0}^{n} \binom{n}{k} 2^{-n} = 2^{-n}(1+1)^n = 1.$$



شکل ۲.۳: احتمال مشاهده دقیقاً k شیر در $n = 100$ پرتاب سکه سالم. بیشینه در $k = 50$ و برابر حدود 0.0796 است.

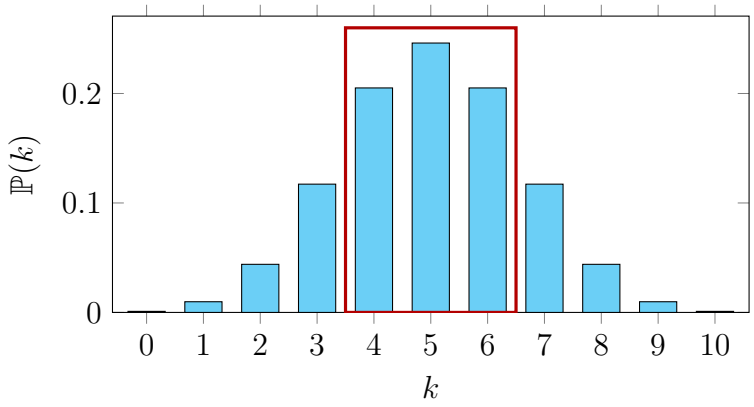
مثال ۳-۱۰: تعداد شیر بین ۴ و ۶

فرض کنید که $n = 10$ باشد. احتمال اینکه تعداد شیرهای ظاهر شده در یک آزمون، عددی بین ۴ تا ۶ باشد چقدر است؟

حل. با توجه به ناسازگاری سه رخداد $\{k=4\}$، $\{k=5\}$ و $\{k=6\}$ داریم:

$$\mathbb{P}(4 \le k \le 6) = \sum_{k=4}^{6} \binom{10}{k} 2^{-10} = \frac{210 + 252 + 210}{1024} = \frac{672}{1024} = 0.65625 \simeq 0.66.$$

■



شکل ۳.۳: توزیع تعداد شیرها برای $n = 10$. مستطیل قرمز رویداد $4 \leq k \leq 6$ را نشان می‌دهد.

مثال ۳-۱۱: دور شدن از میانگین

اگر $n = 100$ باشد، احتمال اینکه تعداد شیرهای ظاهرشده در یک آزمایش از ۴۰ کمتر ($k < 40$)، و یا از ۶۰ بیشتر ($k > 60$) باشند، چقدر است؟ با فرض $n = 1000$، سؤال بالا در مورد $k < 400$ و $k > 600$ چه تفاوتی می‌کند؟

حل. برای $n = 100$: دو رویداد $\{k < 40\}$ و $\{k > 60\}$ ناسازگارند؛ پس

$$\mathbb{P}(k < 40 \cup k > 60) = \sum_{k=0}^{39} \binom{100}{k} 2^{-100} + \sum_{k=61}^{100} \binom{100}{k} 2^{-100} = 1 - \sum_{k=40}^{60} \binom{100}{k} 2^{-100} \simeq 0.035.$$

برای $n = 1000$: به همین ترتیب

$$\mathbb{P}(k < 400 \ \cup \ k > 600) = 1 - \sum_{k=400}^{600} \binom{1000}{k} 2^{-1000} \simeq 2 \times 10^{-10}.$$

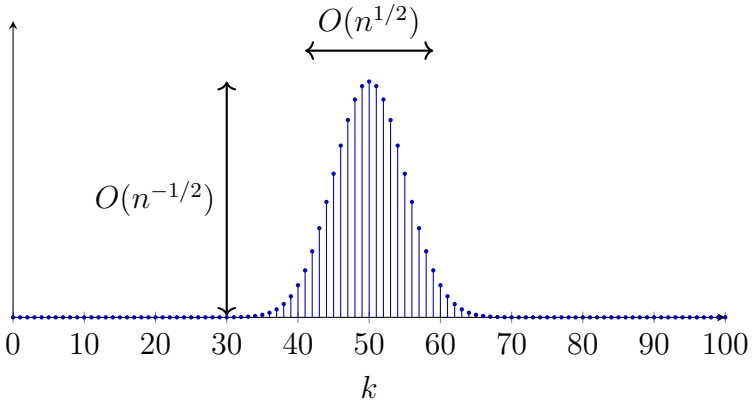
در هر دو حالت از ناحیه «۱۰٪ دورتر از نصف» صحبت می‌کنیم، اما با ده برابر شدن n احتمال آن از حدود ۵٫۳٪ به حدود دو ده‌میلیاردم کاهش یافته است! ■

۱.۶.۳ پدیده تمرکز

نتیجه مثال قبل یک پدیده مهم را نشان می‌دهد: با افزایش n، توزیع تعداد شیرها حول $n/2$ «متمرکز» می‌شود. در شکل ۲.۳ عرض ناحیه‌ای که تقریباً تمام جرم احتمال در آن قرار دارد از مرتبه $O(n^{1/2})$ است، در حالی که کل بازه ممکن طولی برابر n دارد؛ و ارتفاع قله از مرتبه $O(n^{-1/2})$ است. در واقع با استفاده از تقریب استرلینگ $m! \approx \sqrt{2\pi m}\,(m/e)^m$:

$$\mathbb{P}(k = n/2) = \binom{n}{n/2} 2^{-n} \approx \sqrt{\frac{2}{\pi n}},$$

که برای $n = 100$ مقدار 0.0798 را می‌دهد (مقدار دقیق 0.0796).



بنابراین **نسبت** شیرها k/n با افزایش n با احتمال بسیار زیاد به $\frac{1}{2}$ نزدیک می‌شود. این پدیده پیش‌درآمدی بر «قانون اعداد بزرگ» است که در جلسات آینده به‌طور دقیق خواهیم دید.

۷.۳ استقلال آماری (Statistical Independence)

تعریف ۳-۱۲: استقلال دو رویداد

با توجه به یک فضای نمونه مرکب، دو واقعه E_1 و E_2 را مستقل از یکدیگر می‌نامیم، اگر و تنها اگر

$$\mathbb{P}(E_1 \cap E_2) = \mathbb{P}(E_1) \times \mathbb{P}(E_2).$$

برای مثال:

- در صورت پرتاب یک تاس شش‌وجهی و مدل‌سازی تصادفی آن، دو رویداد **فرد** و یا **زوج** آمدن **نمی‌توانند** از یکدیگر مستقل باشند: $\mathbb{P}(\text{odd}\cap\text{even}) = \mathbb{P}(\varnothing) = 0$ در حالی که $\mathbb{P}(\text{even})\mathbb{P}(\text{odd}) = \frac{1}{2}\cdot\frac{1}{2} = \frac{1}{4} \neq 0$. شهوداً دانستن فرد بودن، کاملاً مشخص می‌کند که عدد زوج نیست.
- اما در صورت پرتاب دو تاس پشت سر هم، و با فرض مستقل بودن نتایج آنان، تمام رویدادهای مرتبط با پرتاب اول از تمامی رویدادهای متناظر با پرتاب دوم مستقل می‌شوند.

پرسش: وجود رابطه ضرب در احتمال وقایع مستقل، در ارتباط تنگاتنگ با اصل ضرب است. چرا؟

پاسخ. فرض کنید آزمایش مرکب از دو آزمایش با فضاهای نمونه متناهی Ω_1 و Ω_2 باشد و همه $|\Omega_1||\Omega_2|$ نتیجه در $\Omega = \Omega_1 \times \Omega_2$ هم‌احتمال باشند (مانند دو تاس). رویداد A فقط به آزمایش اول و B فقط به آزمایش دوم مربوط است؛ یعنی $A = A_1 \times \Omega_2$ و $B = \Omega_1 \times B_2$. آنگاه $A \cap B = A_1 \times B_2$ و طبق **اصل ضرب** $|A_1 \times B_2| = |A_1|\,|B_2|$. پس

$$\mathbb{P}(A \cap B) = \frac{|A_1||B_2|}{|\Omega_1||\Omega_2|} = \frac{|A_1|}{|\Omega_1|} \cdot \frac{|B_2|}{|\Omega_2|} = \mathbb{P}(A)\mathbb{P}(B).$$

یعنی قاعده ضرب احتمال‌ها، همان اصل ضرب شمارش است که بر حسب «کسرها» نوشته شده است: وقتی انتخاب در مرحله دوم به انتخاب مرحله اول بستگی ندارد، تعداد حالت‌ها و در نتیجه احتمال‌ها در هم ضرب می‌شوند.

مثال ۳-۱۳: حزب سیاسی و علاقه به پاستا

یک پژوهشگر در ایالات متحده قصد داشته بداند میزان دموکرات/جمهوری‌خواه بودن مردم جامعه، چقدر به علاقه آن‌ها به پاستا ارتباط دارد! با مطالعه روی یک جامعه آماری بزرگ (فرض کنید بی‌نهایت نفر) به احتمالات زیر رسیده است:

	جمهوری‌خواه	دموکرات
پاستا دوست ندارد	0.08	0.12
پاستا دوست دارد	0.32	0.48

آیا این دو ویژگی از یکدیگر مستقل هستند؟

حل. ابتدا احتمال‌های حاشیه‌ای را با جمع سطرها و ستون‌ها حساب می‌کنیم (قانون جمع‌پذیری؛ هر ستون، اجتماع دو خانه ناسازگار است):

$$\mathbb{P}(\text{Rep}) = 0.08 + 0.32 = 0.4, \quad \mathbb{P}(\text{Dem}) = 0.12 + 0.48 = 0.6,$$

$$\mathbb{P}(\text{Pasta}) = 0.32 + 0.48 = 0.8, \quad \mathbb{P}(\text{pasta No}) = 0.08 + 0.12 = 0.2.$$

حال هر خانه جدول را با حاصل‌ضرب احتمال‌های حاشیه‌ای مقایسه می‌کنیم:

$$0.4 \times 0.2 = 0.08, \quad 0.6 \times 0.2 = 0.12, \quad 0.4 \times 0.8 = 0.32, \quad 0.6 \times 0.8 = 0.48.$$

هر چهار خانه دقیقاً برابر حاصل‌ضرب حاشیه‌ها هستند؛ پس این دو ویژگی **مستقل**اند: دانستن حزب یک فرد هیچ اطلاعی درباره علاقه او به پاستا نمی‌دهد (در هر دو حزب ۸۰٪ پاستا دوست دارند). ■

نکته. در یک جدول 2×2، اگر یکی از خانه‌ها در شرط استقلال صدق کند، سه خانه دیگر خودبه‌خود صدق می‌کنند (به تمرین ۹.۳ نگاه کنید). در جدول‌های بزرگ‌تر باید همه خانه‌ها را بررسی کرد.

۱.۷.۳ استقلال و هندسه رویدادها

قضیه ۳-۱۴: چند ویژگی ساده

۱. اگر دو رویداد ناسازگار (disjoint) باشند، قطعاً مستقل نیستند؛ مگر اینکه یکی از آن‌ها (احتمال) تهی باشد.

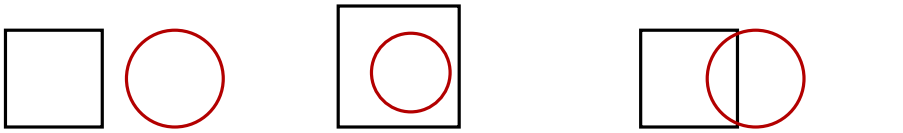
۲. اگر یک رویداد زیرمجموعه دیگری باشد، قطعاً مستقل نیستند؛ مگر اینکه یکی تهی یا خود Ω باشد (احتمال ۰ یا ۱ داشته باشد).

۳. هر رویدادی از $\varnothing$ و Ω مستقل است.

۴. دو رویدادی که قدری اشتراک و قدری عدم اشتراک دارند، می‌توانند مستقل باشند و می‌توانند

نباشند؛ باید رابطه را چک کرد.

اثبات. (۱) اگر $A\cap B=\varnothing$ آنگاه $\mathbb{P}(A\cap B)=0$؛ پس استقلال یعنی $\mathbb{P}(A)\mathbb{P}(B)=0$، یعنی یکی از دو احتمال صفر است. (۲) اگر $A\subseteq B$ آنگاه $A\cap B=A$؛ پس استقلال یعنی $\mathbb{P}(A)=\mathbb{P}(A)\mathbb{P}(B)$، یعنی $\mathbb{P}(A)=0$ یا $\mathbb{P}(B)=1$. (۳) $\mathbb{P}(A\cap\varnothing)=0=\mathbb{P}(A)\cdot 0$ و $\mathbb{P}(A\cap\Omega)=\mathbb{P}(A)=\mathbb{P}(A)\cdot 1$. (۴) با یک تاس سالم: اگر $A=\{1,2\}$ و $B=\{2,3,4\}$ آنگاه $\mathbb{P}(A\cap B)=\frac{1}{6}=\frac{1}{3}\cdot\frac{1}{2}$، پس مستقل‌اند. اما اگر $A=\{1,2\}$ و $B=\{2,3\}$ آنگاه $\mathbb{P}(A\cap B)=\frac{1}{6}\neq\frac{1}{3}\cdot\frac{1}{3}$، پس مستقل نیستند. □



شود چک باید جزئی: هم‌پوشانی　　وابسته زیرمجموعه:　　وابسته ناسازگار:

دقت کنید! «ناسازگار» و «مستقل» دو مفهوم کاملاً متفاوت‌اند و نباید آن‌ها را با هم اشتباه گرفت. ناسازگاری یک ویژگی **مجموعه‌ای** است (اشتراک تهی)، اما استقلال یک ویژگی **عددی** وابسته به اندازه احتمال است. در واقع دو رویداد ناسازگار با احتمال مثبت، به شدت وابسته‌اند: رخ دادن یکی، رخ ندادن دیگری را تضمین می‌کند.

تعریف ۳-۱۵: استقلال چند رویداد

رویدادهای $E_1,\dots,E_n$ را **(به طور متقابل) مستقل** گوییم اگر برای هر زیرمجموعه از اندیس‌ها $\{i_1<\cdots<i_\ell\}$ داشته باشیم

$$\mathbb{P}(E_{i_1}\cap\cdots\cap E_{i_\ell})=\mathbb{P}(E_{i_1})\cdots\mathbb{P}(E_{i_\ell}).$$

دقت کنید! استقلال دوبه‌دو، استقلال متقابل را نتیجه نمی‌دهد. مثال: دو سکه سالم را مستقل پرتاب کنید و قرار دهید A=«سکه اول شیر»، B=«سکه دوم شیر» و C=«دو سکه یکسان». هر سه احتمال $\frac{1}{2}$ دارند و هر دوتا از آن‌ها احتمال اشتراک $\frac{1}{4}$ دارند (پس دوبه‌دو مستقل‌اند)، اما $\mathbb{P}(A\cap B\cap C)=\mathbb{P}(HH)=\frac{1}{4}\neq\frac{1}{8}$.

۸.۳ چند مثال

۱.۸.۳ ترکیب دو یا چند عامل تصادفی با Ω محدود

مثال ۳-۱۶: مجموع سه تاس

یک تاس تصادفی و کاملاً متقارن را سه بار پشت سر هم می‌اندازیم. فرض کنید که پرتاب‌ها از یکدیگر مستقل هستند. احتمال اینکه جمع اعداد ظاهرشده برابر با ۸ شود چقدر است؟

حل. سه بار پرتاب یک تاس تصادفی:

$$\Omega=\{1,2,\dots,6\}^3=\{(1,1,1),\dots,(6,6,6)\},\qquad \mathcal{F}=2^\Omega,\qquad |\Omega|=216.$$

به واسطه تقارن تاس $P(1)=P(2)=\cdots=P(6)=\frac{1}{6}$ و به واسطه استقلال آماری پرتاب‌ها

$$P(i,j,k)=\frac{1}{6}\times\frac{1}{6}\times\frac{1}{6}=\frac{1}{216},\qquad \forall\, i,j,k\in\{1,\dots,6\}.$$

پس همه حالات هم‌احتمال هستند و با یک مسئله شمارش یا ترکیبیات روبه‌رو هستیم. اگر اعداد ظاهرشده برای سه تاس را به ترتیب با A، B و C نشان دهیم، به دنبال یافتن تعداد جواب‌های مسئله زیر هستیم:

$$A+B+C=8,\qquad A,B,C\in\{1,2,\dots,6\}.$$

چرا این مسئله با مسئله زیر معادل است؟

$$A'+B'+C'=5,\qquad A',B',C'\in\mathbb{Z}_{\geq 0}.$$

با تغییر متغیر $A'=A-1$، $B'=B-1$ و $C'=C-1$، شرط $A\geq 1$ به $A'\geq 0$ تبدیل می‌شود و مجموع به $8-3=5$ می‌رسد. این تغییر متغیر یک تناظر یک‌به‌یک بین جواب‌های دو مسئله است. اما شرط $A\leq 6$ (یعنی $A'\leq 5$) چه می‌شود؟ چون مجموع سه عدد نامنفی برابر ۵ است، هیچ‌کدام نمی‌تواند از ۵ بیشتر شود؛ پس قید بالایی خودبه‌خود برقرار است و می‌توان آن را کنار گذاشت.
جواب مسئله دوم را از جلسه اول (قضیه ستاره و میله) می‌دانیم: $\binom{5+3-1}{3-1}=\binom{7}{2}=21$. پس **جواب نهایی**:

$$P=\frac{1}{6^3}\binom{7}{2}=\frac{21}{216}\simeq 0.0972.$$

■

نکته. اگر مجموع مورد نظر مثلاً ۱۰ بود، تغییر متغیر به $A'+B'+C'=7$ می‌رسید و این بار ممکن بود یکی از متغیرها از ۵ بیشتر شود (مثل $A'=7$)؛ آنگاه باید حالت‌های نامعتبر را با اصل شمول و عدم شمول کم کنیم: $\binom{9}{2}-3\binom{3}{2}=36-9=27$، پس $\mathbb{P}(\text{sum}=10)=27/216=0.125$.

۲.۸.۳ مسئله روز تولد (Birthday Party Problem)

مثال ۳-۱۷: پارادوکس روز تولد

در یک جمع n نفره از افراد مستقل و تصادفی، احتمال اینکه هیچ دو نفری روز تولد یکسان نداشته باشند چقدر است؟ (فرض: سال ۳۶۵ روز دارد و روز تولد هر فرد با احتمال یکسان هر یک از این روزهاست.)

حل. افراد را به ترتیب در نظر می‌گیریم و رویداد E_i را «روز تولد نفر iام با هیچ‌یک از نفرات قبلی یکی نباشد» تعریف می‌کنیم.

- احتمال اینکه روز تولد نفر دوم با اولی یکی نباشد: $P(E_2)=1-\frac{1}{365}$.
- احتمال اینکه روز تولد نفر سوم با اولی و دومی یکی نباشد (به شرط اینکه آن دو متفاوت باشند): $P(E_3\,|\,E_2)=1-\frac{2}{365}$.

- ...
- احتمال اینکه روز تولد نفر nام با قبلی‌ها یکی نباشد: $P(E_n \mid E_{2:n-1}) = 1 - \frac{n-1}{365}$.

به دلیل استقلال، روز تولد یک نفر تأثیری در احتمالات روزهای تولد سایر افراد ندارد؛ نفر iام کافی است یکی از $365 - (i-1)$ روز «آزاد» را داشته باشد. لذا احتمال یکی نبودن هیچ روز تولدی (با قانون ضرب/زنجیره‌ای که در جلسه بعد دقیق می‌شود):

$$P(E_2 \cap E_3 \cap \cdots \cap E_n) = \prod_{i=1}^{n-1} \Big(1 - \frac{i}{365}\Big).$$

همین جواب را مستقیماً با شمارش نیز می‌توان دید: از 365^n حالت هم‌احتمال، تعداد حالت‌هایی که همه روزها متمایزند $365 \times 364 \times \cdots \times (365-n+1)$ است.
برای به دست آوردن یک تقریب ساده، از نامساوی $1 - x \le e^{-x}$ استفاده می‌کنیم:

$$\prod_{i=1}^{n-1} \Big(1 - \frac{i}{365}\Big) \le \prod_{i=1}^{n-1} e^{-\frac{i}{365}} = \exp\Big(-\frac{1}{365}\sum_{i=1}^{n-1} i\Big) = \exp\Big(-\frac{n(n-1)}{2\times 365}\Big).$$

■

جدول زیر مقدار دقیق احتمال وجود حداقل یک روز تولد مشترک را نشان می‌دهد:

n	10	20	23	30	40	50	57	70
$\mathbb{P}$(shared no)	0.883	0.589	0.493	0.294	0.109	0.030	0.010	0.001
$\mathbb{P}$(shared)	0.117	0.411	0.507	0.706	0.891	0.970	0.990	0.999

نکته. به همین دلیل به این مسئله «پارادوکس» می‌گویند: تنها با ۲۳ نفر، احتمال وجود دو نفر با روز تولد یکسان از ۵۰٪ بیشتر است و با ۵۷ نفر به ۹۹٪ می‌رسد. دلیل شهودی: تعداد **زوج‌های** افراد $\binom{n}{2}$ است که به صورت n^2 رشد می‌کند؛ برای $n = 23$ داریم ۲۵۳ زوج، و هر زوج با احتمال $1/365$ «برخورد» دارد. فرمول $\exp(-n(n-1)/730)$ نیز نشان می‌دهد احتمال وقتی n از مرتبه $\sqrt{365}$ است، به‌طور معناداری کاهش می‌یابد. این ایده در علوم کامپیوتر در تحلیل **برخورد توابع درهم‌ساز** (hash collision) و «حمله روز تولد» در رمزنگاری کاربرد دارد.

۳.۸.۳ مسئله Monty Hall

مثال ۳-۱۸: مسئله مونتی هال

فرض کنید که در یک مسابقه تلویزیونی شرکت کرده‌اید و جایزه‌ای پشت یکی از سه در زیر پنهان شده است. شما یک در را به صورت کاملاً تصادفی انتخاب می‌کنید... سپس، مجری برنامه (که می‌داند جایزه پشت کدام در است) یکی از دو در باقیمانده را که جایزه پشت آن نیست برای شما باز (پوچ) می‌کند و تنها یک در باقی خواهد ماند که شما انتخاب نکرده‌اید. **سؤال:** آیا انتخاب خود را تغییر می‌دهید؟

حل. بله؛ تغییر انتخاب احتمال برد را از $\frac{1}{3}$ به $\frac{2}{3}$ می‌رساند.

روش اول (استدلال مستقیم): احتمال اینکه انتخاب اولیه شما درست باشد $\frac{1}{3}$ است و کار مجری این

احتمال را تغییر نمی‌دهد؛ زیرا مجری **همیشه** می‌تواند یک در پوچ از میان دو در دیگر باز کند، پس باز کردن در توسط او اطلاعاتی درباره در شما نمی‌دهد. پس اگر روی انتخاب خود بمانید با احتمال $\frac{1}{3}$ برنده می‌شوید. اما اگر عوض کنید، دقیقاً زمانی برنده می‌شوید که انتخاب اولیه‌تان **اشتباه** بوده باشد (چون در آن صورت مجری مجبور است تنها در پوچ دیگر را باز کند و در باقیمانده حتماً جایزه دارد)، که احتمالش $\frac{2}{3}$ است.

روش دوم (شمارش حالات): فرض کنید شما در ۱ را انتخاب کرده‌اید. جایزه با احتمال برابر پشت یکی از سه در است:

محل جایزه	دری که مجری باز می‌کند	نتیجه ماندن	نتیجه تغییر
در ۱ (احتمال $\frac{1}{3}$)	۲ یا ۳	برد	باخت
در ۲ (احتمال $\frac{1}{3}$)	فقط ۳	باخت	برد
در ۳ (احتمال $\frac{1}{3}$)	فقط ۲	باخت	برد

پس $\mathbb{P}(\text{win} \mid \text{stay}) = \frac{1}{3}$ و $\mathbb{P}(\text{win} \mid \text{switch}) = \frac{2}{3}$. ■

دقت کنید! استدلال رایج اما غلط این است که «پس از باز شدن یک در، دو در باقی مانده و هر کدام احتمال $\frac{1}{2}$ دارند». این استدلال فرض می‌کند دو در باقیمانده متقارن‌اند، در حالی که نیستند: در شما **قبل** از اطلاعات مجری انتخاب شده، اما در باقیمانده توسط مجری (با دانستن محل جایزه) «پالایش» شده است. در جلسه بعد همین مسئله را با قانون بیز به‌طور دقیق حل می‌کنیم.

۹.۳ تمرین‌های تکمیلی

تمرین ۳-۱۹: کران پایین بونفرونی

نشان دهید برای هر دو رویداد $\mathbb{P}(A \cap B) \geq \mathbb{P}(A) + \mathbb{P}(B) - 1$. سپس اگر ۹۰٪ دانشجویان درس اول و ۸۰٪ درس دوم را پاس کرده باشند، کمترین درصد ممکن برای پاس کردن هر دو درس چقدر است؟

حل. از اصل شمول و عدم شمول $\mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cup B)$ و چون $\mathbb{P}(A \cup B) \leq 1$، حکم ثابت می‌شود. در مثال عددی: $\mathbb{P}(A \cap B) \geq 0.9 + 0.8 - 1 = 0.7$؛ یعنی دست‌کم ۷۰٪ هر دو درس را پاس کرده‌اند. این کران با حالتی که همه مردودها متفاوت باشند (۱۰٪ و ۲۰٪ بدون هم‌پوشانی) به دست می‌آید. (این نامساوی همان کران اجتماع است که روی متمم‌ها اعمال شده: $\mathbb{P}(A^c \cup B^c) \leq \mathbb{P}(A^c) + \mathbb{P}(B^c)$.) ■

تمرین ۳-۲۰

نشان دهید اگر A و B مستقل باشند، آنگاه A و B^c، و همچنین A^c و B^c نیز مستقل‌اند.

حل. $A = (A \cap B) \cup (A \cap B^c)$ و این دو ناسازگارند، پس $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A)(1 - \mathbb{P}(B)) = \mathbb{P}(A)\mathbb{P}(B^c)$. با اعمال دوباره همین نتیجه روی زوج مستقل (B^c, A) نتیجه می‌گیریم A^c و B^c نیز مستقل‌اند. ■

تمرین ۳-۲۱

سکه سالمی را ۶ بار پرتاب می‌کنیم. احتمال آمدن دست‌کم ۲ شیر چقدر است؟ احتمال اینکه تعداد شیرها زوج باشد چقدر است؟

حل. با متمم: $\mathbb{P}(k \geq 2) = 1 - \mathbb{P}(k=0) - \mathbb{P}(k=1) = 1 - \frac{1+6}{64} = \frac{57}{64} \approx 0.891$. برای زوج بودن: $\mathbb{P}(k \text{ even}) = \frac{\binom{6}{0}+\binom{6}{2}+\binom{6}{4}+\binom{6}{6}}{64} = \frac{1+15+15+1}{64} = \frac{1}{2}$. (در حالت کلی از $(1+1)^n + (1-1)^n = 2\sum_{k \text{ even}} \binom{n}{k}$ نتیجه می‌شود که برای هر $n \geq 1$ این احتمال $\frac{1}{2}$ است.) ■

تمرین ۳-۲۲: روز تولد شما

در یک جمع n نفره (به جز شما)، احتمال اینکه دست‌کم یک نفر روز تولدش با **شما** یکی باشد چقدر است؟ برای $n = 22$ مقدار آن را با مسئله روز تولد مقایسه کنید.

حل. روز تولد هر نفر مستقلاً با احتمال $\frac{364}{365}$ با شما متفاوت است؛ پس $\mathbb{P} = 1 - \left(\frac{364}{365}\right)^n$. برای $n = 22$ این مقدار حدود 0.059 است؛ در حالی که در جمع ۲۳ نفره احتمال وجود **یک جفت** با روز تولد یکسان حدود 0.507 است. تفاوت از آنجاست که در اینجا فقط n مقایسه (با شما) انجام می‌شود، اما در مسئله روز تولد $\binom{n+1}{2}$ مقایسه بین همه جفت‌ها. ■

تمرین ۳-۲۳

تاس سالمی را ۴ بار می‌اندازیم. احتمال اینکه دست‌کم یک بار ۶ بیاید را حساب کنید و نشان دهید کران اجتماع در اینجا چه عددی می‌دهد.

حل. با متمم و استقلال: $\mathbb{P}(\text{ one least at} 6) = 1 - (5/6)^4 = 1 - \frac{625}{1296} \approx 0.518$. کران اجتماع: $\mathbb{P}(\bigcup_{i=1}^{4} \{\text{ roll} i = 6\}) \leq 4 \times \frac{1}{6} \approx 0.667$. کران از مقدار واقعی بزرگ‌تر است، زیرا رویدادها ناسازگار نیستند (ممکن است چند بار ۶ بیاید). ■

جلسه ۴

احتمال شرطی، قانون زنجیره‌ای، احتمال کل و قانون بیز

۱.۴ احتمال شرطی (Conditional Probability)

در بسیاری موارد، **اطلاعاتی** در مورد یک واقعه تصادفی به دست ما می‌رسد. در این شرایط، به دنبال یافتن احتمال‌های به‌روزشده هستیم.

برای مثال، در پرتاب یک تاس ۶ وجهی متقارن، در صورتی که پیش‌تر بدانیم واقعه **آمدن یک عدد فرد**، یعنی $E_{\text{odd}} = \{1, 3, 5\}$، حتماً اتفاق افتاده است، آنگاه:

- احتمال رخ دادن عدد ۲ **صفر** خواهد شد (پیش از آن $\frac{1}{6}$ بود)؛
- احتمال واقعه رخ دادن عددی کوچک‌تر یا مساوی ۳ **بیشتر** خواهد شد: پیش از اطلاع برابر $\frac{3}{6} = \frac{1}{2}$ بود، اما پس از دانستن فرد بودن، از سه حالت ممکن $\{1, 3, 5\}$ دو حالت $\{1, 3\}$ مطلوب‌اند؛ پس احتمال به $\frac{2}{3}$ می‌رسد.

این در حالی است که این احتمالات پیش از رسیدن اطلاعات فوق، اعداد متفاوتی بودند.

تعریف ۴-۱: احتمال شرطی

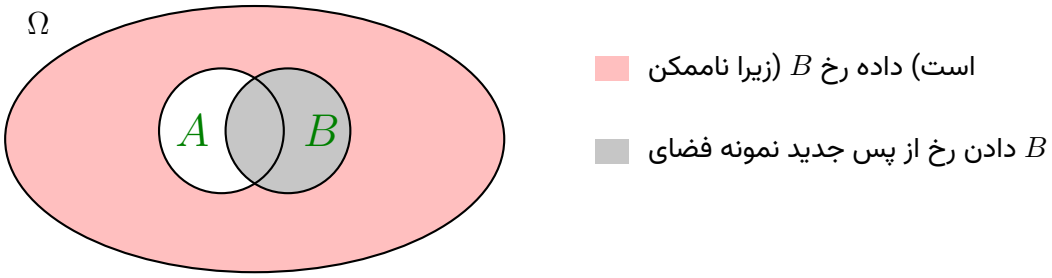
در آمار و احتمال، **احتمال شرطی** واقعه A به شرط B (خوانده می‌شود A given B یا A conditioned on B) را به صورت احتمال به‌روزشده رویداد A تعریف می‌کنیم، به شرطی که بدانیم رویداد B حتماً اتفاق افتاده است. برای $\mathbb{P}(B) > 0$ تعریف می‌کنیم:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

دلیل ظاهر شدن مخرج: پس از دانستن رخ دادن B، گویی فضای نمونه‌ها Ω کوچک‌تر شده است. تنها وقایعی که برابر یا زیرمجموعه B هستند باقی خواهند ماند. پس از A فقط قسمت $A \cap B$ هنوز ممکن است، و برای اینکه احتمال کل فضای جدید (یعنی B) برابر ۱ شود، همه احتمال‌ها را بر $\mathbb{P}(B)$ تقسیم می‌کنیم

(نرمال‌سازی). در مثال تاس:

$$\mathbb{P}(\leq 3 \,|\, \text{odd}) = \frac{\mathbb{P}(\{1,3\})}{\mathbb{P}(\{1,3,5\})} = \frac{2/6}{3/6} = \frac{2}{3}.$$



شکل ۱.۴: نمایش گرافیکی احتمال شرطی: بعد از رخداد B، فضای نمونه مؤثر (و به تبع آن، فضای وقایع مؤثر) کوچک‌تر خواهد شد.

نکته. دقت کنید که $\mathbb{P}(A \,|\, B)$ می‌تواند از $\mathbb{P}(A)$ **بزرگ‌تر**، **کوچک‌تر** یا **مساوی** باشد. این بستگی خواهد داشت که رویداد B، چه میزان اطلاعاتی در مورد رویداد A به دست می‌دهد. در مثال تاس: $\mathbb{P}(\leq 3 \,|\, \text{odd}) = \frac{2}{3} > \frac{1}{2}$ ولی $\mathbb{P}(2 \,|\, \text{odd}) = 0 < \frac{1}{6}$.

قضیه ۴-۲: احتمال شرطی و استقلال

اگر $\mathbb{P}(B) > 0$، آنگاه دو رویداد A و B مستقل‌اند اگر و تنها اگر $\mathbb{P}(A \,|\, B) = \mathbb{P}(A)$؛ زیرا در صورت استقلال

$$\mathbb{P}(A \,|\, B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A),$$

و برعکس، از $\mathbb{P}(A \,|\, B) = \mathbb{P}(A)$ با ضرب دو طرف در $\mathbb{P}(B)$ تعریف استقلال به دست می‌آید.

این تعبیر، استقلال را شهودی‌تر می‌کند: **دانستن رخ دادن B هیچ اطلاعی درباره A نمی‌دهد.**

نکته. به ازای B ثابت، تابع $A \mapsto \mathbb{P}(A \,|\, B)$ خودش یک اندازه احتمال (در اصول کولموگروف صادق) است: نامنفی است، $\mathbb{P}(\Omega \,|\, B) = \mathbb{P}(B)/\mathbb{P}(B) = 1$، و جمع‌پذیر است. پس همه قضایایی که برای احتمال ثابت کردیم (متمم، شمول و عدم شمول، کران اجتماع و ...) برای احتمال شرطی نیز برقرارند؛ مثلاً $\mathbb{P}(A^c \,|\, B) = 1 - \mathbb{P}(A \,|\, B)$.

مثال ۴-۳: تصادفات جاده‌ای و شرایط جوی

فرض کنید احتمالات زیر مربوط به واقعه تصادفات جاده‌ای در شرایط مختلف جوی باشند:

	صاف (clear)	مه‌آلود (mist)
تردد امن	0.73	0.17
تصادف (crash)	0.01	0.09

- سؤال ۱: احتمال تصادف چقدر است؟
- سؤال ۲: احتمال تصادف به شرط هوای مه‌آلود چقدر است؟

- سؤال ۳: آیا احتمال تصادف، از شرایط جوی جاده مستقل است؟

حل. سؤال ۱: رویداد تصادف اجتماع دو خانه ناسازگار سطر دوم است:

$$\mathbb{P}(\text{crash}) = 0.01 + 0.09 = 0.10.$$

سؤال ۲: ابتدا احتمال مه‌آلود بودن (جمع ستون مه‌آلود) و احتمال اشتراک را می‌یابیم:

$$\mathbb{P}(\text{crash} \cap \text{mist}) = 0.09, \qquad \mathbb{P}(\text{mist}) = 0.17 + 0.09 = 0.26,$$

$$\mathbb{P}(\text{crash} \mid \text{mist}) = \frac{0.09}{0.09 + 0.17} = \frac{0.09}{0.26} \approx 0.346.$$

سؤال ۳: $\mathbb{P}(\text{crash} \mid \text{mist}) \approx 0.346$ با $\mathbb{P}(\text{crash}) = 0.10$ **برابر نیستند.** پس واقعه تصادف مستقل از مه‌آلود بودن نیست. به‌علاوه در هوای صاف $\mathbb{P}(\text{crash} \mid \text{clear}) = \frac{0.01}{0.74} \approx 0.0135$؛ یعنی احتمال تصادف در هوای مه‌آلود حدود ۲۶ برابر هوای صاف است! ■

۲.۴ قانون زنجیره‌ای (Chain Rule)

۱.۲.۴ حالت دوتایی و سه‌تایی

با توجه به تعریف احتمال شرطی (و نوشتن $\mathbb{P}(A, B)$ به جای $\mathbb{P}(A \cap B)$) خواهیم داشت:

$$\boxed{\mathbb{P}(A, B) = \mathbb{P}(A \mid B)\, \mathbb{P}(B)}$$

در صورتی که سه واقعه A، B و C را مدنظر قرار داده باشیم، می‌توان رابطه بالا را به صورت تو در تو تکرار کرد. ابتدا (B, C) را یک رویداد در نظر می‌گیریم:

$$\mathbb{P}(A, B, C) = \mathbb{P}(A \mid B, C)\, \mathbb{P}(B, C),$$

و سپس رابطه دوتایی را برای $\mathbb{P}(B, C)$ به کار می‌بریم:

$$\boxed{\mathbb{P}(A, B, C) = \mathbb{P}(A \mid B, C)\, \mathbb{P}(B \mid C)\, \mathbb{P}(C)}$$

نکته. وقتی احتمالی را به بیش از یک رویداد مشروط می‌کنیم (مانند $\mathbb{P}(A \mid B, C)$)، منظور این است که فرض کنید **تمامی** آنان رخ داده باشند؛ یعنی $\mathbb{P}(A \mid B, C) = \mathbb{P}(A \mid B \cap C)$.

۲.۲.۴ حالت کلی و موارد کاربردی

قضیه ۴-۴: قانون زنجیره‌ای

در حالت کلی، برای احتمال رخ دادن توأمان تمامی رویدادهای $A_1, A_2, \ldots, A_n$ خواهیم داشت:

$$\mathbb{P}(A_1, A_2, \ldots, A_n) = \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}(A_i \mid A_{i-1}, \ldots, A_1).$$

اثبات. با استقرا روی n. برای $n = 2$ همان تعریف احتمال شرطی است. اگر برای $n-1$ برقرار باشد، با در نظر گرفتن $B = A_1 \cap \cdots \cap A_{n-1}$ داریم $\mathbb{P}(A_1, \ldots, A_n) = \mathbb{P}(A_n \mid B)\mathbb{P}(B)$ و با جایگذاری فرض استقرا برای $\mathbb{P}(B)$ حکم ثابت می‌شود. (معادلاً، در حاصل‌ضرب سمت راست، صورت هر کسر با مخرج کسر بعدی ساده می‌شود و فقط $\mathbb{P}(A_1 \cap \cdots \cap A_n)$ باقی می‌ماند.) □

در مواردی محاسبه احتمالات شرطی بسیار ساده است. مثلاً، یک مدل‌سازی آماری را از ابتدا بر حسب احتمال‌های شرطی بنا می‌کنیم (مانند مسئله روز تولد در جلسه قبل که در آن $\mathbb{P}(E_i \mid E_2, \ldots, E_{i-1}) = 1 - \frac{i-1}{365}$ به‌راحتی به دست می‌آمد).

نکته. نکته اضافی (خاصیت مارکوف): بسیاری از پدیده‌ها، خاصیت Markovian دارند. به عنوان مثال، رویداد A_i می‌تواند به شرط دانستن A_{i-1} از تمام رویدادهای $A_{i-2}, A_{i-3}, \ldots, A_1$ مستقل شود. در این صورت، محاسبه رابطه فوق بسیار ساده می‌شود:

$$\mathbb{P}(A_1, \ldots, A_n) = \mathbb{P}(A_1) \prod_{i=2}^{n} \mathbb{P}(A_i \mid A_{i-1}).$$

برای مثال آب‌وهوای فردا را معمولاً تنها با دانستن آب‌وهوای امروز پیش‌بینی می‌کنیم.

مثال ۴-۵: بیرون کشیدن بدون جایگذاری

از یک دسته کارت ۵۲تایی، سه کارت بدون جایگذاری بیرون می‌کشیم. احتمال اینکه هر سه کارت آس باشند چقدر است؟

حل. A_i را رویداد «کارت iام آس است» بگیرید. با قانون زنجیره‌ای:

$$\mathbb{P}(A_1, A_2, A_3) = \mathbb{P}(A_1)\mathbb{P}(A_2 \mid A_1)\mathbb{P}(A_3 \mid A_1, A_2) = \frac{4}{52} \cdot \frac{3}{51} \cdot \frac{2}{50} = \frac{24}{132600} \approx 1.81 \times 10^{-4}.$$

هر احتمال شرطی به‌سادگی به دست می‌آید: پس از بیرون آمدن یک آس، ۳ آس در ۵۱ کارت باقی مانده است. (بررسی با شمارش: $\binom{4}{3}/\binom{52}{3} = 4/22100$، همان عدد.) ■

۳.۴ قانون احتمال کل (The Law of Total Probability)

تعریف ۴-۶: افراز

فرض کنید که $A_1, A_2, \ldots, A_n$ (که n می‌تواند ∞ هم باشد) رویدادهایی درون $\mathcal{F}$ باشند. آن‌ها را یک **افراز** (Partition) از Ω گوییم اگر

$$\bigcup_{i=1}^{n} A_i = \Omega, \qquad A_i \cap A_j = \varnothing \quad (\text{if} i \neq j).$$

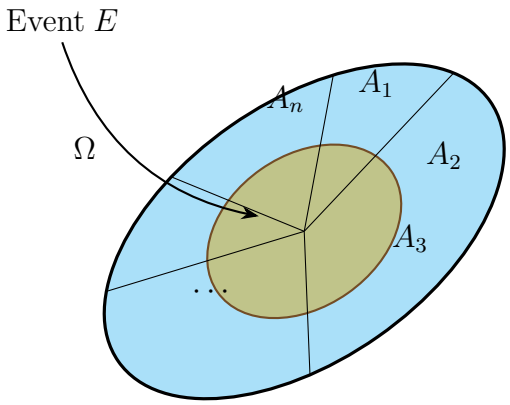
در این صورت، با هر بار انجام آزمایش یکی (و دقیقاً یکی) از $A_1, \ldots, A_n$ رخ خواهد داد. همچنین تمام $\mathbb{P}(A_i)$ها نیز تعریف شده هستند.

قضیه ۴-۷: قانون احتمال کل

اگر $A_1, \ldots, A_n$ یک افراز از Ω باشند، برای هر واقعه‌ای مانند E خواهیم داشت:

$$\mathbb{P}(E) = \sum_{i=1}^{n} \mathbb{P}(E \mid A_i)\, \mathbb{P}(A_i).$$

اثبات. رویدادهای $E \cap A_i$ ناسازگارند (چون A_iها ناسازگارند) و اجتماعشان $E \cap \Omega = E$ است. پس $\mathbb{P}(E) = \sum_i \mathbb{P}(E \cap A_i) = \sum_i \mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$. □



شکل ۲.۴: قانون احتمال کل: رویداد E (بیضی داخلی) توسط افراز $A_1, \ldots, A_n$ به قطعه‌هایی (slice) تقسیم می‌شود.

در واقع هر یک از $\mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$ها، طبق تعریف برابر با $\mathbb{P}(E, A_i)$ هستند، و برابر با جرم احتمال جمع‌شده در یکی از تکه‌ها (slice‌های) واقعه E می‌باشند.

نکته. قانون احتمال کل زمانی به درد می‌خورد که وقوع یک واقعه از طریق چندین **مکانیزم** وجود دارد، و احتمال وقوع به شرط هر یک از آنان را می‌دانیم. به این روش «شکستن به حالات» (conditioning) نیز می‌گویند.

مثال ۴-۸: کارخانه با سه خط تولید

یک کارخانه سه خط تولید دارد که به ترتیب ۵۰٪، ۳۰٪ و ۲۰٪ محصولات را تولید می‌کنند. درصد محصولات معیوب در این خطوط به ترتیب ۱٪، ۲٪ و ۵٪ است. احتمال اینکه یک محصول تصادفی معیوب باشد چقدر است؟

حل. خطوط تولید L_1, L_2, L_3 یک افراز هستند. با قانون احتمال کل:

$$\mathbb{P}(D) = 0.01 \times 0.5 + 0.02 \times 0.3 + 0.05 \times 0.2 = 0.005 + 0.006 + 0.010 = 0.021.$$

■

۴.۴ قانون بیز (Bayes' Rule)

قانون بیز، رابطه ساده ولی بسیار پرکاربردی است که کمک می‌کند تا ترتیب وقایع شرطی در احتمال را عوض کنیم. یعنی با داشتن $\mathbb{P}(A \mid B)$، و همین‌طور احتمال‌های حاشیه‌ای $\mathbb{P}(B)$ و $\mathbb{P}(A)$، بتوانیم $\mathbb{P}(B \mid A)$ را محاسبه کنیم.

قضیه ۴-۹: قانون بیز

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B)\,\mathbb{P}(B)}{\mathbb{P}(A)}.$$

اثبات. طبق قانون زنجیره‌ای، $\mathbb{P}(A \cap B)$ را به دو صورت می‌توان نوشت: $\mathbb{P}(B \mid A)\mathbb{P}(A) = \mathbb{P}(A \cap B) = \mathbb{P}(A \mid B)\mathbb{P}(B)$. با تقسیم بر $\mathbb{P}(A)$ حکم به دست می‌آید. □

یک شکل دیگر نگاه کردن به این رابطه، به صورت زیر است:

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \mid B)}{\mathbb{P}(A)}\,\mathbb{P}(B).$$

در رابطه بالا:

- به احتمال $\mathbb{P}(B)$ در اصطلاح **احتمال پیشین** (Prior Probability)، و
- به احتمال $\mathbb{P}(B \mid A)$ در اصطلاح **احتمال پسین** (Posterior Probability) می‌گوییم.

ضریب $\frac{\mathbb{P}(A \mid B)}{\mathbb{P}(A)}$ نشان می‌دهد مشاهده A باور ما به B را چند برابر می‌کند. به $\mathbb{P}(A \mid B)$ (به عنوان تابعی از B) «درست‌نمایی» (likelihood) می‌گویند.

قضیه ۴-۱۰: قانون بیز همراه با احتمال کل

اگر $B_1, \ldots, B_n$ یک افراز باشند، مخرج قانون بیز را می‌توان با قانون احتمال کل حساب کرد:

$$\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \mid B_j)\mathbb{P}(B_j)}{\sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)}.$$

۱.۴.۴ دیدگاه بیزی

دیدگاه Bayesian در آمار و احتمال بر این اصل مبتنی است که: برای مدل‌سازی تصادفی تأثیر دو رویداد تصادفی بر یکدیگر (مثلاً تأثیر فضای وقایع Ω_B بر Ω_A)، با فضای وقایع کلی $\Omega_A \times \Omega_B$، صرفاً لازم است تا موارد زیر را داشته باشیم (یا مدل‌سازی کنیم):

- احتمال در فضای وقایع منتسب به Ω_B (احتمال پیشین)؛
- احتمالات شرطی در فضای وقایع منتسب به Ω_A به شرط وقایع B (مدل مشاهده).

با این دو، طبق قانون زنجیره‌ای کل توزیع توأم مشخص می‌شود و با قانون بیز می‌توان «برعکس» فکر کرد: از مشاهده A درباره علت B استنتاج کرد. موارد کاربردی دیدگاه Bayesian بسیار زیاد هستند: Bayesian inference, Bayesian optimization, Bayesian network, Bayesian Hierarchy و ...

مثال ۴-۱۱: آزمایش پزشکی ــ یک مثال کلاسیک

بیماری خاصی در ۱٪ جامعه وجود دارد. یک آزمایش تشخیصی، فرد بیمار را با احتمال ۹۹٪ مثبت اعلام می‌کند (حساسیت) و فرد سالم را با احتمال ۹۵٪ منفی اعلام می‌کند. اگر جواب آزمایش یک فرد تصادفی مثبت باشد، احتمال اینکه واقعاً بیمار باشد چقدر است؟

حل. D را رویداد بیماری و $+$ را مثبت شدن آزمایش بگیرید. داریم $\mathbb{P}(D) = 0.01$، $\mathbb{P}(+ \mid D) = 0.99$ و $\mathbb{P}(+ \mid D^c) = 0.05$. با احتمال کل:

$$\mathbb{P}(+) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594.$$

با قانون بیز:

$$\mathbb{P}(D \mid +) = \frac{0.99 \times 0.01}{0.0594} \approx 0.167.$$

یعنی با وجود دقت ظاهراً بالای آزمایش، تنها حدود ۱۷٪ از افراد با جواب مثبت واقعاً بیمارند! علت، کوچک بودن احتمال پیشین (1%) است: تعداد افراد سالمی که به اشتباه مثبت می‌شوند (5% از 99%) از تعداد بیماران واقعی بیشتر است. ■

مثال ۴-۱۲: حل دقیق مسئله مونتی هال با قانون بیز

فرض کنید در ۱ را انتخاب کرده‌اید و مجری در ۳ را باز کرده است. احتمال اینکه جایزه پشت در ۲ باشد چقدر است؟ (فرض: اگر جایزه پشت در ۱ باشد، مجری با احتمال برابر یکی از درهای ۲ و ۳ را باز می‌کند.)

حل. C_i را رویداد «جایزه پشت در i» و O_3 را «مجری در ۳ را باز می‌کند» بگیرید. احتمال‌های پیشین $\mathbb{P}(C_i) = \frac{1}{3}$ هستند. درست‌نمایی‌ها:

$$\mathbb{P}(O_3 \mid C_1) = \tfrac{1}{2}, \qquad \mathbb{P}(O_3 \mid C_2) = 1, \qquad \mathbb{P}(O_3 \mid C_3) = 0.$$

با احتمال کل: $\mathbb{P}(O_3) = \frac{1}{3}(\frac{1}{2} + 1 + 0) = \frac{1}{2}$. با قانون بیز:

$$\mathbb{P}(C_2 \mid O_3) = \frac{1 \times \frac{1}{3}}{\frac{1}{2}} = \frac{2}{3}, \qquad \mathbb{P}(C_1 \mid O_3) = \frac{\frac{1}{2} \times \frac{1}{3}}{\frac{1}{2}} = \frac{1}{3}.$$

پس تغییر انتخاب احتمال برد را دو برابر می‌کند. ■

۵.۴ استقلال شرطی (Conditional Independence)

در موارد متعددی پیش می‌آید که دو رویداد A و B از یکدیگر مستقل نباشند:

$$\mathbb{P}(A, B) \neq \mathbb{P}(A)\mathbb{P}(B),$$

ولی در صورت دانستن رویداد سومی مانند C، به صورت شرطی از یکدیگر مستقل شوند.

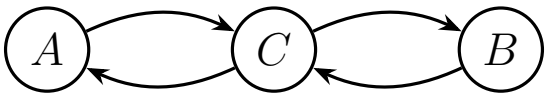
تعریف ۴-۱۳: استقلال شرطی

دو رویداد A و B را به شرط C مستقل گوییم (و می‌نویسیم $A \perp B \,|\, C$) اگر

$$\mathbb{P}(A, B \,|\, C) = \mathbb{P}(A \,|\, C)\, \mathbb{P}(B \,|\, C).$$

معادلاً (وقتی احتمال‌ها مثبت‌اند): $\mathbb{P}(A \,|\, B, C) = \mathbb{P}(A \,|\, C)$؛ یعنی وقتی C را می‌دانیم، دانستن B اطلاع بیشتری درباره A نمی‌دهد.

این اتفاق زمانی رخ می‌دهد که مسیر جریان اطلاعات (information flow) از سمت رویداد A به سمت B (و یا بالعکس)، به واسطه دادن/گرفتن اطلاعاتی در مورد رویداد C باشد:



اگر C معلوم باشد، این «کانال» مسدود می‌شود و A و B دیگر از طریق آن اطلاعاتی رد و بدل نمی‌کنند.

دقت کنید! استقلال و استقلال شرطی هیچ‌کدام دیگری را نتیجه نمی‌دهند. ممکن است $A \perp B$ ولی $A \not\perp B \,|\, C$ (مثلاً دو سکه مستقل و C=«دو سکه یکسان‌اند»؛ با دانستن C، نتیجه سکه اول، سکه دوم را کاملاً مشخص می‌کند). و ممکن است $A \not\perp B$ ولی $A \perp B \,|\, C$ (مثال بعد).

مثال ۴-۱۴: دو سکه نامتقارن ــ صورت مسئله

فرض کنید در جعبه‌ای دو سکه تصادفی و نامتقارن گذارده شده‌اند که احتمال شیر آمدن در آنان به ترتیب ۲۵٪ و ۸۰٪ است. بر این اساس، آزمون تصادفی زیر را انجام می‌دهیم:

۱. به صورت تصادفی و با احتمال‌های برابر، یکی از دو سکه را از جعبه انتخاب می‌کنیم.

۲. این سکه را ۵ بار به صورت مستقل پرتاب کرده و نتایج را در گزارش A ثبت می‌کنیم.

۳. سپس، سکه را ۵ بار دیگر (به صورت مستقل از یکدیگر و بند ۲) پرتاب کرده و نتایج را در گزارش B ثبت می‌کنیم.

سؤال: در صورت دانستن نتیجه گزارش A، پیش‌بینی شما در مورد گزارش B تغییر می‌کند یا خیر؟ چرا؟ فرض کنید که نتیجه گزارش A برابر با $HHTHT$ شود. آنگاه احتمال اینکه در گزارش B رشته $TTHTT$ را ببینیم چقدر است؟

پاسخ کامل این مثال را در ابتدای جلسه بعد خواهیم دید. پاسخ کیفی: **بله، تغییر می‌کند**؛ زیرا گزارش A اطلاعاتی درباره اینکه کدام سکه انتخاب شده است به ما می‌دهد (سه شیر از پنج پرتاب، احتمال سکه دوم

را بالا می‌برد) و این اطلاع، پیش‌بینی ما از B را تغییر می‌دهد. با این حال، **به شرط دانستن سکه**، A و B مستقل‌اند.

۶.۴ تمرین‌های تکمیلی

تمرین ۴-۱۵

دو تاس سالم پرتاب می‌کنیم. به شرط اینکه مجموع دو تاس ۸ باشد، احتمال اینکه دست‌کم یکی از تاس‌ها ۶ باشد چقدر است؟

حل. حالت‌های با مجموع ۸: $(2,6),(3,5),(4,4),(5,3),(6,2)$ ــ پنج حالت هم‌احتمال. از این‌ها دو حالت شامل ۶ هستند. پس $\mathbb{P}=\frac{2}{5}$. (در مقایسه، احتمال غیرشرطی وجود دست‌کم یک ۶ برابر $\frac{11}{36}\approx 0.31$ است.) ■

تمرین ۴-۱۶: دو فرزند

خانواده‌ای دو فرزند دارد (هر فرزند مستقلاً با احتمال $\frac{1}{2}$ پسر است). (الف) به شرط اینکه فرزند بزرگ‌تر پسر باشد، احتمال اینکه هر دو پسر باشند چقدر است؟ (ب) به شرط اینکه دست‌کم یکی پسر باشد چطور؟

حل. فضای نمونه $\{BB,\,BG,\,GB,\,GG\}$ هم‌احتمال است (حرف اول: فرزند بزرگ‌تر). (الف) شرط: $\{BB,BG\}$؛ پس $\mathbb{P}(BB\,|\,\cdot)=\frac{1}{2}$. (ب) شرط: $\{BB,BG,GB\}$؛ پس $\mathbb{P}(BB\,|\,\cdot)=\frac{1}{3}$. تفاوت دو جواب نشان می‌دهد که «چه اطلاعاتی» دقیقاً داده شده، اهمیت دارد. ■

تمرین ۴-۱۷: قانون بیز با سه خط تولید

در مثال کارخانه، اگر محصولی معیوب باشد، احتمال اینکه از خط سوم آمده باشد چقدر است؟

حل. با قانون بیز: $\mathbb{P}(L_3\,|\,D)=\frac{0.05\times 0.2}{0.021}=\frac{0.010}{0.021}\approx 0.476$. به طور مشابه $\mathbb{P}(L_1\,|\,D)=\frac{0.005}{0.021}\approx 0.238$ و $\mathbb{P}(L_2\,|\,D)=\frac{0.006}{0.021}\approx 0.286$ (جمع سه احتمال پسین برابر ۱ است). خط سوم با اینکه فقط ۲۰٪ تولید را دارد، تقریباً نیمی از محصولات معیوب را تولید می‌کند. ■

تمرین ۴-۱۸: آزمایش تکراری

در مثال آزمایش پزشکی، اگر فردی دو بار (به صورت مستقل به شرط وضعیت بیماری) آزمایش دهد و هر دو بار مثبت شود، احتمال بیماری او چقدر است؟

حل. می‌توان احتمال پسین مرحله اول (0.167) را به عنوان پیشین مرحله دوم به کار برد:

$$\mathbb{P}(D\,|\,++)=\frac{0.99\times 0.1667}{0.99\times 0.1667+0.05\times 0.8333}=\frac{0.165}{0.165+0.0417}\approx 0.798.$$

همین جواب مستقیماً نیز به دست می‌آید: $\frac{0.99^2\times 0.01}{0.99^2\times 0.01+0.05^2\times 0.99}\approx 0.798$. (این‌جا از استقلال شرطی دو آزمایش به شرط وضعیت بیماری استفاده کردیم.) ■

جلسه ۵

مثالی از استقلال شرطی و گراف‌های تصادفی

۱.۵ مثال از استقلال شرطی (حل مسئله دو سکه)

صورت مسئله را در جلسه قبل (مثال ۵.۴) دیدیم: دو سکه با احتمال شیر ۲۵٪ و ۸۰٪، یکی به تصادف انتخاب می‌شود، ۵ پرتاب در گزارش A و ۵ پرتاب بعدی در گزارش B ثبت می‌شود. اگر $A = HHTHT$ باشد، احتمال $B = TTHTT$ چقدر است؟

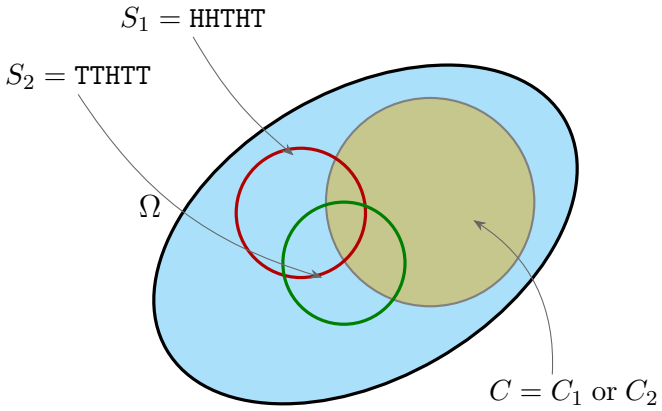
نمادگذاری (notation)

به رشته ۵تایی نخست S_1 و به رشته دوم S_2 می‌گوییم. سکه نخست را با C_1 (۲۵٪ احتمال شیر و ۷۵٪ احتمال خط) و دیگری (۸۰٪ احتمال شیر و ۲۰٪ احتمال خط) را با C_2 نشان می‌دهیم. رویداد سکه انتخابی را $C \in \{C_1, C_2\}$ می‌نامیم.

هدف: می‌خواهیم $\mathbb{P}(S_2 \mid S_1)$ را به ازای $S_1 = \texttt{HHTHT}$ و $S_2 = \texttt{TTHTT}$ بیابیم.

دقت کنید که S_1 و S_2 در حالت کلی مستقل نیستند. اما به شرط دانستن سکه انتخابی C، داریم

$$S_1 \perp S_2 \mid C.$$



۱.۱.۵ یک راه‌حل (اشتباه!)

به راه‌حل زیر دقت کنید:

$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &\stackrel{?}{=} \mathbb{P}(S_2 \mid S_1, C_1)\mathbb{P}(C_1) + \mathbb{P}(S_2 \mid S_1, C_2)\mathbb{P}(C_2) \\ &= \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_1)\mathbb{P}(C_1) + \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_2)\mathbb{P}(C_2) \\ &= (0.75)^4 \times (0.25)^1 \times \tfrac{1}{2} + (0.20)^4 \times (0.80)^1 \times \tfrac{1}{2} \approx 0.0402.\end{aligned}$$

در سطر دوم از استقلال شرطی استفاده شده است: به شرط دانستن C، دیگر اطلاع از S_1 بی‌اهمیت است. آیا به نظر شما درست است؟ این راه‌حل نشان می‌دهد که S_1 اصلاً مهم نیست! (عدد 0.0402 دقیقاً برابر احتمال غیرشرطی $\mathbb{P}(S_2)$ است.)

> **دقت کنید! این راه‌حل اشتباه است!** اشکال در سطر اول است: قانون احتمال کل به صورت $\sum_i \mathbb{P}(E \mid A_i)\mathbb{P}(A_i)$ برای احتمال غیرشرطی $\mathbb{P}(E)$ است. وقتی خود احتمال مورد نظر شرطی است ($\mathbb{P}(\cdot \mid S_1)$)، وزن‌ها نیز باید شرطی باشند. به بیان دیگر، دانستن S_1 احتمال انتخاب هر سکه را تغییر می‌دهد و نمی‌توان از $\mathbb{P}(C_i) = \frac{1}{2}$ استفاده کرد.

۲.۱.۵ راه‌حل صحیح

دقت کنید که وقتی احتمالی را مشروط می‌کنیم، از آنجا به بعد **همه چیز** مشروط شده است. به عبارتی Ω مؤثر ما دیگر کوچک شده و باید همواره آن را رعایت کرد. (یادآوری: $\mathbb{P}(\cdot \mid S_1)$ خود یک اندازه احتمال است و قانون احتمال کل را باید برای همین اندازه نوشت.) لذا نحوه صحیح نوشتن **قانون احتمال کل** این‌گونه می‌شود:

$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &= \mathbb{P}(S_2 \mid S_1, C_1)\mathbb{P}(C_1 \mid S_1) + \mathbb{P}(S_2 \mid S_1, C_2)\mathbb{P}(C_2 \mid S_1) \\ &= \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_1)\,\mathbb{P}(C_1 \mid S_1 = \texttt{HHTHT}) \\ &\quad + \mathbb{P}(S_2 = \texttt{TTHTT} \mid C_2)\,\mathbb{P}(C_2 \mid S_1 = \texttt{HHTHT}).\end{aligned}$$

در سطر دوم (به‌درستی) از استقلال شرطی $S_1 \perp S_2 \mid C$ استفاده کرده‌ایم. حال می‌ماند احتمال‌های شرطی $\mathbb{P}(C_1 \mid S_1)$ و $\mathbb{P}(C_2 \mid S_1)$ را حساب کنیم.

گام ۱ ــ درست‌نمایی‌ها: رشته HHTHT سه شیر و دو خط دارد و پرتاب‌ها به شرط سکه مستقل‌اند:

$$\mathbb{P}(S_1 = \texttt{HHTHT} \mid C_1) = (0.25)^3 \times (0.75)^2 \approx 0.00879,$$

$$\mathbb{P}(S_1 = \texttt{HHTHT} \mid C_2) = (0.80)^3 \times (0.20)^2 = 0.02048.$$

گام ۲ ــ قانون احتمال کل برای مخرج:

$$\mathbb{P}(S_1 = \texttt{HHTHT}) = (0.25)^3(0.75)^2 \times \tfrac{1}{2} + (0.80)^3(0.20)^2 \times \tfrac{1}{2} \approx 0.01463.$$

گام ۳ ــ قانون بیز:

$$\mathbb{P}(C \mid S_1) = \frac{\mathbb{P}(S_1 \mid C)\mathbb{P}(C)}{\mathbb{P}(S_1)} \implies \mathbb{P}(C_1 \mid S_1) \approx \frac{0.00439}{0.01463} \approx 0.300, \quad \mathbb{P}(C_2 \mid S_1) \approx 0.700.$$

یعنی دیدن سه شیر در پنج پرتاب، احتمال اینکه سکه دوم (که بیشتر شیر می‌آورد) انتخاب شده باشد را از ۵۰٪ به ۷۰٪ رسانده است.

گام ۴ ــ جواب نهایی: با ترکیب نتایج پیشین خواهیم داشت:

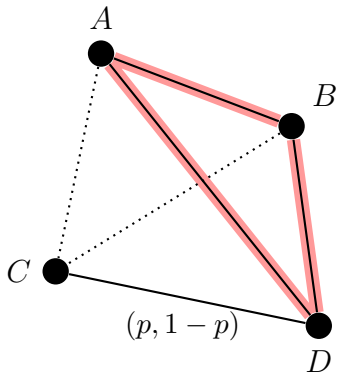
$$\begin{aligned}\mathbb{P}(S_2 \mid S_1) &= (0.75)^4 \times (0.25)^1 \times \left(\frac{(0.25)^3(0.75)^2 \cdot \frac{1}{2}}{(0.25)^3(0.75)^2 \cdot \frac{1}{2} + (0.80)^3(0.20)^2 \cdot \frac{1}{2}} \right) \\ &\quad + (0.20)^4 \times (0.80)^1 \times \left(\frac{(0.80)^3(0.20)^2 \cdot \frac{1}{2}}{(0.25)^3(0.75)^2 \cdot \frac{1}{2} + (0.80)^3(0.20)^2 \cdot \frac{1}{2}} \right) \\ &\approx 0.0791 \times 0.300 + 0.00128 \times 0.700 \approx 0.0246.\end{aligned}$$

نکته. مقایسه کنید: احتمال غیرشرطی $\mathbb{P}(S_2 = \texttt{TTHTT}) \approx 0.0402$ است، اما پس از دیدن $S_1 = \texttt{HHTHT}$ به حدود 0.0246 کاهش یافت. دلیلش این است که S_1 (با شیرهای زیاد) شواهدی به نفع سکه C_2 است و سکه C_2 به‌ندرت رشته پرخطی مثل TTHTT تولید می‌کند. پس S_1 و S_2 **مستقل نیستند**، هرچند به شرط C مستقل‌اند. اطلاعات از S_1 از طریق «کانال» C به S_2 جریان می‌یابد.

۲.۵ یک مثال از گراف‌های تصادفی: تشکیل مثلث

مثال ۵-۱: مسئله تشکیل مثلث در گراف تصادفی

یک گراف تصادفی با ۴ رأس (Node) به نام‌های A, B, C, D را در نظر بگیرید. هر یک از ۶ یال (Edge) بالقوه این گراف، **مستقل** از یکدیگر، می‌توانند با احتمال p وجود داشته باشند، و با احتمال $1-p$ ایجاد نشوند. در اینجا p عددی دلخواه بین ۰ و ۱ است. احتمال اینکه در این گراف، حداقل یک مثلث ایجاد شود چقدر است؟



حل

$$\mathbb{P}(\text{۱ least At}\Delta) = \mathbb{P}(ABC \cup ABD \cup ACD \cup BCD).$$

- کلاً $\binom{4}{3} = 4$ مثلث می‌توانند رخ دهند: ABC، ABD، ACD و BCD.

- احتمال تشکیل هر یک از آن‌ها (به خاطر استقلال سه یال آن) برابر با $p \times p \times p = p^3$ است. یعنی داریم

$$\mathbb{P}(ABC) = \mathbb{P}(ABD) = \mathbb{P}(ACD) = \mathbb{P}(BCD) = p^3.$$

پرسش: آیا می‌توان گفت $\mathbb{P}(\text{۱ least At}\Delta) = 4p^3$ ؟

پاسخ. **خیر، نمی‌توان گفت!** زیرا رخ دادن یک مثلث (مانند ABC) مانع رخ دادن یکی دیگر (مانند BCD) نمی‌شود. به عبارتی، این رخدادها ناسازگار (disjoint) نیستند. پس احتمال اجتماع آنان برابر با جمعشان نیست. (البته طبق کران اجتماع، $4p^3$ یک **کران بالا** است.)

پس باید از **اصل شمول و عدم شمول** استفاده کنیم:

۱. **اشتراک‌های دوتایی:** باید احتمالاتی مانند $\mathbb{P}(ABC \cap ABD)$ که دو بار شمرده شده‌اند کم شوند. تعداد این اشتراکات $\binom{4}{2} = 6$ است. از طرفی، هر دو مثلث متمایز در K_4 دقیقاً در یک یال مشترک‌اند (مثلاً ABC و ABD در یال AB)؛ پس هر اشتراک شامل رخ دادن دقیقاً ۵ یال مستقل است و احتمال هر یک برابر با p^5 است. تا بدین‌جا داریم: $4p^3 - 6p^5$.

۲. **اشتراک‌های سه‌تایی:** سپس باید اشتراک‌های ۳تایی که زیادی کم شده‌اند، دوباره اضافه شوند. تعداد این اشتراکات $\binom{4}{3} = 4$ است، و در صورت بروز هر یک، تمام ۶ یال گراف می‌بایست رخ داده باشند (مثلاً ABC، ABD و ACD با هم همه ۶ یال را می‌پوشانند). پس احتمال هر یک p^6 است.

۳. **اشتراک چهارتایی:** در نهایت، می‌بایست اشتراک ۴تایی (که یک حالت بیشتر ندارد) و دوباره مشتمل بر رخ دادن تمام یال‌های گراف است کم شود: $-p^6$.

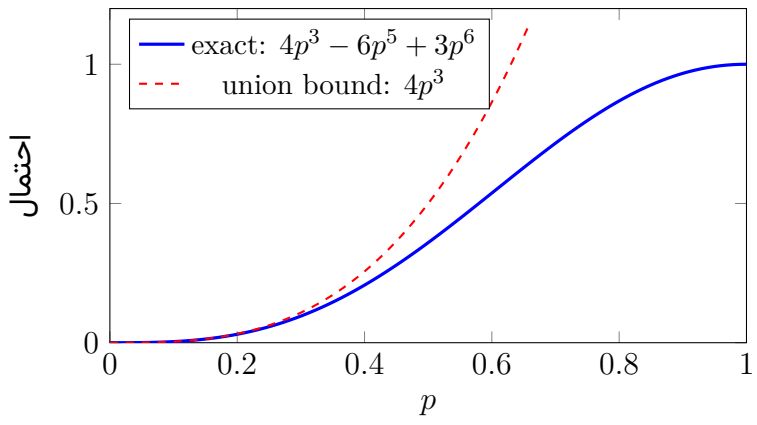
پس در نهایت خواهیم داشت:

$$4p^3 - 6p^5 + 4p^6 - p^6,$$

یعنی

$$\boxed{\mathbb{P}(\text{۱ least At}\Delta) = 4p^3 - 6p^5 + 3p^6}$$

نکته. **بررسی درستی:** به ازای $p = 1$ گراف کامل است و جواب باید ۱ باشد: $4 - 6 + 3 = 1$ ✓. به ازای pهای کوچک، جمله غالب $4p^3$ است؛ یعنی کران اجتماع در این حالت تقریب خوبی است (چون احتمال رخ دادن هم‌زمان دو مثلث، $O(p^5)$، بسیار کوچک‌تر است). این درستی را می‌توان با شمارش مستقیم همه $2^6 = 64$ حالت گراف نیز تأیید کرد.



۳.۵ گراف‌های Erdős–Rényi و مسئله تشکیل Clique

تعریف ۵-۲: گراف تصادفی Erdős–Rényi

یک گراف تصادفی با n رأس $V_1, \dots, V_n$ در نظر بگیرید. هر یک از $\frac{n(n-1)}{2}$ یال بالقوه، مستقل از یکدیگر، با احتمال ثابت p برقرار خواهند شد. به چنین گرافی، یک گراف تصادفی Erdős–Rényi اطلاق می‌گردد و آن را با $G(n,p)$ نشان می‌دهیم.

تعریف ۵-۳: r-clique

به یک زیرگراف کامل (شامل تمام یال‌های دوبه‌دو) به سایز r رأس (برای یک $2 \le r \le n$)، یک r-clique یا «خوشه rتایی» می‌گوییم. مثلث همان 3-clique است.

هدف: یافتن کرانی برای احتمال تشکیل حداقل یک r-clique در گراف، به ازای مقادیر ثابتی از n, p, r.

۱.۳.۵ کران بالا با کران اجتماع

- احتمال تشکیل هر r-clique مشخص (روی r رأس معین) برابر است با

$$\mathbb{P}(\text{ one} r\text{-clique}) = p^{\frac{r(r-1)}{2}},$$

زیرا هر r رأس، $\binom{r}{2} = \frac{r(r-1)}{2}$ یال دارند و همه باید (مستقلاً) برقرار باشند.

- از طرفی، می‌دانیم که تعداد $\binom{n}{r}$ کلیک (مکان بالقوه) از سایز r موجود هستند.
- طبق کران اجتماع (Union Bound)، می‌توان یک کران بالا برای احتمال تشکیل حداقل یک r-clique پیدا کرد:

$$\boxed{\mathbb{P}(\text{ one least At} r\text{-clique}) \le \binom{n}{r} p^{\frac{r(r-1)}{2}}}$$

نکته. محاسبه دقیق این احتمال با اصل شمول و عدم شمول (مانند حالت مثلث) بسیار پیچیده است، زیرا کلیک‌ها به شکل‌های مختلفی با هم هم‌پوشانی دارند. کران اجتماع با وجود سادگی، در بسیاری از کاربردها کافی است.

۲.۳.۵ ساده‌سازی کران

قضیه ۵-۴: کران ضریب دوجمله‌ای

برای $1 \le r \le n$: $\binom{n}{r} \le \left(\frac{ne}{r}\right)^r$.

اثبات. $\binom{n}{r} = \frac{n(n-1)\cdots(n-r+1)}{r!} \le \frac{n^r}{r!}$. از طرفی از بسط تیلور $e^r = \sum_{k\ge 0} \frac{r^k}{k!} \ge \frac{r^r}{r!}$، پس $r! \ge (r/e)^r$. با ترکیب این دو، $\binom{n}{r} \le n^r (e/r)^r$. □

برای ساده‌سازی بیشتر، با نوشتن $p = e^{-\log(1/p)}$ داریم:

$$\mathbb{P}(\text{clique}) \le \binom{n}{r} p^{\frac{r(r-1)}{2}} \le \left(\frac{ne}{r}\right)^r e^{-\frac{r(r-1)}{2}\log\left(\frac{1}{p}\right)} = \exp\left(r\left[\log\frac{ne}{r} - \frac{r-1}{2}\log\frac{1}{p}\right]\right).$$

با کمی عملیات جبری، می‌توان دید که در صورتی که داشته باشیم (فرمول ارائه‌شده در اسلاید)

$$r \ge \frac{2\log(ne)}{\log(1/p)} + \frac{3}{\log(ne)},$$

آنگاه احتمال تشکیل حداقل یک r-clique (در رژیم معمول n بزرگ) از مقدار 0.01 کمتر است. نکته اصلی این است که **بزرگ‌ترین کلیک یک گراف تصادفی، تنها از مرتبه $\frac{2\log n}{\log(1/p)}$ است.**

قضیه ۵-۵: یک شرط کافی دقیق

اگر $r \ge 4$ و $r \ge 1 + \frac{2\log(ne)}{\log(1/p)}$، آنگاه $\mathbb{P}(\text{ one least At} r\text{-clique}) \le r^{-r} \le \frac{1}{256} < 0.01$.

اثبات. از شرط دوم، $\log\frac{ne}{r} - \log(ne) = -\log r$؛ پس عبارت داخل کروشه حداکثر $\frac{r-1}{2}\log\frac{1}{p} \ge \log(ne)$ است و کران برابر $e^{-r\log r} = r^{-r}$ می‌شود. برای $r \ge 4$ داریم $r^{-r} \le 4^{-4} = \frac{1}{256}$. □

مثال ۵-۶: مثال عددی

برای $n = 1000$ و $p = \frac{1}{2}$، شرط بالا $r \ge 1 + \frac{2\log(1000e)}{\log 2} \approx 23.8$ می‌دهد. پس با احتمال بیش از ۹۹٪ هیچ کلیکی با ۲۴ رأس یا بیشتر در این گراف وجود ندارد؛ در حالی که گراف تقریباً $\frac{1}{2}\binom{1000}{2} \approx 250{,}000$ یال دارد! (محاسبه مستقیم کران $\binom{1000}{r}2^{-r(r-1)/2}$ نشان می‌دهد که حتی برای $r = 20$ این احتمال کمتر از 10^{-15} است.)

۳.۳.۵ یک تخمین عددی ساده: شبکه‌های اجتماعی

- در شبکه اجتماعی Facebook یا Instagram از قدر مرتبه $n = O(10^9)$ نفر عضو هستند.
- تعداد متوسط «دوست»های هر عضو، از قدر مرتبه $np \approx O(10^3)$ است. (در گراف Erdős–Rényi هر رأس به طور متوسط با $(n-1)p \approx np$ رأس دیگر همسایه است.) لذا داریم $p \approx O(10^{-6})$.
- با جایگذاری در رابطه قبلی، می‌توان دید که در این صورت احتمال تشکیل کلیک‌هایی با $r \ge O(1)$ بسیار پایین است. به‌طور دقیق‌تر: $\frac{2\log(ne)}{\log(1/p)} \approx \frac{2\times 21.7}{13.8} \approx 3.1$؛ پس طبق قضیه بالا احتمال وجود حتی یک کلیک ۵تایی کمتر از 5^{-5} است. در واقع کران اجتماع برای $r = 5$ مقدار $\binom{10^9}{5}10^{-60} \approx 8 \times 10^{-18}$ را می‌دهد!

پرسش: آیا این عدد برای شما معقول است؟ به نظر شما ایراد کار از کجاست؟

پاسخ. خیر، معقول نیست! در شبکه‌های اجتماعی واقعی، کلیک‌های بزرگ بسیار فراوان‌اند: اعضای یک خانواده، هم‌کلاسی‌ها، هم‌تیمی‌ها یا همکاران یک شرکت اغلب همگی با هم دوست‌اند و کلیک‌هایی با ده‌ها عضو می‌سازند.

ایراد در **مدل** است، نه در محاسبه. مدل Erdős–Rényi دو فرض غیرواقعی دارد:

۱. **استقلال یال‌ها:** در دنیای واقعی، اگر X با Y و Y با Z دوست باشد، احتمال دوستی X و Z بسیار بیشتر از حالت عادی است (پدیده «بستار سه‌گانه» یا triadic closure). یعنی رخداد یال‌ها به شدت **وابسته** است.

۲. **همگنی:** احتمال p برای همه جفت‌ها یکسان فرض شده، در حالی که افراد هم‌شهری، هم‌سن یا هم‌دانشگاهی با احتمال بسیار بیشتری دوست می‌شوند (ساختار اجتماعی یا community structure).

این مثال درس مهمی دارد: نتایج احتمالاتی فقط به اندازه فرض‌های مدل معتبرند. «فرض استقلال» یک فرض ساده‌کننده بسیار قوی است و باید با احتیاط به کار رود.

۴.۵ تمرین‌های تکمیلی

تمرین ۵-۷

در مسئله دو سکه، $\mathbb{P}(C_2 \mid S_1)$ را برای $S_1 = \text{HHHHH}$ حساب کنید. سپس احتمال اینکه پرتاب بعدی شیر باشد (به شرط S_1) را بیابید.

حل. درست‌نمایی‌ها: $\mathbb{P}(S_1 \mid C_1) = 0.25^5 \approx 0.000977$ و $\mathbb{P}(S_1 \mid C_2) = 0.8^5 \approx 0.32768$. با قانون بیز (پیشین‌های برابر):

$$\mathbb{P}(C_2 \mid S_1) = \frac{0.32768}{0.32768 + 0.000977} \approx 0.997.$$

با قانون احتمال کل شرطی و استقلال شرطی: $\mathbb{P}(H \mid S_1) = 0.25 \times 0.003 + 0.8 \times 0.997 \approx 0.798$. ■

تمرین ۵-۸

در گراف تصادفی با ۴ رأس، احتمال اینکه گراف **هیچ** مثلثی نداشته باشد را برای $p = \frac{1}{2}$ حساب کنید و با شمارش مستقیم تأیید کنید.

حل. از فرمول: $1 - (4p^3 - 6p^5 + 3p^6)$ و با $p = \frac{1}{2}$: $4/8 - 6/32 + 3/64 = \frac{32-12+3}{64} = \frac{23}{64}$؛ پس احتمال نبود مثلث $\frac{41}{64}$ است. شمارش مستقیم: با $p = \frac{1}{2}$ همه 64 گراف هم‌احتمال‌اند. گراف‌های دارای مثلث: با ۳ یال فقط ۴ گراف (خود مثلث‌ها)؛ با ۴ یال، هر مثلث به‌همراه یکی از ۳ یال دیگر: $4 \times 3 = 12$؛ با ۵ یال: هر ۶ گراف (حذف یک یال از K_4 فقط دو مثلث را خراب می‌کند)؛ با ۶ یال: ۱. جمع: $4 + 12 + 6 + 1 = 23$ ✓. ■

تمرین ۵-۹

در گراف $G(n,p)$، با استفاده از کران اجتماع نشان دهید احتمال وجود دست‌کم یک رأس **منزوی** (بدون هیچ یال) حداکثر $n(1-p)^{n-1}$ است. برای $n = 100$ و $p = 0.1$ این کران را حساب کنید.

حل. رأس i منزوی است اگر هیچ‌یک از $n-1$ یال آن برقرار نباشد؛ با استقلال احتمال آن $(1-p)^{n-1}$ است. با کران اجتماع روی n رأس: $\mathbb{P}(\exists \text{isolated}) \le n(1-p)^{n-1}$. برای $n = 100, p = 0.1$: $100 \times 0.9^{99} \approx 100 \times 2.95 \times 10^{-5} \approx 0.003$. ■

جلسه ۶

متغیر تصادفی و متغیرهای تصادفی گسسته معروف

۱.۶ متغیر تصادفی (Random Variable) ـ مقدمه

پیش‌تر دیدیم که مدل‌سازی تصادفی یک واقعه، معادل با تعریف یک فضای احتمال به صورت زیر است:

$$(\Omega,\ \mathcal{F},\ P).$$

بیایید هر سه جزء را یک بار دیگر، این بار با نگاه «مهندسی»، مرور کنیم:

- **فضای نمونه Ω:** مجموعه‌ای شامل تمامی **پیشامدهای** (outcome) ممکن است. هر عضو این فضا مشخص‌کننده یک وضعیت خاص از سیستم مدل‌سازی شده است:

$$\omega = \left(\omega^{(1)}, \omega^{(2)}, \dots\right) \in \Omega.$$

  این فضا می‌تواند ابعاد بسیار بالایی داشته باشد، که به معنی زیاد بودن پارامترهای آزاد در مدل‌سازی است. Ω حتی می‌تواند **فضایی بی‌نهایت‌بعدی** باشد.

- **فضای رویدادها $\mathcal{F}$:** مجموعه‌ای شامل تمام یا برخی زیرمجموعه‌های Ω است. وقوع هر پیشامد در Ω، می‌تواند باعث رخ دادن هیچ، یک یا تعدادی (گاهاً بی‌نهایت) رویداد شود. لازم است تا $\mathcal{F}$ یک σ-Field بر روی Ω باشد.

- **قانون یا اندازه احتمال P:** تابعی از فضای رویدادها به بازه بسته اعداد حقیقی بین صفر تا یک است، یعنی

$$P : \mathcal{F} \to [0, 1],$$

  و لازم است تا P قوانین کولموگروف (Kolmogorov) را رعایت کند.

۱.۱.۶ یک مثال: مدل‌سازی آب‌وهوا

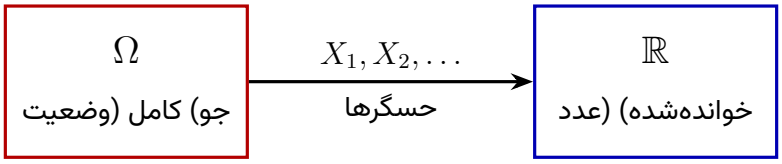
فرض کنید قصد داریم وضعیت آب‌وهوای یک ناحیه از کره زمین را به صورت تصادفی مدل‌سازی کنیم:

- فضای نمونه در این حالت، بسیار پیچیده خواهد بود. لازم است تا محل و تکانه تمامی ذرات و مولکول‌های معلق در هوا را به عنوان پارامتر آزاد (بخشی از ابعاد هر نمونه $\omega \in \Omega$) در نظر بگیریم...
- همچنین، تمامی پارامترهایی که می‌توانند مستقلاً و یا در کنار یکدیگر بر مفهومی که ما از آب‌وهوا در ذهن داریم تأثیرگذار باشند.
- رویدادهایی مانند «بارانی» (Rainy)، «آفتابی» (Sunny) و «طوفانی» (Windy) اعضای $\mathcal{F}$ هستند؛ هر کدام مجموعه بسیار بزرگی از وضعیت‌های میکروسکوپی ω است.

در عمل، **امکان سنجش فضای Ω اصلی وجود ندارد.** لذا، از اندازه‌گیری محدود و در دسترس استفاده خواهد شد:

- **دماسنج:** نگاشت فضای Ω به یک ناحیه از فضای $\mathbb{R}$ از طریق یک حسگر (sensor) دمایی.
- **رطوبت‌سنج:** اندازه‌گیری نادقیق تجمع مولکول‌های آب از طریق حسگر رطوبتی.
- و ...

هر یک از این حسگرها یک تابع $X_1, X_2, \dots$ از Ω به اعداد است.



۲.۱.۶ اندازه‌گیری در فضای نمونه

دستیابی به تمامی مقادیر لازم برای تشکیل فضای Ω و مشاهده یک پیشامد دلخواه $\omega \in \Omega$، بعضاً بسیار سخت و یا حتی غیرممکن است. لذا، به جای مشاهده (یا معادلاً اندازه‌گیری) خود ω، تابعی از آن را مانند $X(\omega)$ اندازه می‌گیریم.

تعریف ۶-۱: متغیر تصادفی

یک **متغیر تصادفی** تابعی از فضای نمونه به یک مجموعه عددی است:

$$X : \Omega \to R.$$

در اینجا، برد تابع X (یعنی R) یک **مجموعه عددی** دلخواه است. R می‌تواند مجموعه اعداد حقیقی $\mathbb{R}$، اعداد طبیعی $\mathbb{N}$ یا مجموعه محدود $\{0, 1\}$ باشد.

نکته. نام «متغیر تصادفی» کمی گمراه‌کننده است: X در واقع یک **تابع** (کاملاً معین) است و تصادف از انتخاب ω می‌آید. احتمال رویدادهایی مانند $\{X \leq 3\}$ به صورت $P(\{\omega \in \Omega : \ X(\omega) \leq 3\})$ تعریف می‌شود؛ یعنی هر سؤال درباره X در نهایت یک سؤال درباره یک رویداد در $\mathcal{F}$ است. (از نظر ریاضی لازم است این مجموعه‌ها عضو $\mathcal{F}$ باشند؛ به این شرط «اندازه‌پذیری» می‌گویند.)

مثال ۶-۲: تعداد شیرها در دو پرتاب

دو سکه سالم پرتاب می‌شوند: $\Omega = \{HH, HT, TH, TT\}$. متغیر تصادفی X = «تعداد شیرها» را تعریف کنید. آنگاه $X(HH) = 2$، $X(HT) = X(TH) = 1$ و $X(TT) = 0$. پس

$$P(X = 0) = \tfrac{1}{4}, \qquad P(X = 1) = P(\{HT, TH\}) = \tfrac{1}{2}, \qquad P(X = 2) = \tfrac{1}{4}.$$

این مثال نشان می‌دهد که X اطلاعات را «فشرده» می‌کند: دو پیشامد متفاوت HT و TH به یک مقدار نگاشته می‌شوند.

۳.۱.۶ متغیر تصادفی به مثابه یک «جعبه سیاه»

برای فهم بهتر، می‌توانید یک متغیر تصادفی مانند X را به مثابه یک **جعبه سیاه** در نظر بگیرید که نمی‌دانید در داخل آن چه خبر است...

- هر بار که دکمه روی جعبه سیاه را فشار می‌دهید، یک آزمایش تصادفی درون آن انجام می‌گیرد (یک مقدار $\omega \in \Omega$ به صورت تصادفی مقدار می‌گیرد)، و یک مقدار تصادفی به X می‌دهد.
- به این مقدار یک **نمونه** از X گفته می‌شود. در حالت کلی، هر بار که این کار را می‌کنید مقادیر مختلفی به دست خواهید آورد (مثلاً $1.2,\ 3.45,\ -2.1,\ 5,\ -0.4, \ldots$). در واقع X یک مقدار مشخص ندارد، و در هر آزمایش یک مقدار خاص خواهد گرفت.
- اما «**توزیع**» یا distribution مقادیر آن مشخص است: اگر تعداد زیادی نمونه بگیریم و هیستوگرام آن‌ها را رسم کنیم، شکل هیستوگرام به یک شکل ثابت (توزیع X) میل می‌کند.

۲.۶ متغیرهای تصادفی گسسته (Discrete Random Variables)

متغیرهای تصادفی می‌توانند پیوسته و یا گسسته باشند. **متغیرهای تصادفی گسسته** می‌توانند مقادیری از یک مجموعه محدود و یا حداکثر شمارا را داشته باشند.

تعریف ۶-۳: تابع جرم احتمال (PMF)

برای متغیر تصادفی گسسته X با مقادیر ممکن $x_1, x_2, \ldots$، تابع جرم احتمال عبارت است از

$$P_X(x) = P(X = x),$$

که در دو شرط صدق می‌کند: $P_X(x) \geq 0$ و $\sum_i P_X(x_i) = 1$.

در صورتی که یک متغیر تصادفی گسسته باشد، **به طور کامل توسط PMF تعیین خواهد شد**؛ زیرا برای هر مجموعه A داریم

$$P(X \in A) = \sum_{x \in A} P_X(x).$$

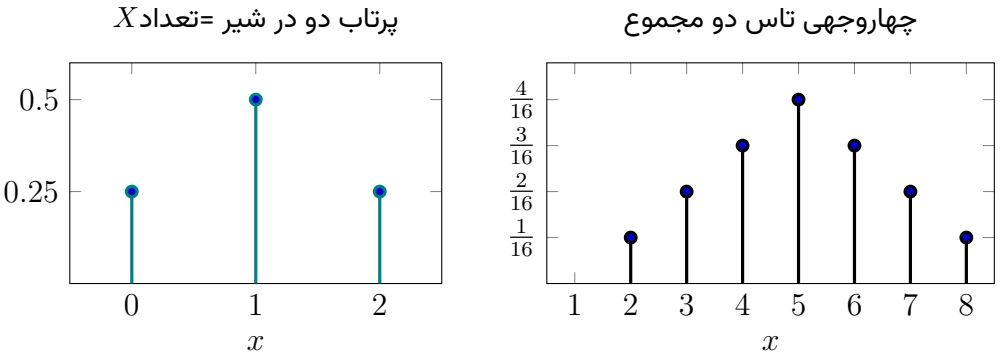
مثال ۶-۴: مجموع دو تاس چهاروجهی

دو تاس چهاروجهی سالم (با وجوه ۱ تا ۴) را پرتاب می‌کنیم و X را مجموع آن‌ها می‌گیریم. PMF آن را بیابید.

حل. ۱۶ حالت هم‌احتمال داریم. تعداد حالت‌هایی که مجموع برابر x می‌شود برای $x = 2, \dots, 8$ به ترتیب $1, 2, 3, 4, 3, 2, 1$ است (مثلاً برای $x = 5$: $(1,4), (2,3), (3,2), (4,1)$). پس:

x	2	3	4	5	6	7	8
$P_X(x)$	$\frac{1}{16}$	$\frac{2}{16}$	$\frac{3}{16}$	$\frac{4}{16}$	$\frac{3}{16}$	$\frac{2}{16}$	$\frac{1}{16}$

که جمع آن‌ها $\frac{16}{16} = 1$ است. ■



۳.۶ متغیرهای تصادفی گسسته معروف

۱.۳.۶ توزیع برنولی (Bernoulli)

ساده‌ترین متغیر تصادفی، نتیجه یک آزمون با دو خروجی «موفقیت» (۱) و «شکست» (۰) است. اگر احتمال موفقیت p باشد، $X \sim \text{Bernoulli}(p)$:

$$P_X(1) = p, \qquad P_X(0) = 1 - p.$$

۲.۳.۶ توزیع دوجمله‌ای (Binomial Distribution)

توزیع دوجمله‌ای مربوط به **تعداد موفقیت‌های** تکرار nباره (مستقل) یک آزمون برنولی است.

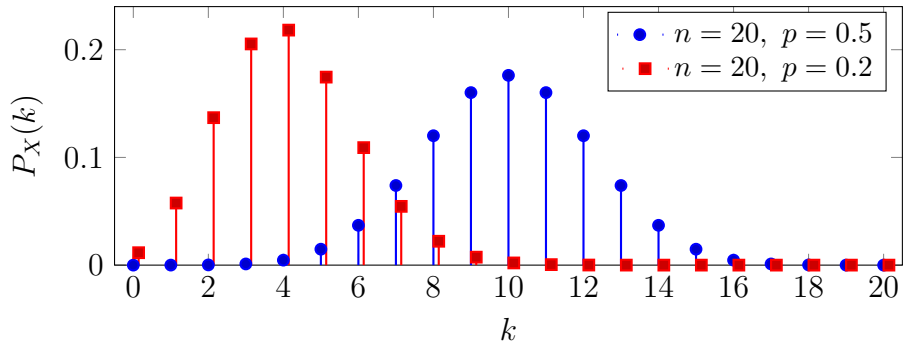
قضیه ۶-۵: PMF توزیع دوجمله‌ای

برای $X \sim \text{Binomial}(n, p)$ و $X = 0, 1, 2, \dots, n$:

$$\boxed{P_X(k) = \binom{n}{k} p^k (1-p)^{n-k}}$$

اثبات. هر رشته مشخص از n نتیجه که دقیقاً k موفقیت دارد، به دلیل استقلال احتمال $p^k(1-p)^{n-k}$ دارد (ضرب احتمال‌ها). تعداد چنین رشته‌هایی $\binom{n}{k}$ است (انتخاب جای موفقیت‌ها) و این رشته‌ها ناسازگارند؛ پس با جمع کردن، حکم به دست می‌آید. جمع کل احتمال‌ها طبق قضیه دوجمله‌ای $(p+(1-p))^n = 1$ است ــ و نام «دوجمله‌ای» از همین‌جاست. □

نکته. آزمایش سکه سالم در جلسه سوم حالت خاص $p = \frac{1}{2}$ است: $\binom{n}{k}2^{-n}$.



مثال ۶-۶: آزمون چندگزینه‌ای

یک آزمون ۱۰ سؤال چهارگزینه‌ای دارد و دانشجویی همه سؤال‌ها را تصادفی جواب می‌دهد. احتمال اینکه دقیقاً ۵ سؤال را درست جواب دهد، و احتمال اینکه دست‌کم ۶ سؤال را درست جواب دهد چقدر است؟

حل. تعداد پاسخ‌های درست $X \sim \text{Binomial}(10, \frac{1}{4})$ است. پس

$$P(X=5) = \binom{10}{5}\left(\frac{1}{4}\right)^5\left(\frac{3}{4}\right)^5 = 252 \times \frac{243}{4^{10}} \approx 0.0584,$$

$$P(X \geq 6) = \sum_{k=6}^{10}\binom{10}{k}\left(\frac{1}{4}\right)^k\left(\frac{3}{4}\right)^{10-k} \approx 0.0197.$$

یعنی شانس قبولی (با حد نصاب ۶) با حدس تصادفی کمتر از ۲٪ است. ■

۳.۳.۶ توزیع چندجمله‌ای (Multinomial Distribution)

توزیع چندجمله‌ای، تعمیم توزیع دوجمله‌ای برای تکرار nباره آزمون‌هایی است که **بیش از دو خروجی** ممکن داشته باشند. فرض کنید آزمونی با m خروجی ممکن، هر یک با احتمال‌های $p_1, p_2, \ldots, p_m$ (با جمع ۱)، را n بار به صورت مستقل انجام می‌دهیم. هدف، به دست آوردن احتمال وقوع k_i بار از پیشامد iام است ($n = k_1 + \cdots + k_m$).

قضیه ۶-۷: PMF توزیع چندجمله‌ای

برای $(k_1, \ldots, k_m) \sim \text{Multinomial}(n, p_1, \ldots, p_m)$:

$$P_X(k_1, \ldots, k_m) = \binom{n}{k_1, \ldots, k_m}\prod_{i=1}^{m} p_i^{k_i}, \qquad \binom{n}{k_1, \ldots, k_m} = \frac{n!}{k_1!\,k_2!\cdots k_m!}.$$

اثبات. هر رشته مشخص با k_1 بار خروجی ۱، ... و k_m بار خروجی m احتمال $\prod p_i^{k_i}$ دارد. تعداد این رشته‌ها برابر تعداد جایگشت‌های n شیء است که k_1 تای آن‌ها یکسان (از نوع ۱)، k_2 تا یکسان و ... باشند؛ یعنی ضریب چندجمله‌ای $\frac{n!}{k_1!\cdots k_m!}$. (برای $m=2$ همان توزیع دوجمله‌ای به دست می‌آید.) □

مثال ۶-۸: تاس و توزیع چندجمله‌ای

(الف) تاس سالمی را ۶ بار می‌اندازیم. احتمال اینکه هر عدد دقیقاً یک بار ظاهر شود چقدر است؟ (ب) در یک انتخابات، ۵۰٪ به نامزد A، ۳۰٪ به B و ۲۰٪ به C رأی می‌دهند. اگر ۱۰ نفر را تصادفی انتخاب کنیم، احتمال اینکه ۵ نفر به A، ۳ نفر به B و ۲ نفر به C رأی داده باشند چقدر است؟

حل. (الف) $n=6$، $m=6$، همه $k_i=1$ و $p_i=\frac{1}{6}$: $\frac{6!}{1!\cdots 1!}\left(\frac{1}{6}\right)^6 = \frac{720}{46656} \approx 0.0154$.

(ب) $\frac{10!}{5!\,3!\,2!}(0.5)^5(0.3)^3(0.2)^2 = 2520 \times 0.03125 \times 0.027 \times 0.04 \approx 0.0851$. ■

۴.۳.۶ توزیع پواسون (Poisson Distribution)

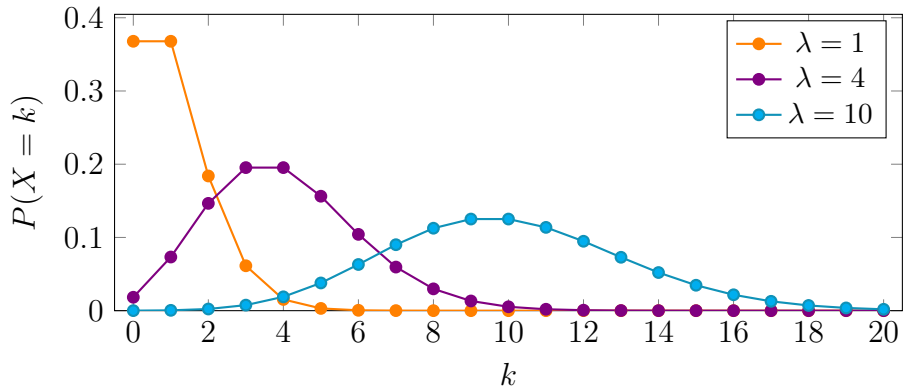
متغیر تصادفی پواسون کاربرد فراوانی در مدل‌سازی **تعداد پیشامدهای** یک ماهیت تصادفی بی‌حافظه در طول زمان دارد (مثلاً تعداد تماس‌های ورودی به یک مرکز تلفن در یک ساعت، تعداد بسته‌های رسیده به یک روتر در یک ثانیه، تعداد ذرات تابیده‌شده از یک ماده رادیواکتیو). این توزیع بر روی اعداد حسابی $k=0,1,2,\ldots$ تعریف شده و تنها دارای یک پارامتر آزاد $\lambda \in \mathbb{R}_{\geq 0}$ (نرخ) است.

تعریف ۶-۹: توزیع پواسون

برای $X \sim \text{Pois}(\lambda)$:

$$P_X(k) = e^{-\lambda}\frac{\lambda^k}{k!}, \qquad k=0,1,\ldots$$

بررسی نرمال بودن: با بسط تیلور $e^{\lambda} = \sum_{k\geq 0}\frac{\lambda^k}{k!}$ داریم $\sum_k P_X(k) = e^{-\lambda}e^{\lambda} = 1$.



۵.۳.۶ خواص توزیع پواسون: حد توزیع دوجمله‌ای

توزیع پواسون نتیجه یکی از حالت‌های توزیع دوجمله‌ای (Binomial) است.

قضیه ۶-۱۰: تقریب پواسون

در توزیع دوجمله‌ای $\text{Binomial}(n,p)$، فرض کنید $n \to \infty$ و $p \to 0$ به طوری که حاصل‌ضرب آن‌ها عددی ثابت بماند، یعنی $np = \lambda$. آنگاه برای هر k ثابت ($k \ll n$):

$$\binom{n}{k} p^k (1-p)^{n-k} \longrightarrow \frac{\lambda^k}{k!} e^{-\lambda}.$$

اثبات.

$$\binom{n}{k} p^k (1-p)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!}\, p^k (1-p)^{n-k}.$$

سه عامل را جداگانه بررسی می‌کنیم:

- $\dfrac{n(n-1)\cdots(n-k+1)}{n^k} = 1 \cdot \left(1-\frac{1}{n}\right)\cdots\left(1-\frac{k-1}{n}\right) \to 1$؛ پس صورت تقریباً n^k است و $n^k p^k = (np)^k = \lambda^k$.
- $(1-p)^{-k} \to 1$ چون $p \to 0$ و k ثابت است؛ پس $(1-p)^{n-k} \simeq (1-p)^n$.
- $(1-p)^n = \left(1-\frac{\lambda}{n}\right)^n \to e^{-\lambda}$ (حد معروف).

پس

$$\simeq \frac{n^k p^k}{k!}(1-p)^n \simeq \frac{(np)^k}{k!} e^{-np},$$

که در حد، دقیقاً برابر با این مقدار خواهد شد. □

نکته. تعبیر: پواسون مدل «تعداد زیادی فرصت مستقل، هر یک با احتمال بسیار کم» است: مثلاً یک ساعت را به n بازه بسیار کوچک تقسیم کنید که در هر کدام با احتمال $p = \lambda/n$ یک تماس رخ می‌دهد. وقتی $n \to \infty$، تعداد تماس‌ها پواسون با میانگین λ می‌شود. به همین دلیل پواسون برای رخدادهای «نادر» و «بی‌حافظه» در زمان به کار می‌رود.

مثال ۶-۱۱: دقت تقریب پواسون

در یک خط تولید هر قطعه با احتمال 0.002 معیوب است. در یک محموله ۱۰۰۰تایی، احتمال اینکه دقیقاً ۳ قطعه معیوب باشد را به صورت دقیق و با تقریب پواسون حساب کنید.

حل. مقدار دقیق (دوجمله‌ای): $\binom{1000}{3}(0.002)^3(0.998)^{997} \approx 0.1806$. تقریب پواسون با $\lambda = np = 2$: $e^{-2}\frac{2^3}{3!} \approx 0.1804$. جدول زیر نشان می‌دهد تقریب برای همه kها بسیار دقیق است:

k	0	1	2	3	4	5
دوجمله‌ای	0.1351	0.2707	0.2709	0.1806	0.0902	0.0360
پواسون	0.1353	0.2707	0.2707	0.1804	0.0902	0.0361

■

۶.۳.۶ توزیع هندسی (Geometric) ــ تکمیلی

اگر آزمون‌های برنولی مستقل با احتمال موفقیت p را تا رسیدن به **اولین** موفقیت تکرار کنیم، تعداد آزمون‌ها X توزیع هندسی دارد:

$$P_X(k) = (1-p)^{k-1}p, \qquad k = 1, 2, \dots$$

زیرا باید $k-1$ شکست متوالی و سپس یک موفقیت رخ دهد. جمع احتمال‌ها یک سری هندسی است: $p\sum_{k\geq 1}(1-p)^{k-1} = p\cdot\frac{1}{p} = 1$. این توزیع همتای گسسته توزیع نمایی (جلسه بعد) و تنها توزیع گسسته **بی‌حافظه** است.

۴.۶ تمرین‌های تکمیلی

تمرین ۶-۱۲

ثابت c را چنان بیابید که $P_X(k) = c\,(1/3)^k$ برای $k = 0, 1, 2, \dots$ یک PMF باشد. سپس $P(X \geq 2)$ را حساب کنید.

حل. $\sum_{k\geq 0}(1/3)^k = \frac{1}{1-1/3} = \frac{3}{2}$؛ پس $c = \frac{2}{3}$. آنگاه $P(X \geq 2) = 1 - P(0) - P(1) = 1 - \frac{2}{3} - \frac{2}{9} = \frac{1}{9}$.
■

تمرین ۶-۱۳

به یک سرور به طور متوسط ۳ درخواست در دقیقه می‌رسد (مدل پواسون). احتمال اینکه در یک دقیقه مشخص هیچ درخواستی نرسد، و احتمال اینکه بیش از ۲ درخواست برسد چقدر است؟

حل. $X \sim \text{Pois}(3)$. $P(X = 0) = e^{-3} \approx 0.0498$. $P(X > 2) = 1 - e^{-3}\big(1 + 3 + \frac{9}{2}\big) = 1 - 8.5e^{-3} \approx 1 - 0.4232 = 0.5768$.
■

تمرین ۶-۱۴

یک بسته داده از طریق کانالی ارسال می‌شود که هر بیت را مستقلاً با احتمال 10^{-3} خراب می‌کند. بسته ۲۰۰۰ بیتی است و کد تصحیح خطا تا ۲ بیت خطا را تصحیح می‌کند. احتمال دریافت صحیح بسته را تقریب بزنید.

حل. تعداد بیت‌های خراب $X \sim \text{Binomial}(2000, 10^{-3}) \approx \text{Pois}(2)$. احتمال موفقیت: $P(X \leq 2) \approx e^{-2}(1 + 2 + 2) = 5e^{-2} \approx 0.677$.
■

تمرین ۶-۱۵

تاسی را آن‌قدر می‌اندازیم تا ۶ بیاید. احتمال اینکه بیش از ۱۰ پرتاب لازم باشد چقدر است؟

حل. تعداد پرتاب‌ها هندسی با $p = \frac{1}{6}$ است. «بیش از ۱۰ پرتاب لازم باشد» یعنی ۱۰ پرتاب اول همگی شکست باشند: $P(X > 10) = (5/6)^{10} \approx 0.1615$.
■

جلسه ۷

متغیرهای تصادفی پیوسته، CDF و PDF

۱.۷ متغیرهای تصادفی پیوسته (Continuous R.V.s)

پیش‌تر دیدیم که مدل‌سازی تصادفی یک واقعه، معادل با تعریف یک فضای احتمال به صورت $(\Omega, \mathcal{F}, P)$ است. این تعاریف، در مورد خود یک متغیر تصادفی نیز برقرار هستند: می‌توانیم به جای فضای پیچیده اولیه، مجموعه مقادیر خود متغیر تصادفی را به عنوان فضای نمونه در نظر بگیریم. برای مثال، در مورد یک متغیر تصادفی گسسته، Ω فضای شمارای مقادیری است که متغیر می‌تواند بگیرد:

- برای متغیر تصادفی برنولی داریم $\Omega = \{0, 1\}$،
- در مورد یک توزیع دوجمله‌ای داریم $\Omega = \{0, 1, \dots, n\}$،
- و برای متغیر تصادفی با توزیع پواسون خواهیم داشت $\Omega = \mathbb{N}_{\geq 0}$.

در تمام موارد بالا، برای فضای وقایع (یعنی $\mathcal{F}$)، قرار می‌دهیم $\mathcal{F} = 2^{\Omega}$.

۱.۱.۷ مشکل فضای ناشمارا

در مورد متغیرهای تصادفی پیوسته (Continuous R.V.s) معمولاً داریم $\Omega = \mathbb{R}$. در این حالات معمولاً (البته نه همیشه!) احتمال بروز تک‌مقدارها صفر هستند. برای مثال، اگر X یک متغیر تصادفی کاملاً پیوسته باشد، خواهیم داشت:

$$\mathbb{P}(X = 1.2) = \mathbb{P}(X = -\sqrt{2}) = \cdots = 0.$$

پرسش: اما احتمال بازه‌ها چطور؟ آیا می‌توان مطابق رابطه زیر نتیجه گرفت؟ چرا این رابطه اشتباه است؟

$$\mathbb{P}(X \in A) = \sum_{x \in A} \mathbb{P}(X = x), \qquad \forall A \in \mathcal{F}.$$

پاسخ. این رابطه اشتباه است زیرا اصل جمع‌پذیری کولموگروف فقط برای اجتماع‌های **شمارا** برقرار است، در حالی که یک بازه مانند $[0, 1]$ اجتماع **ناشمارایی** از نقاط است. اگر این رابطه درست بود، چون همه $\mathbb{P}(X = x) = 0$ هستند، نتیجه می‌گرفتیم $\mathbb{P}(X \in \mathbb{R}) = \sum_{x \in \mathbb{R}} 0 = 0$، که با $\mathbb{P}(\Omega) = 1$ در

تناقض است. پس احتمال یک بازه را نمی‌توان از احتمال نقاط آن به دست آورد؛ بلکه باید مستقیماً برای مجموعه‌ها (بازه‌ها) احتمال تعریف کنیم.

همان‌طور که ملاحظه کردید، در مورد متغیرهای تصادفی پیوسته می‌بایست به صورت مجزا برای زیرمجموعه‌های $\mathbb{R}$ احتمال تعریف کنیم (نمی‌توانیم مستقیماً از اصول کولموگروف استفاده کرده و احتمالشان را به صورت جمع احتمال اعضای آنان بنویسیم؛ به دلیل **ناشمارا** (uncountable) بودن).

اما این سؤال مطرح می‌شود که برای کدام زیرمجموعه‌های $\mathbb{R}$ می‌توانیم احتمال تعریف کنیم... بهتر است سراغ تمام زیرمجموعه‌های موجود در $2^{\mathbb{R}}$ نرویم! (برای مطالعه بیشتر به سراغ عواقب ناخواسته **اصل انتخاب** (Axiom of Choice) در مجموعه‌ها، و همچنین Banach–Tarski paradox بروید.)

نکته. چرا همه زیرمجموعه‌ها نه؟ با پذیرش اصل انتخاب می‌توان زیرمجموعه‌هایی «بسیار عجیب» از $\mathbb{R}$ ساخت (مانند مجموعه ویتالی) که به هیچ وجه نمی‌توان به آن‌ها «طول» یا «احتمال» سازگار با اصول کولموگروف نسبت داد. پارادوکس باناخ–تارسکی حتی نشان می‌دهد که یک کره را می‌توان به چند تکه (غیراندازه‌پذیر) تقسیم کرد و با جابه‌جایی و چرخش آن‌ها دو کره هم‌اندازه کره اول ساخت! پس باید خود را به زیرمجموعه‌های «خوش‌رفتار» محدود کنیم.

۲.۱.۷ مجموعه‌ها و میدان سیگمای بورل (Borel Sets and Borel σ-Field)

به جای تمامی زیرمجموعه‌های $\mathbb{R}$، فقط سراغ زیرمجموعه‌های معقول و زیبای آن می‌رویم! و صرفاً برای آنان احتمال تعریف می‌کنیم.

تعریف ۷-۱: مجموعه بورل

زیرمجموعه‌های معقول و زیبا (nice) روی $\mathbb{R}$ را به صورت زیر تعریف می‌کنیم:

$$\bigcup_{i=1}^{\infty} I_i \subseteq \mathbb{R}, \qquad \text{where} I_i \text{intervals are s},$$

که در اینجا، هر I_i یک بازه کاملاً دلخواه (مانند $(-\infty, 4.7]$، یا $(3, 4.2)$، یا $[1, 1]$، و غیره) روی $\mathbb{R}$ است. همچنین دنباله $\{I_1, I_2, \dots\}$ می‌تواند محدود، یا نامحدود (ولی شمارا) باشد. به هر زیرمجموعه‌ای از $\mathbb{R}$ که بتواند به شکل بالا (یا متمم آن، و به‌طور کلی با تکرار شمارای این اعمال) نوشته شود یک Borel set می‌گوییم.

قضیه ۷-۲

مجموعه تمام Borel setهای روی $\mathbb{R}$ تشکیل یک σ-Field می‌دهند. به آن **میدان سیگمای بورل** گفته و با $\mathcal{B}(\mathbb{R})$ نشان می‌دهیم. (به طور دقیق، $\mathcal{B}(\mathbb{R})$ کوچک‌ترین میدان سیگمایی است که شامل همه بازه‌هاست.)

تقریباً هر مجموعه‌ای که در عمل با آن سر و کار داریم بورل است: بازه‌ها، نقاط تکی، مجموعه‌های شمارا (مثل اعداد گویا)، اجتماع و اشتراک شمارای بازه‌ها و ...

در این صورت، می‌توانیم با خیال راحت فضای وقایع قابل اندازه‌گیری (یعنی $\mathcal{F}$) را به صورت یک Borel

σ-Field روی $\mathbb{R}$ در نظر بگیریم.

۳.۱.۷ کافی بودن احتمال بازه‌ها

در این صورت، برای تعریف احتمال برای تمامی اعضای $\mathcal{F}$ (یعنی یک واقعه یا Event)، کافی است احتمال را برای هر بازه (مثلاً $(a, b]$) به ازای تمامی مقادیر $a, b \in \mathbb{R}$ با شرط $b \geq a$ تعریف کرده باشیم. سپس با استفاده از قوانین کولموگروف احتمال تمامی وقایع به صورت خودکار تعریف می‌شود.

پرسش: چرا؟

پاسخ. هر مجموعه بورل از بازه‌ها با تعداد شمارایی عمل اجتماع، اشتراک و متمم ساخته می‌شود. اصول کولموگروف دقیقاً به ما می‌گویند احتمال تحت این اعمال چگونه رفتار می‌کند:

- احتمال اجتماع شمارای بازه‌های ناسازگار = جمع احتمال بازه‌ها (جمع‌پذیری شمارا)؛ هر اجتماع شمارا از بازه‌ها را هم می‌توان به اجتماع شمارای بازه‌های ناسازگار تبدیل کرد.
- احتمال متمم = یک منهای احتمال.
- احتمال یک نقطه هم از بازه‌ها به دست می‌آید: $\{a\} = \bigcap_n (a - \frac{1}{n}, a]$ و با پیوستگی احتمال $\mathbb{P}(X = a) = \lim_n \mathbb{P}(a - \frac{1}{n} < X \leq a)$.

بنابراین احتمال هر مجموعه بورل به‌طور یکتا از احتمال بازه‌ها تعیین می‌شود. (اثبات کامل این گزاره ــ «قضیه گسترش کاراتئودوری» ــ در درس نظریه اندازه دیده می‌شود.)

پس به یک تابع مانند $P(a, b)$ نیاز داریم که به ازای a, b ورودی احتمال بازه $(a, b]$ را بازگرداند. اما می‌توان به راحتی این تابع را به یک متغیر ورودی کاهش داد. **چگونه؟** چون $(-\infty, b] = (-\infty, a] \cup (a, b]$ و این دو ناسازگارند:

$$P\big((a, b]\big) = P\big((-\infty, b]\big) - P\big((-\infty, a]\big).$$

پس کافی است تابع یک‌متغیره $x \mapsto P((-\infty, x])$ را بدانیم. این همان تابع توزیع انباشته است.

۲.۷ تابع توزیع انباشته (Cumulative Distribution Function)

تعریف ۷-۳: تابع توزیع انباشته (CDF)

تابع توزیع انباشته (CDF) متغیر تصادفی X را به صورت زیر تعریف می‌کنیم:

$$F_X(x) = \mathbb{P}\{X \leq x\}.$$

لذا F_X یک تابع از اعداد (مثلاً اعداد حقیقی) به بازه بسته $[0, 1]$ است.

دقت کنید! اشتباه رایج: دقت کنید که در این رابطه، X بیان‌گر منتسب بودن F_X به یک متغیر تصادفی خاص است. ولی x یک عدد (مثلاً یک عدد حقیقی) و در اینجا صرفاً یک متغیر کمکی (در اصطلاح dummy variable) است. مثلاً $F_X(2) = \mathbb{P}(X \leq 2)$ و $F_Y(2) = \mathbb{P}(Y \leq 2)$ دو عدد متفاوت‌اند.

قضیه ۷-۴: ویژگی‌های CDF

برای هر متغیر تصادفی X:

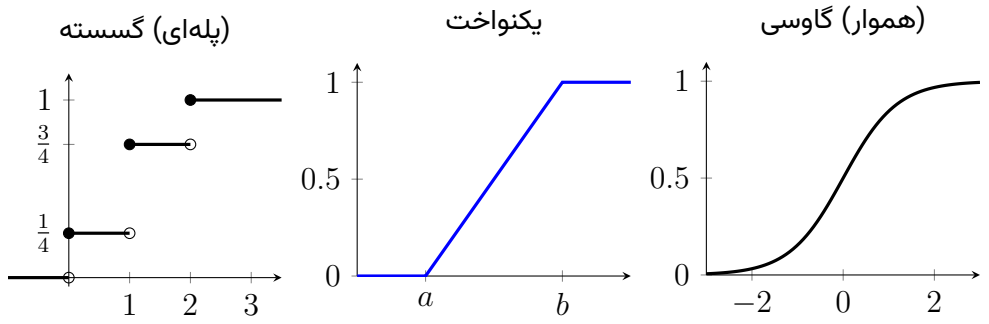
۱. تابع F_X **صعودی** (غیرنزولی) است، ولی لزوماً **اکیداً صعودی** نیست.

۲. مقادیر حدی: $F_X(+\infty) = \lim_{x\to+\infty} F_X(x) = 1.$ $\quad F_X(-\infty) = \lim_{x\to-\infty} F_X(x) = 0,$

۳. F_X از راست پیوسته است: $\lim_{h\to0^+} F_X(x+h) = F_X(x)$.

۴. $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$ و $\mathbb{P}(X = a) = F_X(a) - F_X(a^-)$ (اندازه پرش در نقطه a).

اثبات. (۱) اگر $x < y$ آنگاه $\{X \leq x\} \subseteq \{X \leq y\}$ و طبق یکنوایی احتمال، $F_X(x) \leq F_X(y)$. اما اکیداً صعودی نیست چون اگر X هیچ مقداری در بازه $(x, y]$ نگیرد، $\mathbb{P}(x < X \leq y) = 0$ و F_X روی این بازه ثابت می‌ماند (مانند نواحی افقی در CDF یک متغیر گسسته، یا بیرون بازه $[a, b]$ در توزیع یکنواخت). (۲) وقتی $x \to -\infty$، رویدادهای $\{X \leq x\}$ به $\varnothing$ و وقتی $x \to +\infty$ به Ω میل می‌کنند؛ با پیوستگی احتمال حدود ۰ و ۱ به دست می‌آیند. (۳) و (۴) نیز از پیوستگی احتمال و تعریف به دست می‌آیند. □



شکل ۱.۷: سه نمونه CDF: سمت راست مربوط به تعداد شیرها در دو پرتاب سکه (پرش‌هایی به اندازه $\frac{1}{4}, \frac{1}{2}, \frac{1}{4}$)، وسط توزیع یکنواخت روی $[a, b]$، و چپ یک CDF هموار.

نکته. CDF برای **همه** متغیرهای تصادفی (گسسته، پیوسته یا ترکیبی) تعریف می‌شود و توزیع را به‌طور کامل مشخص می‌کند. برای متغیر گسسته، CDF پله‌ای است و ارتفاع هر پله برابر PMF در آن نقطه است.

۳.۷ تابع چگالی احتمال (Probability Density Function)

۱.۳.۷ مفهوم

کار کردن با تابع توزیع انباشته (CDF) مقداری سخت است:

- شهود بالایی نسبت به آن نداریم.
- اطلاعات محلی (localized) مناسبی از نواحی مختلف فضا به دست نمی‌دهد (مقدار $F_X(x)$ همه جرم احتمال در سمت چپ x را با هم جمع می‌کند).

برای حل این مشکل، از تابع چگالی احتمال (PDF) استفاده خواهد شد:

تعریف ۷-۵: تابع چگالی احتمال

$$f_X(x) = \lim_{h\to 0^+} \frac{P\big(x < X \le x+h\big)}{h} = \frac{\mathrm{d}F_X(x)}{\mathrm{d}x}.$$

عبارت وسط **مفهوم چگالی دارد**: احتمال (جرم) واقع در یک بازه کوچک تقسیم بر طول آن بازه ــ دقیقاً مانند چگالی جرم در فیزیک (جرم بر واحد طول). به بیان دیگر، برای h کوچک:

$$P(x < X \le x+h) \approx f_X(x)\, h.$$

۲.۳.۷ خواص و مقایسه با سایر توابع

تابع چگالی احتمال (PDF):

- $f_X(x)$ همواره نامنفی است ($f_X \ge 0$)؛ زیرا مشتق یک تابع صعودی است.
- $f_X(x)$ **لزوماً بین ۰ و ۱ نیست.** حتی ممکن است گاهی بی‌نهایت شود (دقت کنید که f_X به خودی خود معنای احتمال ندارد). مثال: برای $X \sim \mathrm{Uniform}(0, 0.1)$ داریم $f_X = 10$ روی بازه.
- شرط بهنجارش (Normalization criteria):

$$\int_{-\infty}^{+\infty} f_X(x)\,\mathrm{d}x = F_X(+\infty) - F_X(-\infty) = 1.$$

مقایسه توابع CDF، PDF، PMF و اندازه احتمال P

- **اندازه احتمال** P (Probability Measure or Law): عضو سوم فضای احتمال $(\Omega, \mathcal{F}, P)$، که به هر رویداد در $\mathcal{F}$ عددی در بازه $[0,1]$ نسبت می‌دهد که می‌بایست قوانین کولموگروف را رعایت نماید.
- **تابع توزیع انباشته CDF:** در نقطه $x \in R$ به معنای $P(X \le x)$ خواهد بود. CDF معنای احتمال دارد و بین $[0,1]$ خواهد بود. همچنین تابعی صعودی است که در $-\infty$ برابر با صفر، و در $+\infty$ برابر با یک است.
- **تابع چگالی احتمال PDF:** مشتق تابع CDF، که همواره نامنفی و عددی در $\mathbb{R}_{\ge 0}$ خواهد بود. PDF مفهوم احتمال ندارد، و صرفاً انتگرال آن معنای احتمال می‌دهد:

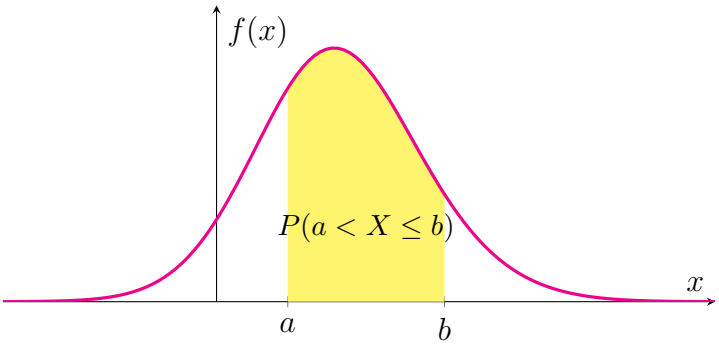
$$\boxed{P\big(a < X \le b\big) = \int_a^b f_X(x)\,\mathrm{d}x = F_X(b) - F_X(a)}$$

- **تابع جرم احتمال PMF:** زمانی که Ω مجموعه‌ای محدود (یا شمارا) باشد، برای $\Omega =$

$\{\omega_1, \ldots, \omega_N\}$ به صورت $p(\omega_i) = P(\{\omega_i\})$ تعریف می‌شود. لذا معنای احتمال دارد و همواره بین ۰ و ۱ است. همچنین، جمع PMF روی کل Ω برابر با ۱ می‌شود.

۳.۳.۷ مفهوم گرافیکی

احتمال اینکه X در بازه $(a, b]$ بیفتد، برابر **مساحت زیر منحنی** PDF بین a و b است:



نکته. برای متغیر پیوسته $P(X = a) = 0$، پس $P(a < X \leq b) = P(a \leq X \leq b) = P(a < X < b)$؛ یعنی باز یا بسته بودن انتهای بازه مهم نیست. این برای متغیرهای گسسته **درست نیست**.

۴.۷ متغیرهای تصادفی پیوسته معروف

۱.۴.۷ توزیع یکنواخت (Uniform Distribution)

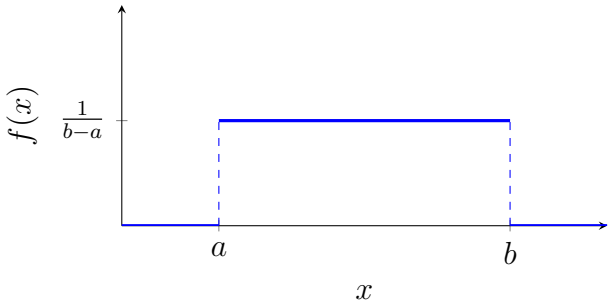
متغیر تصادفی یکنواخت، دارای بیشترین آنتروپی (تصادفی بودن) بین تمامی متغیرهای تصادفی با $\Omega = [a, b]$ است؛ یعنی وقتی فقط می‌دانیم مقدار در $[a, b]$ است و هیچ اطلاع دیگری نداریم، «بی‌طرفانه‌ترین» مدل است. این متغیر تصادفی دارای دو پارامتر آزاد a و b ($b > a$) است.

تعریف ۷-۶: توزیع یکنواخت

برای $X \sim \text{Uniform}(a, b)$:

$$f_X(x) = \begin{cases} \dfrac{1}{b-a} & a \leq x \leq b \\ 0 & \text{o.w.} \end{cases} \qquad F_X(x) = \begin{cases} 0 & x < a \\ \dfrac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$$

احتمال هر زیربازه $[c, d] \subseteq [a, b]$ متناسب با طول آن است: $P(c \leq X \leq d) = \frac{d-c}{b-a}$.



۲.۴.۷ توزیع نمایی (Exponential Distribution)

توزیع نمایی (Exponential) دارای یک پارامتر آزاد به صورت $\lambda \in \mathbb{R}_{>0}$ است.

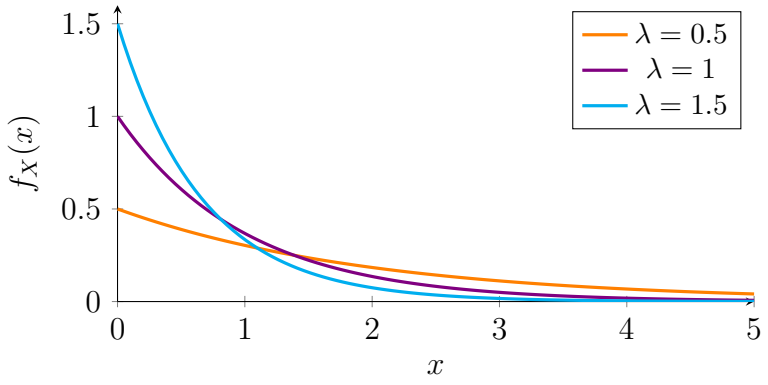
تعریف ۷-۷: توزیع نمایی

برای $X \sim \text{exponential}(\lambda)$:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases} \qquad F_X(x) = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

محاسبه CDF: برای $x \geq 0$، $F_X(x) = \int_0^x \lambda e^{-\lambda t}\,\mathrm{d}t = \big[-e^{-\lambda t}\big]_0^x = 1 - e^{-\lambda x}$.

این توزیع معمولاً برای مدل‌سازی **زمان وقوع** یک رخداد **بی‌حافظه** مورد استفاده قرار می‌گیرد (مثلاً زمان تا خرابی یک قطعه الکترونیکی، یا زمان بین دو تماس متوالی در فرایند پواسون).



قضیه ۷-۸: خاصیت بی‌حافظگی

اگر $X \sim \text{exponential}(\lambda)$، آنگاه برای هر $s, t \geq 0$:

$$P(X > s + t \,|\, X > s) = P(X > t).$$

اثبات. $P(X > x) = 1 - F_X(x) = e^{-\lambda x}$. پس

$$\begin{aligned} P(X > s + t \,|\, X > s) &= \frac{P(X > s + t,\ X > s)}{P(X > s)} = \frac{P(X > s + t)}{P(X > s)} \\ &= \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t). \end{aligned}$$

□

تعبیر: اگر یک لامپ با طول عمر نمایی تا لحظه s سالم مانده باشد، احتمال اینکه t واحد دیگر هم سالم بماند دقیقاً مثل یک لامپ نو است؛ لامپ «پیر نمی‌شود».

۳.۴.۷ توزیع گاوسی یا نرمال (Gaussian or Normal Distribution)

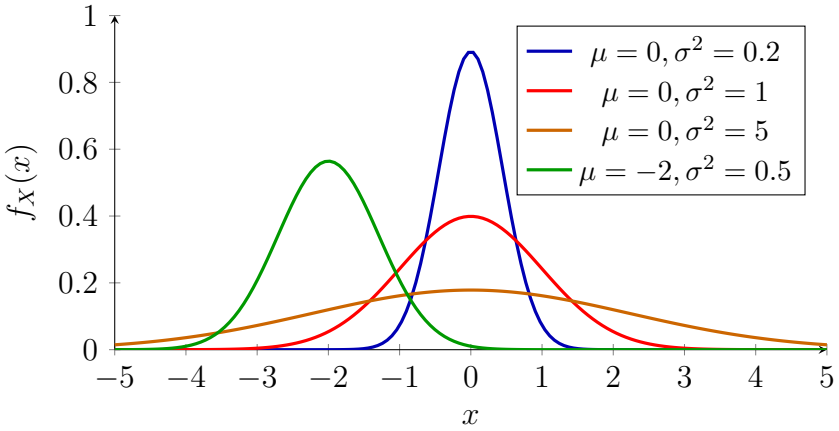
یکی از پرکاربردترین توزیع‌های آماری، توزیع احتمال گاوسی یا نرمال است. توزیع گاوسی $\mathcal{N}(\mu, \sigma^2)$ با دو پارامتر آزاد مشخص می‌شود:

- **میانگین** (mean) $\mu \in \mathbb{R}$، و **واریانس** (variance) $\sigma^2 \in \mathbb{R}_{\geq 0}$.
- به خود مقدار $\sigma \in \mathbb{R}_{\geq 0}$ **انحراف معیار** (standard deviation) اطلاق می‌گردد.

تعریف ۷-۹: توزیع گاوسی

برای $X \sim \mathcal{N}(\mu, \sigma^2)$:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$



خواص توزیع گاوسی

- حول میانگین μ متقارن است. همچنین، بیشینه چگالی احتمال نیز در همین نقطه رخ می‌دهد (مقدار آن $\frac{1}{\sqrt{2\pi}\sigma}$ است).
- دم توزیع (tail) خیلی سریع افت می‌کند (با سرعت e^{-x^2}).
- در طبیعت بسیار ظاهر می‌شود (**قضیه حد مرکزی**): مجموع تعداد زیادی اثر کوچک و مستقل، تقریباً گاوسی است.

تابع توزیع انباشته: انتگرال تابع گاوسی شکل بسته ندارد؛ لذا آن را بر حسب «تابع خطا» بیان می‌کنیم:

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2}\,\mathrm{d}t, \qquad F_X(x) = \frac{1}{2} + \frac{1}{2}\operatorname{erf}\left(\frac{x-\mu}{\sqrt{2}\,\sigma}\right).$$

استخراج. با تغییر متغیر $t := \frac{u-\mu}{\sqrt{2}\sigma}$ با $F_X(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(u-\mu)^2}{2\sigma^2}}\,\mathrm{d}u = \frac{1}{\sqrt{\pi}} \int_{-\infty}^{z} e^{-t^2}\,\mathrm{d}t$ و $z = \frac{x-\mu}{\sqrt{2}\sigma}$. چون $\int_{-\infty}^{0} e^{-t^2}\,\mathrm{d}t = \frac{\sqrt{\pi}}{2}$، داریم $F_X(x) = \frac{1}{2} + \frac{1}{\sqrt{\pi}} \int_{0}^{z} e^{-t^2}\,\mathrm{d}t = \frac{1}{2} + \frac{1}{2}\mathrm{erf}(z)$. □

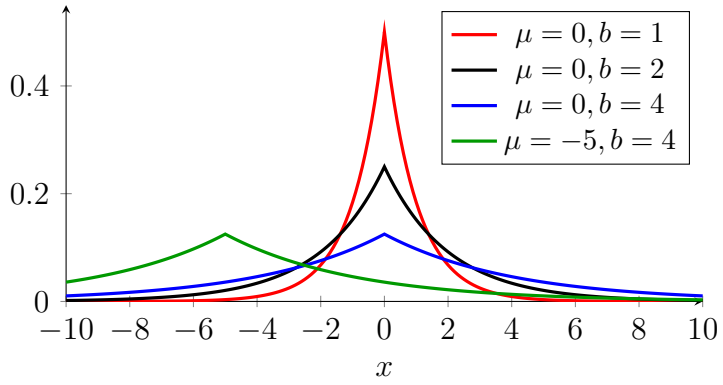
نکته. در آمار معمولاً از CDF گاوسی استاندارد $\Phi(z) = P(Z \le z)$ برای $Z \sim \mathcal{N}(0,1)$ استفاده می‌شود: $F_X(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$. قاعده معروف «۶۸، ۹۵ و ۹۹٫۷ درصد»: $P(|X-\mu| \le \sigma) \approx 0.683$، $P(|X-\mu| \le 2\sigma) \approx 0.954$ و $P(|X-\mu| \le 3\sigma) \approx 0.997$.

۴.۴.۷ توزیع لاپلاس (Laplace Distribution)

توزیع لاپلاس (Laplace) دارای دو پارامتر آزاد به صورت $b \in \mathbb{R}_{>0}$ و میانگین $\mu \in \mathbb{R}$ است. برای $X \sim \mathrm{Laplace}(\mu, b)$:

$$f_X(x) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}.$$

این توزیع از دو توزیع نمایی پشت به پشت تشکیل شده و دم آن (به صورت $e^{-|x|}$) کندتر از گاوسی افت می‌کند؛ پس مقادیر دور از میانگین در آن محتمل‌ترند. (بررسی بهنجارش: $\int \frac{1}{2b} e^{-|x-\mu|/b}\,\mathrm{d}x = 2 \times \frac{1}{2} \int_0^\infty \frac{1}{b} e^{-u/b}\,\mathrm{d}u = 1$.)

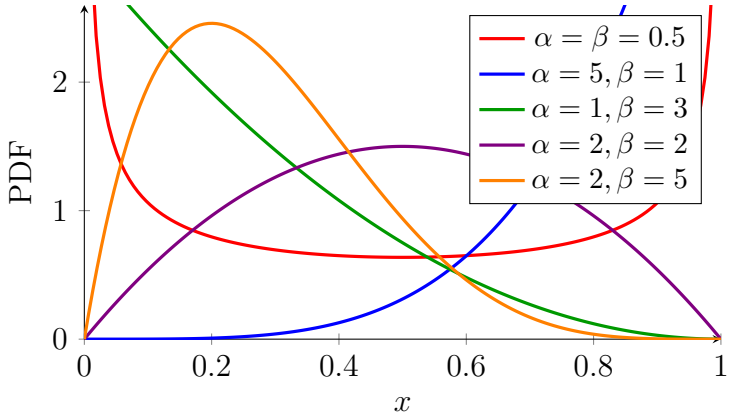


۵.۴.۷ توزیع بتا (Beta Distribution)

متغیر تصادفی بتا بین ۰ و ۱ تعریف شده و معمولاً برای مدل‌سازی احتمالاتی **خود احتمال وقوع یک پدیده** به کار می‌رود (مثلاً احتمال شیر آمدن یک سکه ناشناخته). این متغیر تصادفی دارای دو پارامتر آزاد $\alpha, \beta \in \mathbb{R}_{>0}$ است. به این پارامترها، پارامترهای شکلی (shape parameters) نیز اطلاق می‌گردد. برای $X \sim \mathrm{Beta}(\alpha, \beta)$ در بازه $[0,1]$ یا $(0,1)$ (بسته به پارامترها):

$$f_X(x) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1},$$

که در آن $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t}\,\mathrm{d}t$ تابع گاما است (تعمیم فاکتوریل: $\Gamma(n) = (n-1)!$).



نکته. $\text{Beta}(1,1)$ همان $\text{Uniform}(0,1)$ است. منحنی $\alpha = \beta = 0.5$ مثالی از چگالی است که در دو انتها به بی‌نهایت می‌رود (هرچند مساحت زیر آن ۱ است).

۶.۴.۷ برخی توزیع‌های کمتر کاربردی...

توزیع	پارامترها	تکیه‌گاه	PDF
رایلی (Rayleigh)	$\sigma > 0$	$x \in [0, \infty)$	$\frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)}$
ارلانگ (Erlang)	$k \in \{1, 2, \ldots\},\ \lambda > 0$	$x \in [0, \infty)$	$\frac{\lambda^k x^{k-1} e^{-\lambda x}}{(k-1)!}$
لاگ‌نرمال (Log-normal)	$\mu \in \mathbb{R},\ \sigma > 0$	$x \in (0, \infty)$	$\frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right)$

- **رایلی:** (با CDF برابر $1 - e^{-x^2/(2\sigma^2)}$) اندازه یک بردار دوبعدی با مؤلفه‌های گاوسی مستقل (مثلاً دامنه سیگنال در کانال‌های بی‌سیم با محوشدگی).
- **ارلانگ:** زمان تا رخداد kام در یک فرایند پواسون؛ مجموع k متغیر نمایی مستقل. ($k = 1$ همان نمایی است.)
- **لاگ‌نرمال:** اگر $\ln X$ گاوسی باشد؛ برای کمیت‌هایی که حاصل‌ضرب عوامل تصادفی زیادند (مثل درآمد، اندازه فایل‌ها).

۵.۷ تمرین‌های تکمیلی

تمرین ۷-۱۰

فرض کنید $f_X(x) = cx^2$ برای $0 \le x \le 2$ و صفر در غیر این صورت. (الف) c را بیابید. (ب) $F_X(x)$ را بیابید. (ج) $P(1 < X \le 2)$ را حساب کنید.

حل. (الف) $\int_0^2 cx^2\,\mathrm{d}x = \frac{8c}{3} = 1 \Rightarrow c = \frac{3}{8}$. (ب) برای $0 \le x \le 2$: $F_X(x) = \int_0^x \frac{3}{8}t^2\,\mathrm{d}t = \frac{x^3}{8}$؛ برای $x < 0$ صفر و برای $x > 2$ یک. (ج) $F_X(2) - F_X(1) = 1 - \frac{1}{8} = \frac{7}{8}$. ■

تمرین ۷-۱۱

طول عمر یک هارد دیسک (بر حسب سال) نمایی با $\lambda = 0.2$ است. (الف) احتمال اینکه بیش از ۵ سال کار کند چقدر است؟ (ب) اگر دیسکی ۳ سال کار کرده باشد، احتمال اینکه دست‌کم ۵ سال دیگر کار کند چقدر است؟ (ج) میانه طول عمر (عدد m با $F(m) = \frac{1}{2}$) را بیابید.

حل. (الف) $P(X > 5) = e^{-0.2\times 5} = e^{-1} \approx 0.368$. (ب) با بی‌حافظگی: $P(X > 8 \,|\, X > 3) = P(X > 5) \approx 0.368$. (ج) $1 - e^{-0.2m} = \frac{1}{2} \Rightarrow m = \frac{\ln 2}{0.2} \approx 3.47$ سال. ■

تمرین ۷-۱۲

قد دانشجویان یک دانشگاه تقریباً $\mathcal{N}(170, 10^2)$ (سانتی‌متر) است. چند درصد دانشجویان بین ۱۶۰ و ۱۹۰ سانتی‌متر قد دارند؟ (از $\Phi(1) \approx 0.8413$ و $\Phi(2) \approx 0.9772$ استفاده کنید.)

حل. با استانداردسازی: $P(160 < X \le 190) = \Phi\big(\frac{190-170}{10}\big) - \Phi\big(\frac{160-170}{10}\big) = \Phi(2) - \Phi(-1) = \Phi(2) - (1 - \Phi(1)) \approx 0.9772 - 0.1587 = 0.8185$؛ یعنی حدود ۸۲٪. ■

تمرین ۷-۱۳

متغیر X با احتمال $\frac{1}{2}$ برابر صفر است و با احتمال $\frac{1}{2}$ از $\mathrm{Uniform}(0,1)$ پیروی می‌کند. CDF آن را رسم کنید. آیا X گسسته است یا پیوسته؟

حل. برای $x < 0$: $F = 0$. برای $0 \le x \le 1$: $F(x) = \frac{1}{2} + \frac{1}{2}x$. برای $x > 1$: $F = 1$. CDF در $x = 0$ پرشی به اندازه $\frac{1}{2}$ دارد و سپس به‌طور خطی تا ۱ بالا می‌رود. پس X نه کاملاً گسسته است و نه کاملاً پیوسته؛ یک متغیر **ترکیبی** (mixed) است. این مثال نشان می‌دهد چرا CDF کلی‌ترین ابزار توصیف توزیع است (این متغیر PDF معمولی ندارد). ■

جلسه ۸

تساوی‌های آماری، استقلال متغیرهای تصادفی و متغیرهای مخلوط

۱.۸ مفهوم almost sure در آمار و احتمال

- در مورد یک **متغیر یقینی** (Deterministic) مانند A، راحت می‌توانیم بگوییم $A = 2.7$.
- در مورد یک **متغیر تصادفی** (Random) مانند X، عبارت $X = 2.7$ معنی خیلی مشخصی می‌دهد: یعنی $\forall \omega \in \Omega$ خواهیم داشت $X(\omega) = 2.7$.

معمولاً مورد بالا را نمی‌توان به راحتی در مورد یک متغیر تصادفی فهمید، و سطح بالایی از دسترسی (به تک‌تک نقاط Ω) را می‌طلبد. در عوض، چیزی که معمولاً می‌توانیم بفهمیم این است که

$$\mathbb{P}\Big(\{\omega \in \Omega \mid X(\omega) = 2.7\}\Big) = 1,$$

یعنی متغیر تصادفی X **با احتمال ۱** مقدار 2.7 را به خود می‌گیرد.

تعریف ۸-۱: تساوی تقریباً حتمی

اگر $\mathbb{P}(X = c) = 1$ باشد می‌گوییم X almost surely equals to c یا

$$X \overset{\text{a.s.}}{=} c.$$

به طور کلی، یک گزاره درباره متغیرهای تصادفی «تقریباً حتماً» (a.s.) برقرار است اگر مجموعه ωهایی که در آن‌ها برقرار نیست، احتمال صفر داشته باشد. مثلاً $X \overset{\text{a.s.}}{=} Y$ یعنی $\mathbb{P}(X = Y) = 1$.

- این بدین معنی **نیست** که X **نمی‌تواند** مقداری غیر از 2.7 را به خود بگیرد. بلکه بدین معنی است که **احتمال آن صفر است**.
- یعنی در N آزمایش مستقل برای نمونه‌گیری از X، اگر $n(X \neq 2.7)$ را تعداد دفعاتی تعریف کنیم که X مقداری غیر از 2.7 گرفته، آنگاه خواهیم داشت:

$$\lim_{N \to \infty} \frac{n(X \neq 2.7)}{N} = 0.$$

- دقت کنید تساوی از حیث almost sure **ضعیف‌تر** از تساوی مطلق است: هر تساوی مطلق، تساوی a.s. هم هست، ولی عکس آن لزوماً درست نیست.

مثال ۸-۲: تفاوت تساوی مطلق و a.s.

فرض کنید $U \sim \text{Uniform}(0,1)$ و تعریف کنید $X = 0$ اگر U گویا باشد و $X = 1$ در غیر این صورت. آیا $X = 1$؟

حل. از نظر مطلق خیر: برای ωهایی که $U(\omega)$ گویاست، $X(\omega) = 0$. اما مجموعه اعداد گویای $[0,1]$ شماراست و احتمال هر نقطه برای متغیر پیوسته صفر است؛ پس طبق جمع‌پذیری شمارا $\mathbb{P}(U \in \mathbb{Q}) = \sum_q \mathbb{P}(U = q) = 0$. لذا $\mathbb{P}(X = 1) = 1$ و $X \overset{\text{a.s.}}{=} 1$. در عمل هرگز تفاوتی بین X و ثابت ۱ مشاهده نخواهیم کرد. ■

۲.۸ استقلال متغیرهای تصادفی

پیش‌تر **استقلال آماری** (Independence) میان دو رویداد $A, B \in \mathcal{F}$ را تعریف کرده بودیم: $\mathbb{P}(A,B) = \mathbb{P}(A)\mathbb{P}(B)$.

تعریف ۸-۳: استقلال دو متغیر تصادفی

دو متغیر تصادفی X, Y که روی یک فضای احتمال تعریف شده‌اند را مستقل گوییم، اگر به ازای تمام زیرمجموعه‌های «**خوبی**» (بورل) از اعداد حقیقی مانند $I_1, I_2 \subseteq \mathbb{R}$ داشته باشیم:

$$\forall I_1, I_2 \subseteq \mathbb{R}, \quad \begin{aligned} A &\triangleq \{\omega \,|\, X(\omega) \in I_1\} \\ B &\triangleq \{\omega \,|\, Y(\omega) \in I_2\} \end{aligned}, \quad \text{then} \quad A \perp B.$$

یعنی $\mathbb{P}(X \in I_1,\ Y \in I_2) = \mathbb{P}(X \in I_1)\mathbb{P}(Y \in I_2)$.

به عبارتی، هر رویدادی در ارتباط با فقط متغیر تصادفی X، از هر رویدادی که فقط مرتبط با متغیر تصادفی Y باشد، مستقل باشد.

نکته. در عمل کافی است این شرط را برای نیم‌خط‌ها چک کنیم: X و Y مستقل‌اند اگر و تنها اگر برای همه x, y: $\mathbb{P}(X \le x, Y \le y) = F_X(x)F_Y(y)$. برای متغیرهای گسسته معادل است با $\mathbb{P}(X = x, Y = y) = P_X(x)P_Y(y)$ و برای متغیرهای پیوسته (با چگالی توأم) معادل است با $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ (جلسات بعد).

۳.۸ متغیرهای تصادفی i.i.d.

تعریف ۸-۴: i.i.d.

متغیرهای تصادفی $X_1, X_2, \ldots, X_n$ را در نظر بگیرید. فرض کنید:

- تمامی این متغیرها از یکدیگر **مستقل** باشند؛ یعنی هیچ دو زیرمجموعه ناهم‌پوشان از این متغیرها، ارتباطی با دیگری نداشته باشد.
- توزیع تمام این متغیرها **یکسان** باشد؛ یعنی $X_1, X_2, \ldots, X_n \sim f_X(x)$.

در این صورت به این متغیرها independent and identically distributed یا به اختصار i.i.d. می‌گوییم.

مثال کلاسیک: نتایج n پرتاب مستقل یک تاس، یا n نمونه‌ای که از یک «جعبه سیاه» (جلسه ششم) گرفته می‌شود. فرض i.i.d. پایه بیشتر روش‌های آماری و یادگیری ماشین است (داده‌های آموزش معمولاً i.i.d. فرض می‌شوند).

دقت کنید! دقت کنید که دو متغیر تصادفی می‌توانند اصلاً مستقل نباشند (تقریباً هیچ دو متغیر تصادفی واقعی در جهان مستقل نیستند!). «هم‌توزیع بودن» و «مستقل بودن» دو مفهوم کاملاً جدا هستند:

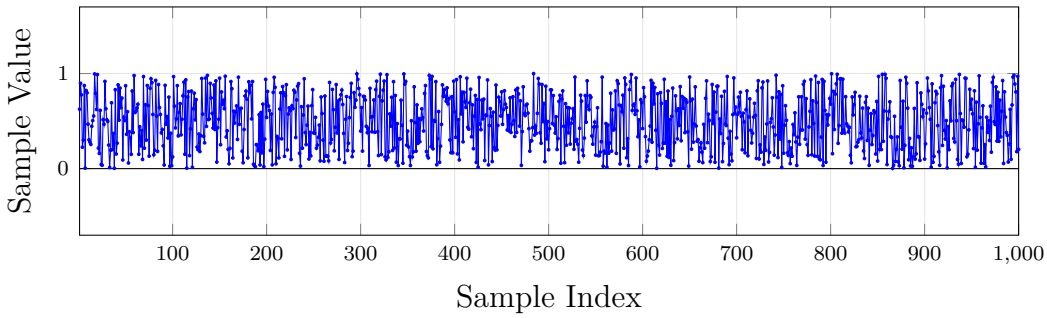
- مثلاً فرض کنید $X \sim \lambda e^{-\lambda x}u(x)$ توزیع نمایی داشته، و متغیر تصادفی $Y \sim \mathcal{N}(0,1)$ توزیع نرمال استاندارد داشته باشد. اما دانستن مقدار X، یا اطلاعاتی در مورد آن، باعث شود توزیع Y تغییر کند. این دو هم‌توزیع نیستند و مستقل هم نیستند.
- از سوی دیگر، این بار فرض کنید $X, Y \sim \mathcal{N}(0,1)$، یعنی **هم‌توزیع** باشند. با این اطلاعات در مورد ارتباط این دو با یکدیگر حرفی نمی‌توان زد. هم می‌توانیم داشته باشیم $X \perp Y$، و هم می‌توانیم داشته باشیم $X \overset{\text{a.s.}}{=} Y$ (یا حتی $Y = -X$ که آن هم $\mathcal{N}(0,1)$ است!).

۴.۸ رفتار دُم توزیع‌های مختلف

(Tail Behavior of Various Distributions)

در این بخش، برای هر توزیع یک نمونه ۱۰۰۰تایی i.i.d. تولید کرده‌ایم و مقادیر نمونه‌ها را بر حسب شماره نمونه رسم کرده‌ایم. سؤال این است: **با نگاه به نمونه‌ها، می‌توان حدس زد از کدام توزیع آمده‌اند؟** ویژگی مهمی که در این نمودارها دیده می‌شود، «**دُم**» (tail) توزیع است؛ یعنی اینکه احتمال مقادیر بسیار بزرگ با چه سرعتی کم می‌شود.

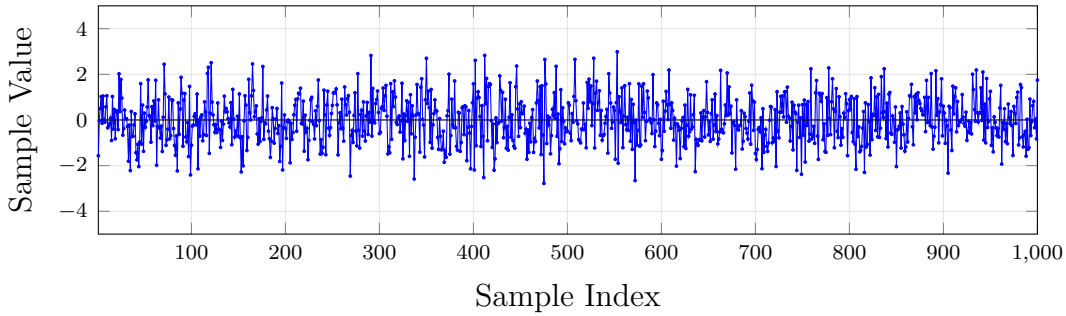
۱.۴.۸ نمونه اول



نمونه‌ها همگی بین ۰ و ۱ هستند و به طور یکنواخت پخش شده‌اند.

جواب: توزیع یکنواخت $X \sim \frac{\mathbb{1}(a \le X \le b)}{b-a}$، در اینجا $\text{Uniform}(0,1)$. دقت کنید تمام نمونه‌ها بین ۰ و ۱ هستند؛ این توزیع اصلاً دُم ندارد (تکیه‌گاه آن کران‌دار است).

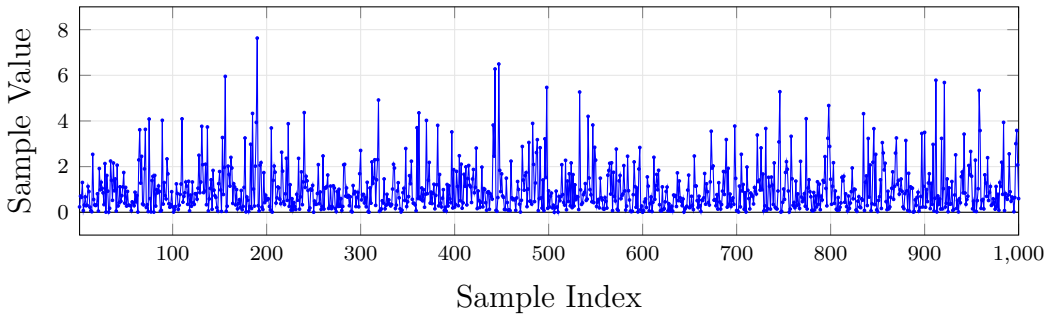
۲.۴.۸ نمونه دوم



نمونه‌ها حول صفر متمرکزند و هر از گاهی مقادیر بزرگ‌تر (تا حدود ± 3) دیده می‌شوند.

جواب: توزیع گاوسی $X \sim \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$، در اینجا $\mathcal{N}(0,1)$: هر از گاهی نمونه‌های بزرگ درست می‌شوند، ولی کماکان متمرکز هستند. طبق قاعده «۶۸، ۹۵ و ۷/۹۹ درصد»، تقریباً همه نمونه‌ها در بازه $[-3,3]$ می‌افتند؛ در ۱۰۰۰ نمونه انتظار داریم فقط حدود ۳ نمونه بیرون از این بازه باشند.

۳.۴.۸ نمونه سوم

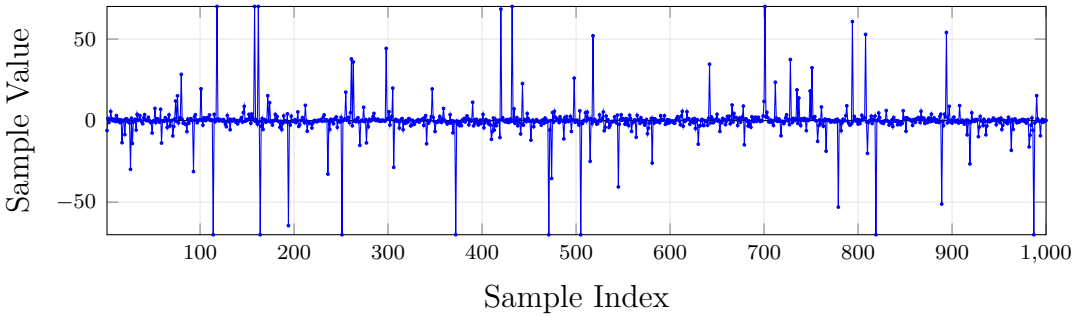


نمونه‌ها همگی نامنفی هستند و گاهی مقادیر بزرگ (تا حدود ۸) ظاهر می‌شوند.

جواب: توزیع نمایی $X \sim \lambda e^{-\lambda x} u(x)$، در اینجا $\text{Exp}(\lambda = 1)$. برخلاف توزیع گاوسی که چگالی دم آن $e^{-O(x^2)}$ است، دم نمایی از قدر مرتبه $e^{-O(x)}$ است و لذا spikeهای بزرگ بیشتر مشاهده می‌شوند. مثلاً

$\mathbb{P}(X > 5) = e^{-5} \approx 0.0067$ (حدود ۷ نمونه از ۱۰۰۰)، در حالی که برای گاوسی استاندارد $\mathbb{P}(Z > 5) \approx .3 \times 10^{-7}$

۴.۴.۸ نمونه چهارم



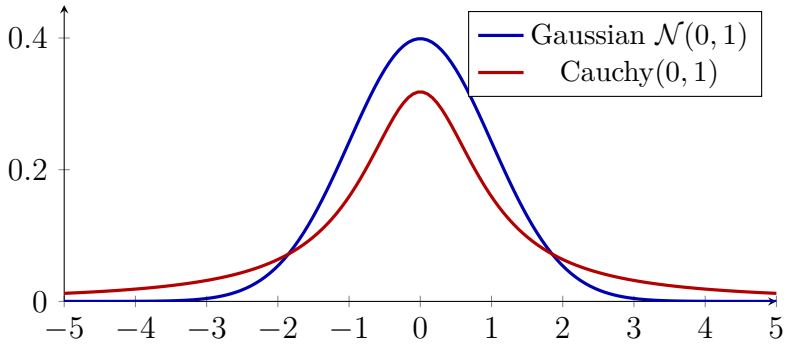
(مقادیر برای نمایش در بازه ± 70 بریده شده‌اند.) و اما مورد آخر... حدس شما چیست؟ چه چیزی در مورد این توزیع عجیب است؟

جواب: توزیع کوشی

$$X \sim \frac{1}{\pi(1+x^2)},$$

در اینجا $\mathrm{Cauchy}(0,1)$. چگالی دم این توزیع $O(1/x^2)$ است، و یکی از قوی‌دم‌ترین (heavy-tail) توزیع‌های دنیا محسوب می‌شود. لطفاً به Spikeهای آن دقت کنید! بیشتر نمونه‌ها نزدیک صفرند اما هر از گاهی مقادیری در حد ده‌ها یا صدها ظاهر می‌شوند.

نکته. چه چیزی عجیب است؟ برای کوشی، $\mathbb{P}(|X| > t) = 1 - \frac{2}{\pi}\arctan t \approx \frac{2}{\pi t}$؛ یعنی احتمال مقادیر بزرگ فقط به صورت $1/t$ کم می‌شود. مثلاً $\mathbb{P}(|X| > 60) \approx 0.0106$، پس در ۱۰۰۰ نمونه حدود ۱۰ نمونه بزرگ‌تر از ۶۰ (از نظر قدر مطلق) خواهیم داشت! نتیجه عجیب‌تر (که در جلسات بعد می‌بینیم): این توزیع **میانگین ندارد** ــ انتگرال $\int |x| \frac{1}{\pi(1+x^2)}\,\mathrm{d}x$ واگراست ــ و میانگین نمونه‌ای $\frac{1}{n}\sum X_i$ هیچ‌گاه همگرا نمی‌شود (در واقع خودش دوباره کوشی استاندارد است!).



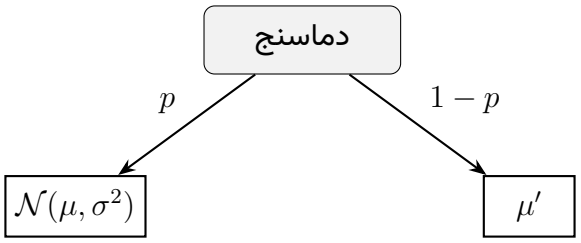
۵.۸ متغیرهای تصادفی مخلوط (گسسته و پیوسته)

مثال ۸-۵: دماسنج نامطمئن

فرض کنید قصد داریم تا دمای یک محیط را با یک دماسنج دیجیتال نامطمئن اندازه‌گیری کنیم:

- در هر بار اندازه‌گیری، دماسنج با احتمال موفقیت p کار کرده و خروجی آن به شکل یک توزیع گاوسی (با انحراف معیار σ) حول دمای واقعی (که با μ نشان داده می‌شود) ظاهر می‌گردد.
- اما دماسنج با احتمال $1-p$ کار نکرده و دمای پیش‌فرض «μ'» را نشان خواهد داد.

سؤال: در صورتی که عدد خروجی دماسنج را با متغیر تصادفی X نشان دهیم، توزیع آن را بیابید.



ابتدا CDF را با قانون احتمال کل می‌نویسیم (W = «دماسنج کار کند»):

$$F_X(x)=\mathbb{P}(X\le x\,|\,W)\mathbb{P}(W)+\mathbb{P}(X\le x\,|\,W^c)\mathbb{P}(W^c)=p\,\Phi\Big(\frac{x-\mu}{\sigma}\Big)+(1-p)\mathbb{1}(x\ge\mu').$$

این CDF در نقطه μ' یک **پرش** به اندازه $1-p$ دارد و در بقیه جاها هموار است. پس X نه گسسته است و نه پیوسته؛ یک متغیر **مخلوط** است. اما مشتق تابع پله در نقطه پرش چیست؟ برای پاسخ، به یک ابزار ریاضی نیاز داریم.

۱.۵.۸ تابع دلتای دیراک

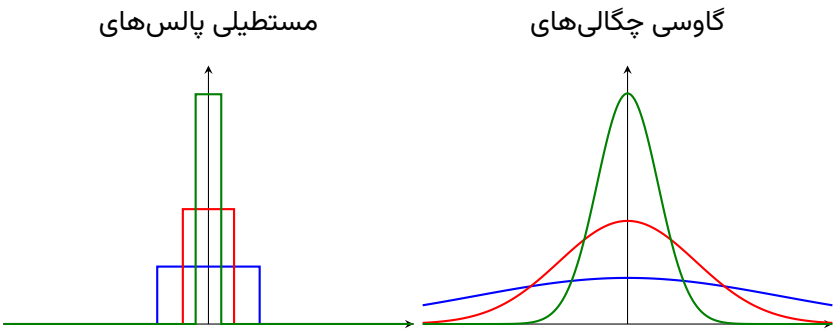
در ریاضیات کاربردی، موارد بسیاری وجود خواهند داشت که در آنان به دنبال **توابعی** می‌گردیم که تنها در **یک نقطه** غیر صفر شوند. در عین حال، نیاز داریم تا انتگرال تابع فوق در هر بازه‌ای که شامل نقطه مورد نظر است مقداری غیرصفر داشته باشد. به یکی از توابع معروفی که خواص فوق را دارد، **تابع دلتای دیراک** $\delta(x)$ اطلاق می‌گردد:

$$\delta(x)=\begin{cases}+\infty & x=0\\ 0 & x\neq 0\end{cases},\qquad \int_R \delta(x)\,\mathrm{d}x=\begin{cases}1 & 0\in R\\ 0 & 0\notin R\end{cases}.$$

- در ریاضیات محض و شاخه آنالیز حقیقی، می‌توان نشان داد که موجودی مانند **دلتای دیراک** $\delta(x)$ نمی‌تواند یک تابع انتگرال‌پذیر (به معنای معمول) باشد: تابعی که جز در یک نقطه صفر است، انتگرال صفر دارد.
- در واقع، انتگرال مفاهیمی مانند دلتای دیراک به صورت اختصاصی و جداگانه تعریف می‌شوند (تعریف عام **جمع ریمان** یا Riemann Sum در مورد دلتای دیراک برقرار نیست). در ریاضیات دقیق، δ یک «تابع تعمیم‌یافته» یا distribution است.

چگونگی ساختن تابع دلتای دیراک: دلتا را می‌توان حد دنباله‌ای از توابع معمولی با مساحت ۱ در نظر گرفت که هر چه باریک‌تر و بلندتر می‌شوند:

- پالس مستطیلی به عرض ε و ارتفاع $\frac{1}{\varepsilon}$ حول صفر، وقتی $\varepsilon \to 0$؛
- چگالی گاوسی $\frac{1}{\sqrt{4\pi\alpha}} e^{-x^2/(4\alpha)}$ (یعنی $\mathcal{N}(0, 2\alpha)$)، وقتی $\alpha \to 0$.



قضیه ۸-۶: خاصیت غربالی

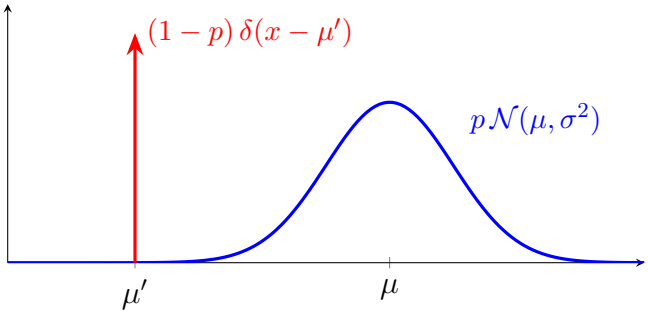
برای هر تابع پیوسته g: $\int_{-\infty}^{\infty} g(x)\,\delta(x-a)\,\mathrm{d}x = g(a)$. همچنین $\delta(x) = \frac{\mathrm{d}}{\mathrm{d}x}u(x)$ که u تابع پله واحد است (به این معنا که $\int_{-\infty}^{x} \delta(t)\,\mathrm{d}t = u(x)$).

۲.۵.۸ حل مسئله دماسنج نامطمئن

با مشتق‌گیری از CDF و استفاده از $\frac{\mathrm{d}}{\mathrm{d}x}\mathbb{1}(x \geq \mu') = \delta(x-\mu')$:

$$f_X(x) = \frac{p}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} + (1-p)\,\delta(x-\mu')$$

این PDF یک «زنگوله» با مساحت p به‌علاوه یک «ضربه» با وزن $1-p$ در نقطه μ' است؛ مساحت کل $p + (1-p) = 1$.



۳.۵.۸ تبدیل PMF به PDF

با دلتای دیراک، متغیرهای گسسته را هم می‌توان با PDF توصیف کرد. فرض کنید که متغیر تصادفی گسسته X دارای تابع جرم احتمال به شکل زیر است:

$$P(X = x_i) = p_i, \qquad \forall x_i \in \mathrm{Support}(X).$$

در این صورت، تابع چگالی احتمال (PDF) این متغیر تصادفی به شکل زیر خواهد بود:

$$f_X(x) = \sum_i p_i \, \delta(x - x_i).$$

بدین ترتیب یک چارچوب واحد برای همه متغیرها (گسسته، پیوسته و مخلوط) داریم: احتمال هر بازه برابر انتگرال PDF روی آن است، به شرطی که ضربه‌های داخل بازه را نیز در نظر بگیریم.

۶.۸ تمرین‌های تکمیلی

تمرین ۸-۷

در مسئله دماسنج نامطمئن با $\mu = 25$، $\sigma = 1$، $\mu' = 0$ و $p = 0.9$، احتمال اینکه دماسنج عددی بین ۲۴ و ۲۶ نشان دهد چقدر است؟ احتمال اینکه دقیقاً صفر نشان دهد چطور؟

حل. $P(24 \le X \le 26) = 0.9 \times P(|Z| \le 1) + 0.1 \times \mathbb{1}(0 \in [24,26]) \approx 0.9 \times 0.683 = 0.615$. و $P(X = 0) = 1 - p = 0.1$ (وزن ضربه در صفر؛ بخش گاوسی در یک نقطه احتمال صفر دارد). ■

تمرین ۸-۸

دو متغیر $X, Y \in \{0, 1\}$ با جدول توأم زیر داده شده‌اند: $P(0,0) = 0.3$، $P(0,1) = 0.2$، $P(1,0) = 0.3$، $P(1,1) = 0.2$. آیا X و Y مستقل‌اند؟ آیا هم‌توزیع‌اند؟

حل. حاشیه‌ها: $P_X(0) = 0.5$، $P_X(1) = 0.5$، $P_Y(0) = 0.6$، $P_Y(1) = 0.4$. حاصل‌ضرب‌ها: $0.5 \times 0.6 = 0.3$ و $0.5 \times 0.4 = 0.2$؛ همه خانه‌ها برابرند، پس **مستقل‌اند**. اما توزیع حاشیه‌ای‌شان متفاوت است، پس **هم‌توزیع نیستند** (و i.i.d. نیستند). ■

تمرین ۸-۹

PDF متغیر X = «تعداد شیرها در دو پرتاب سکه سالم» را با دلتای دیراک بنویسید و $\int_{0.5}^{3} f_X(x)\,\mathrm{d}x$ را حساب کنید.

حل. $f_X(x) = \tfrac{1}{4}\delta(x) + \tfrac{1}{2}\delta(x-1) + \tfrac{1}{4}\delta(x-2)$. بازه $[0.5, 3]$ شامل نقاط ۱ و ۲ است؛ پس انتگرال برابر $\tfrac{1}{2} + \tfrac{1}{4} = \tfrac{3}{4} = P(X \ge 1)$ است. ■

جلسه ۹

توزیع‌های شرطی، مدل‌های مخلوط، میانگین و قانون اعداد بزرگ

۱.۹ توزیع‌های شرطی (Conditional PMF/PDF/CDF)

همان‌طور که برای رویدادها احتمال شرطی تعریف کردیم، برای متغیرهای تصادفی نیز می‌توانیم توزیع شرطی تعریف کنیم. اگر B یک رویداد با $\mathbb{P}(B) > 0$ باشد:

$$F_X(x \mid B) = \mathbb{P}(X \le x \mid B) = \frac{\mathbb{P}(X \le x,\ B)}{\mathbb{P}(B)}, \qquad f_X(x \mid B) = \frac{\mathrm{d}}{\mathrm{d}x} F_X(x \mid B),$$

و برای متغیر گسسته $P_X(x \mid B) = \mathbb{P}(X = x \mid B)$. تابع $F_X(\cdot \mid B)$ خودش یک CDF معتبر است (صعودی، از ۰ تا ۱).

مثال ۹-۱: تابع توزیع انباشته شرطی

فرض کنید متغیر تصادفی X دارای تابع توزیع انباشته $F_X(x)$ باشد. تابع توزیع انباشته $F_X(x \mid X \le a)$ را بیابید.

حل. طبق تعریف:

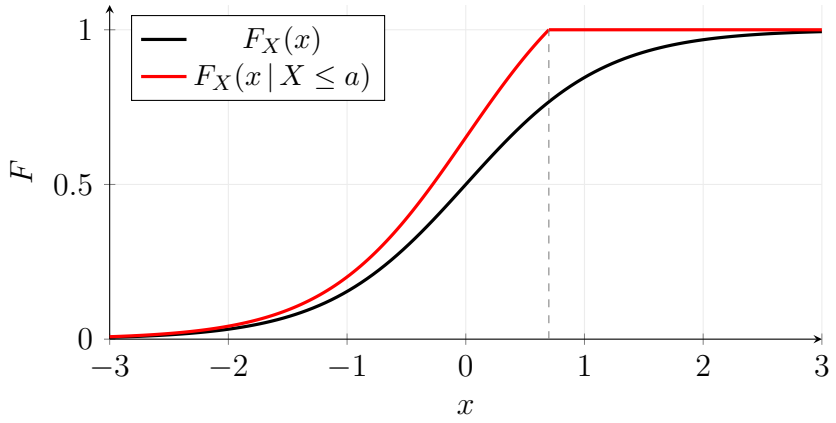
$$F_X(x \mid X \le a) = \frac{\mathbb{P}(X \le x,\ X \le a)}{\mathbb{P}(X \le a)}.$$

- اگر $x \le a$: رویداد $\{X \le x\}$ زیرمجموعه $\{X \le a\}$ است؛ پس اشتراک همان $\{X \le x\}$ است.
- اگر $x > a$: $\{X \le a\} \subseteq \{X \le x\}$ و اشتراک برابر $\{X \le a\}$ است.

بنابراین

$$\boxed{F_X(x \mid X \le a) = \begin{cases} \dfrac{F_X(x)}{F_X(a)} & x \le a \\[2mm] 1 & x > a \end{cases}}$$

با مشتق‌گیری، چگالی شرطی برابر $f_X(x \mid X \le a) = \frac{f_X(x)}{F_X(a)}$ برای $x \le a$ و صفر در غیر این صورت است: چگالی اصلی «بریده» (truncate) و سپس برای بهنجار شدن بر $F_X(a)$ تقسیم می‌شود. ■



(در شکل، X گاوسی استاندارد و $a = 0.7$ است.)

۲.۹ خاصیت بی‌حافظگی (memoryless property)

پیش‌تر بیان شد که توزیع نمایی $X \sim \lambda e^{-\lambda x} u(x)$ یک توزیع **بی‌حافظه** است. این توزیع معمولاً برای مدل‌سازی عمر وسایل الکترونیکی (یا برخی موارد مشابه!) به کار می‌رود.

تعریف ۹-۲: بی‌حافظگی

یک توزیع روی اعداد نامنفی را **بی‌حافظه** (memoryless) گوییم، اگر به ازای هر $a, \Delta \ge 0$ داشته باشیم:

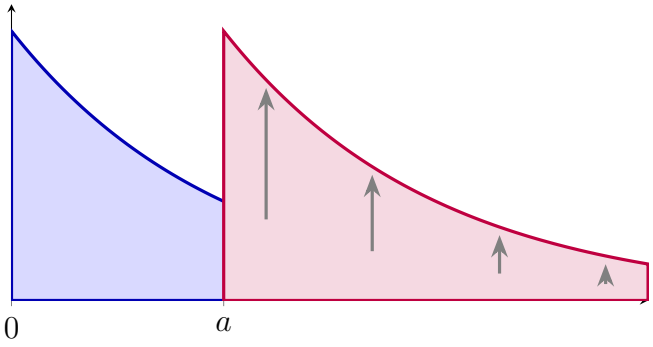
$$\mathbb{P}(X \ge a + \Delta \,|\, X \ge a) = \mathbb{P}(X \ge \Delta).$$

بی‌حافظه بودن توزیع نمایی به لحاظ ریاضیاتی به صورت زیر اثبات می‌شود (فرض کنید $X \sim \mathrm{Exp}(\lambda)$):

$$\begin{aligned}\mathbb{P}(X > a + \Delta \,|\, X > a) &= \frac{\mathbb{P}(X > a + \Delta)}{\mathbb{P}(X > a)} = \frac{1 - F(a + \Delta)}{1 - F(a)} \\ &= \frac{1 - \left(1 - e^{-\lambda(a+\Delta)}\right)}{1 - \left(1 - e^{-\lambda a}\right)} = \frac{e^{-\lambda(a+\Delta)}}{e^{-\lambda a}} = e^{-\lambda \Delta} = \mathbb{P}(X > \Delta).\end{aligned}$$

تعبیر هندسی: چگالی شرطی $f_X(x \mid X > a)$ از بریدن چگالی در $x = a$ و بزرگ‌نمایی (rescaling) بخش باقیمانده با ضریب $1/\mathbb{P}(X > a) = e^{\lambda a}$ به دست می‌آید. برای توزیع نمایی، نتیجه دقیقاً همان منحنی اولیه است که به اندازه a به راست منتقل شده است:

$$f_X(x \mid X > a) = \frac{\lambda e^{-\lambda x}}{e^{-\lambda a}} = \lambda e^{-\lambda(x-a)}, \qquad x > a.$$



نکته. می‌توان نشان داد توزیع نمایی **تنها** توزیع پیوسته بی‌حافظه است (و توزیع هندسی تنها توزیع گسسته بی‌حافظه روی اعداد طبیعی). دلیل: اگر $G(x) = \mathbb{P}(X > x)$ آنگاه بی‌حافظگی یعنی $G(a+\Delta) = G(a)G(\Delta)$، و تنها جواب‌های یکنوای این معادله تابعی به صورت $G(x) = e^{-\lambda x}$ هستند.

۳.۹ مدل‌های آماری مخلوط (Statistical Mixture Models)

یک خانواده از توزیع‌های آماری (مثلاً **خانواده توزیع‌های گاوسی**) را در نظر بگیرید:

- فرض کنید که برای مشخص کردن هر عضو از خانواده، مجموعه پارامترهای آزاد $\theta \in \Theta$ نیاز باشد.
- برای مثال، مشخص کردن هر عضو خانواده گاوسی به صورت یکتا از طریق مشخص کردن مقدار میانگین (μ) و واریانس (σ^2) آن امکان‌پذیر است. پس داریم:

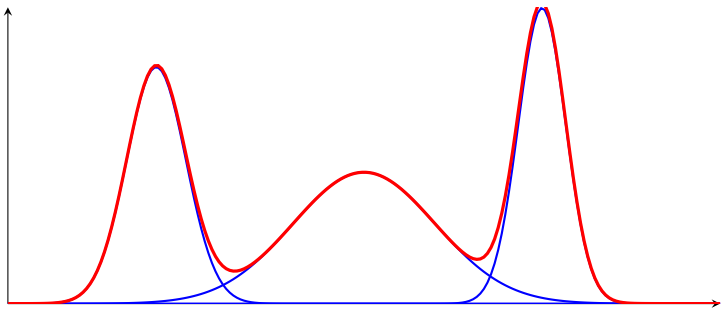
$$\theta = (\mu, \sigma), \qquad \Theta = \mathbb{R} \times \mathbb{R}_{\geq 0}.$$

در این صورت، تابع چگالی احتمال $f_X(x \mid \theta)$ نشان‌دهنده یک عضو از خانواده با پارامترهای θ است.

فرض کنید که متغیر تصادفی X، دارای توزیع احتمال متناظر با یکی از n عضو خانواده با پارامترهای $\theta_1, \theta_2, \ldots, \theta_n$ باشد. اما **این واقعیت که از کدامیک پیروی کند** خود یک متغیر تصادفی گسسته با احتمال‌های $p_1, p_2, \ldots, p_n$ را تشکیل دهد. در این صورت، با توجه به **قانون احتمال کل** داریم:

$$\boxed{f_X(x) = \sum_{i=1}^{n} p_i f_X(x \mid \theta_i)}$$

به چنین توزیع‌هایی اصطلاحاً توزیع‌های آماری مخلوط با n خوشه (یا mixture component) اطلاق می‌گردد. مثال معروف آن **مدل مخلوط گاوسی** (Gaussian Mixture Model — GMM) است که در یادگیری ماشین برای خوشه‌بندی داده‌ها کاربرد فراوان دارد. (مسئله دماسنج نامطمئن جلسه قبل نیز یک مدل مخلوط با دو مؤلفه بود.)



یک GMM با سه مؤلفه: منحنی قرمز = مجموع وزن‌دار سه منحنی آبی (وزن‌ها $0.3, 0.4, 0.3$).

نکته. نمونه‌برداری از مدل مخلوط: ابتدا با احتمال‌های $p_1, \ldots, p_n$ یکی از مؤلفه‌ها (مثلاً i) را انتخاب کنید، سپس یک نمونه از $f_X(\cdot \mid \theta_i)$ بگیرید. این دقیقاً همان «قانون احتمال کل» به زبان الگوریتم است.

۴.۹ توصیف یک متغیر تصادفی

فرض کنید که قصد دارید یک متغیر تصادفی را به صورت ناقص ولی به شکلی ساده توصیف کنید. مثلاً، کسی که اهل شهر شما نیست در مورد دمای هوا در محل زندگیتان از شما سؤالی می‌پرسد:

- دمای هوای شهر به شکل یک متغیر تصادفی مانند T مدل‌سازی شده که دارای فضای احتمال و تابع چگالی احتمال $f_T(T)$ است (برای مقادیر T بین صفر کلوین تا بی‌نهایت).
- ممکن است شما اطلاع دقیقی از تابع توزیع احتمال T داشته باشید. در این صورت تمام چیزی که در مورد دمای هوای شهر می‌توان داشت را دارید.

اما جواب آن شخص را چگونه می‌دهید؟ آیا کل تابع چگالی احتمال (شامل بی‌نهایت عدد) را به وی منتقل می‌کنید؟ آیا انتقال این حجم از اطلاعات در مقابل یک پرسش ساده، کاری منطقی به نظر می‌رسد؟ احتمالاً جواب می‌دهید: «معمولاً حدود ۲۵ درجه است، گاهی تا ۳۵ هم می‌رسد».

۱.۴.۹ آماره یا Statistic

- علم آمار و احتمال، در این مواقع ابزارهایی تحت عنوان «**آماره**» یا «**Statistic**» را در اختیار ما قرار می‌دهد.
- هر آماره، یک تک عدد و یا مجموعه‌ای نسبتاً کوچکی از اعداد است که اطلاعاتی کلی در مورد یک متغیر تصادفی در اختیار قرار می‌دهد.
- اطلاعات آماره در مورد یک متغیر تصادفی ناقص است، ولی در عوض انتقال و فهم آن بسیار سریع و راحت می‌نماید.

۵.۹ میانگین (Expected Value)

۱.۵.۹ مفهوم

- معروف‌ترین و پرکاربردترین آماره در تحلیل آماری و تصادفی وقایع، **میانگین** یا **Expected Value** یک متغیر تصادفی مانند X است.
- میانگین X را به صورت $\mathbb{E}(X)$ نشان می‌دهیم (به آن Expectation of X و یا Mean of X نیز اطلاق می‌گردد).
- میانگین یک متغیر تصادفی، **ماهیت تصادفی نداشته** و یک مقدار **یقینی** (deterministic) دارد.
- میانگین برای متغیرهای تصادفی مستقل از پیوسته یا گسسته بودن آنان تعریف می‌شود.
- امکان تعریف میانگین یا Expected Value برای برخی متغیرهای تصادفی وجود ندارد.

۲.۵.۹ فرمول ریاضی

تعریف ۹-۳: میانگین

میانگین یک متغیر تصادفی گسسته با تابع PMF برابر با $P(X=x)$ مطابق با زیر تعریف می‌شود:

$$\mathbb{E}(X) = \sum_{x_i \in \text{supp}(X)} x_i P(X = x_i).$$

میانگین یک متغیر تصادفی پیوسته (یا مخلوط) با تابع PDF برابر با $f_X(x)$ به صورت زیر تعریف می‌شود:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x)\,\mathrm{d}x.$$

(به شرطی که سری یا انتگرال به‌طور مطلق همگرا باشد، یعنی $\mathbb{E}|X| < \infty$.)

نکته. تعبیر فیزیکی: اگر PMF/PDF را توزیع جرم روی یک میله بدانیم، $\mathbb{E}(X)$ **مرکز جرم** (نقطه تعادل) آن است. **تعبیر آماری:** طبق قانون اعداد بزرگ (پایین‌تر)، میانگین تعداد زیادی نمونه مستقل از X به $\mathbb{E}(X)$ نزدیک می‌شود. همچنین برای هر تابع g داریم $\mathbb{E}[g(X)] = \sum g(x_i)P(X=x_i)$ یا $\int g(x)f_X(x)\,\mathrm{d}x$.

۳.۵.۹ میانگین متغیرهای تصادفی گسسته معروف

مثال ۹-۴: برنولی، تاس و دوجمله‌ای

برنولی با احتمال موفقیت p:

$$\mathbb{E}(X) = 1 \times p + 0 \times (1-p) = p.$$

تاس ۶وجهی متقارن:

$$\mathbb{E}(X) = \frac{1+2+\cdots+6}{6} = \frac{21}{6} = 3.5.$$

دوجمله‌ای $\text{Binomial}(n,p)$: با استفاده از اتحاد $k\binom{n}{k} = n\binom{n-1}{k-1}$:

$$\mathbb{E}(X) = \sum_{k=0}^{n} k\binom{n}{k}p^k(1-p)^{n-k} = np\sum_{k=1}^{n}\binom{n-1}{k-1}p^{k-1}(1-p)^{n-k} = np(p+1-p)^{n-1} = np.$$

(جمله $k=0$ صفر است؛ و مجموع باقیمانده با تغییر اندیس $j = k-1$ طبق قضیه دوجمله‌ای برابر ۱ است.) به‌طور شهودی: n آزمون، هر یک به طور متوسط p موفقیت.

مثال ۹-۵: هندسی و پواسون

هندسی: با قرارداد اسلاید، $P(X=k) = (1-p)p^{k-1}$ برای $k \geq 1$ (در اینجا p احتمال «ادامه دادن» یا

شکست در هر مرحله و $1-p$ احتمال توقف است). با مشتق‌گیری از سری هندسی $\sum_{k\ge 0} p^k = \frac{1}{1-p}$:

$$\mathbb{E}(X) = \sum_{k=1}^{\infty} k(1-p)p^{k-1} = (1-p)\frac{\partial}{\partial p}\big(1+p+p^2+\cdots\big) = (1-p)\frac{1}{(1-p)^2} = \frac{1}{1-p}.$$

دقت کنید: در قرارداد جلسه ششم ($P_X(k)=(1-p)^{k-1}p$ با p = احتمال موفقیت) همین محاسبه نتیجه می‌دهد $\mathbb{E}(X)=\frac{1}{p}$؛ مثلاً به طور متوسط ۶ پرتاب لازم است تا اولین ۶ در تاس بیاید.

پواسون با پارامتر λ:

$$\mathbb{E}(X) = \sum_{k=0}^{\infty} k e^{-\lambda}\frac{\lambda^k}{k!} = \lambda e^{-\lambda}\frac{\partial}{\partial \lambda}\Big(\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}\Big) = \lambda e^{-\lambda}\frac{\partial}{\partial \lambda}\big(e^{\lambda}\big) = \lambda.$$

(از $k\lambda^k = \lambda\frac{\partial}{\partial\lambda}\lambda^k$ استفاده شد.) پس پارامتر λ همان «تعداد متوسط رخدادها» است ــ سازگار با $np=\lambda$ در تقریب پواسون.

۴.۵.۹ میانگین متغیرهای تصادفی پیوسته معروف

مثال ۹-۶: گاوسی و نمایی

گاوسی $\mathcal{N}(\mu,\sigma^2)$:

$$\mathbb{E}(X) = \frac{1}{\sqrt{2\pi}\sigma}\int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,\mathrm{d}x = \mu.$$

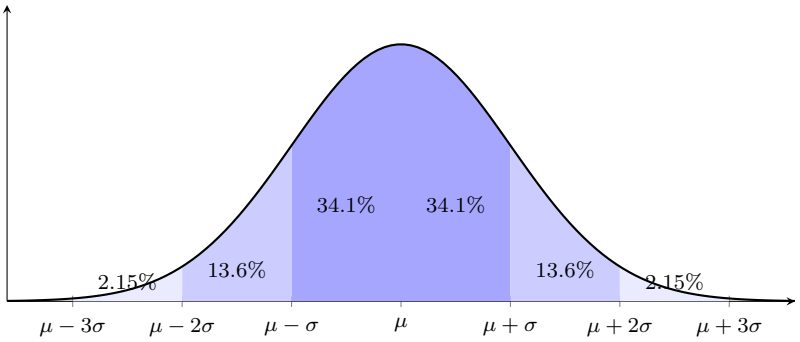
اثبات: با $x=\mu+t$ انتگرال برابر $\mu\int f + \frac{1}{\sqrt{2\pi}\sigma}\int t e^{-t^2/2\sigma^2}\,\mathrm{d}t = \mu\cdot 1 + 0$، زیرا انتگرال دوم از یک تابع فرد روی بازه متقارن است.

نمایی با پارامتر λ: با تغییر متغیر $u=\lambda x$ و انتگرال‌گیری جزءبه‌جزء ($\int_0^\infty ue^{-u}\,\mathrm{d}u = [-ue^{-u}]_0^\infty + \int_0^\infty e^{-u}\,\mathrm{d}u = 1$):

$$\mathbb{E}(X) = \lambda\int_0^\infty x e^{-\lambda x}\,\mathrm{d}x = \frac{1}{\lambda}\int_0^\infty u e^{-u}\,\mathrm{d}u = \frac{1}{\lambda}.$$

پس اگر نرخ خرابی یک قطعه $\lambda=0.2$ در سال باشد، عمر متوسط آن ۵ سال است.

نکته. تمرکز مقادیر حول میانگین در توزیع گاوسی: عمده احتمالات در بازه $\mu\pm 3\sigma$ تجمع پیدا کرده است: 34.1% بین μ و $\mu+\sigma$، 13.6% بین $\mu+\sigma$ و $\mu+2\sigma$، و 2.15% بین $\mu+2\sigma$ و $\mu+3\sigma$ (و به همین ترتیب در سمت چپ). در مجموع: 68.2% در $\mu\pm\sigma$، 95.4% در $\mu\pm 2\sigma$ و 99.7% در $\mu\pm 3\sigma$.



مثال ۹-۷: یکنواخت و بتا

یکنواخت در بازه $[a,b]$:

$$\mathbb{E}(X)=\frac{1}{b-a}\int_a^b x\,\mathrm{d}x=\frac{b^2-a^2}{2(b-a)}=\frac{a+b}{2}.$$

بتا با پارامترهای α,β: با استفاده از اتحاد تابع بتا $\int_0^1 x^{a-1}(1-x)^{b-1}\,\mathrm{d}x=\frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$ و $\Gamma(z+1)=z\Gamma(z)$:

$$\mathbb{E}(X)=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\int_0^1 x^{\alpha}(1-x)^{\beta-1}\,\mathrm{d}x=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\cdot\frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)}=\frac{\alpha}{\alpha+\beta}.$$

۶.۹ خواص میانگین

قضیه ۹-۸: برخی خواص میانگین ــ یک متغیر

فرض کنید X یک متغیر تصادفی گسسته، پیوسته و یا مخلوط باشد و $\mathbb{E}(X)$ وجود داشته باشد. آنگاه:

۱. در صورتی که تابع چگالی احتمال $f_X(x)$ حول نقطه‌ای متقارن باشد، مقدار میانگین نیز برابر با همان نقطه است (مثلاً در مورد متغیرهای تصادفی گاوسی و لاپلاس).

۲. لزومی ندارد که خود $\mathbb{E}(X)$ جزو $\mathrm{Support}(X)$ باشد (مثلاً میانگین تاس 3.5 است که هرگز ظاهر نمی‌شود).

۳. همواره داریم: $\min(X)\le\mathbb{E}(X)\le\max(X)$.

اثبات. (۱) اگر f_X حول c متقارن باشد، $Y=X-c$ چگالی زوج دارد و $\mathbb{E}(Y)=\int yf_Y(y)\,\mathrm{d}y=0$ (انتگرال تابع فرد)؛ پس $\mathbb{E}(X)=c$. (۳) اگر $m\le X\le M$، آنگاه $\mathbb{E}(X)=\int xf\le\int Mf=M$ و به طور مشابه $\ge m$. □

قضیه ۹-۹: خاصیت خطی Expectation

فرض کنید X,Y متغیرهای گسسته، پیوسته و یا مخلوط باشند و $\mathbb{E}(X)$ و $\mathbb{E}(Y)$ وجود داشته باشند. X و Y **لزوماً از یکدیگر مستقل نیستند**. آنگاه برای اعداد ثابت حقیقی a,b:

$$\mathbb{E}(aX+b)=a\mathbb{E}(X)+b.$$

به عبارت دیگر، در صورتی که g یک **تابع خطی** باشد، داریم $\mathbb{E}\big(g(X)\big) = g\big(\mathbb{E}(X)\big)$. همچنین همواره داریم:

$$\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y).$$

اثبات. برای حالت پیوسته: $\mathbb{E}(aX+b) = \int (ax+b) f_X(x)\,\mathrm{d}x = a\int x f_X + b\int f_X = a\mathbb{E}(X)+b$. برای جمع (حالت گسسته): $\mathbb{E}(X+Y) = \sum_{x,y}(x+y)P(x,y) = \sum_x x\sum_y P(x,y) + \sum_y y\sum_x P(x,y) = \sum_x xP_X(x) + \sum_y yP_Y(y)$. دقت کنید که در هیچ جای این اثبات از استقلال استفاده نشد. □

قضیه ۹-۱۰: نامساوی Jensen

اگر g تابعی **محدب** باشد (مثل x^2، e^x یا $|x|$)، آنگاه

$$\mathbb{E}\big(g(X)\big) \geq g\big(\mathbb{E}(X)\big).$$

(برای تابع مقعر جهت نامساوی برعکس است.)

ایده اثبات. تابع محدب بالای خط مماس خود در هر نقطه قرار دارد: با $\mu = \mathbb{E}(X)$، عددی c هست که برای همه x: $g(x) \geq g(\mu) + c(x-\mu)$. با میانگین‌گیری از دو طرف (و خاصیت خطی): $\mathbb{E}g(X) \geq g(\mu) + c(\mathbb{E}X - \mu) = g(\mu)$. □

دقت کنید! در حالت کلی $\mathbb{E}(g(X)) \neq g(\mathbb{E}(X))$. مثلاً برای تاس: $\mathbb{E}(X^2) = \frac{1+4+9+16+25+36}{6} = \frac{91}{6} \approx 15.17$ ولی $(\mathbb{E}X)^2 = 12.25$. طبق جنسن، اختلاف این دو همیشه نامنفی است (و در جلسه بعد نام «واریانس» می‌گیرد).

مثال ۹-۱۱: کاربرد خاصیت خطی ــ تطابق

n نفر کلاه‌های خود را در یک جعبه می‌اندازند و هر نفر یک کلاه به تصادف برمی‌دارد. میانگین تعداد افرادی که کلاه خودشان را برمی‌دارند چقدر است؟

حل. X_i را متغیر برنولی «نفر i کلاه خودش را برداشته» بگیرید؛ $\mathbb{E}(X_i) = \frac{1}{n}$. تعداد کل $X = \sum X_i$ است و با خاصیت خطی (با وجود اینکه X_iها مستقل نیستند!): $\mathbb{E}(X) = \sum_{i=1}^{n} \frac{1}{n} = 1$. جالب است که جواب به n بستگی ندارد. ■

۷.۹ مفهوم متغیرهای تصادفی i.i.d. و قانون اعداد بزرگ (Law of Large Numbers)

فرض کنید که $X_1, X_2, \ldots, X_n$ متغیرهای تصادفی i.i.d. از یک توزیع با میانگین μ باشند. متغیر تصادفی $\bar{X}_n$ را به صورت زیر تعریف می‌کنیم:

$$\bar{X}_n \triangleq \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

(دقت کنید که $\bar{X}_n$ خودش یک متغیر تصادفی است؛ طبق خاصیت خطی $\mathbb{E}(\bar{X}_n) = \mu$.) آنگاه قانون اعداد بزرگ به دو شکل زیر برقرار است:

قضیه ۹-۱۲: قانون اعداد بزرگ

شکل ضعیف: $\bar{X}_n \xrightarrow{P} \mu$ وقتی $n \to \infty$؛ یعنی برای هر عدد مثبت ε:

$$\lim_{n\to\infty} \Pr\left(|\bar{X}_n - \mu| > \varepsilon\right) = 0.$$

شکل قوی: $\bar{X}_n \xrightarrow{\text{a.s.}} \mu$ وقتی $n \to \infty$؛ یعنی

$$\Pr\left(\lim_{n\to\infty} \bar{X}_n = \mu\right) = 1.$$

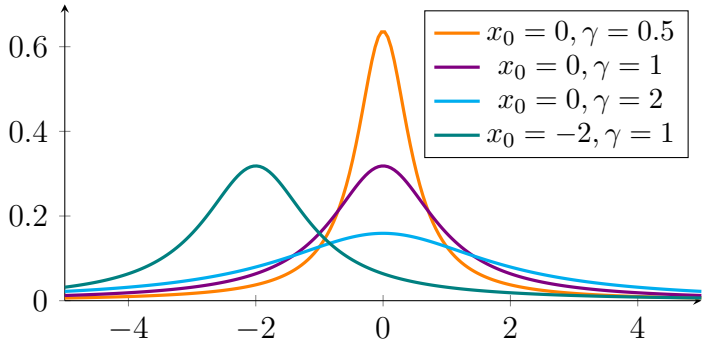
نکته. شکل ضعیف می‌گوید برای هر n بزرگ، احتمال اینکه میانگین نمونه‌ای از μ دور باشد کوچک است. شکل قوی بیشتر می‌گوید: تقریباً هر دنباله از نمونه‌ها (به جز مجموعه‌ای با احتمال صفر) در نهایت به μ همگرا می‌شود. شکل قوی، شکل ضعیف را نتیجه می‌دهد. این قانون توجیه ریاضی تعبیر فرکانسی احتمال است: اگر $X_i = \mathbb{1}(A$ در آزمایش $i)$ باشد، $\bar{X}_n$ همان فرکانس نسبی است و به $\mathbb{P}(A)$ میل می‌کند. (پدیده تمرکز در جلسه سوم نمونه‌ای از همین قانون بود.)

۸.۹ توزیع‌های بدون میانگین

تعریف ۹-۱۳: توزیع کوشی (Cauchy distribution)

توزیع کوشی با محلیت (location) x_0 و مقیاس $\gamma > 0$ را با چگالی احتمال زیر تعریف می‌کنیم:

$$f_X(x) = \frac{1}{\gamma\pi\left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]}.$$



می‌توانید به راحتی ببینید که یک متغیر تصادفی مانند X با توزیع کوشی میانگین ندارد. یعنی $\mathbb{E}(X)$ وجود نداشته و قابل تعریف نیست:

$$\int_{-\infty}^{\infty} |x| \frac{1}{\pi(1+x^2)}\,\mathrm{d}x = \frac{2}{\pi}\int_0^{\infty} \frac{x}{1+x^2}\,\mathrm{d}x = \frac{1}{\pi}\Big[\ln(1+x^2)\Big]_0^{\infty} = \infty.$$

(دقت کنید که با وجود تقارن چگالی حول صفر، نمی‌توان گفت میانگین صفر است؛ زیرا $\int_0^\infty$ و $\int_{-\infty}^0$ هر دو بی‌نهایت‌اند و $\infty - \infty$ تعریف نشده است. خاصیت تقارن فقط وقتی کار می‌کند که میانگین وجود داشته باشد.)

نکته. دقت کنید که این امر در تناقض با هیچ اصلی در آمار و احتمال نیست. تنها لازمه تعریف یک متغیر تصادفی، فضای احتمال $(\Omega, \mathcal{F}, P)$ است که با تعریف یک CDF خود به خود صورت می‌پذیرد. وجود داشتن میانگین شرط تعریف یک متغیر تصادفی نیست. همچنین قانون اعداد بزرگ برای کوشی برقرار نیست (فرض آن، یعنی وجود μ، برقرار نیست).

دلیل اصلی عدم وجود میانگین برای توزیع کوشی، دم (tail) خیلی قوی آن است:

توزیع	یکنواخت	گاوسی	نمایی	کوشی
رفتار دُم چگالی	$\propto 0$	$\propto e^{-x^2}$	$\propto e^{-x}$	$\propto x^{-2}$

برای وجود میانگین باید $xf(x)$ انتگرال‌پذیر باشد. با دم x^{-2}، $xf(x) \sim \frac{1}{x}$ که انتگرالش (لگاریتم) واگراست.

۹.۹ یک مثال تمرینی: سکه تصادفی با احتمال نامعلوم

مثال ۹-۱۴: استنتاج بیزی درباره احتمال شیر

فرض کنید یک سکه تصادفی با احتمال آمدن شیر p در دست داریم. در مورد p هیچ اطلاعی در دست نیست، و تمام اعداد حقیقی بازه $[0,1]$ برای آن شانس برابر دارند. این سکه را n بار به صورت تصادفی پرتاب می‌کنیم و مشاهده می‌شود که k بار شیر ظاهر شده است. در صورت دانسته بودن نتیجه این آزمایش، توزیع احتمال برای «احتمال شیر آمدن سکه p» چقدر است؟

حل. «هیچ اطلاعی نداریم» یعنی توزیع پیشین p یکنواخت است:

$$f_{\boldsymbol{p}}(p) = \begin{cases} 1 & 0 \le p \le 1 \\ 0 & \text{o.w.} \end{cases}$$

به شرط p، تعداد شیرها دوجمله‌ای است: $P(\text{test} \mid p) = \binom{n}{k} p^k (1-p)^{n-k}$. با قانون بیز (نسخه چگالی):

$$f_{\boldsymbol{p}}(p \mid \text{test}) = \frac{P(\text{test} \mid p) f_{\boldsymbol{p}}(p)}{P(\text{test})} = \frac{1}{P(\text{test})} \binom{n}{k} p^k (1-p)^{n-k}, \qquad 0 \le p \le 1.$$

مخرج با قانون احتمال کل (نسخه پیوسته) به دست می‌آید:

$$P(\text{test}) = \int_{\boldsymbol{p}} P(\text{test} \mid p) f_{\boldsymbol{p}}(p)\, \mathrm{d}p = \int_0^1 \binom{n}{k} q^k (1-q)^{n-k}\, \mathrm{d}q = \binom{n}{k} \frac{k!\,(n-k)!}{(n+1)!} = \frac{1}{n+1}.$$

(از اتحاد تابع بتا با $\Gamma(m+1) = m!$ استفاده شد. جالب است: پیش از آزمایش، همه مقادیر $k = 0, \dots, n$ هم‌احتمال‌اند!) پس

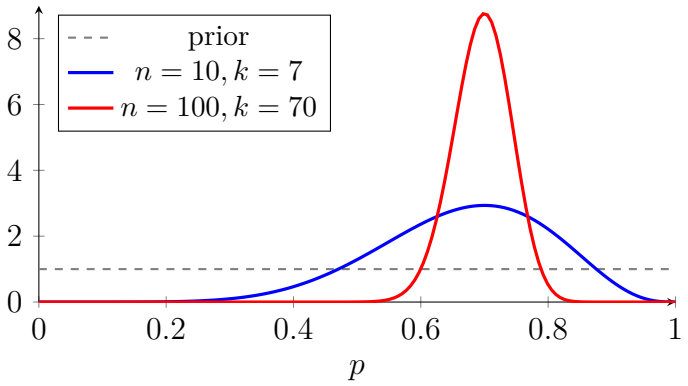
$$f_{\boldsymbol{p}}(p \mid \text{test}) = (n+1)\binom{n}{k} p^k (1-p)^{n-k} = \frac{\Gamma(n+2)}{\Gamma(k+1)\Gamma(n-k+1)} p^k (1-p)^{n-k},$$

که دقیقاً چگالی توزیع بتا است. **جواب نهایی:**

$$\boxed{\boldsymbol{p}\,|\,\text{test} \;\sim\; \text{Beta}(k+1\,,\; n-k+1)}$$

■

نکته. طبق فرمول میانگین بتا، $\mathbb{E}(\boldsymbol{p}\,|\,\text{test}) = \frac{k+1}{n+2}$ (معروف به «قاعده توالی لاپلاس»). مثلاً اگر در ۱۰ پرتاب ۷ شیر بیاید، تخمین ما $\frac{8}{12} \approx 0.67$ است (نه دقیقاً 0.7). با افزایش n، توزیع پسین حول $\frac{k}{n}$ باریک‌تر می‌شود. این مثال نشان می‌دهد چرا توزیع بتا برای مدل‌سازی «خود احتمال» مناسب است.



۱۰.۹ تمرین‌های تکمیلی

تمرین ۹-۱۵

X دارای چگالی $f(x) = 2x$ روی $[0,1]$ است. $\mathbb{E}(X)$ و $\mathbb{E}(X^2)$ را بیابید و نامساوی جنسن را برای $g(x) = x^2$ بررسی کنید.

حل. $\mathbb{E}(X) = \int_0^1 2x^2\,\mathrm{d}x = \frac{2}{3}$ و $\mathbb{E}(X^2) = \int_0^1 2x^3\,\mathrm{d}x = \frac{1}{2}$. داریم $\frac{1}{2} \geq \left(\frac{2}{3}\right)^2 = \frac{4}{9} \approx 0.444$ که با جنسن سازگار است. ■

تمرین ۹-۱۶

در یک بازی، تاسی پرتاب می‌کنید و اگر عدد k بیاید k^2 هزار تومان می‌برید. اگر هزینه ورود ۱۵ هزار تومان باشد، آیا بازی به نفع شماست؟

حل. سود متوسط $\mathbb{E}(X^2) - 15 = \frac{91}{6} - 15 = \frac{1}{6} \approx 0.17$ هزار تومان؛ پس بازی به‌طور متوسط اندکی به نفع بازیکن است. (دقت کنید $(\mathbb{E}X)^2 = 12.25 < 15$؛ استفاده نادرست از $g(\mathbb{E}X)$ نتیجه را برعکس می‌کرد.) ■

تمرین ۹-۱۷

یک کلکسیونر می‌خواهد همه N نوع کارت را جمع کند؛ هر بسته یک کارت تصادفی (یکنواخت) دارد. میانگین تعداد بسته‌های لازم را بیابید (مسئله جمع‌آوری کوپن).

حل. وقتی i نوع جمع شده است، هر بسته جدید با احتمال $\frac{N-i}{N}$ نوع تازه می‌دهد؛ پس تعداد بسته‌های لازم برای نوع بعدی هندسی با میانگین $\frac{N}{N-i}$ است. با خاصیت خطی: $\mathbb{E}(T)=\sum_{i=0}^{N-1}\frac{N}{N-i}=N\big(1+\frac{1}{2}+\cdots+\frac{1}{N}\big)\approx N\ln N$. برای $N=50$: حدود 225 بسته. ■

جلسه ۱۰

عملگر میانگین‌گیری، واریانس، مُد و میانه

۱.۱۰ میانگین‌گیری یا عملگر Expectation

فرض کنید که $X, Y, Z, \ldots$ متغیرهای تصادفی مستقل و یا وابسته باشند. در این صورت، به ازای یک تابع مشخص g، مقدار $g(X, Y, Z, \ldots)$ نیز بدل به یک متغیر تصادفی جدید خواهد شد.

تعریف ۱۰-۱: میانگین تابعی از چند متغیر

میانگین و یا Expectation تابع g در این شرایط را به صورت زیر تعریف می‌کنیم:

$$\mathbb{E}\{g(X, Y, Z, \ldots)\} = \sum_{x,y,z,\ldots} g(x, y, z, \ldots)\, \mathbb{P}(X = x,\ Y = y,\ Z = z, \ldots).$$

در صورت پیوسته بودن هر یک از متغیرهای تصادفی $X, Y, Z, \ldots$، به جای pmf می‌بایست از pdf کلی (توأم) استفاده نمود و جمع را با انتگرال جایگزین کرد:

$$\mathbb{E}\{g(X, Y, \ldots)\} = \int\int \cdots g(x, y, \ldots)\, f_{X,Y,\ldots}(x, y, \ldots)\, \mathrm{d}x\, \mathrm{d}y \cdots$$

- در صورتی که متغیرهای تصادفی **مستقل** باشند، تابع pmf کلی به صورت حاصل‌ضرب توابع pmf حاشیه‌ای در خواهد آمد: $\mathbb{P}(X = x, Y = y, \ldots) = \mathbb{P}(X = x)\mathbb{P}(Y = y) \cdots$.
- دقت کنید که با میانگین‌گیری یا عمل Expectation، به یک مقدار قطعی خواهیم رسید و تمام تصادفی بودن (Randomness) از بین می‌رود.

نکته. به این قاعده گاهی «قانون آماردان ناخودآگاه» (LOTUS) می‌گویند: برای محاسبه $\mathbb{E}[g(X)]$ لازم نیست ابتدا توزیع متغیر جدید $g(X)$ را پیدا کنیم؛ کافی است g را روی توزیع خود X میانگین بگیریم.

مثال ۱۰-۲: میانگین ضرب دو تاس

دو تاس سالم و مستقل پرتاب می‌شوند. $\mathbb{E}(XY)$ و $\mathbb{E}(\max(X, Y))$ را بیابید.

حل. با استقلال، $\mathbb{P}(X = x, Y = y) = \frac{1}{36}$:
$\mathbb{E}(XY) = \frac{1}{36}\sum_{x=1}^{6}\sum_{y=1}^{6} xy = \frac{1}{36}(21)(21) = \frac{441}{36} = 12.25 = \mathbb{E}(X)\mathbb{E}(Y)$.

برای ماکزیمم: $\mathbb{P}(\max \le m) = \frac{m^2}{36}$، پس $\mathbb{P}(\max = m) = \frac{m^2-(m-1)^2}{36} = \frac{2m-1}{36}$ و $\mathbb{E}(\max) = \frac{1}{36}\sum_{m=1}^{6} m(2m-1) = \frac{1+6+15+28+45+66}{36} = \frac{161}{36} \approx 4.47$.
■

۲.۱۰ واریانس و انحراف معیار (Variance & Std. Deviation)

یکی دیگر از آماره‌های پرکاربرد در آمار و احتمال **واریانس** یک متغیر تصادفی مانند X است که آن را با $\mathrm{Var}(X)$ نشان می‌دهیم.

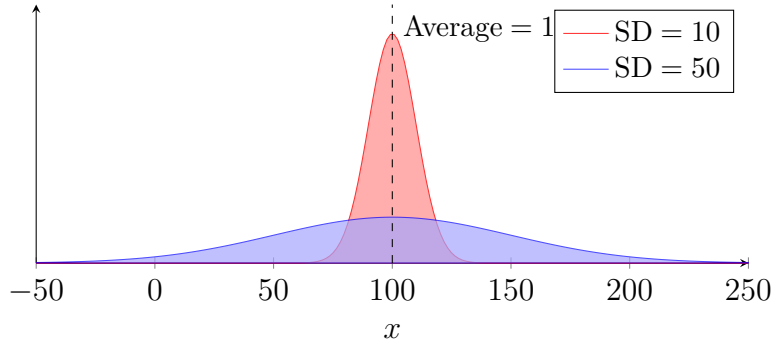
تعریف ۱۰-۳: واریانس و انحراف معیار

با $\mu = \mathbb{E}(X)$:

$$\mathrm{Var}(X) = \mathbb{E}\big((X-\mu)^2\big) = \int_{-\infty}^{\infty} (x-\mu)^2 f_X(x)\,\mathrm{d}x, \qquad \mathrm{Var}(X) = \sum_x (x-\mu)^2 P(X=x),$$

$$\sigma(X) = \sqrt{\mathrm{Var}(X)}.$$

واریانس، و یا جذر آن «انحراف معیار $\sigma(X)$» میزان **پراکندگی** یک متغیر تصادفی حول میانگین را نشان می‌دهند. دو توزیع می‌توانند میانگین یکسان (مثلاً ۱۰۰) ولی پراکندگی کاملاً متفاوت داشته باشند:



نکته. چرا مربع و نه قدر مطلق؟ $\mathbb{E}|X-\mu|$ (انحراف مطلق میانگین) هم معیار پراکندگی است، اما واریانس خواص جبری بسیار زیباتری دارد (مثلاً جمع‌پذیری برای متغیرهای مستقل، پایین‌تر). انحراف معیار هم‌واحد با X است (مثلاً سانتی‌متر)، اما واریانس واحد مربع دارد.

۱.۲.۱۰ خواص

قضیه ۱۰-۴: خواص واریانس

فرض کنید X یک متغیر تصادفی پیوسته، گسسته و یا مخلوط باشد و واریانس آن وجود داشته باشد. آنگاه:

۱. همواره داریم:

$$\mathrm{Var}(X) = \mathbb{E}\big((X-\mathbb{E}(X))^2\big) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \ge 0.$$

۲. در صورتی که a, b اعداد ثابت حقیقی باشند، داریم:

$$\mathrm{Var}(aX + b) = a^2 \,\mathrm{Var}(X).$$

۳. در صورتی که X, Y متغیرهای تصادفی مستقل باشند، داریم:

$$\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y), \qquad \mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

اثبات. (۱) با بسط مربع و خاصیت خطی میانگین (μ یک عدد ثابت است):

$$\mathbb{E}\big((X-\mu)^2\big) = \mathbb{E}(X^2 - 2\mu X + \mu^2) = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

نامنفی بودن از آنجاست که $(X-\mu)^2 \geq 0$ (یا از نامساوی جنسن).

(۲) $\mathbb{E}(aX+b) = a\mu+b$؛ پس $aX+b-\mathbb{E}(aX+b) = a(X-\mu)$ و $\mathrm{Var}(aX+b) = \mathbb{E}\big(a^2(X-\mu)^2\big) = a^2\,\mathrm{Var}(X)$. (افزودن ثابت b فقط توزیع را جابه‌جا می‌کند و پراکندگی را تغییر نمی‌دهد.)

(۳) **ضرب:** با استقلال، $\mathbb{P}\{X=x, Y=y\} = \mathbb{P}\{X=x\}\mathbb{P}\{Y=y\}$؛ پس

$$\begin{aligned}\mathbb{E}(XY) &= \sum_{x,y} xy\,\mathbb{P}\{X=x, Y=y\} = \sum_{x,y} xy\,\mathbb{P}\{X=x\}\mathbb{P}\{Y=y\} \\ &= \sum_{x} x\mathbb{P}\{X=x\} \sum_{y} y\mathbb{P}\{Y=y\} = \mathbb{E}(X)\mathbb{E}(Y).\end{aligned}$$

(در حالت پیوسته روابط مشابهی با انتگرال و $f_{X,Y} = f_X f_Y$ می‌توان نوشت.)

جمع: با $\mu_X = \mathbb{E}X$ و $\mu_Y = \mathbb{E}Y$:

$$\begin{aligned}\mathrm{Var}(X+Y) &= \mathbb{E}\big\{(X+Y-\mu_X-\mu_Y)^2\big\} \\ &= \mathbb{E}\big\{(X-\mu_X)^2 + (Y-\mu_Y)^2 + 2(X-\mu_X)(Y-\mu_Y)\big\} \\ &= \mathbb{E}\big\{(X-\mu_X)^2 + (Y-\mu_Y)^2\big\} = \mathrm{Var}(X) + \mathrm{Var}(Y).\end{aligned}$$

در سطر سوم از خاصیت خطی بودن عملگر Expectation و همچنین نتیجه بند پیشین استفاده شده است: $\mathbb{E}\{(X-\mu_X)(Y-\mu_Y)\} = \mathbb{E}(X-\mu_X)\,\mathbb{E}(Y-\mu_Y) = 0\times 0 = 0$ مستقل‌اند، پس $Y-\mu_Y$ و $X-\mu_X$.

□

دقت کنید! بدون استقلال، $\mathrm{Var}(X+Y) = \mathrm{Var}\,X + \mathrm{Var}\,Y$ لزوماً درست نیست. مثلاً اگر $Y = X$ آنگاه $\mathrm{Var}(2X) = 4\,\mathrm{Var}\,X \neq 2\,\mathrm{Var}\,X$؛ و اگر $Y = -X$ آنگاه $\mathrm{Var}(X+Y) = 0$. جمله اضافی $2\mathbb{E}\{(X-\mu_X)(Y-\mu_Y)\}$ همان «کوواریانس» است که در جلسات آینده مطالعه می‌کنیم. همچنین دقت کنید: $\mathrm{Var}(X-Y) = \mathrm{Var}\,X + \mathrm{Var}\,Y$ (نه تفاضل!)، زیرا $\mathrm{Var}(-Y) = (-1)^2\,\mathrm{Var}\,Y$.

۳.۱۰ واریانس توزیع‌های معروف

۱.۳.۱۰ توزیع‌های برنولی، دوجمله‌ای و پواسون

مثال ۱۰-۵: برنولی $X \sim \mathrm{Bern}(p)$

$$\mathrm{Var}(X) = p \times (1-p)^2 + (1-p) \times (0-p)^2 = p(1-p)\big[(1-p)+p\big] = p(1-p),$$
$$\sigma(X) = \sqrt{p(1-p)}.$$

(روش دیگر: $X^2 = X$ پس $\mathbb{E}X^2 = p$ و $\mathrm{Var}\, X = p - p^2$.) بیشینه واریانس در $p = \frac{1}{2}$ رخ می‌دهد: سکه سالم «غیرقابل‌پیش‌بینی‌ترین» است.

مثال ۱۰-۶: دوجمله‌ای $X \sim \mathrm{Binomial}(n, p)$

$$\mathrm{Var}(X) = \sum_{i=0}^{n} (i - np)^2 \binom{n}{i} p^i (1-p)^{n-i} = np(1-p).$$

حل. روش سریع: $X = \sum_{i=1}^{n} B_i$ که B_iها برنولی‌های مستقل‌اند. طبق خاصیت جمع واریانس برای متغیرهای مستقل: $\mathrm{Var}\, X = \sum \mathrm{Var}\, B_i = np(1-p)$.

روش مستقیم: با اتحاد $k(k-1)\binom{n}{k} = n(n-1)\binom{n-2}{k-2}$ داریم $\mathbb{E}[X(X-1)] = n(n-1)p^2$. پس $\mathbb{E}X^2 = n(n-1)p^2 + np$ و $\mathrm{Var}\, X = n(n-1)p^2 + np - n^2p^2 = np - np^2 = np(1-p)$. ■

مثال ۱۰-۷: پواسون $X \sim \mathrm{Poisson}(\lambda)$

$$\mathbb{E}(X) = \lambda, \qquad \mathrm{Var}(X) = \lambda.$$

حل. $\mathbb{E}[X(X-1)] = \sum_{k\geq 2} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda} \sum_{k\geq 2} \frac{\lambda^{k-2}}{(k-2)!} = \lambda^2$. پس $\mathbb{E}X^2 = \lambda^2 + \lambda$ و $\mathrm{Var}\, X = \lambda^2 + \lambda - \lambda^2 = \lambda$. (سازگار با حد دوجمله‌ای: $np(1-p) \to \lambda$ وقتی $p \to 0$.) ■

۲.۳.۱۰ توزیع‌های گاوسی، نمایی و یکنواخت

مثال ۱۰-۸: گاوسی $X \sim \mathcal{N}(\mu, \sigma^2)$

$\mathrm{Var}(X) = \sigma^2$.

حل. با $z = \frac{x-\mu}{\sigma}$: $\mathrm{Var}\, X = \sigma^2 \int z^2 \frac{e^{-z^2/2}}{\sqrt{2\pi}}\, \mathrm{d}z$. با انتگرال‌گیری جزءبه‌جزء ($u = z$، $\mathrm{d}v = ze^{-z^2/2}\,\mathrm{d}z$): $\int z^2 e^{-z^2/2}\,\mathrm{d}z = \big[-ze^{-z^2/2}\big]_{-\infty}^{\infty} + \int e^{-z^2/2}\,\mathrm{d}z = \sqrt{2\pi}$. پس $\mathrm{Var}\, X = \sigma^2$ ــ پارامتر σ^2 دقیقاً همان واریانس است. ■

مثال ۱۰-۹: نمایی $X \sim \text{Exponential}(\lambda)$

$$\text{Var}(X) = \lambda \int_0^\infty \left(x - \lambda^{-1}\right)^2 e^{-\lambda x}\,\mathrm{d}x = \lambda^{-2}.$$

حل. با $\int_0^\infty x^n e^{-\lambda x}\,\mathrm{d}x = \frac{n!}{\lambda^{n+1}}$: $\mathbb{E}X^2 = \lambda \cdot \frac{2}{\lambda^3} = \frac{2}{\lambda^2}$. پس $\text{Var}\, X = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$؛ یعنی $\sigma = \mathbb{E}X = \frac{1}{\lambda}$. ■

مثال ۱۰-۱۰: یکنواخت $X \sim \text{Uniform}(a, b)$

$$\text{Var}(X) = \frac{1}{12}(b-a)^2.$$

حل. $Y = X - \frac{a+b}{2}$ روی $[-\frac{L}{2}, \frac{L}{2}]$ یکنواخت است ($L = b - a$). پس $\text{Var}\, X = \mathbb{E}Y^2 = \frac{1}{L}\int_{-L/2}^{L/2} y^2\,\mathrm{d}y = \frac{1}{L}\cdot\frac{2}{3}\left(\frac{L}{2}\right)^3 = \frac{L^2}{12}$. ■

جدول خلاصه میانگین و واریانس توزیع‌های معروف

توزیع	$\mathbb{E}(X)$	$\text{Var}(X)$
برنولی $\text{Bern}(p)$	p	$p(1-p)$
دوجمله‌ای $\text{Bin}(n,p)$	np	$np(1-p)$
هندسی (احتمال موفقیت p)	$\frac{1}{p}$	$\frac{1-p}{p^2}$
پواسون $\text{Pois}(\lambda)$	λ	λ
یکنواخت $\mathcal{U}(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
نمایی $\text{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
گاوسی $\mathcal{N}(\mu,\sigma^2)$	μ	σ^2
لاپلاس (μ, b)	μ	$2b^2$
بتا (α,β)	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
کوشی	ندارد	ندارد

۴.۱۰ واریانس جمع متغیرهای تصادفی i.i.d.

فرض کنید که $X_1, X_2, \ldots, X_n$ متغیرهای تصادفی i.i.d. از یک توزیع با میانگین μ و واریانس σ^2 باشند. متغیر تصادفی $\bar{X}_n$ را به صورت زیر تعریف می‌کنیم:

$$\bar{X}_n \triangleq \frac{X_1 + X_2 + \cdots + X_n}{n}.$$

در این صورت (با خاصیت جمع‌پذیری واریانس برای متغیرهای مستقل و $\operatorname{Var}(aX) = a^2 \operatorname{Var} X$) داریم:

$$\boxed{\operatorname{Var}(\bar{X}_n) = \sum_{i=1}^{n} \operatorname{Var}\left(\frac{X_i}{n}\right) = \sum_{i=1}^{n} \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}}$$

با افزایش مجانبی n، واریانس متغیر تصادفی $\bar{X}_n$ به سمت صفر میل می‌کند. پس انحراف معیار میانگین نمونه‌ای $\frac{\sigma}{\sqrt{n}}$ است: برای نصف کردن خطا، باید چهار برابر نمونه جمع کنیم.

نکته. این نتیجه، شهود قانون اعداد بزرگ است: $\mathbb{E}\bar{X}_n = \mu$ و پراکندگی $\bar{X}_n$ حول μ به صفر میل می‌کند. در جلسه بعد با «نامساوی چبیشف» همین را به اثبات دقیق شکل ضعیف قانون اعداد بزرگ تبدیل می‌کنیم: $\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \le \frac{\sigma^2}{n\varepsilon^2} \to 0$. این همچنین توضیح می‌دهد که چرا در جلسه سوم عرض توزیع تعداد شیرها $O(\sqrt{n})$ بود: $\sigma(\text{تعداد شیر}) = \sqrt{n/4}$.

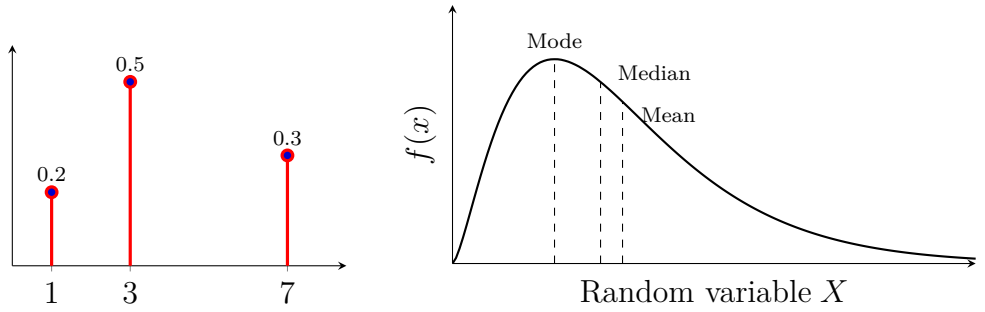
۵.۱۰ مُد و میانه (Mode and Median)

۱.۵.۱۰ مُد (Mode)

تعریف ۱۰-۱۱: مد

به محتمل‌ترین مقدار یک متغیر تصادفی، مُد (Mode) آن متغیر تصادفی اطلاق می‌گردد: برای متغیر گسسته، مقداری که PMF را بیشینه می‌کند؛ برای متغیر پیوسته، نقطه بیشینه PDF.

مثال: اگر $P(X=1) = 0.2$، $P(X=3) = 0.5$ و $P(X=7) = 0.3$ آنگاه مد برابر ۳ است (در حالی که میانگین $0.2 + 1.5 + 2.1 = 3.8$ است).



۲.۵.۱۰ میانه (Median)

تعریف ۱۰-۱۲: میانه

میانه به کوچک‌ترین مقداری اطلاق می‌گردد که یک متغیر تصادفی با احتمال $\frac{1}{2}$ کوچک‌تر یا مساوی آن است. به صورت معادل، به کوچک‌ترین مقداری اطلاق می‌گردد که تابع CDF در آن برابر یا بزرگ‌تر یا مساوی $\frac{1}{2}$ است:

$$m = \min\{x : \ F_X(x) \geq \tfrac{1}{2}\}.$$

برای متغیر پیوسته، میانه نقطه‌ای است که مساحت زیر PDF را به دو نیمه ۵۰٪ تقسیم می‌کند؛ در حالی که میانگین «نقطه تعادل» (مرکز جرم) است.

نکته. رابطه مد، میانه و میانگین: برای توزیع‌های متقارن تک‌قله (مانند گاوسی) هر سه برابرند. برای توزیع‌های چوله به راست (دم بلند در سمت راست، مانند نمایی یا توزیع درآمد) معمولاً میانگین $>$ میانه $>$ مد؛ زیرا مقادیر بزرگ دم، میانگین را به سمت خود می‌کشند. میانه نسبت به داده‌های پرت «مقاوم» (robust) است و حتی برای کوشی (که میانگین ندارد) وجود دارد و برابر x_0 است.

مثال ۱۰-۱۳: مد، میانه و میانگین توزیع نمایی

برای $X \sim \mathrm{Exp}(\lambda)$: مد $= 0$ (چگالی نزولی است)، میانه از $1 - e^{-\lambda m} = \frac{1}{2}$ برابر $m = \frac{\ln 2}{\lambda} \approx \frac{0.693}{\lambda}$ و میانگین $\frac{1}{\lambda}$. پس $0 < 0.693/\lambda < 1/\lambda$ ــ مطابق ترتیب توزیع‌های چوله به راست.

۶.۱۰ تمرین‌های تکمیلی

تمرین ۱۰-۱۴

واریانس عدد یک تاس سالم را حساب کنید. سپس واریانس مجموع اعداد ۱۰ تاس مستقل را بیابید.

حل. $\mathbb{E}X = 3.5$ و $\mathbb{E}X^2 = \frac{91}{6}$؛ پس $\operatorname{Var} X = \frac{91}{6} - \frac{49}{4} = \frac{182-147}{12} = \frac{35}{12} \approx 2.92$. برای مجموع ۱۰ تاس مستقل: $10 \times \frac{35}{12} = \frac{350}{12} \approx 29.17$ (انحراف معیار حدود 5.4 حول میانگین 35). ■

تمرین ۱۰-۱۵

اگر $\mathbb{E}X = 2$ و $\operatorname{Var} X = 3$ باشد، $\mathbb{E}[(2X-1)^2]$ و $\operatorname{Var}(5 - 3X)$ را بیابید.

حل. $\mathbb{E}X^2 = \operatorname{Var} X + (\mathbb{E}X)^2 = 7$. پس $\mathbb{E}[(2X-1)^2] = 4\mathbb{E}X^2 - 4\mathbb{E}X + 1 = 28 - 8 + 1 = 21$. $\operatorname{Var}(5 - 3X) = 9 \operatorname{Var} X = 27$. ■

تمرین ۱۰-۱۶

برای اندازه‌گیری یک کمیت، از دستگاهی با خطای تصادفی با انحراف معیار ۲ میلی‌متر استفاده می‌کنیم. چند اندازه‌گیری مستقل لازم است تا انحراف معیار میانگین اندازه‌گیری‌ها حداکثر 0.25 میلی‌متر شود؟

حل. $\sigma(\bar{X}_n) = \frac{2}{\sqrt{n}} \leq 0.25 \Rightarrow \sqrt{n} \geq 8 \Rightarrow n \geq 64$. ■

تمرین ۱۰-۱۷

میانه و مد توزیع $f(x) = 2x$ روی $[0, 1]$ را بیابید و با میانگین $(\frac{2}{3})$ مقایسه کنید.

حل. $F(x) = x^2$؛ میانه: $m^2 = \frac{1}{2} \Rightarrow m = \frac{1}{\sqrt{2}} \approx 0.707$. مد: $x = 1$ (چگالی صعودی است). ترتیب: میانگین < 0.667 میانه < 0.707 مد 1 ــ این توزیع چوله به چپ است و ترتیب برعکس می‌شود. ■

جلسه ۱۱

گشتاورها، تابع مولد گشتاور، تابع مشخصه و توابع یک متغیر تصادفی

۱.۱۱ گشتاورهای یک توزیع (Moments of a Distribution)

تعریف ۱۱-۱: گشتاور (Moment)

برای $n \in \mathbb{W} = \{0, 1, 2, \dots\}$، گشتاورهای یک متغیر تصادفی مانند $X \sim f_X(x)$ به صورت زیر تعریف می‌شوند:

$$m_n \triangleq \mathbb{E}(X^n) = \int_{-\infty}^{\infty} x^n f_X(x)\,\mathrm{d}x.$$

گشتاورهای مرکزی (حول میانگین μ):

$$\mu_n \triangleq \mathbb{E}\big((X-\mu)^n\big).$$

همچنین گشتاورهای مطلق ($\mathbb{E}|X|^n$) و تعمیم‌یافته ($\mathbb{E}[(X-c)^n]$) حول نقطه دلخواه c، یا توان‌های غیرصحیح) نیز وجود دارند.

۱.۱.۱۱ خواص

- گشتاور صفرم همواره برابر با ۱، و گشتاور اول (در صورت وجود) برابر با **میانگین توزیع** هستند: $m_0 = \int f_X = 1$ و $m_1 = \mathbb{E}X = \mu$. همچنین $\mu_1 = 0$ و $\mu_2 = \mathrm{Var}(X)$.
- تمام و یا برخی از گشتاورها می‌توانند وجود نداشته باشند (توزیع کوشی)، گاهی اوقات نیز تمامی گشتاورها وجود دارند (گاوسی، نمایی و تمامی توزیع‌های finite-support).
- تحت شرایطی، کل توزیع f_X را می‌توان صرفاً با دانستن $m_0, m_1, m_2, \dots$ به صورت یکتا به دست آورد.
- همواره داریم:

$$m_{2n} \geq m_n^2.$$

اثبات نامساوی آخر. $\mathrm{Var}(X^n) = \mathbb{E}(X^{2n}) - \left(\mathbb{E}X^n\right)^2 \geq 0$. (یا از جنسن با تابع محدب $g(u) = u^2$ روی $U = X^n$.) □

نکته. اگر گشتاور مرتبه k وجود داشته باشد، همه گشتاورهای مرتبه کمتر نیز وجود دارند. برای توزیع‌های با تکیه‌گاه کران‌دار (مثلاً $|X| \leq M$) همه گشتاورها وجود دارند زیرا $|m_n| \leq M^n$. برای توزیع کوشی حتی m_1 وجود ندارد.

۲.۱.۱۱ گشتاور دوم، واریانس و Kurtosis

دقت کنید که برای یک متغیر تصادفی، سه مقدار زیر با یکدیگر فرق دارند:

- **گشتاور دوم:** $m_2 = \mathbb{E}(X^2)$؛
- **واریانس:** $\mathrm{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$؛
- **انحراف معیار:** $\sigma(X) = \sqrt{\mathrm{Var}(X)}$.

(این سه فقط وقتی $\mathbb{E}X = 0$ باشد به هم مربوط و $m_2 = \mathrm{Var}\, X$ می‌شود.)

تعریف ۱۱-۲: چولگی و کشیدگی

یکی از آماره‌های پرکاربرد در پردازش سیگنال (Signal Processing)، **Kurtosis** (کشیدگی) نام دارد:

$$\mathrm{Kurt}(X) = \frac{\mu_4}{\sigma^4}.$$

به طور مشابه، **چولگی** (Skewness) به صورت $\frac{\mu_3}{\sigma^3}$ تعریف می‌شود و میزان عدم تقارن توزیع را می‌سنجد.

از Kurtosis در Independent Component Analysis (ICA) و جداسازی کور منابع (Blind Source Separation) استفاده می‌گردد. برای توزیع گاوسی $\mathrm{Kurt} = 3$ است؛ توزیع‌های با دم سنگین‌تر (مثل لاپلاس با $\mathrm{Kurt} = 6$) کشیدگی بیشتر و توزیع‌های «پهن» (مثل یکنواخت با $\mathrm{Kurt} = 1.8$) کشیدگی کمتری دارند. ایده ICA: طبق قضیه حد مرکزی، مخلوط چند منبع مستقل «گاوسی‌تر» از تک‌تک منابع است؛ پس با بیشینه کردن فاصله Kurtosis از ۳ می‌توان منابع را از هم جدا کرد (مثلاً جدا کردن صدای چند گوینده که هم‌زمان ضبط شده‌اند).

مثال ۱۱-۳: گشتاورهای توزیع یکنواخت

گشتاورهای $X \sim \mathcal{U}(0,1)$ و Kurtosis آن را بیابید.

حل. $m_n = \int_0^1 x^n\,\mathrm{d}x = \frac{1}{n+1}$. پس $\mu = \frac{1}{2}$ و $\sigma^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$. گشتاور مرکزی چهارم: $\mu_4 = \int_{-1/2}^{1/2} y^4\,\mathrm{d}y = \frac{2}{5}\cdot\frac{1}{32} = \frac{1}{80}$. پس $\mathrm{Kurt} = \frac{1/80}{1/144} = \frac{144}{80} = 1.8$. ■

۲.۱۱ تابع مولد گشتاور (Moment Generating Function)

تعریف ۱۱-۴: تابع مولد گشتاور

تابع مولد گشتاور (MGF) برای متغیر تصادفی $X \sim f_X(x)$ و $t \in \mathbb{C}$ به صورت زیر تعریف می‌شود:

$$M_X(t) \triangleq \mathbb{E}\left[e^{tX}\right] = \int_{-\infty}^{\infty} e^{tx} f_X(x)\,\mathrm{d}x.$$

محدوده تعریف ورودی تابع MGF، تمامی مقادیری از $t \in \mathbb{C}$ است که مقدار میانگین فوق به ازای آن وجود داشته باشد.

۱.۲.۱۱ خواص

- تابع مولد گشتاور به ازای هر $t \in \mathbb{R}$ (صرفاً مقادیر حقیقی) همواره مقداری مثبت است (چون $e^{tX} > 0$).
- تابع MGF در اثر میانگین‌گیری بر روی یک ماهیت تصادفی (یعنی e^{tX}) به وجود آمده است. لذا MGF تصادفی نیست و تابعی یقینی به حساب می‌آید.
- تمام اطلاعات توزیع $f_X(x)$ در MGF آن وجود دارد. به عبارت دیگر، تابع MGF حاصل انتقال توزیع $f_X(x)$ به یک حوزه دیگر (مشابه حوزه لاپلاس) است. (در واقع $M_X(t)$ همان تبدیل لاپلاس دوطرفه f_X در $s = -t$ است.)
- می‌توان به راحتی دید که $M_X(0) = 1$. همچنین برای توزیع گاوسی، MGF به ازای تمامی صفحه اعداد مختلط وجود دارد.

۲.۲.۱۱ کاربرد اصلی: تولید گشتاورها

می‌توان به راحتی دید که خاصیت زیر برای مشتقات MGF وجود دارد (به دلیل خطی بودن عملگر مشتق، از انتگرال عبور خواهد کرد):

$$\frac{\partial^n}{\partial t^n} M_X(t) = \frac{\partial^n}{\partial t^n} \int_{-\infty}^{\infty} e^{tx} f_X(x)\,\mathrm{d}x = \int_{-\infty}^{\infty} x^n e^{tx} f_X(x)\,\mathrm{d}x.$$

در صورتی که مشتق nام تابع MGF را با $M_X^{(n)}(t)$ نشان دهیم، خواهیم داشت:

$$\boxed{M_X^{(n)}(0) = \int_{-\infty}^{\infty} x^n f_X(x)\,\mathrm{d}x = m_n}$$

یعنی مشتق nام در صفر، همان گشتاور مرتبه n برای متغیر تصادفی X است. معادلاً با بسط تیلور:

$$M_X(t) = \mathbb{E}\Big[\sum_{n\geq 0} \frac{t^n X^n}{n!}\Big] = \sum_{n\geq 0} \frac{m_n}{n!} t^n;$$

MGF همه گشتاورها را به صورت ضرایب سری تیلورش در خود «بسته‌بندی» کرده است ــ از این‌رو «مولد گشتاور» نام دارد.

مثال ۱۱-۵: MGF و گشتاورهای توزیع نمایی

حل. برای $t < \lambda$: $M_X(t) = \int_0^\infty e^{tx}\lambda e^{-\lambda x}\,\mathrm{d}x = \lambda\int_0^\infty e^{-(\lambda-t)x}\,\mathrm{d}x = \frac{\lambda}{\lambda-t}$ (برای $t \geq \lambda$ انتگرال واگراست). مشتقات: $M'(t) = \frac{\lambda}{(\lambda-t)^2}$ و $M''(t) = \frac{2\lambda}{(\lambda-t)^3}$؛ پس $m_1 = \frac{1}{\lambda}$ و $m_2 = \frac{2}{\lambda^2}$ و $\operatorname{Var} X = \frac{1}{\lambda^2}$ (مطابق جلسه قبل). در حالت کلی $M_X(t) = \frac{1}{1-t/\lambda} = \sum_n \frac{t^n}{\lambda^n}$، پس $m_n = \frac{n!}{\lambda^n}$. ■

مثال ۱۱-۶: MGF توزیع گاوسی

حل. ابتدا برای $Z \sim \mathcal{N}(0,1)$ با «تکمیل مربع»: $tz - \frac{z^2}{2} = -\frac{(z-t)^2}{2} + \frac{t^2}{2}$

$$M_Z(t) = \int \frac{1}{\sqrt{2\pi}} e^{tz - z^2/2}\,\mathrm{d}z = e^{t^2/2}\int \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2}\,\mathrm{d}z = e^{t^2/2}.$$

برای $X = \mu + \sigma Z$: $M_X(t) = \mathbb{E}e^{t\mu + t\sigma Z} = e^{t\mu}M_Z(\sigma t) = e^{t\mu + \sigma^2 t^2/2}$. ■

۳.۲.۱۱ خاصیت مهم: MGF جمع متغیرهای مستقل

قضیه ۱۱-۷

در صورتی که X, Y دو متغیر تصادفی مستقل با توابع مولد گشتاور $M_X(t), M_Y(t)$ باشند، برای متغیر تصادفی جدید $X+Y$ خواهیم داشت:

$$\begin{aligned} M_{X+Y}(t) &= \mathbb{E}\left[e^{t(X+Y)}\right] = \mathbb{E}\left[e^{tX+tY}\right] = \mathbb{E}\left[e^{tX}e^{tY}\right] \\ &= \mathbb{E}\left[e^{tX}\right]\mathbb{E}\left[e^{tY}\right] = M_X(t)\,M_Y(t). \end{aligned}$$

(در سطر دوم از استقلال e^{tX} و e^{tY} و قاعده $\mathbb{E}(UV) = \mathbb{E}U\,\mathbb{E}V$ استفاده شد.)

این خاصیت بسیار قدرتمند است: توزیع جمع متغیرهای مستقل (که مستقیماً با «کانولوشن» به دست می‌آید) در حوزه MGF به یک ضرب ساده تبدیل می‌شود ــ درست مثل تبدیل لاپلاس/فوریه در سیگنال‌ها و سیستم‌ها.

مثال ۱۱-۸: جمع پواسون‌های مستقل

اگر $X \sim \mathrm{Pois}(\lambda_1)$ و $Y \sim \mathrm{Pois}(\lambda_2)$ مستقل باشند، توزیع $X+Y$ چیست؟

حل. $M_X(t) = \sum_k e^{tk}e^{-\lambda}\frac{\lambda^k}{k!} = e^{-\lambda}e^{\lambda e^t} = e^{\lambda(e^t-1)}$. پس $M_{X+Y}(t) = e^{\lambda_1(e^t-1)}e^{\lambda_2(e^t-1)} = e^{(\lambda_1+\lambda_2)(e^t-1)}$ که MGF توزیع $\mathrm{Pois}(\lambda_1+\lambda_2)$ است. طبق یکتایی (پایین‌تر)، $X+Y \sim \mathrm{Pois}(\lambda_1+\lambda_2)$.

مثلاً اگر به دو صف مستقل به ترتیب ۲ و ۳ مشتری در ساعت برسد، به مجموع آن‌ها پواسون با نرخ ۵ می‌رسد. به همین روش، جمع دو گاوسی مستقل نیز گاوسی است: $\mathrm{MGF} = e^{t\mu_1+\sigma_1^2t^2/2}e^{t\mu_2+\sigma_2^2t^2/2}$ $\mathcal{N}(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$. ■

۴.۲.۱۱ توزیع‌های مشهور MGF

توزیع	تابع مولد گشتاور $M_X(t)$
تباهیده (ثابت) δ_a	e^{ta}
برنولی $P(X=1)=p$	$1-p+pe^t$
دوجمله‌ای $B(n,p)$	$(1-p+pe^t)^n$
هندسی $(k\geq 0)$ $(1-p)^k p$	$\dfrac{p}{1-(1-p)e^t}, \quad t<-\ln(1-p)$
دوجمله‌ای منفی $\mathrm{NB}(r,p)$	$\left(\dfrac{p}{1-e^t+pe^t}\right)^r, \quad t<-\ln(1-p)$
پواسون $\mathrm{Pois}(\lambda)$	$e^{\lambda(e^t-1)}$
یکنواخت پیوسته $U(a,b)$	$\dfrac{e^{tb}-e^{ta}}{t(b-a)}$
یکنواخت گسسته $DU(a,b)$	$\dfrac{e^{at}-e^{(b+1)t}}{(b-a+1)(1-e^t)}$
لاپلاس $L(\mu,b)$	$\dfrac{e^{t\mu}}{1-b^2t^2}, \quad \lvert t\rvert<1/b$
نرمال $N(\mu,\sigma^2)$	$e^{t\mu+\sigma^2t^2/2}$
نمایی $\mathrm{Exp}(\lambda)$	$\dfrac{\lambda}{\lambda-t}, \quad t<\lambda$

نکته. دوجمله‌ای = جمع n برنولی مستقل، پس MGF آن توان nام MGF برنولی است. به همین ترتیب دوجمله‌ای منفی (تعداد شکست‌ها تا rامین موفقیت) جمع r هندسی مستقل است و MGF آن توان rام MGF هندسی است.

۳.۱۱ تابع مشخصه (Characteristic Function)

تعریف ۱۱-۹: تابع مشخصه

تابع مشخصه یا Characteristic Function برای $\omega \in \mathbb{R}$ به صورت زیر تعریف می‌شود:

$$\Phi(\omega) = M_X(j\omega) = \int_{-\infty}^{\infty} e^{j\omega x} f_X(x)\,\mathrm{d}x.$$

- همان‌گونه که مشخص است، این تابع به نوعی بیانگر **تبدیل فوریه** تابع چگالی احتمال متغیر تصادفی است (با علامت مثبت در نما).
- عمده خواص MGF، از جمله تولید گشتاور، برای Characteristic Function هم وجود دارد: $\Phi^{(n)}(0) = j^n m_n$ و برای متغیرهای مستقل $\Phi_{X+Y} = \Phi_X \Phi_Y$.

- مزیت بزرگ: چون $|e^{j\omega x}| = 1$، انتگرال همواره همگراست؛ پس تابع مشخصه **برای هر توزیعی** (حتی کوشی) وجود دارد، در حالی که MGF ممکن است وجود نداشته باشد.

۱.۳.۱۱ خواص و قضیه یکتایی

قضیه ۱۱-۱۰

۱. تابع مشخصه در $\omega = 0$ بیشترین مقدار قدرمطلق (Magnitude) را داراست:

$$|\Phi(\omega)| \le \Phi(0) = 1.$$

۲. **(یکتایی)** در صورتی که برای دو متغیر تصادفی X, Y داشته باشیم $\Phi_X(\omega) = \Phi_Y(\omega)$ (برای همه ω)، آنگاه دو متغیر تصادفی هم‌توزیع (identically distributed) هستند.

اثبات بند ۱. $|\Phi(\omega)| = \left|\int e^{j\omega x} f_X(x)\,\mathrm{d}x\right| \le \int |e^{j\omega x}| f_X(x)\,\mathrm{d}x = \int f_X(x)\,\mathrm{d}x = 1 = \Phi(0)$. □

(بند ۲ نتیجه وارون‌پذیری تبدیل فوریه است: $f_X(x) = \frac{1}{2\pi}\int \Phi(\omega) e^{-j\omega x}\,\mathrm{d}\omega$.)

۲.۳.۱۱ توابع مشخصه توزیع‌های معروف

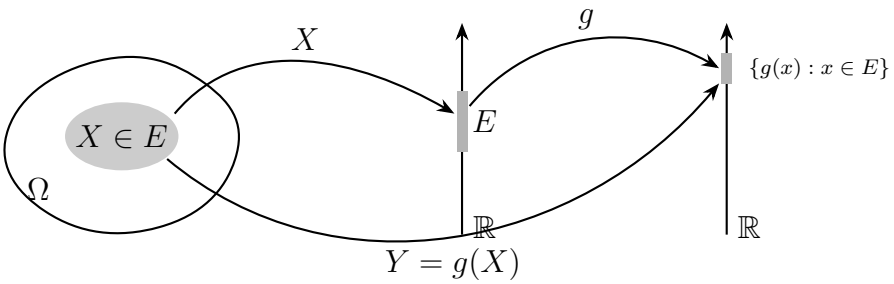
گاوسی $\mathcal{N}(\mu, \sigma^2)$	$\Phi_X(\omega) = e^{j\mu\omega - \sigma^2\omega^2/2}$
نمایی $\mathrm{Exponential}(\lambda)$	$\Phi_X(\omega) = \left(1 - \frac{j\omega}{\lambda}\right)^{-1}$
یکنواخت $\mathrm{Uniform}(a, b)$	$\Phi_X(\omega) = e^{j\omega\frac{a+b}{2}} \dfrac{\sin\left((b-a)\omega/2\right)}{(b-a)\omega/2}$
برنولی $\mathrm{Bern}(p)$	$\Phi_X(\omega) = pe^{j\omega} + (1-p)$
کوشی (x_0, γ)	$\Phi_X(\omega) = e^{jx_0\omega - \gamma\lvert\omega\rvert}$

نکته. (در اسلاید، فرمول یکنواخت بدون ضریب $\frac{1}{2}$ داخل سینوس آمده؛ شکل درست همان است که در جدول بالا نوشته‌ایم: $\int_a^b \frac{e^{j\omega x}}{b-a}\,\mathrm{d}x = \frac{e^{j\omega b} - e^{j\omega a}}{j\omega(b-a)} = e^{j\omega\frac{a+b}{2}} \frac{2\sin(\omega\frac{b-a}{2})}{\omega(b-a)}$.)
تابع مشخصه توزیع گاوسی، خود به شکل تابع چگالی احتمال یک توزیع گاوسی است ($e^{-\sigma^2\omega^2/2}$ یک «زنگوله» است) ــ همان خاصیت معروف «تبدیل فوریه گاوسی، گاوسی است». همچنین کوشی در نقطه $\omega = 0$ مشتق‌پذیر نیست (به دلیل $|\omega|$)، که با عدم وجود میانگین آن سازگار است.

۴.۱۱ توابعی از یک متغیر تصادفی

۱.۴.۱۱ تعریف مسئله

فرض کنید که متغیر تصادفی $X \sim f_X(x)$ و تابع دلخواه $g : \mathbb{R} \to \mathbb{R}$ داده شده باشند. متغیر تصادفی جدیدی به شکل $Y = g(X)$ را تشکیل می‌دهیم. هدف، به دست آوردن تابع چگالی احتمال $f_Y(y)$ بر حسب $f_X(x)$ و $g(\cdot)$ است.



روش کلی (از طریق CDF):

$$F_Y(y) = \mathbb{P}(g(X) \le y) = \mathbb{P}\big(X \in \{x :\ g(x) \le y\}\big) = \int_{\{x:\, g(x)\le y\}} f_X(x)\,\mathrm{d}x,$$

و سپس $f_Y = F_Y'$. این روش برای هر تابع g کار می‌کند.

۲.۴.۱۱ موارد ساده

شیفت. فرض کنید که متغیر تصادفی Y به صورت $Y = X + b$ تعریف شده باشد، که در اینجا b یک مقدار ثابت و یقینی است. در این صورت، هر مقدار تصادفی Y از طریق ابتدا نمونه‌گیری از X با استفاده از $f_X(x)$، و سپس شیفت دادن آن به اندازه مقدار ثابت و یقینی b حاصل می‌شود. پس می‌توان به راحتی استدلال کرد که:

$$\boxed{f_Y(y) = f_X(y-b)}$$

(از طریق CDF: $F_Y(y) = \mathbb{P}(X \le y-b) = F_X(y-b)$ و با مشتق‌گیری حکم به دست می‌آید.)

تبدیل خطی. حال فرض کنید که متغیر تصادفی Y به صورت $Y = aX + b$ تعریف شده باشد، که در اینجا $a \neq 0, b$ مقادیر ثابت و یقینی هستند. می‌توان نوشت (برای $a > 0$):

$$\begin{aligned} f_Y(y) &= \lim_{h\to 0} \frac{\mathbb{P}(y \le aX+b \le y+h)}{h} = \lim_{h\to 0} \frac{\mathbb{P}(y-b \le aX \le y+h-b)}{h} \\ &= \lim_{h\to 0} \frac{\mathbb{P}\big(\frac{y-b}{a} \le X \le \frac{y-b}{a} + \frac{h}{|a|}\big)}{h} = \frac{1}{|a|}\lim_{h\to 0} \frac{\mathbb{P}\big(\frac{y-b}{a} \le X \le \frac{y-b}{a} + \frac{h}{|a|}\big)}{h/|a|} \\ &= \frac{1}{|a|} f_X\Big(\frac{y-b}{a}\Big). \end{aligned}$$

(برای $a < 0$ جهت نامساوی‌ها برعکس می‌شود و همان نتیجه با $|a|$ به دست می‌آید.)

$$\boxed{f_Y(y) = \frac{1}{|a|} f_X\Big(\frac{y-b}{a}\Big)}$$

نکته. تعبیر: ضریب $\frac{1}{|a|}$ از آنجاست که تبدیل، بازه‌ها را $|a|$ برابر کش می‌دهد؛ برای حفظ مساحت (احتمال) کل، ارتفاع چگالی باید $|a|$ برابر کم شود. به عنوان نتیجه مهم: اگر $X \sim \mathcal{N}(\mu, \sigma^2)$ آنگاه $aX+b \sim \mathcal{N}(a\mu+b, a^2\sigma^2)$؛ به‌ویژه $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$ (استانداردسازی).

مثال ۱۱-۱۱: تبدیل خطی یکنواخت

اگر $X \sim \mathcal{U}(0,1)$ و $Y = 3 - 2X$، چگالی Y را بیابید.

حل. $a=-2$، $b=3$: برای $0 \le y \le 3$، یعنی $0 \le \frac{3-y}{2} \le 1$. پس $f_Y(y) = \frac{1}{2} f_X\!\left(\frac{y-3}{-2}\right) = \frac{1}{2}$ $1 \le y \le 3$. پس $Y \sim \mathcal{U}(1,3)$. ■

مثال ۱۱-۱۲: یک تبدیل غیرخطی: $Y = X^2$

اگر $X \sim \mathcal{N}(0,1)$، چگالی $Y = X^2$ را بیابید.

حل. برای $y > 0$: $F_Y(y) = \mathbb{P}(-\sqrt{y} \le X \le \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$. با مشتق‌گیری (قاعده زنجیره‌ای):

$$f_Y(y) = \frac{1}{2\sqrt{y}}\big[f_X(\sqrt{y}) + f_X(-\sqrt{y})\big] = \frac{1}{\sqrt{2\pi y}} e^{-y/2}, \qquad y > 0.$$

این توزیع «کای‌دو با یک درجه آزادی» (χ^2_1) نام دارد. دقت کنید که چون $g(x) = x^2$ یک‌به‌یک نیست، دو شاخه $\pm\sqrt{y}$ هر دو سهم دارند. (این ایده در جلسه بعد به فرمول کلی تبدیل تعمیم داده می‌شود.) ■

۵.۱۱ تمرین‌های تکمیلی

تمرین ۱۱-۱۳

با استفاده از MGF، میانگین و واریانس توزیع دوجمله‌ای را به دست آورید.

حل. $M(t) = (1-p+pe^t)^n$. $M'(t) = npe^t(1-p+pe^t)^{n-1}$، پس $M'(0) = np$. $M''(t) = npe^t(\cdots)^{n-1} + n(n-1)p^2e^{2t}(\cdots)^{n-2}$، پس $M''(0) = np + n(n-1)p^2$. واریانس: $np+n(n-1)p^2 - n^2p^2 = np(1-p)$. ■

تمرین ۱۱-۱۴

اگر $M_X(t) = \frac{1}{4} + \frac{1}{2}e^t + \frac{1}{4}e^{2t}$، توزیع X را مشخص کنید.

حل. $M_X(t) = \sum_k P(X=k)e^{tk}$، پس با مقایسه ضرایب: $P(X=0) = \frac{1}{4}$، $P(X=1) = \frac{1}{2}$، $P(X=2) = \frac{1}{4}$ ــ یعنی $\mathrm{Bin}(2, \frac{1}{2})$ (تعداد شیر در دو پرتاب). در واقع $M_X(t) = \left(\frac{1}{2} + \frac{1}{2}e^t\right)^2$. ■

تمرین ۱۱-۱۵

اگر $X \sim \mathrm{Exp}(1)$، چگالی $Y = 2X + 1$ و $\mathbb{E}Y$ را بیابید.

حل. $f_Y(y) = \frac{1}{2}e^{-(y-1)/2}$ برای $y \geq 1$ (نمایی با نرخ $\frac{1}{2}$ که یک واحد شیفت خورده است). $\mathbb{E}Y = 2\mathbb{E}X + 1 = 3$.
■

تمرین ۱۱-۱۶

نشان دهید Kurtosis توزیع گاوسی برابر ۳ است.

حل. برای $Z \sim \mathcal{N}(0,1)$: $M_Z(t) = e^{t^2/2} = 1 + \frac{t^2}{2} + \frac{t^4}{8} + \cdots$. ضریب t^4 برابر $\frac{m_4}{4!}$ است، پس $m_4 = \frac{24}{8} = 3$. چون کشیدگی به تبدیل خطی حساس نیست (μ_4 و σ^4 هر دو در σ^4 ضرب می‌شوند)، برای هر گاوسی $\mathrm{Kurt} = 3$.
■

جلسه ۱۲

توابعی از یک متغیر تصادفی و تبدیل توزیع‌ها

۱.۱۲ یادآوری: تعریف مسئله و موارد ساده

فرض کنید که متغیر تصادفی $X \sim f_X(x)$ و تابع دلخواه $g : \mathbb{R} \to \mathbb{R}$ داده شده باشند. متغیر تصادفی جدیدی به شکل $Y = g(X)$ را تشکیل می‌دهیم. هدف، به دست آوردن تابع چگالی احتمال $f_Y(y)$ بر حسب $f_X(x)$ و $g(\cdot)$ است.

در جلسه قبل دو حالت ساده را دیدیم:

- **شیفت** $Y = X + b$: هر مقدار Y از نمونه‌گیری از X و سپس شیفت به اندازه b حاصل می‌شود؛ پس

$$f_Y(y) = f_X(y - b).$$

- **تبدیل خطی** $Y = aX + b$ با $a \neq 0$:

$$\begin{aligned} f_Y(y) &= \lim_{h \to 0} \frac{\mathbb{P}(y \leq aX + b \leq y + h)}{h} \\ &= \frac{1}{|a|} \lim_{h \to 0} \frac{\mathbb{P}\left(\frac{y-b}{a} \leq X \leq \frac{y-b}{a} + \frac{h}{|a|}\right)}{h/|a|} = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right). \end{aligned}$$

۲.۱۲ فرمول در حالت توابع g یک‌به‌یک

قضیه ۱۲-۱: تبدیل یک‌به‌یک

فرض کنید که g تابعی مشتق‌پذیر (با مشتق غیرصفر) و یک‌به‌یک باشد. در این صورت، فرض کنید به ازای مقدار معلوم y، مقدار یکتای x^* را به صورت زیر تعریف کنیم:

$$y = g(x^*) \qquad \text{or} \qquad x^* = g^{-1}(y).$$

مشابه با روش گام به گام پیشین می‌توان نشان داد که:

$$\boxed{f_Y(y) = \frac{1}{|g'(x^*)|} f_X(x^*)}$$

(برای $g(x) = ax + b$ داریم $g' = a$ و $x^* = \frac{y-b}{a}$، که همان فرمول تبدیل خطی است.)

۳.۱۲ فرمول کلی

قضیه ۱۲-۲: تبدیل کلی

فرض کنید که g تابعی مشتق‌پذیر باشد. همچنین $x_1, x_2, \dots$ را به صورت زیر تعریف می‌کنیم (همه ریشه‌های معادله $g(x) = y$):

$$y = g(x_1) = g(x_2) = \cdots \qquad \text{or} \qquad \{x_1, x_2, \dots\} = g^{-1}(y).$$

در این صورت، می‌توان رابطه کلی را به صورت زیر نوشت:

$$\boxed{f_Y(y) = \frac{1}{|g'(x_1)|} f_X(x_1) + \frac{1}{|g'(x_2)|} f_X(x_2) + \cdots}$$

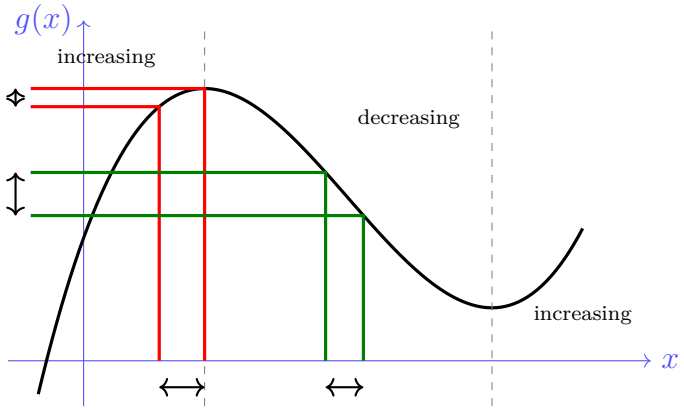
اگر معادله $g(x) = y$ هیچ ریشه‌ای نداشته باشد، $f_Y(y) = 0$.

در صورتی که تابع g در نقاطی مشتق‌پذیر نبود و یا مشتق آن صفر شد، معمولاً به صورت موردی باید تکلیف آن نقاط را مشخص نمود. (مثلاً اگر g روی یک بازه با احتمال مثبت ثابت باشد، Y در آن مقدار ثابت یک «ضربه» (دلتای دیراک) خواهد داشت.)

۴.۱۲ بررسی و شهود ریاضیاتی

۱.۴.۱۲ توجیه گرافیکی

دلیل ظاهر شدن مشتق در رابطه پیشین چیست؟ یک تابع غیریکنوا مانند شکل زیر را در نظر بگیرید که بخش‌هایی صعودی (increasing) و بخش‌هایی نزولی (decreasing) دارد.



- **نزدیک بیشینه (شیب کم):** یک بازه **بزرگ** از x به یک بازه **کوچک** از y نگاشته می‌شود (خطوط قرمز در شکل). کل احتمال یک بازه بزرگ در یک بازه کوچک فشرده می‌شود؛ پس چگالی Y آنجا **زیاد** است.

چون $|g'|$ کوچک است، $\frac{1}{|g'|}$ بزرگ است.

- **ناحیه پرشیب:** یک بازه **کوچک** از x به یک بازه **بزرگ‌تر** از y نگاشته می‌شود (خطوط سبز). احتمال کمی روی بازه بزرگی پخش می‌شود؛ پس چگالی Y **کم** است. چون $|g'|$ بزرگ است، $\frac{1}{|g'|}$ کوچک است.
- یک مقدار y (خط افقی) ممکن است منحنی را در چند نقطه قطع کند؛ احتمال همه این شاخه‌ها با هم جمع می‌شود ــ از این‌رو در فرمول کلی جمع ظاهر شده است.

به زبان دقیق: برای $\mathrm{d}y$ کوچک، $\mathbb{P}(y < Y \le y + \mathrm{d}y) = \sum_i \mathbb{P}(X \in$ بازه‌ای به طول $\frac{\mathrm{d}y}{|g'(x_i)|}$ حول $x_i) \approx \sum_i f_X(x_i)\frac{\mathrm{d}y}{|g'(x_i)|}$.

۲.۴.۱۲ توجیه تحلیلی

(برای سادگی) فرض کنید که g تابعی اکیداً صعودی و لذا یک‌به‌یک باشد. در این صورت داریم:

$$F_Y(y) = \mathbb{P}\big(g(X) \le y\big) = \mathbb{P}\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big).$$

مطابق قبل تعریف می‌کنیم $x^* = g^{-1}(y)$. با قاعده زنجیره‌ای:

$$f_Y(y) = \frac{\partial}{\partial y}F_Y(y) = \frac{\partial g^{-1}(y)}{\partial y} \cdot \frac{\partial F_X\big(g^{-1}(y)\big)}{\partial g^{-1}(y)} = \frac{1}{g'(x^*)} f_X(x^*),$$

که در آن از مشتق تابع معکوس $\frac{\mathrm{d}g^{-1}(y)}{\mathrm{d}y} = \frac{1}{g'(x^*)}$ استفاده شد. به دلیل فرض اکیداً صعودی بودن تابع، $g' > 0$ و نیازی به قدرمطلق نیست.

اگر g اکیداً نزولی باشد، $F_Y(y) = \mathbb{P}(X \ge g^{-1}(y)) = 1 - F_X(g^{-1}(y))$ و مشتق آن $-\frac{f_X(x^*)}{g'(x^*)} = \frac{f_X(x^*)}{|g'(x^*)|}$ است (چون $g' < 0$). قدرمطلق هر دو حالت را یکجا پوشش می‌دهد. برای g غیریکنوا، دامنه را به بازه‌های یکنوا تقسیم کرده و سهم هر بازه را جمع می‌کنیم.

۵.۱۲ مثال

مثال ۱۲-۳: مربع یک متغیر یکنواخت

فرض کنید متغیر تصادفی X توزیعی یکنواخت بین -2 تا 2 دارد. متغیر تصادفی Y را به صورت $Y = X^2$ تعریف می‌کنیم.

۱. ساپورت Y شامل چه مقادیری است؟

۲. در کدام بخش‌های ساپورت، چگالی احتمال Y خیلی زیاد می‌شود؟ در کدام بخش‌ها کم است؟

۳. چگالی احتمال متغیر تصادفی Y، یعنی $f_Y(y)$ را به دست آورید.

حل. ۱. ساپورت: چون $X \in [-2, 2]$، داریم $Y = X^2 \in [0, 4]$.

۲. شهود: $g'(x) = 2x$ نزدیک $x = 0$ صفر است (شیب کم)؛ پس بازه‌ای از x حول صفر به بازه بسیار کوچکی از y نزدیک صفر فشرده می‌شود و چگالی Y نزدیک $y = 0$ **خیلی زیاد** (حتی بی‌نهایت) است.

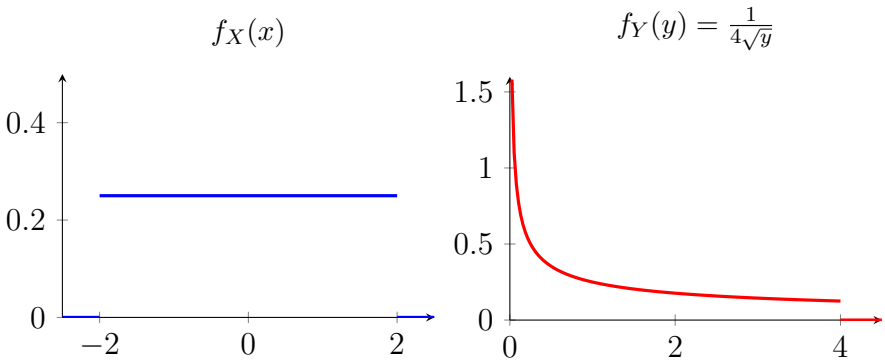
نزدیک $x = \pm 2$ شیب زیاد است ($|g'| = 4$)، پس چگالی Y نزدیک $y = 4$ **کم** است.

۳. محاسبه: $f_X(x) = \frac{1}{4}$ برای $-2 \le x \le 2$. برای $0 < y \le 4$، معادله $x^2 = y$ دو ریشه $x_{1,2} = \pm\sqrt{y}$ دارد و $|g'(x_{1,2})| = 2\sqrt{y}$. طبق فرمول کلی:

$$f_Y(y) = \frac{1}{2\sqrt{y}} \cdot \frac{1}{4} + \frac{1}{2\sqrt{y}} \cdot \frac{1}{4} = \frac{1}{4\sqrt{y}}, \qquad 0 < y \le 4,$$

و $f_Y(y) = 0$ در غیر این صورت.

بررسی: $\int_0^4 \frac{\mathrm{d}y}{4\sqrt{y}} = \frac{1}{4}\big[2\sqrt{y}\big]_0^4 = \frac{1}{4} \times 4 = 1$ ✓. همچنین $F_Y(y) = \mathbb{P}(|X| \le \sqrt{y}) = \frac{2\sqrt{y}}{4} = \frac{\sqrt{y}}{2}$ که مشتقش همان $\frac{1}{4\sqrt{y}}$ است. ■



نکته. دقت کنید که $f_Y(y) \to \infty$ وقتی $y \to 0^+$، ولی مساحت زیر آن متناهی (برابر ۱) است ــ نمونه دیگری از اینکه PDF می‌تواند از ۱ بزرگ‌تر شود.

۶.۱۲ تبدیل توزیع‌های مختلف به یکدیگر (Transforming Distributions)

۱.۶.۱۲ تبدیل توزیع‌ها به توزیع یکنواخت

قضیه ۱۲-۴: تبدیل انتگرال احتمال

برای متغیر تصادفی (پیوسته) X با توزیع انباشته دلخواه F_X، می‌توان مشاهده نمود که توزیع $Y = F_X(X)$ به صورت زیر محاسبه خواهد شد:

$$f_Y(y) = \frac{f_X\big(F_X^{-1}(y)\big)}{F_X'\big(F_X^{-1}(y)\big)} = \mathbb{1}(0 \le y \le 1).$$

لذا Y یک توزیع یکنواخت بین صفر و یک خواهد داشت.

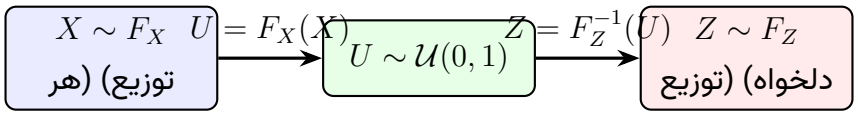
اثبات. $g = F_X$ اکیداً صعودی است (روی تکیه‌گاه) و $g' = F_X' = f_X$. با فرمول تبدیل یک‌به‌یک و $x^* = F_X^{-1}(y)$: $f_Y(y) = \frac{f_X(x^*)}{f_X(x^*)} = 1$ برای $y \in [0,1]$ (برد F_X). روش دوم با CDF: $\mathbb{P}(Y \le y) = \mathbb{P}(F_X(X) \le y) = \mathbb{P}(X \le F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y$. □

۲.۶.۱۲ تبدیل توزیع یکنواخت به سایر توزیع‌ها

قضیه ۱۲-۵: روش تبدیل معکوس

فرض کنید که f_Z, F_Z به ترتیب توابع چگالی و توزیع انباشته یک متغیر تصادفی فرضی مانند Z باشند (دقت کنید که f_Z و F_Z توابعی معلوم و غیرتصادفی هستند). برای متغیر تصادفی Y با توزیع یکنواخت $\mathcal{U}(0,1)$، می‌توان مشاهده نمود که توزیع متغیر تصادفی $F_Z^{-1}(Y)$ با متغیر تصادفی فرضی Z یکسان خواهد بود.

اثبات. $\mathbb{P}\big(F_Z^{-1}(Y) \le z\big) = \mathbb{P}\big(Y \le F_Z(z)\big) = F_Z(z)$، زیرا برای Y یکنواخت $\mathbb{P}(Y \le u) = u$. پس CDF متغیر $F_Z^{-1}(Y)$ دقیقاً F_Z است. □



یعنی توزیع یکنواخت مانند یک «زبان مشترک» است: با ترکیب دو مرحله، هر توزیع پیوسته را می‌توان به هر توزیع دیگری تبدیل کرد: $Z = F_Z^{-1}(F_X(X))$.

۷.۱۲ چگونگی تولید اعداد تصادفی

کامپیوترها معمولاً تنها یک مولد **شبه‌تصادفی** از اعداد یکنواخت در $[0,1)$ دارند (مثلاً بر پایه «مولد هم‌نهشتی خطی» $s_{k+1} = (a\,s_k + c) \bmod m$ و $u_k = s_k/m$، یا الگوریتم‌های پیشرفته‌تری مانند Mersenne Twister). سؤال: چگونه از این اعداد یکنواخت، نمونه‌هایی از توزیع‌های دیگر (نمایی، گاوسی، ...) تولید کنیم؟ پاسخ همان روش تبدیل معکوس است:

الگوریتم نمونه‌برداری با تبدیل معکوس (Inverse Transform Sampling)

۱. یک عدد u از $\mathcal{U}(0,1)$ تولید کنید.

۲. $z = F_Z^{-1}(u)$ را خروجی دهید.

مثال ۱۲-۶: تولید نمونه نمایی

برای $Z \sim \mathrm{Exp}(\lambda)$ داریم $F_Z(z) = 1 - e^{-\lambda z}$. با حل $u = 1 - e^{-\lambda z}$:

$$z = F_Z^{-1}(u) = -\frac{1}{\lambda}\ln(1-u).$$

چون $1-U$ نیز یکنواخت است، می‌توان از $z = -\frac{1}{\lambda}\ln u$ هم استفاده کرد. مثلاً با $\lambda = 2$ و $u = 0.3$: $z = -\frac{1}{2}\ln 0.7 \approx 0.178$.

مثال ۱۲-۷: تولید نمونه گسسته

برای متغیر گسسته (مثلاً تاس)، تبدیل معکوس یعنی: $[0,1)$ را به بازه‌هایی با طول $p_1, p_2, \dots$ تقسیم کنید و اگر u در بازه iام افتاد، مقدار x_i را برگردانید. برای تاس سالم: $x = \lfloor 6u \rfloor + 1$.

نکته. برای گاوسی، F^{-1} شکل بسته ندارد؛ در عمل از روش‌های دیگری مانند **تبدیل باکس–مولر** استفاده می‌شود: اگر U_1, U_2 یکنواخت و مستقل باشند، $Z = \sqrt{-2\ln U_1}\cos(2\pi U_2)$ گاوسی استاندارد است (این نتیجه از تبدیل دو متغیره به دست می‌آید که در جلسات بعد می‌بینیم).

۸.۱۲ تمرین‌های تکمیلی

تمرین ۱۲-۸

اگر $X \sim \mathcal{U}(0,1)$، چگالی $Y = -\ln X$ را بیابید.

حل. $g(x) = -\ln x$ روی $(0,1)$ اکیداً نزولی است و برد آن $(0,\infty)$. $x^* = e^{-y}$ و $|g'(x^*)| = \frac{1}{x^*} = e^{y}$. پس $f_Y(y) = \frac{1}{e^y}\cdot 1 = e^{-y}$ برای $y > 0$؛ یعنی $Y \sim \mathrm{Exp}(1)$ (همان نتیجه روش تبدیل معکوس). ■

تمرین ۱۲-۹

اگر $X \sim \mathcal{N}(0,1)$، چگالی $Y = e^X$ را بیابید (توزیع لاگ‌نرمال).

حل. $x^* = \ln y$ و $g'(x^*) = e^{x^*} = y$. پس برای $y > 0$: $f_Y(y) = \frac{1}{y}\cdot\frac{1}{\sqrt{2\pi}}e^{-(\ln y)^2/2}$ ــ همان لاگ‌نرمال جلسه هفتم با $\mu = 0, \sigma = 1$. ■

تمرین ۱۲-۱۰

اگر $X \sim \mathcal{U}(0,\pi)$، چگالی $Y = \sin X$ را بیابید.

حل. برد: $Y \in [0,1]$. برای $0 < y < 1$ دو ریشه دارد: $x_1 = \arcsin y$ و $x_2 = \pi - \arcsin y$؛ در هر دو $|g'| = |\cos x| = \sqrt{1-y^2}$. پس $f_Y(y) = 2\cdot\frac{1}{\pi}\cdot\frac{1}{\sqrt{1-y^2}} = \frac{2}{\pi\sqrt{1-y^2}}$، $0 < y < 1$. (بررسی: $\int_0^1 \frac{2}{\pi\sqrt{1-y^2}}\,dy = \frac{2}{\pi}\cdot\frac{\pi}{2} = 1$.) ■

تمرین ۱۲-۱۱

یک الگوریتم برای تولید نمونه از توزیعی با چگالی $f(z) = 2z$ روی $[0,1]$ بنویسید.

حل. $F(z) = z^2$، پس $F^{-1}(u) = \sqrt{u}$. الگوریتم: $u \sim \mathcal{U}(0,1)$ تولید کن و $z = \sqrt{u}$ را برگردان. (معادلاً $\max(U_1, U_2)$ برای دو یکنواخت مستقل نیز همین توزیع را دارد، چون $\mathbb{P}(\max \le z) = z^2$.) ■